Riassunto della tesi

Rilevamento unsupervised di anomalie meteorologiche con reti generative avversarie spazio-temporali

Candidato: Alberto Pedalino (s334042)
Relatore: Simone Monaco
Politecnico di Torino
Laurea Magistrale in Ingegneria Informatica – Ingegneria del software – A.A. 2025/2026

1 Introduzione e motivazione

Le anomalie meteorologiche, cioè le condizioni dell'atmosfera lontane da quelle abituali per il luogo e il periodo dell'anno, sono i casi in cui i modelli addestrati su dati storici, come i previsori della produzione fotovoltaica da cui il lavoro è partito, tendono a sbagliare di più. La rianalisi ERA5, una ricostruzione dello stato passato dell'atmosfera, offre campi meteorologici completi, su una griglia regolare, per oltre quarant'anni, ma senza etichette di anomalia.

Il compito ha tre difficoltà. Senza etichette il rilevamento è *unsupervised* e la valutazione indiretta. Gli anni di addestramento non sono garantiti privi di anomalie meteorologiche, quindi si cercano le condizioni nuove rispetto a quel periodo. Infine ciò che è normale cambia con il luogo e la stagione, e su una griglia non è dato quali punti siano collegati.

La tesi parte da STGAN, una rete generativa avversaria spazio-temporale proposta per il traffico stradale, dove i punti sono collegati dalle strade; il suo score somma l'errore di ricostruzione del generatore e la componente del discriminatore. La tesi non propone un algoritmo nuovo: adatta STGAN ai campi ERA5 e si chiede se le due componenti segnalino gli stessi valori, cioè le stesse coppie cella–istante, e quale delle due usare.

2 Metodologia

Il rilevatore ricostruisce ogni istante del campo a partire dalle ore precedenti e segnala i valori che ricostruisce molto peggio del solito per quel luogo e quel periodo dell'anno.

2.1 Adattamento di STGAN ai campi su griglia

Il generatore stima l'intero campo in un solo passaggio e unisce cella per cella tre rami: il ramo recente legge gli ultimi campi con una ConvGRU, che sostituisce la convoluzione su grafo dell'articolo di STGAN; il ramo del trend legge con una LSTM una serie più lunga di ogni cella; il ramo del calendario riceve l'ora solare locale e il periodo dell'anno. Il discriminatore giudica la patch 3×3 di ogni cella, osservata o ricostruita, con un valore fra 0 (reale) e 1 (generata). Il dropout Monte Carlo resta attivo nelle due reti anche dopo l'addestramento: ogni istante è calcolato 20 volte, ognuna con una diversa maschera di dropout (un'*estrazione*); la media delle estrazioni dà il valore usato, la loro deviazione standard la *dispersione*.

2.2 Normalizzazione stagionale e pesi delle variabili

Ogni variabile è standardizzata con media e deviazione standard della stessa cella e ora, stimate sugli anni di addestramento nei 15 giorni prima e dopo ogni giorno dell'anno: il modello legge così lo scarto standardizzato, cioè di quante deviazioni standard ogni valore si allontana dal suo normale, non il ciclo stagionale e giornaliero. Con il solo min–max dell'articolo, la copertura nuvolosa produrrebbe l'84% della variazione su 24 ore di tutte le variabili e dominerebbe l'errore. Nell'errore di ricostruzione del generatore, inoltre, ogni variabile pesa in proporzione inversa alla sua variazione abituale su 24 ore, così che ciascuna sia misurata in rapporto a quanto cambia.

2.3 Score del rilevatore e soglia

Dalla stessa esecuzione si ricavano due componenti. G è l'errore di ricostruzione del generatore, cioè quanto il campo ricostruito si allontana da quello osservato. D, la componente del discriminatore, è la differenza fra il giudizio sull'osservazione, D_{reale}, e quello sulla ricostruzione, D_{generato}: come per G, una D alta indica un valore più insolito. G non è confrontabile fra luoghi e stagioni, perché a sud e d'estate è alto per natura. Lo score del rilevatore, G_{n}, dice di quante deviazioni standard G supera il suo valore abituale nella stessa cella, alla stessa ora e nello stesso periodo dell'anno. È l'idea della normalizzazione stagionale applicata a G anziché agli ingressi; questa normalizzazione climatologica è stimata sugli anni di validazione, perché su quelli di addestramento G è più basso. Un valore è segnalato quando G_{n} supera il 95-esimo percentile degli anni di validazione. Lo score combinato dell'articolo, somma di G e D riportati su una scala comune, è calcolato solo per confronto; la scelta di G_{n} è motivata nella Sezione 4.1.

3 Impostazione sperimentale

I dati sono 15 variabili ERA5 in superficie e a 850 hPa, ogni 3 ore, su 10 611 celle di 0.5° che coprono l'Europa, il Mediterraneo e parte dell'Africa settentrionale e del Medio Oriente. Gli anni 1980–1999 servono all'addestramento, i 2000–2004 alla validazione; gli anni di test, 2005–2025, non entrano in nessuna scelta.

Senza etichette, la configurazione è scelta con la distanza MMD fra campi ricostruiti e osservati degli anni di validazione, vicina a zero quando le due distribuzioni coincidono. Si usano solo campi di tempo ordinario, cioè con pochi valori insoliti secondo un criterio che non usa il modello. Su 29 prove di una ricerca bayesiana dei quattro iperparametri dell'addestramento avversario, la configurazione scelta ha la distanza più bassa.

G_{n} è confrontato con otto baseline, ciascuna con la propria normalizzazione climatologica e soglia. Due non hanno modello: la distanza dal normale, cioè l'errore che si commetterebbe rispondendo in ogni cella con il valore normale per quel giorno e quell'ora, e la variazione in tre ore, l'errore che si commetterebbe rispondendo con il valore di tre ore prima. Sei sono modelli shallow (PCA, CBLOF, MCD, HBOS, COPOD, Isolation Forest). I modelli shallow e la distanza dal normale leggono una cella in un istante, cioè le sue quindici variabili; nessuna baseline legge le celle vicine.

4 Risultati e discussione

4.1 Generatore e discriminatore non concordano

Sugli anni di validazione G e D ordinano i luoghi quasi senza legame: la correlazione di Spearman, calcolata in ogni istante sulle celle, vale in media 0.015. Le segnalazioni di G_{n} a contatto nello spazio e nel tempo formano cluster di segnalazioni: il *nucleo* è formato dalle celle del cluster in un istante, la *zona lontana* dalle celle a più di tre celle da ogni nucleo. In ogni zona ogni score è riassunto dal suo percentile mediano fra tutti i suoi valori degli anni di validazione, da 0 a 100: senza legame con i cluster sarebbe 50. Nel nucleo il percentile mediano di D_{reale} è 5, contro 58 nella zona lontana: il discriminatore giudica l'osservazione e la ricostruzione più reali del consueto, anche se in valore assoluto i giudizi cambiano di poco. D supera la propria soglia, anch'essa al 95-esimo percentile, nel **25%** dei valori del nucleo, contro il 2.9% della zona lontana: segnala di più nel nucleo, ma solo un valore su quattro. Dove G_{n} segnala, quindi, D in genere non segnala. Sugli anni di test le correlazioni cambiano di al più tre centesimi.

Lo score combinato dell'articolo ordina i valori quasi come D (Spearman **0.99**, contro 0.13 con G): sommare le due componenti mescola due segnali in disaccordo e, di fatto, equivale a usare D. Poiché G ha un significato chiaro, quanto un campo si allontana da ciò che il modello si aspetta, mentre il comportamento di D si spiega solo in parte, il rilevatore usa G_{n}. La normalizzazione

rende quasi uniforme la percentuale di valori segnalati: sugli anni di validazione, per fascia di latitudine e mese, senza normalizzazione va dall'1.6% (50–60°N, dicembre) all'11.1% (20–30°N, agosto); con essa resta fra il **3.7%** e il **6.3%**, contro il 5% atteso.

4.2 Confronto con le baseline

Il confronto è un controllo di coerenza, non una misura di accuratezza: senza etichette, l'accordo non dice quale metodo abbia ragione. Sugli anni di test i metodi che leggono una cella in un istante segnalano in larga parte gli stessi valori, mentre la variazione in tre ore ne segnala soprattutto altri. G_{n} si sovrappone a entrambi senza coincidere con nessuno: la variazione in tre ore segnala il **54%** dei valori segnalati da G_{n}, ciascuno dei metodi che leggono una cella in un istante fra il 39% e il 52%, contro il 5% atteso fra metodi indipendenti. Il 18.1% delle segnalazioni di G_{n} non è segnalato da nessuna baseline: può indicare ciò che solo il generatore coglie, per esempio perché legge le celle vicine, oppure un suo errore. Nel nucleo, infine, solo il 41% dei valori supera la soglia della distanza dal normale: G_{n} segnala anche valori che, presi uno per uno, non sono fra i più lontani dal normale.

4.3 Cluster, dispersione e soglia

Sugli anni di test lo 0.5% dei cluster, quelli con almeno 1000 valori, contiene il 75.5% dei valori segnalati. Sono per lo più catene, cioè successioni di gruppi di segnalazioni ciascuno a contatto con il seguente, più che singole anomalie meteorologiche. Accade con tutti i metodi: nei loro cluster con almeno 1000 valori sta fra il 60% e l'86% dei valori segnalati. Il tipo di un cluster è la variabile che vi si allontana di più dal normale: i cluster di tipo velocità verticale o precipitazione contengono il 61% dei valori segnalati.

Quanto alla dispersione, il 75% dei valori segnalati resta sopra la soglia anche togliendo a G_{n} una volta la dispersione: tre segnalazioni su quattro reggono alle maschere di dropout.

Con la soglia al 99-esimo percentile, cioè l'1% dei valori, il comportamento del discriminatore è lo stesso e più marcato e il confronto con le baseline resta simile; la normalizzazione invece riduce meno le differenze fra luoghi e stagioni: sugli anni di validazione 1.4% fra 20 e 30°N, 0.7% fra 50 e 60°N, contro l'1% atteso.

4.4 Anomalie meteorologiche note

5 Conclusioni

5.1 Sintesi dei risultati

5.2 Limiti

5.3 Sviluppi futuri