Politecnico di Torino

Laurea Magistrale in Computer Engineering – Artificial Intelligence and Data Analytics

A.A. 2025/2026

Sessione di laurea [mese e anno]

[Titolo della tesi]

Relatore:
Simone Monaco

Candidato:
Alberto Pedalino

Indice

Elenco delle figure **v**

1 Introduzione **1**
1.1 Contesto e motivazioni 1
1.2 Il problema: anomalie meteorologiche senza etichette 2
1.3 Obiettivi e contributi della tesi 2
1.4 Organizzazione del documento 3

2 Fondamenti teorici e stato dell'arte **4**
2.1 Rilevamento di anomalie in serie multivariate e spazio-temporali 4
2.1.1 MTGFlow 5
2.1.2 Reti generative avversarie per il rilevamento di anomalie 6
2.1.3 STGAN 7
2.1.4 Alternative considerate: CATCH e M2AD 9
2.2 Contesto spaziale su griglie e grafi 10
2.2.1 Unità ricorrenti convoluzionali 10
2.2.2 Reti su grafo e Graph Attention Network 11
2.2.3 Dall'articolo alla tesi: le varianti di STGAN 12
2.3 Quantificazione dell'incertezza 13
2.3.1 Monte Carlo Dropout e Deep Ensemble 13
2.3.2 Equazioni differenziali stocastiche neurali 14
2.3.3 SDE-Net 16
2.3.4 SDE U-Net 16
2.4 Posizionamento del lavoro 17
2.4.1 Il contributo sostenuto 17
2.4.2 Confronto dei detector esaminati 18

3 Dati e preprocessing **19**
3.1 Serie PVGIS, località geografiche e target 19
3.2 Feature, trasformazioni fisiche e normalizzazione 21

3.3 Finestre temporali, split cronologici e previsione diretta multiorizzonte . . . 22
3.4 Campi ERA5, allineamento e celle valide . . . 22

4 Metodologia **25**
4.1 Panoramica del percorso metodologico . . . 25
4.2 Backbone BiLSTM–GAT . . . 26
4.2.1 Tensori di input, encoder temporale e attention pooling 26
4.2.2 Grafo geografico Haversine . . . 26
4.2.3 Teste di previsione, funzione di perdita e training . . . 27
4.3 Soglie climatologiche . . . 27
4.4 Esperimenti probabilistici preliminari . . . 28
4.4.1 Enhanced Monte Carlo Dropout . . . 29
4.4.2 Deep Ensemble di modelli addestrati indipendentemente 29
4.4.3 Previsioni medie, dispersione e intervalli empirici . . . 29
4.5 Variante SDE U-Net . . . 30
4.5.1 Backbone paralleli di drift e diffusione . . . 30
4.5.2 Perturbazioni Browniane negli stadi BiLSTM e GAT . 30
4.5.3 Training alternato, pseudo-OOD e inferenza a traiettorie 31
4.6 Variante SDE-Net . . . 31
4.6.1 Campo di drift, diffusione e integrazione Euler–Maruyama 31
4.6.2 Testa gaussiana, negative log-likelihood e training . . . 32
4.6.3 Campionamento e componenti dell'incertezza predittiva 32
4.7 Rilevamento delle anomalie climatiche con MTGFlow . . . 33
4.7.1 Serie storiche per località, variabili climatiche e finestre 33
4.7.2 Grafo dinamico tra entità e normalizing flow condizionale 33
4.7.3 Score aggregato della località, score per variabile e soglie IQR . . . 34
4.7.4 Modelli indipendenti per località e assenza di message passing geografico . . . 35
4.8 STGAN su PVGIS: versione su grafo e variante a griglia . . . 35
4.8.1 Contesto spaziale e architettura GCGRU–LSTM . . . 35
4.8.2 Variante ConvGRU–LSTM e gestione delle celle assenti 36
4.8.3 Ablazione del kernel e supporto spaziale osservato . . . 37
4.8.4 Training avversario, anomaly score e soglia globale . . . 38
4.8.5 Campionamento e riproducibilità del calcolo . . . 38
4.9 Estensione a ERA5 ed estrazione degli eventi . . . 39
4.9.1 Adattamento del detector alla cadenza trioraria . . . 39
4.9.2 Soglia, morfologia e cluster spaziali . . . 39
4.9.3 Collegamento temporale, separazioni e fusioni . . . 40

4.10 STGAN su ERA5: score Monte Carlo e varianti ConvGRU e GAT-GRU . . . 40
4.10.1 Dropout nel generatore e campionamento dello score . 41
4.10.2 Split di validation e bilanciamento dell'addestramento avversario . . . 42
4.10.3 Finestra recente, codifica temporale ciclica e normalizzazione stagionale . . . 42
4.10.4 Monitoraggio senza etichette e spazio PCA di riferimento 43
4.10.5 Generatore GAT-GRU sul grafo della griglia . . . 45
4.10.6 Variante convoluzionale sul campo intero . . . 46
4.10.7 Incertezza negli eventi e normalizzazione climatologica degli score . . . 47

5 Esperimenti **49**
5.1 Percorso degli esperimenti . . . 49
5.2 Configurazioni di addestramento . . . 50
5.3 Protocollo di valutazione . . . 52
5.4 Metriche . . . 52

6 Risultati e discussione **54**
6.1 Accuratezza del forecasting . . . 54
6.1.1 Enhanced Monte Carlo Dropout . . . 54
6.1.2 Deep Ensemble . . . 54
6.1.3 Variante SDE U-Net . . . 54
6.1.4 Variante SDE-Net e previsione diretta multiorizzonte . 54
6.2 Quantificazione dell'incertezza . . . 54
6.2.1 Intervalli dell'Enhanced Monte Carlo Dropout . . . 54
6.2.2 Intervalli e disaccordo tra membri del Deep Ensemble . 54
6.2.3 Intervalli delle due varianti SDE . . . 54
6.3 Rilevamento delle anomalie con MTGFlow, STGAN e ConvGRU 55
6.3.1 Score e distribuzione spazio-temporale delle anomalie . 55
6.3.2 Soglie IQR, top-K e confronto fra grafo e griglia . . . 55
6.3.3 Stabilità delle decisioni al variare del modello . . . 55
6.4 Analisi post-hoc forecasting–anomalie . . . 57
6.4.1 MAE e RMSE sui campioni normali e anomali . . . 57
6.4.2 Confronto a una e sei ore e quattro casi input–target . 57
6.4.3 Errore in funzione della soglia e bande di dispersione . 57
6.4.4 Errori per tipo e direzione dell'estremo meteorologico . 57
6.5 Anomalie ed eventi geografici su ERA5 . . . 57
6.5.1 Copertura dei dati e configurazione del detector . . . 57
6.5.2 Score Monte Carlo e dispersione . . . 57

6.5.3 Monitoraggio per epoca e selezione delle configurazioni 57
6.5.4 Confronto fra generatore ConvGRU e GAT e fra unità di training 57
6.5.5 Cluster spaziali, traiettorie e sensibilità del postprocessing 57
6.6 Confronto progressivo degli esperimenti 57
6.6.1 Accuratezza puntuale 57
6.6.2 Copertura e ampiezza degli intervalli 57
6.6.3 Costo computazionale e complessità dei modelli 57

7 Conclusioni e sviluppi futuri 58
7.1 Il problema affrontato 58
7.2 Sintesi dei risultati 58
7.3 Limiti dello studio 58
7.4 Sviluppi futuri 58

Bibliografia 59

Elenco delle figure

2.1 Schema di STGAN. Il generatore combina tre moduli e produce la stima $\hat{X}_{v,t}$, che sostituisce l'ultimo elemento della sequenza reale; il discriminatore valuta entrambe le sequenze. Lo score somma l'errore di previsione e la differenza fra le due uscite del discriminatore. Ridisegnato a partire da Deng et al. [2]. . . 7

2.2 Intorno di una cella nelle due varianti. A sinistra la convoluzione assegna a ogni vicino un peso legato alla sua posizione. A destra l'attenzione su grafo assegna a ogni arco un coefficiente α_{ij} che dipende dalle feature dei nodi collegati: lo spessore delle frecce ne rappresenta un esempio. 13

2.3 Cinque traiettorie di un'equazione differenziale stocastica lineare con lo stesso drift e due valori della diffusione, integrate con lo schema di Euler–Maruyama. La dispersione fra le traiettorie è la quantità da cui SDE-Net ricava l'incertezza epistemica. Simulazione illustrativa sul modello della figura analoga di Kong et al. [3]; non è un risultato della tesi. 15

3.1 Le 1149 località dei dati PVGIS. Ogni punto è una posizione del reticolo con passo di 5 km per la quale sono disponibili le serie orarie. 20

Capitolo 1

Introduzione

1.1 Contesto e motivazioni

La produzione di un impianto fotovoltaico dipende dalle condizioni meteorologiche: irradianza, temperatura e vento ne determinano l'andamento, dalle variazioni entro la giornata a quelle stagionali. La gestione di una rete con una quota crescente di fotovoltaico richiede quindi previsioni della produzione, possibilmente accompagnate da una misura della loro incertezza [1].

Un previsore addestrato su dati storici è affidabile nelle condizioni che quei dati rappresentano bene. Le condizioni meteorologiche poco frequenti, o mai osservate, sono quelle in cui l'errore di previsione può crescere e in cui una stima dell'incertezza è più utile. Riconoscerle è un problema a sé, distinto dalla previsione: richiede di stabilire, per ogni località e ogni istante, quanto le condizioni osservate si discostano da quelle abituali. È il compito del rilevamento di anomalie, a cui questa tesi è dedicata.

Il lavoro considera due insiemi di dati. Il primo è costituito da serie orarie PVGIS, con la produzione fotovoltaica teorica e le variabili meteorologiche di un insieme di località. Su questi dati il rilevamento è collegato a un previsore della produzione. I dati PVGIS contengono però soltanto le grandezze che determinano la produzione fotovoltaica: irradianza, temperatura e vento. Un'anomalia rilevata su questi dati non può essere ricondotta a una condizione meteorologica più generale. Per rilevare anomalie di tipo diverso e descriverne l'origine il lavoro passa quindi al secondo insieme: i campi della rianalisi ERA5, con quindici variabili su una griglia regolare e passo di tre ore, sui quali il rilevamento è studiato come problema autonomo, su un dominio più ampio.

1.2 Il problema: anomalie meteorologiche senza etichette

Tre caratteristiche dei dati rendono il problema difficile e guidano le scelte dei capitoli successivi.

La prima è l'assenza di etichette. Non esiste un elenco di osservazioni meteorologiche anomale con cui addestrare un classificatore o misurare direttamente l'accuratezza di un detector. Il rilevamento deve essere non supervisionato e la sua valutazione deve ricorrere a strumenti indiretti.

La seconda è che i dati di training non sono garantiti privi di anomalie. Molti detector apprendono il comportamento normale da un insieme che si assume pulito; con dati meteorologici non etichettati questa ipotesi non è verificabile. Ne segue una scelta di obiettivo: rilevare le condizioni nuove rispetto al periodo di training, trattando come già osservate quelle che il modello ha incontrato durante l'addestramento.

La terza è la struttura spaziale. Le condizioni di una località dipendono da quelle delle località vicine, e un valore insolito in un punto può essere ordinario se considerato nel suo intorno. I dati non hanno però una topologia fisica, come una rete stradale: sono disposti su un insieme di siti o su un reticolo regolare, e il modo di rappresentare l'intorno va scelto.

Il termine anomalia indica in questa tesi un'osservazione che si discosta da quanto il modello ha appreso dal periodo di training. Un evento meteorologico estremo è un caso particolare di anomalia, ma non ogni anomalia è un evento estremo.

1.3 Obiettivi e contributi della tesi

L'obiettivo della tesi è rilevare condizioni meteorologiche anomale in dati privi di etichette e dotati di struttura spaziale, e usare le decisioni del detector per esaminare il comportamento di un previsore fotovoltaico probabilistico. I due compiti restano distinti: il detector assegna uno score alle osservazioni meteorologiche, il previsore stima la produzione futura. La tesi non propone un nuovo algoritmo di rilevamento: adatta e combina componenti esistenti. I contributi sono i seguenti.

- L'adattamento di STGAN [2], un detector avversario spazio-temporale nato per il traffico, a variabili meteorologiche prive di topologia fisica, in due varianti che rappresentano l'intorno di una cella con una convoluzione su griglia oppure con l'attenzione su grafo.

- La definizione dell'obiettivo come rilevamento di condizioni nuove rispetto al periodo di training, con uno score continuo e una quota di osservazioni segnalate che è un parametro del protocollo.
- Tre estensioni del detector sui campi ERA5: uno score Monte Carlo con una misura di dispersione, un monitoraggio dell'addestramento privo di etichette e la ricostruzione di eventi geografici a partire dagli score.
- L'analisi degli errori e degli intervalli di un previsore fotovoltaico probabilistico, costruito sullo schema di SDE-Net [3], rispetto alle decisioni dei detector.

Le varianti architetturali costituiscono confronti da valutare sperimentalmente; la loro implementazione non implica un miglioramento delle prestazioni.

Il lavoro procede in tre passi. Le prime etichette sono soglie climatologiche: un'osservazione è segnalata quando il suo valore esce dalla banda fra i quantili 0.025 e 0.975 della distribuzione storica della stessa località e della stessa ora. Queste etichette servono a esaminare il previsore sulle osservazioni segnalate e ad addestrarlo sulle sole finestre normali. Per individuare anomalie di altro tipo il lavoro passa poi a detector appresi, MTGFlow [4] e STGAN. Infine, poiché i dati PVGIS contengono soltanto irradianza, temperatura e vento, il detector è portato sui campi ERA5. Il percorso è descritto per esteso nel Capitolo 5.

1.4 Organizzazione del documento

Il Capitolo 2 presenta i fondamenti teorici e i lavori su cui la tesi è costruita, indicando per ciascuno ciò che propone, ciò che non copre e ciò che la tesi ne riprende. Il Capitolo 3 descrive i dati e la loro preparazione. Il Capitolo 4 presenta i modelli e i loro adattamenti. Il Capitolo 5 descrive il percorso degli esperimenti, le configurazioni confrontate e il protocollo di valutazione. Il Capitolo 6 riporta e discute i risultati. Il Capitolo 7 riassume il lavoro, ne indica i limiti e gli sviluppi futuri.

Capitolo 2

Fondamenti teorici e stato dell'arte

Il capitolo presenta i fondamenti teorici e i lavori su cui la tesi è costruita. Per ciascun lavoro di riferimento sono indicati ciò che propone e ciò che non copre, quindi ciò che la tesi ne riprende e il modo in cui ne affronta i limiti. I modelli di uso generale impiegati come componenti sono richiamati nella sezione in cui servono. La trattazione segue l'ordine dei temi del lavoro: il rilevamento delle anomalie, il contesto spaziale su griglie e grafi, la quantificazione dell'incertezza, per lo score dei detector e per il previsore. L'ultima sezione riassume la posizione della tesi rispetto a questi lavori.

2.1 Rilevamento di anomalie in serie multivariate e spazio-temporali

I metodi di rilevamento di anomalie in serie multivariate basati su reti profonde sono comunemente distinti secondo il segnale da cui ricavano lo score. Wu et al. li classificano in metodi basati su previsione, su ricostruzione e su apprendimento contrastivo [5]. Alnegheimish et al. distinguono in modo analogo modelli di predizione e di ricostruzione, e osservano che molti di essi costruiscono uno score senza definire in modo appropriato la soglia [6]. Zhou et al. mettono in evidenza un'ipotesi comune a gran parte di questi lavori, cioè la disponibilità di un training composto da sole osservazioni normali: quando il training contiene anomalie le prestazioni possono degradare sensibilmente, e la stima della densità dell'intero insieme di training è proposta come alternativa [4].

I lavori esaminati in questa sezione si collocano lungo queste distinzioni: MTGFlow appartiene alla stima di densità, STGAN all'approccio avversario,

che combina l'errore di previsione con il giudizio di un discriminatore, CATCH alla ricostruzione e M2AD alla predizione con uno score aggregato. Due criteri guidano il confronto: la tolleranza alla presenza di anomalie nel training e la rappresentazione del contesto spaziale fra località. Il primo ha portato alla scelta di MTGFlow e all'esclusione di CATCH e M2AD; il secondo al passaggio a STGAN, che offre il contesto spaziale ma non la stessa tolleranza.

2.1.1 MTGFlow

Zhou et al. [4] affrontano il rilevamento di anomalie in serie multivariate senza assumere che i dati di training siano tutti normali. Il metodo stima la densità dell'intero insieme di training e identifica come anomale le osservazioni di test a bassa densità, sotto l'ipotesi che le anomalie occupino regioni più sparse. Le dipendenze fra entità sono apprese come grafo dinamico e un normalizing flow specifico per entità associa a ciascuna una distribuzione normale parametrizzata. La soglia è ricavata dall'intervallo interquartile degli score di training e lo score per entità consente di localizzare l'anomalia. Le entità sono i sensori o le variabili di un unico sistema e la valutazione usa dataset pubblici di riferimento: il grafo è appreso dai dati e descrive relazioni fra variabili, non fra siti geografici distinti. Un'estensione assegna una distribuzione comune alle entità di uno stesso gruppo, quando è noto che hanno caratteristiche simili. Il raggruppamento esprime soltanto che certe entità possono comportarsi allo stesso modo: non modella vicinanza, distanze o propagazione nello spazio, e non rende il metodo un detector spazio-temporale.

MTGFlow è stato scelto per la sua robustezza alla presenza di anomalie nei dati di training: per le condizioni meteorologiche non sono disponibili etichette, quindi non è possibile garantire un training composto da sole osservazioni normali. La tesi implementa la versione base, senza l'estensione a gruppi, e la applica alle tre variabili climatiche di ogni località, trattate come entità. Poiché il metodo non rappresenta il contesto geografico, viene addestrato un modello indipendente per località: gli score possono essere confrontati sulla mappa, ma il modello non apprende relazioni fra località. Per introdurre anche una componente spaziale, il lavoro è quindi passato a STGAN. La soglia interquartile dell'articolo è mantenuta come protocollo di base e affiancata da una variante esplorativa a budget globale.

2.1.2 Reti generative avversarie per il rilevamento di anomalie

Una rete generativa avversaria [7] addestra insieme due reti con obiettivi opposti. Il generatore G trasforma un rumore z, estratto da una distribuzione nota p_z, in un campione $G(z)$; i dati reali seguono la distribuzione p_{data} e il discriminatore D restituisce la probabilità $D(x)$ che un campione x provenga dai dati reali anziché dal generatore. Le due reti sono addestrate sulla stessa funzione, che il discriminatore massimizza e il generatore minimizza:

$$\min_G \max_D V(D,G) = \mathbb{E}_{x\sim p_{\text{data}}}\Big[\log D(x)\Big] + \mathbb{E}_{z\sim p_z}\Big[\log\Big(1 - D(G(z))\Big)\Big]. \quad (2.1)$$

Il primo termine cresce quando il discriminatore riconosce i dati reali, il secondo quando riconosce i campioni generati; il generatore è addestrato a rendere i propri campioni indistinguibili da quelli reali. Entrambe le reti sono ottimizzate con la retropropagazione. Lo stesso articolo osserva che, all'inizio dell'addestramento, il secondo termine fornisce al generatore un gradiente debole, e propone in alternativa di addestrarlo a massimizzare $\log D(G(z))$.

Nel detector avversario adottato in questa tesi lo schema è usato in forma condizionata: il generatore riceve il contesto di un'osservazione e ne produce una stima. L'uso per il rilevamento di anomalie poggia su un'ipotesi di lavoro: che la stima sia accurata nelle condizioni frequenti nei dati di training e meno accurata in quelle poco rappresentate. È un'ipotesi e non una proprietà garantita dall'addestramento. Se vale, se ne ricavano due segnali: lo scarto fra l'osservazione e la stima del generatore, e il giudizio del discriminatore sull'osservazione. STGAN, descritto di seguito, li combina in un unico score.

Rispetto all'equazione (2.1), in STGAN il significato dell'uscita del discriminatore è invertito: le sequenze reali sono trattate come normali e quelle generate come anomale, con valore 0 per le prime e 1 per le seconde. Per il discriminatore l'obiettivo è lo stesso a meno di questo scambio, ma la sua uscita cresce con il sospetto di anomalia e può essere usata per costruire lo score. L'obiettivo del generatore è riportato nell'equazione (2.2): il termine avversario ha la forma alternativa appena descritta, scritta nella convenzione invertita, e a esso si aggiunge un termine di ricostruzione.

L'addestramento richiede un equilibrio fra le due reti: nella tesi i tassi di apprendimento delle due reti, il coefficiente β_1 dei loro ottimizzatori e il numero di aggiornamenti per batch sono parametri configurabili, come descritto nel Capitolo 4.

2.1.3 STGAN

Deng et al. [2] propongono una rete avversaria per il rilevamento di anomalie del traffico. Il generatore prevede la dinamica normale combinando tre componenti: un modulo recente, basato su unità ricorrenti con convoluzione su grafo, per le dipendenze spazio-temporali di breve periodo, un modulo per il trend di lungo periodo e uno per le variabili esterne. Il discriminatore stabilisce se una sequenza è reale o generata in funzione dei vicini nello spazio e nel tempo, fornendo un criterio che varia con località e istante. Dopo l'addestramento avversario entrambe le reti agiscono da detector e uno score ne combina i contributi. Il grafo deriva da una topologia fisica, cioè sensori adiacenti sulla stessa strada o regioni con confini comuni, e la valutazione misura il richiamo rispetto a incidenti ed eventi documentati, che gli autori stessi indicano come verità di riferimento incompleta. Il metodo presuppone quindi una rete di adiacenze nota e produce uno score puntuale, privo di una misura di dispersione; la sua valutazione dipende dalla disponibilità di eventi documentati. L'articolo non discute la presenza di anomalie nei dati di training: il discriminatore è addestrato considerando normali le sequenze reali e anomale quelle generate, quindi l'ipotesi di un training normale è implicita. La Figura 2.1 riassume la struttura del metodo.

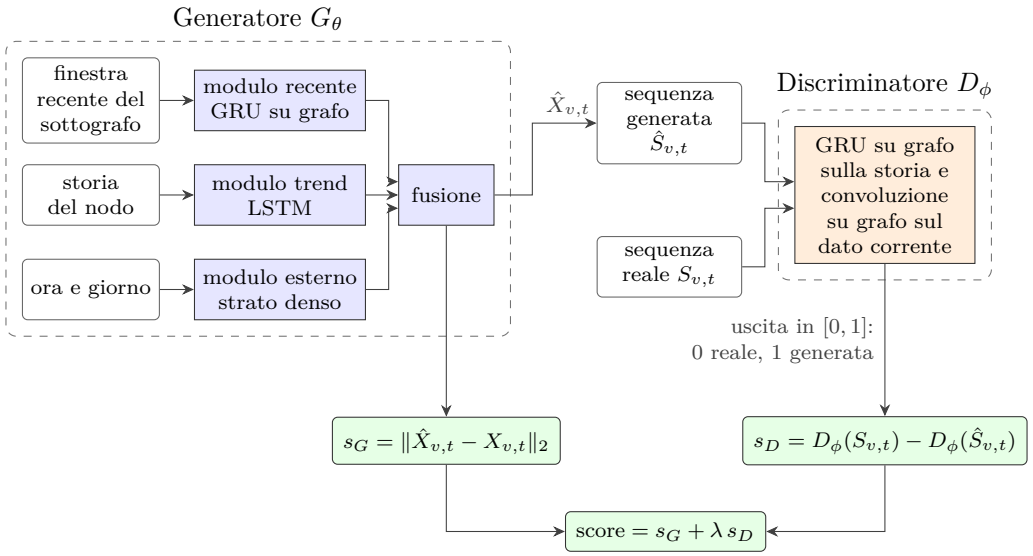


Figura 2.1: Schema di STGAN. Il generatore combina tre moduli e produce la stima $\hat{X}_{v,t}$, che sostituisce l'ultimo elemento della sequenza reale; il discriminatore valuta entrambe le sequenze. Lo score somma l'errore di previsione e la differenza fra le due uscite del discriminatore. Ridisegnato a partire da Deng et al. [2].

Sia $x_{v,t}$ l'osservazione del nodo v all'istante t e $X_{v,t}$ l'insieme delle osservazioni nel sottografo formato da v e dai suoi vicini. Sia poi $S_{v,t}$ la sequenza reale dei valori del sottografo che termina con $X_{v,t}$, e $\hat{S}_{v,t}$ la stessa sequenza in cui l'ultimo elemento è sostituito dalla stima $G_\theta(v,t)$ del generatore. Gli obiettivi di addestramento dell'articolo sono

$$\mathcal{L}_G(\theta) = \sum_s -\log\Big(1 - D_\phi(\hat{S}_{v,t})\Big) + \lambda_G \, \|G_\theta(v,t) - X_{v,t}\|_2, \tag{2.2}$$

$$\mathcal{L}_D(\phi) = \sum_s -\log\Big(D_\phi(\hat{S}_{v,t})\Big) - \log\Big(1 - D_\phi(S_{v,t})\Big), \tag{2.3}$$

dove la somma è sui punti $s = \langle v, t, x_{v,t}\rangle$ e λ_G bilancia l'errore di previsione e il termine avversario. Il discriminatore è quindi spinto verso 1 sulle sequenze generate e verso 0 su quelle reali. Lo score combina le due reti:

$$\begin{aligned} s_D(v,t) &= D_\phi(S_{v,t}) - D_\phi(\hat{S}_{v,t}), \\ s_G(v,t) &= \|G_\theta(v,t) - X_{v,t}\|_2, \\ \text{score}(v,t) &= s_G(v,t) + \lambda \, s_D(v,t). \end{aligned} \tag{2.4}$$

La componente del discriminatore non è la sua uscita sulla sequenza reale ma la differenza rispetto alla sequenza generata: gli autori la introducono per ridurre l'effetto dell'imprevedibilità dei dati reali. Negli esperimenti dell'articolo $\lambda_G = 500$, le due componenti sono normalizzate e $\lambda = 1$.

La tesi riprende l'architettura a tre rami, gli obiettivi avversari e lo score combinato, e li applica a variabili meteorologiche, per le quali non esiste una topologia fisica. Nella versione su grafo le adiacenze sono sostituite da un criterio di vicinanza geografica. A differenza di MTGFlow, il metodo non tollera per costruzione un training contaminato. La tesi accetta questo limite in cambio del contesto spaziale e lo traduce in una scelta di obiettivo: rilevare condizioni nuove rispetto al periodo di training. Le anomalie presenti negli anni di addestramento sono trattate come già osservate: nella misura in cui il modello le apprende, condizioni simili non vengono segnalate, mentre lo sono quelle poco o per nulla rappresentate in quegli anni. Lo score misura quindi lo scostamento da quanto il modello ha appreso dal periodo di training, non la rarità di una condizione in assoluto. Lo score è continuo e non coincide con la decisione: sono considerate anomale soltanto le osservazioni con score più alto, in una quota che è un parametro del protocollo e viene fatta variare nell'analisi di sensibilità del Capitolo 6. Il termine anomalia è usato in questo senso in tutta la tesi: un evento estremo è un caso particolare di anomalia, ma non ogni anomalia è un evento estremo. Su questa base sono costruite le due varianti descritte nella Sezione 2.2 e tre estensioni comuni, introdotte su ERA5: uno score Monte Carlo che associa a ogni osservazione

una misura di dispersione; un monitoraggio privo di etichette, necessario perché non sono disponibili eventi documentati con cui misurare il richiamo; l'aggregazione degli score in eventi geografici, un passaggio assente nell'articolo. Gli obiettivi di addestramento e lo score, nella forma implementata, sono riportati nella Sezione 4.8: rispetto alle equazioni (2.2)–(2.4), l'errore di previsione vi compare come errore quadratico medio anziché come norma, mentre $\lambda_G = 500$, la differenza fra le uscite del discriminatore e $\lambda = 1$ sono mantenuti. La scelta segue il codice pubblicato dagli autori, che usa l'errore quadratico medio sia nella loss del generatore sia nella componente di ricostruzione dello score, e dimezza la somma dei due termini della loss del discriminatore.

2.1.4 Alternative considerate: CATCH e M2AD

CATCH. Wu et al. [5] propongono un metodo basato su ricostruzione nel dominio della frequenza. Lo spettro è suddiviso in bande, trattate come patch, per cogliere caratteristiche a grana fine; un modulo di fusione dei canali, con un generatore di maschere e un'attenzione mascherata, seleziona per ciascuna banda le correlazioni fra canali ritenute utili e isola quelle irrilevanti. Il metodo mira a rilevare insieme anomalie puntuali e di sottosequenza ed è valutato su dataset reali e sintetici. Lo score di anomalia è l'errore di ricostruzione: il modello impara a ricostruire i pattern normali, e nei dataset sintetici dell'articolo le anomalie sono inserite soltanto nella serie di test. Il caso di anomalie presenti nei dati di training non è trattato. I canali sono le variabili di una serie multivariata: non è prevista una struttura geografica fra serie di siti diversi, e gli autori segnalano che anomalie più lunghe della finestra osservata non vengono colte efficacemente.

CATCH è stato preso in esame come alternativa a MTGFlow e non è stato adottato, per due ragioni. La prima è che richiede un training privo di anomalie: apprende i pattern normali per ricostruzione e l'articolo non considera un training contaminato, mentre in assenza di etichette questa condizione non è verificabile sui dati meteorologici. La seconda è che, come MTGFlow, non rappresenta relazioni fra località geografiche.

M2AD. Alnegheimish et al. [6] considerano serie multivariate provenienti da più sistemi. Un modello LSTM apprende il comportamento atteso dei sensori; i residui fra valori attesi e osservati sono aggregati in uno score globale mediante un modello a mistura gaussiana e una calibrazione Gamma; la soglia è stimata dagli score osservati in training e i sensori sono ordinati per contributo allo score. Il metodo assume che i dati di training siano privi di anomalie e che training e test abbiano andamenti simili; gli autori indicano

come limite il caso in cui la distribuzione cambia, che richiede un nuovo addestramento.

Anche M2AD è stato preso in esame e non adottato, per le stesse due ragioni: assume esplicitamente un training privo di anomalie, ipotesi opposta a quella che ha guidato la scelta di MTGFlow e non verificabile senza etichette, e i suoi sistemi sono insiemi di sensori senza relazione geografica fra loro. A differenza di STGAN, quindi, né CATCH né M2AD offrono il contesto spaziale in cambio dell'ipotesi sul training. Nessuno dei due è stato eseguito sui dati della tesi e non compaiono fra i risultati.

2.2 Contesto spaziale su griglie e grafi

2.2.1 Unità ricorrenti convoluzionali

Le unità ricorrenti a gate, come quella introdotta da Cho et al. [8] e nota come GRU, aggiornano uno stato nascosto mediante gate che regolano quanta parte dello stato precedente conservare e quanta sostituire. Nella forma originaria ingresso e stato sono vettori e i gate sono trasformazioni dense. Quando l'ingresso è un campo disposto su una griglia, le trasformazioni dense possono essere sostituite da convoluzioni, così che lo stato mantenga la struttura spaziale e i parametri siano condivisi fra le posizioni. L'idea è stata proposta per la LSTM nella previsione a breve termine delle precipitazioni [9] e per la GRU nell'apprendimento di rappresentazioni di sequenze video [10]. STGAN applica la stessa idea a un grafo: nel suo modulo recente i prodotti matriciali della GRU sono sostituiti da convoluzioni su grafo [2].

Sia X_s l'ingresso al passo s e H_{s-1} lo stato precedente, entrambi disposti sulla griglia. Uno strato ricorrente convoluzionale a gate calcola

$$R_s = \sigma(W_r * [X_s, H_{s-1}] + b_r)\,, \tag{2.5}$$

$$U_s = \sigma(W_u * [X_s, H_{s-1}] + b_u)\,, \tag{2.6}$$

$$\widetilde{H}_s = \tanh(W_c * [X_s, R_s \odot H_{s-1}] + b_c)\,, \tag{2.7}$$

$$H_s = U_s \odot H_{s-1} + (1 - U_s) \odot \widetilde{H}_s, \tag{2.8}$$

dove σ è la funzione sigmoidale, $*$ una convoluzione spaziale, $\odot$ il prodotto elemento per elemento e $[\cdot,\cdot]$ la concatenazione sui canali. Il gate di reset R_s regola quanto dello stato precedente entra nello stato candidato $\widetilde{H}_s$; il gate di aggiornamento U_s regola quanto dello stato precedente viene conservato. La forma è quella dell'unità su grafo di STGAN, con la convoluzione su grafo sostituita da una convoluzione spaziale.

Con un kernel di lato k e padding $\lfloor k/2 \rfloor$, ogni convoluzione vede le celle entro $\lfloor k/2 \rfloor$ posizioni. Il gate di reset e lo stato candidato applicano due convoluzioni in sequenza, quindi a ogni passo lo stato precedente si propaga fino a $2\lfloor k/2 \rfloor$ posizioni: l'area che influenza una cella cresce con il numero di passi temporali e di strati. La tesi impiega questo operatore nella variante a griglia di STGAN: la Sezione 4.8.2 descrive il trattamento delle celle assenti, che modifica l'ingresso e l'equazione (2.8) ed è l'adattamento specifico di questo lavoro.

2.2.2 Reti su grafo e Graph Attention Network

Una rete su grafo aggiorna la rappresentazione di ogni nodo aggregando quelle dei suoi vicini. Nella Graph Attention Network [11] i pesi dell'aggregazione non sono fissati dalla struttura del grafo: ogni nodo assegna ai propri vicini coefficienti di attenzione calcolati a partire dalle rispettive feature. Il calcolo non richiede operazioni matriciali costose né la conoscenza anticipata dell'intero grafo, e si applica anche a grafi non osservati durante il training. Più teste di attenzione possono operare in parallelo, e i loro risultati sono concatenati oppure mediati.

Sia h_i il vettore di feature del nodo i e $\mathcal{N}(i)$ l'insieme dei suoi vicini, che negli esperimenti dell'articolo comprende il nodo stesso. Uno strato calcola

$$e_{ij} = \mathrm{LeakyReLU}\Big(\mathbf{a}^\top \left[Wh_i \,\|\, Wh_j\right]\Big), \tag{2.9}$$

$$\alpha_{ij} = \frac{\exp e_{ij}}{\sum_{l \in \mathcal{N}(i)} \exp e_{il}}, \tag{2.10}$$

$$h'_i = \sigma\left(\sum_{j \in \mathcal{N}(i)} \alpha_{ij}\, Wh_j\right), \tag{2.11}$$

dove W è una trasformazione lineare condivisa fra i nodi, $\mathbf{a}$ il vettore dei pesi dell'attenzione, $\|$ la concatenazione e σ una non linearità. Il coefficiente α_{ij} esprime l'importanza del nodo j per il nodo i. Con più teste, ciascuna con parametri propri, le uscite sono concatenate negli strati intermedi e mediate nell'ultimo. Lo strato può essere letto come una convoluzione su grafo in cui i pesi dell'aggregazione sono appresi, invece che fissati dalla struttura del grafo.

La tesi impiega questo meccanismo in due punti: nel backbone del previsore, su un grafo geografico con pesi che dipendono dalla distanza, e nei gate dell'unità ricorrente del generatore, nella variante su grafo di STGAN, sul grafo regolare della griglia e senza pesi geografici. Il grafo e la configurazione dell'encoder nel generatore sono descritti nella Sezione 4.10.5.

2.2.3 Dall'articolo alla tesi: le varianti di STGAN

Le due varianti non corrispondono ad articoli distinti: sono adattamenti di STGAN realizzati in questo lavoro. I dati della tesi non hanno una topologia fisica come quella dell'articolo: sono disposti su un reticolo regolare di celle, e le due varianti rappresentano l'intorno di una cella in due modi diversi. Sono riportate qui per chiarire che cosa cambia rispetto all'articolo e quali componenti sono preesistenti.

Variante a griglia: STGAN con ConvGRU. Nell'articolo il contesto spaziale è un grafo, e in assenza di una rete fisica le sue adiacenze devono essere scelte con un criterio di vicinanza. I dati della tesi sono invece disposti su un reticolo regolare, per il quale le posizioni relative dei vicini sono definite. La variante sostituisce quindi la convoluzione su grafo con una ConvGRU su patch geografiche, conservando il ramo LSTM del trend, gli obiettivi avversari e lo score. Rispetto all'articolo aggiunge il trattamento delle celle assenti, con una maschera fornita come canale e l'azzeramento dello stato ricorrente, e un'ablazione dell'ampiezza dei kernel. Nella prima forma un campione è una cella con la propria patch. Su ERA5 l'addestramento in questa forma si è rivelato troppo lento e la variante è stata portata sull'intero campo: il generatore elabora in una sola passata il reticolo completo di un timestamp, mentre il discriminatore continua a giudicare la patch di ogni cella. L'operatore ricorrente convoluzionale non è un contributo della tesi; lo sono il suo impiego in questo detector e la gestione delle celle mancanti.

Variante con attenzione su grafo: STGAN con GAT-GRU. Nell'articolo i pesi fra vicini derivano da adiacenze fissate. La seconda variante definisce il generatore sul grafo dell'intera griglia, con otto vicini per nodo, e mantiene la struttura dell'unità ricorrente dell'articolo: in ciascun gate la convoluzione su grafo, i cui pesi sono fissati dall'adiacenza, è sostituita da uno strato di attenzione su grafo, i cui pesi sono calcolati dalle feature dei nodi. L'operatore agisce quindi sull'ingresso e sullo stato a ogni passo recente, come nell'articolo e nella variante a griglia. L'unità che ne risulta è indicata nel seguito come GAT-GRU, per analogia con la ConvGRU: una GRU i cui gate sono strati di attenzione su grafo. Un campione è un timestamp con tutti i nodi. Il discriminatore resta quello locale a patch: il criterio di giudizio continua a dipendere dall'intorno di ciascun sito, come nell'articolo. Anche qui il meccanismo di attenzione è preesistente; è della tesi il suo inserimento nei gate dell'unità ricorrente di STGAN, con discriminatore locale invariato.

Che cosa distingue le due varianti. Con otto vicini per nodo, uno strato di attenzione e una convoluzione 3×3 osservano le stesse celle e differiscono nel modo di pesarle, come mostra la Figura 2.2. Nella convoluzione il peso di un vicino dipende dalla sua posizione relativa ed è lo stesso in ogni punto del campo e in ogni istante; nell'attenzione dipende dalle feature dei due nodi ed è ricalcolato per ogni cella e ogni istante. In cambio l'attenzione tratta i vicini come un insieme non ordinato e non distingue le direzioni, che la convoluzione invece rappresenta. Poiché in entrambe l'operatore sta dentro i gate, l'ampiezza del contesto è la stessa: l'area che influenza una cella cresce allo stesso modo con il numero di passi recenti. Sul campo intero le due varianti differiscono quindi per il modo di pesare i vicini e, di conseguenza, per il numero di parametri. Mettono a confronto due ipotesi sullo stesso intorno, l'una basata sulla posizione dei vicini e l'altra sul loro stato; quale sia più adatta al rilevamento è una questione sperimentale.

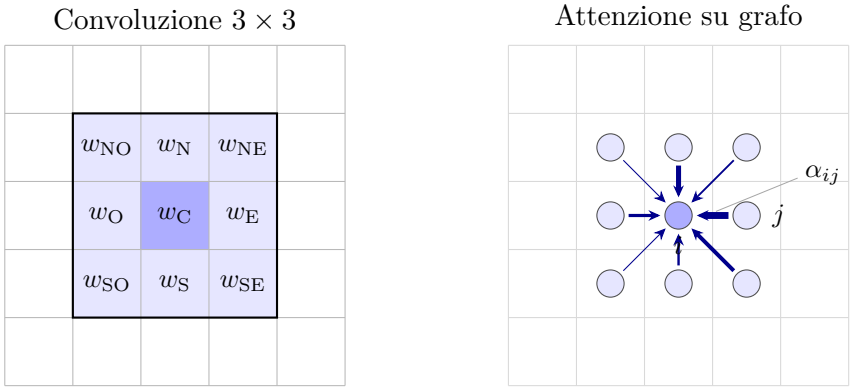


Figura 2.2: Intorno di una cella nelle due varianti. A sinistra la convoluzione assegna a ogni vicino un peso legato alla sua posizione. A destra l'attenzione su grafo assegna a ogni arco un coefficiente α_{ij} che dipende dalle feature dei nodi collegati: lo spessore delle frecce ne rappresenta un esempio.

2.3 Quantificazione dell'incertezza

2.3.1 Monte Carlo Dropout e Deep Ensemble

Gal e Ghahramani [12] interpretano l'addestramento con dropout come un'inferenza bayesiana approssimata. Mantenendo il dropout attivo in previsione

e ripetendo più volte il passaggio in avanti si ottiene un insieme di uscite, la cui dispersione fornisce una stima dell'incertezza del modello con un costo aggiuntivo contenuto. Lakshminarayanan et al. [13] propongono un'alternativa non bayesiana: più reti vengono addestrate in modo indipendente a partire da inizializzazioni diverse e le loro previsioni sono combinate. Il metodo è semplice da realizzare e da eseguire in parallelo, e produce un'incertezza maggiore sugli ingressi lontani dai dati di training.

Nel dropout Monte Carlo, dati J passaggi in avanti $\hat{y}_j(x)$ ottenuti con maschere di dropout diverse, la media predittiva è stimata da

$$\mathbb{E}[y \mid x] \approx \frac{1}{J} \sum_{j=1}^{J} \hat{y}_j(x), \tag{2.12}$$

e la varianza predittiva dalla varianza campionaria dei J passaggi, a cui l'articolo somma l'inverso della precisione del modello. Nei Deep Ensemble ciascuna delle M reti restituisce una media $\mu_m(x)$ e una varianza $\sigma_m^2(x)$ ed è addestrata con la negative log-likelihood gaussiana; l'insieme è trattato come una miscela a pesi uguali, con media e varianza

$$\mu_*(x) = \frac{1}{M} \sum_{m=1}^{M} \mu_m(x), \qquad \sigma_*^2(x) = \frac{1}{M} \sum_{m=1}^{M} \Big(\sigma_m^2(x) + \mu_m^2(x)\Big) - \mu_*^2(x). \tag{2.13}$$

La varianza della miscela è quindi la somma della media delle varianze delle singole reti e della dispersione delle loro medie.

Nella tesi il dropout Monte Carlo ha due impieghi. Il principale riguarda il detector avversario: su ERA5 è applicato al generatore di STGAN, in entrambe le varianti, non per stimare l'incertezza di una previsione ma per campionare lo score di anomalia. Durante lo scoring i dropout del generatore restano attivi e per ogni osservazione sono riportate la media dello score sui campioni, come nell'equazione (2.12), e la sua deviazione standard, come descritto nella Sezione 4.10.1. L'articolo di STGAN non prevede questo passaggio: il suo score è un valore unico per osservazione. In questo impiego la dispersione misura la variabilità dello score rispetto alle maschere di dropout e non costituisce una stima calibrata dell'incertezza; il termine di precisione previsto da Gal e Ghahramani non viene aggiunto. Il secondo impiego riguarda il previsore: dropout Monte Carlo e Deep Ensemble sono usati negli esperimenti preliminari.

2.3.2 Equazioni differenziali stocastiche neurali

Una rete residua aggiorna lo stato sommando a esso una trasformazione dello stato stesso, $x_{t+1} = x_t + f(x_t, t)$. Interpretando l'aggiornamento come un

passo di integrazione, la trasformazione complessiva può essere descritta da un'equazione differenziale ordinaria, $\mathrm{d}x/\mathrm{d}t = f(x, t)$, in cui f è una rete neurale e l'uscita è calcolata da un risolutore numerico [14]. Un modello di questo tipo è deterministico. Aggiungendo un termine di moto browniano si ottiene un'equazione differenziale stocastica,

$$\mathrm{d}x_t = f(x_t, t)\,\mathrm{d}t + g(x_t, t)\,\mathrm{d}W_t, \tag{2.14}$$

in cui f è il drift e g la diffusione, che regola l'ampiezza della componente casuale [3].

In pratica l'equazione è integrata a passi discreti con lo schema di Euler–Maruyama. Dividendo l'intervallo $[0, T]$ in N passi di ampiezza $\Delta t = T/N$, l'aggiornamento è

$$x_{k+1} = x_k + f(x_k, t_k)\,\Delta t + g(x_k, t_k)\sqrt{\Delta t}\,Z_k, \qquad Z_k \sim \mathcal{N}(0, 1) : \tag{2.15}$$

a ogni passo lo stato avanza del drift moltiplicato per l'ampiezza del passo e di un termine gaussiano scalato dalla diffusione e dalla radice dell'ampiezza del passo. Ripetendo l'integrazione con estrazioni diverse di Z_k si ottengono traiettorie diverse dallo stesso ingresso, tanto più disperse quanto maggiore è la diffusione (Figura 2.3). Il tempo di integrazione è una variabile interna del modello e non coincide con l'orizzonte fisico della previsione. I due lavori descritti di seguito applicano questo schema alla stima dell'incertezza.

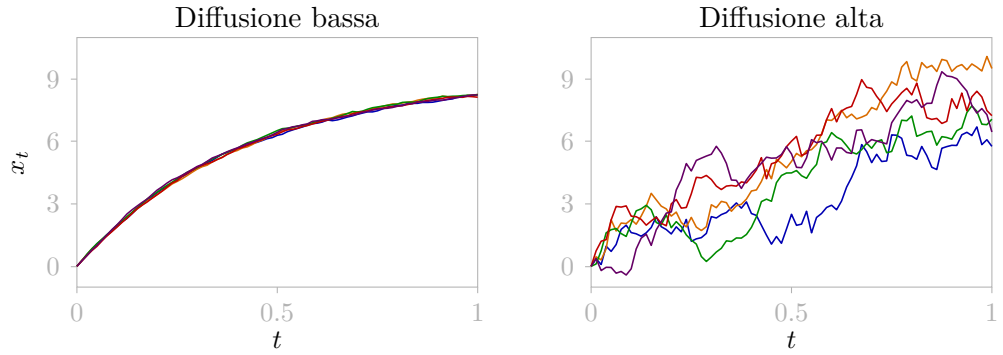


Figura 2.3: Cinque traiettorie di un'equazione differenziale stocastica lineare con lo stesso drift e due valori della diffusione, integrate con lo schema di Euler–Maruyama. La dispersione fra le traiettorie è la quantità da cui SDE-Net ricava l'incertezza epistemica. Simulazione illustrativa sul modello della figura analoga di Kong et al. [3]; non è un risultato della tesi.

2.3.3 SDE-Net

Kong et al. [3] interpretano le trasformazioni di una rete profonda come l'evoluzione dello stato di un sistema dinamico stocastico. Il modello comprende una rete di drift, che adatta la funzione predittiva, e una rete di diffusione, che scala un termine browniano e rappresenta l'incertezza epistemica. La diffusione è addestrata ad assumere valori bassi sui dati di training e alti su dati fuori distribuzione, ottenuti aggiungendo rumore gaussiano agli ingressi. L'equazione è integrata con lo schema dell'equazione (2.15) a passo fisso, con parametri condivisi fra i passi e diffusione calcolata sul solo stato iniziale, cioè con $g(x_0; \theta_g)$ al posto di $g(x_k, t_k)$; l'uscita della rete di diffusione è una sigmoide moltiplicata per un valore massimo, fissato come iperparametro. Dopo l'addestramento si campionano più traiettorie per lo stesso ingresso: l'incertezza aleatoria è la varianza predittiva media sulle traiettorie, quella epistemica la varianza dello stato finale fra le traiettorie. Il metodo separa così le due incertezze con un unico modello, senza distribuzioni a priori sui pesi e senza addestrare un insieme di reti. La valutazione riguarda il riconoscimento di dati fuori distribuzione, di errori di classificazione e di esempi avversari e l'active learning, su immagini e su un problema di regressione tabellare. Il lavoro non considera serie temporali né dati con struttura spaziale: gli esempi sono indipendenti, e il fuori distribuzione è definito da un dataset diverso o da ingressi perturbati, non da condizioni rare ma ricorrenti nello stesso dominio.

La tesi adotta di SDE-Net lo schema drift–diffusione, l'addestramento alternato delle due reti con pseudo-dati fuori distribuzione e la forma gaussiana dell'obiettivo di regressione. La variante SDE-Net del Capitolo 4 colloca il blocco SDE sullo stato latente prodotto dal backbone BiLSTM–GAT, quindi su un insieme di località collegate da un grafo e su finestre temporali; la diffusione è un coefficiente per esempio, ottenuto aggregando le località, e la testa gaussiana è estesa a più orizzonti di previsione. Il contesto di valutazione è diverso da quello dell'articolo: intervalli predittivi della produzione fotovoltaica e loro comportamento sulle osservazioni che i detector classificano come anomale. Il comportamento delle due componenti dell'incertezza, la varianza della testa gaussiana e la dispersione fra le traiettorie generata dalla diffusione, è valutato nel Capitolo 6.

2.3.4 SDE U-Net

Monaco et al. [15] adattano SDE-Net a un'architettura U-Net per il post-processing di previsioni numeriche di precipitazione, con mappe di precipitazione cumulata giornaliera sull'Italia nord-occidentale. Poiché i blocchi dell'encoder hanno dimensioni diverse, il numero di passi di integrazione

è allineato al numero di blocchi: a ciascun blocco è associato un blocco di diffusione, funzione dell'ingresso iniziale, il cui segnale è sommato alla rispettiva skip connection. La loss di regressione è una MSE e la diffusione è addestrata, come in SDE-Net, a distinguere ingressi originali e ingressi perturbati con rumore gaussiano. Il disegno sperimentale usa per training e validation soltanto eventi non intensi e valuta il modello sia su eventi non intensi sia su eventi intensi, confrontando più architetture probabilistiche in termini di equilibrio fra ampiezza e affidabilità degli intervalli. Il lavoro opera su campi regolari elaborati da un encoder–decoder convoluzionale e su mappe giornaliere: non tratta insiemi irregolari di località, serie temporali per sito o più orizzonti di previsione.

Di questo lavoro la tesi riprende due elementi. Il primo è l'allineamento fra passi stocastici e stadi dell'encoder, trasferito nella variante SDE U-Net della tesi agli stadi BiLSTM e GAT del backbone, con percorsi paralleli di drift e diffusione. Il secondo è il protocollo che esclude dal training gli eventi intensi e li mantiene nel test, realizzato qui con il filtro sulle finestre che contengono osservazioni anomale. Rispetto all'articolo cambiano il supporto spaziale, un grafo di località invece di una griglia, e il compito, la previsione di una serie per località. In questa variante la banda deriva dalla sola dispersione fra le traiettorie, senza una componente aleatoria; la sua ampiezza rispetto alle osservazioni è valutata nel Capitolo 6.

2.4 Posizionamento del lavoro

2.4.1 Il contributo sostenuto

I lavori esaminati coprono ciascuno una parte del problema affrontato. MTG-Flow tollera la presenza di anomalie nel training, ma descrive relazioni fra le variabili di un sistema e non fra siti geografici. STGAN introduce il contesto spaziale e un criterio avversario, ma presuppone una topologia fisica, la disponibilità di eventi documentati e, implicitamente, un training normale. CATCH e M2AD operano su serie multivariate prive di struttura geografica e non trattano, o escludono per ipotesi, un training contaminato. SDE-Net e SDE U-Net forniscono lo schema per l'incertezza del previsore, ma su esempi indipendenti o su mappe giornaliere: non trattano serie temporali per località collegate da un grafo.

La tesi adatta un detector avversario spazio-temporale, nato per il traffico, a campi meteorologici privi di etichette e di topologia fisica, in due varianti che rappresentano l'intorno di una cella con una convoluzione su griglia oppure con l'attenzione su grafo. Poiché un training privo di anomalie non

è garantito, ne definisce l'obiettivo come rilevamento di condizioni nuove rispetto al periodo di training. Lo estende con una misura di dispersione dello score, ottenuta con dropout Monte Carlo, con un monitoraggio senza etichette e con la ricostruzione di eventi geografici; e usa le sue decisioni per analizzare gli errori di un previsore fotovoltaico probabilistico. Il contributo consiste nell'adattamento, nella combinazione di questi elementi e nel protocollo di analisi. I componenti di base sono preesistenti: la tesi non propone un nuovo algoritmo di rilevamento.

2.4.2 Confronto dei detector esaminati

La Tabella 2.1 riassume i quattro detector esaminati e il percorso della tesi rispetto ai criteri usati nel capitolo. Le voci relative agli articoli riportano ciò che gli articoli dichiarano; dove un aspetto non è discusso, è indicato come non trattato. MTGFlow e STGAN sono stati eseguiti sui dati della tesi; CATCH e M2AD sono stati valutati sugli articoli e non eseguiti.

Tabella 2.1: Detector esaminati e percorso della tesi a confronto. La colonna sulle anomalie nel training indica come ciascun lavoro tratta la presenza di osservazioni anomale nei dati di addestramento.

Lavoro	Segnale dello score	Anomalie nel training	Contesto spaziale	Dati	Dispersione
MTGFlow [4]	Densità stimata	Ammesse per costruzione	No: relazioni fra variabili	Dataset pubblici	Non prevista
STGAN [2]	Errore di previsione e discriminatore	Non trattate: dati reali considerati normali	Sì: grafo da topologia fisica	Traffico	Non prevista
CATCH [5]	Errore di ricostruzione in frequenza	Non trattate	No: canali di una serie	Dataset reali e sintetici	Non prevista
M2AD [6]	Residui di previsione aggregati	Escluse per ipotesi	No: sensori di più sistemi	Dataset pubblici e caso industriale	Non prevista
Tesi	Come STGAN; densità per MTGFlow	Ammesse con MTGFlow; trattate come già osservate con STGAN	Sì: vicinanza geografica, griglia o grafo di griglia	PVGIS, ERA5	Sì: dropout Monte Carlo sullo score di STGAN

Capitolo 3

Dati e preprocessing

3.1 Serie PVGIS, località geografiche e target

I dati PVGIS sono serie orarie ottenute dal Photovoltaic Geographical Information System [16] con la banca dati di radiazione SARAH3, e provengono dal progetto SentinelPV del Politecnico di Torino. Coprono 1149 località del Piemonte, comprese fra 44.08° e 46.47° di latitudine nord e fra 6.66° e 9.20° di longitudine est. Nella proiezione UTM del fuso 32 le località occupano 1149 delle 41×54 posizioni di un reticolo regolare con passo di 5 km: quelle che ricadono nel territorio regionale (Figura 3.1). Sono disponibili gli anni dal 2005 al 2023, senza valori mancanti; i valori sono riferiti al minuto 10 di ciascuna ora, in tempo universale.

Per ogni località e ogni istante sono disponibili l'irradianza globale con le sue componenti diretta, diffusa e riflessa, l'altezza del sole, la temperatura dell'aria a due metri, la velocità del vento a dieci metri e la potenza prodotta. L'irradianza è riferita al piano orizzontale: l'inclinazione indicata nei dati è nulla, la componente riflessa risulta nulla e l'irradianza globale coincide con la somma delle componenti diretta e diffusa. La potenza è una produzione teorica calcolata da PVGIS, non la misura di un impianto reale. La Tabella 3.1 riassume le grandezze e il loro impiego.

Per il previsore il test è il 2019. Gli esperimenti preliminari con dropout Monte Carlo e Deep Ensemble usano gli anni 2016–2018 per l'addestramento, senza un insieme di validation. La variante SDE-Net, come l'articolo [3], non usa un insieme di validation ed è addestrata sugli anni 2016–2018 per un numero fissato di epoche. La variante SDE U-Net segue il protocollo dell'articolo [15], che prevede una validation: usa gli anni 2016–2017 per l'addestramento e il 2018 per la validation. I detector usano gli anni 2005–2018 per l'addestramento e il 2019 per il test. Il 2019 è usato come anno di

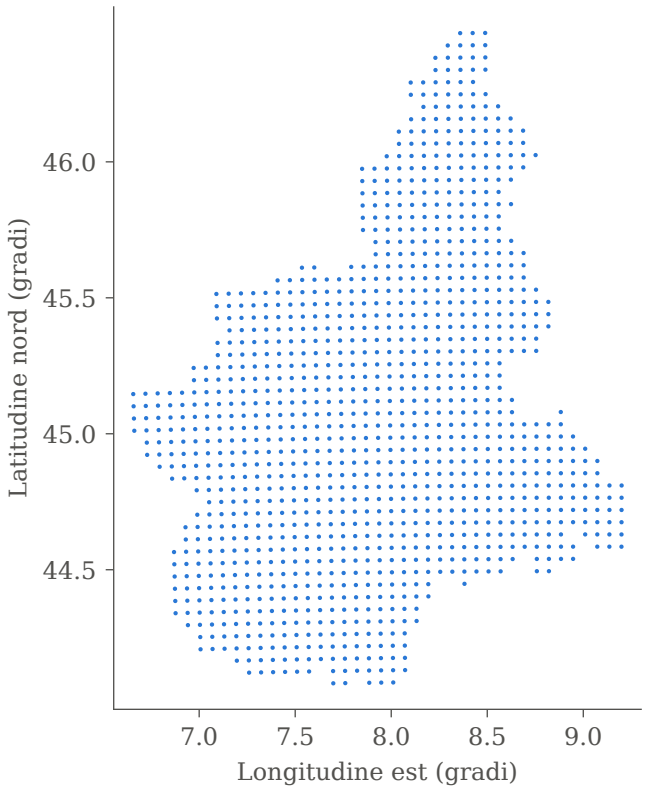


Figura 3.1: Le 1149 località dei dati PVGIS. Ogni punto è una posizione del reticolo con passo di 5 km per la quale sono disponibili le serie orarie.

Tabella 3.1: Grandezze dei dati PVGIS e loro impiego nel previsore, nei detector MTGFlow e STGAN e nelle soglie climatologiche della Sezione 4.3. L'altezza del sole fornita da PVGIS non è usata: l'elevazione solare è ricalcolata.

Grandezza	Unità	Previsore	Detector	Soglie climatologiche
Irradianza diretta	$\mathrm{W\,m^{-2}}$	Ingresso	–	–
Irradianza diffusa	$\mathrm{W\,m^{-2}}$	Ingresso	–	–
Irradianza riflessa (nulla)	$\mathrm{W\,m^{-2}}$	–	–	–
Irradianza globale (diretta più diffusa)	$\mathrm{W\,m^{-2}}$	Ingresso	Sì	Sì
Altezza del sole	gradi	–	–	–
Temperatura dell'aria a due metri	°C	Ingresso	Sì	Sì
Velocità del vento a dieci metri	$\mathrm{m\,s^{-1}}$	Ingresso	Sì	Sì
Potenza prodotta (teorica)	W	Target e ingresso storico	–	Sì

test perché è l'anno con la migliore disponibilità di misure da impianti reali. Il confronto con queste misure non fa parte della tesi: il lavoro si è orientato all'individuazione delle anomalie meteorologiche a supporto della previsione fotovoltaica.Il previsore utilizza serie orarie sincronizzate fra località e stima la produzione futura di ciascuna. Il detector STGAN utilizza invece tre variabili meteorologiche: irradianza globale, temperatura a due metri e velocità del vento a dieci metri. La produzione futura non è il target della GAN: il generatore stima le variabili meteorologiche al passo successivo del contesto spaziale considerato.

Queste sono le sole grandezze disponibili, e sono quelle che determinano la produzione fotovoltaica. Un'anomalia rilevata su questi dati non può essere ricondotta a una condizione meteorologica più generale. Per rilevare anomalie di tipo diverso e descriverne l'origine il lavoro passa ai campi ERA5, che comprendono quindici variabili in superficie e a 850 hPa e sono descritti nella Sezione 3.4.

3.2 Feature, trasformazioni fisiche e normalizzazione

Nel percorso PVGIS del previsore, il set completo comprende temperatura, irradianza globale, vento, seno e coseno dell'elevazione solare, indice di cielo sereno, sua deviazione standard mobile su tre ore, differenza temporale dell'irradianza, componenti diretta e diffusa e produzione storica. L'indice di cielo sereno è il rapporto fra l'irradianza globale e l'irradianza che si avrebbe a cielo sereno sullo stesso piano, cioè sul piano orizzontale. La posizione del sole e l'irradianza a cielo sereno, da cui derivano l'elevazione solare e l'indice, sono calcolate con la libreria pvlib [17].

La normalizzazione del previsore usa statistiche dei dati di fit: z-score per temperatura, irradianza, vento e differenza temporale dell'irradianza, e una scala della produzione per località ricavata dal percentile 99 dei valori positivi diurni. La produzione storica è causale perché viene inclusa soltanto nella finestra che precede il target. Le feature mobili possono richiedere anche osservazioni precedenti l'inizio della finestra esplicita.

Per STGAN, la trasformazione delle feature è un min–max stimato sul training, aggregando tempo e località e riportando i valori nel sistema di coordinate $[-1, 1]$. Valori di test esterni all'intervallo del training possono superare questi estremi, poiché la trasformazione non applica un clipping generale. La normalizzazione delle feature è distinta da quella delle componenti dello score, descritta nella sezione dedicata al detector.

3.3 Finestre temporali, split cronologici e previsione diretta multiorizzonte

Indicando con t l'ultimo timestamp della finestra di input, il target dell'orizzonte h è associato a $t + h$. L'ingresso del previsore ha forma $[B, N, L, F]$, con dimensione del batch B, numero di località N, lunghezza della sequenza L e numero di feature F. Il percorso a singolo orizzonte resta disponibile; nell'estensione diretta, un solo modello produce le uscite per l'insieme di orizzonti richiesto, ad esempio da una a sei ore.

Per H orizzonti, i target e le uscite assumono forma $[B, N, H]$. Le previsioni intermedie non vengono reinserite nell'input: tutte le uscite derivano dalla stessa finestra osservata. Ogni previsione conserva località, timestamp di emissione, timestamp target e orizzonte. I confronti a una e sei ore possono quindi essere estratti dallo stesso modello diretto, distinguendoli dalle precedenti esecuzioni con modelli separati per orizzonte.

Nella variante SDE U-Net l'anno di validation viene separato prima di stimare la normalizzazione. Il test viene fornito separatamente. Quando è attivo il filtro di training su finestre normali, vengono escluse le finestre con eventi nel contesto delle feature, nell'input o in almeno uno dei target richiesti. L'estensione degli orizzonti può pertanto cambiare sia il numero di finestre disponibili sia quello delle finestre ammissibili.

La preparazione STGAN prevede periodi storici e test separati; il primo target di test può utilizzare la coda contigua del training come contesto.

3.4 Campi ERA5, allineamento e celle valide

I dati della rianalisi ERA5 [18] provengono da due prodotti distinti: variabili a livello singolo e variabili su livelli di pressione, di cui è usato soltanto il livello di 850 hPa. Le variabili sono quindici. Le dieci variabili a livello singolo sono temperatura a due metri, componenti orizzontali del vento a dieci metri, pressione al livello medio del mare, precipitazione totale, copertura nuvolosa totale, radiazione solare discendente alla superficie, umidità volumetrica del primo strato del suolo, velocità d'attrito e altezza dello strato limite. Le altre cinque sono le componenti orizzontali del vento, la velocità verticale, la temperatura e l'umidità specifica a 850 hPa. La Tabella 3.2 le elenca con le unità di ERA5, che non vengono convertite.

I dati coprono gli anni dal 1980 al 2025. Sono selezionati gli istanti UTC 00, 03, 06, 09, 12, 15, 18 e 21, su una griglia di $0.5° \times 0.5°$ nell'area compresa fra 20° e 60° di latitudine nord e fra 15° di longitudine ovest e 50° di longitudine est. Il campionamento ogni tre ore è una selezione di tempi

Tabella 3.2: Le quindici variabili ERA5, con la sigla e l'unità del dataset. Precipitazione e radiazione sono accumuli di un'ora; le altre variabili sono istantanee.

Variabile	Sigla	Livello	Unità
Temperatura a due metri	t2m	Superficie	K
Componente zonale del vento a dieci metri	u10	Superficie	$\mathrm{m\,s^{-1}}$
Componente meridionale del vento a dieci metri	v10	Superficie	$\mathrm{m\,s^{-1}}$
Pressione al livello medio del mare	msl	Superficie	Pa
Precipitazione totale	tp	Superficie	m
Copertura nuvolosa totale	tcc	Superficie	0–1
Radiazione solare discendente alla superficie	ssrd	Superficie	$\mathrm{J\,m^{-2}}$
Umidità volumetrica del primo strato del suolo	swvl1	Superficie	$\mathrm{m^3\,m^{-3}}$
Velocità d'attrito	zust	Superficie	$\mathrm{m\,s^{-1}}$
Altezza dello strato limite	blh	Superficie	m
Componente zonale del vento	u	850 hPa	$\mathrm{m\,s^{-1}}$
Componente meridionale del vento	v	850 hPa	$\mathrm{m\,s^{-1}}$
Velocità verticale	w	850 hPa	$\mathrm{Pa\,s^{-1}}$
Temperatura	t	850 hPa	K
Umidità specifica	q	850 hPa	$\mathrm{kg\,kg^{-1}}$

validi, non un'aggregazione temporale: precipitazione e radiazione conservano gli accumuli di un'ora associati ai tempi selezionati, senza somme triorarie o conversioni locali delle unità.

I file mensili vengono verificati rispetto a tempi, griglia, variabili e livello di pressione richiesti. La preparazione allinea i due prodotti sulle stesse coordinate e sugli stessi timestamp, ordina le latitudini da nord a sud e le longitudini da ovest a est. Il reticolo contiene $81 \times 131 = 10611$ posizioni.

Sono conservate le celle per le quali tutte le variabili sono definite nel primo istante di training, e si verifica che questo insieme rimanga identico nel resto del periodo; se cambia, la preparazione si interrompe. La selezione non utilizza il test e non viene applicata imputazione. Il criterio è la completezza delle variabili, non una classificazione terra–mare: nei dati usati nessuna cella è esclusa.

I dati preparati hanno forma $[T, N, 15]$, con $N = 10611$ celle. Gli anni 1980–2004 sono usati per il training e gli anni 2005–2025 per il test: rispettivamente 73056 e 61360 istanti. La normalizzazione delle variabili è stimata soltanto sul training. Questa suddivisione segue l'articolo di STGAN [2], che separa i dati in training e test senza un insieme di validation. Gli esperimenti con il monitoraggio descritto nella Sezione 4.10.4 tengono invece il 2004 fuori dal training come anno di validation, letto soltanto dal monitoraggio; in questi esperimenti il training comprende gli anni 1980–2003.

Capitolo 4

Metodologia

4.1 Panoramica del percorso metodologico

La metodologia parte dal previsore: il backbone deterministico BiLSTM–GAT, le soglie climatologiche della Sezione 4.3, che forniscono le prime etichette di condizioni insolite, gli esperimenti preliminari con Enhanced MC Dropout e Deep Ensemble, valutati su quelle etichette, e le due varianti basate su equazioni differenziali stocastiche, SDE U-Net e SDE-Net. La variante SDE-Net include una previsione diretta multiorizzonte. Il rilevamento delle anomalie con modelli appresi costituisce una linea distinta, condotta dapprima sui dati PVGIS, come analisi iniziale, con MTGFlow, STGAN e un adattamento STGAN a griglia, evoluto da una CNN senza ricorrenza a un encoder ConvGRU. La versione finale conserva la LSTM del trend e permette un'ablazione della dimensione dei kernel. Un'estensione separata applica lo stesso detector a ERA5 e introduce la ricostruzione di eventi geografici a partire dagli score. Su ERA5 il detector viene poi dotato di dropout nel generatore e di uno score Monte Carlo con una misura di dispersione associata. Due varianti intervengono sul generatore: la prima sostituisce, nei gate dell'unità ricorrente, la convoluzione con l'attenzione su grafo definita sull'intera griglia; la seconda applica la ConvGRU al campo completo invece che a singole patch. In entrambe il discriminatore rimane locale.

Le analisi post-hoc utilizzano previsioni e score già prodotti. Il cambiamento della soglia o del raggruppamento delle osservazioni modifica il protocollo di valutazione, senza comportare un nuovo addestramento del previsore.

4.2 Backbone BiLSTM–GAT

Il backbone è stato messo a punto inizialmente su una configurazione mista, con la produzione misurata di impianti reali come grandezza da prevedere e le variabili meteorologiche PVGIS della località più vicina come ingressi. Quella configurazione non fa parte della tesi; il backbone è descritto qui come architettura comune ai previsori addestrati sui soli dati PVGIS. Su questi dati non è stato addestrato come modello a sé con il protocollo delle varianti SDE: è il modello di base degli esperimenti preliminari della Sezione 4.4.

4.2.1 Tensori di input, encoder temporale e attention pooling

Il previsore riceve un tensore $X \in \mathbb{R}^{B\times N\times L\times F}$: B esempi, N località, una finestra di $L = 24$ ore e le F feature descritte nel Capitolo 3. L'uscita è la produzione normalizzata di ogni località all'ora successiva, di forma $[B, N]$.

L'encoder temporale elabora la sequenza di ciascuna località con parametri condivisi fra le località. È una LSTM bidirezionale a due strati, con 128 unità per direzione, che restituisce per ogni passo t uno stato $h_t \in \mathbb{R}^{256}$. Gli stati sono aggregati con un pooling ad attenzione: un punteggio scalare per passo, ottenuto da una trasformazione lineare, è normalizzato con una softmax sui passi e usato come peso,

$$w_t = \frac{\exp\big(a^\top h_t + b\big)}{\sum_{s=1}^{L} \exp(a^\top h_s + b)}, \qquad h = \mathrm{LayerNorm}\left(\sum_{t=1}^{L} w_t\, h_t\right). \tag{4.1}$$

La rappresentazione h è poi proiettata in uno spazio latente di 96 dimensioni da uno strato lineare seguito da GELU e da una normalizzazione di strato. Questo vettore, uno per località, è l'ingresso dello stadio spaziale.

4.2.2 Grafo geografico Haversine

Ogni località è un nodo. Due località sono collegate, in entrambe le direzioni, quando la loro distanza sulla superficie terrestre, calcolata con la formula di Haversine, non supera 20 km; una località senza vicini entro questo raggio è collegata alla più vicina, e ogni nodo ha un arco verso sé stesso. A ogni arco è associato un peso che decresce con la distanza d_{ij},

$$p_{ij} = \exp\left[-\frac{1}{2}\left(\frac{d_{ij}}{s}\right)^2\right], \tag{4.2}$$

con scala $s = 10$ km e $p_{ii} = 1$. Lo stadio spaziale è uno strato di attenzione su grafo [11] a quattro teste, seguito da una connessione residua e da una normalizzazione di strato.

Gli archi esprimono quindi relazioni di vicinanza geografica e i pesi gaussiani forniscono un prior ai coefficienti di attenzione. Nella variante SDE-Net, il logaritmo del peso geografico viene aggiunto al logit appreso e_{ij} dell'equazione (2.9), prima della softmax sugli archi entranti.

4.2.3 Teste di previsione, funzione di perdita e training

Lo stato prodotto dallo stadio spaziale alimenta due teste, ciascuna formata da due strati lineari con una GELU intermedia, che riducono le 96 dimensioni a 48 e poi a un valore per località. La testa della produzione applica una softplus e restituisce una previsione non negativa $\hat{y}_{bn}$ della produzione normalizzata. La testa ausiliaria applica una sigmoide moltiplicata per un valore massimo e stima l'indice di cielo sereno $\hat{k}_{bn}$, cioè il rapporto fra l'irradianza globale e quella a cielo sereno; moltiplicata per l'irradianza a cielo sereno fornisce una stima dell'irradianza.

Nel percorso deterministico la funzione di perdita è un errore quadratico medio sulla produzione, a cui si somma, quando la testa ausiliaria è attiva, l'errore quadratico medio sull'indice di cielo sereno con peso λ:

$$\mathcal{L} = \text{media}_{b,n}\,(y_{bn} - \hat{y}_{bn})^2 + \lambda\ \text{media}_{b,n}\left(k_{bn} - \hat{k}_{bn}\right)^2. \tag{4.3}$$

Negli esperimenti preliminari della Sezione 4.4 la perdita comprende anche un termine di errore assoluto pesato sui valori alti della produzione, che penalizza maggiormente le sottostime; le varianti SDE non lo usano. La testa gaussiana e la negative log-likelihood della variante SDE-Net sono descritte nella Sezione 4.6. Epoche, dimensione del batch e tasso di apprendimento sono riportati nel Capitolo 5.

4.3 Soglie climatologiche

Il primo criterio usato per individuare condizioni insolite non è un modello appreso, ma un confronto con la climatologia degli stessi dati PVGIS. Per ogni località e ogni ora del giorno si raccolgono i valori osservati negli anni della climatologia entro una finestra di ± 15 giorni di calendario attorno alla data considerata; da questo insieme si ricavano la mediana e i quantili 0.025 e 0.975. Un'osservazione è segnalata quando il suo valore cade fuori dalla banda fra i due quantili. Il confronto è svolto separatamente per l'irradianza globale, la produzione teorica, la temperatura e la velocità del vento. Per

irradianza e produzione l'etichetta distingue i valori insolitamente alti da quelli insolitamente bassi; per temperatura e vento indica una condizione estrema. Dove la climatologia non contiene dati sufficienti l'osservazione non viene classificata.

Per il 2019, anno di test, la climatologia comprende gli anni 2005–2018. Per gli anni di addestramento del previsore comprende soltanto gli anni precedenti a quello valutato: 2005–2015 per il 2016, 2005–2016 per il 2017 e 2005–2017 per il 2018.

Le etichette hanno due impieghi. Il primo è l'analisi del previsore: errori e intervalli sono confrontati fra le osservazioni segnalate e le altre, e per l'irradianza separatamente sui valori insolitamente alti e su quelli insolitamente bassi. In particolare, le etichette indicano le osservazioni attorno alle quali verificare se gli intervalli degli esperimenti preliminari della Sezione 4.4 contengono il valore osservato. Il secondo è l'addestramento sulle sole finestre normali, secondo il protocollo ripreso da SDE U-Net [15]. Per questo impiego le etichette locali sono aggregate sull'intera regione: per ogni istante e ogni variabile si calcola il quantile 0.99, fra le località, degli score delle osservazioni segnalate, e l'istante è considerato un evento quando questo valore supera il quantile 0.975 della sua distribuzione negli anni di addestramento. Dal training e dalla validation sono escluse le finestre che contengono un evento; il test le conserva, come nell'articolo, dove soltanto gli eventi non intensi sono usati per training e validation.

Le soglie climatologiche segnalano i valori estremi di ciascuna variabile rispetto alla sua distribuzione storica. Per verificare se un modello appreso individua anomalie di altro tipo, e come il previsore si comporta su di esse, il lavoro passa ai detector descritti nelle Sezioni 4.7 e 4.8. A differenza delle soglie climatologiche, i detector non usano la produzione: operano sulle sole variabili meteorologiche.

4.4 Esperimenti probabilistici preliminari

I primi due metodi usati per associare un intervallo alla previsione non modificano il backbone: ne campionano l'uscita. Entrambi sono valutati sulle osservazioni segnalate dalle soglie climatologiche della Sezione 4.3, per verificare se l'intervallo si allarga e contiene il valore osservato nelle condizioni insolite.

4.4.1 Enhanced Monte Carlo Dropout

Il dropout Monte Carlo [12] mantiene il dropout attivo in previsione e ripete il passaggio in avanti. Nel backbone il dropout è presente in origine soltanto sui coefficienti di attenzione dello strato su grafo e fra gli strati della LSTM. La variante qui indicata come Enhanced aggiunge tre strati di dropout: dopo l'encoder temporale, dopo la proiezione nello spazio latente e prima dell'ultimo strato della testa della produzione. La probabilità è 0.2.

In addestramento il dropout agisce da regolarizzatore. In previsione il modello è posto in modalità di valutazione e vengono riattivati i soli strati di dropout, in modo che le normalizzazioni restino quelle di valutazione. Per ogni coppia località–istante si eseguono $J = 20$ passaggi in avanti con maschere diverse, che producono J previsioni della produzione.

4.4.2 Deep Ensemble di modelli addestrati indipendentemente

Nel Deep Ensemble [13] i campioni non provengono da maschere diverse dello stesso modello, ma da modelli diversi. Ogni membro è lo stesso modello, addestrato in modo indipendente con un seme diverso, sugli stessi dati e con lo stesso protocollo; i membri sono cinque. In previsione ogni membro è usato in modo deterministico, senza dropout attivo. Le previsioni dei membri sul test sono allineate per località e istante, verificando che i valori osservati coincidano, e combinate in una matrice con una riga per membro.

Rispetto all'articolo c'è una differenza: i membri restituiscono una previsione puntuale e non una media e una varianza gaussiane. Della varianza di miscela dell'equazione (2.13) resta quindi il solo termine di dispersione fra le medie.

4.4.3 Previsioni medie, dispersione e intervalli empirici

I due metodi producono per ogni osservazione un insieme di previsioni $\hat{y}^{(1)}, \ldots, \hat{y}^{(S)}$, con S pari al numero di passaggi o di membri, e sono riassunti allo stesso modo. La previsione puntuale è la media dell'insieme, come nell'equazione (2.12), e la dispersione è la sua deviazione standard. L'intervallo al 95% è delimitato dai quantili empirici 0.025 e 0.975 dell'insieme; la banda gaussiana $\bar{y} \pm 1.96\, s_y$ è conservata come diagnostica. Agli intervalli non è applicata alcuna correzione di scala successiva all'addestramento.

Le due dispersioni hanno significato diverso: quella del dropout Monte Carlo misura la variabilità di un solo modello rispetto alle maschere, quella del Deep Ensemble il disaccordo fra modelli addestrati separatamente. Nessuna

delle due comprende una stima del rumore dei dati, e con pochi membri i quantili del Deep Ensemble sono necessariamente grossolani. Le metriche con cui gli intervalli sono valutati sono definite nel Capitolo 5.

4.5 Variante SDE U-Net

Questa variante trasferisce al backbone BiLSTM–GAT lo schema di SDE U-Net [15], in cui i passi stocastici sono allineati agli stadi dell'encoder e a ciascuno stadio corrisponde un blocco di diffusione. Gli stadi sono qui due: quello temporale e quello spaziale.

4.5.1 Backbone paralleli di drift e diffusione

Il percorso di drift è il backbone della sezione precedente: encoder temporale, proiezione, strato di attenzione su grafo e teste. Il percorso di diffusione ne replica gli stadi con parametri propri: una seconda LSTM bidirezionale con pooling ad attenzione, una proiezione lineare seguita da ReLU e un secondo strato di attenzione su grafo, sullo stesso grafo geografico. A ogni stadio il percorso di diffusione restituisce, attraverso una sigmoide, un coefficiente compreso fra 0 e 1 per ogni località e ogni dimensione latente: g_1 per lo stadio temporale e g_2 per quello spaziale, entrambi di forma $[B, N, 96]$. Lo stato che passa da uno stadio di diffusione al successivo è quello che precede la sigmoide.

4.5.2 Perturbazioni Browniane negli stadi BiLSTM e GAT

Sia c la rappresentazione proiettata dell'encoder temporale del drift. Nello stadio temporale la perturbazione è sommata a c insieme a un raffinamento $r(c)$, formato da uno strato lineare e da una GELU:

$$h_1 = \mathrm{LayerNorm}(r(c) + c + \kappa\, g_1 \odot \varepsilon_1)\,, \qquad \varepsilon_1 \sim \mathcal{N}(0, I). \tag{4.4}$$

Nello stadio spaziale la perturbazione è sommata all'uscita dello strato di attenzione su grafo $\mathcal{A}$ e alla connessione residua, prima della normalizzazione:

$$h_2 = \mathrm{LayerNorm}(\mathcal{A}(h_1) + h_1 + \kappa\, g_2 \odot \varepsilon_2)\,, \qquad \varepsilon_2 \sim \mathcal{N}(0, I). \tag{4.5}$$

La scala comune è $\kappa = s_{\max}\sqrt{\Delta\tau}$. L'orizzonte astratto è $T = 4$ e il passo è $\Delta\tau = T/(S+1)$, con $S = 2$ stadi stocastici; il valore massimo della diffusione è $s_{\max} = 0.5$. Le teste ricevono lo stato h_2.

A differenza della variante SDE-Net, lo schema non applica più volte lo stesso campo di drift a uno stesso stato: ogni perturbazione è legata a uno stadio diverso della rete, e il tempo τ serve soltanto a fissare la scala del rumore. Nel percorso deterministico le due perturbazioni sono assenti.

4.5.3 Training alternato, pseudo-OOD e inferenza a traiettorie

A ogni passo di addestramento si alternano due aggiornamenti, con due ottimizzatori Adam [19] distinti. Il primo aggiorna il percorso di drift e le teste su un passaggio stocastico, minimizzando la perdita dell'equazione (4.3) con $\lambda = 0.1$. Il secondo aggiorna il solo percorso di diffusione: i coefficienti g_1 e g_2 sono spinti verso 0 sugli ingressi di training e verso 1 su ingressi pseudo fuori distribuzione, con una entropia incrociata binaria sommata sui due stadi. Gli ingressi pseudo fuori distribuzione sono ottenuti aggiungendo rumore gaussiano di deviazione standard unitaria alle feature continue dell'ingresso; seno e coseno dell'elevazione solare non sono perturbati.

Il modello valutato sul test è quello dell'epoca con il miglior errore sulla validation, calcolato con il percorso deterministico. Quando è attivo l'addestramento sulle sole finestre normali, training e validation sono filtrati come descritto nella Sezione 4.3.

In previsione si campionano $M = 20$ traiettorie per ogni ingresso. La previsione puntuale è la media delle M uscite, la dispersione la loro deviazione standard e l'intervallo al 95% è delimitato dai quantili empirici 0.025 e 0.975, come nella Sezione 4.4. La testa della produzione restituisce un solo valore per traiettoria: non c'è una stima della varianza dei dati, e la dispersione fra le traiettorie non è separata in una componente aleatoria e una epistemica.

4.6 Variante SDE-Net

4.6.1 Campo di drift, diffusione e integrazione Euler–Maruyama

Il backbone BiLSTM–GAT produce lo stato iniziale z_0 della dinamica latente. Il drift applica una trasformazione lineare seguita da ReLU. La rete di diffusione media lo stato iniziale sulle località e restituisce un coefficiente sigmoidale $g(z_0)$ per esempio, condiviso fra nodi e canali. L'integrazione implementata specializza l'equazione (2.15) ed è

$$z_{k+1} = z_k + f(z_k)\Delta\tau + s_{\max} g(z_0)\sqrt{\Delta\tau}\,\varepsilon_k, \qquad \varepsilon_k \sim \mathcal{N}(0, I). \tag{4.6}$$

La scala della diffusione viene calcolata una volta sullo stato iniziale e mantenuta lungo la traiettoria. Il tempo latente τ e il suo passo di integrazione sono distinti dall'orizzonte fisico h della previsione.

4.6.2 Testa gaussiana, negative log-likelihood e training

La testa PV restituisce una media non negativa e una deviazione standard positiva mediante trasformazioni softplus. Nell'estensione multiorizzonte, lo stato finale condiviso alimenta H coppie (μ_h, σ_h). Non viene appresa una matrice di covarianza esplicita fra orizzonti.

L'obiettivo di regressione utilizza la forma

$$\mathcal{L}_{\mathrm{PV}} = \mathrm{media}_{b,n,h}\left[\log \sigma_{bnh}^2 + \frac{(y_{bnh} - \mu_{bnh})^2}{\sigma_{bnh}^2}\right], \tag{4.7}$$

equivalente alla negative log-likelihood gaussiana a meno di una costante e di un fattore moltiplicativo. Quando abilitata, una testa ausiliaria stima l'indice di cielo sereno e aggiunge un termine MSE pesato.

Il training alterna due aggiornamenti: il primo ottimizza encoder, eventuale GAT, drift e teste; il secondo aggiorna soltanto la rete di diffusione. Quest'ultimo usa una BCE con dati di ingresso etichettati zero e pseudo-OOD etichettati uno, ottenuti aggiungendo rumore gaussiano all'intero input. Le rappresentazioni del secondo passo sono staccate dall'encoder. La procedura prevede inoltre warm-up della scala SDE e selezione del modello tramite validazione.

4.6.3 Campionamento e componenti dell'incertezza predittiva

Ogni traiettoria browniana m produce una componente gaussiana con parametri $(\mu^{(m)}, \sigma^{(m)})$ per ciascuna uscita. La media e la varianza predittiva sono calcolate come

$$\bar{\mu} = \frac{1}{M}\sum_{m=1}^{M} \mu^{(m)}, \tag{4.8}$$

$$v_{\mathrm{tot}} = \mathrm{Var}_m\left(\mu^{(m)}\right) + \frac{1}{M}\sum_{m=1}^{M}\left(\sigma^{(m)}\right)^2. \tag{4.9}$$

La varianza v_{tot} ha la forma della varianza di miscela dell'equazione (2.13), con le traiettorie al posto delle reti di un insieme. Il codice conserva separatamente la dispersione delle medie lungo le traiettorie e la varianza delle teste gaussiane, indicate rispettivamente come componenti epistemica e aleatorica.

L'intervallo principale è ottenuto dai quantili a code uguali della miscela gaussiana equiponderata rappresentata dalle traiettorie. La banda $\bar{\mu} \pm z\sqrt{v_{\text{tot}}}$ è mantenuta come approssimazione gaussiana diagnostica. Il percorso senza rumore integra invece il solo drift e non coincide, in generale, con la media esatta delle traiettorie stocastiche.

4.7 Rilevamento delle anomalie climatiche con MTGFlow

Il primo detector appreso è MTGFlow [4], nella versione base dell'articolo. Stima la densità delle finestre di training e assegna uno score alto alle finestre a bassa densità; non richiede etichette e non assume che il training sia privo di anomalie.

4.7.1 Serie storiche per località, variabili climatiche e finestre

MTGFlow è applicato separatamente a ogni località. Le entità del modello sono le tre variabili meteorologiche della località: irradianza globale, temperatura a due metri e velocità del vento a dieci metri. La produzione e le etichette delle soglie climatologiche non entrano nel detector.

Ogni variabile è normalizzata sottraendo la media e dividendo per la deviazione standard, calcolate sul solo training della località. Le serie sono suddivise in finestre di $T = 60$ ore; una finestra ha forma $[K, T]$, con $K = 3$ entità. Le finestre che attraversano un'interruzione della cadenza oraria sono scartate. In addestramento le finestre sono estratte con passo 10. Nello scoring il passo è 1: ogni ora riceve lo score della finestra che termina in quell'ora. È uno scostamento dalla configurazione di riferimento, che usa il passo 10 anche nello scoring, ed è necessario per collegare gli score alle previsioni orarie del previsore.

4.7.2 Grafo dinamico tra entità e normalizing flow condizionale

Per ogni finestra il modello calcola una matrice di adiacenza fra le entità. Indicando con $x^k \in \mathbb{R}^T$ la finestra dell'entità k e con W_Q, W_K due trasformazioni lineari,

$$A_{kj} = \frac{\exp\left[(W_Q x^k)^\top (W_K x^j)/\sqrt{T}\right]}{\sum_{l=1}^{K} \exp\left[(W_Q x^k)^\top (W_K x^l)/\sqrt{T}\right]}. \tag{4.10}$$

La matrice cambia da una finestra all'altra e descrive quanto l'entità j contribuisce al contesto dell'entità k: collega le variabili di una stessa località, non località diverse.

Una LSTM con parametri condivisi fra le entità elabora la sequenza di ciascuna e restituisce gli stati $H_t \in \mathbb{R}^{K\times d}$. Il condizionamento del passo t combina gli stati delle entità collegate con lo stato del passo precedente,

$$C_t = \mathrm{ReLU}(A\,H_t\,W_1 + H_{t-1}\,W_2)\,W_3. \tag{4.11}$$

Il normalizing flow trasforma ogni valore x_t^k in una variabile z_t^k con una sequenza di blocchi autoregressivi mascherati, ciascuno dei quali applica una traslazione e una scala calcolate da C_t:

$$z = (x - m(C_t))\exp(-a(C_t))\,, \qquad \log\left|\frac{\partial z}{\partial x}\right| = -a(C_t). \tag{4.12}$$

I parametri dei blocchi sono condivisi fra le entità; ciò che distingue un'entità dall'altra è la distribuzione di arrivo, una gaussiana di varianza unitaria con media μ_k propria dell'entità. La log-verosimiglianza della finestra dell'entità k è la somma sui passi della log-densità gaussiana di z_t^k e dei logaritmi dei determinanti dei blocchi.

L'addestramento massimizza la log-verosimiglianza media delle finestre di training. Nella configurazione di riferimento il modello ha due blocchi di flow e stati di dimensione 32, ed è addestrato per 40 epoche con Adam; il modello usato per lo scoring è quello dell'ultima epoca, senza selezione su una validation.

4.7.3 Score aggregato della località, score per variabile e soglie IQR

Lo score di una finestra è l'opposto della log-verosimiglianza, mediato sulle entità:

$$S = -\frac{1}{K}\sum_{k=1}^{K}\log p\Big(x^k\Big) = \sum_{k=1}^{K} S_k, \qquad S_k = -\frac{1}{K}\log p\Big(x^k\Big)\,. \tag{4.13}$$

S è lo score aggregato della località e S_k il contributo della variabile k. Lo score è attribuito all'ultimo istante della finestra.

La soglia segue l'articolo ed è ricavata dagli score di training della stessa località: indicando con Q_1 e Q_3 il primo e il terzo quartile,

$$\theta = Q_3 + 1.5\,(Q_3 - Q_1), \tag{4.14}$$

e una finestra è segnalata quando $S \geq \theta$. Per ogni variabile è calcolata allo stesso modo una soglia sugli score S_k, moltiplicata per 0.8. Lo score per variabile indica quale grandezza contribuisce di più alla bassa verosimiglianza; non identifica la causa fisica dell'anomalia.

Con soglie stimate per località, la quota di osservazioni segnalate varia da una località all'altra. Come variante esplorativa le decisioni sono ricalcolate con una quota fissata sull'insieme di tutte le località, ordinando le osservazioni secondo lo scarto dalla soglia della propria località, $(S - \theta)/(Q_3 - Q_1)$. Il confronto fra i due criteri è riportato nel Capitolo 6.

4.7.4 Modelli indipendenti per località e assenza di message passing geografico

Per ogni località è addestrato un modello distinto, che vede soltanto la serie di quella località, con un solo seme. Gli score delle diverse località sono riuniti soltanto dopo lo scoring. È quindi possibile rappresentarli su una mappa e confrontarli, ma il modello non apprende relazioni fra località: il grafo dinamico dell'equazione (4.10) riguarda le tre variabili di un sito.

Questo è il limite che motiva il passo successivo. Una condizione meteorologica insolita interessa di norma più località vicine, e un valore insolito in un punto può essere ordinario rispetto al suo intorno. Per introdurre il contesto spaziale il lavoro passa a STGAN, descritto nella sezione seguente.

4.8 STGAN su PVGIS: versione su grafo e variante a griglia

4.8.1 Contesto spaziale e architettura GCGRU–LSTM

La versione STGAN basata su grafo costruisce un sottografo locale di nove siti: la località centrale e gli otto vicini geografici più prossimi. Gli archi diretti derivano da un criterio kNN, con pesi gaussiani delle distanze, self-loop e normalizzazione dell'adiacenza.

Il generatore combina un ramo GCGRU sul contesto recente, una LSTM sulla storia della località centrale e una codifica one-hot dell'ora e del giorno della settimana. Il contesto recente contiene un passo e il trend 168 passi orari. L'uscita stima le tre variabili meteorologiche al timestamp successivo per tutti i nodi del sottografo.

Il discriminatore combina una rappresentazione GCGRU della storia con una convoluzione sul dato corrente, reale o generato, e restituisce un valore

sigmoidale. I due componenti operano sullo stesso contesto locale; il generatore non stima direttamente la produzione fotovoltaica.

4.8.2 Variante ConvGRU–LSTM e gestione delle celle assenti

L'adattamento a griglia sostituisce gli operatori sul grafo con convoluzioni su una patch geografica $P \times P$. Le coordinate vengono proiettate e verificate rispetto a un reticolo prima di assegnare righe e colonne: l'ordine originario dei siti non viene semplicemente rimodellato come un'immagine. Sui dati PVGIS il reticolo è quello della proiezione UTM del fuso 32, con passo di 5 km, e la patch è 3×3: 917 località hanno una patch completa e 232 una patch incompleta, perché sul bordo della regione mancano alcune celle. Le celle assenti non vengono sostituite da località più lontane.

Il primo adattamento utilizzava un encoder CNN senza ricorrenza. La versione finale impiega invece una ConvGRU [9, 10] sia nel ramo recente del generatore sia in quello storico del discriminatore. Le denominazioni delle due versioni non identificano quindi architetture intercambiabili. Con R passi recenti, L passi di trend e F feature, gli ingressi hanno forma $[B, R, F, P, P]$ per la patch recente e $[B, L, F]$ per la storia del sito centrale; maschera e calendario hanno rispettivamente forma $[B, 1, P, P]$ e $[B, 31]$.

Le feature delle celle assenti sono azzerate dopo normalizzazione e la maschera binaria M viene fornita come canale aggiuntivo a ogni strato ConvGRU. Rispetto alle equazioni (2.5)–(2.8) cambiano l'ingresso e l'ultimo passaggio. I gate e lo stato candidato sono calcolati su X'_s, la concatenazione dei valori mascherati e di M, al posto di X_s; lo stato precedente H_{s-1} è già mascherato e lo stato aggiornato viene moltiplicato per la maschera, replicata sui canali:

$$H_s = M \odot \left[U_s \odot H_{s-1} + (1 - U_s) \odot \widetilde{H}_s \right]. \tag{4.15}$$

Il mascheramento dello stato impedisce alle celle assenti di conservare attivazioni da propagare negli strati o nei passi successivi. Non viene applicata una rinormalizzazione del kernel in funzione delle celle osservate, come avverrebbe in una partial convolution.

Lo stato ricorrente è inizializzato a zero per ogni finestra. Il modello ha due strati ConvGRU da 32 canali, $R = 1$ e una LSTM del trend a due strati con stato nascosto di dimensione 64, con $L = 168$ ore. Con un solo passo recente la ConvGRU esegue un solo aggiornamento dallo stato nullo: la ricorrenza sul lungo periodo rimane affidata alla LSTM.

Nel generatore, l'uscita ConvGRU viene concatenata alla rappresentazione del trend centrale e a quella del calendario, replicate sulle posizioni della

patch. Una proiezione 1×1 seguita da tanh produce il target meteorologico $[B, F, P, P]$, azzerando le celle assenti. Nel discriminatore, la storia codificata viene appiattita su tutta la patch e proiettata linearmente; il dato corrente passa attraverso una proiezione 1×1 e un massimo sulle celle valide. Le due rappresentazioni alimentano la classificazione sigmoidale.

Il numero di celle osservate può variare fra patch. La loss generativa e lo score di errore sono mediati sulle sole celle valide e sulle feature, prima di aggregare gli esempi. Le patch complete e incomplete vengono mantenute distinte nel confronto dei detector. La presenza delle stesse località, quando verificata, non rende equivalenti gli operatori convoluzionali e quelli sul grafo.

4.8.3 Ablazione del kernel e supporto spaziale osservato

La dimensione k del kernel è indipendente dal lato P della patch. L'ablazione consente $k = 1, 3, 5$ nei gate reset, update e candidato delle ConvGRU del generatore e del discriminatore, con padding $\lfloor k/2 \rfloor$. Le proiezioni finali 1×1 rimangono tali in tutte le configurazioni. Il caso di riferimento è $k = 3$; la patch resta $P = 3$ in tutte le configurazioni.

Con $k = 1$ i gate non mescolano celle geografiche diverse mediante convoluzione. Il detector continua tuttavia a utilizzare una patch: il discriminatore aggrega la storia appiattita e il massimo sulle celle valide, mentre loss e score generativo considerano l'intero supporto osservato. L'ablazione elimina quindi il mixing convoluzionale locale, senza rendere l'intero detector indipendente dalle altre celle.

Con $k = 5$ aumenta l'ampiezza del kernel, ma non il numero di siti forniti in ingresso. Su una patch 3×3 rimangono al massimo nove siti osservati e la parte esterna è gestita dal padding. Modificare P costituirebbe un diverso intervento, perché cambierebbe il supporto geografico e la dimensione della proiezione storica del discriminatore.

A parità di canali e strati, la dimensione del kernel modifica anche il numero di parametri. Il confronto deve pertanto riportare capacità parametrica, patch, lunghezza delle finestre e configurazione di training: non isola automaticamente il solo effetto dell'estensione spaziale a capacità costante.

4.8.4 Training avversario, anomaly score e soglia globale

Il discriminatore viene addestrato con reale uguale a zero e generato uguale a uno. Gli obiettivi sono

$$\mathcal{L}_D = \tfrac{1}{2}\Big[\mathrm{BCE}(D_{\text{reale}}, 0) + \mathrm{BCE}(D_{\text{generato}}, 1)\Big], \tag{4.16}$$

$$\mathcal{L}_G = \lambda_G \ \mathrm{MSE}(\hat{x}, x) + \mathrm{BCE}(D_{\text{generato}}, 0). \tag{4.17}$$

Il peso di ricostruzione è $\lambda_G = 500$; nella variante ConvGRU la MSE applica la riduzione mascherata descritta sopra. Generatore e discriminatore vengono aggiornati con ottimizzatori Adam separati, prima D e poi G. Nel passo del generatore, i parametri del discriminatore sono congelati ma viene mantenuto il gradiente rispetto alla predizione generata. La storia usata per questa loss è ricalcolata con i pesi aggiornati di D; il riuso del forward del generatore non sostituisce questo aggiornamento. Il valore del discriminatore non viene interpretato come probabilità di anomalia calibrata mediante etichette reali.

Lo score combina l'errore quadratico medio sul contesto spaziale e la differenza $D_{\text{reale}} - D_{\text{generato}}$. Le due componenti vengono normalizzate separatamente con min–max sull'intero insieme di test località–timestamp e sommate. I residui per feature della sola località centrale sono conservati come diagnostica distinta.

La decisione utilizza un ranking globale stabile: con percentuale p, vengono selezionate $\lceil np/100 \rceil$ osservazioni fra le n disponibili. Nelle esecuzioni $p = 1$. Non viene applicato un budget dell'1% separatamente a ogni sito. Poiché normalizzazione dello score e ranking dipendono dal test completo, il protocollo è retrospettivo; non definisce da solo una soglia causale per uso online.

4.8.5 Campionamento e riproducibilità del calcolo

Il training predefinito visita il prodotto completo fra tempi target e località con ordine casuale. La modalità globale conserva l'ordine del percorso di riferimento; una modalità alternativa mescola blocchi e campioni al loro interno. Quest'ultima conserva insieme e molteplicità dei campioni, ma cambia l'ordine e la distribuzione delle permutazioni: deve essere indicata come parte del protocollo, non soltanto come scelta di memoria.

Estrazione vettoriale delle finestre, cache normalizzata e scoring su disco permettono di elaborare i dati a blocchi. Gli estremi delle due componenti dello score rimangono globali sull'intero test; non vengono stimati separatamente per blocco. Il ranking esterno conserva l'ordinamento decrescente e risolve i pareggi secondo l'indice originale. Il batch di inferenza è configurabile

separatamente da quello di training. L'equivalenza prevista dalle implementazioni e dai relativi controlli non costituisce una misura di accelerazione o di riduzione della memoria nelle esecuzioni reali.

4.9 Estensione a ERA5 ed estrazione degli eventi

4.9.1 Adattamento del detector alla cadenza trioraria

L'estensione utilizza i cubi e la maschera descritti nella Sezione 3.4, mantenendo l'architettura ConvGRU–LSTM e le loss della Sezione 4.8. Il target del generatore resta meteorologico e comprende ora quindici feature. La griglia è definita direttamente in coordinate geografiche, con EPSG:4326 e passo angolare di 0.5°.

La cadenza diventa di tre ore e il trend viene impostato a 56 passi, conservando una durata di 168 ore. In questa prima estensione il ramo recente mantiene un passo e la codifica di ora e giorno della settimana rimane di dimensione 31. Lunghezza del ramo recente e codifica temporale cambiano negli sviluppi della Sezione 4.10. Preparazione, training con scoring e analisi degli eventi costituiscono fasi distinte: gli eventi vengono ricavati dagli score già disponibili, senza un nuovo aggiornamento dei pesi del detector.

4.9.2 Soglia, morfologia e cluster spaziali

Gli score $[T, N_{\text{valide}}]$ vengono ricollocati sulla griglia $[T, H, W]$, mantenendo non valide le celle escluse. La selezione iniziale può utilizzare una soglia assoluta oppure un percentile degli score finiti, globale per default o distinto per frame. Una cella è selezionata soltanto se lo score è strettamente maggiore della soglia. In presenza di pareggi, questa regola non garantisce lo stesso numero di selezionati del top-K esatto degli export PVGIS.

Per ogni frame, la maschera binaria viene sottoposta ad apertura e chiusura, rispettando le celle valide. Il default usa un elemento strutturante quadrato 3×3 e un'iterazione per operazione. Le componenti connesse sono individuate con otto vicini e possono essere filtrate per numero minimo di celle. Le operazioni morfologiche possono rimuovere o aggiungere celle rispetto alla selezione iniziale: i cluster risultanti non coincidono necessariamente con l'insieme degli score sopra soglia.

Il kernel della morfologia e quello della ConvGRU sono parametri di fasi diverse. Un confronto fra kernel neurali 1×1 e 5×5 non implica una modifica dell'elemento strutturante usato sugli eventi. Le aree dei cluster

sono ottenute sommando le aree sferiche delle celle e i centroidi sono pesati con tali aree. Questa correzione geometrica nel postprocessing non rende uniforme in chilometri la patch neurale, la cui estensione fisica varia con la latitudine.

4.9.3 Collegamento temporale, separazioni e fusioni

I cluster di frame consecutivi vengono collegati secondo sovrapposizione, sovrapposizione dopo dilatazione, distanza dei centroidi oppure unione dei criteri. Indicando con A e B i supporti di due cluster, il rapporto di sovrapposizione è

$$o(A, B) = \frac{|A \cap B|}{\min(|A|, |B|)}. \tag{4.18}$$

Non si tratta dell'intersezione sull'unione. Nel criterio dilatato, A è sostituito dal supporto ottenuto dopo dilatazione, anche nel denominatore. Il default utilizza una dilatazione di una cella e una soglia di sovrapposizione pari a 0.1; la distanza dei centroidi è un criterio alternativo configurabile.

L'identità di un evento corrisponde a una componente connessa del grafo temporale dei cluster. Il collegamento non è vincolato a essere uno a uno: una separazione mantiene i rami nello stesso evento, mentre una fusione unifica retrospettivamente le identità precedenti. Un salto nella cadenza temporale interrompe i collegamenti, evitando di unire automaticamente osservazioni separate da intervalli mancanti.

La durata riportata comprende l'intervallo rappresentato dall'ultimo frame,

$$d_{\text{evento}} = t_{\text{fine}} - t_{\text{inizio}} + \Delta t, \qquad \Delta t = 3\,\text{h} \tag{4.19}$$

nel default ERA5; il solo tempo trascorso fra primo e ultimo frame viene conservato separatamente. La normalizzazione degli score sull'intero test, la soglia globale quando utilizzata e l'unificazione retrospettiva degli eventi definiscono un protocollo di analisi successiva al periodo osservato, non un sistema causale di allerta.

4.10 STGAN su ERA5: score Monte Carlo e varianti ConvGRU e GAT-GRU

Gli sviluppi di questa sezione riguardano il solo percorso ERA5. Feature, griglia, maschera delle celle ed estrazione degli eventi restano quelle delle Sezioni 3.4 e 4.9. Il lavoro procede su due linee parallele, che condividono protocollo di training, score e monitoraggio e si distinguono per l'encoder

spaziale del generatore: una ConvGRU, come nella Sezione 4.8.2, oppure una Graph Attention Network. Nessuna delle due linee è la continuazione dell'altra.

4.10.1 Dropout nel generatore e campionamento dello score

Lo score è campionato con il dropout Monte Carlo [12]. Il generatore riceve tre strati di dropout: sulla rappresentazione spaziale del ramo recente, sulla rappresentazione del trend e sulla loro concatenazione con la codifica temporale, prima della proiezione di uscita. La probabilità predefinita è 0.2. Il discriminatore non contiene dropout.

Durante lo scoring il modello è in modalità di valutazione, con l'eccezione dei dropout del generatore, che restano attivi. Per ogni osservazione vengono estratti J campioni, 20 nel default. Gli encoder del generatore, la codifica della storia nel discriminatore e il valore D_{reale} non dipendono dal dropout e sono calcolati una sola volta; a ogni campione vengono ripetuti i dropout, la proiezione di uscita e la valutazione del dato generato.

Per la coppia tempo–località (t, n) e il campione j, le due componenti sono l'errore quadratico medio $s^{(j)}_{G,tn}$ sulle celle valide del contesto spaziale e la differenza $s^{(j)}_{D,tn} = D_{\text{reale}} - D^{(j)}_{\text{generato}}$. Indicando con $\bar{s}_G$ e $\bar{s}_D$ le rispettive medie sui J campioni, lo score è

$$a_{tn} = \frac{\bar{s}_{G,tn} - \min \bar{s}_G}{\max \bar{s}_G - \min \bar{s}_G} + \frac{\bar{s}_{D,tn} - \min \bar{s}_D}{\max \bar{s}_D - \min \bar{s}_D}, \tag{4.20}$$

dove minimi e massimi sono presi sull'intero prodotto tempo–località del test. La fusione mantiene quindi lo schema della Sezione 4.8, applicato alle mappe medie. Una componente costante contribuisce zero.

Gli stessi estremi trasformano ciascun campione, producendo $a^{(j)}_{tn}$. La dispersione associata allo score è la deviazione standard di popolazione

$$u_{tn} = \sqrt{\frac{1}{J} \sum_{j=1}^{J} \left(a^{(j)}_{tn} - a_{tn} \right)^2}. \tag{4.21}$$

Con $J = 1$ lo score coincide con quello deterministico e u_{tn} è nulla. Vengono conservati anche media e deviazione standard delle due componenti non normalizzate e la loro covarianza.

La quantità u_{tn} misura la variabilità dello score rispetto alle maschere di dropout del generatore. È espressa nelle unità dello score normalizzato e non è una probabilità di anomalia; la sua calibrazione come misura di incertezza

non è verificata dal metodo. Come nel caso deterministico, la normalizzazione dipende da tutti gli score del test, senza uso di etichette: estendere il periodo di test può modificare estremi e ordinamento.

4.10.2 Split di validation e bilanciamento dell'addestramento avversario

Gli obiettivi $\mathcal{L}_D$ e $\mathcal{L}_G$ sono quelli della Sezione 4.8. Il peso di ricostruzione λ_G diventa un parametro, con valore predefinito invariato. I tassi di apprendimento dei due ottimizzatori Adam possono essere distinti: quello del discriminatore è espresso come rapporto rispetto a quello del generatore oppure come valore indipendente, e le due forme non possono essere indicate insieme. Anche il coefficiente β_1 dei due ottimizzatori, che regola quanto gli aggiornamenti precedenti pesano nella media dei gradienti, è un parametro: il valore predefinito è 0.9, quello usato dal codice degli autori di STGAN.

Un secondo controllo riguarda il numero di aggiornamenti per batch. Con rapporto n_D:n_G, sullo stesso batch vengono eseguiti prima n_D aggiornamenti del discriminatore e poi n_G del generatore, ciascuno con un proprio forward completo; il default è 1:1. Il passo del discriminatore e quello del generatore utilizzano forward indipendenti del generatore, quindi maschere di dropout distinte. Questo rapporto è un conteggio di aggiornamenti e non va confuso con il rapporto fra i tassi di apprendimento.

A ogni epoca vengono salvati i pesi e lo stato dei due ottimizzatori. Un training interrotto può essere ripreso soltanto con la stessa configurazione, la stessa normalizzazione e gli stessi riferimenti di monitoraggio. È disponibile un'esecuzione in precisione mista BF16, con pesi mantenuti in FP32 e loss avversaria calcolata sui logit; si tratta di una scelta numerica, da riportare insieme alla configurazione.

Rapporti fra tassi, numero di aggiornamenti e peso di ricostruzione sono strumenti per studiare l'equilibrio fra le due reti. La loro disponibilità non indica quale combinazione sia preferibile.

4.10.3 Finestra recente, codifica temporale ciclica e normalizzazione stagionale

La finestra recente contiene gli R istanti che precedono quello da stimare. L'unità ricorrente spaziale la percorre in ordine: parte da uno stato nullo ed esegue un aggiornamento per ogni istante, sicché lo stato finale riassume gli R campi osservati. Con $R = 1$ il ramo recente vede soltanto l'ultimo istante e la ricorrenza si riduce a un solo aggiornamento: la storia più lunga è affidata

alla LSTM del trend, che riguarda la sola cella centrale. Con $R > 1$ il modello riceve anche l'evoluzione del campo negli istanti precedenti, e l'area che può influenzare una cella cresce con R, perché a ogni aggiornamento lo stato si propaga alle celle vicine.

Nell'analisi iniziale sui dati PVGIS la finestra recente è di un passo, cioè un'ora. Su ERA5 è portata a $R = 16$ passi, che alla cadenza di tre ore corrispondono a 48 ore; il trend conserva 56 passi, cioè 168 ore.

La codifica temporale predefinita resta quella a 31 elementi, composta dal giorno della settimana e dall'ora UTC. In alternativa è disponibile una codifica ciclica a quattro elementi, diversa per località. Indicando con h_t l'ora UTC, con ℓ_n la longitudine in gradi, con g_t il giorno frazionario dell'anno e con G_t il numero di giorni dell'anno corrispondente, la codifica è

$$c_{tn} = [\sin\phi_{tn},\ \cos\phi_{tn},\ \sin\psi_t,\ \cos\psi_t]\,, \quad \phi_{tn} = \frac{2\pi}{24}\left(h_t + \frac{\ell_n}{15}\right), \quad \psi_t = \frac{2\pi g_t}{G_t}. \tag{4.22}$$

Il primo angolo rappresenta l'ora solare locale, ottenuta dalla sola longitudine senza fusi orari; il secondo la posizione nell'anno. La codifica ciclica non contiene il giorno della settimana.

La normalizzazione predefinita rimane il min–max per feature stimato sul training. La variante stagionale applica prima una standardizzazione per località n, feature f, ora del giorno o e giorno dell'anno g,

$$z_{tnf} = \frac{x_{tnf} - \mu_{nfog}}{\sigma_{nfog}}, \tag{4.23}$$

e poi lo stesso min–max. Media e deviazione standard sono stimate sul solo training, raggruppando una finestra circolare di giorni attorno a g, di quindici giorni per lato nel default. La dispersione è calcolata attorno alla media lisciata di ciascun giorno, in modo che la variazione del ciclo stagionale all'interno della finestra non venga contata come variabilità. Un valore minimo, pari a una frazione della deviazione standard complessiva della feature, limita la divisione dove una variabile è quasi costante, come la radiazione solare notturna.

Finestra recente, codifica temporale e normalizzazione modificano l'ingresso del modello: ciascuna scelta richiede un nuovo addestramento e identifica una configurazione distinta.

4.10.4 Monitoraggio senza etichette e spazio PCA di riferimento

Le quantità di questa sezione servono a osservare l'addestramento e a confrontare configurazioni. Non entrano in una loss, in un aggiornamento dei pesi,

nello score o nella valutazione sul test, e non utilizzano etichette di anomalia. Il loro calcolo avviene senza gradiente e ripristina gli stati dei generatori casuali, così da non alterare la traiettoria del training.

Al termine di ogni epoca, un sottoinsieme fisso della validation viene elaborato con un forward deterministico, a dropout spento. Il sottoinsieme comprende 32 timestamp equispaziati nel default, ciascuno con tutte le località. Vengono registrate tre diagnostiche: la differenza assoluta media fra le attivazioni del penultimo strato del discriminatore sull'osservazione e sulla ricostruzione; la variazione dello score fra epoche consecutive sulle stesse celle, riassunta da media, mediana e correlazione di Spearman; la Maximum Mean Discrepancy [20] fra le stesse attivazioni, con kernel RBF e banda scelta con l'euristica della mediana.

Una seconda misura confronta osservazioni e ricostruzioni in uno spazio indipendente dal modello. Lo spazio è ottenuto da un'analisi delle componenti principali dei campi di training: ogni campione è il campo completo di un timestamp, normalizzato e appiattito su località e feature. La PCA è calcolata in forma esatta su un insieme di timestamp equispaziati sull'intero training, 4096 nel default, e viene salvata con le componenti principali e la varianza spiegata. È costruita una sola volta, prima delle esecuzioni, e successivamente soltanto caricata.

Su questo spazio viene definito un riferimento per la validation: S sottoinsiemi fissi di timestamp, cinque da 512 nel default e disgiunti quando il numero di timestamp lo consente, le feature PCA delle loro osservazioni e una banda σ pari alla distanza euclidea mediana fra tali feature. Anche questo riferimento è fissato prima delle esecuzioni. A ogni epoca, per ciascun sottoinsieme, si calcola la stima non distorta

$$\widehat{\mathrm{MMD}}^2 = \frac{1}{n(n-1)} \sum_{i \neq i'} k(x_i, x_{i'}) + \frac{1}{n(n-1)} \sum_{i \neq i'} k(y_i, y_{i'}) - \frac{2}{n^2} \sum_{i,i'} k(x_i, y_{i'}), \tag{4.24}$$

dove x_i sono le feature PCA delle osservazioni, y_i quelle delle ricostruzioni del generatore e il kernel è la media di tre RBF,

$$k(a, b) = \frac{1}{3} \sum_{c \in \{0.5,\, 1,\, 2\}} \exp\left(-\frac{\|a - b\|^2}{2(c\sigma)^2} \right). \tag{4.25}$$

Vengono registrate media e varianza della stima sui sottoinsiemi e la media mobile delle ultime epoche, cinque nel default. Quest'ultima è la quantità proposta per la selezione fra configurazioni. La stima non distorta può assumere valori leggermente negativi.

Dopo l'ultima epoca viene inoltre calcolato, su tutti i punti validi della validation, l'errore di ricostruzione medio sui campioni Monte Carlo, riassunto da media, deviazione standard, mediana e 95-esimo percentile.

Numero di componenti principali, sottoinsiemi e banda fanno parte del protocollo e devono essere riportati. Poiché tutte le esecuzioni confrontate caricano gli stessi riferimenti, le differenze nella misura non dipendono da una nuova stima dello spazio o della banda. Una MMD più bassa indica ricostruzioni più vicine alle osservazioni nello spazio considerato; non misura direttamente la qualità del rilevamento delle anomalie.

4.10.5 Generatore GAT-GRU sul grafo della griglia

Nella variante su grafo ogni località valida è un nodo. Ciascun nodo riceve un arco da ognuno degli otto vicini immediati presenti sulla griglia e da sé stesso. Gli archi sono diretti e memorizzati in forma sparsa; i bordi non sono collegati fra loro e una cella senza località non genera archi. A differenza del grafo del previsore, gli archi non hanno pesi geografici.

Lo strato di attenzione è quello delle equazioni (2.9)–(2.11), a più teste e con pendenza negativa 0.2 nella LeakyReLU; $\mathcal{N}(i)$ è l'insieme delle sorgenti degli archi entranti in i, compreso i stesso. Nella GAT-GRU lo strato sostituisce la convoluzione nei gate dell'unità ricorrente. Siano $\mathcal{A}_r$, $\mathcal{A}_u$ e $\mathcal{A}_c$ tre strati di attenzione distinti, con le teste mediate e senza non linearità propria, e X'_s l'ingresso del passo s concatenato alla maschera. L'aggiornamento di uno strato ricorrente è

$$R_s = \sigma(\mathcal{A}_r([X'_s, H_{s-1}])) \,, \tag{4.26}$$

$$U_s = \sigma(\mathcal{A}_u([X'_s, H_{s-1}])) \,, \tag{4.27}$$

$$\widetilde{H}_s = \tanh(\mathcal{A}_c([X'_s, R_s \odot H_{s-1}])) \,, \tag{4.28}$$

$$H_s = M \odot \left[U_s \odot H_{s-1} + (1 - U_s) \odot \widetilde{H}_s\right] . \tag{4.29}$$

È la forma delle equazioni (2.5)–(2.8), con l'attenzione su grafo al posto della convoluzione spaziale e con lo stesso trattamento della maschera della Sezione 4.8.2. I default prevedono due strati ricorrenti, quattro teste e 32 canali. Poiché il gate di reset e lo stato candidato applicano l'operatore in sequenza, a ogni passo lo stato si propaga di due archi: con $R \geq 2$ passi recenti e due strati, l'ingresso del primo passo raggiunge i nodi fino a $2R + 1$ archi di distanza. La ConvGRU con kernel 3×3 ha la stessa struttura e lo stesso raggio.

La LSTM del trend elabora una sequenza per nodo e la codifica temporale è proiettata per nodo o condivisa; seguono i tre dropout della Sezione 4.10.1 e la proiezione di uscita, che restituisce $[B, N, F]$.

Il discriminatore resta quello a patch. Per ogni nodo vengono estratte le patch $P \times P$ della storia recente, dell'osservazione e della ricostruzione globale del generatore, con le celle assenti azzerate e la relativa maschera. I centri sono elaborati a blocchi per limitare la memoria. La loss di ricostruzione è la media, sui centri, dell'errore quadratico medio sulla patch di ciascun centro: l'errore di un nodo entra quindi attraverso tutte le patch che lo contengono. Le loss dei blocchi sono pesate per la rispettiva frazione di centri, in modo che la loro somma coincida con la media su tutti i centri, e i gradienti vengono accumulati prima di un unico aggiornamento per rete.

Un campione è un timestamp con tutti i nodi e il batch predefinito contiene un solo timestamp. Un'epoca comprende quindi $\lceil T/B \rceil$ aggiornamenti per rete, con T timestamp utili, contro $\lceil TN/B \rceil$ del modello a patch. Score, campionamento Monte Carlo e fusione delle componenti seguono la Sezione 4.10.1.

Rispetto alla variante ConvGRU sul campo intero della Sezione 4.10.6, il generatore GAT-GRU ha la stessa unità del campione, lo stesso numero di aggiornamenti per epoca, la stessa struttura ricorrente e lo stesso raggio: cambia il modo di pesare i vicini e, con esso, il numero di parametri. Rispetto alla variante ConvGRU a patch cambiano invece anche l'unità del campione e il numero di aggiornamenti per epoca.

4.10.6 Variante convoluzionale sul campo intero

La seconda variante nasce dal tempo di addestramento del modello a patch su ERA5, in cui il numero di aggiornamenti per epoca cresce con il prodotto fra timestamp e località. Mantiene la ConvGRU e modifica l'unità del campione: invece di una cella con la propria patch, un campione è l'intero campo di un timestamp, disposto sul reticolo $H \times W$. Moduli e parametri sono quelli del modello a patch; cambia ciò a cui vengono applicati. Alla variante porta anche la lunghezza della finestra recente: su una patch 3×3 aumentare R moltiplica il costo di ciascuno dei TN campioni senza ampliare l'area osservata, che resta di nove celle. Il passaggio da uno a sedici passi recenti è stato quindi fatto sul campo intero.

Il generatore opera sul campo completo, da $[B, R, F, H, W]$ a $[B, F, H, W]$. Le convoluzioni scorrono sull'intero reticolo, quindi il campo ricettivo non è più troncato al bordo di una patch e ogni cella viene ricostruita una sola volta. La LSTM del trend e la codifica temporale sono calcolate per cella e disposte sul reticolo, dove il modello a patch replicava quelle del sito centrale sulle posizioni della patch.

Il discriminatore rimane locale. La patch di ogni cella viene estratta dal campo e il discriminatore a patch le valuta tutte in un'unica passata, con le

stesse maschere e gli stessi azzeramenti. L'uscita relativa a una cella è quella che il discriminatore a patch produrrebbe sulla sua patch. Una convoluzione che scorre liberamente sul campo non darebbe lo stesso valore, perché la ConvGRU del discriminatore applica il padding all'interno di ciascuna patch. Il costo del discriminatore per cella resta pertanto quello del modello a patch.

La loss di ricostruzione è la media su celle con località e feature del campo, poi sui timestamp del batch. La loss avversaria è la media della BCE sugli output locali, uno per cella. Lo score conserva le definizioni per coppia tempo–località: la componente di ricostruzione è l'errore medio sulla patch della cella, calcolato sul campo ricostruito.

Come nella variante su grafo, un'epoca comprende $\lceil T/B \rceil$ aggiornamenti per rete invece di $\lceil TN/B \rceil$. A parità di epoche i due regimi non sono confrontabili: il numero di aggiornamenti dei pesi differisce di un fattore dell'ordine di N e ogni gradiente è mediato su tutte le celle di un timestamp. La variante va quindi trattata come configurazione di training distinta, non come ottimizzazione del modello a patch.

4.10.7 Incertezza negli eventi e normalizzazione climatologica degli score

L'estrazione degli eventi della Sezione 4.9 può operare sullo score combinato oppure su una sola componente. La dispersione u_{tn} viene ricollocata sulla griglia e riportata per cluster, come media e massimo sulle celle, e per evento, come media pesata sulle celle e massimo. Non partecipa alla soglia, alla morfologia o ai collegamenti temporali: è un'annotazione degli eventi già individuati.

Una trasformazione successiva allo scoring esprime ogni score rispetto alla climatologia della stessa località. Per la località n, il mese m e l'ora UTC o del timestamp t, appartenente all'anno y,

$$\zeta_{tn} = \frac{a_{tn} - \mu_{nmo}^{(-y)}}{\sigma_{nmo}^{(-y)}}, \tag{4.30}$$

dove media e deviazione standard sono calcolate sugli score della stessa località, mese e ora negli altri anni del test. Un anno non contribuisce quindi alla propria climatologia. I gruppi con meno di trenta valori di riferimento, nel default, o con varianza nulla non ricevono uno score. La dispersione u_{tn} viene divisa per la stessa deviazione standard. Gli eventi possono essere estratti da questi score normalizzati con lo stesso algoritmo.

Questa trasformazione agisce sugli score, dopo l'addestramento, e non modifica il detector. È distinta dalla normalizzazione stagionale della Sezione 4.10.3, che agisce sull'ingresso e richiede un nuovo training. Le due

operazioni rimuovono componenti cicliche in punti diversi della catena e il loro uso congiunto deve essere dichiarato.

Capitolo 5

Esperimenti

Il capitolo descrive gli esperimenti nell'ordine in cui sono stati condotti, le configurazioni di addestramento, il protocollo con cui i modelli sono valutati e le metriche. I metodi sono quelli del Capitolo 4; i risultati, con la descrizione delle singole analisi, sono nel Capitolo 6.

5.1 Percorso degli esperimenti

Gli esperimenti seguono due linee che si incontrano nell'analisi finale: il previsore della produzione e il rilevamento delle anomalie. La Tabella 5.1 le riassume.

Il primo passo riguarda il previsore. Le soglie climatologiche della Sezione 4.3 indicano le osservazioni insolite dell'anno di test, e su di esse si verifica se un intervallo costruito attorno alla previsione contiene il valore osservato. I primi due metodi provati sono il dropout Monte Carlo e il Deep Ensemble, applicati al backbone senza modificarlo. Sono esperimenti preliminari, con un addestramento breve: poiché gli intervalli ottenuti contengono una quota ridotta delle osservazioni, come riportato nel Capitolo 6, non sono stati proseguiti con addestramenti più lunghi.

Il secondo passo introduce le due varianti basate su equazioni differenziali stocastiche. La variante SDE U-Net segue l'articolo di Monaco et al. [15], compreso l'addestramento sulle sole finestre normali. La variante SDE-Net segue l'articolo di Kong et al. [3] ed è eseguita in tre configurazioni: a un'ora, con uscita diretta su sei orizzonti da una a sei ore, e con le etichette di MTGFlow al posto di quelle climatologiche.

La seconda linea cerca le anomalie con modelli appresi, per verificare se individuano condizioni diverse dai valori estremi segnalati dalle soglie climatologiche. Sui dati PVGIS, come analisi iniziale, sono addestrati MTGFlow, che

non usa il contesto geografico, la versione su grafo di STGAN e la variante ConvGRU, quest'ultima con kernel di lato 1, 3 e 5. Poiché i dati PVGIS contengono soltanto irradianza, temperatura e vento, il detector è poi portato sui campi ERA5, prima con un passo recente su patch e poi con sedici passi sul campo intero, nelle due varianti ConvGRU e GAT-GRU.

Le due linee si incontrano nell'analisi della Sezione 6.4: gli errori e gli intervalli del previsore sono confrontati fra le osservazioni che un detector segnala e le altre.

Tabella 5.1: Esperimenti condotti, nell'ordine del percorso, con i dati usati e lo scopo di ciascuno.

Esperimento	Dati	Scopo
Soglie climatologiche	PVGIS	Prime etichette di condizioni insolite, per località e ora
Dropout Monte Carlo, Deep Ensemble	PVGIS	Verificare se un intervallo ottenuto campionando il backbone contiene le osservazioni
Variante SDE U-Net	PVGIS	Schema di Monaco et al. sul backbone, con addestramento sulle sole finestre normali
Variante SDE-Net	PVGIS	Schema di Kong et al. con testa gaussiana; un'ora, sei orizzonti, etichette MTGFlow
MTGFlow	PVGIS	Detector appreso senza contesto geografico, un modello per località
STGAN su grafo	PVGIS	Detector con contesto spaziale, come nell'articolo
STGAN con ConvGRU	PVGIS	Stesso detector su griglia; kernel di lato 1, 3 e 5
STGAN con ConvGRU e con GAT-GRU	ERA5	Stesso detector su quindici variabili e su un dominio più ampio

5.2 Configurazioni di addestramento

La Tabella 5.2 riporta anni, numero di epoche, dimensione del batch, tasso di apprendimento e semi dei modelli addestrati sui dati PVGIS. Tutti usano le 1149 località e il 2019 come anno di test.

I previsori ricevono una finestra di 24 ore e undici feature. Il dropout Monte Carlo usa 20 passaggi in avanti e il Deep Ensemble cinque membri; la variante SDE U-Net campiona 20 traiettorie e la variante SDE-Net 10. Gli esperimenti preliminari sono addestrati per 5 epoche e le due varianti SDE

Tabella 5.2: Configurazioni di addestramento sui dati PVGIS. Per la variante SDE-Net il secondo tasso è quello della rete di diffusione. L'ultima colonna indica il numero di esecuzioni con semi diversi.

Modello	Training	Validation	Epoche	Batch	Tasso	Esecuzioni
Dropout Monte Carlo	2016–2018	–	5	16	10^{-3}	1
Deep Ensemble	2016–2018	–	5	16	10^{-3}	5
Variante SDE U-Net	2016–2017	2018	60	16	10^{-4}	1
Variante SDE-Net	2016–2018	–	60	16	10^{-4}, 10^{-2}	1
MTGFlow	2005–2018	–	40	256	$2 \cdot 10^{-3}$	1
STGAN su grafo	2005–2018	–	6	256	10^{-3}	1
STGAN con ConvGRU	2005–2018	–	6	256	10^{-3}	1

per 60: i due gruppi non sono a parità di addestramento, e i loro risultati non vanno letti come un confronto alla pari.

La variante SDE U-Net sceglie sul 2018 l'epoca del modello valutato; quando è addestrata sulle sole finestre normali, il filtro conserva 11109 delle 17496 finestre di training e 6054 delle 8736 di validation. La variante SDE-Net, come l'articolo, è addestrata per un numero fissato di epoche e valutata all'ultima; la sua diffusione massima parte da 0.01 e passa a 0.5 dopo 30 epoche, e il tasso di apprendimento del drift è ridotto di un fattore 10 dopo l'epoca 20.

I detector su PVGIS usano tre variabili. MTGFlow è addestrato con finestre di 60 ore, un modello per località. Le versioni di STGAN usano un passo recente, 168 passi di trend e nove siti per contesto; ogni epoca visita tutte le coppie fra località e istanti, 140803056 campioni, e la variante ConvGRU ha 140931 parametri nel generatore e 114593 nel discriminatore con kernel 3.

Su ERA5 il training comprende gli anni 1980–2004 e il test gli anni 2005–2025, con sei epoche. Nella configurazione a patch un'epoca comprende 3025793 aggiornamenti dei pesi; sul campo intero ne comprende 70072, perché un campione è un intero istante. A parità di epoche le due configurazioni non sono quindi confrontabili.

Tutti i modelli sono addestrati su una scheda NVIDIA RTX PRO 6000 Blackwell.

5.3 Protocollo di valutazione

Tutti i modelli sui dati PVGIS sono valutati sul 2019, che non entra in alcun addestramento. Per i previsori ogni previsione richiede le 24 ore precedenti: le previsioni sono 8736 per località, in tutto 10037664. I detector assegnano uno score a ogni ora dell'anno, usando come contesto la coda del periodo di training: le osservazioni valutate sono 10065240.

Le metriche del previsore sono calcolate sull'insieme completo e separatamente sulle ore diurne, definite da un'irradianza al target maggiore di $10\,\mathrm{W\,m^{-2}}$: sono 4747545, il 47.3% del totale. Le fasce di produzione dividono le osservazioni diurne in intervalli di 20 punti percentuali rispetto a un riferimento unico per tutte le località, il percentile 99 della produzione positiva diurna. La fascia è assegnata dalla produzione osservata e non da quella prevista.

Le osservazioni sono divise in normali e segnalate secondo le etichette disponibili. Le soglie climatologiche sono calcolate sugli anni 2005–2018, che precedono l'anno di test: con queste le segnalate sono 1059283, il 10.6%.

Per i detector la decisione dipende dal metodo: MTGFlow usa la soglia per località dell'equazione (4.14), STGAN segnala l'1% delle osservazioni con lo score più alto sull'intero test, cioè 100653 osservazioni.

Nel confronto fra previsore e detector ogni previsione è associata alla decisione del detector sulla stessa località e sullo stesso istante previsto. Con sei orizzonti la stessa osservazione è associata a più previsioni, emesse in ore diverse. La restrizione alle ore diurne è applicata dopo la decisione: l'1% di STGAN resta calcolato su tutte le ore e non soltanto su quelle diurne. Il modo in cui è calcolata ciascuna analisi è descritto insieme al risultato, nel Capitolo 6.

5.4 Metriche

Per un gruppo di n previsioni, le metriche puntuali sono l'errore assoluto medio e la radice dell'errore quadratico medio,

$$\mathrm{MAE} = \frac{1}{n}\sum_{i=1}^{n} |y_i - \hat{y}_i|, \qquad \mathrm{RMSE} = \sqrt{\frac{1}{n}\sum_{i=1}^{n} (y_i - \hat{y}_i)^2}, \tag{5.1}$$

espresse in watt. Le aggregazioni per orizzonte, fascia di produzione, etichetta o caso input–target utilizzano i campioni appartenenti al gruppo; il RMSE complessivo non viene ottenuto mediando i RMSE dei sottogruppi.

Un intervallo predittivo $[l_i, u_i]$ è valutato per affidabilità e per ampiezza. La copertura è la quota di osservazioni contenute nell'intervallo,

$$\text{PICP} = \frac{1}{n} \sum_{i=1}^{n} \mathbb{1} \left[l_i \leq y_i \leq u_i \right], \tag{5.2}$$

e per un intervallo al 95% dovrebbe essere vicina a 0.95. L'ampiezza media, divisa per l'intervallo dei valori osservati R, è

$$\text{NMPIL} = \frac{1}{nR} \sum_{i=1}^{n} (u_i - l_i). \tag{5.3}$$

Un intervallo utile è stretto e insieme affidabile. Il criterio usato da Monaco et al. [15] combina le due misure penalizzando l'ampiezza quando la copertura scende sotto il livello γ:

$$\text{CLC} = \text{NMPIL} \left[1 + \exp(-\eta \left(\text{PICP} - \gamma \right)) \right], \tag{5.4}$$

con $\gamma = 0.95$ e $\eta = 9$. Valori più bassi sono migliori.

L'accordo fra due detector che segnalano gli insiemi di osservazioni A e B è misurato dall'indice di Jaccard,

$$J(A, B) = \frac{|A \cap B|}{|A \cup B|}, \tag{5.5}$$

che vale 1 quando gli insiemi coincidono e 0 quando sono disgiunti. Non è una misura di accuratezza: due detector possono concordare ed entrambi sbagliare.

Capitolo 6

Risultati e discussione

6.1 Accuratezza del forecasting

6.1.1 Enhanced Monte Carlo Dropout

6.1.2 Deep Ensemble

6.1.3 Variante SDE U-Net

6.1.4 Variante SDE-Net e previsione diretta multiorizzonte

6.2 Quantificazione dell'incertezza

6.2.1 Intervalli dell'Enhanced Monte Carlo Dropout

6.2.2 Intervalli e disaccordo tra membri del Deep Ensemble

6.2.3 Intervalli delle due varianti SDE

6.3 Rilevamento delle anomalie con MTG-Flow, STGAN e ConvGRU

6.3.1 Score e distribuzione spazio-temporale delle anomalie

Per le osservazioni segnalate dalla ConvGRU con kernel 3 è disponibile la ripartizione dell'errore di ricostruzione della località centrale fra le tre variabili. In media il 75.5% dell'errore è dovuto all'irradianza, il 15.8% alla temperatura e l'8.6% al vento. L'irradianza è la variabile con il contributo maggiore in 81733 delle 100653 osservazioni segnalate (81.2%), la temperatura in 13320 (13.2%) e il vento in 5600 (5.6%). Su PVGIS le osservazioni segnalate riguardano quindi in prevalenza scostamenti dell'irradianza, in accordo con la composizione di questi dati, che contengono le sole grandezze legate alla produzione (Capitolo 3).

Il dato descrive la sola componente di ricostruzione dello score e le sole osservazioni segnalate. La stessa ripartizione sulle osservazioni non segnalate non è stata calcolata: non è quindi possibile dire se la prevalenza dell'irradianza sia specifica delle anomalie o valga per l'errore di ricostruzione in generale.

6.3.2 Soglie IQR, top-K e confronto fra grafo e griglia

6.3.3 Stabilità delle decisioni al variare del modello

La versione su grafo di STGAN e la variante ConvGRU sono state addestrate sugli stessi dati PVGIS con lo stesso protocollo: sei epoche, un passo recente, 168 passi di trend e l'1% delle osservazioni di test segnalato con un ranking globale. La ConvGRU è stata addestrata con kernel di lato 1, 3 e 5, a parità di ogni altra impostazione. Ogni detector segnala quindi 100653 delle 10065240 osservazioni del 2019. In assenza di etichette non è possibile stabilire quale configurazione individui meglio le anomalie; si può misurare quanto le osservazioni segnalate coincidono. La Tabella 6.1 confronta ciascuna configurazione ConvGRU con la versione su grafo.

L'accordo è da sei a dieci volte quello atteso per due detector indipendenti, ma resta basso in valore assoluto: più del 90% delle osservazioni segnalate da una configurazione ConvGRU non è segnalato dalla versione su grafo. Il risultato non cambia sulle 917 località con patch completa, nelle quali le due versioni osservano gli stessi nove siti. La quota di osservazioni segnalate differisce inoltre fra località con patch completa e incompleta: 0.93% e 1.27% per la ConvGRU con kernel 3, contro 0.97% e 1.12% per la versione su grafo.

Tabella 6.1: Accordo fra le osservazioni segnalate dalla variante ConvGRU e dalla versione su grafo di STGAN sui dati PVGIS del 2019. Ogni detector segnala 100653 osservazioni. L'indice di Jaccard è il rapporto fra le osservazioni segnalate da entrambi e quelle segnalate da almeno uno; l'ultima riga riporta il valore atteso per due detector indipendenti con la stessa quota.

Configurazione	Segnalate da entrambi	Quota	Jaccard	Patch complete	Patch incomplete
ConvGRU, kernel 1	9956	9.9%	0.052	0.054	0.046
ConvGRU, kernel 3	6267	6.2%	0.032	0.032	0.032
ConvGRU, kernel 5	7325	7.3%	0.038	0.039	0.034
Detector indipendenti	circa 1007	1.0%	0.005	–	–

Altre due misure vanno nella stessa direzione. La loss del discriminatore resta fra 0.60 e 0.63 per tutte le sei epoche nelle tre configurazioni ConvGRU, mentre un discriminatore che assegna la stessa uscita a ogni ingresso ha loss $\ln 2 \approx 0.69$; per la versione su grafo la storia delle loss non è stata salvata. Lo score, somma di due componenti normalizzate in $[0, 1]$, è concentrato in un intervallo stretto: con kernel 3, sulle patch complete, la mediana è 0.489 e il quantile 0.95 è 0.553.

Una lettura coerente con le tre misure è che su questi dati lo score distingua poco le osservazioni fra loro: l'1% più alto è scelto fra valori vicini, e piccole differenze fra i modelli bastano a cambiarne la composizione. È un'interpretazione e non una dimostrazione, perché le due componenti dello score non sono state salvate separatamente e il contributo di ciascuna non è verificabile su queste esecuzioni.

Due limiti restringono le conclusioni. Ogni configurazione è stata addestrata con un solo seme: non è noto quanto concorderebbero due esecuzioni identiche con semi diversi, e la differenza osservata non può essere attribuita alla sola architettura. Il confronto è inoltre fra ciascuna ConvGRU e la versione su grafo; l'accordo diretto fra kernel diversi non è stato calcolato.

La conseguenza riguarda le analisi della Sezione 6.4: gli errori del previsore sulle osservazioni segnalate da STGAN si riferiscono alle decisioni di una specifica configurazione, e non a un insieme di anomalie stabile rispetto al modello.

6.4 Analisi post-hoc forecasting–anomalie

6.4.1 MAE e RMSE sui campioni normali e anomali

6.4.2 Confronto a una e sei ore e quattro casi input–target

6.4.3 Errore in funzione della soglia e bande di dispersione

6.4.4 Errori per tipo e direzione dell'estremo meteorologico

6.5 Anomalie ed eventi geografici su ERA5

6.5.1 Copertura dei dati e configurazione del detector

6.5.2 Score Monte Carlo e dispersione

6.5.3 Monitoraggio per epoca e selezione delle configurazioni

6.5.4 Confronto fra generatore ConvGRU e GAT e fra unità di training

6.5.5 Cluster spaziali, traiettorie e sensibilità del post-processing

6.6 Confronto progressivo degli esperimenti

6.6.1 Accuratezza puntuale

6.6.2 Copertura e ampiezza degli intervalli

6.6.3 Costo computazionale e complessità dei modelli

Capitolo 7

Conclusioni e sviluppi futuri

7.1 Il problema affrontato

7.2 Sintesi dei risultati

7.3 Limiti dello studio

7.4 Sviluppi futuri

Bibliografia

[1] J. Antonanzas et al. «Review of photovoltaic power forecasting». In: *Solar Energy* 136 (2016), pp. 78–111. DOI: 10.1016/j.solener.2016.06.069.

[2] Leyan Deng et al. «Graph Convolutional Adversarial Networks for Spatiotemporal Anomaly Detection». In: *IEEE Transactions on Neural Networks and Learning Systems* 33.6 (2022), pp. 2416–2428. DOI: 10.1109/TNNLS.2021.3136171.

[3] Lingkai Kong, Jimeng Sun e Chao Zhang. «SDE-Net: Equipping Deep Neural Networks with Uncertainty Estimates». In: *Proceedings of the 37th International Conference on Machine Learning*. Vol. 119. Proceedings of Machine Learning Research. 2020. arXiv: 2008.10546.

[4] Qihang Zhou et al. «Label-Free Multivariate Time Series Anomaly Detection». In: *IEEE Transactions on Knowledge and Data Engineering* 36.7 (2024), pp. 3166–3179. DOI: 10.1109/TKDE.2024.3349613. arXiv: 2312.11549.

[5] Xingjian Wu et al. «CATCH: Channel-Aware Multivariate Time Series Anomaly Detection via Frequency Patching». In: *International Conference on Learning Representations*. 2025.

[6] Sarah Alnegheimish et al. «M2AD: Multi-Sensor Multi-System Anomaly Detection through Global Scoring and Calibrated Thresholding». In: *Proceedings of the 28th International Conference on Artificial Intelligence and Statistics*. Vol. 258. Proceedings of Machine Learning Research. 2025.

[7] Ian J. Goodfellow et al. «Generative Adversarial Nets». In: *Advances in Neural Information Processing Systems*. Vol. 27. Curran Associates, Inc., 2014. arXiv: 1406.2661.

[8] Kyunghyun Cho et al. «Learning Phrase Representations using RNN Encoder-Decoder for Statistical Machine Translation». In: *Conference on Empirical Methods in Natural Language Processing (EMNLP)*. 2014. arXiv: 1406.1078.

[9] Xingjian Shi et al. «Convolutional LSTM Network: A Machine Learning Approach for Precipitation Nowcasting». In: *Advances in Neural Information Processing Systems*. Vol. 28. Curran Associates, Inc., 2015. arXiv: 1506.04214.

[10] Nicolas Ballas et al. «Delving Deeper into Convolutional Networks for Learning Video Representations». In: *International Conference on Learning Representations (ICLR)*. 2016. arXiv: 1511.06432.

[11] Petar Veličković et al. «Graph Attention Networks». In: *International Conference on Learning Representations (ICLR)*. 2018. arXiv: 1710.10903.

[12] Yarin Gal e Zoubin Ghahramani. «Dropout as a Bayesian Approximation: Representing Model Uncertainty in Deep Learning». In: *International Conference on Machine Learning (ICML)*. 2016. arXiv: 1506.02142.

[13] Balaji Lakshminarayanan, Alexander Pritzel e Charles Blundell. «Simple and Scalable Predictive Uncertainty Estimation using Deep Ensembles». In: *Advances in Neural Information Processing Systems (NIPS)*. 2017. arXiv: 1612.01474.

[14] Ricky T. Q. Chen et al. «Neural Ordinary Differential Equations». In: *Advances in Neural Information Processing Systems*. Vol. 31. Curran Associates, Inc., 2018. arXiv: 1806.07366.

[15] Simone Monaco et al. «Uncertainty-aware methods for enhancing rainfall prediction with deep-learning based post-processing segmentation». In: *Computers & Geosciences* 205 (2025), p. 105992. DOI: 10.1016/j.cageo.2025.105992.

[16] Thomas Huld, Richard Müller e Attilio Gambardella. «A new solar radiation database for estimating PV performance in Europe and Africa». In: *Solar Energy* 86.6 (2012), pp. 1803–1815. DOI: 10.1016/j.solener.2012.03.006.

[17] William F. Holmgren, Clifford W. Hansen e Mark A. Mikofski. «pvlib python: a python package for modeling solar energy systems». In: *Journal of Open Source Software* 3.29 (2018), p. 884. DOI: 10.21105/joss.00884.

[18] Hans Hersbach et al. «The ERA5 global reanalysis». In: *Quarterly Journal of the Royal Meteorological Society* 146.730 (2020), pp. 1999–2049. DOI: 10.1002/qj.3803.

[19] Diederik P. Kingma e Jimmy Ba. «Adam: A Method for Stochastic Optimization». In: *International Conference on Learning Representations (ICLR)*. 2015. arXiv: 1412.6980.

[20] Arthur Gretton et al. «A Kernel Two-Sample Test». In: *Journal of Machine Learning Research* 13.25 (2012), pp. 723–773.