

Politecnico di Torino

Politecnico di Torino

Laurea Magistrale in Ingegneria Informatica – Ingegneria del software

A.A. 2025/2026

Sessione di laurea [mese e anno]

Rilevamento unsupervised di anomalie meteorologiche con reti generative avversarie spazio-temporali

Relatore:
Simone Monaco

Candidato:
Alberto Pedalino

Indice

Elenco delle figure **iv**

1 Introduzione **1**
1.1 Contesto e motivazioni 1
1.2 Il problema: anomalie meteorologiche senza etichette 1
1.3 Approccio proposto 2
1.4 Obiettivi e contributi della tesi 3
1.5 Organizzazione del documento 3

2 Fondamenti teorici e stato dell'arte **4**
2.1 Rilevamento di anomalie in serie multivariate e spazio-temporali 4
2.1.1 Dalla deviazione dal valore atteso ai modelli profondi . 4
2.1.2 Reti generative avversarie per il rilevamento di anomalie 6
2.1.3 STGAN 8
2.1.4 Grafi appresi e training contaminato: GDN e MTGFlow 10
2.1.5 Alternative considerate: CATCH e M2AD 11
2.1.6 Il problema della valutazione 12
2.2 Apprendimento automatico e dati meteorologici 13
2.2.1 Dalla previsione numerica ai modelli basati sui dati . . 13
2.2.2 Eventi estremi e anomalie nei campi meteorologici . . . 14
2.3 Contesto spaziale su griglie e grafi 15
2.3.1 Unità ricorrenti convoluzionali 15
2.4 Quantificazione dell'incertezza 16
2.4.1 Dropout Monte Carlo e Deep Ensemble 17
2.5 Da STGAN al detector della tesi 18
2.6 Posizionamento del lavoro 19
2.6.1 Il contributo sostenuto 19
2.6.2 Confronto dei detector esaminati 20

3 Dati e preprocessing **22**
3.1 Campi ERA5, dominio e celle valide 22
3.2 Acquisizione e preparazione dei dati 24
3.3 Anni di addestramento, di validazione e di test 26
3.4 Caratteristiche dei campi 26
3.5 I dati PVGIS del lavoro preliminare 29

4 Metodologia **32**
4.1 Architettura e addestramento avversario 32
4.1.1 Generatore ConvGRU sul campo intero e celle assenti . 33
4.1.2 Discriminatore locale 35
4.1.3 Obiettivi di addestramento 35
4.2 Ingresso: finestra recente, codifica temporale e normalizzazione stagionale 36
4.2.1 Finestra recente e trend 36
4.2.2 Codifica temporale ciclica 37
4.2.3 Normalizzazione stagionale 37
4.3 Pesi delle variabili nell'errore di ricostruzione 39
4.4 Dropout Monte Carlo nelle due reti e score 40
4.4.1 Dropout nel generatore e nel discriminatore 40
4.4.2 Campioni Monte Carlo e componenti dello score 40
4.4.3 Score combinato e score di ricostruzione 41
4.4.4 Dispersione 42
4.4.5 Classi di fiducia 42
4.5 Normalizzazione climatologica degli score 42
4.6 Validazione senza etichette 44
4.6.1 Valori insoliti della validazione 44
4.6.2 Distanza fra campi osservati e ricostruiti nello spazio delle componenti principali 44
4.6.3 Diagnostiche per epoca e misure finali 45
4.7 Eventi geografici 46
4.7.1 Soglia, morfologia e cluster spaziali 46
4.7.2 Collegamento temporale, separazioni e fusioni 47

5 Esperimenti **48**
5.1 Configurazioni di addestramento 48
5.2 Protocollo di valutazione 50

6 Risultati e discussione **51**
6.1 Ricerca dei parametri 51
6.2 Correlazione spaziale degli score 51

6.3 Correlazione temporale degli score 54
6.4 Il comportamento del discriminatore 57
6.5 Confronto con metodi semplici e modelli poco profondi 61
6.6 Eventi per tipo e dimensione 61
6.7 Casi specifici 61
6.8 Limiti dei risultati 61

7 Conclusioni e sviluppi futuri **62**
7.1 Il problema affrontato 62
7.2 Sintesi dei risultati 62
7.3 Limiti dello studio 62
7.4 Sviluppi futuri 63

A Lavoro preliminare sui dati PVGIS **64**
A.1 Previsore probabilistico della produzione 64
A.2 Equazioni differenziali stocastiche neurali 64
A.3 Soglie climatologiche 66
A.4 Detector appresi: MTGFlow e STGAN 66

Bibliografia **68**

Elenco delle figure

2.1 Schema di STGAN. Il generatore combina tre moduli e produce la stima $\hat{X}_{v,t}$, che sostituisce l'ultimo elemento della sequenza reale; il discriminatore valuta entrambe le sequenze. Lo score somma l'errore di previsione e la differenza fra le due uscite del discriminatore. Ridisegnato a partire da Deng et al. [3]. . . 9

3.1 Dominio dei campi ERA5: 81×131 celle di 0.5°, fra 20° e 60° di latitudine nord e fra 15° di longitudine ovest e 50° di longitudine est. Il rettangolo indica il Piemonte, la regione dei dati PVGIS della Sezione 3.5. Linee di costa da Natural Earth. 24

3.2 Dai file di ERA5 ai dati letti dal modello. I campi sono scaricati mese per mese dal Climate Data Store e conservati solo se superano la verifica; la preparazione li riunisce in array su disco, da cui il modello legge le sole finestre che usa. 25

3.3 Ciclo stagionale e giornaliero della temperatura a due metri e della copertura nuvolosa in tre celle: Europa settentrionale (55°N, 10°E), Pianura Padana (45°N, 9°E) e Sahara (25°N, 10°E). A sinistra la media per mese, con una deviazione standard; a destra la media per ora UTC in gennaio e in luglio. Anni 1980–1999. 27

3.4 Quota di ciascuna variabile nella variazione quadratica media su 24 ore, dopo il min–max dell'articolo e dopo la normalizzazione stagionale e il min–max del detector. Anni 1980–1999; la seconda quota è ricavata dai pesi della Sezione 4.3. La linea tratteggiata indica la quota uguale per tutte le variabili, un quindicesimo. 28

3.5 Correlazione delle anomalie di due celle in funzione della loro distanza: mediana e quartili per fasce di 100 km, su 300 celle scelte a caso e un istante ogni nove degli anni 1980–1999. Il primo punto, entro 100 km, si basa su 36 coppie di celle. . . . 29

3.6 Le 1149 località dei dati PVGIS. Ogni punto è una posizione del reticolo con passo di 5 km per la quale sono disponibili le serie orarie. 30

4.1 Ordine dei passaggi del detector su un istante, dai campi ERA5 agli eventi geografici. In corsivo, gli anni su cui è stimata ciascuna quantità: le scale della normalizzazione stagionale e i pesi sugli anni di addestramento, la climatologia dello score e la soglia sugli anni di validazione. 33
4.2 Struttura del generatore (a) e del discriminatore (b). Il generatore unisce cella per cella i tre rami, recente, trend e calendario, e produce il campo stimato dell'istante. Il discriminatore giudica ogni cella sulla propria patch, a partire dalla storia recente e dal campo corrente, osservato o generato. I riquadri tratteggiati indicano i dropout, con probabilità 0.2 (Sezione 4.4). 34
4.3 Dagli score agli eventi geografici, su un esempio illustrativo. Gli score di un istante sono riportati sulla griglia; le celle sopra soglia formano una maschera, da cui apertura e chiusura rimuovono le celle isolate e le sporgenze; le celle rimaste sono riunite in cluster, gruppi di celle adiacenti. I cluster di istanti consecutivi sono poi collegati: un evento è un insieme di cluster collegati, e resta unico anche quando un cluster si separa in due o due cluster si fondono. 46

6.1 Correlazione spaziale fra G e D in ogni istante degli anni di test, calcolata sulle 10611 celle: media giornaliera (linea sottile) e media mobile su 30 giorni (linea spessa), con Spearman e con Pearson. Le due correlazioni restano negative per quasi tutto il periodo. 52
6.2 Score di G e di D in due istanti degli anni di test: in alto un istante con la correlazione spaziale di Spearman uguale alla mediana del test, in basso l'istante con la media di G più alta. Ogni mappa ha una propria scala, dal primo al 99-esimo percentile dei suoi valori. In basso, le celle del Nord Africa in cui G è più alto sono fra quelle in cui D è più basso. Linee di costa da Natural Earth. 53
6.3 Correlazione temporale di Spearman fra G e D in ogni cella, sugli istanti degli anni di test. La correlazione è negativa in tutte le celle; la cornice a due celle dal bordo è un effetto del modello. Linee di costa da Natural Earth. 55

6.4 Quota dei valori segnalati, per fascia di latitudine e mese, sugli anni di test: G senza e con la normalizzazione climatologica. La soglia di ciascuno score è il suo 95-esimo percentile sugli anni di validazione; il bianco corrisponde al 5%. Senza normalizzazione le segnalazioni si concentrano a sud e in estate, con la normalizzazione sono distribuite in modo quasi uniforme. . . 56
6.5 Correlazione temporale di Spearman fra G e ciascuno dei due termini di D in ogni cella, sugli anni di test: a sinistra con il giudizio sull'osservazione, D_{reale}, a destra con il giudizio sulla ricostruzione, D_{generato}. D_{generato} cresce con G quasi ovunque, D_{reale} non ne segue l'ordine. Linee di costa da Natural Earth. . 57
6.6 Percentile mediano di G senza normalizzazione, dei due termini di D e della componente D nel nucleo degli eventi di G con la normalizzazione climatologica, nel loro contorno e lontano da essi, sugli anni di test. Il percentile è calcolato rispetto a tutti i valori dello stesso score; la linea tratteggiata indica 50, il valore atteso senza legame con gli eventi. Nel nucleo D_{reale} è basso e D_{generato} alto, e la componente D scende al percentile 10. 58
6.7 Score di G, giudizio del discriminatore sull'osservazione (D_{reale}) e sulla ricostruzione (D_{generato}) e componente D, il 30 agosto 2024 alle 12 UTC, l'istante con la media di G più alta degli anni di test. Ogni mappa ha una propria scala, dal primo al 99-esimo percentile dei suoi valori. Dove G è alto, D_{reale} è vicino a zero e D_{generato} è al massimo. Linee di costa da Natural Earth. 60

Capitolo 1

Introduzione

1.1 Contesto e motivazioni

Le condizioni meteorologiche insolite, come una perturbazione intensa, un fronte che attraversa una regione o un'ondata di caldo, sono quelle in cui i modelli addestrati su dati storici sbagliano di più e in cui servono informazioni aggiuntive. Il lavoro è nato in questo contesto, nell'ambito della previsione della produzione fotovoltaica [1], dove un previsore è affidabile nelle condizioni che i dati di addestramento rappresentano bene e meno in quelle poco frequenti. Riconoscere queste condizioni è però un problema a sé, distinto dalla previsione: richiede di stabilire, per ogni luogo e ogni istante, quanto le condizioni osservate si discostano da quelle abituali. È il compito del rilevamento di anomalie, a cui questa tesi è dedicata.

I campi meteorologici delle rianalisi, come ERA5 [2], descrivono lo stato dell'atmosfera su una griglia regolare, con molte variabili e per diversi decenni. Sono quindi una base adatta per cercare condizioni insolite in modo sistematico, su un dominio ampio e senza limitarsi alle grandezze di un singolo impiego.

1.2 Il problema: anomalie meteorologiche senza etichette

Tre caratteristiche dei dati rendono il problema difficile e guidano le scelte dei capitoli successivi.

La prima è l'assenza di etichette. Non esiste un elenco completo di osservazioni meteorologiche anomale con cui addestrare un classificatore o

misurare direttamente l'accuratezza di un detector. Il rilevamento deve essere unsupervised e la sua valutazione deve ricorrere a strumenti indiretti.

La seconda è che i dati di training non sono garantiti privi di anomalie. Molti detector apprendono il comportamento normale da un insieme che si assume pulito; con dati meteorologici non etichettati questa ipotesi non è verificabile. Ne segue una scelta di obiettivo: rilevare le condizioni nuove rispetto al periodo di training, trattando come già osservate quelle che il modello ha incontrato durante l'addestramento.

La terza è la struttura spaziale. Le condizioni di un luogo dipendono da quelle dei luoghi vicini, e un valore insolito in un punto può essere ordinario se considerato nel suo intorno. I campi non hanno però una topologia fisica, come una rete stradale: sono disposti su un reticolo regolare, e il modo di rappresentare l'intorno va scelto.

Il termine anomalia indica in questa tesi un'osservazione che si discosta da quanto il modello ha appreso dal periodo di training. Un evento meteorologico estremo è un caso particolare di anomalia, ma non ogni anomalia è un evento estremo.

1.3 Approccio proposto

Il detector parte da STGAN [3], una rete avversaria proposta per il rilevamento di anomalie nel traffico: un generatore stima i valori dell'istante successivo a partire dal contesto spaziale e temporale, un discriminatore giudica se una sequenza è osservata o generata, e uno score combina i due. In questa tesi lo schema è adattato e trasformato per i campi ERA5, con quindici variabili in superficie e a 850 hPa, ogni tre ore, su un dominio che comprende l'Europa e il Mediterraneo. Le modifiche principali sono quattro:

1. un generatore che opera sul campo intero con un'unità ricorrente convoluzionale, mentre il discriminatore resta locale;

2. un ingresso riferito al clima di ogni cella, con una normalizzazione stagionale e pesi che misurano l'errore di ogni variabile in rapporto a quanto essa cambia abitualmente;

3. il dropout Monte Carlo nelle due reti, che associa a ogni score una misura di dispersione;

4. una validazione senza etichette su anni di tempo normale, con cui si scelgono i parametri dell'addestramento avversario senza usare gli anni di test.

1.4 Obiettivi e contributi della tesi

L'obiettivo della tesi è rilevare condizioni meteorologiche anomale in campi privi di etichette e dotati di struttura spaziale, e studiare, senza riferimenti esterni, come si comportano le parti dello score e quale usare. La tesi non propone un nuovo algoritmo di rilevamento: adatta e combina componenti esistenti. I contributi sono i seguenti.

- L'adattamento di STGAN a campi meteorologici privi di topologia fisica, con un generatore sul campo intero che rappresenta l'intorno di una cella con una convoluzione su griglia, e la definizione dell'obiettivo come rilevamento di condizioni nuove rispetto al periodo di training.
- Uno score Monte Carlo, con il dropout nel generatore e nel discriminatore, e la ricostruzione di eventi geografici a partire dagli score.
- Un protocollo di addestramento e di scelta della configurazione che non usa etichette né anni di test: una validazione da cui le condizioni insolite sono escluse con un criterio indipendente dal modello, e una misura della distanza fra campi osservati e ricostruiti.
- Una valutazione senza etichette: lo studio delle componenti dello score nello spazio e nel tempo, e il confronto, a parità di segnalazioni, con rilevatori che non usano un modello e con modelli poco profondi.

1.5 Organizzazione del documento

Il Capitolo 2 presenta i fondamenti teorici e i lavori su cui la tesi è costruita, per temi e in ordine cronologico all'interno di ciascun tema; si chiude con il modo in cui la tesi adatta STGAN e con la sua posizione rispetto ai lavori esaminati. Il Capitolo 3 descrive i campi ERA5 e la loro preparazione, e i dati PVGIS da cui il lavoro è partito. Il Capitolo 4 presenta il detector nella forma finale. Il Capitolo 5 descrive come il detector è addestrato e valutato: la configurazione e la ricerca dei parametri, e il protocollo di valutazione. Il Capitolo 6 riporta e discute i risultati. Il Capitolo 7 riassume il lavoro, ne indica i limiti e gli sviluppi futuri. L'Appendice A descrive il lavoro preliminare sui dati PVGIS: il previsore probabilistico della produzione, i metodi per associargli un intervallo e i primi detector.

Capitolo 2

Fondamenti teorici e stato dell'arte

Il capitolo presenta i fondamenti teorici e i lavori su cui la tesi è costruita. Ogni tema è trattato come un percorso: dai lavori che ne hanno definito il problema a quelli più recenti, fino al metodo che la tesi riprende. Per ciascun lavoro sono indicati ciò che propone, ciò che ottiene e il limite che lascia aperto, che spesso è il punto da cui parte il lavoro successivo; i lavori su cui il detector si basa direttamente sono descritti più a fondo, con le relative formule. I temi sono quattro: il rilevamento di anomalie in serie temporali, l'apprendimento automatico applicato ai dati meteorologici, il contesto spaziale su griglie e grafi, la quantificazione dell'incertezza. Una sezione descrive poi il modo in cui la tesi adatta STGAN, e l'ultima riassume la posizione della tesi rispetto ai lavori esaminati. Il lavoro preliminare sui dati PVGIS, da cui la tesi è partita, è descritto nell'Appendice A.

2.1 Rilevamento di anomalie in serie multivariate e spazio-temporali

2.1.1 Dalla deviazione dal valore atteso ai modelli profondi

Nella rassegna di Gupta et al. [4] sui dati temporali, un'anomalia è definita in generale come uno scostamento dal valore atteso o previsto. Per i dati spazio-temporali la rassegna riprende una definizione più specifica: un'osservazione è anomala quando le sue grandezze differiscono in modo significativo da quelle degli oggetti vicini nello spazio e nel tempo. I metodi che la rassegna raccoglie per questi dati procedono per lo più in due passi, prima cercando le anomalie

spaziali e poi verificandole rispetto ai vicini temporali, con intorni fissati a mano; fra le applicazioni figurano anche dati ambientali e meteorologici, come serie di precipitazione e campi di rianalisi. I metodi esaminati precedono l'uso diffuso delle reti profonde e trattano grandezze scalari o singoli oggetti, non campi multivariati considerati insieme.

La rassegna di Zamanzadeh Darban et al. [5] raccoglie i metodi profondi per serie temporali e li divide secondo il segnale da cui ricavano lo score: la previsione del valore successivo, la ricostruzione dell'osservazione, una rappresentazione appresa, oppure una combinazione delle prime due. Le reti generative avversarie vi figurano fra i metodi a ricostruzione; gli autori ne indicano come limite l'addestramento, che richiede di bilanciare generatore e discriminatore ed è instabile e difficile da far convergere. Nella rassegna il termine spaziale indica le dipendenze fra le variabili di una serie, non fra luoghi geografici; fra i dataset raccolti non compaiono campi meteorologici su griglia, e i lavori su dati geografici, come STGAN, sono citati soltanto fra le applicazioni urbane e al traffico.

Le due famiglie di metodi profondi che seguono derivano lo score dallo scarto rispetto a un modello appreso. Malhotra et al. [6] propongono un encoder–decoder basato su LSTM, addestrato a ricostruire finestre di serie normali: una finestra anomala, che il modello non ha imparato a ricostruire, produce un errore più alto, e lo score è la distanza di Mahalanobis del vettore degli errori dalla loro distribuzione sui dati normali. La soglia di decisione è però scelta massimizzando un indice di accuratezza su sequenze anomale etichettate, e negli esperimenti con più sensori le serie sono ridotte alla prima componente principale: il metodo, quindi, non è interamente unsupervised e non modella più variabili insieme. Hundman et al. [7] seguono la via della previsione per la telemetria di veicoli spaziali: una LSTM per canale prevede il valore successivo, e gli errori, smussati, sono confrontati con una soglia scelta senza etichette, che separa i valori più alti dal resto della distribuzione degli errori. Sui due insiemi di dati dell'articolo il metodo raggiunge una precisione dell'87.5% e un richiamo dell'80.0% [7]. Gli autori indicano fra i limiti le interazioni fra i canali, che un modello per canale non rappresenta, e osservano che la qualità del rilevamento dipende da quella della previsione.

Fra i metodi più recenti, Xu et al. [8] introducono Anomaly Transformer, in cui l'attenzione di un Transformer è affiancata da una distribuzione a priori concentrata sui punti vicini. Il criterio è che un'osservazione anomala, essendo rara, non riesce a stabilire legami con il resto della serie e concentra l'attenzione sui punti adiacenti; lo score moltiplica l'errore di ricostruzione per una funzione della differenza fra le due distribuzioni. La soglia è fissata senza etichette, come la quota di score più alti su un periodo di validazione. Le variabili sono riunite in un unico vettore per istante e lo score è uno per istante:

il metodo non rappresenta relazioni spaziali e non localizza l'anomalia fra le variabili. I risultati dell'articolo sono misurati con un criterio che considera rilevato un intero segmento anomalo quando ne è segnalato anche un solo punto [8].

I metodi di rilevamento di anomalie in serie multivariate basati su reti profonde sono comunemente distinti secondo il segnale da cui ricavano lo score. Wu et al. li classificano in metodi basati su previsione, su ricostruzione e su apprendimento contrastivo [9]. Alnegheimish et al. distinguono in modo analogo modelli di previsione e di ricostruzione, e osservano che molti di essi costruiscono uno score senza definire in modo appropriato la soglia [10]. Zhou et al. mettono in evidenza un'ipotesi comune a gran parte di questi lavori, cioè la disponibilità di un training composto da sole osservazioni normali. Quando il training contiene anomalie le prestazioni possono degradare sensibilmente; come alternativa è proposta la stima della densità dell'intero insieme di training [11].

I lavori esaminati in questa sezione si collocano lungo queste distinzioni: STGAN appartiene all'approccio avversario, che combina l'errore di previsione con il giudizio di un discriminatore, MTGFlow alla stima di densità, CATCH alla ricostruzione e M2AD alla previsione con uno score aggregato. Due criteri guidano il confronto: la tolleranza alla presenza di anomalie nel training e la rappresentazione del contesto spaziale fra località. Il primo ha portato alla scelta di MTGFlow e all'esclusione di CATCH e M2AD; il secondo al passaggio a STGAN, che offre il contesto spaziale ma non la stessa tolleranza.

2.1.2 Reti generative avversarie per il rilevamento di anomalie

Una rete generativa avversaria [12] è formata da due reti, addestrate insieme con obiettivi opposti. Il generatore G trasforma un rumore z, estratto da una distribuzione nota p_z, in un campione $G(z)$; i dati reali seguono la distribuzione p_{data} e il discriminatore D restituisce la probabilità $D(x)$ che un campione x provenga dai dati reali anziché dal generatore. Le due reti sono addestrate sulla stessa funzione, che il discriminatore massimizza e il generatore minimizza:

$$\min_G \max_D V(D,G) = \mathbb{E}_{x\sim p_{\text{data}}}\Big[\log D(x)\Big] + \mathbb{E}_{z\sim p_z}\Big[\log\Big(1 - D(G(z))\Big)\Big]. \quad (2.1)$$

Il primo termine cresce quando il discriminatore riconosce i dati reali, il secondo quando riconosce i campioni generati; il generatore è addestrato a rendere i propri campioni indistinguibili da quelli reali. Entrambe le reti sono ottimizzate con la retropropagazione. Lo stesso articolo osserva che, all'inizio

dell'addestramento, il secondo termine fornisce al generatore un gradiente debole, e propone in alternativa di addestrarlo a massimizzare $\log D(G(z))$.

Schlegl et al. [13] usano per primi questo schema per il rilevamento di anomalie, su immagini di tomografia della retina. La rete è addestrata soltanto su immagini sane; poiché una GAN non fornisce la trasformazione inversa da un'immagine al rumore che la genera, per ogni immagine da valutare il rumore è cercato con un'ottimizzazione iterativa, a reti fissate. Lo score somma due termini: lo scarto fra l'immagine e quella generata, e la distanza fra le rispettive caratteristiche in uno strato intermedio del discriminatore. Sui dati dell'articolo lo score completo raggiunge un'area sotto la curva ROC di 0.89; preso da solo, il termine di ricostruzione arriva a 0.88, quello del discriminatore a 0.74 [13]. Li et al. [14] estendono l'idea alle serie temporali multivariate di impianti industriali con MAD-GAN, in cui generatore e discriminatore sono LSTM e tutte le variabili sono modellate insieme, dopo una riduzione con le componenti principali. Lo score combina, con un peso, lo scarto di ricostruzione, ottenuto ancora con un'inversione iterativa nello spazio latente, e l'uscita del discriminatore. L'articolo non indica come scegliere quel peso né la soglia, e i risultati migliori sono selezionati fra più configurazioni; gli autori segnalano inoltre una forte oscillazione del richiamo da un'epoca all'altra, che attribuiscono all'instabilità del rilevamento basato su GAN [14]. Nessuno dei due metodi rappresenta relazioni spaziali fra le serie.

Nel detector avversario adottato in questa tesi lo schema è usato in forma condizionata: il generatore riceve il contesto di un'osservazione e ne produce una stima. L'uso per il rilevamento di anomalie poggia su un'ipotesi di lavoro: che la stima sia accurata nelle condizioni frequenti nei dati di addestramento e meno accurata in quelle poco rappresentate. È un'ipotesi e non una proprietà garantita dall'addestramento. Se vale, se ne ricavano due segnali: lo scarto fra l'osservazione e la stima del generatore, e il giudizio del discriminatore sull'osservazione. STGAN, descritto di seguito, li combina in un unico score. Il risultato di AnoGAN, in cui il termine del discriminatore preso da solo rileva meno di quello di ricostruzione, è il riferimento con cui la Sezione 6.4 legge il comportamento delle due componenti.

Rispetto all'equazione (2.1), in STGAN il significato dell'uscita del discriminatore è invertito: le sequenze reali sono trattate come normali e quelle generate come anomale, con valore 0 per le prime e 1 per le seconde. Per il discriminatore l'obiettivo è lo stesso a meno di questo scambio, ma la sua uscita cresce con il sospetto di anomalia e può essere usata per costruire lo score. L'obiettivo del generatore è riportato nell'equazione (2.2): il termine avversario ha la forma alternativa appena descritta, scritta nella convenzione invertita, e a esso si aggiunge l'errore di previsione.

L'addestramento richiede un equilibrio fra le due reti: nella tesi i tassi di

apprendimento delle due reti, il numero di aggiornamenti per batch e il peso di ricostruzione sono parametri configurabili, come descritto nel Capitolo 4.

2.1.3 STGAN

Deng et al. [3] propongono una rete avversaria per il rilevamento di anomalie del traffico. Il generatore prevede la dinamica normale combinando tre componenti: un modulo recente, basato su unità ricorrenti con convoluzione su grafo, per le dipendenze spazio-temporali di breve periodo, un modulo per il trend di lungo periodo e uno per le variabili esterne. Il discriminatore stabilisce se una sequenza è reale o generata in funzione dei vicini nello spazio e nel tempo, fornendo un criterio che varia con località e istante. Dopo l'addestramento avversario entrambe le reti agiscono da detector e uno score ne combina i contributi. Il grafo deriva da una topologia fisica, cioè sensori adiacenti sulla stessa strada o regioni con confini comuni, e la valutazione misura il richiamo rispetto a incidenti ed eventi documentati, che gli autori stessi indicano come verità di riferimento incompleta. Il metodo presuppone quindi una rete di adiacenze nota e produce uno score puntuale, privo di una misura di dispersione; la sua valutazione dipende dalla disponibilità di eventi documentati. L'articolo non discute la presenza di anomalie nei dati di training: il discriminatore è addestrato considerando normali le sequenze reali e anomale quelle generate, quindi l'ipotesi di un training normale è implicita. La Figura 2.1 riassume la struttura del metodo.

Sia $x_{v,t}$ l'osservazione del nodo v all'istante t e $X_{v,t}$ l'insieme delle osservazioni nel sottografo formato da v e dai suoi vicini. Sia poi $S_{v,t}$ la sequenza reale dei valori del sottografo che termina con $X_{v,t}$, e $\hat{S}_{v,t}$ la stessa sequenza in cui l'ultimo elemento è sostituito dalla stima $G_\theta(v,t)$ del generatore. Gli obiettivi di addestramento dell'articolo sono

$$\mathcal{L}_G(\theta) = \sum_s -\log\Big(1 - D_\phi(\hat{S}_{v,t})\Big) + \lambda_G \, \|G_\theta(v,t) - X_{v,t}\|_2, \tag{2.2}$$

$$\mathcal{L}_D(\phi) = \sum_s -\log\Big(D_\phi(\hat{S}_{v,t})\Big) - \log\Big(1 - D_\phi(S_{v,t})\Big), \tag{2.3}$$

dove la somma è sui punti $s = \langle v, t, x_{v,t}\rangle$ e λ_G bilancia l'errore di previsione e il termine avversario. Il discriminatore è quindi spinto verso 1 sulle sequenze generate e verso 0 su quelle reali. Lo score combina le due reti:

$$\begin{aligned} s_D(v,t) &= D_\phi(S_{v,t}) - D_\phi(\hat{S}_{v,t}), \\ s_G(v,t) &= \|G_\theta(v,t) - X_{v,t}\|_2, \\ \text{score}(v,t) &= s_G(v,t) + \lambda \, s_D(v,t). \end{aligned} \tag{2.4}$$

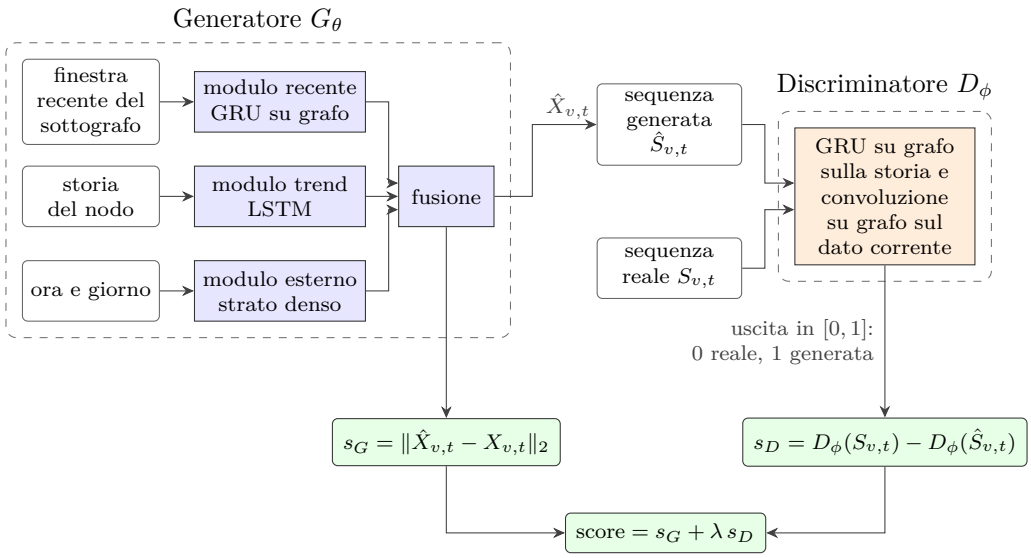


Figura 2.1: Schema di STGAN. Il generatore combina tre moduli e produce la stima $\hat{X}_{v,t}$, che sostituisce l'ultimo elemento della sequenza reale; il discriminatore valuta entrambe le sequenze. Lo score somma l'errore di previsione e la differenza fra le due uscite del discriminatore. Ridisegnato a partire da Deng et al. [3].

La componente del discriminatore non è la sua uscita sulla sequenza reale ma la differenza rispetto alla sequenza generata: gli autori la introducono per ridurre l'effetto dell'imprevedibilità dei dati reali. Negli esperimenti dell'articolo $\lambda_G = 500$, le due componenti sono normalizzate e $\lambda = 1$.

La tesi riprende l'architettura a tre rami e gli obiettivi avversari, e mantiene lo score combinato come riferimento; il modo in cui li adatta ai campi meteorologici è descritto nella Sezione 2.5. Gli obiettivi di addestramento e lo score, nella forma implementata, sono riportati nella Sezione 4.1: rispetto alle equazioni (2.2)–(2.4), l'errore di previsione vi compare come errore quadratico medio anziché come norma, mentre la differenza fra le uscite del discriminatore e $\lambda = 1$ sono mantenuti; λ_G è un parametro, con valore predefinito 500. La scelta segue il codice pubblicato dagli autori, che usa l'errore quadratico medio sia nella loss del generatore sia nella componente di ricostruzione dello score, e dimezza la somma dei due termini della loss del discriminatore.

2.1.4 Grafi appresi e training contaminato: GDN e MTGFlow

In STGAN il grafo è dato da una topologia fisica. Una linea parallela di lavori lo apprende dai dati, quando le relazioni fra le serie non sono note. Deng e Hooi [15] propongono GDN per i sensori di impianti industriali: a ogni sensore è associato un vettore appreso, i vicini di ciascun sensore sono i più simili secondo questi vettori, e un'attenzione su grafo prevede il valore successivo di ogni sensore. L'errore di ogni sensore è normalizzato con la sua mediana e il suo intervallo interquartile, e lo score di un istante è il massimo sui sensori, perché un'anomalia può interessarne anche uno soltanto; la soglia è il massimo dello score su un periodo di validazione. Come in STGAN, si assume che i dati di addestramento siano normali.

L'ipotesi di un training normale, implicita in STGAN e in GDN, è quella che il lavoro successivo rimuove. Zhou et al. [11] affrontano il rilevamento di anomalie in serie multivariate senza assumere che i dati di training siano tutti normali. Il metodo stima la densità dell'intero insieme di training e identifica come anomale le osservazioni di test a bassa densità, sotto l'ipotesi che le anomalie occupino regioni più sparse. Le dipendenze fra entità sono apprese come grafo dinamico e un normalizing flow specifico per entità associa a ciascuna una distribuzione normale parametrizzata. La soglia è ricavata dall'intervallo interquartile degli score di training e lo score per entità consente di localizzare l'anomalia. Le entità sono i sensori o le variabili di un unico sistema e la valutazione usa dataset pubblici di riferimento: il grafo è appreso dai dati e descrive relazioni fra variabili, non fra siti geografici distinti. Un'estensione assegna una distribuzione comune alle entità di uno stesso gruppo, quando è noto che hanno caratteristiche simili. Il raggruppamento esprime soltanto che certe entità possono comportarsi allo stesso modo: non modella vicinanza, distanze o propagazione nello spazio, e non rende il metodo un detector spazio-temporale.

MTGFlow è stato il primo detector esaminato nel lavoro, per la sua robustezza alla presenza di anomalie nei dati di training: per le condizioni meteorologiche non sono disponibili etichette, quindi non è possibile garantire un training composto da sole osservazioni normali. È stato applicato ai dati PVGIS del lavoro preliminare, descritto nell'Appendice A. Poiché non rappresenta il contesto geografico, il lavoro è passato a STGAN (Sezione 2.1.3), accettandone l'ipotesi sul training.

2.1.5 Alternative considerate: CATCH e M2AD

CATCH. I due lavori più recenti esaminati tornano all'ipotesi di un training normale. Wu et al. [9] propongono un metodo basato su ricostruzione nel dominio della frequenza. Lo spettro è suddiviso in bande, trattate come patch, per cogliere caratteristiche a grana fine; un modulo di fusione dei canali, con un generatore di maschere e un'attenzione mascherata, seleziona per ciascuna banda le correlazioni fra canali ritenute utili e isola quelle irrilevanti. Il metodo mira a rilevare insieme anomalie puntuali e di sottosequenza ed è valutato su dataset reali e sintetici. Lo score di anomalia è l'errore di ricostruzione: il modello impara a ricostruire i pattern normali, e nei dataset sintetici dell'articolo le anomalie sono inserite soltanto nella serie di test. Il caso di anomalie presenti nei dati di training non è trattato. I canali sono le variabili di una serie multivariata: non è prevista una struttura geografica fra serie di siti diversi. Gli autori segnalano inoltre che anomalie più lunghe della finestra osservata non vengono colte efficacemente.

CATCH è stato preso in esame come alternativa a MTGFlow e non è stato adottato, per due ragioni. La prima è che richiede un training privo di anomalie: apprende i pattern normali per ricostruzione e l'articolo non considera un training contaminato, mentre in assenza di etichette questa condizione non è verificabile sui dati meteorologici. La seconda è che, come MTGFlow, non rappresenta relazioni fra località geografiche.

M2AD. Alnegheimish et al. [10] considerano serie multivariate provenienti da più sistemi. Un modello LSTM apprende il comportamento atteso dei sensori. I residui fra valori attesi e osservati sono aggregati in uno score globale mediante un modello a miscela gaussiana e una calibrazione Gamma. La soglia è stimata dagli score osservati in training, e i sensori sono ordinati per contributo allo score. Il metodo assume che i dati di training siano privi di anomalie e che training e test abbiano andamenti simili; gli autori indicano come limite il caso in cui la distribuzione cambia, che richiede un nuovo addestramento.

Anche M2AD è stato preso in esame e non adottato, per le stesse due ragioni. Assume esplicitamente un training privo di anomalie, ipotesi opposta a quella che ha guidato la scelta di MTGFlow e non verificabile senza etichette; inoltre i suoi sistemi sono insiemi di sensori senza relazione geografica fra loro. A differenza di STGAN, quindi, né CATCH né M2AD offrono il contesto spaziale in cambio dell'ipotesi sul training. Nessuno dei due è stato eseguito sui dati della tesi né compare fra i risultati.

2.1.6 Il problema della valutazione

I risultati dei lavori precedenti sono misurati su dataset etichettati, e la loro affidabilità dipende da quella delle etichette. Wu e Keogh [16] esaminano i dataset più usati per le serie temporali univariate e vi riscontrano quattro difetti ricorrenti: problemi risolvibili con una sola riga di codice basata su operazioni elementari come media, deviazione standard e differenze successive, che risolve 316 delle 367 serie di uno dei dataset; una densità di anomalie poco realistica; etichette errate o mancanti; anomalie concentrate verso la fine delle serie. Ne concludono che parte dei progressi riportati può essere apparente, e raccomandano di confrontare ogni metodo con soluzioni banali e di esaminare sempre visivamente dati e score. L'analisi riguarda serie univariate e non tratta campi multivariati su griglia; le sue indicazioni valgono però anche in assenza di etichette, dove il confronto con rilevatori semplici e l'esame diretto di mappe e serie degli score restano gli strumenti disponibili.

Liu e Paparrizos [17] riprendono il problema con TSB-AD, un insieme di 1070 serie, univariate e multivariate, ricontrollate a mano, su cui confrontano quaranta detector con gli stessi dati e la stessa procedura di scelta dei parametri. Mostrano che il criterio che considera rilevato un intero segmento quando ne è segnalato un solo punto premia anche uno score casuale, e adottano misure che non dipendono da una soglia. Con queste misure i metodi statistici sono spesso fra i migliori, con un'analisi per componenti principali in testa fra le serie univariate; fra le multivariate prevalgono reti semplici, convoluzionali o ricorrenti, e lo stesso metodo per componenti principali, mentre Anomaly Transformer risulta ultimo in entrambi i gruppi. Anche TSB-AD richiede etichette, non contiene campi su griglia e non studia un addestramento contaminato da anomalie; ne resta l'indicazione che un detector appreso va sempre confrontato con metodi semplici, perché la sua superiorità non è scontata. Per questo le segnalazioni del detector sono confrontate con sette dei metodi statistici valutati in TSB-AD: l'analisi per componenti principali, KMeans, CBLOF, MCD, HBOS, COPOD e Isolation Forest (Sezione 6.5).

2.2 Apprendimento automatico e dati meteorologici

2.2.1 Dalla previsione numerica ai modelli basati sui dati

La previsione meteorologica numerica tratta l'evoluzione dell'atmosfera come un problema ai valori iniziali: le equazioni che la governano sono integrate a partire dallo stato osservato, e i processi di scala inferiore alla griglia, come convezione, radiazione e nubi, sono rappresentati da parametrizzazioni. Bauer et al. [18] ne ricostruiscono i progressi, che attribuiscono soprattutto a parametrizzazioni migliori, alla previsione d'insieme e all'assimilazione dei dati, e stimano che l'accuratezza fra tre e dieci giorni sia cresciuta di circa un giorno per decennio. Fra le sfide aperte indicano la verifica delle code della distribuzione, per cui servono misure adatte a statistiche scarse. Le rianalisi come ERA5 [2] nascono dallo stesso apparato: combinano un modello di previsione con le osservazioni disponibili per stimare lo stato dell'atmosfera in ogni istante.

Rasp et al. [19] rendono ERA5 il riferimento comune per i modelli di previsione basati sui dati, con WeatherBench: un insieme di campi ERA5 a risoluzione ridotta, periodi di addestramento, validazione e test contigui nel tempo e confronti con persistenza, climatologia e previsione numerica. Nella discussione gli autori osservano che gli eventi estremi, essendo rari, contano poco nelle metriche medie come l'errore quadratico, che le reti estrapolano male a stati diversi da quelli visti in addestramento e che una rete addestrata con l'errore quadratico produce campi troppo regolari; propongono le GAN come possibile rimedio a quest'ultimo problema. Lam et al. [20] portano l'approccio alla risoluzione nativa di ERA5 con GraphCast, una rete su grafo addestrata sui campi ERA5 dal 1979 al 2017, che supera la previsione deterministica operativa sul 90.3% delle combinazioni di variabile, livello e orizzonte esaminate. Gli autori riconoscono che l'addestramento con l'errore quadratico porta il modello a esprimere l'incertezza sfumando i campi, e che il modello migliora quando è riaddestrato su anni più recenti, per ragioni non del tutto chiarite. Per valutare gli eventi estremi definiscono come tali i valori oltre un percentile di una climatologia per luogo, ora del giorno e mese.

Questi lavori usano ERA5 per prevedere; la tesi lo usa per riconoscere condizioni insolite. Alcune loro osservazioni valgono anche per questo impiego: un modello addestrato su anni passati con un errore medio rappresenta meglio le condizioni frequenti, tende a smussare quelle rare, e il suo comportamento può cambiare quando i dati si allontanano dal periodo di addestramento.

2.2.2 Eventi estremi e anomalie nei campi meteorologici

I primi lavori che applicano reti profonde agli eventi meteorologici estremi lo fanno in modo supervised. Liu et al. [21] classificano con reti convoluzionali poco profonde ritagli di campi centrati su cicloni tropicali, fiumi atmosferici e fronti, con etichette ottenute da criteri a soglia e da esperti, e riportano accuratezze di test fra l'89% e il 99%; il metodo classifica ritagli già centrati e non localizza gli eventi. Gli autori indicano nella scarsità di dati etichettati un limite, e la necessità di approcci unsupervised. Racah et al. [22] passano alla localizzazione con ExtremeWeather, un insieme di simulazioni climatiche in cui i riquadri degli eventi sono ottenuti da criteri a soglia: un encoder–decoder convoluzionale nello spazio e nel tempo unisce una perdita supervised sui riquadri a una di ricostruzione su tutti i campi, così che contribuiscano anche quelli senza etichette. Gli autori osservano che etichette prodotte da criteri a soglia sono incomplete, e che un metodo supervised addestrato su di esse può al più imitarli; lasciano esplicitamente aperto il rilevamento di anomalie.

Prabhat, Kashinath et al. [23] affrontano il problema delle etichette con ClimateNet, un insieme di campi annotati a mano da esperti. La campagna ha coinvolto circa ottanta esperti e ha prodotto 459 immagini etichettate; l'accordo fra due esperti sulla stessa immagine, misurato come sovrapposizione delle aree annotate, è in media di 0.51, e il modello di segmentazione addestrato su queste etichette ottiene un valore analogo rispetto agli esperti. Le etichette sono quindi costose e, sui contorni degli eventi, incerte anche per gli esperti. Il modello è addestrato e valutato su simulazioni climatiche, e l'applicazione alle rianalisi è lasciata a lavori futuri.

La scarsità di etichette motiva i lavori più recenti, che applicano modelli generativi unsupervised a ERA5. Zaninelli et al. [24] addestrano un autoencoder variazionale sui campi giornalieri di temperatura a due metri di un clima di riferimento, preindustriale in un modello climatico oppure i primi decenni di ERA5, e trattano come anomalo ciò che il modello non ricostruisce nei campi recenti; l'obiettivo è l'attribuzione delle ondate di calore al cambiamento climatico, e l'anomalia è quindi lo scostamento da un clima di riferimento, su una sola variabile. Paçal et al. [25] addestrano un autoencoder variazionale spazio-temporale su nove variabili ERA5, con addestramento sugli anni 1941–1990 e test sugli anni 2001–2022, e raggruppano nello spazio latente le configurazioni atmosferiche delle ondate di calore in Europa occidentale; i campioni sono però selezionati in anticipo con una soglia sulla temperatura, e gli autori notano che le ricostruzioni del modello smussano gli estremi.

Nelle ricerche condotte per questa tesi non è emerso un lavoro che assegni uno score di anomalia a tutti gli stati dell'atmosfera di una rianalisi, su più variabili insieme e con un modello spazio-temporale avversario: i lavori

supervised richiedono etichette che sono scarse e incerte, quelli unsupervised su ERA5 riguardano una sola variabile oppure eventi già selezionati. La ricerca non è esaustiva, e l'assenza va intesa in questo senso.

2.3 Contesto spaziale su griglie e grafi

STGAN rappresenta il contesto spaziale con convoluzioni su grafo, che presuppongono una rete di adiacenze. Le convoluzioni su grafo si sono diffuse nella previsione del traffico: Yu et al. [26] propongono STGCN, in cui blocchi formati da una convoluzione temporale, una convoluzione su grafo e una seconda convoluzione temporale prevedono la velocità del traffico sulle stazioni di una rete stradale. Il grafo è dato dalla rete stradale oppure costruito con un nucleo sulla distanza fra le stazioni, con parametri fissati a mano. Gli autori motivano il grafo osservando che una convoluzione ordinaria limita il modello a dati disposti su una griglia, come immagini e video. È proprio il caso dei campi della tesi, disposti su un reticolo regolare: questa sezione richiama l'operatore che sul reticolo svolge il ruolo della convoluzione su grafo.

Un modo più semplice di usare il contesto spaziale non richiede un modello appreso: confrontare il valore di un luogo con quelli dei luoghi vicini. Shekhar et al. [27] definiscono così gli outlier spaziali su un grafo, con un'applicazione ai sensori di traffico di Minneapolis–Saint Paul. Per ogni nodo calcolano la differenza fra il valore di un attributo e la media dei suoi vicini, la standardizzano con la media e la deviazione standard di queste differenze su tutti i nodi e segnalano i nodi in cui supera una soglia. Il vicinato può essere spaziale, temporale, cioè lo stesso nodo negli istanti adiacenti, oppure spazio-temporale, e il test riguarda un solo attributo. Chen et al. [28] osservano che i test di questo tipo trattano un attributo alla volta e che un vicino con valori molto estremi può far apparire anomali anche i luoghi normali attorno. Propongono quindi di confrontare ogni luogo con la mediana dei vicini e, quando gli attributi sono più di uno, di misurare il vettore delle differenze con una distanza di Mahalanobis a stime robuste, quelle del determinante di covarianza minimo; il metodo è provato su dati del virus del Nilo occidentale. Nessuno dei due metodi apprende la dinamica dei dati né è pensato per campi continui su griglia. Proprio per la loro semplicità sono però un riferimento per il contesto spaziale, e la tesi li usa come rilevatori di confronto (Sezione 6.5).

2.3.1 Unità ricorrenti convoluzionali

Le unità ricorrenti a gate, come quella introdotta da Cho et al. [29] e nota come GRU, aggiornano uno stato nascosto mediante gate che regolano quanta parte

dello stato precedente conservare e quanta sostituire. Nella forma originaria ingresso e stato sono vettori e i gate sono trasformazioni dense. Quando l'ingresso è un campo disposto su una griglia, le trasformazioni dense possono essere sostituite da convoluzioni, così che lo stato mantenga la struttura spaziale e i parametri siano condivisi fra le posizioni. L'idea è stata proposta per la LSTM nella previsione a breve termine delle precipitazioni [30] e per la GRU nell'apprendimento di rappresentazioni di sequenze video [31]. STGAN applica la stessa idea a un grafo: nel suo modulo recente i prodotti matriciali della GRU sono sostituiti da convoluzioni su grafo [3].

Sia X_s l'ingresso al passo s e H_{s-1} lo stato precedente, entrambi disposti sulla griglia. Uno strato ricorrente convoluzionale a gate calcola

$$R_s = \sigma(W_r * [X_s, H_{s-1}] + b_r)\,, \tag{2.5}$$

$$U_s = \sigma(W_u * [X_s, H_{s-1}] + b_u)\,, \tag{2.6}$$

$$\widetilde{H}_s = \tanh(W_c * [X_s, R_s \odot H_{s-1}] + b_c)\,, \tag{2.7}$$

$$H_s = U_s \odot H_{s-1} + (1 - U_s) \odot \widetilde{H}_s, \tag{2.8}$$

dove σ è la funzione sigmoidale, $*$ una convoluzione spaziale, $\odot$ il prodotto elemento per elemento e $[\cdot, \cdot]$ la concatenazione sui canali. Il gate di reset R_s regola quanto dello stato precedente entra nello stato candidato $\widetilde{H}_s$; il gate di aggiornamento U_s regola quanto dello stato precedente viene conservato. La forma è quella dell'unità su grafo di STGAN, con la convoluzione su grafo sostituita da una convoluzione spaziale.

Con un kernel di lato k e padding $\lfloor k/2 \rfloor$, ogni convoluzione vede le celle entro $\lfloor k/2 \rfloor$ posizioni. Il gate di reset e lo stato candidato applicano due convoluzioni in sequenza, quindi a ogni passo lo stato precedente si propaga fino a $2\lfloor k/2 \rfloor$ posizioni: l'area che influenza una cella cresce con il numero di passi temporali e di strati. La tesi impiega questo operatore nel generatore e nel discriminatore di STGAN: la Sezione 4.1.1 descrive il trattamento delle celle assenti, che modifica l'ingresso e l'equazione (2.8).

2.4 Quantificazione dell'incertezza

Lo score di STGAN è un valore unico per osservazione, senza una misura della sua variabilità. Nella rassegna di Abdar et al. [32] l'incertezza di una previsione è distinta in due componenti: quella aleatoria, propria dei dati e non riducibile, e quella epistemica, dovuta alla conoscenza limitata del modello e ai dati insufficienti. Gli autori indicano le approssimazioni bayesiane e gli insiemi di modelli come i due metodi più usati, e il riconoscimento di dati lontani da quelli di addestramento come un problema ancora aperto;

è la componente epistemica quella che ci si attende cresca per stati poco rappresentati nei dati, come le condizioni meteorologiche rare per un modello addestrato su anni passati. Questa sezione presenta i due metodi: il dropout Monte Carlo, applicato al detector, e il Deep Ensemble, l'alternativa più diffusa.

2.4.1 Dropout Monte Carlo e Deep Ensemble

Gal e Ghahramani [33] interpretano l'addestramento con dropout come un'inferenza bayesiana approssimata. Mantenendo il dropout attivo in previsione e ripetendo più volte il passaggio in avanti si ottiene un insieme di uscite, la cui dispersione fornisce una stima dell'incertezza del modello con un costo aggiuntivo contenuto. Lakshminarayanan et al. [34] propongono un'alternativa non bayesiana: più reti vengono addestrate in modo indipendente a partire da inizializzazioni diverse e le loro previsioni sono combinate. Il metodo è semplice da realizzare e da eseguire in parallelo, e produce un'incertezza maggiore sugli ingressi lontani dai dati di training.

Nel dropout Monte Carlo, dati J passaggi in avanti $\hat{y}_j(x)$ ottenuti con maschere di dropout diverse, la media predittiva è stimata da

$$\mathbb{E}[y \mid x] \approx \frac{1}{J} \sum_{j=1}^{J} \hat{y}_j(x), \tag{2.9}$$

e la varianza predittiva dalla varianza campionaria dei J passaggi, a cui l'articolo somma l'inverso della precisione del modello. Nei Deep Ensemble ciascuna delle M reti restituisce una media $\mu_m(x)$ e una varianza $\sigma_m^2(x)$ ed è addestrata con la negative log-likelihood gaussiana; l'insieme è trattato come una miscela a pesi uguali, con media e varianza

$$\mu_*(x) = \frac{1}{M} \sum_{m=1}^{M} \mu_m(x), \qquad \sigma_*^2(x) = \frac{1}{M} \sum_{m=1}^{M} \Big(\sigma_m^2(x) + \mu_m^2(x)\Big) - \mu_*^2(x). \tag{2.10}$$

La varianza della miscela è quindi la somma della media delle varianze delle singole reti e della dispersione delle loro medie.

Nella tesi il dropout Monte Carlo è applicato alle due reti del detector avversario, il generatore e il discriminatore di STGAN, non per stimare l'incertezza di una previsione ma per campionare lo score di anomalia. Durante il calcolo degli score i dropout restano attivi e per ogni osservazione sono riportate la media dello score sui campioni, come nell'equazione (2.9), e la sua deviazione standard, come descritto nella Sezione 4.4. In questo impiego la dispersione misura la variabilità dello score rispetto alle maschere di dropout

e non costituisce una stima calibrata dell'incertezza; il termine di precisione previsto da Gal e Ghahramani non viene aggiunto.

Una terza famiglia di metodi ottiene la dispersione rendendo stocastica la dinamica interna della rete, con una rete di diffusione che scala un termine casuale: SDE-Net [35] e il suo adattamento SDE U-Net [36], impiegati nel lavoro preliminare sul previsore della produzione e descritti nell'Appendice A.2. Il detector non li adotta: aggiungere a STGAN una rete di diffusione e una dinamica stocastica si sarebbe discostato molto dall'architettura dell'articolo, che il lavoro ha seguito il più fedelmente possibile, mentre il dropout Monte Carlo agisce su reti che contengono già il dropout senza modificarne la struttura. L'applicazione di questi metodi al detector è indicata fra gli sviluppi futuri.

2.5 Da STGAN al detector della tesi

STGAN è nato per il traffico: il grafo deriva da una rete fisica, lo score è un valore unico per osservazione e la valutazione misura il richiamo su incidenti documentati (Sezione 2.1.3). La tesi ne riprende l'architettura a tre rami e gli obiettivi avversari, e lo adatta lungo cinque assi a campi meteorologici privi di etichette.

Griglia e campo intero. Nell'articolo il contesto spaziale è un grafo, e in assenza di una rete fisica le sue adiacenze andrebbero scelte con un criterio di vicinanza. Sul reticolo regolare dei campi della tesi, invece, le posizioni relative dei vicini sono definite. La convoluzione su grafo del modulo recente è quindi sostituita da una ConvGRU (Sezione 2.3), e il ramo LSTM del trend è conservato. Il generatore elabora in una sola passata il reticolo completo di un istante, mentre il discriminatore continua a giudicare l'intorno di ogni cella, una patch al posto del sottografo dell'articolo. Si aggiunge il trattamento delle celle assenti, con una maschera fornita come canale e l'azzeramento dello stato ricorrente (Sezione 4.1.1).

Obiettivo: condizioni nuove rispetto all'addestramento. L'articolo tratta come normali le sequenze reali del training, mentre per i campi meteorologici un training privo di anomalie non è garantito. A differenza di MTGFlow, STGAN non tollera per costruzione un training contaminato: la tesi accetta questo limite in cambio del contesto spaziale e lo traduce in una scelta di obiettivo, cioè rilevare condizioni nuove rispetto al periodo di addestramento. Le anomalie presenti negli anni di addestramento sono trattate come già osservate: nella misura in cui il modello le apprende, condizioni simili non

vengono segnalate, mentre lo sono quelle poco o per nulla rappresentate in quegli anni. Lo score misura quindi lo scostamento da quanto il modello ha appreso dal periodo di addestramento, non la rarità di una condizione in assoluto. Lo score è continuo e non coincide con la decisione: sono considerate anomale soltanto le osservazioni con score più alto, in una quota che è un parametro del protocollo. Il termine anomalia è usato in questo senso in tutta la tesi: un evento estremo è un caso particolare di anomalia, ma non ogni anomalia è un evento estremo.

Score e dispersione. Accanto allo score combinato dell'articolo, la tesi considera l'errore di ricostruzione del generatore espresso rispetto alla climatologia della propria cella, del periodo dell'anno e dell'ora, perché la grandezza tipica dell'errore cambia da luogo a luogo e da stagione a stagione (Sezione 4.5). Quale delle due componenti usare è studiato nel Capitolo 6. Il dropout Monte Carlo nel generatore e nel discriminatore (Sezione 2.4) associa a ogni score una misura di dispersione, che l'articolo non prevede.

Validazione senza etichette. L'articolo valuta il detector su eventi documentati, che per i campi meteorologici non sono disponibili in modo sistematico. La tesi introduce quindi anni di validazione, da cui i valori insoliti sono esclusi con un criterio che non dipende dal modello, un'idea analoga al protocollo di Monaco et al. [36], che escludono gli eventi intensi dall'addestramento e li mantengono nel test (Sezione 4.6.1). Sulla validazione sono confrontate le configurazioni e fissate soglie e climatologia degli score, prima di valutare gli anni di test.

Eventi geografici. Gli score delle celle sono aggregati in eventi geografici, gruppi di celle adiacenti collegati da un istante al successivo, che possono separarsi e fondersi (Sezione 4.7). Il passaggio è assente nell'articolo, che si ferma allo score della singola osservazione.

2.6 Posizionamento del lavoro

2.6.1 Il contributo sostenuto

I lavori esaminati coprono ciascuno una parte del problema affrontato. STGAN introduce il contesto spaziale e un criterio avversario, ma presuppone una topologia fisica, la disponibilità di eventi documentati e, implicitamente, un training normale. MTGFlow tollera la presenza di anomalie nel training, ma descrive relazioni fra le variabili di un sistema e non fra siti geografici.

CATCH e M2AD operano su serie multivariate prive di struttura geografica e non trattano, o escludono per ipotesi, un training contaminato.

La tesi adatta un detector avversario spazio-temporale, nato per il traffico, a campi meteorologici privi di etichette e di topologia fisica, lungo gli assi della Sezione 2.5. Lo valuta senza etichette, confrontandolo con rilevatori senza modello e con modelli poco profondi. Il contributo consiste nell'adattamento, nella combinazione di questi elementi e nel protocollo di valutazione. I componenti di base sono preesistenti: la tesi non propone un nuovo algoritmo di rilevamento.

2.6.2 Confronto dei detector esaminati

La Tabella 2.1 riassume i quattro detector esaminati e il percorso della tesi rispetto ai criteri usati nel capitolo. Le voci relative agli articoli riportano ciò che gli articoli dichiarano; dove un aspetto non è discusso, è indicato come non trattato. STGAN è la base del detector; MTGFlow è stato eseguito nel lavoro preliminare (Appendice A); CATCH e M2AD sono stati valutati sugli articoli e non eseguiti.

Tabella 2.1: Detector esaminati e percorso della tesi a confronto. La colonna sulle anomalie nel training indica come ciascun lavoro tratta la presenza di osservazioni anomale nei dati di addestramento.

Lavoro	Segnale dello score	Anomalie nel training	Contesto spaziale	Dati	Dispersione
STGAN [3]	Errore di previsione e discriminatore	Non trattate: dati reali considerati normali	Sì: grafo da topologia fisica	Traffico	Non prevista
MTGFlow [11]	Densità stimata	Ammesse per costruzione	No: relazioni fra variabili	Dataset pubblici	Non prevista
CATCH [9]	Errore di ricostruzione in frequenza	Non trattate	No: canali di una serie	Dataset reali e sintetici	Non prevista
M2AD [10]	Residui di previsione aggregati	Escluse per ipotesi	No: sensori di più sistemi	Dataset pubblici e caso industriale	Non prevista
Tesi	Errore di ricostruzione rispetto alla climatologia, scelto sulla validazione; score di STGAN come riferimento	Trattate come già osservate; escluse dalla validazione	Sì: vicinanza sulla griglia, convoluzione	Campi ERA5	Sì: dropout Monte Carlo nelle due reti

Capitolo 3

Dati e preprocessing

Il capitolo descrive i campi meteorologici su cui il detector è addestrato e valutato: le variabili della rianalisi ERA5, il dominio e la cadenza temporale, la preparazione dei dati e la loro suddivisione in anni di addestramento, di validazione e di test. L'ultima sezione descrive i dati PVGIS da cui il lavoro è partito. Le trasformazioni che dipendono dal modello, come la normalizzazione stagionale, sono descritte nel Capitolo 4.

3.1 Campi ERA5, dominio e celle valide

I dati della rianalisi ERA5 [2] provengono da due prodotti distinti: variabili a livello singolo e variabili su livelli di pressione, di cui è usato soltanto il livello di 850 hPa. Le variabili sono quindici. Le dieci variabili a livello singolo sono temperatura a due metri, componenti orizzontali del vento a dieci metri, pressione al livello medio del mare, precipitazione totale, copertura nuvolosa totale, radiazione solare discendente alla superficie, umidità volumetrica del primo strato del suolo, velocità d'attrito e altezza dello strato limite. Le altre cinque sono le componenti orizzontali del vento, la velocità verticale, la temperatura e l'umidità specifica a 850 hPa. La Tabella 3.1 le elenca con le unità di ERA5, che non vengono convertite.

I dati coprono gli anni dal 1980 al 2025. Sono selezionati gli istanti UTC 00, 03, 06, 09, 12, 15, 18 e 21, su una griglia di $0.5° \times 0.5°$ nell'area compresa fra 20° e 60° di latitudine nord e fra 15° di longitudine ovest e 50° di longitudine est (Figura 3.1). Il dominio comprende l'Europa, il Mediterraneo e parte dell'Africa settentrionale e del Medio Oriente. Il campionamento ogni tre ore è una selezione di tempi validi, non un'aggregazione temporale: precipitazione e radiazione conservano gli accumuli di un'ora associati ai tempi selezionati, senza somme triorarie o conversioni locali delle unità.

Tabella 3.1: Le quindici variabili ERA5, con la sigla e l'unità del dataset. Precipitazione e radiazione sono accumuli di un'ora; le altre variabili sono istantanee.

Variabile	Sigla	Livello	Unità
Temperatura a due metri	t2m	Superficie	K
Componente zonale del vento a dieci metri	u10	Superficie	$\mathrm{m\,s^{-1}}$
Componente meridionale del vento a dieci metri	v10	Superficie	$\mathrm{m\,s^{-1}}$
Pressione al livello medio del mare	msl	Superficie	Pa
Precipitazione totale	tp	Superficie	m
Copertura nuvolosa totale	tcc	Superficie	0–1
Radiazione solare discendente alla superficie	ssrd	Superficie	$\mathrm{J\,m^{-2}}$
Umidità volumetrica del primo strato del suolo	swvl1	Superficie	$\mathrm{m^3\,m^{-3}}$
Velocità d'attrito	zust	Superficie	$\mathrm{m\,s^{-1}}$
Altezza dello strato limite	blh	Superficie	m
Componente zonale del vento	u	850 hPa	$\mathrm{m\,s^{-1}}$
Componente meridionale del vento	v	850 hPa	$\mathrm{m\,s^{-1}}$
Velocità verticale	w	850 hPa	$\mathrm{Pa\,s^{-1}}$
Temperatura	t	850 hPa	K
Umidità specifica	q	850 hPa	$\mathrm{kg\,kg^{-1}}$

Il reticolo contiene $81 \times 131 = 10611$ celle.

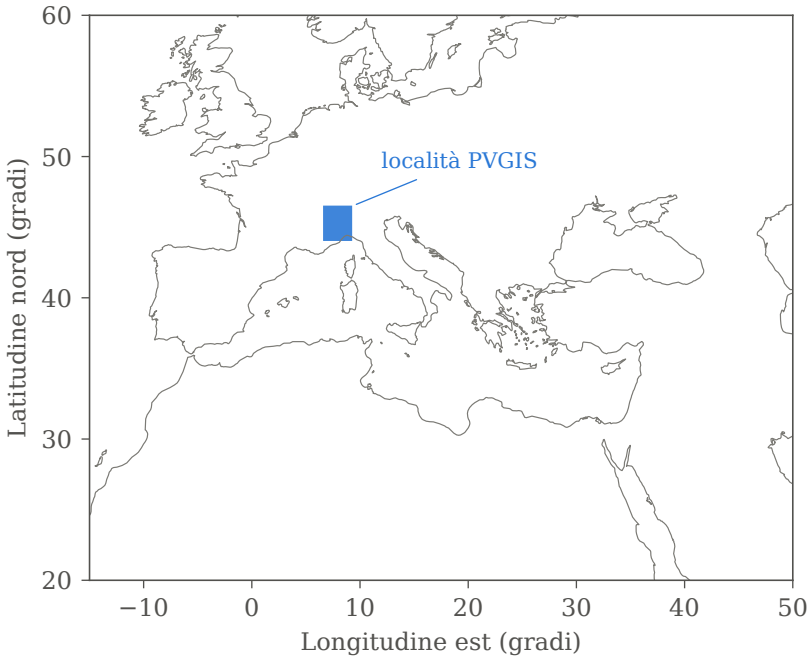


Figura 3.1: Dominio dei campi ERA5: 81×131 celle di 0.5°, fra 20° e 60° di latitudine nord e fra 15° di longitudine ovest e 50° di longitudine est. Il rettangolo indica il Piemonte, la regione dei dati PVGIS della Sezione 3.5. Linee di costa da Natural Earth.

Sono conservate le celle per le quali tutte le variabili sono definite nel primo istante di addestramento, e si verifica che questo insieme rimanga identico nel resto del periodo; se cambia, la preparazione si interrompe. La selezione non utilizza il test e non viene applicata imputazione. Il criterio è la completezza delle variabili, non una classificazione terra–mare: nei dati usati nessuna cella è esclusa.

3.2 Acquisizione e preparazione dei dati

I dati comprendono 134416 istanti, 10611 celle e 15 variabili: circa 2.1×10^{10} valori, 85.6 GB in precisione singola. Il passaggio dai file di ERA5 ai dati letti dal modello è quindi automatizzato, in modo che nessun passo richieda di tenere in memoria l'intero periodo. Si articola in quattro fasi: scarico, verifica, preparazione e lettura (Figura 3.2).

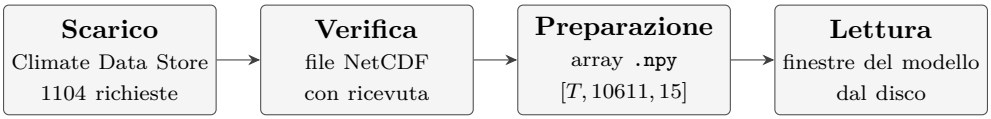


Figura 3.2: Dai file di ERA5 ai dati letti dal modello. I campi sono scaricati mese per mese dal Climate Data Store e conservati solo se superano la verifica; la preparazione li riunisce in array su disco, da cui il modello legge le sole finestre che usa.

Scarico. I campi sono richiesti al Climate Data Store di Copernicus attraverso la sua interfaccia di programmazione, con una richiesta per mese e per prodotto: 552 mesi e 1104 richieste. Ogni richiesta fissa le variabili, gli otto istanti del giorno, la griglia di 0.5°, il dominio e, per il secondo prodotto, il livello di 850 hPa. Il passaggio alla griglia di 0.5° è svolto dal servizio; i file ricevuti, in formato NetCDF [37], non vengono riscritti. Prima dello scarico i nomi delle variabili sono confrontati con quelli accettati dal servizio. Fino a otto richieste sono eseguite in parallelo, e una richiesta respinta per un limite temporaneo del servizio viene ripetuta dopo un'attesa crescente.

Verifica. Un mese è conservato solo se supera tutti i controlli. Gli istanti devono essere esattamente quelli richiesti, senza mancanti né duplicati; latitudini e longitudini devono essere quelle del dominio, con passo di 0.5°; il livello di pressione deve essere soltanto 850 hPa. Devono essere presenti tutte le variabili, senza valori infiniti e, tranne per l'umidità del suolo, che può mancare sul mare, senza campi interamente mancanti in un istante. Per ogni mese è salvata una ricevuta con la richiesta e l'impronta SHA-256 di ciascun file. Quando lo scarico viene ripreso, i mesi con ricevuta e impronta corrette sono saltati e gli altri sono scaricati di nuovo.

Preparazione. Un secondo programma controlla prima che tutti i mesi del periodo siano presenti, poi legge i file mese per mese, a blocchi di 32 istanti. Ripete i controlli su istanti, griglia e livello di pressione, allinea i due prodotti sugli stessi istanti e sulle stesse coordinate, e ordina le latitudini da nord a sud e le longitudini da ovest a est. Ogni blocco diventa un array di forma [istanti, N, 15] in precisione singola, senza conversioni di unità né imputazione, ed è scritto direttamente nella sua posizione in file in formato `.npy` di NumPy [38]. Un file di metadati registra la griglia, le variabili, gli anni e il numero di celle escluse.

Lettura. I file sono aperti in mappatura di memoria: durante l'addestramento e il calcolo degli score si leggono dal disco soltanto gli istanti e le celle di ciascuna finestra. La suddivisione negli anni della Sezione 3.3 è applicata alla lettura.

3.3 Anni di addestramento, di validazione e di test

I dati preparati hanno forma $[T, N, 15]$, con $N = 10611$ celle, e sono divisi in tre periodi consecutivi. Gli anni 1980–1999 sono usati per l'addestramento, gli anni 2000–2004 per la validazione e gli anni 2005–2025 per il test: rispettivamente 58440, 14616 e 61360 istanti. Le quantità stimate dai dati per l'ingresso e la loss del modello, cioè la normalizzazione stagionale, la tendenza rimossa, gli estremi del min–max e i pesi delle variabili del Capitolo 4, sono calcolate sui soli anni di addestramento.

La validazione serve a confrontare le configurazioni e a fissare, prima di valutare il test, tutte le quantità che descrivono il comportamento abituale degli score. Queste quantità sono la climatologia degli score, gli estremi con cui le due componenti dello score combinato sono riportate sulla stessa scala, le soglie e i limiti delle classi di fiducia (Capitolo 5). Sulla validazione è fatta anche la scelta dello score. Gli anni di test non entrano in alcuna scelta: ricevono senza modificarle le quantità stimate sugli anni di addestramento e su quelli di validazione. L'articolo di STGAN [3] separa i dati in training e test senza un insieme di validazione: la validazione è un'aggiunta di questo lavoro, necessaria perché in assenza di etichette la scelta della configurazione deve basarsi su una misura calcolata fuori dal test.

I primi istanti di ciascun periodo usano come contesto la coda del periodo precedente: le finestre di ingresso dei primi istanti di validazione contengono gli ultimi istanti di addestramento, e lo stesso vale fra validazione e test. Il contesto non rientra fra gli istanti valutati.

3.4 Caratteristiche dei campi

Tre proprietà dei campi motivano altrettante scelte del Capitolo 4. Sono misurate sugli anni di addestramento, senza alcun modello.

Cicli diversi da luogo a luogo. La temperatura a due metri e la copertura nuvolosa hanno un ciclo stagionale e uno giornaliero, con livello e ampiezza diversi da una cella all'altra (Figura 3.3). La media mensile della temperatura

va da 1 a 17 °C in una cella dell'Europa settentrionale, da 2 a 24 °C nella Pianura Padana e da 11 a 32 °C nel Sahara; la copertura nuvolosa media sta fra 0.60 e 0.78 nella prima cella e fra 0.04 e 0.29 nell'ultima. Lo stesso valore è quindi abituale in un luogo e in una stagione e insolito in altri. Per questo i valori in ingresso sono riferiti al normale della propria cella, del giorno e dell'ora (Sezione 4.2), e gli score alla climatologia della propria cella (Sezione 4.5).

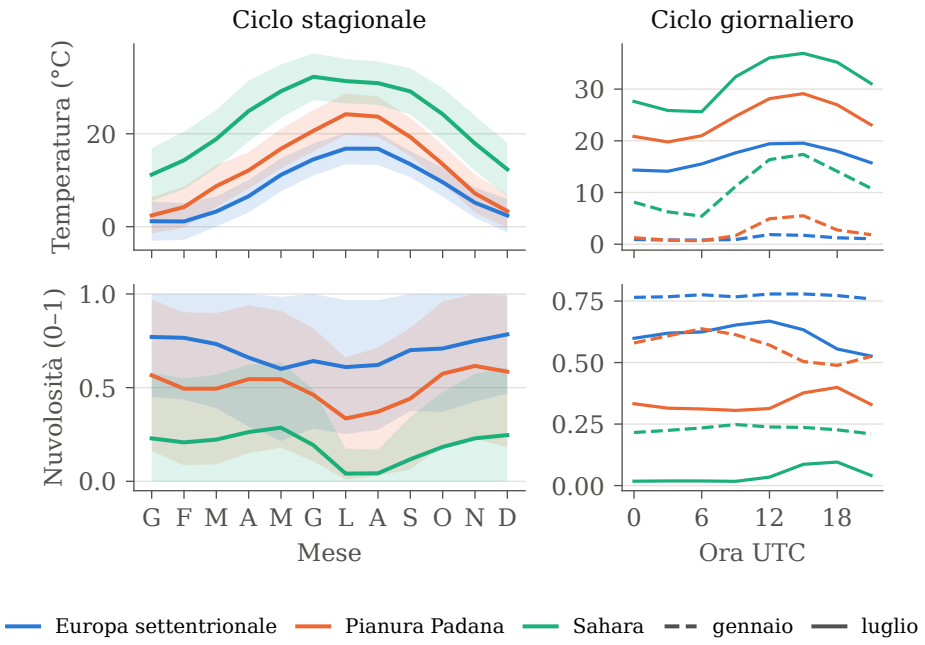


Figura 3.3: Ciclo stagionale e giornaliero della temperatura a due metri e della copertura nuvolosa in tre celle: Europa settentrionale (55°N, 10°E), Pianura Padana (45°N, 9°E) e Sahara (25°N, 10°E). A sinistra la media per mese, con una deviazione standard; a destra la media per ora UTC in gennaio e in luglio. Anni 1980–1999.

Variazioni di grandezza diversa. Con il min–max dell'articolo, che riporta ogni variabile fra il minimo e il massimo degli anni di addestramento, la copertura nuvolosa produce l'84.1% della variazione quadratica media su 24 ore delle quindici variabili, e nessuna delle altre supera il 3.3% (Figura 3.4). La copertura nuvolosa passa spesso da sereno a coperto nel corso di un giorno e attraversa quasi tutto il proprio intervallo; la temperatura cambia di pochi gradi, in un intervallo che comprende tutte le celle e tutte le stagioni. Un errore di ricostruzione che somma le variabili con lo stesso peso sarebbe quindi

in gran parte un errore sulla copertura nuvolosa. Dopo la normalizzazione stagionale e il min–max del detector le quote vanno dallo 0.9% dell'umidità del suolo al 16.6% dell'umidità specifica, e la copertura nuvolosa ha il 6.7%, la quota di una variabile media: la normalizzazione stagionale rende confrontabili anche le variabili fra loro. Le differenze che restano sono corrette dai pesi della Sezione 4.3.

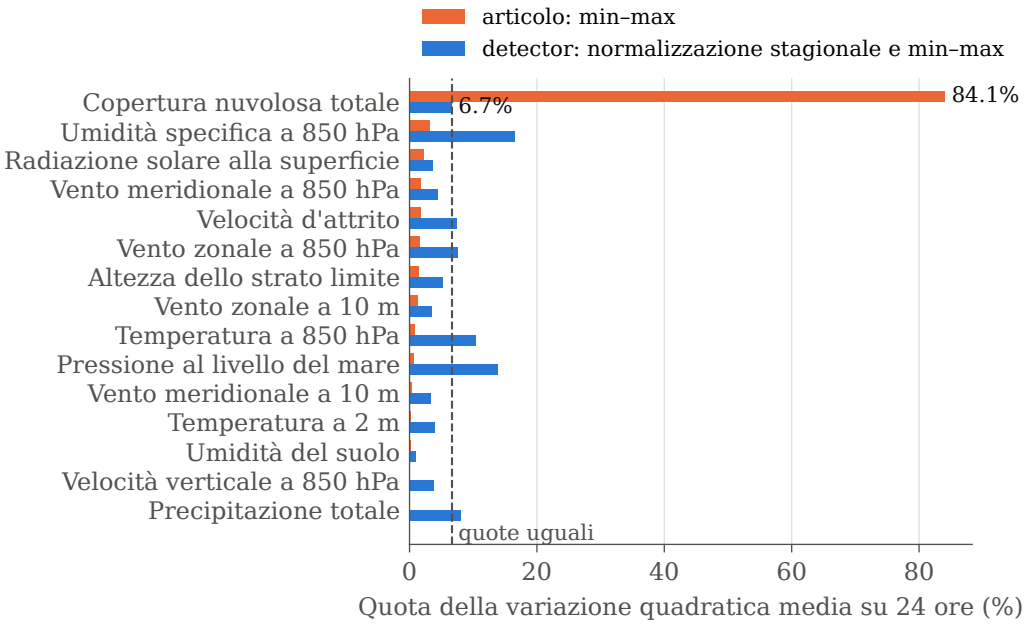


Figura 3.4: Quota di ciascuna variabile nella variazione quadratica media su 24 ore, dopo il min–max dell'articolo e dopo la normalizzazione stagionale e il min–max del detector. Anni 1980–1999; la seconda quota è ricavata dai pesi della Sezione 4.3. La linea tratteggiata indica la quota uguale per tutte le variabili, un quindicesimo.

Legame spaziale a corto raggio. Le anomalie di due celle, cioè gli scostamenti dalla media della propria cella, del mese e dell'ora, sono tanto meno correlate quanto più le celle sono lontane (Figura 3.5). La correlazione mediana scende sotto 0.5 oltre circa 1300 km per la pressione al livello del mare e 900 km per la temperatura a due metri, ma già oltre 200 km per la copertura nuvolosa e 100 km per la precipitazione. Le variabili legate alle perturbazioni dipendono quindi dalle celle vicine, entro poche celle di 0.5°: è il contesto che il detector rappresenta con la ConvGRU del generatore e con la patch del discriminatore (Sezione 4.1).

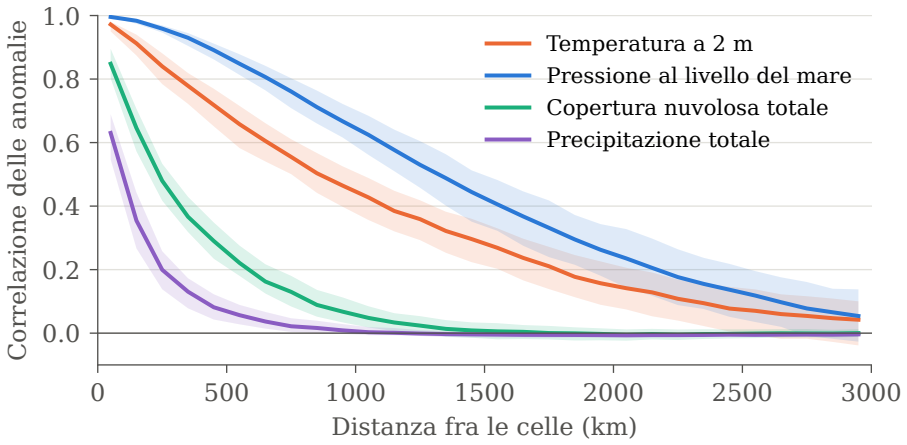


Figura 3.5: Correlazione delle anomalie di due celle in funzione della loro distanza: mediana e quartili per fasce di 100 km, su 300 celle scelte a caso e un istante ogni nove degli anni 1980–1999. Il primo punto, entro 100 km, si basa su 36 coppie di celle.

3.5 I dati PVGIS del lavoro preliminare

Il lavoro è partito, nell'ambito della previsione della produzione fotovoltaica, da serie orarie ottenute dal Photovoltaic Geographical Information System [39] con la banca dati di radiazione SARAH3, provenienti dal progetto SentinelPV del Politecnico di Torino. Coprono 1149 località del Piemonte, comprese fra 44.08° e 46.47° di latitudine nord e fra 6.66° e 9.20° di longitudine est. Nella proiezione UTM del fuso 32 le località occupano 1149 delle 41×54 posizioni di un reticolo regolare con passo di 5 km: quelle che ricadono nel territorio regionale (Figura 3.6), cioè il rettangolo della Figura 3.1. Sono disponibili gli anni dal 2005 al 2023, con 8760 ore per anno (8784 negli anni bisestili) e senza valori mancanti; i valori sono riferiti al minuto 10 di ciascuna ora, in tempo universale.

Per ogni località e ogni istante sono disponibili l'irradianza globale con le sue componenti diretta, diffusa e riflessa, l'altezza del sole, la temperatura dell'aria a due metri, la velocità del vento a dieci metri e la potenza prodotta (Tabella 3.2). L'irradianza è riferita al piano orizzontale: l'inclinazione indicata nei dati è nulla, la componente riflessa risulta nulla e l'irradianza globale coincide con la somma delle componenti diretta e diffusa. Circa la metà dei valori di irradianza è nulla, perché notturna. La potenza è una produzione teorica calcolata da PVGIS, non la misura di un impianto reale.

Queste sono le sole grandezze disponibili, e sono quelle che determinano la produzione fotovoltaica. Un'anomalia rilevata su questi dati non può

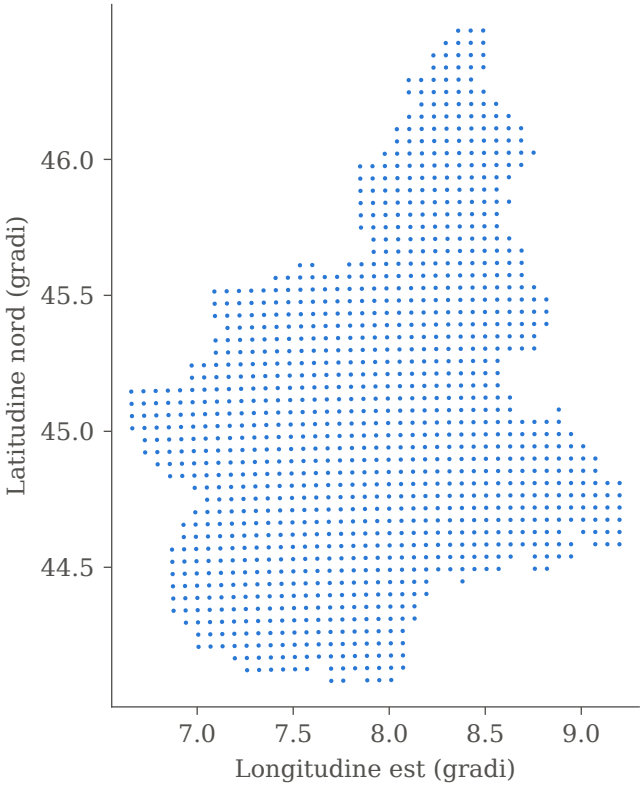


Figura 3.6: Le 1149 località dei dati PVGIS. Ogni punto è una posizione del reticolo con passo di 5 km per la quale sono disponibili le serie orarie.

Tabella 3.2: Grandezze dei dati PVGIS, con l'unità e l'impiego nei metodi dell'Appendice A: il previsore della produzione, le soglie climatologiche e i detector MTGFlow e STGAN.

Grandezza	Unità	Impiego
Irradianza globale (diretta più diffusa)	$\mathrm{W\,m^{-2}}$	Previsore, soglie, detector
Irradianza diretta	$\mathrm{W\,m^{-2}}$	Previsore
Irradianza diffusa	$\mathrm{W\,m^{-2}}$	Previsore
Irradianza riflessa (nulla)	$\mathrm{W\,m^{-2}}$	–
Altezza del sole	gradi	–
Temperatura dell'aria a due metri	°C	Previsore, soglie, detector
Velocità del vento a dieci metri	$\mathrm{m\,s^{-1}}$	Previsore, soglie, detector
Potenza prodotta (teorica)	W	Target del previsore, soglie

essere ricondotta a una condizione meteorologica più generale: per rilevare anomalie di tipo diverso e descriverne l'origine il lavoro è passato ai campi ERA5 descritti nelle sezioni precedenti. I metodi applicati ai dati PVGIS sono descritti nell'Appendice A.

Capitolo 4

Metodologia

Il capitolo descrive il detector nella forma usata sui campi ERA5. La Sezione 4.1 presenta l'architettura, cioè il generatore che opera sul campo intero e il discriminatore locale, e gli obiettivi dell'addestramento avversario. La Sezione 4.2 descrive l'ingresso del modello: finestra recente, codifica temporale e normalizzazione stagionale. Seguono i pesi delle variabili nell'errore di ricostruzione, il dropout Monte Carlo nelle due reti e gli score che ne derivano, la normalizzazione climatologica degli score, la validazione senza etichette e la ricostruzione di eventi geografici a partire dagli score. Il percorso che ha portato a queste scelte, a partire dalla configurazione dell'articolo, è descritto nel Capitolo 5.

La Figura 4.1 riporta l'ordine in cui questi passaggi agiscono su un istante. I campi ERA5 sono riferiti al normale stagionale della propria cella (Sezione 4.2) e dati in ingresso al generatore, che stima il campo dell'istante. L'errore di ricostruzione, pesato per variabile (Sezione 4.3) e mediato sui campioni Monte Carlo (Sezione 4.4), è lo score di ricostruzione. Lo score è poi espresso rispetto alla climatologia del proprio errore (Sezione 4.5) e confrontato con una soglia; le celle sopra soglia formano gli eventi geografici (Sezione 4.7). Normalizzazione stagionale e pesi sono stimati sugli anni di addestramento, prima di addestrare il modello; climatologia e soglia sono stimate sugli anni di validazione, dopo l'addestramento. Il discriminatore non compare nella catena: serve all'addestramento del generatore e allo score combinato, mantenuto come riferimento dell'articolo.

4.1 Architettura e addestramento avversario

Il detector segue lo schema di STGAN [3] descritto nella Sezione 2.1.3: un generatore stima il campo dell'istante successivo a partire dagli istanti

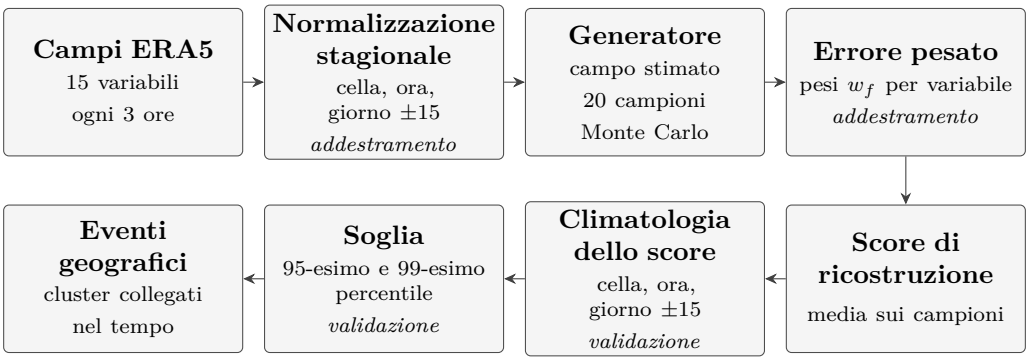


Figura 4.1: Ordine dei passaggi del detector su un istante, dai campi ERA5 agli eventi geografici. In corsivo, gli anni su cui è stimata ciascuna quantità: le scale della normalizzazione stagionale e i pesi sugli anni di addestramento, la climatologia dello score e la soglia sugli anni di validazione.

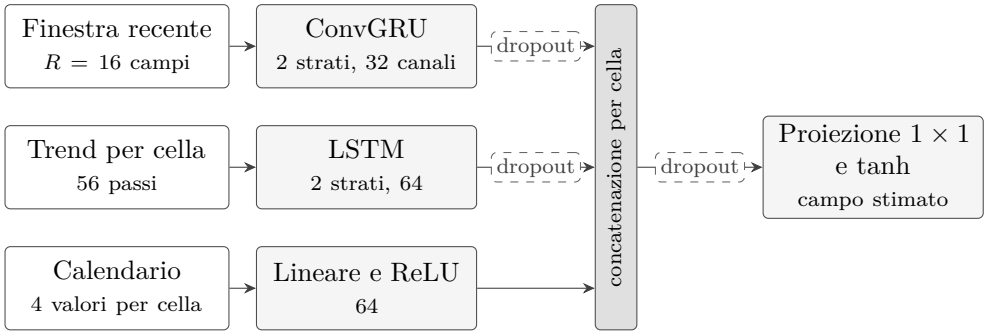
precedenti, e un discriminatore giudica se il campo di un istante, insieme alla sua storia recente, è osservato o generato. Il bersaglio del generatore è meteorologico e comprende le quindici variabili della Tabella 3.1. La griglia è definita direttamente in coordinate geografiche, con passo angolare di 0.5°, e la cadenza è di tre ore. La Figura 4.2 riporta la struttura delle due reti, descritta nelle sottosezioni seguenti.

4.1.1 Generatore ConvGRU sul campo intero e celle assenti

Un campione è il campo completo di un istante, disposto sul reticolo $H \times W$ della Sezione 3.1. Il generatore ha tre rami. Il ramo recente elabora gli R campi che precedono l'istante da stimare con una ConvGRU [30, 31], l'unità ricorrente convoluzionale delle equazioni (2.5)–(2.8), che sostituisce la convoluzione su grafo dell'articolo. Il ramo del trend elabora con una LSTM [40] la serie di ciascuna cella su un periodo più lungo. Il ramo del calendario proietta la codifica temporale. Con R passi recenti, L passi di trend e F variabili, gli ingressi hanno forma $[B, R, F, H, W]$ per il ramo recente e $[B, L, N, F]$ per il trend; l'uscita ha forma $[B, F, H, W]$.

Le convoluzioni scorrono sull'intero reticolo: il campo ricettivo non è troncato al bordo di una regione e ogni cella viene ricostruita una sola volta. La LSTM del trend e la codifica temporale sono calcolate per cella e disposte sul reticolo. Le rappresentazioni dei tre rami sono concatenate cella per cella; una proiezione 1×1 seguita da tanh produce il campo stimato.

(a) Generatore



(b) Discriminatore

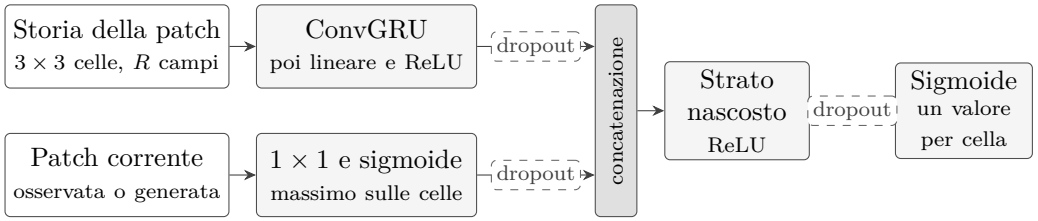


Figura 4.2: Struttura del generatore (a) e del discriminatore (b). Il generatore unisce cella per cella i tre rami, recente, trend e calendario, e produce il campo stimato dell'istante. Il discriminatore giudica ogni cella sulla propria patch, a partire dalla storia recente e dal campo corrente, osservato o generato. I riquadri tratteggiati indicano i dropout, con probabilità 0.2 (Sezione 4.4).

Le celle del reticolo prive di dati sono azzerate dopo la normalizzazione, e una maschera binaria M è fornita come canale aggiuntivo a ogni strato ConvGRU. Rispetto alle equazioni (2.5)–(2.8) cambiano l'ingresso e l'ultimo passaggio. I gate e lo stato candidato sono calcolati su X'_s, la concatenazione dei valori mascherati e di M, al posto di X_s; lo stato precedente H_{s-1} è già mascherato e lo stato aggiornato viene moltiplicato per la maschera, replicata sui canali:

$$H_s = M \odot \left[U_s \odot H_{s-1} + (1 - U_s) \odot \widetilde{H}_s \right]. \tag{4.1}$$

Il mascheramento dello stato impedisce alle celle assenti di conservare attivazioni da propagare negli strati o nei passi successivi. Non viene applicata una rinormalizzazione del kernel in funzione delle celle osservate, come avverrebbe in una partial convolution. Su ERA5 nessuna cella del reticolo è priva di dati, ma la maschera resta necessaria per il discriminatore, le cui patch sul bordo del dominio sono incomplete. Lo stato ricorrente è inizializzato a zero per ogni finestra. Il modello ha due strati ConvGRU da 32 canali con kernel 3×3, e una LSTM del trend a due strati con stato nascosto di dimensione 64.

4.1.2 Discriminatore locale

Il discriminatore giudica ogni cella sulla propria patch $P \times P$, con $P = 3$, così come nell'articolo giudica ogni nodo sul proprio sottografo. La patch di ogni cella è estratta dal campo, con le celle esterne al reticolo azzerate e indicate dalla maschera. Una ConvGRU codifica la storia recente della patch; la storia codificata è appiattita e proiettata linearmente. Il campo corrente della patch, osservato o generato, passa attraverso una proiezione 1×1 seguita da una sigmoide e da un massimo sulle celle valide. Le due rappresentazioni sono concatenate e alimentano uno strato nascosto e un'uscita sigmoidale. Il discriminatore restituisce quindi un valore per cella e per istante.

Le patch di tutte le celle sono valutate in un'unica passata, con le stesse maschere e gli stessi azzeramenti. L'uscita relativa a una cella è quella che il discriminatore produrrebbe sulla sua patch isolata. Una convoluzione che scorresse liberamente sul campo non darebbe lo stesso valore, perché la ConvGRU del discriminatore applica il padding all'interno di ciascuna patch.

4.1.3 Obiettivi di addestramento

Il discriminatore viene addestrato con etichetta zero per il campo reale e uno per il campo generato, come nell'articolo. Indicando con D_{reale} e D_{generato} le uscite sulle patch con il campo osservato e con il campo generato, gli obiettivi

sono

$$\mathcal{L}_D = \tfrac{1}{2}\Big[\mathrm{BCE}(D_{\text{reale}}, 0) + \mathrm{BCE}(D_{\text{generato}}, 1)\Big], \tag{4.2}$$

$$\mathcal{L}_G = \lambda_G \ \mathrm{MSE}_w(\hat{x}, x) + \mathrm{BCE}(D_{\text{generato}}, 0), \tag{4.3}$$

dove MSE_w è l'errore quadratico medio sulle celle valide e sulle variabili, con i pesi delle variabili della Sezione 4.3, mediato poi sugli istanti del batch, e la BCE è mediata sulle uscite locali, una per cella. Rispetto alle equazioni (2.2)–(2.3) dell'articolo, l'errore di ricostruzione è un errore quadratico medio anziché una norma e la loss del discriminatore è dimezzata: la scelta segue il codice pubblicato dagli autori.

Generatore e discriminatore vengono aggiornati con ottimizzatori Adam [41] separati. Nel passo del generatore, i parametri del discriminatore sono congelati ma viene mantenuto il gradiente rispetto al campo generato; la storia della patch è ricalcolata con i pesi aggiornati del discriminatore. Il peso di ricostruzione λ_G è un parametro, con valore predefinito 500, quello dell'articolo. I tassi di apprendimento dei due ottimizzatori possono essere distinti: quello del discriminatore è espresso come rapporto rispetto a quello del generatore. Il coefficiente β_1 degli ottimizzatori vale 0.9, il valore del codice degli autori. Con rapporto n_D:n_G, sullo stesso batch vengono eseguiti prima n_D aggiornamenti del discriminatore e poi n_G del generatore, ciascuno con un proprio passaggio in avanti. Il rapporto è un conteggio di aggiornamenti e non va confuso con il rapporto fra i tassi di apprendimento. Tassi, rapporto e peso di ricostruzione sono gli strumenti con cui si regola l'equilibrio fra le due reti; i valori usati sono scelti nel Capitolo 5.

Un'epoca comprende $\lceil T/B \rceil$ batch, con T istanti di addestramento utili e B istanti per batch, e ogni gradiente è mediato su tutte le celle di un istante. A ogni epoca vengono salvati i pesi e lo stato dei due ottimizzatori; un addestramento interrotto può essere ripreso soltanto con la stessa configurazione, la stessa normalizzazione e gli stessi riferimenti di validazione. Il calcolo usa la precisione mista BF16, con pesi mantenuti in FP32 e loss avversaria calcolata sui logit.

4.2 Ingresso: finestra recente, codifica temporale e normalizzazione stagionale

4.2.1 Finestra recente e trend

La finestra recente contiene gli R istanti che precedono quello da stimare. L'unità ricorrente spaziale la percorre in ordine: parte da uno stato nullo ed

esegue un aggiornamento per ogni istante, sicché lo stato finale riassume gli R campi osservati. Con $R = 1$ il ramo recente vede soltanto l'ultimo istante e la ricorrenza si riduce a un solo aggiornamento. Con $R > 1$ il modello riceve anche l'evoluzione del campo negli istanti precedenti, e l'area che può influenzare una cella cresce con R, perché a ogni aggiornamento lo stato si propaga alle celle vicine. Il detector usa $R = 16$ passi, cioè 48 ore; il trend comprende 56 passi, cioè 168 ore, la stessa durata dell'articolo.

4.2.2 Codifica temporale ciclica

La codifica temporale dell'articolo, a 31 elementi, è composta dal giorno della settimana e dall'ora UTC. È pensata per il traffico e su ERA5 è poco adatta, per due motivi. Il primo è che il vettore è lo stesso per tutte le celle, mentre il dominio si estende per 65 gradi di longitudine: alla stessa ora UTC, l'ora solare delle celle più a ovest e quella delle celle più a est differiscono di oltre quattro ore. Il secondo è che non contiene la posizione nell'anno, e non distingue quindi le stagioni. È perciò sostituita da una codifica ciclica a quattro elementi, diversa per cella. Indicando con h_t l'ora UTC, con ℓ_n la longitudine in gradi, con g_t il giorno frazionario dell'anno e con G_t il numero di giorni dell'anno corrispondente, la codifica è

$$c_{tn} = [\sin \phi_{tn},\ \cos \phi_{tn},\ \sin \psi_t,\ \cos \psi_t], \quad \phi_{tn} = \frac{2\pi}{24}\left(h_t + \frac{\ell_n}{15}\right), \quad \psi_t = \frac{2\pi g_t}{G_t}. \tag{4.4}$$

Il primo angolo rappresenta l'ora solare locale, ottenuta dalla sola longitudine senza fusi orari; il secondo la posizione nell'anno. Seno e coseno rendono vicini gli istanti vicini nel ciclo, come le ore 23 e le ore 1 oppure la fine di dicembre e l'inizio di gennaio. La codifica ciclica non contiene il giorno della settimana.

4.2.3 Normalizzazione stagionale

La normalizzazione dell'articolo è un min–max per variabile stimato sui dati di addestramento. Usa un solo intervallo per variabile, valido per tutte le celle e per tutto l'anno. Su un dominio che va dal Sahara all'Europa settentrionale questo ha un limite: la scala non distingue un valore alto in assoluto, ma abituale per quella cella e quella stagione, da un valore lontano dagli estremi, ma insolito per quella cella e quella stagione. La normalizzazione stagionale riferisce invece ogni valore a ciò che è abituale nella stessa cella, nello stesso periodo dell'anno e alla stessa ora (Figura 3.3). Per ogni cella n, variabile f,

ora del giorno o e giorno dell'anno g il valore è standardizzato,

$$z_{tnf} = \frac{x_{tnf} - \mu_{nfog}}{\sigma_{nfog}}, \tag{4.5}$$

con otto ore del giorno e 366 giorni dell'anno. Media e deviazione standard sono quindi due tensori di forma $[8, 366, N, F]$, con una voce per ogni ora, giorno, cella e variabile, e la standardizzazione è un unico passaggio: ogni valore è confrontato direttamente con la media e la deviazione della propria ora, del proprio giorno, della propria cella e della propria variabile, senza una normalizzazione nel tempo seguita da una nello spazio. Media e deviazione standard sono stimate sui soli anni di addestramento, raccogliendo i quindici giorni che precedono g e i quindici che lo seguono. La deviazione standard è calcolata attorno alla media lisciata di ciascun giorno, in modo che la variazione del ciclo stagionale all'interno della finestra non venga contata come variabilità. Espresse in deviazioni standard del proprio normale, le variabili diventano confrontabili anche fra loro: la copertura nuvolosa, che con il solo min–max produce l'84.1% della variazione su 24 ore, ne produce il 6.7% (Sezione 3.4).

La precipitazione richiede un passaggio in più. È nulla nella maggior parte degli istanti e assume di rado valori molto alti: media e deviazione standard dei valori originali sono determinate in larga parte da questi pochi valori. Prima della standardizzazione la precipitazione è quindi sostituita dalla sua radice quarta, che comprime i valori alti e lascia nullo ciò che è nullo; media e deviazione standard descrivono la radice e non il valore originale. A differenza del logaritmo, la radice è definita anche per i valori nulli e non richiede una costante aggiuntiva.

La deviazione standard σ_{nfog} non può scendere sotto una frazione della deviazione standard complessiva della variabile sugli anni di addestramento: 0.1 per la precipitazione e per l'umidità del primo strato del suolo, 0.01 per le altre tredici variabili. Il limite evita la divisione per valori quasi nulli, come accade per la radiazione solare di notte.

L'ultimo passaggio riguarda il tempo. Gli anni di test seguono quelli di addestramento, fino a oltre vent'anni dopo. Per una variabile che nel periodo ha una tendenza, la differenza fra il clima degli anni di test e quello degli anni di addestramento entrerebbe in ogni valore standardizzato, e crescerebbe con la distanza dagli anni di addestramento. Per tre variabili (temperatura a due metri, temperatura a 850 hPa e umidità del primo strato del suolo) ai valori standardizzati è quindi sottratta una retta nel tempo. La retta è una per variabile, uguale per tutte le celle: passa per le medie annuali dei valori standardizzati sull'intero dominio, è stimata sui soli anni di addestramento e viene prolungata agli anni successivi. La scelta precisa la definizione adottata

nella tesi: le condizioni nuove sono valutate rispetto al clima del momento, e non rispetto al clima degli anni di addestramento. Per le altre dodici variabili la retta non è sottratta. Fra queste c'è l'umidità specifica: la sua deriva inizia dopo gli anni di addestramento, e una retta stimata su quegli anni non la descrive. Per questa variabile la correzione non può quindi essere applicata senza usare gli anni di test.

Dopo questi passaggi è applicato un min–max per variabile, stimato sugli anni di addestramento, che riporta i valori nell'intervallo $[-1, 1]$ dell'uscita del generatore. Negli anni successivi, i valori esterni all'intervallo degli anni di addestramento possono superare questi estremi, perché la trasformazione non applica un clipping.

4.3 Pesi delle variabili nell'errore di ricostruzione

Nell'articolo tutte le variabili contano allo stesso modo nell'errore di ricostruzione. Il detector pesa invece l'errore per variabile, in modo che ciascuna sia misurata in rapporto a quanto cambia abitualmente. Dopo la normalizzazione stagionale le variabili hanno già variazioni dello stesso ordine, ma non uguali: le loro quote della variazione su 24 ore vanno dallo 0.9% al 16.6% (Figura 3.4). I pesi correggono queste differenze. Indicando con m_f il quadrato medio della variazione della variabile f su 24 ore, calcolato sui dati di addestramento normalizzati, il peso è

$$w_f = \frac{\bar{m}}{m_f}, \qquad \bar{m} = \frac{1}{F} \sum_{f=1}^{F} m_f, \tag{4.6}$$

con $F = 15$. La differenza a 24 ore confronta istanti alla stessa ora del giorno e non contiene quindi il ciclo giornaliero. Il fattore $\bar{m}$ lascia invariata la loss per un errore proporzionale a m_f. Il peso non misura la difficoltà del modello su una variabile: è una misura di quanto la variabile cambia, fissata prima dell'addestramento e senza usare il modello. Nella configurazione scelta vanno da 0.40 per l'umidità specifica a 7.14 per l'umidità del primo strato del suolo, che cambia lentamente. I pesi moltiplicano l'errore quadratico di ciascuna variabile nel termine di ricostruzione della loss del generatore e nell'errore di ricostruzione da cui sono calcolati gli score.

4.4 Dropout Monte Carlo nelle due reti e score

4.4.1 Dropout nel generatore e nel discriminatore

Lo score è campionato con il dropout Monte Carlo [33], nella forma che pone il dropout dopo gli encoder e prima degli strati di uscita. Il generatore riceve tre strati di dropout: sulla rappresentazione spaziale del ramo recente, sulla rappresentazione del trend e sulla loro concatenazione con la codifica temporale, prima della proiezione di uscita. Il discriminatore ne riceve altrettanti, nelle posizioni corrispondenti: sulla storia codificata, sul campo corrente codificato e sullo strato nascosto che precede l'uscita. La probabilità è 0.2 in entrambe le reti. I dropout sono attivi nell'addestramento e nel calcolo degli score. L'articolo e il codice degli autori non usano il dropout: è un'aggiunta di questo lavoro.

Il discriminatore riceve il campo generato senza il dropout del generatore: nell'addestramento, sia nel proprio aggiornamento sia nel termine avversario del generatore, e nel calcolo degli score. Se ricevesse il campo con il dropout, potrebbe distinguere i campi generati da quelli osservati per il rumore che il dropout vi introduce, e non per il loro contenuto. Il dropout del generatore agisce quindi sull'errore di ricostruzione, quello del discriminatore sul suo giudizio.

4.4.2 Campioni Monte Carlo e componenti dello score

Durante il calcolo degli score il modello è in modalità di valutazione, con l'eccezione dei dropout, che restano attivi. Per ogni istante vengono estratti $J = 20$ campioni. Nel campione j il generatore ricostruisce il campo con una propria maschera, e il discriminatore giudica l'osservazione e il campo generato senza dropout con una propria maschera, la stessa per i due giudizi: il campione corrisponde a un'unica estrazione delle due reti. Gli encoder del generatore e la codifica della storia nel discriminatore non dipendono dal dropout e sono calcolati una sola volta; a ogni campione vengono ripetuti i dropout e gli strati che li seguono.

Per la coppia istante–cella (t, n) e il campione j, la ricostruzione $\hat{x}^{(j)}$ dà l'errore di ricostruzione

$$s_{G,tn}^{(j)} = \frac{1}{|P_n|\, F} \sum_{c \in P_n} \sum_{f=1}^{F} w_f \left(\hat{x}_{tcf}^{(j)} - x_{tcf} \right)^2 , \tag{4.7}$$

dove P_n sono le celle valide della patch di n. La componente del discriminatore è, come nell'articolo, la differenza fra il giudizio sull'osservazione e quello sul

campo generato,

$$s^{(j)}_{D,tn} = D^{(j)}_{\text{reale},tn} - D^{(j)}_{\text{generato},tn}. \tag{4.8}$$

La componente di ricostruzione media sui campioni,

$$\bar{s}_{G,tn} = \frac{1}{J}\sum_{j=1}^{J} s^{(j)}_{G,tn}, \tag{4.9}$$

è la media degli errori dei singoli campioni, e non l'errore della ricostruzione media. Per ogni cella e variabile le due quantità differiscono per la varianza delle ricostruzioni:

$$\frac{1}{J}\sum_{j=1}^{J}\left(\hat{x}^{(j)} - x\right)^2 = \left(\bar{\hat{x}} - x\right)^2 + \frac{1}{J}\sum_{j=1}^{J}\left(\hat{x}^{(j)} - \bar{\hat{x}}\right)^2, \qquad \bar{\hat{x}} = \frac{1}{J}\sum_{j=1}^{J}\hat{x}^{(j)}. \tag{4.10}$$

La componente cresce quindi sia quando la ricostruzione si allontana dall'osservazione, sia quando i campioni non sono concordi fra loro.

4.4.3 Score combinato e score di ricostruzione

Dalla stessa esecuzione sono ricavati due score. Lo *score combinato* è quello dell'articolo. Le due componenti sono riportate su una scala comune con un min–max e sommate con peso unitario, campione per campione:

$$a^{(j)}_{tn} = \frac{s^{(j)}_{G,tn} - r_{\min}}{r_{\max} - r_{\min}} + \frac{s^{(j)}_{D,tn} - d_{\min}}{d_{\max} - d_{\min}}, \qquad \bar{a}_{tn} = \frac{1}{J}\sum_{j=1}^{J} a^{(j)}_{tn}. \tag{4.11}$$

L'articolo indica che le due componenti sono normalizzate prima della somma, senza specificare come, e il codice degli autori salva le componenti senza combinarle: il min–max è quindi una scelta di questo lavoro. Gli estremi $r_{\min}$, $r_{\max}$, $d_{\min}$ e $d_{\max}$ sono quelli delle due componenti medie sui campioni negli anni di validazione, esclusi i valori segnati come insoliti (Sezione 4.6.1), e restano fissi per il test: nessuna quantità dello score è stimata sugli anni valutati. I valori del test possono uscire dall'intervallo $[0, 1]$ di ciascuna componente, perché non è applicato un clipping.

Lo *score di ricostruzione* usa la sola componente $\bar{s}_{G,tn}$, espressa poi rispetto alla climatologia della propria cella come nella Sezione 4.5. Quale dei due score usare è studiato nel Capitolo 6, dal comportamento delle due componenti nello spazio e nel tempo (Sezione 5.2).

4.4.4 Dispersione

La dispersione associata a ciascuno score è la deviazione standard di popolazione dei suoi campioni; per lo score combinato,

$$u_{tn} = \sqrt{\frac{1}{J}\sum_{j=1}^{J}\left(a_{tn}^{(j)} - \bar{a}_{tn}\right)^2}, \tag{4.12}$$

nelle stesse unità dello score, e analogamente per la componente di ricostruzione. Misura quanto lo score cambia con le maschere di dropout delle due reti e non è una probabilità di anomalia; la sua calibrazione come misura di incertezza non è verificata dal metodo. Una segnalazione che resta sopra la soglia anche con lo score diminuito di u_{tn} non dipende dalle maschere estratte. Le singole estrazioni non vengono conservate: media, deviazione standard e covarianza delle due componenti bastano a ricavare la dispersione di qualunque loro combinazione lineare.

4.4.5 Classi di fiducia

La dispersione dei campioni del generatore cresce con l'errore di ricostruzione: un'osservazione ricostruita male ha in genere anche campioni più discordi. Per ricavarne un'informazione che l'errore non contiene già, la deviazione standard dei campioni del generatore di una segnalazione è confrontata con quella delle segnalazioni che hanno un errore simile. Sugli anni di validazione le segnalazioni sono divise in venti fasce di uguale numerosità secondo la componente di ricostruzione media $\bar{s}_{G,tn}$; in ogni fascia i quintili della deviazione standard dei campioni del generatore definiscono cinque classi. La classe 1 raccoglie le segnalazioni i cui campioni sono i più concordi per il loro errore, la classe 5 quelle con i campioni più discordi. I limiti delle fasce e dei quintili restano fissi per il test. La classe accompagna ogni segnalazione come indicazione di fiducia: non entra nello score né nella soglia, e non decide se un'osservazione è segnalata.

4.5 Normalizzazione climatologica degli score

Una trasformazione successiva al calcolo degli score esprime ogni score rispetto alla climatologia della stessa cella. Per la cella n, il giorno dell'anno g e l'ora UTC o dell'istante t,

$$\zeta_{tn} = \frac{a_{tn} - \mu_{ngo}}{\sigma_{ngo}}, \tag{4.13}$$

dove a_{tn} è lo score da trasformare, lo score di ricostruzione $\bar{s}_{G,tn}$ o lo score combinato $\bar{a}_{tn}$. Media e deviazione standard sono calcolate con la stessa ricetta della normalizzazione stagionale della Sezione 4.2: sugli score della stessa cella e della stessa ora nei quindici giorni che precedono g e nei quindici che lo seguono, con una finestra che scavalca la fine dell'anno, e con la deviazione standard calcolata attorno alla media lisciata di ciascun giorno. Lo score è uno per cella e non ha la dimensione delle variabili: media e deviazione standard sono due tensori di forma $[8, 366, N]$. Sono stimate negli anni di validazione, esclusi i valori segnati come insoliti (Sezione 4.6.1), e restano fisse per il test. Non possono essere stimate sugli anni di addestramento, perché su quegli anni il modello ha già visto i dati e il suo errore è più basso di quello su anni nuovi. Quando lo score trasformato serve sugli anni di validazione stessi, per le scelte e per fissare le soglie, media e deviazione standard di un anno y sono calcolate sugli altri quattro anni di validazione, $\mu_{ngo}^{(-y)}$ e $\sigma_{ngo}^{(-y)}$: nessun valore entra nella propria climatologia. I gruppi con meno di trenta valori di riferimento o con varianza nulla non ricevono uno score. La dispersione viene divisa per la stessa deviazione standard.

Gli score di validazione da cui sono stimate queste quantità sono calcolati con la storia reale degli istanti di validazione, come quelli del test. La sostituzione dei valori insoliti nella storia (Sezione 4.6.1) serve alla misura con cui si confrontano le configurazioni durante l'addestramento e al passaggio di validazione che chiude l'addestramento, da cui vengono gli estremi dello score combinato; non entra nella climatologia. Una climatologia stimata su errori calcolati da una storia ripulita descriverebbe un errore più basso di quello che il modello commette sul test, dove la storia contiene le condizioni insolite.

Lo scopo è rendere confrontabili celle e stagioni in cui l'errore di ricostruzione ha una grandezza tipica diversa: senza questo passaggio, le segnalazioni si concentrerebbero dove l'errore è grande per natura. La trasformazione applica la stessa idea della normalizzazione stagionale, cioè esprimere un valore rispetto a ciò che è abituale per quella cella, quel periodo dell'anno e quell'ora, ma a un oggetto diverso. La normalizzazione stagionale agisce sui campi in ingresso, prima del modello, ed è stimata sugli anni di addestramento: toglie il ciclo stagionale e giornaliero dei dati, ma non la differenza di prevedibilità fra celle e stagioni. Dove il tempo cambia più rapidamente il generatore sbaglia di più anche su dati standardizzati. La normalizzazione climatologica agisce sull'errore del generatore, dopo l'addestramento, è stimata sugli anni di validazione e toglie questa seconda differenza senza modificare il detector.

4.6 Validazione senza etichette

Gli anni di validazione servono a confrontare configurazioni del detector senza usare il test e senza etichette. Il confronto deve misurare quanto bene il modello ricostruisce il tempo normale: le condizioni insolite presenti negli anni di validazione sono quindi individuate con un criterio che non usa il modello, e tenute fuori dalle misure.

4.6.1 Valori insoliti della validazione

Un valore, cioè una coppia istante–cella, è segnato come insolito con due distanze calcolate sui dati standardizzati della Sezione 4.2. La prima è la distanza dal normale stagionale: la media sulle variabili del quadrato dei valori standardizzati, con i pesi delle variabili della Sezione 4.3, che dice quanto il valore è lontano dal normale della propria cella, giorno e ora. La seconda è la variazione dall'istante precedente: la stessa media pesata sul quadrato della differenza rispetto a tre ore prima, che coglie i cambiamenti rapidi anche quando il valore resta vicino al normale. Ciascuna distanza è standardizzata con la media e la deviazione standard della stessa cella, dello stesso mese e della stessa ora negli anni di addestramento, così che un luogo o una stagione più variabili non concentrino le segnalazioni. Un valore è segnato quando almeno una delle due distanze standardizzate supera il livello oltrepassato dal 5% dei valori di addestramento. Medie, deviazioni standard e livelli sono stimati sui soli anni di addestramento; la validazione riceve soltanto le segnalazioni. Il criterio è approssimato: non pretende di individuare tutte le condizioni insolite, ma di togliere le più evidenti, così che le misure dipendano soprattutto dal tempo ordinario. La soglia del 5% è una scelta, e segna il 9.75% dei valori di validazione.

I valori segnati non entrano nelle misure calcolate sulla validazione, e nelle finestre di ingresso degli istanti di validazione sono sostituiti dal normale stagionale, cioè dal valore standardizzato nullo. In questo modo né il bersaglio né la storia recente da cui il modello parte contengono le condizioni insolite.

4.6.2 Distanza fra campi osservati e ricostruiti nello spazio delle componenti principali

La misura usata per confrontare le configurazioni confronta osservazioni e ricostruzioni in uno spazio indipendente dal modello. Lo spazio è ottenuto da un'analisi delle componenti principali dei campi di addestramento: ogni campione è il campo completo di un istante, normalizzato e appiattito su celle e variabili. Sono usati i campi con la quota più bassa di valori insoliti, nello

stesso numero per ogni mese, e sono conservate 300 componenti principali. Lo spazio è costruito una sola volta, prima delle esecuzioni, e successivamente soltanto caricato.

I campi di tempo normale sono scelti, non corretti. Sostituire i valori insoliti con il normale stagionale darebbe campi più lisci di qualunque campo osservato, e una distanza calcolata su di essi premierebbe un generatore che ricostruisce campi lisci. Un campo scelto può contenere ancora qualche valore insolito, entro la quota che lo fa rientrare fra i campi normali del suo mese. Per lo stesso motivo il valore da ricostruire, quando è insolito, non è sostituito ma escluso dalle misure: si sostituisce soltanto la storia da cui il modello parte.

Su questo spazio viene definito un riferimento per la validazione. È formato da $S = 5$ sottoinsiemi fissi e disgiunti di 512 campi normali degli anni di validazione, scelti con lo stesso criterio, dalle coordinate delle loro osservazioni nello spazio e da una banda σ pari alla distanza euclidea mediana fra tali coordinate. Anche questo riferimento è fissato prima delle esecuzioni. A ogni epoca, per ciascun sottoinsieme, si calcola la stima non distorta della Maximum Mean Discrepancy [42]

$$\widehat{\mathrm{MMD}}^2 = \frac{1}{n(n-1)} \sum_{i \neq i'} k(x_i, x_{i'}) + \frac{1}{n(n-1)} \sum_{i \neq i'} k(y_i, y_{i'}) - \frac{2}{n^2} \sum_{i,i'} k(x_i, y_{i'}), \tag{4.14}$$

dove x_i sono le coordinate delle osservazioni, y_i quelle delle ricostruzioni del generatore e il kernel è la media di tre RBF,

$$k(a, b) = \frac{1}{3} \sum_{c \in \{0.5,\, 1,\, 2\}} \exp\left(-\frac{\|a - b\|^2}{2(c\sigma)^2} \right). \tag{4.15}$$

Vengono registrate media e varianza della stima sui sottoinsiemi e la media delle ultime cinque epoche, che è la quantità usata per scegliere fra configurazioni. La stima non distorta può assumere valori leggermente negativi. Poiché tutte le esecuzioni confrontate caricano gli stessi riferimenti, le differenze nella misura non dipendono da una nuova stima dello spazio o della banda. Una MMD più bassa indica ricostruzioni più vicine alle osservazioni nello spazio considerato; non misura direttamente la qualità del rilevamento delle anomalie.

4.6.3 Diagnostiche per epoca e misure finali

Al termine di ogni epoca un sottoinsieme fisso della validazione, 32 istanti equispaziati con tutte le celle, viene elaborato con un passaggio deterministico,

a dropout spento. Vengono registrate due quantità: la differenza assoluta media fra le attivazioni del penultimo strato del discriminatore sull'osservazione e sulla ricostruzione, e la variazione dello score fra epoche consecutive sulle stesse celle. Queste quantità e la MMD non entrano in una loss, in un aggiornamento dei pesi o negli score; sono calcolate senza gradiente e ripristinando gli stati dei generatori di numeri casuali, così da non alterare la traiettoria dell'addestramento.

Dopo l'ultima epoca, su tutti i valori validi e non segnati della validazione, viene calcolata la componente di ricostruzione media sui campioni Monte Carlo, riassunta da media, deviazione standard, mediana e 95° percentile. Gli stessi campioni danno gli estremi delle due componenti usati dallo score combinato.

4.7 Eventi geografici

Gli score di un istante formano un campo sulla griglia. Gli eventi geografici sono ricavati da questi campi in una fase distinta, successiva al calcolo degli score e senza un nuovo aggiornamento dei pesi del detector. La Figura 4.3 riassume i passaggi.

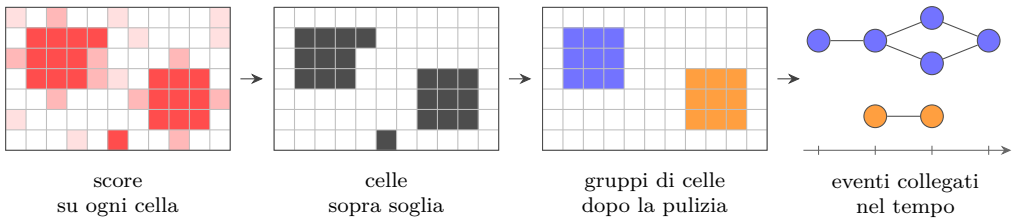


Figura 4.3: Dagli score agli eventi geografici, su un esempio illustrativo. Gli score di un istante sono riportati sulla griglia; le celle sopra soglia formano una maschera, da cui apertura e chiusura rimuovono le celle isolate e le sporgenze; le celle rimaste sono riunite in cluster, gruppi di celle adiacenti. I cluster di istanti consecutivi sono poi collegati: un evento è un insieme di cluster collegati, e resta unico anche quando un cluster si separa in due o due cluster si fondono.

4.7.1 Soglia, morfologia e cluster spaziali

Gli score $[T, N]$ vengono ricollocati sulla griglia $[T, H, W]$. La selezione iniziale può utilizzare una soglia assoluta oppure un percentile degli score finiti, globale

in modo predefinito o distinto per istante. Una cella è selezionata soltanto se lo score è strettamente maggiore della soglia.

Per ogni istante, la maschera binaria viene sottoposta ad apertura e chiusura, rispettando le celle valide. La configurazione predefinita usa un elemento strutturante quadrato 3×3 e un'iterazione per operazione. Le componenti connesse, cioè i cluster, sono individuate con otto vicini e possono essere filtrate per numero minimo di celle. Le operazioni morfologiche possono rimuovere o aggiungere celle rispetto alla selezione iniziale: i cluster risultanti non coincidono necessariamente con l'insieme degli score sopra soglia. Le aree dei cluster sono ottenute sommando le aree sferiche delle celle e i centroidi sono pesati con tali aree.

4.7.2 Collegamento temporale, separazioni e fusioni

I cluster di istanti consecutivi vengono collegati secondo sovrapposizione, sovrapposizione dopo dilatazione, distanza dei centroidi oppure unione dei criteri. Indicando con A e B i supporti di due cluster, il rapporto di sovrapposizione è

$$o(A, B) = \frac{|A \cap B|}{\min(|A|, |B|)}. \tag{4.16}$$

Non si tratta dell'intersezione sull'unione. Nel criterio dilatato, A è sostituito dal supporto ottenuto dopo dilatazione, anche nel denominatore. La configurazione predefinita usa una dilatazione di una cella e una soglia di sovrapposizione pari a 0.1.

L'identità di un evento corrisponde a una componente connessa del grafo temporale dei cluster. Il collegamento non è vincolato a essere uno a uno: una separazione mantiene i rami nello stesso evento, mentre una fusione unifica retrospettivamente le identità precedenti. Un salto nella cadenza temporale interrompe i collegamenti. La durata riportata comprende l'intervallo rappresentato dall'ultimo istante,

$$d_{\text{evento}} = t_{\text{fine}} - t_{\text{inizio}} + \Delta t, \qquad \Delta t = 3\,\text{h}. \tag{4.17}$$

La dispersione dello score viene riportata per cluster e per evento, come media e massimo sulle celle; non partecipa alla soglia, alla morfologia o ai collegamenti. L'unificazione retrospettiva degli eventi definisce un'analisi successiva al periodo osservato, non un sistema di allerta in tempo reale.

Capitolo 5

Esperimenti

Il capitolo descrive come il detector del Capitolo 4 è addestrato e valutato sui campi ERA5: la configurazione di addestramento e la ricerca dei parametri, e il protocollo di valutazione. I risultati sono nel Capitolo 6.

5.1 Configurazioni di addestramento

La configurazione del detector è fissata, a eccezione dei quattro parametri che regolano l'equilibrio fra generatore e discriminatore, scelti con una ricerca bayesiana. La Tabella 5.1 riporta gli uni e gli altri.

L'obiettivo della ricerca è la media delle ultime cinque epoche della distanza fra campi osservati e ricostruiti della Sezione 4.6, da minimizzare. Ogni esecuzione della ricerca è addestrata e misurata sulla validazione, senza calcolare gli score sul test. La ricerca non ha un numero di esecuzioni fissato: le esecuzioni si succedono finché la ricerca non viene fermata. È scelta la configurazione con l'obiettivo più basso fra le esecuzioni completate al momento della scelta. Alcune esecuzioni si sono interrotte prima della fine perché una loss è diventata non finita: il controllo che le ferma interviene prima che vengano salvati score, e queste esecuzioni, prive di un obiettivo completo, non entrano nella scelta. Del modello scelto si usano i pesi dell'ultima epoca, come nel codice degli autori, che salva i pesi a ogni epoca e valuta quelli dell'ultima [3]; nessuna epoca è scelta in base al risultato. Gli score di test e di validazione della configurazione scelta sono calcolati in seguito, a partire da quei pesi. Un'epoca comprende 58384 aggiornamenti per rete, cioè gli istanti di addestramento meno i 56 di contesto del trend, e dura circa 2.4 ore.

I modelli sono implementati in PyTorch [43]. I dati sono letti con xarray [44] dai file mensili in formato NetCDF [37]; le tabelle di score sono elaborate con pandas [45]; le operazioni morfologiche e le componenti connes-

Tabella 5.1: Configurazione del detector su ERA5. Nella parte superiore i valori fissati, nella parte inferiore i parametri della ricerca, con l'intervallo esplorato e il valore della configurazione scelta; la distribuzione logaritmica rende equidistanti, per esempio, i rapporti 0.5 e 2.

Elemento	Valore
Anni di addestramento, validazione, test	1980–1999, 2000–2004, 2005–2025
Unità del campione e batch	Campo intero, un istante per batch
Generatore	ConvGRU, due strati da 32 canali, kernel 3×3
Finestra recente e trend	16 e 56 passi, cioè 48 e 168 ore
Codifica temporale	Ciclica, per cella
Normalizzazione	Stagionale, con retta per tre variabili, poi min–max
Pesi delle variabili	Inversi della variazione su 24 ore
Dropout	0.2, nel generatore e nel discriminatore
Campioni Monte Carlo negli score	20
Epoche	6
Precisione	BF16
Tasso di apprendimento del generatore	da 10^{-4} a $3 \cdot 10^{-3}$, logaritmica; scelto $4.93 \cdot 10^{-4}$
Rapporto fra i tassi del discriminatore e del generatore	da 0.25 a 4, logaritmica; scelto 0.951
Peso di ricostruzione λ_G	da 50 a 2000, logaritmica; scelto 176.6
Aggiornamenti per batch, n_D:n_G	1:1, 2:1 oppure 1:2; scelto 1:1

se degli eventi geografici usano SciPy [46]. Tutti i modelli sono addestrati su una scheda NVIDIA RTX PRO 6000 Blackwell.

5.2 Protocollo di valutazione

Gli score della configurazione scelta sono calcolati sugli anni di validazione 2000–2004 e di test 2005–2025, su tutti gli istanti e tutte le 10611 celle, con i 20 campioni Monte Carlo della Sezione 4.4; in entrambi i periodi le finestre di ingresso contengono la storia reale. Dalla stessa esecuzione sono ricavati lo score combinato e lo score di ricostruzione. Il protocollo separa ciò che si stima da ciò che si valuta. Le quantità che descrivono il comportamento abituale degli score, cioè la climatologia, gli estremi dello score combinato, le soglie e i limiti delle classi di fiducia, sono stimate sugli anni di validazione e restano fisse per il test. La soglia è il 95-esimo percentile degli score di validazione; sul test segnala una quota che può scostarsi dal 5%, ed è riportata nei risultati. Alcune analisi sono ripetute con il 99-esimo percentile, per verificare che le conclusioni non dipendano dalla soglia. Non esistono etichette di anomalia: il comportamento degli score e il loro confronto con altri rilevatori sono descritti nel Capitolo 6.

Componenti dello score. Lo score dell'articolo combina l'errore di ricostruzione del generatore e il giudizio del discriminatore (Sezione 4.4). Quale delle due componenti usare non è fissato in anticipo con un riferimento esterno: le due componenti, prima e dopo la normalizzazione climatologica (Sezione 4.5), sono calcolate dalla stessa esecuzione, e il loro comportamento nello spazio e nel tempo è studiato nel Capitolo 6. Gli anni di test non intervengono nell'addestramento né nella scelta degli iperparametri, fatta sulla validazione con la distanza fra campi osservati e ricostruiti (Sezioni 4.6 e 5.1).

Capitolo 6

Risultati e discussione

Il capitolo riporta e discute i risultati del detector sui campi ERA5, nella configurazione scelta dalla ricerca dei parametri. In assenza di etichette, il comportamento del detector è studiato in cinque passi. Il primo riguarda la scelta della configurazione e la convergenza della ricerca. Il secondo esamina le componenti dello score, del generatore e del discriminatore, e il loro legame nello spazio e nel tempo, per stabilire quale parte dello score usare. Il terzo confronta le segnalazioni del detector con quelle di metodi più semplici, statistici o basati su modelli poco profondi. Il quarto raggruppa le segnalazioni in eventi e li descrive per tipo e dimensione. L'ultimo esamina casi specifici.

6.1 Ricerca dei parametri

Sezione da scrivere quando la ricerca con Optuna si sarà assestata.

6.2 Correlazione spaziale degli score

Lo score dell'articolo somma due componenti, e prima di sceglierne una conviene capire se segnalano le stesse situazioni. Questa sezione e le due seguenti riguardano gli anni di test 2005–2025 della configurazione scelta: 61360 istanti su 10611 celle. Con G si indica la componente del generatore $\bar{s}_{G,tn}$, con D quella del discriminatore $\bar{s}_{D,tn}$, entrambe medie sui 20 campioni (Sezione 4.4); per entrambe un valore più alto indica un'osservazione più insolita. Due score sono confrontati con la correlazione di Pearson, calcolata sui valori, e con quella di Spearman, calcolata sui ranghi, che pochi valori molto alti non bastano a decidere.

Correlazione in ogni istante. La correlazione spaziale è calcolata in ogni istante sulle celle: vale 1 se i due score ordinano i luoghi allo stesso modo, -1 se li ordinano in modo opposto. Fra G e D è negativa quasi sempre: la correlazione di Spearman vale in media -0.24 ed è negativa nel 99.98% degli istanti, quella di Pearson vale in media -0.51 (Figura 6.1). Nello stesso istante, quindi, le celle in cui il generatore sbaglia di più sono in genere quelle a cui il discriminatore dà lo score più basso, cioè meno anomalo.

Stagione e ora del giorno. Il legame cambia poco nel corso del test. È un po' più forte d'estate e nelle ore centrali del giorno, un po' più debole d'inverno e di notte. Solo in pochi giorni, fra la fine del 2019 e l'inizio del 2020, la correlazione di Pearson diventa positiva.

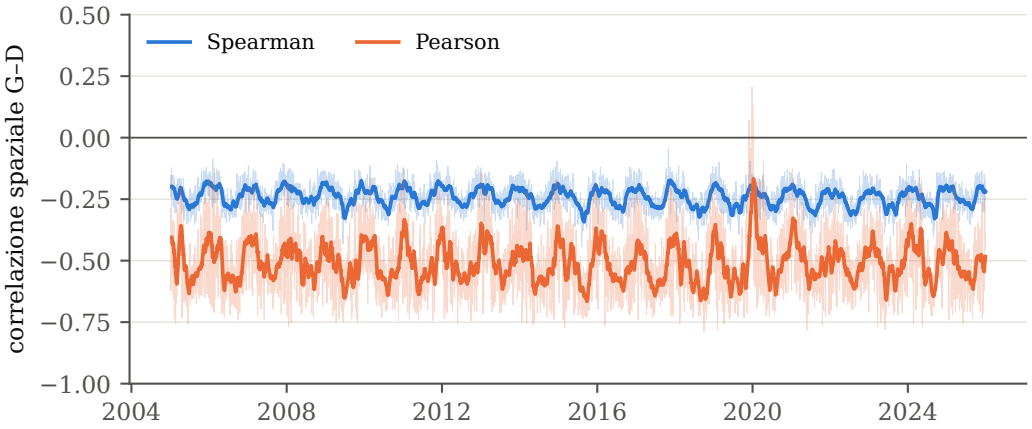


Figura 6.1: Correlazione spaziale fra G e D in ogni istante degli anni di test, calcolata sulle 10611 celle: media giornaliera (linea sottile) e media mobile su 30 giorni (linea spessa), con Spearman e con Pearson. Le due correlazioni restano negative per quasi tutto il periodo.

Due istanti. La Figura 6.2 mostra i due score in due istanti: l'8 agosto 2014 alle 3 UTC, in cui la correlazione di Spearman è uguale alla sua mediana sul test, e il 30 agosto 2024 alle 12 UTC, in cui la media di G sulle celle è la più alta del test. Nel secondo, G è alto su una fascia stretta del Nord Africa orientale; nella stessa zona, su un'area più ampia, D assume i valori più bassi del dominio.

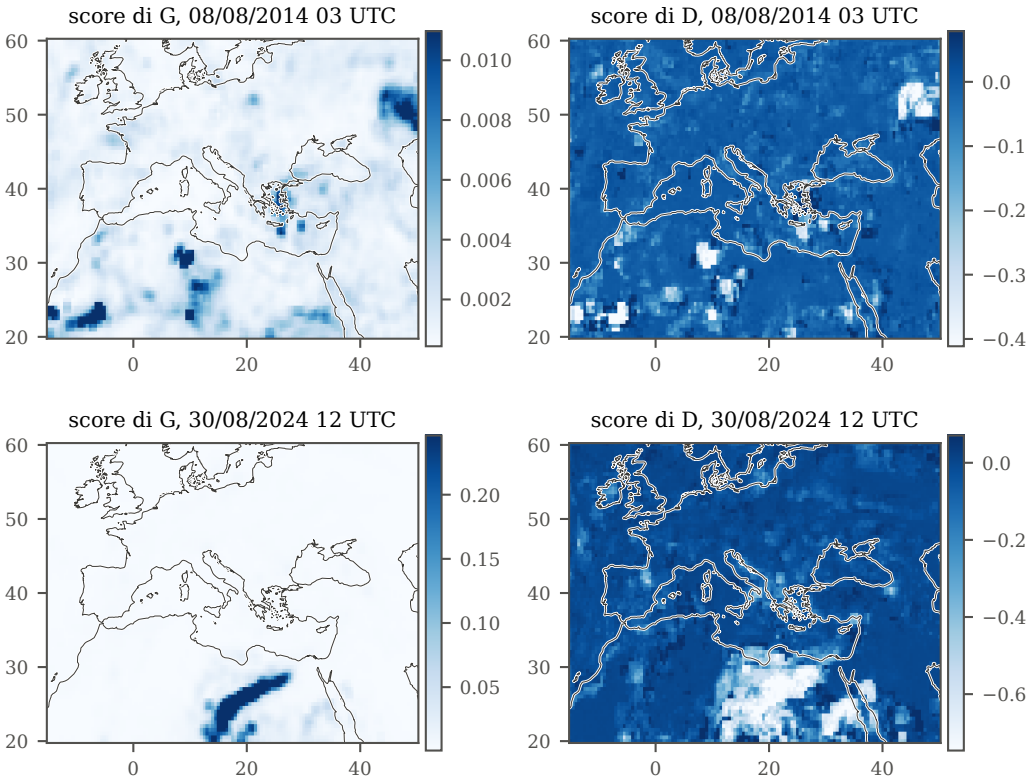


Figura 6.2: Score di G e di D in due istanti degli anni di test: in alto un istante con la correlazione spaziale di Spearman uguale alla mediana del test, in basso l'istante con la media di G più alta. Ogni mappa ha una propria scala, dal primo al 99-esimo percentile dei suoi valori. In basso, le celle del Nord Africa in cui G è più alto sono fra quelle in cui D è più basso. Linee di costa da Natural Earth.

6.3 Correlazione temporale degli score

La correlazione spaziale dice se i due score segnalano gli stessi luoghi nello stesso istante; quella temporale dice se, in un luogo, salgono e scendono insieme.

Correlazione in ogni cella. La correlazione temporale è calcolata in ogni cella sugli istanti: vale 1 se nella cella i due score salgono e scendono insieme. Fra G e D la correlazione di Spearman è negativa in tutte le celle, con mediana -0.25, e quella di Pearson ha mediana -0.51 (Figura 6.3). Il legame è quindi lo stesso nello spazio e nel tempo: quando in una cella il generatore sbaglia di più, lo score del discriminatore scende. È più forte nel sud del dominio e più debole su parte dell'Europa centrale.

Cornice vicino al bordo. Nella mappa si vede una cornice a due celle dal bordo, dove il legame è più debole. È un effetto del modello e non del tempo. Vicino al bordo le convoluzioni del generatore completano il campo con zeri, e il suo errore è un po' più alto che all'interno; il discriminatore legge questa fascia attraverso le patch, e il suo giudizio sulle ricostruzioni ha un piccolo minimo proprio a due celle dal bordo. Lontano dal bordo la mediana della correlazione è la stessa di tutto il dominio.

Effetto della normalizzazione climatologica. La normalizzazione climatologica (Sezione 4.5) cambia poco le correlazioni: dopo la normalizzazione quella di Spearman fra i due score vale -0.23, e ciascuno score conserva quasi lo stesso ordine di prima. Cambia invece dove cadono le segnalazioni di G (Figura 6.4). Un valore è segnalato quando supera la soglia del proprio score, il 95-esimo percentile dello stesso score sugli anni di validazione (Sezione 5.2); sul test i due score segnalano circa il 5.6% dei valori, un po' più del 5%, perché negli anni di test l'errore del generatore è in media un po' più alto. Senza normalizzazione G segnala soprattutto a sud e in estate, dove il suo errore è alto per natura: la quota va dall'1.9% fra 50° e 60°N in febbraio al 16.3% fra 20° e 30°N in agosto. Con la normalizzazione resta fra il 3.6% e il 7.6% in ogni fascia e in ogni mese. Con la soglia al 99-esimo percentile la normalizzazione riduce ancora molto le differenze, da un intervallo fra lo 0.2% e il 5.1% a uno fra lo 0.6% e il 2.5%, ma resta un eccesso di segnalazioni a sud: la normalizzazione allinea media e deviazione standard dell'errore di ogni cella, non la frequenza dei suoi valori più estremi. È l'effetto atteso dalla Sezione 4.5: la normalizzazione toglie la differenza di prevedibilità fra luoghi e stagioni.

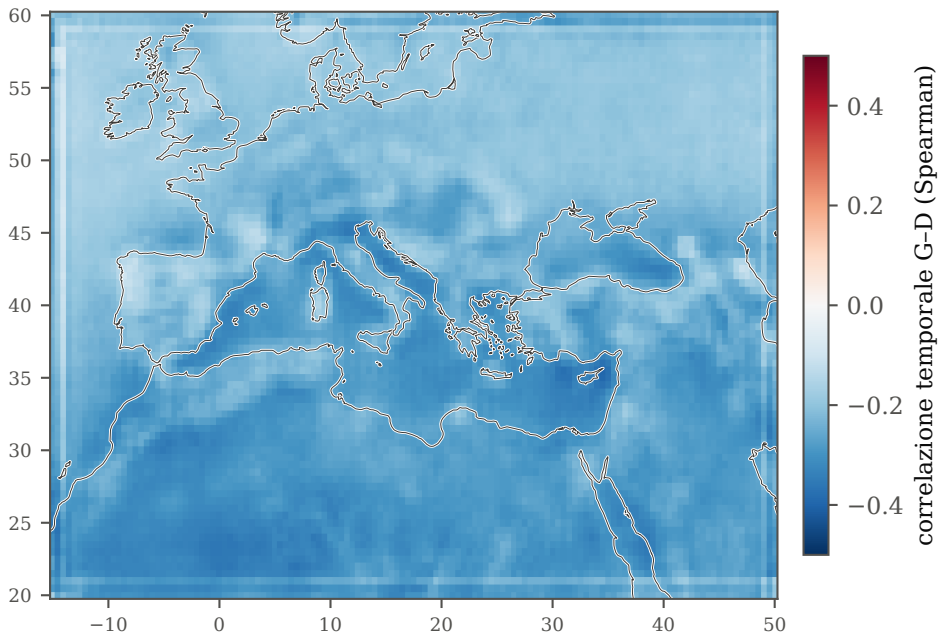


Figura 6.3: Correlazione temporale di Spearman fra G e D in ogni cella, sugli istanti degli anni di test. La correlazione è negativa in tutte le celle; la cornice a due celle dal bordo è un effetto del modello. Linee di costa da Natural Earth.

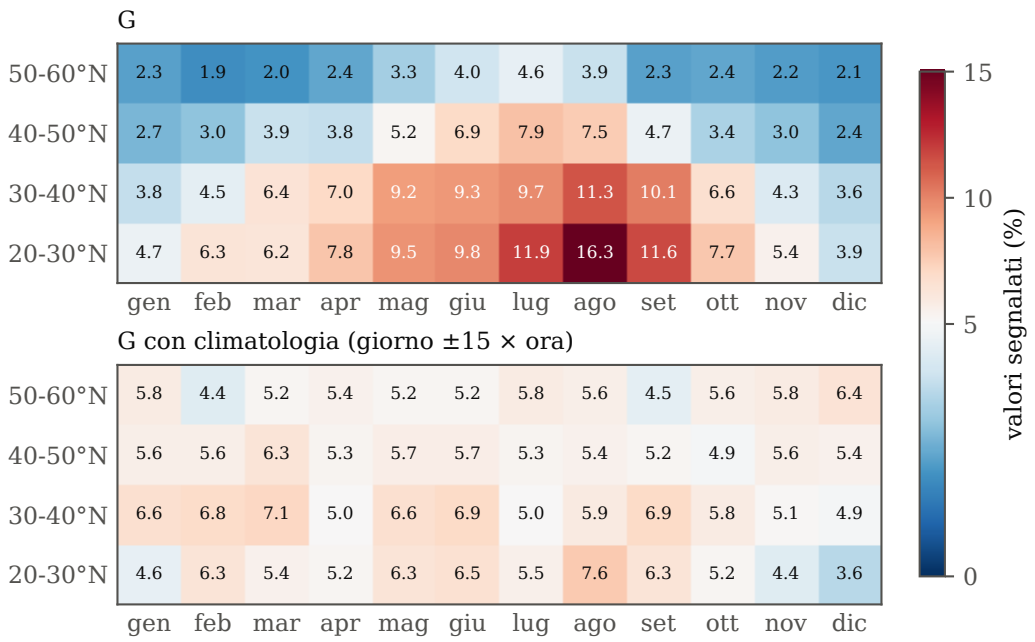


Figura 6.4: Quota dei valori segnalati, per fascia di latitudine e mese, sugli anni di test: G senza e con la normalizzazione climatologica. La soglia di ciascuno score è il suo 95-esimo percentile sugli anni di validazione; il bianco corrisponde al 5%. Senza normalizzazione le segnalazioni si concentrano a sud e in estate, con la normalizzazione sono distribuite in modo quasi uniforme.

6.4 Il comportamento del discriminatore

Le due sezioni precedenti mostrano che D ordina le osservazioni in senso opposto a G. Per capire da dove viene questo comportamento, la componente del discriminatore va scomposta nei suoi due termini: D_{reale}, il giudizio sull'osservazione, e D_{generato}, il giudizio sulla ricostruzione del generatore, con $\bar{s}_D = D_{\text{reale}} - D_{\text{generato}}$. Un valore vicino a 1 indica che il discriminatore giudica il campo generato; entrambi i termini sono medie sui 20 campioni.

I due termini di D. I due termini si comportano in modo diverso rispetto a G (Figura 6.5). D_{generato} cresce con G: la correlazione temporale di Spearman ha mediana 0.26 ed è positiva quasi ovunque. Dove il generatore sbaglia, il discriminatore riconosce quindi la ricostruzione come generata. D_{reale} invece non segue l'ordine di G, con una mediana di Spearman di 0.02, ma i valori più alti di G cadono insieme ai valori più bassi di D_{reale}: la correlazione di Pearson, che dà peso ai valori estremi, ha mediana -0.40. La correlazione negativa fra G e D nasce quindi da entrambi i termini: D sottrae il termine che cresce con G a quello che scende quando G è più alto.

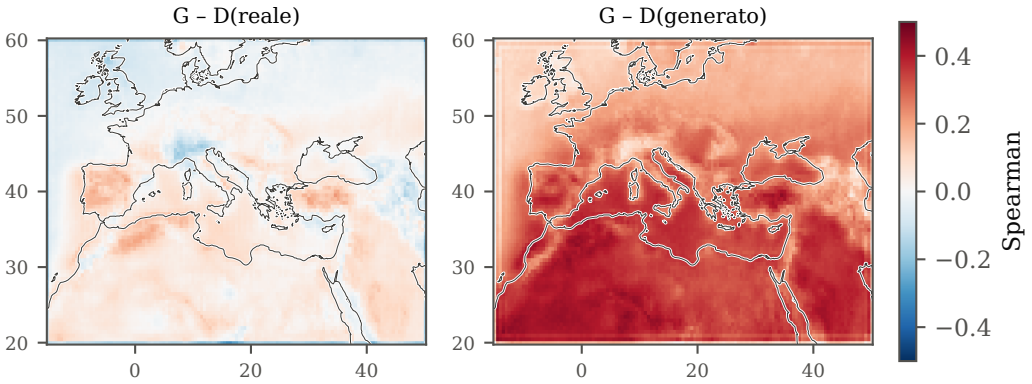


Figura 6.5: Correlazione temporale di Spearman fra G e ciascuno dei due termini di D in ogni cella, sugli anni di test: a sinistra con il giudizio sull'osservazione, D_{reale}, a destra con il giudizio sulla ricostruzione, D_{generato}. D_{generato} cresce con G quasi ovunque, D_{reale} non ne segue l'ordine. Linee di costa da Natural Earth.

Zone attorno agli eventi di G. Le correlazioni riguardano tutti i valori. Per vedere che cosa fa il discriminatore proprio dove G segnala, gli score sono letti attorno agli eventi di G. Gli eventi sono i valori di G con la

normalizzazione climatologica sopra la sua soglia, fissata sulla validazione, raggruppati nell'ipercubo di tempo, latitudine e longitudine: due valori fanno parte dello stesso evento se in un istante le loro celle si toccano, anche in diagonale, o se sono la stessa cella in due istanti consecutivi. Sugli anni di test risultano 754692 eventi, per un totale di 36.7 milioni di valori. In ogni istante le celle sono divise in tre zone: il *nucleo*, le celle di un evento; il *contorno*, le otto celle attorno a una cella del nucleo, che corrispondono alla patch 3×3 letta dal discriminatore, escluse quelle del nucleo; e la zona *lontana*, le celle a più di tre celle da ogni nucleo. Le celle intermedie non sono considerate. Nucleo e contorno sono definiti dalle sole segnalazioni di G: indicano dove G segnala, non dove il tempo è davvero insolito, che senza un riferimento esterno non si può stabilire. Per ogni score si riporta il percentile mediano dei suoi valori in ciascuna zona, rispetto a tutti i valori dello stesso score sul test: in una zona senza legame con l'evento sarebbe vicino a 50.

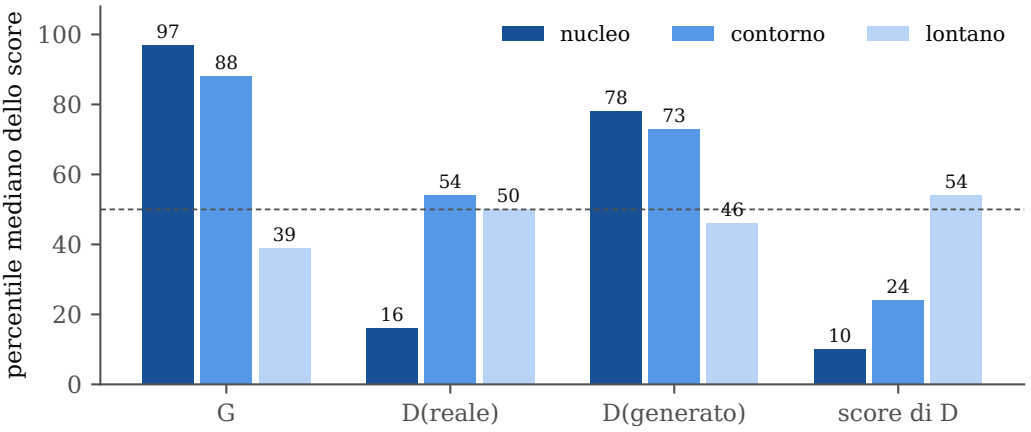


Figura 6.6: Percentile mediano di G senza normalizzazione, dei due termini di D e della componente D nel nucleo degli eventi di G con la normalizzazione climatologica, nel loro contorno e lontano da essi, sugli anni di test. Il percentile è calcolato rispetto a tutti i valori dello stesso score; la linea tratteggiata indica 50, il valore atteso senza legame con gli eventi. Nel nucleo D_{reale} è basso e D_{generato} alto, e la componente D scende al percentile 10.

Il discriminatore nelle tre zone. La Figura 6.6 riporta il risultato. G senza normalizzazione ha un percentile mediano di 97 nel nucleo, di 88 nel contorno e di 39 lontano dagli eventi. Questi valori servono da riferimento e non sono un risultato: nel nucleo G è alto per costruzione, e nel contorno lo è in parte perché lo score di una cella è l'errore medio sulla sua patch 3×3, che contiene celle del nucleo. In parte vale lo stesso per D_{generato}, che legge

la stessa patch: è alto nel nucleo e nel contorno, con mediane di 78 e 73. D_{reale} fa il contrario, e questo non è un effetto della definizione delle zone: nel nucleo ha una mediana di 16, cioè il discriminatore giudica le osservazioni segnalate da G più reali del consueto; nel contorno e lontano torna intorno a 50. Nella componente D i due effetti si sommano e la mediana nel nucleo scende a 10: lo score del discriminatore pone i valori segnalati da G fra i più normali del test. Con la soglia al 99-esimo percentile il comportamento è lo stesso e più marcato: nel nucleo D_{reale} e la componente D scendono entrambi al percentile 2.

Il giudizio sull'osservazione nel nucleo. Il comportamento di D_{reale} nel nucleo non è uniforme: una minoranza dei valori segnalati da G è giudicata generata, ma la maggior parte è giudicata più reale del consueto. Il giudizio dipende dalla dimensione e dal tipo dell'evento, dove il tipo è la variabile d'ingresso più lontana dal proprio normale stagionale nel nucleo. È più basso negli eventi più grandi e in quelli di copertura nuvolosa, velocità verticale, radiazione solare e altezza dello strato limite; è più vicino al consueto negli eventi di pressione al livello del mare, umidità del suolo e velocità di attrito.

Un istante. La Figura 6.7 mostra i termini nell'istante con la media di G più alta del test. Sulla fascia del Nord Africa in cui G è alto, e su un'area più ampia attorno, D_{reale} è vicino a zero e D_{generato} è al massimo: il discriminatore giudica reale l'osservazione e generata la ricostruzione, e la loro differenza porta D ai valori più bassi del dominio.

Levigatezza delle ricostruzioni. Una possibile spiegazione è che il discriminatore riconosca le ricostruzioni dal loro aspetto più liscio. In letteratura i modelli addestrati con un errore quadratico, come in parte il generatore della tesi, producono campi troppo regolari e smussano gli estremi [19, 20, 25]. L'ipotesi è verificata su 240 istanti del test, distribuiti su tutte le ore, con il modello senza dropout. La rugosità di un campo è la differenza quadratica media fra celle adiacenti. Le ricostruzioni sono meno rugose delle osservazioni in tutti gli istanti, con un rapporto mediano di 0.86. Lisciando l'osservazione con la media sulle celle della sua patch 3×3, il discriminatore la giudica più generata nell'89% delle celle, e nelle celle con il 5% più alto di G nel 94%, con un aumento medio sette volte maggiore. L'osservazione lisciata gli appare in media generata quanto una ricostruzione. Il discriminatore risponde quindi alla levigatezza del campo, e le celle in cui G è alto tendono a essere quelle in cui il campo è più rugoso: la correlazione di Spearman fra la rugosità locale e G ha mediana 0.50. La rugosità locale da sola non ordina però il giudizio

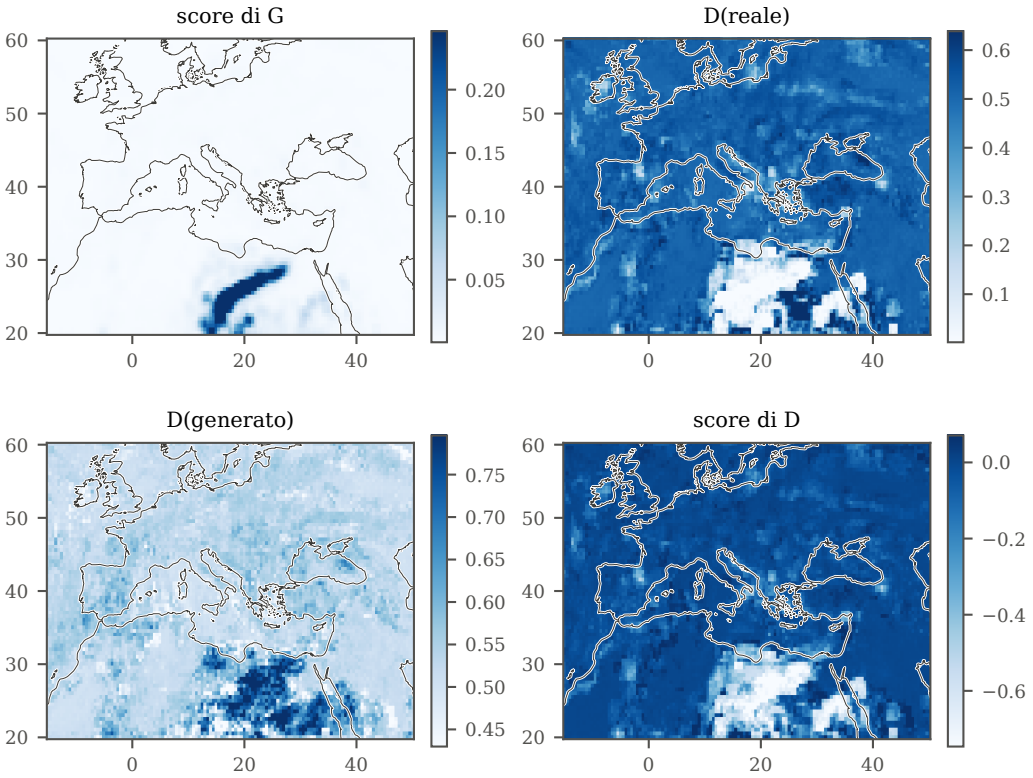


Figura 6.7: Score di G, giudizio del discriminatore sull'osservazione (D_{reale}) e sulla ricostruzione (D_{generato}) e componente D, il 30 agosto 2024 alle 12 UTC, l'istante con la media di G più alta degli anni di test. Ogni mappa ha una propria scala, dal primo al 99-esimo percentile dei suoi valori. Dove G è alto, D_{reale} è vicino a zero e D_{generato} è al massimo. Linee di costa da Natural Earth.

sulle osservazioni, con una correlazione mediana di 0.03: la levigatezza è un indizio che il discriminatore usa, non l'unico. Il lisciamento, inoltre, riduce anche i valori più estremi del campo, e la verifica non separa i due effetti.

Sintesi. Il discriminatore distingue bene le ricostruzioni dalle osservazioni proprio dove il generatore sbaglia, ma non ordina come insoliti i valori che G segnala: nel nucleo degli eventi di G li giudica più reali del consueto. La componente dell'articolo, che sottrae il giudizio sulla ricostruzione a quello sull'osservazione, va quindi nella direzione opposta a G proprio dove G segnala. Una parte del motivo è la levigatezza: le ricostruzioni sono più lisce, il discriminatore lo riconosce, e un campo osservato rugoso, come quelli in cui G segnala, gli appare reale. Anche in letteratura il termine del discriminatore, preso da solo, rileva meno di quello di ricostruzione: in AnoGAN l'area sotto la curva ROC è 0.74 contro 0.88 (Sezione 2.1.1), su immagini e con un discriminatore usato in modo diverso. Per questi motivi le sezioni seguenti usano lo score di ricostruzione, cioè G con la normalizzazione climatologica: sommare a G lo score del discriminatore, come nell'articolo, aggiungerebbe un termine che dove G segnala va nella direzione opposta.

6.5 Confronto con metodi semplici e modelli poco profondi

Sezione da scrivere con la run finale.

6.6 Eventi per tipo e dimensione

Sezione da scrivere con la run finale.

6.7 Casi specifici

Sezione da scrivere con la run finale.

6.8 Limiti dei risultati

Sezione da scrivere alla fine.

Capitolo 7

Conclusioni e sviluppi futuri

7.1 Il problema affrontato

7.2 Sintesi dei risultati

7.3 Limiti dello studio

Assenza di una verità di riferimento. I campi ERA5 non contengono etichette di anomalia, e l'accuratezza del rilevamento non è quindi misurata. I risultati descrivono come si comportano le componenti dello score e quanto le segnalazioni del detector coincidono con quelle di rilevatori più semplici; non dicono quante condizioni insolite il detector trovi né quante delle sue segnalazioni lo siano davvero.

Una sola esecuzione per configurazione. Ogni configurazione è stata addestrata una sola volta, con un solo seme. Non è noto quanto concorderebbero due esecuzioni identiche con semi diversi, e le differenze fra configurazioni non possono essere attribuite con certezza alla sola scelta confrontata.

Score e dispersione. La dispersione dello score dipende dal dropout delle due reti e non è calibrata come misura di incertezza.

Validazione breve e clima che cambia. Soglie e normalizzazione climatologica sono stimate su cinque anni di validazione e applicate a un periodo di test di ventuno anni. Con la deriva del clima, la quota di osservazioni segnalate negli anni più lontani può scostarsi da quella prevista. La ricostruzione degli eventi, inoltre, unifica a posteriori le identità che si fondono, e non descrive un utilizzo in tempo reale.

7.4 Sviluppi futuri

Il primo sviluppo è ripetere la configurazione scelta con più semi, per avere un riferimento con cui leggere le differenze fra configurazioni.

Il secondo riguarda il protocollo: aggiornare periodicamente soglie e normalizzazione climatologica su una finestra di anni recenti, invece di tenerle fisse dalla validazione, ridurrebbe l'effetto della deriva del clima sulla quota di osservazioni segnalate.

Il terzo riguarda la valutazione. Casi studio su eventi documentati, scelti con fonti meteorologiche indipendenti, mostrerebbero che cosa il detector segnala in situazioni note; un catalogo esterno di eventi su tutto il dominio, o anomalie inserite in posizioni note, darebbe una misura del richiamo, che in questa tesi manca.

Il quarto riguarda l'incertezza dello score. La dispersione potrebbe essere confrontata con l'errore effettivo del generatore, per verificare se può essere usata come misura di incertezza. I metodi basati su equazioni differenziali stocastiche, impiegati nel lavoro preliminare sul previsore (Appendice A.2), potrebbero inoltre essere applicati al detector: richiedono di aggiungere a STGAN una rete di diffusione, una modifica che questa tesi ha evitato per restare vicina all'architettura dell'articolo.

Ritorno alla previsione fotovoltaica. Il lavoro è partito dalla previsione della produzione fotovoltaica sui dati PVGIS, ed è passato ai campi ERA5 perché quei dati non permettevano di riconoscere condizioni meteorologiche insolite di tipo generale. Il detector può ora essere riportato a quel problema in più modi. Il primo passo è allineare i due insiemi di dati: le località PVGIS, su un reticolo di 5 km, ricadono in poche decine di celle ERA5 di $0.5°$, e lo score, calcolato ogni tre ore, va riportato alle ore del previsore. Con questo allineamento le segnalazioni del detector possono servire a valutare il previsore separatamente nelle condizioni normali e in quelle insolite, misurando se l'errore cresce e se gli intervalli restano affidabili quando il detector segnala un'anomalia, come nel lavoro preliminare era stato fatto con le soglie climatologiche. Possono servire poi all'addestramento, per escludere dal training le finestre segnalate, secondo il protocollo di SDE U-Net, oppure per dare loro un peso diverso. Lo score può infine entrare nel previsore come ingresso aggiuntivo, oppure regolare l'ampiezza degli intervalli, allargandoli quando le condizioni sono insolite. In ciascun caso la verifica più diretta sarebbe sulle misure di impianti reali disponibili per il 2019, l'anno di test del lavoro preliminare.

Appendice A

Lavoro preliminare sui dati PVGIS

Il lavoro è partito, nell'ambito della previsione della produzione fotovoltaica, dalle serie orarie PVGIS descritte nella Sezione 3.5. Su questi dati sono stati esplorati un previsore probabilistico della produzione, con diversi metodi per associare un intervallo alla previsione, un primo criterio per individuare condizioni insolite basato su soglie climatologiche e due detector appresi, MTGFlow e STGAN. Questa appendice ne descrive i metodi; il corpo della tesi riguarda soltanto il detector applicato ai campi ERA5.

A.1 Previsore probabilistico della produzione

Il previsore stima la produzione dell'ora successiva in ogni località. Combina un encoder temporale, una LSTM bidirezionale con pooling ad attenzione, con uno strato di attenzione su grafo [47] fra località vicine, su un grafo geografico con pesi decrescenti con la distanza. Per associare un intervallo alla previsione sono stati provati il dropout Monte Carlo [33] e il Deep Ensemble [34], descritti nella Sezione 2.4, e due varianti costruite sugli schemi di SDE-Net [35] e di SDE U-Net [36], descritti di seguito; la variante basata su SDE-Net è stata provata anche con previsione diretta su più orizzonti.

A.2 Equazioni differenziali stocastiche neurali

Dropout Monte Carlo e Deep Ensemble ottengono la dispersione ripetendo il passaggio in avanti con pesi diversi. Una linea successiva la ottiene rendendo stocastica la dinamica interna della rete. Una rete residua aggiorna lo stato sommando a esso una trasformazione dello stato stesso, $x_{t+1} = x_t + f(x_t, t)$.

Interpretando l'aggiornamento come un passo di integrazione, la trasformazione complessiva può essere descritta da un'equazione differenziale ordinaria, $\mathrm{d}x/\mathrm{d}t = f(x,t)$, in cui f è una rete neurale e l'uscita è calcolata da un risolutore numerico [48]. Un modello di questo tipo è deterministico. Aggiungendo un termine di moto browniano si ottiene un'equazione differenziale stocastica,

$$\mathrm{d}x_t = f(x_t,t)\,\mathrm{d}t + g(x_t,t)\,\mathrm{d}W_t, \tag{A.1}$$

in cui f è il drift e g la diffusione, che regola l'ampiezza della componente casuale [35].

In pratica l'equazione è integrata a passi discreti con lo schema di Euler–Maruyama. Dividendo l'intervallo $[0,T]$ in N passi di ampiezza $\Delta t = T/N$, l'aggiornamento è

$$x_{k+1} = x_k + f(x_k,t_k)\,\Delta t + g(x_k,t_k)\sqrt{\Delta t}\,Z_k, \qquad Z_k \sim \mathcal{N}(0,1): \tag{A.2}$$

a ogni passo lo stato avanza del drift moltiplicato per l'ampiezza del passo e di un termine gaussiano scalato dalla diffusione e dalla radice dell'ampiezza del passo. Ripetendo l'integrazione con estrazioni diverse di Z_k si ottengono traiettorie diverse dallo stesso ingresso, tanto più disperse quanto maggiore è la diffusione. Il tempo di integrazione è una variabile interna del modello e non coincide con l'orizzonte fisico della previsione.

SDE-Net. Kong et al. [35] interpretano le trasformazioni di una rete profonda come l'evoluzione dello stato di un sistema dinamico stocastico. Il modello comprende una rete di drift, che adatta la funzione predittiva, e una rete di diffusione, che scala un termine browniano e rappresenta l'incertezza epistemica. La diffusione è addestrata ad assumere valori bassi sui dati di training e alti su dati fuori distribuzione, ottenuti aggiungendo rumore gaussiano agli ingressi. L'equazione è integrata con lo schema dell'equazione (A.2) a passo fisso, con parametri condivisi fra i passi e diffusione calcolata sul solo stato iniziale, cioè con $g(x_0;\theta_g)$ al posto di $g(x_k,t_k)$. L'uscita della rete di diffusione è una sigmoide moltiplicata per un valore massimo, fissato come iperparametro. Dopo l'addestramento si campionano più traiettorie per lo stesso ingresso: l'incertezza aleatoria è la varianza predittiva media sulle traiettorie, quella epistemica la varianza dello stato finale fra le traiettorie. Il metodo separa così le due incertezze con un unico modello, senza distribuzioni a priori sui pesi e senza addestrare un insieme di reti. La valutazione riguarda il riconoscimento di dati fuori distribuzione, di errori di classificazione e di esempi avversari e l'active learning, su immagini e su un problema di regressione tabellare. Il lavoro non considera serie temporali né dati con struttura spaziale: gli esempi

sono indipendenti, e il fuori distribuzione è definito da un dataset diverso o da ingressi perturbati, non da condizioni rare ma ricorrenti nello stesso dominio.

Nel previsore della produzione lo schema drift–diffusione di SDE-Net è stato applicato con l'addestramento alternato delle due reti e la forma gaussiana dell'obiettivo di regressione. Il blocco stocastico è stato collocato sullo stato latente di un insieme di località collegate da un grafo.

SDE U-Net. Monaco et al. [36] adattano SDE-Net a un'architettura U-Net per il post-processing di previsioni numeriche di precipitazione, con mappe di precipitazione cumulata giornaliera sull'Italia nord-occidentale. Poiché i blocchi dell'encoder hanno dimensioni diverse, il numero di passi di integrazione è allineato al numero di blocchi: a ciascun blocco è associato un blocco di diffusione, funzione dell'ingresso iniziale, il cui segnale è sommato alla rispettiva skip connection. La loss di regressione è una MSE e la diffusione è addestrata, come in SDE-Net, a distinguere ingressi originali e ingressi perturbati con rumore gaussiano. Il disegno sperimentale usa per addestramento e validazione soltanto eventi non intensi e valuta il modello sia su eventi non intensi sia su eventi intensi, confrontando più architetture probabilistiche in termini di equilibrio fra ampiezza e affidabilità degli intervalli. Il lavoro opera su campi regolari elaborati da un encoder–decoder convoluzionale e su mappe giornaliere: non tratta insiemi irregolari di località, serie temporali per sito o più orizzonti di previsione.

Nel previsore della produzione ne sono stati ripresi l'allineamento fra passi stocastici e stadi dell'encoder, trasferito agli stadi del previsore, e il protocollo che esclude dal training gli eventi intensi e li mantiene nel test.

A.3 Soglie climatologiche

Come primo criterio per individuare condizioni insolite, un'osservazione è segnalata quando esce dalla banda fra i quantili 0.025 e 0.975 della distribuzione della stessa località e della stessa ora negli anni precedenti, entro quindici giorni di calendario. Le soglie segnalano i valori estremi di ciascuna variabile presa da sola; sono servite a esaminare il previsore nelle condizioni insolite e ad addestrarlo sulle sole finestre normali, secondo il protocollo di SDE U-Net.

A.4 Detector appresi: MTGFlow e STGAN

Per individuare anomalie diverse dai valori estremi di una variabile sono stati applicati due detector appresi. Di MTGFlow [11] è stata implementata

la versione base, senza l'estensione a gruppi, applicata alle tre variabili meteorologiche di ogni località, trattate come entità, con la soglia interquartile dell'articolo. Poiché il metodo non rappresenta il contesto geografico, è addestrato un modello indipendente per località: gli score possono essere confrontati sulla mappa, ma il modello non apprende relazioni fra località. Per introdurre una componente spaziale il lavoro è passato a STGAN [3].

STGAN è stato applicato alle stesse serie, con irradianza globale, temperatura a due metri e velocità del vento a dieci metri, addestramento sugli anni 2005–2018 e test sul 2019. Accanto alla versione su grafo dell'articolo è stata provata una variante a griglia, perché anche le località PVGIS sono disposte su un reticolo regolare e le posizioni dei vicini sono quindi definite: la convoluzione su grafo è sostituita da una ConvGRU sulla patch 3×3 di ogni località. Nella variante a griglia con kernel di lato 3 il 75.5% dell'errore di ricostruzione delle osservazioni segnalate è dovuto all'irradianza, il 15.8% alla temperatura e l'8.6% al vento. I dati PVGIS contengono soltanto le grandezze da cui dipende la produzione fotovoltaica, e un'osservazione segnalata non può essere ricondotta a una condizione meteorologica più generale. Per individuare condizioni insolite di tipo più generale il lavoro è passato ai campi ERA5 del Capitolo 3.

Bibliografia

[1] J. Antonanzas et al. «Review of photovoltaic power forecasting». In: *Solar Energy* 136 (2016), pp. 78–111. DOI: 10.1016/j.solener.2016.06.069.

[2] Hans Hersbach et al. «The ERA5 global reanalysis». In: *Quarterly Journal of the Royal Meteorological Society* 146.730 (2020), pp. 1999–2049. DOI: 10.1002/qj.3803.

[3] Leyan Deng et al. «Graph Convolutional Adversarial Networks for Spatiotemporal Anomaly Detection». In: *IEEE Transactions on Neural Networks and Learning Systems* 33.6 (2022), pp. 2416–2428. DOI: 10.1109/TNNLS.2021.3136171.

[4] Manish Gupta et al. «Outlier Detection for Temporal Data: A Survey». In: *IEEE Transactions on Knowledge and Data Engineering* 26.9 (2014), pp. 2250–2267. DOI: 10.1109/TKDE.2013.184.

[5] Zahra Zamanzadeh Darban et al. «Deep Learning for Time Series Anomaly Detection: A Survey». In: *ACM Computing Surveys* 57.1 (2024), pp. 1–42. DOI: 10.1145/3691338.

[6] Pankaj Malhotra et al. *LSTM-based Encoder-Decoder for Multi-sensor Anomaly Detection*. Presentato all'ICML 2016 Anomaly Detection Workshop. 2016. arXiv: 1607.00148.

[7] Kyle Hundman et al. «Detecting Spacecraft Anomalies Using LSTMs and Nonparametric Dynamic Thresholding». In: *Proceedings of the 24th ACM SIGKDD International Conference on Knowledge Discovery & Data Mining*. ACM, 2018, pp. 387–395. DOI: 10.1145/3219819.3219845.

[8] Jiehui Xu et al. «Anomaly Transformer: Time Series Anomaly Detection with Association Discrepancy». In: *International Conference on Learning Representations (ICLR)*. 2022. arXiv: 2110.02642.

[9] Xingjian Wu et al. «CATCH: Channel-Aware Multivariate Time Series Anomaly Detection via Frequency Patching». In: *International Conference on Learning Representations (ICLR)*. 2025. arXiv: 2410.12261.

[10] Sarah Alnegheimish et al. «M^{2}AD: Multi-Sensor Multi-System Anomaly Detection through Global Scoring and Calibrated Thresholding». In: *Proceedings of the 28th International Conference on Artificial Intelligence and Statistics*. Vol. 258. Proceedings of Machine Learning Research. PMLR, 2025, pp. 4384–4392.

[11] Qihang Zhou et al. «Label-Free Multivariate Time Series Anomaly Detection». In: *IEEE Transactions on Knowledge and Data Engineering* 36.7 (2024), pp. 3166–3179. DOI: 10.1109/TKDE.2024.3349613. arXiv: 2312.11549.

[12] Ian J. Goodfellow et al. «Generative Adversarial Nets». In: *Advances in Neural Information Processing Systems*. Vol. 27. Curran Associates, Inc., 2014. arXiv: 1406.2661.

[13] Thomas Schlegl et al. «Unsupervised Anomaly Detection with Generative Adversarial Networks to Guide Marker Discovery». In: *Information Processing in Medical Imaging (IPMI 2017)*. Vol. 10265. Lecture Notes in Computer Science. Springer, 2017, pp. 146–157. DOI: 10.1007/978-3-319-59050-9_12.

[14] Dan Li et al. «MAD-GAN: Multivariate Anomaly Detection for Time Series Data with Generative Adversarial Networks». In: *Artificial Neural Networks and Machine Learning – ICANN 2019: Text and Time Series*. Vol. 11730. Lecture Notes in Computer Science. Springer, 2019, pp. 703–716. DOI: 10.1007/978-3-030-30490-4_56.

[15] Ailin Deng e Bryan Hooi. «Graph Neural Network-Based Anomaly Detection in Multivariate Time Series». In: *Proceedings of the AAAI Conference on Artificial Intelligence*. Vol. 35. 5. 2021, pp. 4027–4035. DOI: 10.1609/aaai.v35i5.16523.

[16] Renjie Wu e Eamonn J. Keogh. «Current Time Series Anomaly Detection Benchmarks are Flawed and are Creating the Illusion of Progress». In: *IEEE Transactions on Knowledge and Data Engineering* (2021). DOI: 10.1109/TKDE.2021.3112126. arXiv: 2009.13807.

[17] Qinghua Liu e John Paparrizos. «The Elephant in the Room: Towards A Reliable Time-Series Anomaly Detection Benchmark». In: *Advances in Neural Information Processing Systems 37 (NeurIPS 2024), Datasets*

and Benchmarks Track. Vol. 37. 2024, pp. 108231–108261. DOI: 10.52202/079017-3437.

[18] Peter Bauer, Alan Thorpe e Gilbert Brunet. «The quiet revolution of numerical weather prediction». In: *Nature* 525.7567 (2015), pp. 47–55. DOI: 10.1038/nature14956.

[19] Stephan Rasp et al. «WeatherBench: A Benchmark Data Set for Data-Driven Weather Forecasting». In: *Journal of Advances in Modeling Earth Systems* 12.11 (2020), e2020MS002203. DOI: 10.1029/2020MS002203.

[20] Remi Lam et al. «Learning skillful medium-range global weather forecasting». In: *Science* 382.6677 (2023), pp. 1416–1421. DOI: 10.1126/science.adi2336.

[21] Yunjie Liu et al. *Application of Deep Convolutional Neural Networks for Detecting Extreme Weather in Climate Datasets*. 2016. arXiv: 1605.01156.

[22] Evan Racah et al. «ExtremeWeather: A large-scale climate dataset for semi-supervised detection, localization, and understanding of extreme weather events». In: *Advances in Neural Information Processing Systems*. Vol. 30. Curran Associates, Inc., 2017.

[23] Prabhat et al. «ClimateNet: an expert-labeled open dataset and deep learning architecture for enabling high-precision analyses of extreme weather». In: *Geoscientific Model Development* 14 (2021), pp. 107–124. DOI: 10.5194/gmd-14-107-2021.

[24] Pablo G. Zaninelli et al. «AI-Based Anomaly Detection for Extreme Event Attribution: An Analysis of European Heatwaves». In: *Earth Systems and Environment* 10.8 (2026), pp. 9949–9969. DOI: 10.1007/s41748-026-01122-6.

[25] Aytaç Paçal et al. «A multivariate analysis of atmospheric drivers for Western European heatwaves». In: *Earth System Dynamics* 17 (2026), pp. 955–986. DOI: 10.5194/esd-17-955-2026.

[26] Bing Yu, Haoteng Yin e Zhanxing Zhu. «Spatio-Temporal Graph Convolutional Networks: A Deep Learning Framework for Traffic Forecasting». In: *Proceedings of the Twenty-Seventh International Joint Conference on Artificial Intelligence (IJCAI-18)*. 2018, pp. 3634–3640. DOI: 10.24963/ijcai.2018/505.

[27] Shashi Shekhar, Chang-Tien Lu e Pusheng Zhang. «Detecting Graph-Based Spatial Outliers: Algorithms and Applications (A Summary of Results)». In: *Proceedings of the Seventh ACM SIGKDD International Conference on Knowledge Discovery and Data Mining (KDD '01)*. San Francisco, CA, USA: ACM, 2001, pp. 371–376.

[28] Dechang Chen et al. «On Detecting Spatial Outliers». In: *GeoInformatica* 12 (2008), pp. 455–475. DOI: 10.1007/s10707-007-0038-8.

[29] Kyunghyun Cho et al. «Learning Phrase Representations using RNN Encoder–Decoder for Statistical Machine Translation». In: *Proceedings of the 2014 Conference on Empirical Methods in Natural Language Processing (EMNLP)*. Association for Computational Linguistics, 2014, pp. 1724–1734. DOI: 10.3115/v1/D14-1179. arXiv: 1406.1078.

[30] Xingjian Shi et al. «Convolutional LSTM Network: A Machine Learning Approach for Precipitation Nowcasting». In: *Advances in Neural Information Processing Systems*. Vol. 28. Curran Associates, Inc., 2015. arXiv: 1506.04214.

[31] Nicolas Ballas et al. «Delving Deeper into Convolutional Networks for Learning Video Representations». In: *International Conference on Learning Representations (ICLR)*. 2016. arXiv: 1511.06432.

[32] Moloud Abdar et al. «A review of uncertainty quantification in deep learning: Techniques, applications and challenges». In: *Information Fusion* 76 (2021), pp. 243–297. DOI: 10.1016/j.inffus.2021.05.008.

[33] Yarin Gal e Zoubin Ghahramani. «Dropout as a Bayesian Approximation: Representing Model Uncertainty in Deep Learning». In: *Proceedings of the 33rd International Conference on Machine Learning*. Vol. 48. Proceedings of Machine Learning Research. PMLR, 2016, pp. 1050–1059. arXiv: 1506.02142.

[34] Balaji Lakshminarayanan, Alexander Pritzel e Charles Blundell. «Simple and Scalable Predictive Uncertainty Estimation using Deep Ensembles». In: *Advances in Neural Information Processing Systems*. Vol. 30. Curran Associates, Inc., 2017. arXiv: 1612.01474.

[35] Lingkai Kong, Jimeng Sun e Chao Zhang. «SDE-Net: Equipping Deep Neural Networks with Uncertainty Estimates». In: *Proceedings of the 37th International Conference on Machine Learning*. Vol. 119. Proceedings of Machine Learning Research. PMLR, 2020, pp. 5405–5415. arXiv: 2008.10546.

[36] Simone Monaco et al. «Uncertainty-aware methods for enhancing rainfall prediction with deep-learning based post-processing segmentation». In: *Computers & Geosciences* 205 (2025), p. 105992. DOI: 10.1016/j.cageo.2025.105992.

[37] Russ Rew e Glenn Davis. «NetCDF: An Interface for Scientific Data Access». In: *IEEE Computer Graphics and Applications* 10.4 (1990), pp. 76–82. DOI: 10.1109/38.56302.

[38] Charles R. Harris et al. «Array Programming with NumPy». In: *Nature* 585.7825 (2020), pp. 357–362. DOI: 10.1038/s41586-020-2649-2.

[39] Thomas Huld, Richard Müller e Attilio Gambardella. «A new solar radiation database for estimating PV performance in Europe and Africa». In: *Solar Energy* 86.6 (2012), pp. 1803–1815. DOI: 10.1016/j.solener.2012.03.006.

[40] Sepp Hochreiter e Jürgen Schmidhuber. «Long Short-Term Memory». In: *Neural Computation* 9.8 (1997), pp. 1735–1780. DOI: 10.1162/neco.1997.9.8.1735.

[41] Diederik P. Kingma e Jimmy Ba. «Adam: A Method for Stochastic Optimization». In: *International Conference on Learning Representations (ICLR)*. 2015. arXiv: 1412.6980.

[42] Arthur Gretton et al. «A Kernel Two-Sample Test». In: *Journal of Machine Learning Research* 13.25 (2012), pp. 723–773.

[43] Adam Paszke et al. «PyTorch: An Imperative Style, High-Performance Deep Learning Library». In: *Advances in Neural Information Processing Systems*. Vol. 32. Curran Associates, Inc., 2019.

[44] Stephan Hoyer e Joe Hamman. «xarray: N-D labeled Arrays and Datasets in Python». In: *Journal of Open Research Software* 5.1 (2017), p. 10. DOI: 10.5334/jors.148.

[45] Wes McKinney. «Data Structures for Statistical Computing in Python». In: *Proceedings of the 9th Python in Science Conference*. 2010, pp. 56–61. DOI: 10.25080/Majora-92bf1922-00a.

[46] Pauli Virtanen et al. «SciPy 1.0: Fundamental Algorithms for Scientific Computing in Python». In: *Nature Methods* 17.3 (2020), pp. 261–272. DOI: 10.1038/s41592-019-0686-2.

[47] Petar Veličković et al. «Graph Attention Networks». In: *International Conference on Learning Representations (ICLR)*. 2018. arXiv: 1710.10903.

[48] Ricky T. Q. Chen et al. «Neural Ordinary Differential Equations». In: *Advances in Neural Information Processing Systems*. Vol. 31. Curran Associates, Inc., 2018. arXiv: 1806.07366.