

Politecnico di Torino

Politecnico di Torino

Laurea Magistrale in Ingegneria Informatica – Ingegneria del software

A.A. 2025/2026

Sessione di laurea [mese e anno]

Rilevamento unsupervised di anomalie meteorologiche con reti generative avversarie spazio-temporali

Relatore:
Simone Monaco

Candidato:
Alberto Pedalino

Indice

Elenco delle figure **iv**

1 Introduzione **1**
1.1 Contesto e motivazioni 1
1.2 Il problema: anomalie meteorologiche senza etichette 1
1.3 Approccio proposto 2
1.4 Obiettivi e contributi della tesi 3
1.5 Organizzazione del documento 3

2 Fondamenti teorici e stato dell'arte **4**
2.1 Rilevamento di anomalie in serie multivariate e spazio-temporali 4
2.1.1 Dalla deviazione dal valore atteso ai modelli profondi . 5
2.1.2 Grafi appresi e dati di addestramento contaminati: GDN e MTGFlow 6
2.1.3 Alternative considerate: CATCH e M2AD 7
2.1.4 Reti generative avversarie per il rilevamento di anomalie 8
2.1.5 STGAN 9
2.1.6 Il problema della valutazione 11
2.2 Apprendimento automatico e dati meteorologici 13
2.2.1 Dalla previsione numerica ai modelli basati sui dati . . 13
2.2.2 Eventi estremi e anomalie nei campi meteorologici . . . 14
2.3 Contesto spaziale su griglie e grafi 15
2.4 Quantificazione dell'incertezza 16
2.5 Da STGAN al detector della tesi 18
2.6 Posizionamento del lavoro 19

3 Dati e preprocessing **21**
3.1 Campi ERA5 e dominio 21
3.2 Acquisizione e preparazione dei dati 24
3.3 Anni di addestramento, di validazione e di test 25
3.4 Caratteristiche dei campi 26

3.5 Qualità e limiti dei dati 29
3.6 I dati PVGIS del lavoro preliminare 30

4 Metodologia **33**
4.1 Formulazione del problema 33
4.2 Architettura e addestramento avversario 34
4.2.1 Generatore ConvGRU sul campo intero e celle assenti . 34
4.2.2 Discriminatore locale 36
4.2.3 Obiettivi di addestramento 37
4.3 Ingresso: finestra recente, codifica temporale e normalizzazione stagionale 38
4.3.1 Finestra recente e trend 38
4.3.2 Codifica temporale ciclica 38
4.3.3 Normalizzazione stagionale 39
4.4 Pesi delle variabili nell'errore di ricostruzione 40
4.5 Valori insoliti negli anni di validazione 41
4.6 Componenti dello score e dropout Monte Carlo 42
4.6.1 Dropout nel generatore e nel discriminatore 42
4.6.2 Estrazioni Monte Carlo e componenti dello score 42
4.6.3 Score combinato e score di ricostruzione 43
4.7 Normalizzazione climatologica degli score 44
4.8 Validazione senza etichette 45
4.8.1 Distanza fra campi osservati e ricostruiti nello spazio delle componenti principali 45
4.8.2 Diagnostiche per epoca e misure finali 46

5 Esperimenti **48**
5.1 Configurazione e ricerca degli iperparametri 48
5.2 Protocollo di valutazione 49

6 Risultati e discussione **52**
6.1 Ricerca dei parametri 52
6.2 Correlazione spaziale degli score 52
6.3 Correlazione temporale degli score 55
6.4 Normalizzazione climatologica e distribuzione delle segnalazioni 55
6.5 Il comportamento del discriminatore 58
6.6 Confronto con metodi semplici e modelli poco profondi 63
6.7 Eventi per tipo e dimensione 63
6.8 Casi specifici 63
6.9 Sensibilità alla soglia 63

7 Conclusioni e sviluppi futuri **65**
7.1 Il problema affrontato 65
7.2 Sintesi dei risultati 65
7.3 Sviluppi futuri 65

Bibliografia **67**

Elenco delle figure

2.1 Schema di STGAN. Il generatore combina tre moduli e produce la stima $\hat{X}_{v,t} = G_\theta(v, t)$, che sostituisce l'ultimo elemento della sequenza reale; il discriminatore valuta entrambe le sequenze. Lo score somma l'errore di previsione e la differenza fra le due uscite del discriminatore. Ridisegnato a partire da Deng et al. [3]. 10

3.1 Dominio dei campi ERA5: 81×131 celle di 0.5°, fra 20° e 60° di latitudine nord e fra 15° di longitudine ovest e 50° di longitudine est. Il rettangolo indica l'area delle località PVGIS della Sezione 3.6, in Piemonte. Linee di costa da Natural Earth. 23

3.2 Dai file di ERA5 ai dati letti dal modello. I campi sono scaricati mese per mese dal Climate Data Store e conservati solo se superano la verifica; la preparazione li riunisce in array su disco, da cui il modello legge le sole finestre che usa. 24

3.3 Ciclo stagionale e giornaliero della temperatura a due metri e della copertura nuvolosa in tre celle: Europa settentrionale (55°N, 10°E), Pianura Padana (45°N, 9°E) e Sahara (25°N, 10°E). A sinistra la media per mese, con le linee punteggiate a una deviazione standard dei valori triorari del mese; a destra la media per ora UTC in gennaio e in luglio. La temperatura è in gradi Celsius (in kelvin nei dati). Lo stesso mese ha livelli e variabilità diversi da una cella all'altra. Anni 1980–1999. . . 27

3.4 Quota di ciascuna variabile nella variazione quadratica media su 24 ore (equazione (3.1)), dopo il min–max di STGAN e dopo la normalizzazione stagionale e il min–max del detector, in scala logaritmica. Anni 1980–1999; la seconda quota è ricavata dai pesi della Sezione 4.4, che sono proporzionali all'inverso di m_f. La linea tratteggiata indica la quota uguale per tutte le variabili, un quindicesimo. Con il min–max di STGAN la copertura nuvolosa domina; dopo la normalizzazione stagionale le quote sono dello stesso ordine. 28

3.5 Correlazione degli scarti dalla media climatologica di due celle in funzione della loro distanza: mediana e quartili per fasce di 100 km, su 300 celle scelte a caso e un istante ogni nove degli anni 1980–1999 (un passo dispari, che legge tutte le ore del giorno). Il primo punto, entro 100 km, si basa su 36 coppie di celle. Precipitazione e copertura nuvolosa perdono la correlazione entro poche celle. 29
3.6 Le 1149 località dei dati PVGIS. Ogni punto è una posizione del reticolo con passo di 5 km per la quale sono disponibili le serie orarie. 31

4.1 Ordine dei passaggi del detector su un istante, dai campi ERA5 alla segnalazione. In corsivo, gli anni su cui è stimata ciascuna quantità: le scale della normalizzazione stagionale e i pesi sugli anni di addestramento, la climatologia dello score e la soglia sugli anni di validazione. 34
4.2 Struttura del generatore (a) e del discriminatore (b). Il generatore unisce cella per cella i tre rami, recente, trend e calendario, e produce il campo stimato dell'istante. Il discriminatore giudica ogni cella sulla propria patch, a partire dalla storia recente e dal campo corrente, osservato o generato. I riquadri tratteggiati indicano i dropout, con probabilità 0.2 (Sezione 4.6). 35

6.1 Correlazione spaziale fra G e D in ogni istante degli anni di test, calcolata sulle 10611 celle: media giornaliera (linea sottile) e media mobile su 30 giorni (linea spessa). Le due correlazioni restano negative per quasi tutto il periodo. 54
6.2 G (a sinistra) e D (a destra) l'8 agosto 2014 alle 3 UTC, un istante con la correlazione spaziale di Spearman uguale alla mediana del test. Per entrambi i colori chiari indicano valori più insoliti; ogni mappa ha una propria scala, dal primo al 99-esimo percentile dei suoi valori, quindi i colori non si confrontano fra le due mappe. Le celle con G più alto sono in gran parte fra quelle con D più basso. Linee di costa da Natural Earth. . . . 54
6.3 Correlazione temporale di Spearman fra G e D in ogni cella, sugli istanti degli anni di test. La correlazione è negativa in tutte le celle, più forte (colori scuri) nel sud del dominio. La linea tratteggiata indica la cornice a due celle dal bordo, un effetto del modello. Linee di costa da Natural Earth. 56

6.4 Quota dei valori segnalati, per fascia di latitudine e mese, sugli anni di test: G senza (in alto) e con (in basso) la normalizzazione climatologica, calcolata per cella, giorno dell'anno, con una finestra di ± 15 giorni, e ora. La soglia di ciascuno score è il suo 95-esimo percentile sugli anni di validazione. La scala dei colori non è lineare: il bianco corrisponde al 5%, il blu a quote minori, il rosso a quote maggiori. Senza normalizzazione le segnalazioni si concentrano a sud e in estate, con la normalizzazione sono distribuite in modo quasi uniforme. . . . 57
6.5 Correlazione temporale di Spearman, in ogni cella, fra G e il giudizio del discriminatore sull'osservazione, D_{reale} (a sinistra), e sulla ricostruzione, D_{generato} (a destra), sugli anni di test. Il rosso indica che i due crescono insieme. D_{generato} cresce con G quasi ovunque, D_{reale} non ne segue l'ordine. Linee di costa da Natural Earth. 58
6.6 Le tre zone attorno a un evento, in un istante, su una porzione della griglia: il nucleo, il contorno, le celle intermedie escluse e la zona lontana. Ogni quadrato è una cella. 59
6.7 Percentile mediano di G senza normalizzazione, di D_{reale}, di D_{generato} e di D nel nucleo degli eventi di G con la normalizzazione climatologica, nel loro contorno e lontano da essi, sugli anni di test. La linea tratteggiata indica 50, il valore atteso senza legame con gli eventi. G serve da riferimento: è alto nel nucleo per costruzione. Nel nucleo D_{reale} è basso e D_{generato} alto, e D scende al percentile 10. 60
6.8 G, D_{reale}, D_{generato} e D il 30 agosto 2024 alle 12 UTC, l'istante con la media di G più alta degli anni di test. Ogni mappa ha una propria scala, dal primo al 99-esimo percentile dei suoi valori. Dove G è alto (in chiaro), D_{reale} è vicino a zero e D_{generato} è al massimo, e D è al minimo. Linee di costa da Natural Earth. 61

Capitolo 1

Introduzione

1.1 Contesto e motivazioni

Le condizioni meteorologiche insolite, come una perturbazione intensa, un fronte che attraversa una regione o un'ondata di caldo, sono quelle in cui i modelli addestrati su dati storici sbagliano di più e in cui servono informazioni aggiuntive. Il lavoro è nato in questo contesto, nell'ambito della previsione della produzione fotovoltaica [1], dove un previsore è affidabile nelle condizioni che i dati di addestramento rappresentano bene e meno in quelle poco frequenti. Riconoscere queste condizioni è però un problema a sé, distinto dalla previsione: richiede di stabilire, per ogni luogo e ogni istante, quanto le condizioni osservate si discostano da quelle abituali. È il compito del rilevamento di anomalie, a cui questa tesi è dedicata.

I campi meteorologici delle rianalisi, come ERA5 [2], descrivono lo stato dell'atmosfera su una griglia regolare, con molte variabili e per diversi decenni. Sono quindi una base adatta per cercare condizioni insolite in modo sistematico, su un dominio ampio e senza limitarsi alle grandezze di un singolo impiego.

1.2 Il problema: anomalie meteorologiche senza etichette

Tre caratteristiche dei dati rendono il problema difficile e guidano le scelte dei capitoli successivi.

La prima è l'assenza di etichette. Non esiste un elenco completo di osservazioni meteorologiche anomale con cui addestrare un classificatore o

misurare direttamente l'accuratezza di un detector. Il rilevamento deve essere unsupervised e la sua valutazione deve ricorrere a strumenti indiretti.

La seconda è che i dati di training non sono garantiti privi di anomalie. Molti detector apprendono il comportamento normale da un insieme che si assume pulito; con dati meteorologici non etichettati questa ipotesi non è verificabile. Ne segue una scelta di obiettivo: rilevare le condizioni nuove rispetto al periodo di training, trattando come già osservate quelle che il modello ha incontrato durante l'addestramento.

La terza è la struttura spaziale. Le condizioni di un luogo dipendono da quelle dei luoghi vicini, e un valore insolito in un punto può essere ordinario se considerato nel suo intorno. I campi non hanno però una topologia fisica, come una rete stradale: sono disposti su un reticolo regolare, e il modo di rappresentare l'intorno va scelto.

Il termine anomalia indica in questa tesi un'osservazione che si discosta da quanto il modello ha appreso dal periodo di training. Un evento meteorologico estremo è un caso particolare di anomalia, ma non ogni anomalia è un evento estremo.

1.3 Approccio proposto

Il detector parte da STGAN [3], una rete avversaria proposta per il rilevamento di anomalie nel traffico: un generatore stima i valori dell'istante successivo a partire dal contesto spaziale e temporale, un discriminatore giudica se una sequenza è osservata o generata, e uno score combina i due. In questa tesi lo schema è adattato e trasformato per i campi ERA5, con quindici variabili in superficie e a 850 hPa, ogni tre ore, su un dominio che comprende l'Europa e il Mediterraneo. Le modifiche principali sono quattro:

1. un generatore che opera sul campo intero con un'unità ricorrente convoluzionale, mentre il discriminatore resta locale;

2. un ingresso riferito al clima di ogni cella, con una normalizzazione stagionale e pesi che misurano l'errore di ogni variabile in rapporto a quanto essa cambia abitualmente;

3. il dropout Monte Carlo nelle due reti, che associa a ogni score una misura di dispersione;

4. una validazione senza etichette su anni di tempo normale, con cui si scelgono i parametri dell'addestramento avversario senza usare gli anni di test.

1.4 Obiettivi e contributi della tesi

L'obiettivo della tesi è rilevare condizioni meteorologiche anomale in campi privi di etichette e dotati di struttura spaziale, e studiare, senza riferimenti esterni, come si comportano le parti dello score e quale usare. La tesi non propone un nuovo algoritmo di rilevamento: adatta e combina componenti esistenti. I contributi sono i seguenti.

- L'adattamento di STGAN a campi meteorologici privi di topologia fisica, con un generatore sul campo intero che rappresenta l'intorno di una cella con una convoluzione su griglia, e la definizione dell'obiettivo come rilevamento di condizioni nuove rispetto al periodo di training.
- Uno score Monte Carlo, con il dropout nel generatore e nel discriminatore.
- Un protocollo di addestramento e di scelta della configurazione che non usa etichette né anni di test: una validazione da cui le condizioni insolite sono escluse con un criterio indipendente dal modello, e una misura della distanza fra campi osservati e ricostruiti.
- Una valutazione senza etichette: lo studio delle componenti dello score nello spazio e nel tempo, e il confronto, a parità di segnalazioni, con rilevatori che non usano un modello e con modelli poco profondi.

1.5 Organizzazione del documento

Il Capitolo 2 presenta i fondamenti teorici e i lavori su cui la tesi è costruita, per temi e in ordine cronologico all'interno di ciascun tema; si chiude con il modo in cui la tesi adatta STGAN e con la sua posizione rispetto ai lavori esaminati. Il Capitolo 3 descrive i campi ERA5 e la loro preparazione, e i dati PVGIS da cui il lavoro è partito. Il Capitolo 4 presenta il detector nella forma finale. Il Capitolo 5 descrive come il detector è addestrato e valutato: la configurazione e la ricerca dei parametri, e il protocollo di valutazione. Il Capitolo 6 riporta e discute i risultati. Il Capitolo 7 riassume il lavoro e ne indica gli sviluppi futuri.

Capitolo 2

Fondamenti teorici e stato dell'arte

Il capitolo presenta i fondamenti teorici e i lavori su cui la tesi è costruita. Ogni tema è trattato come un percorso: dai lavori che ne hanno definito il problema a quelli più recenti, fino al metodo che la tesi riprende. Per ciascun lavoro sono indicati ciò che propone, ciò che ottiene e il limite che lascia aperto, che spesso è il punto da cui parte il lavoro successivo; i lavori su cui il *detector* si basa direttamente sono descritti più a fondo, con le relative formule. I temi sono quattro: il rilevamento di anomalie in serie temporali, l'apprendimento automatico applicato ai dati meteorologici, il contesto spaziale su griglie e grafi, la quantificazione dell'incertezza. Una sezione descrive poi il modo in cui la tesi adatta STGAN, e l'ultima riassume la posizione della tesi rispetto ai lavori esaminati. Il percorso del capitolo segue quello del lavoro: partito da dati fotovoltaici PVGIS (Sezione 3.6) con il detector MTGFlow, è passato a STGAN sui campi ERA5 per rappresentare il contesto spaziale fra luoghi diversi.

2.1 Rilevamento di anomalie in serie multivariate e spazio-temporali

Questa sezione va dalle definizioni di anomalia ai metodi basati su reti profonde, e arriva a STGAN, la base del detector. Lungo il percorso due criteri guidano la scelta del detector: la tolleranza alla presenza di anomalie nei dati di addestramento, che senza etichette non si possono escludere, e la rappresentazione del contesto spaziale fra luoghi diversi. La sezione si chiude con il problema della valutazione e con i metodi semplici usati come confronto.

2.1.1 Dalla deviazione dal valore atteso ai modelli profondi

Nella rassegna di Gupta et al. [4] sui dati temporali, un'anomalia è definita in generale come uno scostamento dal valore atteso o previsto. Per i dati spazio-temporali la rassegna riprende una definizione più specifica: un'osservazione è anomala quando le sue grandezze differiscono in modo significativo da quelle degli oggetti vicini nello spazio e nel tempo. I metodi che la rassegna raccoglie per questi dati procedono per lo più in due passi, prima cercando le anomalie spaziali e poi verificandole rispetto ai vicini temporali, con intorni fissati a mano; fra le applicazioni figurano anche dati ambientali e meteorologici, come serie di precipitazione e campi di rianalisi. I metodi esaminati precedono l'uso diffuso delle reti profonde e trattano grandezze scalari o singoli oggetti, non campi multivariati considerati insieme.

La rassegna di Zamanzadeh Darban et al. [5] raccoglie i metodi profondi per serie temporali e li divide secondo il segnale da cui ricavano lo *score*: la *previsione* del valore successivo, la *ricostruzione* dell'osservazione, una rappresentazione appresa, oppure una combinazione delle prime due. Distinzioni analoghe compaiono nei lavori più recenti esaminati più avanti [6, 7]. Le reti generative avversarie vi figurano fra i metodi a ricostruzione; gli autori ne indicano come limite l'addestramento, che richiede di bilanciare generatore e discriminatore ed è instabile e difficile da far convergere. Nella rassegna il termine spaziale indica le dipendenze fra le variabili di una serie, non fra luoghi geografici; fra i dataset raccolti non compaiono campi meteorologici su griglia, e i lavori su dati geografici, come STGAN, sono citati soltanto fra le applicazioni urbane e al traffico.

Due lavori mostrano i due segnali principali e il loro limite comune, cioè l'assenza di relazioni fra le serie. Malhotra et al. [8] propongono un *encoder–decoder* basato su LSTM, addestrato a ricostruire finestre di serie normali: una finestra anomala, che il modello non ha imparato a ricostruire, produce un errore più alto, e lo score è la distanza di Mahalanobis del vettore degli errori dalla loro distribuzione sui dati normali. La soglia di decisione è però scelta massimizzando un indice di accuratezza su sequenze anomale etichettate, e negli esperimenti con più sensori le serie sono ridotte alla prima componente principale: il metodo, quindi, non è interamente unsupervised e non modella più variabili insieme. Hundman et al. [9] seguono la via della previsione per la telemetria di veicoli spaziali: una LSTM per canale prevede il valore successivo, e gli errori, smussati, sono confrontati con una soglia scelta senza etichette, che separa i valori più alti dal resto della distribuzione degli errori. Sui due insiemi di dati dell'articolo il metodo raggiunge una precisione dell'87.5% e un richiamo dell'80.0% [9]. Gli autori indicano fra i limiti le interazioni fra i

canali, che un modello per canale non rappresenta, e osservano che la qualità del rilevamento dipende da quella della previsione.

Anche i modelli più complessi non risolvono questo limite. Xu et al. [10] introducono Anomaly Transformer, in cui l'attenzione di un Transformer è affiancata da una distribuzione a priori concentrata sui punti vicini. Il criterio è che un'osservazione anomala, essendo rara, non riesce a stabilire legami con il resto della serie e concentra l'attenzione sui punti adiacenti; lo score moltiplica l'errore di ricostruzione per una funzione della differenza fra le due distribuzioni. La soglia è fissata senza etichette, come la quota di score più alti su un periodo di validazione. Le variabili sono riunite in un unico vettore per istante e lo score è uno per istante: il metodo non rappresenta relazioni spaziali e non localizza l'anomalia fra le variabili. I risultati dell'articolo sono misurati con un criterio che considera rilevato un intero segmento anomalo quando ne è segnalato anche un solo punto [10].

In questa tesi un'anomalia è uno scostamento da ciò che il modello ha appreso dal periodo di addestramento, non dai vicini fissati a mano: la definizione è precisata nella Sezione 2.5.

2.1.2 Grafi appresi e dati di addestramento contaminati: GDN e MTGFlow

Una linea di lavori rappresenta le relazioni fra le serie con un grafo appreso dai dati, quando queste relazioni non sono note. Deng e Hooi [11] propongono GDN per i sensori di impianti industriali: a ogni sensore è associato un vettore appreso, i vicini di ciascun sensore sono i più simili secondo questi vettori, e un'attenzione su grafo prevede il valore successivo di ogni sensore. L'errore di ogni sensore è normalizzato con la sua mediana e il suo intervallo interquartile, e lo score di un istante è il massimo sui sensori, perché un'anomalia può interessarne anche uno soltanto; la soglia è il massimo dello score su un periodo di validazione. Il grafo collega sensori di uno stesso impianto, non luoghi, e si assume che i dati di addestramento siano normali.

Zhou et al. [12] rimuovono questa ipotesi: osservano che gran parte dei metodi presuppone dati di addestramento composti da sole osservazioni normali, e che quando contengono anomalie le prestazioni possono degradare sensibilmente. Il loro metodo, MTGFlow, stima la densità dell'intero insieme di addestramento e identifica come anomale le osservazioni di test a bassa densità, sotto l'ipotesi che le anomalie occupino regioni più sparse. Le dipendenze fra entità sono apprese come grafo dinamico e un *normalizing flow* specifico per entità associa a ciascuna una distribuzione normale parametrizzata. La

soglia è ricavata dall'intervallo interquartile degli score di addestramento e lo score per entità consente di localizzare l'anomalia.

Le entità di MTGFlow sono i sensori o le variabili di un unico sistema e la valutazione usa dataset pubblici di riferimento: il grafo è appreso dai dati e descrive relazioni fra variabili, non fra siti geografici distinti. Un'estensione assegna una distribuzione comune alle entità di uno stesso gruppo, quando è noto che hanno caratteristiche simili. Il raggruppamento esprime soltanto che certe entità possono comportarsi allo stesso modo: non modella vicinanza, distanze o propagazione nello spazio, e non rende il metodo un detector spazio-temporale.

MTGFlow è stato il primo detector esaminato nel lavoro, per la sua robustezza alla presenza di anomalie nei dati di addestramento: per le condizioni meteorologiche non sono disponibili etichette, quindi non è possibile garantire dati di addestramento composti da sole osservazioni normali. È stato applicato ai dati PVGIS del lavoro preliminare (Sezione 3.6). Non rappresenta però il contesto geografico.

2.1.3 Alternative considerate: CATCH e M2AD

I due lavori più recenti esaminati tornano all'ipotesi di dati di addestramento normali.

CATCH. Wu et al. [6] propongono un metodo basato su ricostruzione nel dominio della frequenza. Lo spettro è suddiviso in bande, trattate come *patch*, per cogliere caratteristiche a grana fine; un modulo di fusione dei canali, con un generatore di maschere e un'attenzione mascherata, seleziona per ciascuna banda le correlazioni fra canali ritenute utili e isola quelle irrilevanti. Il metodo mira a rilevare insieme anomalie puntuali e di sottosequenza ed è valutato su dataset reali e sintetici. Lo score di anomalia è l'errore di ricostruzione: il modello impara a ricostruire i pattern normali, e nei dataset sintetici dell'articolo le anomalie sono inserite soltanto nella serie di test. Il caso di anomalie presenti nei dati di addestramento non è trattato. I canali sono le variabili di una serie multivariata: non è prevista una struttura geografica fra serie di siti diversi. Gli autori segnalano inoltre che anomalie più lunghe della finestra osservata non vengono colte efficacemente.

M2AD. Alnegheimish et al. [7] considerano serie multivariate provenienti da più sistemi. Un modello LSTM apprende il comportamento atteso dei sensori. I residui fra valori attesi e osservati sono aggregati in uno score globale mediante un modello a miscela gaussiana e una calibrazione Gamma. La soglia

è stimata dagli score osservati in addestramento, e i sensori sono ordinati per contributo allo score. Il metodo assume che i dati di addestramento siano privi di anomalie e che addestramento e test abbiano andamenti simili; gli autori indicano come limite il caso in cui la distribuzione cambia, che richiede un nuovo addestramento.

Perché non sono stati adottati. CATCH e M2AD sono stati presi in esame come alternative a MTGFlow e non sono stati adottati, per due ragioni. Richiedono dati di addestramento privi di anomalie, una condizione che senza etichette non è verificabile sui dati meteorologici; e, come MTGFlow, non rappresentano relazioni fra luoghi geografici. Nessuno dei due è stato eseguito sui dati della tesi. Dei due criteri della sezione, quindi, il primo ha portato a MTGFlow, il secondo, che nessuno di questi metodi soddisfa, a STGAN, che offre il contesto spaziale al prezzo di presupporre dati di addestramento normali.

2.1.4 Reti generative avversarie per il rilevamento di anomalie

Una rete generativa avversaria [13] è formata da due reti, addestrate insieme con obiettivi opposti. Il generatore G trasforma un rumore z, estratto da una distribuzione nota p_z, in un campione $G(z)$; i dati reali seguono la distribuzione p_{data} e il discriminatore D restituisce la probabilità $D(x)$ che un campione x provenga dai dati reali anziché dal generatore. Le due reti sono addestrate sulla stessa funzione, che il discriminatore massimizza e il generatore minimizza:

$$\min_G \max_D V(D,G) = \mathbb{E}_{x\sim p_{\text{data}}}\Big[\log D(x)\Big] + \mathbb{E}_{z\sim p_z}\Big[\log\Big(1 - D(G(z))\Big)\Big]. \quad (2.1)$$

Il primo termine cresce quando il discriminatore riconosce i dati reali, il secondo quando riconosce i campioni generati; il generatore è addestrato a rendere i propri campioni indistinguibili da quelli reali. Entrambe le reti sono ottimizzate con la retropropagazione. Lo stesso articolo osserva che, all'inizio dell'addestramento, il secondo termine fornisce al generatore un gradiente debole, e propone in alternativa di addestrarlo a massimizzare $\log D(G(z))$.

Schlegl et al. [14] usano per primi questo schema per il rilevamento di anomalie, con AnoGAN, su immagini di tomografia della retina. La rete è addestrata soltanto su immagini sane; poiché una GAN non fornisce la trasformazione inversa da un'immagine al rumore che la genera, per ogni immagine da valutare il rumore è cercato con un'ottimizzazione iterativa, a reti fissate. Lo score somma due termini: lo scarto fra l'immagine e quella

generata, e la distanza fra le rispettive caratteristiche in uno strato intermedio del discriminatore. Sui dati dell'articolo lo score completo raggiunge un'area sotto la curva ROC di 0.89; preso da solo, il termine di ricostruzione arriva a 0.88, quello del discriminatore a 0.74 [14]. Li et al. [15] estendono l'idea alle serie temporali multivariate di impianti industriali con MAD-GAN, in cui generatore e discriminatore sono LSTM e tutte le variabili sono modellate insieme, dopo una riduzione con le componenti principali. Lo score combina, con un peso, lo scarto di ricostruzione, ottenuto ancora con un'inversione iterativa nello spazio latente, e l'uscita del discriminatore. L'articolo non indica come scegliere quel peso né la soglia, e i risultati migliori sono selezionati fra più configurazioni; gli autori segnalano inoltre una forte oscillazione del richiamo da un'epoca all'altra, che attribuiscono all'instabilità del rilevamento basato su GAN [15]. Nessuno dei due metodi rappresenta relazioni spaziali fra le serie.

Nel detector della tesi lo schema è usato in forma condizionata: il generatore riceve il contesto di un'osservazione e ne produce una stima. L'uso per il rilevamento di anomalie poggia su un'ipotesi di lavoro: che la stima sia accurata nelle condizioni frequenti nei dati di addestramento e meno accurata in quelle poco rappresentate. È un'ipotesi e non una proprietà garantita dall'addestramento. Se vale, se ne ricavano due segnali: lo scarto fra l'osservazione e la stima del generatore, e il giudizio del discriminatore sull'osservazione. STGAN, descritto di seguito, li combina in un unico score. Il risultato di AnoGAN, in cui il termine del discriminatore preso da solo rileva meno di quello di ricostruzione, è il riferimento con cui la Sezione 6.5 legge il comportamento delle due componenti.

2.1.5 STGAN

Deng et al. [3] propongono una rete avversaria per il rilevamento di anomalie del traffico. Il generatore prevede la dinamica normale combinando tre componenti: un modulo recente, basato su unità ricorrenti con convoluzione su grafo, per le dipendenze spazio-temporali di breve periodo, un modulo per il trend di lungo periodo e uno per le variabili esterne. Il discriminatore stabilisce se una sequenza è reale o generata in funzione dei vicini nello spazio e nel tempo, fornendo un criterio che varia con località e istante. Dopo l'addestramento avversario entrambe le reti agiscono da detector e uno score ne combina i contributi. Il grafo deriva da una topologia fisica, cioè sensori adiacenti sulla stessa strada o regioni con confini comuni, e la valutazione misura il richiamo rispetto a incidenti ed eventi documentati, che gli autori stessi indicano come verità di riferimento incompleta. L'articolo non discute la presenza di anomalie nei dati di addestramento: il discriminatore è addestrato

considerando normali le sequenze reali e anomale quelle generate, quindi l'ipotesi di dati di addestramento normali è implicita. La Figura 2.1 riassume la struttura del metodo.

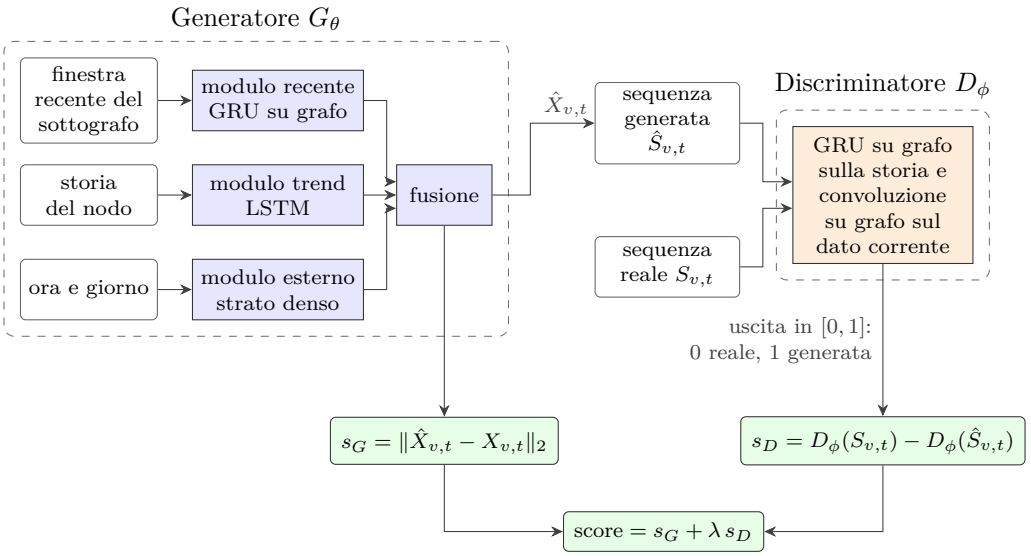


Figura 2.1: Schema di STGAN. Il generatore combina tre moduli e produce la stima $\hat{X}_{v,t} = G_\theta(v,t)$, che sostituisce l'ultimo elemento della sequenza reale; il discriminatore valuta entrambe le sequenze. Lo score somma l'errore di previsione e la differenza fra le due uscite del discriminatore. Ridisegnato a partire da Deng et al. [3].

Sia $x_{v,t}$ l'osservazione del nodo v all'istante t e $X_{v,t}$ l'insieme delle osservazioni nel sottografo formato da v e dai suoi vicini. Sia poi $S_{v,t}$ la sequenza reale dei valori del sottografo che termina con $X_{v,t}$, e $\hat{S}_{v,t}$ la stessa sequenza in cui l'ultimo elemento è sostituito dalla stima $\hat{X}_{v,t} = G_\theta(v,t)$ del generatore. Gli obiettivi di addestramento dell'articolo sono

$$\mathcal{L}_G(\theta) = \sum_s -\log\Big(1 - D_\phi(\hat{S}_{v,t})\Big) + \lambda_G \,\|G_\theta(v,t) - X_{v,t}\|_2, \tag{2.2}$$

$$\mathcal{L}_D(\phi) = \sum_s -\log\Big(D_\phi(\hat{S}_{v,t})\Big) - \log\Big(1 - D_\phi(S_{v,t})\Big), \tag{2.3}$$

dove la somma è sui punti $s = \langle v, t, x_{v,t}\rangle$ e λ_G bilancia l'errore di previsione e il termine avversario. Lo score combina le due reti:

$$\begin{aligned} s_D(v,t) &= D_\phi(S_{v,t}) - D_\phi(\hat{S}_{v,t}), \\ s_G(v,t) &= \|G_\theta(v,t) - X_{v,t}\|_2, \\ \text{score}(v,t) &= s_G(v,t) + \lambda\, s_D(v,t). \end{aligned} \tag{2.4}$$

La componente del discriminatore non è la sua uscita sulla sequenza reale ma la differenza rispetto alla sequenza generata: gli autori la introducono per ridurre l'effetto dell'imprevedibilità dei dati reali. Negli esperimenti dell'articolo $\lambda_G = 500$, le due componenti sono normalizzate e $\lambda = 1$.

Rispetto all'equazione (2.1), in STGAN il significato dell'uscita del discriminatore è invertito: le sequenze reali sono trattate come normali e quelle generate come anomale, e il discriminatore è spinto verso 1 sulle sequenze generate e verso 0 su quelle reali. Per il discriminatore l'obiettivo è lo stesso a meno di questo scambio, ma la sua uscita cresce con il sospetto di anomalia e può essere usata per costruire lo score. Il termine avversario dell'equazione (2.2) è la forma alternativa dell'obiettivo del generatore proposta da Goodfellow et al., scritta in questa convenzione, a cui si aggiunge l'errore di previsione.

Il generatore di STGAN stima i valori dell'istante corrente a partire dagli istanti precedenti, e l'articolo chiama *errore di previsione* lo scarto fra stima e osservazione. Nella tesi il generatore stima allo stesso modo il campo di un istante dal contesto che lo precede, e lo stesso scarto è chiamato *errore di ricostruzione*: i due termini indicano la stessa grandezza.

La tesi riprende l'architettura a tre rami e gli obiettivi avversari, e mantiene lo score combinato come riferimento; il modo in cui li adatta ai campi meteorologici è descritto nella Sezione 2.5. Gli obiettivi di addestramento e lo score, nella forma implementata, sono riportati nella Sezione 4.2: rispetto alle equazioni (2.2)–(2.4), l'errore vi compare come errore quadratico medio anziché come norma, mentre la differenza fra le uscite del discriminatore e $\lambda = 1$ sono mantenuti; λ_G è un parametro, con valore predefinito 500. La scelta segue il codice pubblicato dagli autori, che usa l'errore quadratico medio sia nella *loss* del generatore sia nella componente di ricostruzione dello score, e dimezza la somma dei due termini della loss del discriminatore. L'addestramento richiede un equilibrio fra le due reti: nella tesi i tassi di apprendimento delle due reti, il numero di aggiornamenti per *batch* e il peso di ricostruzione λ_G sono parametri configurabili (Capitolo 4).

2.1.6 Il problema della valutazione

I risultati dei lavori precedenti sono misurati su dataset etichettati, e la loro affidabilità dipende da quella delle etichette. Wu e Keogh [16] esaminano i dataset più usati per le serie temporali univariate e vi riscontrano quattro difetti ricorrenti. Il primo è che molti problemi si risolvono con una sola riga di codice basata su operazioni elementari, come media, deviazione standard e differenze successive: una riga di questo tipo risolve 316 delle 367 serie di uno dei dataset. Gli altri sono una densità di anomalie poco realistica,

etichette errate o mancanti, e anomalie concentrate verso la fine delle serie. Gli autori ne concludono che parte dei progressi riportati può essere apparente, e raccomandano di confrontare ogni metodo con soluzioni banali e di esaminare sempre visivamente dati e score. L'analisi riguarda serie univariate e non tratta campi multivariati su griglia; le sue indicazioni valgono però anche in assenza di etichette, dove il confronto con metodi semplici e l'esame diretto di mappe e serie degli score restano gli strumenti disponibili.

Liu e Paparrizos [17] riprendono il problema con TSB-AD, un insieme di 1070 serie, univariate e multivariate, ricontrollate a mano, su cui confrontano quaranta detector con gli stessi dati e la stessa procedura di scelta dei parametri. Mostrano che il criterio che considera rilevato un intero segmento quando ne è segnalato un solo punto premia anche uno score casuale, e adottano misure che non dipendono da una soglia. Con queste misure i metodi statistici sono spesso fra i migliori, con un'analisi per componenti principali in testa fra le serie univariate; fra le multivariate prevalgono reti semplici, convoluzionali o ricorrenti, e lo stesso metodo per componenti principali, mentre Anomaly Transformer risulta ultimo in entrambi i gruppi. Anche TSB-AD richiede etichette, non contiene campi su griglia e non studia dati di addestramento contaminati da anomalie; ne resta l'indicazione che un detector appreso va sempre confrontato con metodi semplici, perché la sua superiorità non è scontata.

Per il contesto spaziale esistono metodi altrettanto semplici, che confrontano il valore di un luogo con quelli dei luoghi vicini senza un modello appreso. Shekhar et al. [18] definiscono così gli outlier spaziali su un grafo, con un'applicazione ai sensori di traffico di Minneapolis–Saint Paul. Per ogni nodo calcolano la differenza fra il valore di un attributo e la media dei suoi vicini, la standardizzano con la media e la deviazione standard di queste differenze su tutti i nodi e segnalano i nodi in cui supera una soglia. Il vicinato può essere spaziale, temporale, cioè lo stesso nodo negli istanti adiacenti, oppure spazio-temporale, e il test riguarda un solo attributo. Chen et al. [19] osservano che i test di questo tipo trattano un attributo alla volta e che un vicino con valori molto estremi può far apparire anomali anche i luoghi normali attorno. Propongono quindi di confrontare ogni luogo con la mediana dei vicini e, quando gli attributi sono più di uno, di misurare il vettore delle differenze con una distanza di Mahalanobis a stime robuste, quelle del determinante di covarianza minimo; il metodo è provato su dati del virus del Nilo occidentale. Nessuno dei due metodi apprende la dinamica dei dati né è pensato per campi continui su griglia.

Per questi motivi le segnalazioni del detector sono confrontate con un insieme di *metodi di confronto*: sette dei metodi statistici valutati in TSB-AD, cioè l'analisi per componenti principali, KMeans, CBLOF, MCD, HBOS,

COPOD e Isolation Forest, e i test spaziali di Shekhar et al. e di Chen et al. (Sezione 6.6).

2.2 Apprendimento automatico e dati meteorologici

Questa sezione descrive come l'apprendimento automatico è stato applicato ai campi meteorologici, prima per prevederli e poi per riconoscerne gli eventi estremi, e mostra che il rilevamento unsupervised di anomalie su tutti gli stati di una rianalisi non è stato affrontato nei lavori esaminati.

2.2.1 Dalla previsione numerica ai modelli basati sui dati

La previsione meteorologica numerica tratta l'evoluzione dell'atmosfera come un problema ai valori iniziali: le equazioni che la governano sono integrate a partire dallo stato osservato, e i processi di scala inferiore alla griglia, come convezione, radiazione e nubi, sono rappresentati da parametrizzazioni. Bauer et al. [20] ne ricostruiscono i progressi, che attribuiscono soprattutto a parametrizzazioni migliori, alla previsione d'insieme e all'assimilazione dei dati, e stimano che l'accuratezza fra tre e dieci giorni sia cresciuta di circa un giorno per decennio. Fra le sfide aperte indicano la verifica delle code della distribuzione, per cui servono misure adatte a statistiche scarse. Le rianalisi come ERA5 [2] nascono dallo stesso apparato: combinano un modello di previsione con le osservazioni disponibili per stimare lo stato dell'atmosfera in ogni istante.

Rasp et al. [21] rendono ERA5 il riferimento comune per i modelli di previsione basati sui dati, con WeatherBench: un insieme di campi ERA5 a risoluzione ridotta, periodi di addestramento, validazione e test contigui nel tempo e confronti con persistenza, climatologia e previsione numerica. Nella discussione gli autori osservano che gli eventi estremi, essendo rari, contano poco nelle metriche medie come l'errore quadratico, che le reti estrapolano male a stati diversi da quelli visti in addestramento e che una rete addestrata con l'errore quadratico produce campi troppo regolari; propongono le GAN come possibile rimedio a quest'ultimo problema. Lam et al. [22] portano l'approccio alla risoluzione nativa di ERA5 con GraphCast, una rete su grafo addestrata sui campi ERA5 dal 1979 al 2017, che supera la previsione deterministica operativa sul 90.3% delle combinazioni di variabile, livello e orizzonte esaminate. Gli autori riconoscono che l'addestramento con l'errore

quadratico porta il modello a esprimere l'incertezza sfumando i campi, e che il modello migliora quando è riaddestrato su anni più recenti, per ragioni non del tutto chiarite. Per valutare gli eventi estremi definiscono come tali i valori oltre un percentile di una climatologia per luogo, ora del giorno e mese.

Questi lavori usano ERA5 per prevedere; la tesi lo usa per riconoscere condizioni insolite. Alcune loro osservazioni valgono anche per questo impiego: un modello addestrato su anni passati con un errore medio rappresenta meglio le condizioni frequenti, tende a smussare quelle rare, e il suo comportamento può cambiare quando i dati si allontanano dal periodo di addestramento.

2.2.2 Eventi estremi e anomalie nei campi meteorologici

I primi lavori che applicano reti profonde agli eventi meteorologici estremi lo fanno in modo supervised. Liu et al. [23] classificano con reti convoluzionali poco profonde ritagli di campi centrati su cicloni tropicali, fiumi atmosferici e fronti, con etichette ottenute da criteri a soglia e da esperti, e riportano accuratezze di test fra l'89% e il 99%; il metodo classifica ritagli già centrati e non localizza gli eventi. Gli autori indicano nella scarsità di dati etichettati un limite, e la necessità di approcci unsupervised. Racah et al. [24] passano alla localizzazione con ExtremeWeather, un insieme di simulazioni climatiche in cui i riquadri degli eventi sono ottenuti da criteri a soglia: un encoder–decoder convoluzionale nello spazio e nel tempo unisce una perdita supervised sui riquadri a una di ricostruzione su tutti i campi, così che contribuiscano anche quelli senza etichette. Gli autori osservano che etichette prodotte da criteri a soglia sono incomplete, e che un metodo supervised addestrato su di esse può al più imitarli; lasciano esplicitamente aperto il rilevamento di anomalie.

Prabhat, Kashinath et al. [25] affrontano il problema delle etichette con ClimateNet, un insieme di campi annotati a mano da esperti. La campagna ha coinvolto circa ottanta esperti e ha prodotto 459 immagini etichettate; l'accordo fra due esperti sulla stessa immagine, misurato come sovrapposizione delle aree annotate, è in media di 0.51, e il modello di segmentazione addestrato su queste etichette ottiene un valore analogo rispetto agli esperti. Le etichette sono quindi costose e, sui contorni degli eventi, incerte anche per gli esperti. Il modello è addestrato e valutato su simulazioni climatiche, e l'applicazione alle rianalisi è lasciata a lavori futuri.

La scarsità di etichette motiva i lavori più recenti, che applicano modelli generativi unsupervised a ERA5. Zaninelli et al. [26] addestrano un autoencoder variazionale sui campi giornalieri di temperatura a due metri di un clima di riferimento, preindustriale in un modello climatico oppure i primi decenni di ERA5, e trattano come anomalo ciò che il modello non ricostruisce nei campi recenti; l'obiettivo è l'attribuzione delle ondate di calore al cambiamento

climatico, e l'anomalia è quindi lo scostamento da un clima di riferimento, su una sola variabile. Paçal et al. [27] addestrano un autoencoder variazionale spazio-temporale su nove variabili ERA5, con addestramento sugli anni 1941–1990 e test sugli anni 2001–2022, e raggruppano nello spazio latente le configurazioni atmosferiche delle ondate di calore in Europa occidentale; i campioni sono però selezionati in anticipo con una soglia sulla temperatura, e gli autori notano che le ricostruzioni del modello smussano gli estremi.

Nelle ricerche condotte per questa tesi non è emerso un lavoro che assegni uno score di anomalia a tutti gli stati dell'atmosfera di una rianalisi, su più variabili insieme e con un modello spazio-temporale avversario: i lavori supervised richiedono etichette che sono scarse e incerte, quelli unsupervised su ERA5 riguardano una sola variabile oppure eventi già selezionati. La ricerca non è esaustiva, e l'assenza va intesa in questo senso.

2.3 Contesto spaziale su griglie e grafi

STGAN rappresenta il contesto spaziale con convoluzioni su grafo, che presuppongono una rete di adiacenze. Le convoluzioni su grafo si sono diffuse nella previsione del traffico: Yu et al. [28] propongono STGCN, in cui blocchi formati da una convoluzione temporale, una convoluzione su grafo e una seconda convoluzione temporale prevedono la velocità del traffico sulle stazioni di una rete stradale. Il grafo è dato dalla rete stradale oppure costruito con un nucleo sulla distanza fra le stazioni, con parametri fissati a mano. Gli autori motivano il grafo osservando che una convoluzione ordinaria limita il modello a dati disposti su una griglia, come immagini e video. È proprio il caso dei campi della tesi, disposti su un reticolo regolare: questa sezione richiama l'operatore che sul reticolo svolge il ruolo della convoluzione su grafo, l'unità ricorrente convoluzionale.

Le unità ricorrenti a gate, come quella introdotta da Cho et al. [29] e nota come GRU, aggiornano uno stato nascosto mediante gate che regolano quanta parte dello stato precedente conservare e quanta sostituire. Nella forma originaria ingresso e stato sono vettori e i gate sono trasformazioni dense. Quando l'ingresso è un campo disposto su una griglia, le trasformazioni dense possono essere sostituite da convoluzioni, così che lo stato mantenga la struttura spaziale e i parametri siano condivisi fra le posizioni. L'idea è stata proposta per la LSTM nella previsione a breve termine delle precipitazioni [30] e per la GRU nell'apprendimento di rappresentazioni di sequenze video [31]. STGAN applica la stessa idea a un grafo: nel suo modulo recente i prodotti matriciali della GRU sono sostituiti da convoluzioni su grafo [3].

Sia X_s l'ingresso al passo s e H_{s-1} lo stato precedente, entrambi disposti sulla griglia. Uno strato ricorrente convoluzionale a gate calcola

$$R_s = \sigma(W_r * [X_s, H_{s-1}] + b_r)\,, \tag{2.5}$$
$$U_s = \sigma(W_u * [X_s, H_{s-1}] + b_u)\,, \tag{2.6}$$
$$\widetilde{H}_s = \tanh(W_c * [X_s, R_s \odot H_{s-1}] + b_c)\,, \tag{2.7}$$
$$H_s = U_s \odot H_{s-1} + (1 - U_s) \odot \widetilde{H}_s, \tag{2.8}$$

dove W_r, W_u, W_c sono i nuclei delle convoluzioni e b_r, b_u, b_c i termini costanti, appresi durante l'addestramento, σ è la funzione sigmoidale, $*$ una convoluzione spaziale, $\odot$ il prodotto elemento per elemento e $[\cdot, \cdot]$ la concatenazione sui canali. Il gate di reset R_s regola quanto dello stato precedente entra nello stato candidato $\widetilde{H}_s$; il gate di aggiornamento U_s regola quanto dello stato precedente viene conservato. La forma è quella dell'unità su grafo di STGAN, con la convoluzione su grafo sostituita da una convoluzione spaziale.

Con un *kernel* di lato k e *padding* $\lfloor k/2 \rfloor$, ogni convoluzione vede le celle entro $\lfloor k/2 \rfloor$ posizioni. Il gate di reset e lo stato candidato applicano due convoluzioni in sequenza, quindi a ogni passo lo stato precedente si propaga fino a $2\lfloor k/2 \rfloor$ posizioni: l'area che influenza una cella cresce con il numero di passi temporali e di strati. La tesi impiega questo operatore nel generatore e nel discriminatore di STGAN. L'implementazione prevede anche celle assenti, cioè posizioni del reticolo senza dati, come accade su domini di forma irregolare; nel dominio ERA5 della tesi il reticolo è completo, ma il trattamento è descritto nella Sezione 4.2.1.

2.4 Quantificazione dell'incertezza

Lo score di STGAN è un valore unico per osservazione, senza una misura della sua variabilità. Nella rassegna di Abdar et al. [32] l'incertezza di una previsione è distinta in due componenti: quella aleatoria, propria dei dati e non riducibile, e quella epistemica, dovuta alla conoscenza limitata del modello e ai dati insufficienti. Gli autori indicano le approssimazioni bayesiane e gli insiemi di modelli come i due metodi più usati, e il riconoscimento di dati lontani da quelli di addestramento come un problema ancora aperto; è la componente epistemica quella che ci si attende cresca per stati poco rappresentati nei dati, come le condizioni meteorologiche rare per un modello addestrato su anni passati. Questa sezione presenta il *dropout* Monte Carlo, applicato al detector, e le principali alternative.

Gal e Ghahramani [33] interpretano l'addestramento con dropout come un'inferenza bayesiana approssimata. Mantenendo il dropout attivo in pre-

visione e ripetendo più volte il passaggio in avanti si ottiene un insieme di uscite, la cui dispersione fornisce una stima dell'incertezza del modello con un costo aggiuntivo contenuto. Dati J passaggi in avanti $\hat{y}_j(x)$ ottenuti con maschere di dropout diverse, la media predittiva è stimata da

$$\mathbb{E}[y \mid x] \approx \frac{1}{J} \sum_{j=1}^{J} \hat{y}_j(x), \tag{2.9}$$

e la varianza predittiva dalla varianza campionaria dei J passaggi, a cui l'articolo somma l'inverso della precisione del modello.

Nella tesi il dropout Monte Carlo è applicato alle due reti del detector, il generatore e il discriminatore di STGAN, non per stimare l'incertezza di una previsione ma per campionare lo score di anomalia. Durante il calcolo degli score i dropout restano attivi e per ogni osservazione sono riportate la media dello score sui campioni, come nell'equazione (2.9), e la sua deviazione standard, come descritto nella Sezione 4.6. In questo impiego la dispersione misura la variabilità dello score rispetto alle maschere di dropout e non costituisce una stima calibrata dell'incertezza; il termine di precisione previsto da Gal e Ghahramani non viene aggiunto.

Le alternative principali richiedono di cambiare l'addestramento. Lakshminarayanan et al. [34] propongono il Deep Ensemble, un'alternativa non bayesiana: più reti vengono addestrate in modo indipendente a partire da inizializzazioni diverse, e le loro previsioni sono combinate come una miscela a pesi uguali. Il metodo è semplice da realizzare, produce un'incertezza maggiore sugli ingressi lontani dai dati di addestramento, ma richiede di addestrare una rete per ogni membro dell'insieme: per il detector, ciascun addestramento dura circa quattordici ore, mentre il dropout Monte Carlo ottiene la dispersione da un solo addestramento. Una terza famiglia di metodi ottiene la dispersione rendendo stocastica la dinamica interna della rete, con una rete di diffusione che scala un termine casuale: SDE-Net [35] e il suo adattamento SDE U-Net [36], impiegati nel lavoro preliminare per associare un intervallo di incertezza alle previsioni della produzione fotovoltaica sui dati PVGIS. Il detector non li adotta: aggiungere a STGAN una rete di diffusione e una dinamica stocastica si sarebbe discostato molto dall'architettura dell'articolo, che il lavoro ha seguito il più fedelmente possibile, mentre il dropout Monte Carlo richiede soltanto di aggiungere strati di dropout alle reti esistenti, senza cambiarne l'architettura. L'applicazione di questi metodi al detector è indicata fra gli sviluppi futuri.

2.5 Da STGAN al detector della tesi

STGAN è nato per il traffico: il grafo deriva da una rete fisica, lo score è un valore unico per osservazione e la valutazione misura il richiamo su incidenti documentati (Sezione 2.1.5). La tesi ne riprende l'architettura a tre rami e gli obiettivi avversari, e lo adatta lungo quattro assi a campi meteorologici privi di etichette.

Griglia e campo intero. Nell'articolo il contesto spaziale è un grafo, e in assenza di una rete fisica le sue adiacenze andrebbero scelte con un criterio di vicinanza. Sul reticolo regolare dei campi della tesi, invece, le posizioni relative dei vicini sono definite. La convoluzione su grafo del modulo recente è quindi sostituita da una ConvGRU (Sezione 2.3), e il ramo LSTM del trend è conservato. Il generatore elabora in una sola passata il reticolo completo di un istante, mentre il discriminatore continua a giudicare l'intorno di ogni cella, una patch al posto del sottografo dell'articolo (Sezione 4.2.1).

Obiettivo: condizioni nuove rispetto all'addestramento. L'articolo tratta come normali le sequenze reali dei dati di addestramento, mentre per i campi meteorologici dati di addestramento privi di anomalie non sono garantiti. A differenza di MTGFlow, STGAN non tollera per costruzione dati contaminati: la tesi accetta questo limite in cambio del contesto spaziale e lo traduce in una scelta di obiettivo, cioè rilevare condizioni nuove rispetto al periodo di addestramento. Le anomalie presenti negli anni di addestramento sono trattate come già osservate: nella misura in cui il modello le apprende, condizioni simili non vengono segnalate, mentre lo sono quelle poco o per nulla rappresentate in quegli anni. Lo score misura quindi lo scostamento da quanto il modello ha appreso dal periodo di addestramento, non la rarità di una condizione in assoluto.

Lo score è continuo e non coincide con la decisione: sono considerate anomale soltanto le osservazioni con score più alto, in una quota che è un parametro del protocollo. Il termine anomalia è usato in questo senso in tutta la tesi: un evento estremo è un caso particolare di anomalia, ma non ogni anomalia è un evento estremo.

Score e dispersione. Accanto allo score combinato dell'articolo, la tesi considera l'errore di ricostruzione del generatore normalizzato rispetto ai valori abituali di questo stesso errore nella cella, nel periodo dell'anno e nell'ora, perché la grandezza tipica dell'errore cambia da luogo a luogo e da stagione a stagione (Sezione 4.7). Quale delle due componenti usare è studiato

nel Capitolo 6. Il dropout Monte Carlo nel generatore e nel discriminatore (Sezione 2.4) associa a ogni score una misura di dispersione, che l'articolo non prevede.

Validazione senza etichette. L'articolo valuta il detector su eventi documentati, che per i campi meteorologici non sono disponibili in modo sistematico. La tesi introduce quindi anni di validazione, da cui i valori insoliti sono esclusi con un criterio che non dipende dal modello (Sezione 4.5). L'idea è analoga al protocollo di Monaco et al. [36], che nella correzione delle previsioni di precipitazione escludono gli eventi intensi dall'addestramento e li mantengono nel test. Sulla validazione sono confrontate le configurazioni e fissate soglie e climatologia degli score, prima di valutare gli anni di test.

2.6 Posizionamento del lavoro

La tesi adatta un detector avversario spazio-temporale, nato per il traffico, a campi meteorologici privi di etichette e di topologia fisica, lungo gli assi della Sezione 2.5, e lo valuta senza etichette, confrontandolo con i metodi di confronto della Sezione 2.1.6. Il contributo consiste nell'adattamento, nella combinazione di questi elementi e nel protocollo di valutazione. I componenti di base sono preesistenti: la tesi non propone un nuovo algoritmo di rilevamento.

La Tabella 2.1 riassume i quattro candidati considerati per il detector e il percorso della tesi, secondo i criteri usati nel capitolo. Le voci relative agli articoli riportano ciò che gli articoli dichiarano; dove un aspetto non è discusso, è indicato come non trattato. STGAN è la base del detector; MTGFlow è stato eseguito nel lavoro preliminare (Sezione 3.6); CATCH e M2AD sono stati valutati sugli articoli e non eseguiti.

Tabella 2.1: Candidati considerati per il detector e percorso della tesi a confronto. La colonna sulle anomalie nell'addestramento indica come ciascun lavoro tratta la presenza di osservazioni anomale nei dati di addestramento; la colonna sulla valutazione indica i dati e il riferimento con cui il lavoro misura il rilevamento.

Lavoro	Segnale dello score	Anomalie nei dati di addestramento	Contesto spaziale	Valutazione	Dispersione
STGAN [3]	Errore di previsione e discriminatore	Non trattate: dati reali considerati normali	Sì: grafo da topologia fisica	Traffico; richiamo su eventi documentati	Non prevista
MTGFlow [12]	Densità stimata	Ammesse per costruzione	No: relazioni fra variabili	Sensori; dataset etichettati	Non prevista
CATCH [6]	Errore di ricostruzione in frequenza	Non trattate	No: canali di una serie	Serie multivariate; dataset etichettati, reali e sintetici	Non prevista
M2AD [7]	Residui di previsione aggregati	Escluse per ipotesi	No: sensori di più sistemi	Sensori di più sistemi; dataset etichettati e un caso industriale	Non prevista
Tesi	Errore di ricostruzione normalizzato; score di STGAN come riferimento	Trattate come già osservate	Sì: vicini sulla griglia	Campi ERA5; nessuna etichetta: componenti dello score e metodi di confronto	Dropout Monte Carlo

Capitolo 3

Dati e preprocessing

Il capitolo descrive i campi meteorologici su cui il detector è addestrato e valutato: le variabili della rianalisi ERA5, il dominio e la cadenza temporale, la preparazione dei dati e la loro suddivisione in anni di addestramento, di validazione e di test. L'ultima sezione descrive i dati PVGIS da cui il lavoro è partito: serie orarie di poche località, con irradianza, temperatura e vento soltanto, che non permettono di risalire alla condizione meteorologica che le ha prodotte, e per questo il lavoro è passato ai campi ERA5. Le trasformazioni che dipendono dal modello, come la normalizzazione stagionale, sono descritte nel Capitolo 4.

3.1 Campi ERA5 e dominio

I dati della rianalisi ERA5 [2] provengono da due prodotti distinti: variabili a livello singolo e variabili su livelli di pressione, di cui è usato soltanto il livello di 850 hPa. Le variabili sono quindici, scelte per descrivere le perturbazioni seguendo le variabili usate comunemente in climatologia. Si possono raggruppare per ruolo: la temperatura, a due metri e a 850 hPa, e l'umidità specifica a 850 hPa descrivono lo stato termodinamico; la pressione al livello del mare, il vento a dieci metri e a 850 hPa e la velocità verticale descrivono la circolazione; la copertura nuvolosa, la radiazione solare alla superficie e la precipitazione descrivono nubi e fenomeni associati; l'umidità del primo strato del suolo, la velocità d'attrito e l'altezza dello strato limite descrivono la superficie e lo strato più basso dell'atmosfera. La Tabella 3.1 le elenca con le unità di ERA5, che non vengono convertite.

I dati coprono gli anni dal 1980 al 2025. Sono selezionati gli istanti UTC 00, 03, 06, 09, 12, 15, 18 e 21, su una griglia di $0.5° \times 0.5°$ nell'area compresa fra 20° e 60° di latitudine nord e fra 15° di longitudine ovest

Tabella 3.1: Le quindici variabili ERA5, con la sigla e l'unità del dataset. Precipitazione e radiazione sono accumuli di un'ora; le altre variabili sono istantanee.

Variabile	Sigla	Livello	Unità
Temperatura a due metri	t2m	Superficie	K
Componente zonale del vento a dieci metri	u10	Superficie	$\mathrm{m\,s^{-1}}$
Componente meridionale del vento a dieci metri	v10	Superficie	$\mathrm{m\,s^{-1}}$
Pressione al livello medio del mare	msl	Superficie	Pa
Precipitazione totale	tp	Superficie	m
Copertura nuvolosa totale	tcc	Superficie	0–1
Radiazione solare discendente alla superficie	ssrd	Superficie	$\mathrm{J\,m^{-2}}$
Umidità volumetrica del primo strato del suolo	swvl1	Superficie	$\mathrm{m^3\,m^{-3}}$
Velocità d'attrito	zust	Superficie	$\mathrm{m\,s^{-1}}$
Altezza dello strato limite	blh	Superficie	m
Componente zonale del vento	u	850 hPa	$\mathrm{m\,s^{-1}}$
Componente meridionale del vento	v	850 hPa	$\mathrm{m\,s^{-1}}$
Velocità verticale	w	850 hPa	$\mathrm{Pa\,s^{-1}}$
Temperatura	t	850 hPa	K
Umidità specifica	q	850 hPa	$\mathrm{kg\,kg^{-1}}$

e 50° di longitudine est (Figura 3.1). Il dominio comprende l'Europa, il Mediterraneo e parte dell'Africa settentrionale e del Medio Oriente. La griglia di 0.5° e la cadenza di tre ore sono più rade di quelle originali di ERA5, di 0.25° e di un'ora: sono scelte per contenere la memoria occupata e i tempi di calcolo. Il campionamento ogni tre ore è una selezione di tempi validi, non un'aggregazione temporale: precipitazione e radiazione conservano gli accumuli di un'ora associati ai tempi selezionati, senza somme triorarie o conversioni locali delle unità.

Il reticolo contiene $81 \times 131 = 10611$ celle. Nel seguito i dati sono indicati come un tensore $X \in \mathbb{R}^{T \times N \times F}$, con T istanti, $N = 10611$ celle e $F = 15$ variabili.

Sono conservate le celle per le quali tutte le variabili sono definite nel primo istante dei dati, e si verifica che questo insieme rimanga identico in tutto il periodo; se cambia, la preparazione si interrompe, e non viene applicata imputazione. Il criterio è la completezza delle variabili, non una classificazione terra–mare: nei dati usati tutte le variabili, anche l'umidità del suolo, sono definite su tutte le celle, mare compreso, e nessuna cella è esclusa.

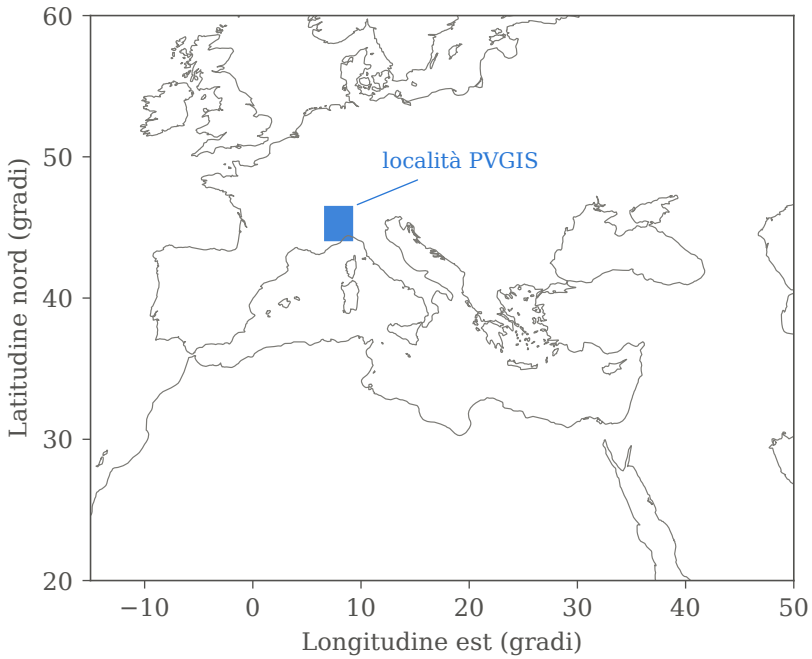


Figura 3.1: Dominio dei campi ERA5: 81 × 131 celle di 0.5°, fra 20° e 60° di latitudine nord e fra 15° di longitudine ovest e 50° di longitudine est. Il rettangolo indica l'area delle località PVGIS della Sezione 3.6, in Piemonte. Linee di costa da Natural Earth.

3.2 Acquisizione e preparazione dei dati

I dati comprendono 134416 istanti, 10611 celle e 15 variabili: circa 2.1×10^{10} valori, 85.6 GB in precisione singola. Il passaggio dai file di ERA5 ai dati letti dal modello è quindi automatizzato, in modo che nessun passo richieda di tenere in memoria l'intero periodo. Si articola in quattro fasi: scarico, verifica, preparazione e lettura (Figura 3.2).

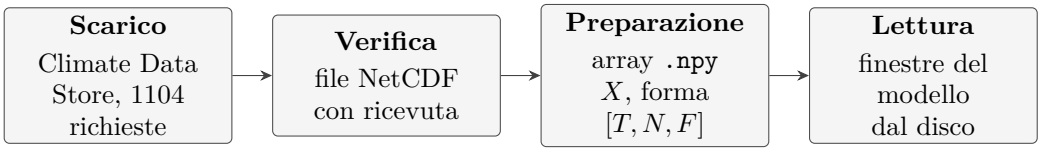


Figura 3.2: Dai file di ERA5 ai dati letti dal modello. I campi sono scaricati mese per mese dal Climate Data Store e conservati solo se superano la verifica; la preparazione li riunisce in array su disco, da cui il modello legge le sole finestre che usa.

Scarico. I campi sono richiesti al Climate Data Store di Copernicus attraverso la sua interfaccia di programmazione, con una richiesta per mese e per prodotto: 552 mesi e 1104 richieste. Ogni richiesta fissa le variabili, gli otto istanti del giorno, la griglia di 0.5°, il dominio e, per il secondo prodotto, il livello di 850 hPa. Il passaggio alla griglia di 0.5° è svolto dal servizio; i file ricevuti, in formato NetCDF [37], non vengono riscritti. Prima dello scarico i nomi delle variabili sono confrontati con quelli accettati dal servizio. Fino a otto richieste sono eseguite in parallelo, e una richiesta respinta per un limite temporaneo del servizio viene ripetuta dopo un'attesa crescente.

Verifica. Un mese è conservato solo se supera tutti i controlli. Gli istanti devono essere esattamente quelli richiesti, senza mancanti né duplicati; latitudini e longitudini devono essere quelle del dominio, con passo di 0.5°; il livello di pressione deve essere soltanto 850 hPa. Devono essere presenti tutte le variabili, senza valori infiniti e senza campi interamente mancanti in un istante; il controllo tollera campi mancanti per la sola umidità del suolo, una grandezza di terra, ma nei file usati non se ne sono presentati. Per ogni mese è salvata una *ricevuta*, un piccolo file con la richiesta e l'impronta SHA-256 di ciascun file scaricato, che permette di riconoscere i mesi già scaricati e integri. Quando lo scarico viene ripreso, i mesi con ricevuta e impronta corrette sono saltati e gli altri sono scaricati di nuovo.

Preparazione. La preparazione, svolta da un programma distinto da quello di scarico, controlla prima che tutti i mesi del periodo siano presenti, poi legge i file mese per mese, a blocchi di 32 istanti. Ripete i controlli su istanti, griglia e livello di pressione, allinea i due prodotti sugli stessi istanti e sulle stesse coordinate, e ordina le latitudini da nord a sud e le longitudini da ovest a est. Ogni blocco diventa la parte corrispondente del tensore X, in precisione singola, senza conversioni di unità né imputazione, ed è scritto direttamente nella sua posizione in file in formato `.npy` di NumPy [38]. Un file di metadati registra la griglia, le variabili, gli anni e il numero di celle escluse.

Lettura. I file sono aperti in mappatura di memoria: durante l'addestramento e il calcolo degli score si leggono dal disco soltanto gli istanti e le celle di ciascuna finestra. La suddivisione negli anni della Sezione 3.3 è applicata alla lettura.

3.3 Anni di addestramento, di validazione e di test

Il tensore X è diviso in tre periodi consecutivi. Gli anni 1980–1999 sono usati per l'addestramento, gli anni 2000–2004 per la validazione e gli anni 2005–2025 per il test: rispettivamente 58440, 14616 e 61360 istanti, cioè il 43%, l'11% e il 46% del totale. La divisione è cronologica: il modello non vede mai anni successivi a quelli su cui è valutato. Il test comincia nel 2005, il primo anno dei dati PVGIS della Sezione 3.6. Tutte le quantità che il Capitolo 4 stima dai dati per l'ingresso e la loss del modello sono calcolate sui soli anni di addestramento.

La validazione serve a confrontare le configurazioni e a fissare, prima di valutare il test, tutte le quantità che descrivono il comportamento abituale degli score. Queste quantità, fra cui le soglie, sono elencate nel Capitolo 5. Gli anni di test non entrano in alcuna scelta: ricevono senza modificarle le quantità stimate sugli anni di addestramento e su quelli di validazione. L'articolo di STGAN [3] separa i dati in training e test senza un insieme di validazione: la validazione è un'aggiunta di questo lavoro, necessaria perché in assenza di etichette la scelta della configurazione deve basarsi su una misura calcolata fuori dal test.

Il modello legge, per ogni istante, fino a 56 istanti precedenti, cioè sette giorni. I primi istanti di ciascun periodo usano quindi come contesto la coda del periodo precedente: le finestre di ingresso dei primi istanti di validazione

contengono gli ultimi istanti di addestramento, e lo stesso vale fra validazione e test. Il contesto non rientra fra gli istanti valutati.

3.4 Caratteristiche dei campi

Tre proprietà dei campi motivano altrettante scelte del Capitolo 4. Sono misurate sugli anni di addestramento, senza il detector; solo il confronto della Figura 3.4 anticipa i pesi del Capitolo 4.

Cicli diversi da luogo a luogo. La temperatura a due metri e la copertura nuvolosa hanno un ciclo stagionale e uno giornaliero, con livello e ampiezza diversi da una cella all'altra (Figura 3.3). La media mensile della temperatura va da 1 a 17 °C in una cella dell'Europa settentrionale, da 2 a 24 °C nella Pianura Padana e da 11 a 32 °C nel Sahara; la copertura nuvolosa media sta fra 0.60 e 0.78 nella prima cella e fra 0.04 e 0.29 nell'ultima. Lo stesso valore è quindi abituale in un luogo e in una stagione e insolito in altri. Per questo i valori in ingresso sono riferiti al normale climatologico della propria cella, del giorno e dell'ora (Sezione 4.3), e gli score alla climatologia della propria cella (Sezione 4.7).

Variazioni di grandezza diversa. Per una variabile f, la variazione quadratica media su 24 ore è

$$m_f = \frac{1}{TN} \sum_{t,n} \left(\tilde{x}_{t,n,f} - \tilde{x}_{t-8,n,f} \right)^2, \tag{3.1}$$

dove $\tilde{x}$ è il valore dopo la trasformazione considerata e $t - 8$ l'istante di 24 ore prima; la quota di f è $m_f / \sum_{f'} m_{f'}$. Le 24 ore confrontano istanti alla stessa ora e non contengono quindi il ciclo giornaliero. La quota dice quanto ciascuna variabile pesa in un errore di ricostruzione che somma le variabili con lo stesso peso. Con il min–max di STGAN, che riporta ogni variabile fra il minimo e il massimo degli anni di addestramento, la copertura nuvolosa produce l'84.1% della variazione quadratica media su 24 ore delle quindici variabili, e nessuna delle altre supera il 3.3% (Figura 3.4). La copertura nuvolosa passa spesso da sereno a coperto nel corso di un giorno e attraversa quasi tutto il proprio intervallo; la temperatura cambia di pochi gradi, in un intervallo che comprende tutte le celle e tutte le stagioni. Un errore di ricostruzione che somma le variabili con lo stesso peso sarebbe quindi in gran parte un errore sulla copertura nuvolosa. Dopo la normalizzazione stagionale e il min–max del detector le quote vanno dallo 0.9% dell'umidità del suolo al

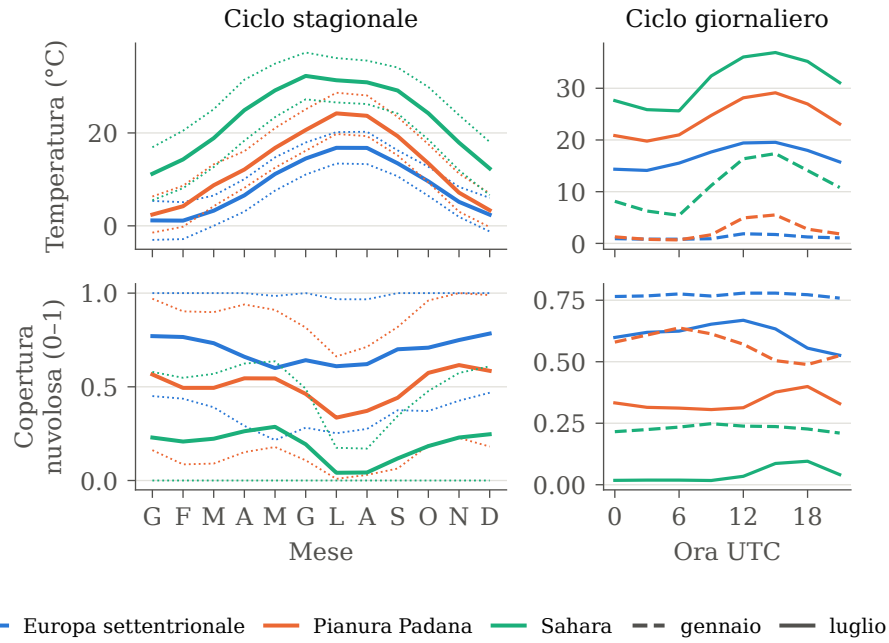


Figura 3.3: Ciclo stagionale e giornaliero della temperatura a due metri e della copertura nuvolosa in tre celle: Europa settentrionale (55°N, 10°E), Pianura Padana (45°N, 9°E) e Sahara (25°N, 10°E). A sinistra la media per mese, con le linee punteggiate a una deviazione standard dei valori triorari del mese; a destra la media per ora UTC in gennaio e in luglio. La temperatura è in gradi Celsius (in kelvin nei dati). Lo stesso mese ha livelli e variabilità diversi da una cella all'altra. Anni 1980–1999.

16.6% dell'umidità specifica, e la copertura nuvolosa ha il 6.7%, la quota di una variabile media: la normalizzazione stagionale rende confrontabili anche le variabili fra loro. Le differenze che restano sono corrette dai pesi della Sezione 4.4.

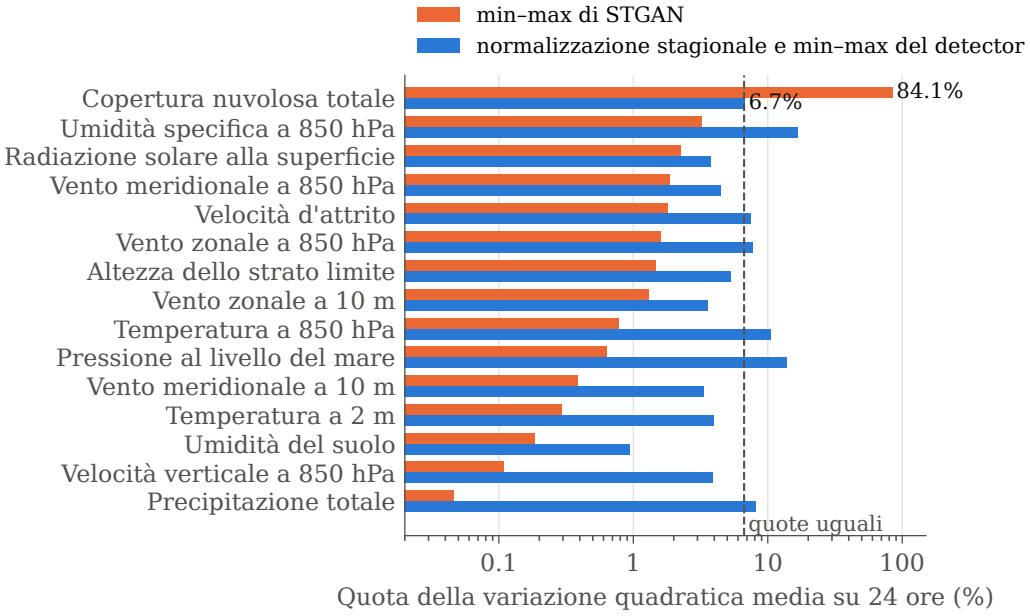


Figura 3.4: Quota di ciascuna variabile nella variazione quadratica media su 24 ore (equazione (3.1)), dopo il min–max di STGAN e dopo la normalizzazione stagionale e il min–max del detector, in scala logaritmica. Anni 1980–1999; la seconda quota è ricavata dai pesi della Sezione 4.4, che sono proporzionali all'inverso di m_f. La linea tratteggiata indica la quota uguale per tutte le variabili, un quindicesimo. Con il min–max di STGAN la copertura nuvolosa domina; dopo la normalizzazione stagionale le quote sono dello stesso ordine.

Legame spaziale a corto raggio. Gli scarti dalla media climatologica di due celle, cioè le differenze fra il valore e la media della propria cella, del mese e dell'ora, sono tanto meno correlati quanto più le celle sono lontane (Figura 3.5). Qui la media è per mese, una stima più semplice di quella per giorno usata nel Capitolo 4. Sono confrontate due variabili di grande scala, pressione e temperatura, e due legate alle perturbazioni, copertura nuvolosa e precipitazione; la distanza è misurata lungo la superficie terrestre. La correlazione mediana scende sotto 0.5 oltre circa 1300 km per la pressione al livello del mare e 900 km per la temperatura a due metri, ma già oltre 200 km per la copertura nuvolosa e 100 km per la precipitazione. Le variabili

legate alle perturbazioni dipendono quindi dalle celle vicine, entro poche celle di 0.5°: è il contesto che il detector rappresenta con la ConvGRU del generatore e con la patch del discriminatore (Sezione 4.2). Una cella misura circa 55 km in latitudine: la patch 3×3 del discriminatore copre le celle entro circa 55 km, e la ConvGRU allarga il raggio di alcune celle a ogni passo della finestra recente.

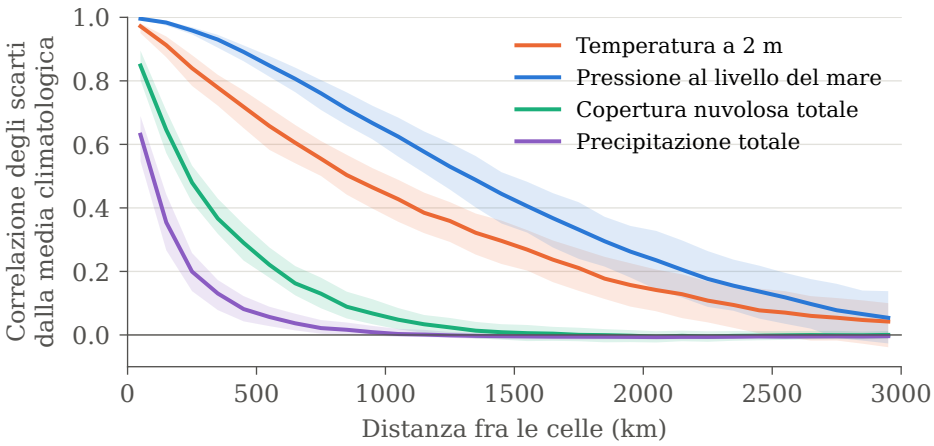


Figura 3.5: Correlazione degli scarti dalla media climatologica di due celle in funzione della loro distanza: mediana e quartili per fasce di 100 km, su 300 celle scelte a caso e un istante ogni nove degli anni 1980–1999 (un passo dispari, che legge tutte le ore del giorno). Il primo punto, entro 100 km, si basa su 36 coppie di celle. Precipitazione e copertura nuvolosa perdono la correlazione entro poche celle.

3.5 Qualità e limiti dei dati

ERA5 è una rianalisi: i campi sono stime di un modello vincolato dalle osservazioni disponibili, non misure dirette (Sezione 2.2). I dati usati sono completi, senza istanti o celle mancanti, e non è applicata imputazione. Due loro proprietà vanno però tenute presenti nella lettura dei risultati.

Variabili lontane da una distribuzione gaussiana. La precipitazione è nulla nella maggior parte degli istanti e assume di rado valori molto alti; la copertura nuvolosa è limitata fra 0 e 1. Il Capitolo 4 tratta la precipitazione con una radice quarta prima della standardizzazione (Sezione 4.3).

Cambiamenti dopo gli anni di addestramento. Riferite al normale climatologico degli anni 1980–1999, le medie annuali delle variabili sull'intero dominio non restano costanti negli anni successivi. Per l'umidità specifica a 850 hPa la media resta fra -0.13 e $+0.06$ deviazioni standard negli anni di addestramento e sale a $+0.17$ negli ultimi cinque anni: è una deriva reale, che la normalizzazione del Capitolo 4 non toglie. Per la precipitazione totale la media passa da circa 0 a valori fra $+0.09$ e $+0.26$ dal 2000 in poi; nei dati grezzi non c'è alcun salto, e lo spostamento è un effetto della standardizzazione di una variabile molto asimmetrica fuori dagli anni su cui è stimata, non un cambiamento del clima. In entrambi i casi gli anni di test si allontanano da quelli di addestramento, e un detector unsupervised può segnalare in parte questa distanza invece di condizioni insolite di un singolo istante (Sezione 6.4).

3.6 I dati PVGIS del lavoro preliminare

Il lavoro è partito, nell'ambito della previsione della produzione fotovoltaica, da serie orarie ottenute dal Photovoltaic Geographical Information System [39] con la banca dati di radiazione SARAH3, provenienti dal progetto SentinelPV del Politecnico di Torino. Coprono 1149 località del Piemonte, comprese fra 44.08° e 46.47° di latitudine nord e fra 6.66° e 9.20° di longitudine est. Nella proiezione UTM del fuso 32 le località occupano 1149 delle 41×54 posizioni di un reticolo regolare con passo di 5 km: quelle che ricadono nel territorio regionale (Figura 3.6), cioè il rettangolo della Figura 3.1. Sono disponibili gli anni dal 2005 al 2023, con 8760 ore per anno (8784 negli anni bisestili) e senza valori mancanti; i valori sono riferiti al minuto 10 di ciascuna ora, in tempo universale.

Per ogni località e ogni istante sono disponibili l'irradianza globale con le sue componenti diretta, diffusa e riflessa, l'altezza del sole, la temperatura dell'aria a due metri, la velocità del vento a dieci metri e la potenza prodotta (Tabella 3.2). L'irradianza è riferita al piano orizzontale: l'inclinazione indicata nei dati è nulla, la componente riflessa risulta nulla e l'irradianza globale coincide con la somma delle componenti diretta e diffusa. Circa la metà dei valori di irradianza è nulla, perché notturna. La potenza è una produzione teorica calcolata da PVGIS, non la misura di un impianto reale.

Queste sono le sole grandezze disponibili, e sono quelle che determinano la produzione fotovoltaica. Un'anomalia rilevata su questi dati non può essere ricondotta a una condizione meteorologica più generale: per rilevare anomalie di tipo diverso e descriverne l'origine il lavoro è passato ai campi ERA5 descritti nelle sezioni precedenti. Su questi dati il lavoro preliminare

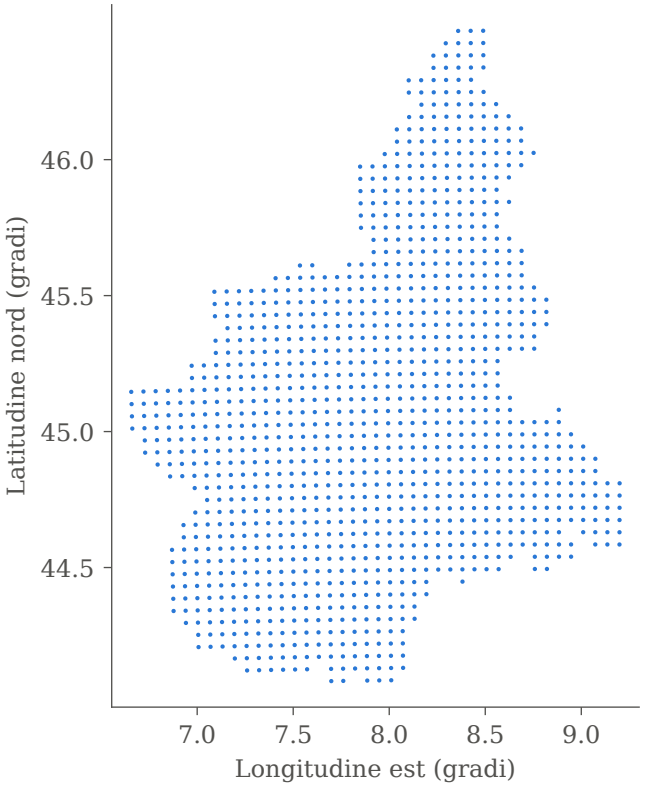


Figura 3.6: Le 1149 località dei dati PVGIS. Ogni punto è una posizione del reticolo con passo di 5 km per la quale sono disponibili le serie orarie.

Tabella 3.2: Grandezze dei dati PVGIS e loro unità.

Grandezza	Unità
Irradianza globale (diretta più diffusa)	$\mathrm{W\,m^{-2}}$
Irradianza diretta	$\mathrm{W\,m^{-2}}$
Irradianza diffusa	$\mathrm{W\,m^{-2}}$
Irradianza riflessa (nulla)	$\mathrm{W\,m^{-2}}$
Altezza del sole	gradi
Temperatura dell'aria a due metri	°C
Velocità del vento a dieci metri	$\mathrm{m\,s^{-1}}$
Potenza prodotta (teorica)	W

ha sviluppato un previsore della produzione e i primi detector, che la tesi non riporta.

Capitolo 4

Metodologia

Il capitolo descrive il detector nella forma usata sui campi ERA5. La Sezione 4.1 formula il problema: che cosa entra nel detector, che cosa ne esce e quando un valore è segnalato. Seguono l'architettura del generatore e del discriminatore con gli obiettivi dell'addestramento avversario (Sezione 4.2), l'ingresso del modello (Sezione 4.3), i pesi delle variabili nell'errore di ricostruzione, i valori insoliti tenuti fuori dalle misure sulla validazione, le componenti dello score con il dropout Monte Carlo, la normalizzazione climatologica dello score e la misura con cui si confrontano le configurazioni. Il capitolo si ferma allo score: ciò che se ne ricava, come il raggruppamento delle segnalazioni in eventi, è descritto nel Capitolo 6.

La Figura 4.1 riporta l'ordine in cui questi passaggi agiscono su un istante, e per ogni quantità stimata gli anni su cui è stimata: normalizzazione stagionale e pesi sugli anni di addestramento, prima di addestrare il modello; climatologia e soglia sugli anni di validazione, dopo l'addestramento. Il discriminatore non compare nella catena: serve all'addestramento del generatore e allo score combinato.

4.1 Formulazione del problema

I dati sono una sequenza di campi X_t, uno per istante t, su un reticolo di $N_y = 81$ righe e $N_x = 131$ colonne, cioè $N = 10611$ celle, con $F = 15$ variabili (Capitolo 3); x_{tnf} indica il valore della variabile f nella cella n. Per ogni istante il generatore riceve il contesto che lo precede, cioè gli R campi più recenti, una serie più lunga di ciascuna cella per il trend e la codifica temporale, e restituisce una stima $\hat{X}_t$ del campo, con valori $\hat{x}_{tnf}$. Lo scarto fra stima e osservazione, pesato per variabile e mediato sulla patch 3×3 di ogni cella e su più estrazioni Monte Carlo, è la *componente di ricostruzione*

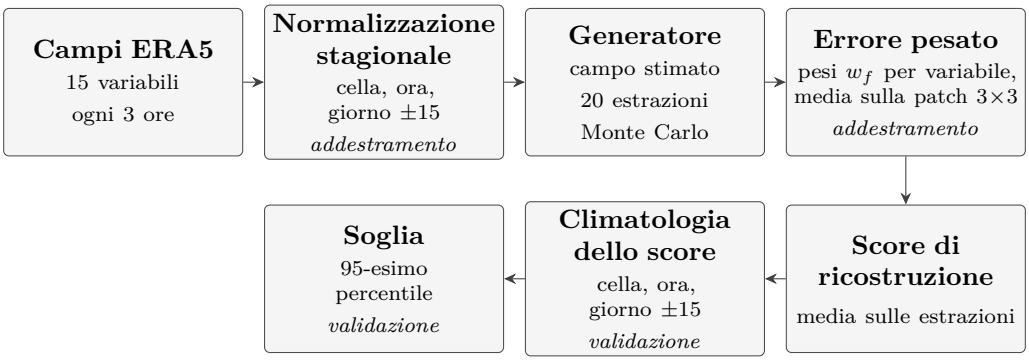


Figura 4.1: Ordine dei passaggi del detector su un istante, dai campi ERA5 alla segnalazione. In corsivo, gli anni su cui è stimata ciascuna quantità: le scale della normalizzazione stagionale e i pesi sugli anni di addestramento, la climatologia dello score e la soglia sugli anni di validazione.

$\bar{s}_{G,tn}$ (Sezione 4.6). Espressa rispetto ai valori abituali di questo stesso errore nella cella, nel periodo dell'anno e nell'ora, diventa lo *score di ricostruzione* ζ_{tn} (Sezione 4.7). Una coppia istante–cella è *segnalata* quando $\zeta_{tn} > \tau$, con la soglia τ pari al 95-esimo percentile di ζ sugli anni di validazione. Un'anomalia è quindi uno scostamento da ciò che il modello ha appreso negli anni di addestramento (Sezione 2.5). Il discriminatore serve all'addestramento del generatore e allo score combinato dell'articolo, calcolato dalla stessa esecuzione come termine di confronto.

4.2 Architettura e addestramento avversario

Il detector segue lo schema di STGAN [3] descritto nella Sezione 2.1.5: un generatore stima il campo dell'istante successivo a partire dagli istanti precedenti, e un discriminatore giudica se il campo di un istante, insieme alla sua storia recente, è osservato o generato. Il bersaglio del generatore è meteorologico e comprende le quindici variabili della Tabella 3.1. La griglia è definita direttamente in coordinate geografiche, con passo angolare di 0.5°, e la cadenza è di tre ore. La Figura 4.2 riporta la struttura delle due reti, descritta nelle sottosezioni seguenti.

4.2.1 Generatore ConvGRU sul campo intero e celle assenti

Un campione di addestramento è il campo completo di un istante, disposto sul reticolo $N_y \times N_x$ della Sezione 3.1. Il generatore ha tre rami. Il ramo

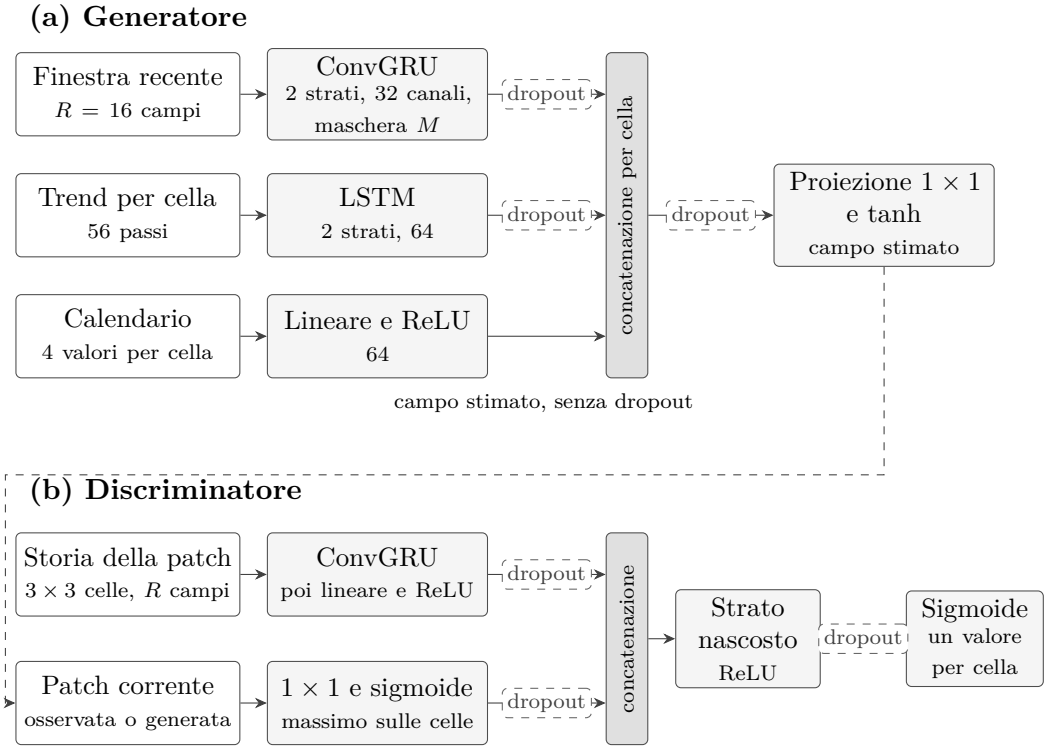


Figura 4.2: Struttura del generatore (a) e del discriminatore (b). Il generatore unisce cella per cella i tre rami, recente, trend e calendario, e produce il campo stimato dell'istante. Il discriminatore giudica ogni cella sulla propria patch, a partire dalla storia recente e dal campo corrente, osservato o generato. I riquadri tratteggiati indicano i dropout, con probabilità 0.2 (Sezione 4.6).

recente elabora gli R campi che precedono l'istante da stimare con una ConvGRU [30, 31], l'unità ricorrente convoluzionale delle equazioni (2.5)–(2.8), che sostituisce la convoluzione su grafo dell'articolo. Il ramo del trend elabora con una LSTM [40] la serie di ciascuna cella su un periodo più lungo. Il ramo del calendario proietta la codifica temporale con uno strato lineare seguito da una ReLU. Con b istanti per batch, R passi recenti, L passi di trend e F variabili, gli ingressi hanno forma $[b, R, F, N_y, N_x]$ per il ramo recente e $[b, L, N, F]$ per il trend; l'uscita ha forma $[b, F, N_y, N_x]$.

Le convoluzioni scorrono sull'intero reticolo: il campo ricettivo non è troncato al bordo di una regione e ogni cella viene ricostruita una sola volta. La LSTM del trend e la codifica temporale sono calcolate per cella e disposte sul reticolo. Le rappresentazioni dei tre rami sono concatenate cella per cella; una proiezione 1×1 seguita da tanh produce il campo stimato.

Le celle del reticolo prive di dati sono azzerate dopo la normalizzazione, e una maschera binaria M è fornita come canale aggiuntivo a ogni strato ConvGRU. Rispetto alle equazioni (2.5)–(2.8) cambiano l'ingresso e l'ultimo passaggio. I gate e lo stato candidato sono calcolati su X'_s, la concatenazione dei valori mascherati e di M, al posto di X_s; lo stato precedente H_{s-1} è già mascherato e lo stato aggiornato viene moltiplicato per la maschera, replicata sui canali:

$$H_s = M \odot \left[U_s \odot H_{s-1} + (1 - U_s) \odot \widetilde{H}_s \right]. \tag{4.1}$$

Il mascheramento dello stato impedisce alle celle assenti di conservare attivazioni da propagare negli strati o nei passi successivi. Non viene applicata una rinormalizzazione del kernel in funzione delle celle osservate, come avverrebbe in una partial convolution. Su ERA5 nessuna cella del reticolo è priva di dati, ma la maschera resta necessaria per il discriminatore, le cui patch sul bordo del dominio sono incomplete. Lo stato ricorrente è inizializzato a zero per ogni finestra. Il modello ha due strati ConvGRU da 32 canali con kernel 3×3, e una LSTM del trend a due strati con stato nascosto di dimensione 64.

4.2.2 Discriminatore locale

Il discriminatore giudica ogni cella sulla propria patch $P \times P$, con $P = 3$, così come nell'articolo giudica ogni nodo sul proprio sottografo: la patch comprende la cella e le sue otto vicine dirette, così che il giudizio tenga conto dell'intorno immediato. La patch di ogni cella è estratta dal campo, con le celle esterne al reticolo azzerate e indicate dalla maschera. Una ConvGRU codifica la storia recente della patch; la storia codificata è appiattita e proiettata con uno strato lineare seguito da una ReLU. Il campo corrente della patch, osservato o generato, passa attraverso una proiezione 1×1 seguita da una

sigmoide e da un massimo sulle celle valide. Le due rappresentazioni sono concatenate e alimentano uno strato nascosto e un'uscita sigmoidale. Il discriminatore restituisce quindi un valore per cella e per istante.

Le patch di tutte le celle sono valutate in un'unica passata, con le stesse maschere e gli stessi azzeramenti. L'uscita relativa a una cella è quella che il discriminatore produrrebbe sulla sua patch isolata. Una convoluzione che scorresse liberamente sul campo non darebbe lo stesso valore, perché la ConvGRU del discriminatore applica il padding all'interno di ciascuna patch.

4.2.3 Obiettivi di addestramento

Il discriminatore viene addestrato con etichetta zero per il campo reale e uno per il campo generato, come nell'articolo. Indicando con D_{reale} e D_{generato} le uscite sulle patch con il campo osservato e con il campo generato, cioè le $D_\phi(S_{v,t})$ e $D_\phi(\hat{S}_{v,t})$ dell'articolo (Sezione 2.1.5), gli obiettivi sono

$$\mathcal{L}_D = \tfrac{1}{2}\Big[\mathrm{BCE}(D_{\text{reale}}, 0) + \mathrm{BCE}(D_{\text{generato}}, 1)\Big], \tag{4.2}$$

$$\mathcal{L}_G = \lambda_G \ \mathrm{MSE}_w(\hat{x}, x) + \mathrm{BCE}(D_{\text{generato}}, 0), \tag{4.3}$$

dove MSE_w è l'errore quadratico medio sulle celle valide e sulle variabili, con i pesi delle variabili della Sezione 4.4, mediato poi sugli istanti del batch, e la BCE è mediata sulle uscite locali, una per cella. Rispetto alle equazioni (2.2)–(2.3) dell'articolo, l'errore di ricostruzione è un errore quadratico medio anziché una norma e la loss del discriminatore è dimezzata: la scelta segue il codice pubblicato dagli autori.

Generatore e discriminatore vengono aggiornati con ottimizzatori Adam [41] separati. Nel passo del generatore, i parametri del discriminatore sono congelati ma viene mantenuto il gradiente rispetto al campo generato; la storia della patch è ricalcolata con i pesi aggiornati del discriminatore. Il peso di ricostruzione λ_G, che nell'articolo vale 500, è un parametro. I tassi di apprendimento dei due ottimizzatori possono essere distinti: quello del discriminatore è espresso come rapporto rispetto a quello del generatore. Il coefficiente β_1 degli ottimizzatori vale 0.9, il valore del codice degli autori. Con rapporto n_D:n_G, sullo stesso batch vengono eseguiti prima n_D aggiornamenti del discriminatore e poi n_G del generatore, ciascuno con un proprio passaggio in avanti. Il rapporto è un conteggio di aggiornamenti e non va confuso con il rapporto fra i tassi di apprendimento. Tassi, rapporto e peso di ricostruzione sono gli strumenti con cui si regola l'equilibrio fra le due reti; i valori usati sono scelti nel Capitolo 5.

Un'epoca comprende $\lceil T_{\mathrm{a}}/b \rceil$ batch, con T_{a} istanti di addestramento utili e b istanti per batch, e ogni gradiente è mediato su tutte le celle di un istante.

In sintesi. Il generatore stima il campo di un istante su tutto il reticolo, a partire dai campi recenti, dal trend di ogni cella e dal calendario; il discriminatore giudica ogni cella sulla propria patch 3×3. Le due reti sono addestrate con gli obiettivi dell'articolo, nella forma del codice degli autori.

4.3 Ingresso: finestra recente, codifica temporale e normalizzazione stagionale

4.3.1 Finestra recente e trend

La finestra recente contiene gli R istanti che precedono quello da stimare. L'unità ricorrente spaziale la percorre in ordine: parte da uno stato nullo ed esegue un aggiornamento per ogni istante, sicché lo stato finale riassume gli R campi osservati. Con $R = 1$ il ramo recente vede soltanto l'ultimo istante e la ricorrenza si riduce a un solo aggiornamento. Con $R > 1$ il modello riceve anche l'evoluzione del campo negli istanti precedenti, e l'area che può influenzare una cella cresce con R, perché a ogni aggiornamento lo stato si propaga alle celle vicine. Il detector usa $R = 16$ passi, cioè 48 ore; il trend comprende 56 passi, cioè 168 ore, la stessa durata dell'articolo.

4.3.2 Codifica temporale ciclica

La codifica temporale dell'articolo, a 31 elementi, è composta dal giorno della settimana e dall'ora UTC. È pensata per il traffico e su ERA5 è poco adatta, per due motivi. Il primo è che il vettore è lo stesso per tutte le celle, mentre il dominio si estende per 65 gradi di longitudine: alla stessa ora UTC, l'ora solare delle celle più a ovest e quella delle celle più a est differiscono di oltre quattro ore. Il secondo è che non contiene la posizione nell'anno, e non distingue quindi le stagioni. È perciò sostituita da una codifica ciclica a quattro elementi, diversa per cella. Indicando con h_t l'ora UTC, con ℓ_n la longitudine in gradi, con g_t il giorno frazionario dell'anno e con G_t il numero di giorni dell'anno corrispondente, la codifica è

$$\begin{aligned} c_{tn} &= [\sin\phi_{tn},\ \cos\phi_{tn},\ \sin\psi_t,\ \cos\psi_t]\,, \\ \phi_{tn} &= \frac{2\pi}{24}\left(h_t + \frac{\ell_n}{15}\right), \qquad \psi_t = \frac{2\pi g_t}{G_t}, \end{aligned} \tag{4.4}$$

Il primo angolo rappresenta l'ora solare locale, ottenuta dalla sola longitudine senza fusi orari; il secondo la posizione nell'anno. Seno e coseno rendono vicini gli istanti vicini nel ciclo, come le ore 23 e le ore 1 oppure la fine di

dicembre e l'inizio di gennaio. La codifica ciclica non contiene il giorno della settimana.

4.3.3 Normalizzazione stagionale

La normalizzazione dell'articolo è un min–max per variabile stimato sui dati di addestramento. Usa un solo intervallo per variabile, valido per tutte le celle e per tutto l'anno. Su un dominio che va dal Sahara all'Europa settentrionale questo ha un limite: lo stesso valore riceve la stessa scala ovunque e in ogni stagione. Una temperatura di 20 °C, per esempio, è insolitamente alta a gennaio in Europa settentrionale e insolitamente bassa a luglio nel Sahara (Sezione 3.4), ma con un solo min–max per variabile riceve in entrambi i casi lo stesso valore normalizzato. La normalizzazione stagionale riferisce invece ogni valore a ciò che è abituale nella stessa cella, nello stesso periodo dell'anno e alla stessa ora (Figura 3.3). Per ogni cella n, variabile f, ora del giorno o e giorno dell'anno g il valore è standardizzato,

$$z_{tnf} = \frac{x_{tnf} - \mu_{nfog}}{\sigma_{nfog}}, \tag{4.5}$$

con otto ore del giorno e 366 giorni dell'anno. Media e deviazione standard sono quindi due tensori di forma $[8, 366, N, F]$, con una voce per ogni ora, giorno, cella e variabile, e la standardizzazione è un unico passaggio: ogni valore è confrontato direttamente con la media e la deviazione della propria ora, del proprio giorno, della propria cella e della propria variabile, senza una normalizzazione nel tempo seguita da una nello spazio. Media e deviazione standard sono stimate sui soli anni di addestramento, raccogliendo i quindici giorni che precedono g e i quindici che lo seguono. La deviazione standard è calcolata attorno alla media lisciata di ciascun giorno, in modo che la variazione del ciclo stagionale all'interno della finestra non venga contata come variabilità. Espresse in deviazioni standard del proprio normale, le variabili diventano confrontabili anche fra loro: la copertura nuvolosa, che con il solo min–max produce l'84.1% della variazione su 24 ore, ne produce il 6.7% (Sezione 3.4).

La precipitazione richiede un passaggio in più. È nulla nella maggior parte degli istanti e assume di rado valori molto alti: media e deviazione standard dei valori originali sono determinate in larga parte da questi pochi valori. Prima della standardizzazione la precipitazione è quindi sostituita dalla sua radice quarta, che comprime i valori alti e lascia nullo ciò che è nullo; media e deviazione standard descrivono la radice e non il valore originale. A differenza del logaritmo, la radice è definita anche per i valori nulli e non richiede una costante aggiuntiva.

La deviazione standard σ_{nfog} non può scendere sotto una frazione della deviazione standard complessiva della variabile sugli anni di addestramento: 0.1 per la precipitazione e per l'umidità del primo strato del suolo, 0.01 per le altre tredici variabili. Il limite evita la divisione per valori quasi nulli, come accade per la radiazione solare di notte.

L'ultimo passaggio riguarda il tempo. Gli anni di test seguono quelli di addestramento, fino a oltre vent'anni dopo. Per una variabile che nel periodo ha una tendenza, la differenza fra il clima degli anni di test e quello degli anni di addestramento entrerebbe in ogni valore standardizzato, e crescerebbe con la distanza dagli anni di addestramento. Per tre variabili (temperatura a due metri, temperatura a 850 hPa e umidità del primo strato del suolo) ai valori standardizzati è quindi sottratta una retta nel tempo. Sono le variabili in cui un controllo della media sull'intero dominio ha mostrato una deriva evidente, a partire dagli anni di addestramento; per le altre lo spostamento resta piccolo, con l'eccezione dell'umidità specifica, discussa più avanti.

Dopo questi passaggi è applicato un min–max per variabile, stimato sugli anni di addestramento, che riporta i valori nell'intervallo $[-1, 1]$ dell'uscita del generatore. Negli anni successivi, i valori esterni all'intervallo degli anni di addestramento possono superare questi estremi, perché la trasformazione non applica un clipping. Nel seguito x_{tnf} indica il valore dopo tutti questi passaggi e $\hat{x}_{tnf}$ la sua stima da parte del generatore.

4.4 Pesi delle variabili nell'errore di ricostruzione

Nell'articolo tutte le variabili contano allo stesso modo nell'errore di ricostruzione. Il detector pesa invece l'errore per variabile, in modo che ciascuna sia misurata in rapporto a quanto cambia abitualmente. Dopo la normalizzazione stagionale le variabili hanno già variazioni dello stesso ordine, ma non uguali: le loro quote della variazione su 24 ore vanno dallo 0.9% al 16.6% (Figura 3.4). I pesi correggono queste differenze. Indicando con m_f il quadrato medio della variazione della variabile f su 24 ore, calcolato sui dati di addestramento normalizzati, il peso è

$$w_f = \frac{\bar{m}}{m_f}, \qquad \bar{m} = \frac{1}{F} \sum_{f=1}^{F} m_f, \tag{4.6}$$

con $F = 15$. La differenza a 24 ore confronta istanti alla stessa ora del giorno e non contiene quindi il ciclo giornaliero. Il fattore $\bar{m}$ lascia invariata la loss per un errore proporzionale a m_f. Il peso non misura la difficoltà del modello

su una variabile: è una misura di quanto la variabile cambia, fissata prima dell'addestramento e senza usare il modello. Nella configurazione scelta vanno da 0.40 per l'umidità specifica a 7.14 per l'umidità del primo strato del suolo, che cambia lentamente. I pesi moltiplicano l'errore quadratico di ciascuna variabile nel termine di ricostruzione della loss del generatore e nell'errore di ricostruzione da cui sono calcolati gli score.

In sintesi. Ogni valore entra nel modello riferito al normale climatologico della propria cella, giorno e ora, con la codifica dell'ora solare locale e del periodo dell'anno, e l'errore di ciascuna variabile pesa in proporzione inversa a quanto la variabile cambia abitualmente.

4.5 Valori insoliti negli anni di validazione

Gli anni di validazione servono a confrontare configurazioni e a stimare le quantità dello score prima di valutare il test. Perché queste misure dipendano soprattutto dal tempo ordinario, i valori più insoliti della validazione sono individuati prima, con un criterio che non usa il modello.

Un valore, cioè una coppia istante–cella, è segnato come insolito con due distanze calcolate sui dati standardizzati della Sezione 4.3. La prima è la distanza dal normale stagionale: la media sulle variabili del quadrato dei valori standardizzati, con i pesi delle variabili della Sezione 4.4, che dice quanto il valore è lontano dal normale della propria cella, giorno e ora. La seconda è la variazione dall'istante precedente: la stessa media pesata sul quadrato della differenza rispetto a tre ore prima, che coglie i cambiamenti rapidi anche quando il valore resta vicino al normale. Ciascuna distanza è standardizzata con la media e la deviazione standard della stessa cella, dello stesso mese e della stessa ora negli anni di addestramento, così che un luogo o una stagione più variabili non concentrino le segnalazioni. Un valore è segnato quando almeno una delle due distanze standardizzate supera il livello oltrepassato dal 5% dei valori di addestramento. Medie, deviazioni standard e livelli sono stimati sui soli anni di addestramento; la validazione riceve soltanto le segnalazioni. Il criterio è approssimato: non pretende di individuare tutte le condizioni insolite, ma di togliere le più evidenti, così che le misure dipendano soprattutto dal tempo ordinario. La soglia del 5% è una scelta, e segna il 9.75% dei valori di validazione.

I valori segnati non entrano nelle misure calcolate sulla validazione, e nelle finestre di ingresso degli istanti di validazione sono sostituiti dal normale stagionale, cioè dal valore standardizzato nullo. In questo modo né il bersaglio né la storia recente da cui il modello parte contengono le condizioni insolite.

4.6 Componenti dello score e dropout Monte Carlo

4.6.1 Dropout nel generatore e nel discriminatore

Lo score è calcolato più volte con il dropout Monte Carlo [33], nella forma che pone il dropout dopo gli encoder e prima degli strati di uscita. Il generatore riceve tre strati di dropout: sulla rappresentazione spaziale del ramo recente, sulla rappresentazione del trend e sulla loro concatenazione con la codifica temporale, prima della proiezione di uscita. Il discriminatore ne riceve altrettanti, nelle posizioni corrispondenti: sulla storia codificata, sul campo corrente codificato e sullo strato nascosto che precede l'uscita. La probabilità è 0.2 in entrambe le reti, un valore fissato e non ottimizzato. I dropout sono attivi nell'addestramento e nel calcolo degli score. L'articolo e il codice degli autori non usano il dropout: è un'aggiunta di questo lavoro.

Il discriminatore riceve il campo generato senza il dropout del generatore: nell'addestramento, sia nel proprio aggiornamento sia nel termine avversario del generatore, e nel calcolo degli score. Se ricevesse il campo con il dropout, potrebbe distinguere i campi generati da quelli osservati per il rumore che il dropout vi introduce, e non per il loro contenuto. Il dropout del generatore agisce quindi sull'errore di ricostruzione, quello del discriminatore sul suo giudizio.

4.6.2 Estrazioni Monte Carlo e componenti dello score

Durante il calcolo degli score il modello è in modalità di valutazione, con l'eccezione dei dropout, che restano attivi. Per ogni istante sono fatte $J = 20$ estrazioni, un numero usato comunemente per il dropout Monte Carlo.

Per la coppia istante–cella (t, n) e l'estrazione j, la ricostruzione $\hat{x}^{(j)}$ dà l'errore di ricostruzione

$$s^{(j)}_{G,tn} = \frac{1}{|\mathcal{P}_n|\, F} \sum_{c \in \mathcal{P}_n} \sum_{f=1}^{F} w_f \left(\hat{x}^{(j)}_{tcf} - x_{tcf} \right)^2 , \tag{4.7}$$

dove $\mathcal{P}_n$ sono le celle valide della patch 3×3 di n. L'errore di una cella è quindi la media su sé stessa e sulle celle vicine, come nell'articolo, dove l'errore di un nodo è misurato sul suo sottografo. La componente del discriminatore è, come nell'articolo, la differenza fra il giudizio sull'osservazione e quello sul campo generato,

$$s^{(j)}_{D,tn} = D^{(j)}_{\text{reale},tn} - D^{(j)}_{\text{generato},tn}. \tag{4.8}$$

La componente di ricostruzione, media sulle estrazioni,

$$\bar{s}_{G,tn} = \frac{1}{J}\sum_{j=1}^{J} s_{G,tn}^{(j)}, \tag{4.9}$$

è la media degli errori delle singole estrazioni, e non l'errore della ricostruzione media. Per ogni cella e variabile le due quantità differiscono per la varianza delle ricostruzioni:

$$\frac{1}{J}\sum_{j=1}^{J}\left(\hat{x}^{(j)} - x\right)^2 = \left(\bar{\hat{x}} - x\right)^2 + \frac{1}{J}\sum_{j=1}^{J}\left(\hat{x}^{(j)} - \bar{\hat{x}}\right)^2, \qquad \bar{\hat{x}} = \frac{1}{J}\sum_{j=1}^{J}\hat{x}^{(j)}. \tag{4.10}$$

La componente cresce quindi sia quando la ricostruzione si allontana dall'osservazione, sia quando le estrazioni non sono concordi fra loro. Dalle stesse estrazioni si ricava anche la deviazione standard dello score, che misura quanto lo score dipende dalle maschere di dropout; non è una probabilità di anomalia né una stima calibrata dell'incertezza.

4.6.3 Score combinato e score di ricostruzione

Dalla stessa esecuzione sono ricavati due score. Lo *score combinato* è quello dell'articolo. Le due componenti sono riportate su una scala comune con un min–max e sommate con peso unitario, estrazione per estrazione:

$$a_{tn}^{(j)} = \frac{s_{G,tn}^{(j)} - r_{\min}}{r_{\max} - r_{\min}} + \frac{s_{D,tn}^{(j)} - d_{\min}}{d_{\max} - d_{\min}}, \qquad \bar{a}_{tn} = \frac{1}{J}\sum_{j=1}^{J} a_{tn}^{(j)}. \tag{4.11}$$

L'articolo indica che le due componenti sono normalizzate prima della somma, senza specificare come, e il codice degli autori salva le componenti senza combinarle: il min–max è quindi una scelta di questo lavoro. Gli estremi $r_{\min}$, $r_{\max}$, $d_{\min}$ e $d_{\max}$ sono quelli delle due componenti medie sulle estrazioni negli anni di validazione, esclusi i valori segnati come insoliti (Sezione 4.5), e restano fissi per il test: nessuna quantità dello score è stimata sugli anni valutati. I valori del test possono uscire dall'intervallo $[0, 1]$ di ciascuna componente, perché non è applicato un clipping.

Lo *score di ricostruzione* ζ_{tn} è la sola componente $\bar{s}_{G,tn}$, espressa rispetto alla propria climatologia (Sezione 4.7). Quale dei due score usare è studiato nel Capitolo 6, dal comportamento delle due componenti nello spazio e nel tempo.

4.7 Normalizzazione climatologica degli score

Una trasformazione successiva al calcolo degli score esprime ogni score rispetto alla climatologia della stessa cella. Per la cella n, il giorno dell'anno g e l'ora UTC o dell'istante t,

$$\zeta_{tn} = \frac{s_{tn} - \mu^{s}_{nog}}{\sigma^{s}_{nog}}, \tag{4.12}$$

dove s_{tn} è lo score da trasformare, la componente di ricostruzione $\bar{s}_{G,tn}$ o lo score combinato $\bar{a}_{tn}$. Media e deviazione standard sono calcolate con la stessa ricetta della normalizzazione stagionale della Sezione 4.3: sugli score della stessa cella e della stessa ora nei quindici giorni che precedono g e nei quindici che lo seguono, con una finestra che scavalca la fine dell'anno, e con la deviazione standard calcolata attorno alla media lisciata di ciascun giorno. Lo score è uno per cella e non ha la dimensione delle variabili: media e deviazione standard sono due tensori di forma $[8, 366, N]$. Sono stimate negli anni di validazione, esclusi i valori segnati come insoliti (Sezione 4.5), e restano fisse per il test. Non possono essere stimate sugli anni di addestramento, perché su quegli anni il modello ha già visto i dati e il suo errore è più basso di quello su anni nuovi. Quando lo score trasformato serve sugli anni di validazione stessi, per le scelte e per fissare le soglie, media e deviazione standard di un anno y sono calcolate sugli altri quattro anni di validazione, $\mu^{s,(-y)}_{nog}$ e $\sigma^{s,(-y)}_{nog}$: nessun valore entra nella propria climatologia. I gruppi con meno di trenta valori di riferimento o con varianza nulla non ricevono uno score.

Gli score di validazione da cui sono stimate queste quantità sono calcolati con la storia reale degli istanti di validazione, come quelli del test. La sostituzione dei valori insoliti nella storia (Sezione 4.5) serve alla misura con cui si confrontano le configurazioni durante l'addestramento e al passaggio di validazione che chiude l'addestramento, da cui vengono gli estremi dello score combinato; non entra nella climatologia. Una climatologia stimata su errori calcolati da una storia ripulita descriverebbe un errore più basso di quello che il modello commette sul test, dove la storia contiene le condizioni insolite.

Lo scopo è rendere confrontabili celle e stagioni in cui l'errore di ricostruzione ha una grandezza tipica diversa: senza questo passaggio, le segnalazioni si concentrerebbero dove l'errore è grande per natura. La trasformazione applica la stessa idea della normalizzazione stagionale, cioè esprimere un valore rispetto a ciò che è abituale per quella cella, quel periodo dell'anno e quell'ora, ma a un oggetto diverso. La normalizzazione stagionale agisce sui campi in ingresso, prima del modello, ed è stimata sugli anni di addestramento: toglie il ciclo stagionale e giornaliero dei dati, ma non la differenza di prevedibilità fra celle e stagioni. Dove il tempo cambia più rapidamente il generatore sbaglia di più anche su dati standardizzati. La normalizzazione climatologica

agisce sull'errore del generatore, dopo l'addestramento, è stimata sugli anni di validazione e toglie questa seconda differenza senza modificare il detector.

Score finale. Riassumendo, lo score usato nei risultati è lo score di ricostruzione

$$\zeta_{tn} = \frac{\bar{s}_{G,tn} - \mu^{s}_{nog}}{\sigma^{s}_{nog}}, \tag{4.13}$$

con $\bar{s}_{G,tn}$ dell'equazione (4.9): l'errore pesato del generatore, medio sulla patch 3×3 della cella e sulle 20 estrazioni Monte Carlo, riferito ai valori abituali dello stesso errore nella cella, nel periodo dell'anno e nell'ora. Una coppia istante–cella è segnalata quando ζ_{tn} supera la soglia τ, il 95-esimo percentile di ζ sugli anni di validazione.

4.8 Validazione senza etichette

Gli anni di validazione servono a confrontare configurazioni del detector senza usare il test e senza etichette. Il confronto deve misurare quanto bene il modello ricostruisce il tempo normale: le condizioni insolite presenti negli anni di validazione, individuate come nella Sezione 4.5, sono tenute fuori dalle misure.

4.8.1 Distanza fra campi osservati e ricostruiti nello spazio delle componenti principali

La misura usata per confrontare le configurazioni confronta osservazioni e ricostruzioni in uno spazio indipendente dal modello. Lo spazio è ottenuto da un'analisi delle componenti principali dei campi di addestramento: ogni campione è il campo completo di un istante, normalizzato e appiattito su celle e variabili. Sono usati i campi con la quota più bassa di valori insoliti, nello stesso numero per ogni mese, e sono conservate 300 componenti principali: oltre questo numero la varianza spiegata cresce poco, e 300 componenti ne spiegano il 78.8%, contro il 67.4% di 100 componenti. Lo spazio è costruito una sola volta, prima delle esecuzioni, e successivamente soltanto caricato.

I campi di tempo normale sono scelti, non corretti. Sostituire i valori insoliti con il normale stagionale darebbe campi più lisci di qualunque campo osservato, e una distanza calcolata su di essi premierebbe un generatore che ricostruisce campi lisci. Un campo scelto può contenere ancora qualche valore insolito, entro la quota che lo fa rientrare fra i campi normali del suo mese. Per lo stesso motivo il valore da ricostruire, quando è insolito, non è sostituito

ma escluso dalle misure: si sostituisce soltanto la storia da cui il modello parte.

Su questo spazio viene definito un riferimento per la validazione. È formato da $S = 5$ sottoinsiemi fissi e disgiunti di 512 campi normali degli anni di validazione, scelti con lo stesso criterio, dalle coordinate delle loro osservazioni nello spazio e da una banda h pari alla distanza euclidea mediana fra tali coordinate. Anche questo riferimento è fissato prima delle esecuzioni. A ogni epoca, per ciascun sottoinsieme, si calcola la stima non distorta della Maximum Mean Discrepancy [42]

$$\widehat{\mathrm{MMD}}^2 = \frac{1}{n(n-1)} \sum_{i \neq i'} k(x_i, x_{i'}) + \frac{1}{n(n-1)} \sum_{i \neq i'} k(y_i, y_{i'}) - \frac{2}{n^2} \sum_{i,i'} k(x_i, y_{i'}), \tag{4.14}$$

dove x_i sono le coordinate delle osservazioni, y_i quelle delle ricostruzioni del generatore e il kernel è la media di tre RBF,

$$k(a, b) = \frac{1}{3} \sum_{c \in \{0.5,\, 1,\, 2\}} \exp\left(-\frac{\|a - b\|^2}{2(ch)^2} \right). \tag{4.15}$$

Vengono registrate media e varianza della stima sui sottoinsiemi e la media delle ultime cinque epoche, che è la quantità usata per scegliere fra configurazioni. La stima non distorta può assumere valori leggermente negativi. Poiché tutte le esecuzioni confrontate caricano gli stessi riferimenti, le differenze nella misura non dipendono da una nuova stima dello spazio o della banda. Una MMD più bassa indica ricostruzioni più vicine alle osservazioni nello spazio considerato; non misura direttamente la qualità del rilevamento delle anomalie.

4.8.2 Diagnostiche per epoca e misure finali

Al termine di ogni epoca un sottoinsieme fisso della validazione, 32 istanti equispaziati con tutte le celle, viene elaborato con un passaggio deterministico, a dropout spento. Vengono registrate due quantità: la differenza assoluta media fra le attivazioni del penultimo strato del discriminatore sull'osservazione e sulla ricostruzione, e la variazione dello score fra epoche consecutive sulle stesse celle. Queste quantità e la MMD non entrano in una loss, in un aggiornamento dei pesi o negli score; sono calcolate senza gradiente e ripristinando gli stati dei generatori di numeri casuali, così da non alterare la traiettoria dell'addestramento.

Dopo l'ultima epoca, su tutti i valori validi e non segnati della validazione, viene calcolata la componente di ricostruzione media sulle estrazioni Monte

Carlo, riassunta da media, deviazione standard, mediana e 95° percentile. Le stesse estrazioni danno gli estremi delle due componenti usati dallo score combinato.

Capitolo 5

Esperimenti

Il capitolo descrive come il detector del Capitolo 4 è addestrato e valutato sui campi ERA5. La Sezione 5.1 riporta la configurazione fissata e la ricerca dei quattro iperparametri che regolano l'equilibrio fra generatore e discriminatore; la Sezione 5.2 descrive il protocollo di valutazione: che cosa si stima sugli anni di validazione e che cosa si valuta sul test. I risultati, compresi quelli della ricerca, sono nel Capitolo 6.

5.1 Configurazione e ricerca degli iperparametri

La configurazione del detector è fissata, a eccezione di quattro iperparametri che regolano l'equilibrio fra generatore e discriminatore, scelti con una ricerca bayesiana. La Tabella 5.1 riporta gli uni e gli altri, con la sezione del Capitolo 4 che li descrive.

Obiettivo. L'obiettivo della ricerca è la distanza MMD fra campi osservati e ricostruiti nello spazio delle componenti principali (Sezione 4.8), mediata sulle ultime cinque epoche, da minimizzare. Ogni esecuzione è addestrata e misurata sulla validazione, senza calcolare score sul test. Ogni configurazione è addestrata una sola volta, con lo stesso seme per tutte le esecuzioni. Le esecuzioni interrotte perché una loss è diventata non finita non hanno un obiettivo e sono escluse dalla scelta.

Due fasi. La ricerca si è svolta in due fasi. La prima ha usato il controllore bayesiano di Weights & Biases, che stima con un processo gaussiano l'obiettivo in funzione degli iperparametri. Il suo modello usa però una sola scala di

lunghezza per tutti gli iperparametri e non stima il rumore dell'obiettivo; nelle esecuzioni di questo lavoro, su un obiettivo rumoroso, il suo adattamento si fermava al limite dell'intervallo e le proposte erano di fatto casuali. La seconda fase usa la libreria Optuna, con un processo gaussiano che stima una scala per ogni iperparametro e il rumore dell'obiettivo, e riparte dalle esecuzioni della prima fase con lo stesso seme. La ricerca si ferma quando un numero fissato di prove consecutive non abbassa il miglior obiettivo di almeno una soglia prefissata, oppure dopo un numero massimo di prove. È scelta la configurazione con l'obiettivo più basso fra le esecuzioni completate. Le esecuzioni, il loro andamento e la configurazione scelta sono riportati nella Sezione 6.1.

Pesi e calcolo. Del modello scelto si usano i pesi dell'ultima epoca, come nel codice degli autori, che salva i pesi a ogni epoca e valuta quelli dell'ultima [3]: nessuna epoca è scelta in base al risultato. Un'epoca comprende 58384 aggiornamenti per rete, cioè gli istanti di addestramento meno i 56 di contesto del trend, e dura circa 2.4 ore, quindi un'esecuzione completa circa 14 ore e mezza. I modelli sono implementati in PyTorch [43]. I dati sono letti con xarray [44] dai file mensili in formato NetCDF [37]; le tabelle di score sono elaborate con pandas [45]; il Capitolo 6 usa anche SciPy [46]. Tutti i modelli sono addestrati su una scheda NVIDIA RTX PRO 6000 Blackwell.

5.2 Protocollo di valutazione

Che cosa si calcola. Gli score della configurazione scelta sono calcolati sugli anni di validazione 2000–2004 e di test 2005–2025, su tutti gli istanti e tutte le celle: 14616×10611 coppie istante–cella sulla validazione e 61360×10611 sul test, ciascuna con le 20 estrazioni Monte Carlo della Sezione 4.6. In entrambi i periodi le finestre di ingresso contengono la storia reale, compresi i valori insoliti, e i primi istanti prendono il contesto dal periodo precedente (Sezione 3.3).

Che cosa si stima sulla validazione. Le quantità che descrivono il comportamento abituale degli score sono stimate sugli anni di validazione e restano fisse per il test: la climatologia degli score (Sezione 4.7) e la soglia. La soglia di uno score è il 95-esimo percentile dello stesso score sugli anni di validazione,

$$\tau = Q_{0.95}\Big\{\zeta_{tn} \,:\, t \in \text{validazione},\ n = 1, \ldots, N\Big\}, \tag{5.1}$$

calcolato su tutti i valori, una soglia per ciascuno score confrontato. Sul test segnala una quota che può scostarsi dal 5%, ed è riportata nei risultati. Le analisi principali sono ripetute con il 99-esimo percentile, per verificare quanto le conclusioni dipendano dalla soglia (Sezione 6.9). Gli estremi con cui le due componenti dello score combinato sono riportate su una scala comune vengono invece dal passaggio di validazione che chiude l'addestramento, con la storia in cui i valori insoliti sono sostituiti dal normale (Sezioni 4.5 e 4.6).

Score usato e termini di confronto. Lo score del detector è lo score di ricostruzione ζ dell'equazione (4.13). Dalla stessa esecuzione sono calcolati anche la componente del discriminatore e lo score combinato dell'articolo: la scelta di ζ è motivata nel Capitolo 6 dal comportamento delle due componenti nello spazio e nel tempo (Sezioni 6.2–6.5). Non esistono etichette di anomalia: gli anni di test non intervengono né nell'addestramento né nella scelta della configurazione, e il comportamento degli score e il loro confronto con altri metodi sono descritti nel Capitolo 6.

Tabella 5.1: Configurazione del detector su ERA5. Nella parte superiore i valori fissati, nella parte inferiore gli iperparametri della ricerca, con l'intervallo esplorato e il valore della configurazione scelta. Nella distribuzione logaritmica, per esempio, i rapporti 0.5 e 2 sono equidistanti da 1.

Elemento	Valore	Sezione
Anni di addestramento, validazione, test	1980–1999, 2000–2004, 2005–2025	3.3
Unità del campione e batch	Campo intero, un istante per batch	4.2.1
Generatore	ConvGRU a due strati da 32 canali, kernel 3×3; LSTM del trend a due strati da 64	4.2.1
Discriminatore	Patch 3×3; ConvGRU a due strati da 32 canali; strato nascosto da 64	4.2
Finestra recente e trend	16 e 56 passi, cioè 48 e 168 ore	4.3
Codifica temporale	Ora solare locale e posizione nell'anno, per cella	4.3
Normalizzazione dell'ingresso	Rispetto al normale di cella, giorno e ora; retta nel tempo tolta a tre variabili; poi min–max	4.3
Pesi delle variabili	Inversi della variazione quadratica media su 24 ore	4.4
Dropout	0.2, nel generatore e nel discriminatore	4.6
Estrazioni Monte Carlo negli score	20	4.6
Ottimizzatore	Adam, $\beta_1 = 0.9$, $\beta_2 = 0.999$, tasso costante	4.2
Epoche	6	–
Precisione	BF16, pesi in FP32	–
Tasso di apprendimento del generatore	da 10^{-4} a $3 \cdot 10^{-3}$, logaritmica; scelto $4.93 \cdot 10^{-4}$	4.2
Rapporto fra i tassi del discriminatore e del generatore	da 0.25 a 4, logaritmica; scelto 0.951	4.2
Peso di ricostruzione λ_G	da 50 a 2000, logaritmica; scelto 176.6	4.2
Aggiornamenti per batch, n_D:n_G	1:1, 2:1 oppure 1:2; scelto 1:1	4.2

Capitolo 6

Risultati e discussione

Il capitolo riporta e discute i risultati del detector sui campi ERA5, nella configurazione scelta dalla ricerca dei parametri. In assenza di etichette, la domanda centrale è quale parte dello score di STGAN usare, e il comportamento del detector è studiato in più passi. La Sezione 6.1 riguarda la scelta della configurazione. Le Sezioni 6.2–6.5 esaminano le due componenti dello score, del generatore e del discriminatore, nello spazio e nel tempo, e la normalizzazione climatologica; ne risulta che lo score da usare è quello del generatore, normalizzato. La Sezione 6.6 confronta le segnalazioni del detector con quelle di metodi più semplici, la Sezione 6.7 le raggruppa in eventi per tipo e dimensione, la Sezione 6.8 esamina casi specifici, e la Sezione 6.9 verifica quanto i risultati dipendano dalla soglia.

6.1 Ricerca dei parametri

Sezione da scrivere quando la ricerca con Optuna si sarà assestata.

6.2 Correlazione spaziale degli score

Lo score di STGAN somma due componenti, e prima di sceglierne una conviene capire se segnalano le stesse situazioni. Questa sezione e le tre seguenti riguardano gli anni di test 2005–2025 della configurazione scelta: 61360 istanti su 10611 celle. Le grandezze usate sono riassunte nella Tabella 6.1. G e D sono le due componenti dello score, medie sulle 20 estrazioni (Sezione 4.6); D_{reale} e D_{generato} sono le due uscite del discriminatore da cui D è calcolata, e servono nella Sezione 6.5. Il discriminatore è addestrato a dare 1 al campo generato e 0 a quello osservato: un valore alto delle sue uscite significa quindi "giudicato generato", e un valore alto di D, come di G, significa "più insolito".

Tabella 6.1: Le grandezze del capitolo e il significato di un loro valore alto. Tutte sono calcolate per ogni cella e ogni istante.

Grandezza	Che cosa misura	Valore alto
G	errore di ricostruzione del generatore, medio sulla patch 3×3 della cella	osservazione più insolita
D_{reale}	giudizio del discriminatore sull'osservazione, fra 0 e 1	osservazione giudicata generata
D_{generato}	giudizio del discriminatore sulla ricostruzione, fra 0 e 1	ricostruzione giudicata generata
D	$D_{\text{reale}} - D_{\text{generato}}$, la componente del discriminatore	osservazione più insolita

Due score sono confrontati con la correlazione di Pearson, calcolata sui valori, e con quella di Spearman, calcolata sui ranghi e quindi meno sensibile a pochi valori estremi.

G e D ordinano i luoghi in senso opposto. La correlazione spaziale è calcolata in ogni istante sulle celle: vale 1 se i due score ordinano i luoghi allo stesso modo, -1 se li ordinano in modo opposto. Fra G e D è negativa quasi sempre: la correlazione di Spearman vale in media -0.24 ed è negativa nel 99.98% degli istanti (Figura 6.1). Nello stesso istante, quindi, le celle in cui il generatore sbaglia di più sono in genere quelle a cui il discriminatore dà lo score più basso, cioè meno anomalo. La correlazione di Pearson, più sensibile ai valori estremi, è più negativa, con una media di -0.51: il legame opposto è più forte fra i valori più alti di G.

Il legame è più forte d'estate e di giorno. La correlazione di Spearman vale in media -0.28 fra giugno e agosto e -0.21 fra novembre e gennaio; nelle ore del giorno va da -0.29 alle 12 UTC a -0.20 alle 18, alle 21 e alle 3 UTC. Solo in otto giornate, tutte fra la fine di novembre 2019 e l'inizio di gennaio 2020, la media giornaliera della correlazione di Pearson è positiva, con un massimo di 0.21 il 27 dicembre 2019. Il motivo non è stato esaminato.

Un istante tipico. La Figura 6.2 mostra G e D l'8 agosto 2014 alle 3 UTC, l'istante in cui la correlazione di Spearman è uguale alla sua mediana sul test (-0.24). Le celle in cui G è più alto, nel Nord Africa, all'angolo sud-ovest del dominio e all'estremo nord-est, sono in gran parte fra quelle in cui D è più basso. Un secondo istante, quello con la media di G più alta del test, è esaminato nella Sezione 6.5.

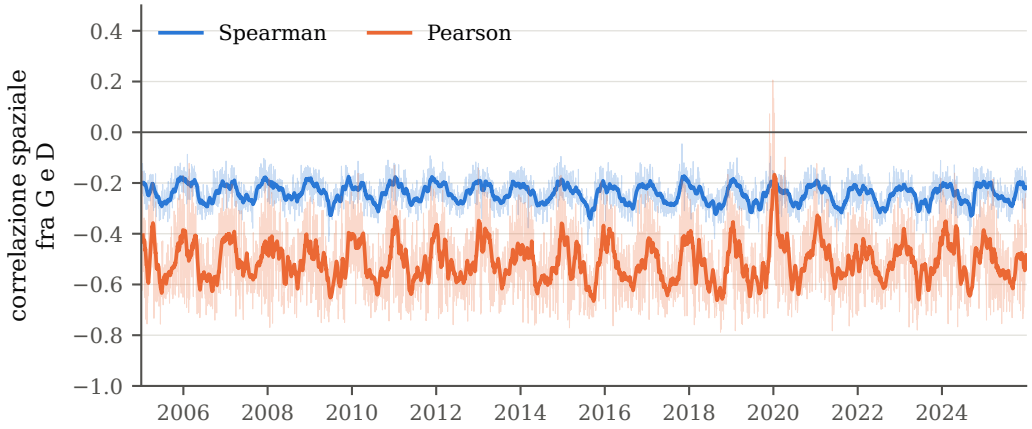


Figura 6.1: Correlazione spaziale fra G e D in ogni istante degli anni di test, calcolata sulle 10611 celle: media giornaliera (linea sottile) e media mobile su 30 giorni (linea spessa). Le due correlazioni restano negative per quasi tutto il periodo.

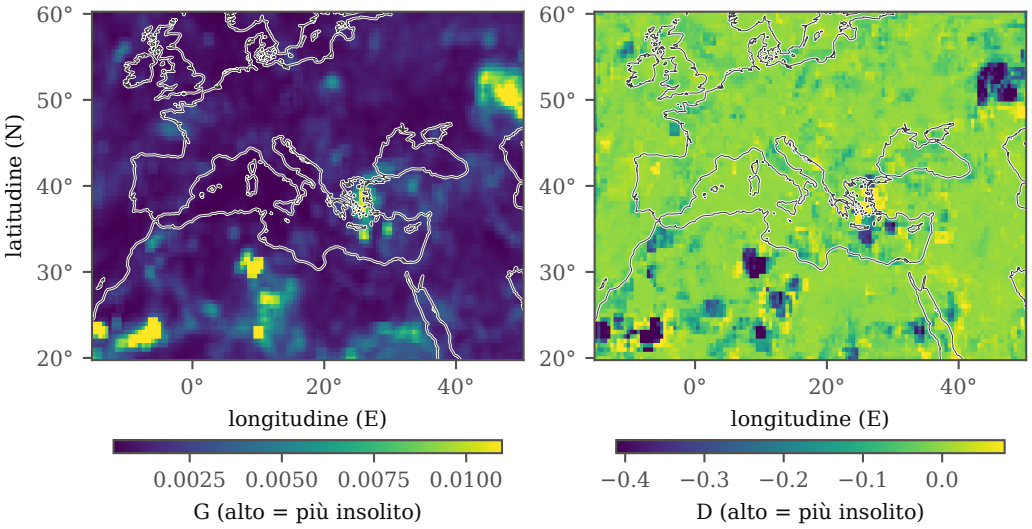


Figura 6.2: G (a sinistra) e D (a destra) l'8 agosto 2014 alle 3 UTC, un istante con la correlazione spaziale di Spearman uguale alla mediana del test. Per entrambi i colori chiari indicano valori più insoliti; ogni mappa ha una propria scala, dal primo al 99-esimo percentile dei suoi valori, quindi i colori non si confrontano fra le due mappe. Le celle con G più alto sono in gran parte fra quelle con D più basso. Linee di costa da Natural Earth.

6.3 Correlazione temporale degli score

La correlazione spaziale dice se i due score segnalano gli stessi luoghi nello stesso istante; quella temporale dice se, in un luogo, salgono e scendono insieme.

Il legame è lo stesso in ogni cella. La correlazione temporale è calcolata in ogni cella sugli istanti: vale 1 se nella cella i due score salgono e scendono insieme. Fra G e D la correlazione di Spearman è negativa in tutte le celle, con mediana -0.25, e quella di Pearson ha mediana -0.51 (Figura 6.3). Il legame è quindi lo stesso nello spazio e nel tempo: quando in una cella il generatore sbaglia di più, D scende. È più forte nel sud del dominio e più debole su parte dell'Europa centrale.

La cornice vicino al bordo è un effetto del modello. Nella mappa si vede una cornice a due celle dal bordo, dove la mediana della correlazione è -0.19, contro -0.25 nelle celle a più di quattro celle dal bordo. Vicino al bordo le convoluzioni del generatore completano il campo con zeri, e il suo errore nelle prime tre celle è più alto del 4–5% rispetto all'interno; il discriminatore legge questa fascia attraverso le patch, e il suo giudizio sulle ricostruzioni ha un piccolo minimo proprio a due celle dal bordo. Le mediane riportate non cambiano.

6.4 Normalizzazione climatologica e distribuzione delle segnalazioni

La normalizzazione climatologica (Sezione 4.7) esprime ogni score rispetto a ciò che è abituale per la stessa cella, lo stesso periodo dell'anno e la stessa ora. Questa sezione verifica che cosa cambia nelle correlazioni e nelle segnalazioni.

L'ordine degli score cambia poco. Dopo la normalizzazione la correlazione di Spearman fra G e D vale in media -0.23 nello spazio e ha mediana -0.23 nel tempo, quasi come prima. Ciascuno score conserva quasi lo stesso ordine: la correlazione di Spearman fra lo score prima e dopo la normalizzazione è 0.92 per G e 0.95 per D.

Le segnalazioni di G diventano quasi uniformi. La normalizzazione cambia invece dove cadono le segnalazioni (Figura 6.4). Un valore è segnalato quando supera la soglia del proprio score, il 95-esimo percentile dello stesso

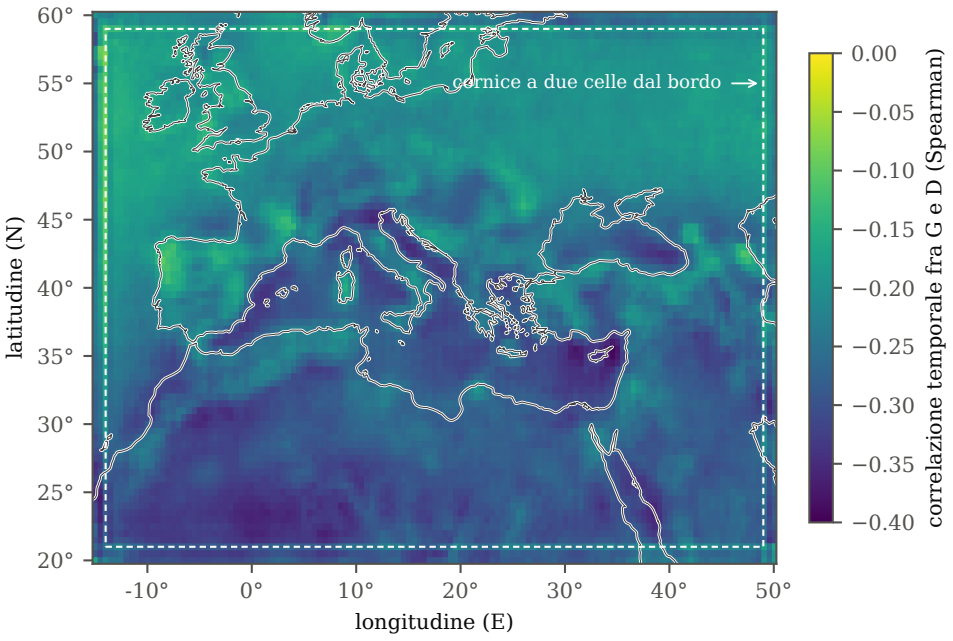


Figura 6.3: Correlazione temporale di Spearman fra G e D in ogni cella, sugli istanti degli anni di test. La correlazione è negativa in tutte le celle, più forte (colori scuri) nel sud del dominio. La linea tratteggiata indica la cornice a due celle dal bordo, un effetto del modello. Linee di costa da Natural Earth.

score sugli anni di validazione (Sezione 5.2); sul test i due score segnalano circa il 5.6% dei valori, un po' più del 5%, perché negli anni di test l'errore del generatore è in media un po' più alto. Senza normalizzazione G segnala soprattutto a sud e in estate, dove il suo errore è alto per natura: la quota va dall'1.9% fra 50° e 60°N in febbraio al 16.3% fra 20° e 30°N in agosto. Con la normalizzazione resta fra il 3.6% e il 7.6% in ogni fascia e in ogni mese. È l'effetto atteso dalla Sezione 4.7: la normalizzazione toglie la differenza di prevedibilità fra luoghi e stagioni. Con una soglia più alta l'effetto è solo parziale (Sezione 6.9).

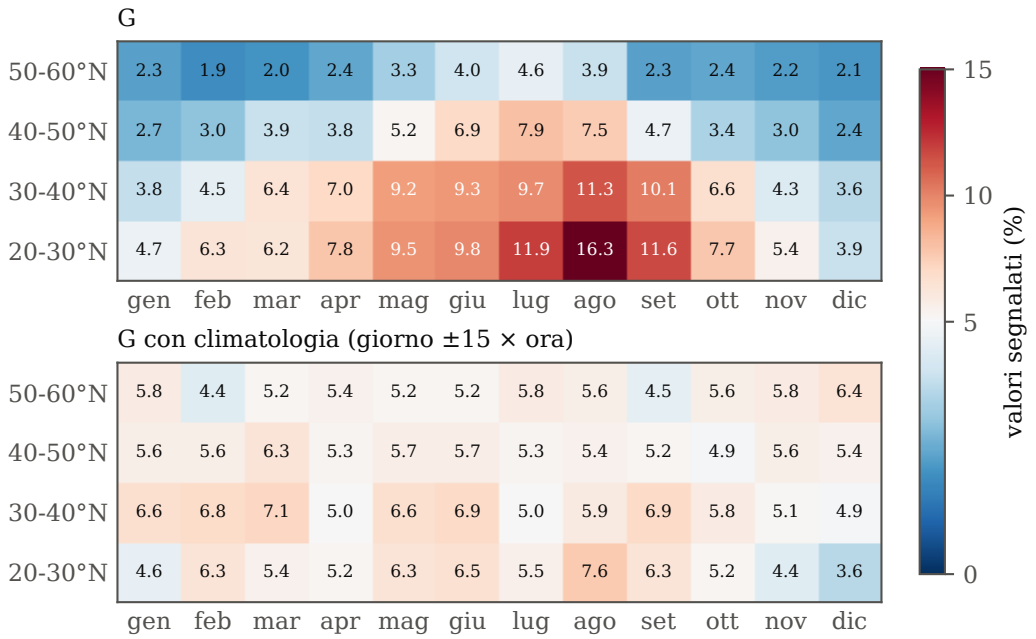


Figura 6.4: Quota dei valori segnalati, per fascia di latitudine e mese, sugli anni di test: G senza (in alto) e con (in basso) la normalizzazione climatologica, calcolata per cella, giorno dell'anno, con una finestra di ±15 giorni, e ora. La soglia di ciascuno score è il suo 95-esimo percentile sugli anni di validazione. La scala dei colori non è lineare: il bianco corrisponde al 5%, il blu a quote minori, il rosso a quote maggiori. Senza normalizzazione le segnalazioni si concentrano a sud e in estate, con la normalizzazione sono distribuite in modo quasi uniforme.

6.5 Il comportamento del discriminatore

Le sezioni precedenti mostrano che D ordina le osservazioni in senso opposto a G. Per capire da dove viene questo comportamento, D va scomposta nei suoi due termini, D_{reale} e D_{generato} (Tabella 6.1): D è alta quando il discriminatore giudica generata l'osservazione più della sua ricostruzione.

D_{generato} cresce con G, D_{reale} no. La correlazione temporale di Spearman fra G e D_{generato} ha mediana 0.26 ed è positiva quasi ovunque (Figura 6.5): dove il generatore sbaglia, il discriminatore riconosce la ricostruzione come generata. Quella fra G e D_{reale} ha mediana 0.02: il giudizio sull'osservazione non segue l'ordine di G. I valori più alti di G cadono però insieme ai valori più bassi di D_{reale}: la correlazione di Pearson, che dà peso ai valori estremi, ha mediana -0.40. La correlazione negativa fra G e D nasce quindi da entrambi i termini: D sottrae il termine che cresce con G a quello che scende quando G è più alto.

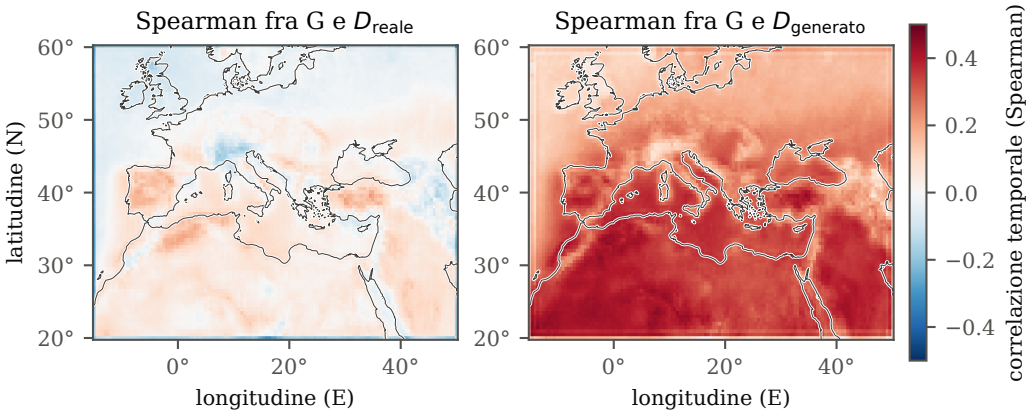


Figura 6.5: Correlazione temporale di Spearman, in ogni cella, fra G e il giudizio del discriminatore sull'osservazione, D_{reale} (a sinistra), e sulla ricostruzione, D_{generato} (a destra), sugli anni di test. Il rosso indica che i due crescono insieme. D_{generato} cresce con G quasi ovunque, D_{reale} non ne segue l'ordine. Linee di costa da Natural Earth.

Gli eventi di G. Le correlazioni riguardano tutti i valori. Per vedere che cosa fa il discriminatore proprio dove G segnala, gli score sono letti attorno agli eventi di G. Un evento è un insieme di valori di G con la normalizzazione climatologica sopra la sua soglia, collegati nello spazio e nel tempo: due valori fanno parte dello stesso evento se in un istante le loro celle si toccano, anche

in diagonale, o se sono la stessa cella in due istanti consecutivi. Sugli anni di test risultano 754692 eventi, con 36.7 milioni di valori in tutto, in media circa 49 valori per evento.

Le zone e la misura. In ogni istante le celle sono divise in tre zone (Figura 6.6): il *nucleo*, le celle di un evento; il *contorno*, le otto celle attorno a una cella del nucleo, le stesse della patch 3×3 letta dal discriminatore, escluse quelle del nucleo; e la zona *lontana*, le celle a più di tre celle da ogni nucleo. Le celle intermedie non sono considerate. Nucleo e contorno sono definiti dalle sole segnalazioni di G: indicano dove G segnala, non dove il tempo è davvero insolito, che senza un riferimento esterno non si può stabilire. In ciascuna zona ogni score è riassunto dal suo *percentile mediano*: per ogni valore si calcola la sua posizione fra tutti i valori dello stesso score sul test, da 0 (il più basso) a 100 (il più alto), e se ne prende la mediana. In una zona senza legame con gli eventi il percentile mediano sarebbe vicino a 50.

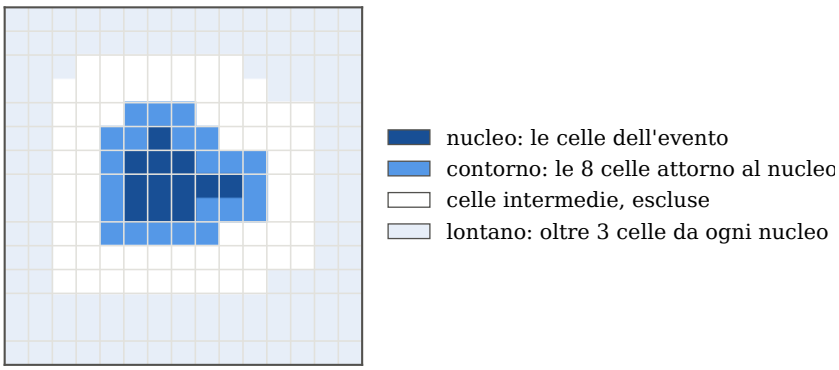


Figura 6.6: Le tre zone attorno a un evento, in un istante, su una porzione della griglia: il nucleo, il contorno, le celle intermedie escluse e la zona lontana. Ogni quadrato è una cella.

Dove G segnala, il discriminatore giudica l'osservazione più reale. La Figura 6.7 riporta il risultato. G senza normalizzazione ha un percentile mediano di 97 nel nucleo, di 88 nel contorno e di 39 lontano dagli eventi. Questi valori servono da riferimento e non sono un risultato: nel nucleo G è alto per costruzione, e nel contorno lo è in parte perché lo score di una cella è l'errore medio sulla sua patch 3×3, che contiene celle del nucleo. In parte vale lo stesso per D_{generato}, che legge la stessa patch: è alto nel nucleo e nel contorno, con mediane di 78 e 73. D_{reale} fa il contrario, e questo non è un effetto della definizione delle zone: nel nucleo ha una mediana di 16, cioè il

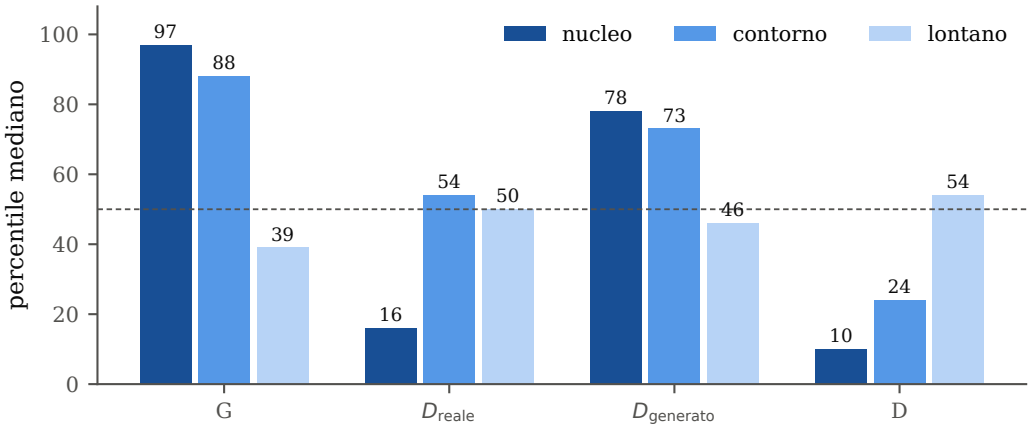


Figura 6.7: Percentile mediano di G senza normalizzazione, di D_{reale}, di D_{generato} e di D nel nucleo degli eventi di G con la normalizzazione climatologica, nel loro contorno e lontano da essi, sugli anni di test. La linea tratteggiata indica 50, il valore atteso senza legame con gli eventi. G serve da riferimento: è alto nel nucleo per costruzione. Nel nucleo D_{reale} è basso e D_{generato} alto, e D scende al percentile 10.

discriminatore giudica le osservazioni segnalate da G più reali del consueto; nel contorno e lontano torna intorno a 50. Il giudizio non è però uniforme: il 14% dei valori del nucleo supera la soglia di D_{reale} fissata sulla validazione, contro il 3.5% lontano dagli eventi, quindi una minoranza dei valori segnalati da G è giudicata generata. Nella componente D i due effetti si sommano e la mediana nel nucleo scende a 10: il discriminatore pone i valori segnalati da G fra i più normali del test. Con una soglia più alta il comportamento è lo stesso e più marcato (Sezione 6.9).

Un esempio: l'istante con G più alto. La Figura 6.8 mostra i termini il 30 agosto 2024 alle 12 UTC, l'istante con la media di G più alta del test. Sulla fascia del Nord Africa in cui G è alto, e su un'area più ampia attorno, D_{reale} è vicino a zero e D_{generato} è al massimo: il discriminatore giudica reale l'osservazione e generata la ricostruzione, e la loro differenza porta D ai valori più bassi del dominio.

Le ricostruzioni sono più lisce, e il discriminatore lo riconosce. Una possibile spiegazione è che il discriminatore riconosca le ricostruzioni dal loro aspetto più liscio. In letteratura i modelli addestrati con un errore quadratico, come in parte il generatore della tesi, producono campi troppo regolari e smussano gli estremi [21, 22, 27]. L'ipotesi è verificata su 240 istanti del test,

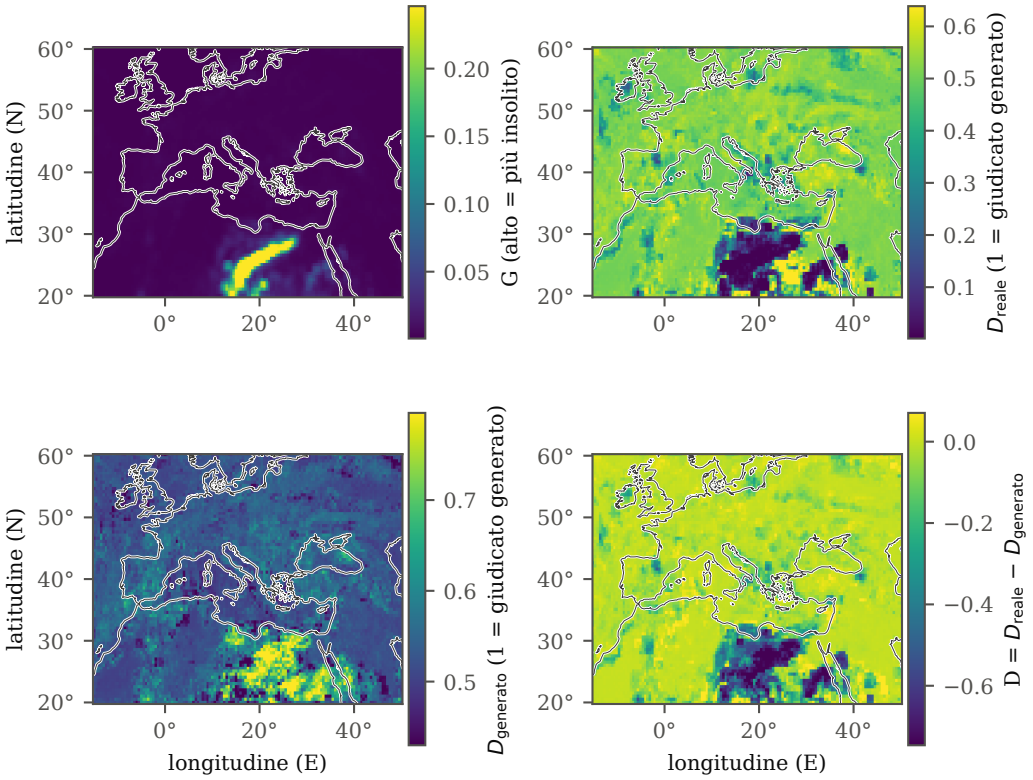


Figura 6.8: G, D_{reale}, D_{generato} e D il 30 agosto 2024 alle 12 UTC, l'istante con la media di G più alta degli anni di test. Ogni mappa ha una propria scala, dal primo al 99-esimo percentile dei suoi valori. Dove G è alto (in chiaro), D_{reale} è vicino a zero e D_{generato} è al massimo, e D è al minimo. Linee di costa da Natural Earth.

distribuiti su tutte le ore (Tabella 6.2). La rugosità di un campo è la differenza quadratica media fra celle adiacenti, e un campo è lisciato sostituendo ogni cella con la media della sua patch 3×3. Per confrontare i campi con lo stesso giudizio, la verifica usa il modello senza dropout: con il dropout attivo il giudizio cambierebbe con la maschera estratta. Le ricostruzioni sono meno rugose delle osservazioni in tutti gli istanti, con un rapporto mediano di 0.86. Lisciando l'osservazione, il discriminatore la giudica più generata nell'89% delle celle, con un aumento medio di 0.014; nelle celle con il 5% più alto di G l'aumento riguarda il 94% delle celle e vale in media 0.099. L'osservazione lisciata gli appare in media generata quanto una ricostruzione. Le celle in cui G è alto tendono a essere quelle in cui il campo è più rugoso: la correlazione di Spearman fra la rugosità locale e G ha mediana 0.50. La rugosità locale da sola non ordina però il giudizio sulle osservazioni, con una correlazione mediana di 0.03: la levigatezza è un indizio che il discriminatore usa, non l'unico. Il lisciamento, inoltre, riduce anche i valori più estremi del campo, e la verifica non separa i due effetti.

Tabella 6.2: Rugosità e giudizio medio del discriminatore su quattro campi, mediane su 240 istanti degli anni di test, con il modello senza dropout. Un giudizio più alto significa "più generato".

Campo	Rugosità	Giudizio del discriminatore
Osservazione	0.00087	0.512
Ricostruzione	0.00074	0.522
Osservazione lisciata	0.00022	0.526
Ricostruzione lisciata	0.00017	0.533

Sintesi. Il discriminatore distingue bene le ricostruzioni dalle osservazioni proprio dove il generatore sbaglia, ma non ordina come insoliti i valori che G segnala: nel nucleo degli eventi di G li giudica più reali del consueto. D, che sottrae il giudizio sulla ricostruzione a quello sull'osservazione, va quindi nella direzione opposta a G proprio dove G segnala. Una parte del motivo è la levigatezza: le ricostruzioni sono più lisce, il discriminatore lo riconosce, e un campo osservato rugoso, come quelli in cui G segnala, gli appare reale. Anche in letteratura il termine del discriminatore, preso da solo, rileva meno di quello di ricostruzione: in AnoGAN l'area sotto la curva ROC è 0.74 contro 0.88 (Sezione 2.1.1), su immagini e con un discriminatore usato in modo diverso. Per questi motivi le sezioni seguenti usano lo score di ricostruzione, cioè G con la normalizzazione climatologica: sommare a G la componente

del discriminatore, come fa STGAN, aggiungerebbe un termine che dove G segnala va nella direzione opposta.

6.6 Confronto con metodi semplici e modelli poco profondi

Sezione da scrivere con la run finale.

6.7 Eventi per tipo e dimensione

Sezione da scrivere con la run finale.

6.8 Casi specifici

Sezione da scrivere con la run finale.

6.9 Sensibilità alla soglia

Tutti i risultati precedenti usano la soglia del 95-esimo percentile degli score di validazione, che sul test segnala poco più del 5% dei valori (il 5.6% per lo score di ricostruzione, Sezione 6.4). È una scelta convenzionale, non ottimizzata. Questa sezione ripete le analisi con il 99-esimo percentile, cioè segnalando circa l'1% dei valori, stimato anch'esso sugli anni di validazione, per verificare quanto le conclusioni dipendano dalla soglia (Tabella 6.3).

La normalizzazione climatologica nella coda. Con la soglia più alta la normalizzazione riduce ancora molto le differenze fra luoghi e stagioni, ma non le annulla: resta un eccesso di segnalazioni a sud, dove la quota media è circa il doppio di quella a nord. La normalizzazione allinea media e deviazione standard dell'errore di ogni cella, non la frequenza dei suoi valori più estremi; con il 5% questa differenza si vede appena, con l'1% sì.

Il comportamento del discriminatore. Con la soglia più alta gli eventi sono meno della metà, e il comportamento del discriminatore è lo stesso e più marcato. Nel nucleo D_{reale} e D scendono al percentile 2. Anche nel contorno D_{reale} diventa basso: con la soglia più alta gli eventi sono più estremi, e anche le celle attorno sono fra i valori più alti di G. Il gruppo più piccolo per tipo e dimensione contiene ancora 78 eventi.

Tabella 6.3: Le analisi delle sezioni precedenti con la soglia al 95-esimo e al 99-esimo percentile degli score di validazione, sugli anni di test. Lo scarto relativo è lo scarto medio delle quote per fascia di latitudine e mese dalla loro media, diviso per la media.

Analisi	Misura	95-esimo	99-esimo
Quota per luogo (Sez. 6.4)	G, intervallo fra fasce e mesi	1.9–16.3%	0.2–5.1%
	G con climatologia, intervallo	3.6–7.6%	0.6–2.5%
	scarto relativo, G → G con climatologia	0.47 → 0.11	0.77 → 0.32
Zone degli eventi (Sez. 6.5)	eventi di G con climatologia	754692	296199
	D_{reale} nel nucleo, percentile mediano	16	2
	D_{reale} nel contorno, percentile mediano	54	13
	D nel nucleo, percentile mediano	10	2
Confronti (Sez. 6.6)	da completare		

Confronti con metodi semplici. Da scrivere con i risultati della Sezione 6.6.

Sintesi. Le conclusioni sul discriminatore non dipendono dalla soglia, e con una soglia più alta diventano più nette. L'effetto della normalizzazione climatologica dipende invece dalla soglia: è quasi completo con il 5%, solo parziale con l'1%.

Capitolo 7

Conclusioni e sviluppi futuri

7.1 Il problema affrontato

7.2 Sintesi dei risultati

7.3 Sviluppi futuri

Il primo sviluppo è ripetere la configurazione scelta con più semi, per avere un riferimento con cui leggere le differenze fra configurazioni.

Il secondo riguarda il protocollo: aggiornare periodicamente soglie e normalizzazione climatologica su una finestra di anni recenti, invece di tenerle fisse dalla validazione, ridurrebbe l'effetto della deriva del clima sulla quota di osservazioni segnalate.

Il terzo riguarda la valutazione. Casi studio su eventi documentati, scelti con fonti meteorologiche indipendenti, mostrerebbero che cosa il detector segnala in situazioni note; un catalogo esterno di eventi su tutto il dominio, o anomalie inserite in posizioni note, darebbe una misura del richiamo, che in questa tesi manca.

Il quarto riguarda l'incertezza dello score. La dispersione potrebbe essere confrontata con l'errore effettivo del generatore, per verificare se può essere usata come misura di incertezza. I metodi basati su equazioni differenziali stocastiche, impiegati nel lavoro preliminare sul previsore, potrebbero inoltre essere applicati al detector: richiedono di aggiungere a STGAN una rete di diffusione, una modifica che questa tesi ha evitato per restare vicina all'architettura dell'articolo.

Ritorno alla previsione fotovoltaica. Il lavoro è partito dalla previsione della produzione fotovoltaica sui dati PVGIS, ed è passato ai campi ERA5

perché quei dati non permettevano di riconoscere condizioni meteorologiche insolite di tipo generale. Il detector può ora essere riportato a quel problema in più modi. Il primo passo è allineare i due insiemi di dati: le località PVGIS, su un reticolo di 5 km, ricadono in poche decine di celle ERA5 di 0.5°, e lo score, calcolato ogni tre ore, va riportato alle ore del previsore. Con questo allineamento le segnalazioni del detector possono servire a valutare il previsore separatamente nelle condizioni normali e in quelle insolite, misurando se l'errore cresce e se gli intervalli restano affidabili quando il detector segnala un'anomalia. Possono servire poi all'addestramento, per escludere dal training le finestre segnalate, secondo il protocollo di SDE U-Net, oppure per dare loro un peso diverso. Lo score può infine entrare nel previsore come ingresso aggiuntivo, oppure regolare l'ampiezza degli intervalli, allargandoli quando le condizioni sono insolite. In ciascun caso la verifica più diretta sarebbe sulle misure di impianti reali disponibili per il 2019, l'anno di test del lavoro preliminare.

Bibliografia

[1] J. Antonanzas et al. «Review of photovoltaic power forecasting». In: *Solar Energy* 136 (2016), pp. 78–111. DOI: 10.1016/j.solener.2016.06.069.

[2] Hans Hersbach et al. «The ERA5 global reanalysis». In: *Quarterly Journal of the Royal Meteorological Society* 146.730 (2020), pp. 1999–2049. DOI: 10.1002/qj.3803.

[3] Leyan Deng et al. «Graph Convolutional Adversarial Networks for Spatiotemporal Anomaly Detection». In: *IEEE Transactions on Neural Networks and Learning Systems* 33.6 (2022), pp. 2416–2428. DOI: 10.1109/TNNLS.2021.3136171.

[4] Manish Gupta et al. «Outlier Detection for Temporal Data: A Survey». In: *IEEE Transactions on Knowledge and Data Engineering* 26.9 (2014), pp. 2250–2267. DOI: 10.1109/TKDE.2013.184.

[5] Zahra Zamanzadeh Darban et al. «Deep Learning for Time Series Anomaly Detection: A Survey». In: *ACM Computing Surveys* 57.1 (2024), pp. 1–42. DOI: 10.1145/3691338.

[6] Xingjian Wu et al. «CATCH: Channel-Aware Multivariate Time Series Anomaly Detection via Frequency Patching». In: *International Conference on Learning Representations (ICLR)*. 2025. arXiv: 2410.12261.

[7] Sarah Alnegheimish et al. «M^{2}AD: Multi-Sensor Multi-System Anomaly Detection through Global Scoring and Calibrated Thresholding». In: *Proceedings of the 28th International Conference on Artificial Intelligence and Statistics*. Vol. 258. Proceedings of Machine Learning Research. PMLR, 2025, pp. 4384–4392.

[8] Pankaj Malhotra et al. *LSTM-based Encoder-Decoder for Multi-sensor Anomaly Detection*. Presentato all'ICML 2016 Anomaly Detection Workshop. 2016. arXiv: 1607.00148.

[9] Kyle Hundman et al. «Detecting Spacecraft Anomalies Using LSTMs and Nonparametric Dynamic Thresholding». In: *Proceedings of the 24th ACM SIGKDD International Conference on Knowledge Discovery & Data Mining*. ACM, 2018, pp. 387–395. DOI: 10.1145/3219819.3219845.

[10] Jiehui Xu et al. «Anomaly Transformer: Time Series Anomaly Detection with Association Discrepancy». In: *International Conference on Learning Representations (ICLR)*. 2022. arXiv: 2110.02642.

[11] Ailin Deng e Bryan Hooi. «Graph Neural Network-Based Anomaly Detection in Multivariate Time Series». In: *Proceedings of the AAAI Conference on Artificial Intelligence*. Vol. 35. 5. 2021, pp. 4027–4035. DOI: 10.1609/aaai.v35i5.16523.

[12] Qihang Zhou et al. «Label-Free Multivariate Time Series Anomaly Detection». In: *IEEE Transactions on Knowledge and Data Engineering* 36.7 (2024), pp. 3166–3179. DOI: 10.1109/TKDE.2024.3349613. arXiv: 2312.11549.

[13] Ian J. Goodfellow et al. «Generative Adversarial Nets». In: *Advances in Neural Information Processing Systems*. Vol. 27. Curran Associates, Inc., 2014. arXiv: 1406.2661.

[14] Thomas Schlegl et al. «Unsupervised Anomaly Detection with Generative Adversarial Networks to Guide Marker Discovery». In: *Information Processing in Medical Imaging (IPMI 2017)*. Vol. 10265. Lecture Notes in Computer Science. Springer, 2017, pp. 146–157. DOI: 10.1007/978-3-319-59050-9_12.

[15] Dan Li et al. «MAD-GAN: Multivariate Anomaly Detection for Time Series Data with Generative Adversarial Networks». In: *Artificial Neural Networks and Machine Learning – ICANN 2019: Text and Time Series*. Vol. 11730. Lecture Notes in Computer Science. Springer, 2019, pp. 703–716. DOI: 10.1007/978-3-030-30490-4_56.

[16] Renjie Wu e Eamonn J. Keogh. «Current Time Series Anomaly Detection Benchmarks are Flawed and are Creating the Illusion of Progress». In: *IEEE Transactions on Knowledge and Data Engineering* (2021). DOI: 10.1109/TKDE.2021.3112126. arXiv: 2009.13807.

[17] Qinghua Liu e John Paparrizos. «The Elephant in the Room: Towards A Reliable Time-Series Anomaly Detection Benchmark». In: *Advances in Neural Information Processing Systems 37 (NeurIPS 2024), Datasets and Benchmarks Track*. Vol. 37. 2024, pp. 108231–108261. DOI: 10.52202/079017-3437.

[18] Shashi Shekhar, Chang-Tien Lu e Pusheng Zhang. «Detecting Graph-Based Spatial Outliers: Algorithms and Applications (A Summary of Results)». In: *Proceedings of the Seventh ACM SIGKDD International Conference on Knowledge Discovery and Data Mining (KDD '01)*. San Francisco, CA, USA: ACM, 2001, pp. 371–376.

[19] Dechang Chen et al. «On Detecting Spatial Outliers». In: *GeoInformatica* 12 (2008), pp. 455–475. DOI: 10.1007/s10707-007-0038-8.

[20] Peter Bauer, Alan Thorpe e Gilbert Brunet. «The quiet revolution of numerical weather prediction». In: *Nature* 525.7567 (2015), pp. 47–55. DOI: 10.1038/nature14956.

[21] Stephan Rasp et al. «WeatherBench: A Benchmark Data Set for Data-Driven Weather Forecasting». In: *Journal of Advances in Modeling Earth Systems* 12.11 (2020), e2020MS002203. DOI: 10.1029/2020MS002203.

[22] Remi Lam et al. «Learning skillful medium-range global weather forecasting». In: *Science* 382.6677 (2023), pp. 1416–1421. DOI: 10.1126/science.adi2336.

[23] Yunjie Liu et al. *Application of Deep Convolutional Neural Networks for Detecting Extreme Weather in Climate Datasets*. 2016. arXiv: 1605.01156.

[24] Evan Racah et al. «ExtremeWeather: A large-scale climate dataset for semi-supervised detection, localization, and understanding of extreme weather events». In: *Advances in Neural Information Processing Systems*. Vol. 30. Curran Associates, Inc., 2017.

[25] Prabhat et al. «ClimateNet: an expert-labeled open dataset and deep learning architecture for enabling high-precision analyses of extreme weather». In: *Geoscientific Model Development* 14 (2021), pp. 107–124. DOI: 10.5194/gmd-14-107-2021.

[26] Pablo G. Zaninelli et al. «AI-Based Anomaly Detection for Extreme Event Attribution: An Analysis of European Heatwaves». In: *Earth Systems and Environment* 10.8 (2026), pp. 9949–9969. DOI: 10.1007/s41748-026-01122-6.

[27] Aytaç Paçal et al. «A multivariate analysis of atmospheric drivers for Western European heatwaves». In: *Earth System Dynamics* 17 (2026), pp. 955–986. DOI: 10.5194/esd-17-955-2026.

[28] Bing Yu, Haoteng Yin e Zhanxing Zhu. «Spatio-Temporal Graph Convolutional Networks: A Deep Learning Framework for Traffic Forecasting». In: *Proceedings of the Twenty-Seventh International Joint Conference on Artificial Intelligence (IJCAI-18)*. 2018, pp. 3634–3640. DOI: 10.24963/ijcai.2018/505.

[29] Kyunghyun Cho et al. «Learning Phrase Representations using RNN Encoder–Decoder for Statistical Machine Translation». In: *Proceedings of the 2014 Conference on Empirical Methods in Natural Language Processing (EMNLP)*. Association for Computational Linguistics, 2014, pp. 1724–1734. DOI: 10.3115/v1/D14-1179. arXiv: 1406.1078.

[30] Xingjian Shi et al. «Convolutional LSTM Network: A Machine Learning Approach for Precipitation Nowcasting». In: *Advances in Neural Information Processing Systems*. Vol. 28. Curran Associates, Inc., 2015. arXiv: 1506.04214.

[31] Nicolas Ballas et al. «Delving Deeper into Convolutional Networks for Learning Video Representations». In: *International Conference on Learning Representations (ICLR)*. 2016. arXiv: 1511.06432.

[32] Moloud Abdar et al. «A review of uncertainty quantification in deep learning: Techniques, applications and challenges». In: *Information Fusion* 76 (2021), pp. 243–297. DOI: 10.1016/j.inffus.2021.05.008.

[33] Yarin Gal e Zoubin Ghahramani. «Dropout as a Bayesian Approximation: Representing Model Uncertainty in Deep Learning». In: *Proceedings of the 33rd International Conference on Machine Learning*. Vol. 48. Proceedings of Machine Learning Research. PMLR, 2016, pp. 1050–1059. arXiv: 1506.02142.

[34] Balaji Lakshminarayanan, Alexander Pritzel e Charles Blundell. «Simple and Scalable Predictive Uncertainty Estimation using Deep Ensembles». In: *Advances in Neural Information Processing Systems*. Vol. 30. Curran Associates, Inc., 2017. arXiv: 1612.01474.

[35] Lingkai Kong, Jimeng Sun e Chao Zhang. «SDE-Net: Equipping Deep Neural Networks with Uncertainty Estimates». In: *Proceedings of the 37th International Conference on Machine Learning*. Vol. 119. Proceedings of Machine Learning Research. PMLR, 2020, pp. 5405–5415. arXiv: 2008.10546.

[36] Simone Monaco et al. «Uncertainty-aware methods for enhancing rainfall prediction with deep-learning based post-processing segmentation». In: *Computers & Geosciences* 205 (2025), p. 105992. DOI: 10.1016/j.cageo.2025.105992.

[37] Russ Rew e Glenn Davis. «NetCDF: An Interface for Scientific Data Access». In: *IEEE Computer Graphics and Applications* 10.4 (1990), pp. 76–82. DOI: 10.1109/38.56302.

[38] Charles R. Harris et al. «Array Programming with NumPy». In: *Nature* 585.7825 (2020), pp. 357–362. DOI: 10.1038/s41586-020-2649-2.

[39] Thomas Huld, Richard Müller e Attilio Gambardella. «A new solar radiation database for estimating PV performance in Europe and Africa». In: *Solar Energy* 86.6 (2012), pp. 1803–1815. DOI: 10.1016/j.solener.2012.03.006.

[40] Sepp Hochreiter e Jürgen Schmidhuber. «Long Short-Term Memory». In: *Neural Computation* 9.8 (1997), pp. 1735–1780. DOI: 10.1162/neco.1997.9.8.1735.

[41] Diederik P. Kingma e Jimmy Ba. «Adam: A Method for Stochastic Optimization». In: *International Conference on Learning Representations (ICLR)*. 2015. arXiv: 1412.6980.

[42] Arthur Gretton et al. «A Kernel Two-Sample Test». In: *Journal of Machine Learning Research* 13.25 (2012), pp. 723–773.

[43] Adam Paszke et al. «PyTorch: An Imperative Style, High-Performance Deep Learning Library». In: *Advances in Neural Information Processing Systems*. Vol. 32. Curran Associates, Inc., 2019.

[44] Stephan Hoyer e Joe Hamman. «xarray: N-D labeled Arrays and Datasets in Python». In: *Journal of Open Research Software* 5.1 (2017), p. 10. DOI: 10.5334/jors.148.

[45] Wes McKinney. «Data Structures for Statistical Computing in Python». In: *Proceedings of the 9th Python in Science Conference*. 2010, pp. 56–61. DOI: 10.25080/Majora-92bf1922-00a.

[46] Pauli Virtanen et al. «SciPy 1.0: Fundamental Algorithms for Scientific Computing in Python». In: *Nature Methods* 17.3 (2020), pp. 261–272. DOI: 10.1038/s41592-019-0686-2.