Politecnico di Torino

Laurea Magistrale in Computer Engineering – Artificial Intelligence and Data Analytics

A.A. 2025/2026

Sessione di laurea [mese e anno]

[Titolo della tesi]

Relatore:
Simone Monaco

Candidato:
Alberto Pedalino

Indice

Elenco delle figure **iv**

1 Introduzione **1**
1.1 Contesto e motivazioni 1
1.2 Il problema: anomalie meteorologiche senza etichette 1
1.3 Approccio proposto 2
1.4 Obiettivi e contributi della tesi 3
1.5 Organizzazione del documento 3

2 Fondamenti teorici e stato dell'arte **4**
2.1 Rilevamento di anomalie in serie multivariate e spazio-temporali 4
2.1.1 MTGFlow 5
2.1.2 Reti generative avversarie per il rilevamento di anomalie 6
2.1.3 STGAN 7
2.1.4 Alternative considerate: CATCH e M2AD 9
2.2 Contesto spaziale su griglie e grafi 10
2.2.1 Unità ricorrenti convoluzionali 10
2.2.2 Reti su grafo e Graph Attention Network 11
2.2.3 Dall'articolo alla tesi: le varianti di STGAN 12
2.3 Quantificazione dell'incertezza 13
2.3.1 Dropout Monte Carlo e Deep Ensemble 13
2.3.2 Equazioni differenziali stocastiche neurali 14
2.3.3 SDE-Net 15
2.3.4 SDE U-Net 16
2.4 Lavoro preliminare sui dati PVGIS 17
2.5 Posizionamento del lavoro 18
2.5.1 Il contributo sostenuto 18
2.5.2 Confronto dei detector esaminati 18

3 Dati e preprocessing **20**
3.1 Campi ERA5, allineamento e celle valide 20
3.2 Anni di addestramento, di validazione e di test 22

4 Metodologia **24**
4.1 Architettura e addestramento avversario 24
4.1.1 Generatore ConvGRU sul campo intero e celle assenti . 24
4.1.2 Discriminatore locale 25
4.1.3 Obiettivi di addestramento 26
4.2 Ingresso: finestra recente, codifica temporale e normalizzazione stagionale 27
4.2.1 Finestra recente e trend 27
4.2.2 Codifica temporale ciclica 27
4.2.3 Normalizzazione stagionale 27
4.3 Pesi delle variabili nell'errore di ricostruzione 29
4.4 Dropout Monte Carlo nelle due reti e score 29
4.4.1 Dropout nel generatore e nel discriminatore 29
4.4.2 Campioni Monte Carlo e componenti dello score 30
4.4.3 Score combinato e score di ricostruzione 31
4.4.4 Dispersione 31
4.5 Normalizzazione climatologica degli score 32
4.6 Validazione senza etichette 32
4.6.1 Valori insoliti della validazione 32
4.6.2 Distanza fra campi osservati e ricostruiti nello spazio delle componenti principali 33
4.6.3 Diagnostiche per epoca e misure finali 34
4.7 Eventi geografici 34
4.7.1 Soglia, morfologia e cluster spaziali 35
4.7.2 Collegamento temporale, separazioni e fusioni 35
4.8 Variante del generatore con attenzione su grafo 36

5 Esperimenti **38**
5.1 Evoluzione del detector 38
5.1.1 STGAN sui dati PVGIS 38
5.1.2 Dalla patch al campo intero 40
5.1.3 Il discriminatore e il dropout del generatore 41
5.1.4 Dalla configurazione di base a quella adattata 41
5.1.5 Validazione di tempo normale e dropout nel discriminatore 43
5.2 Configurazioni di addestramento 43
5.3 Protocollo di valutazione 45
5.4 Metriche 46

5.5 Rilevatori di confronto senza modello 46

6 Risultati e discussione **48**
6.1 Contributo dei componenti 48
6.2 Ricerca dei parametri 49
6.3 Confronto con i rilevatori senza modello 49
6.4 Conferma dalle stazioni 50
6.5 Anticipo 51
6.6 Estensione delle perturbazioni 52
6.7 Incertezza Monte Carlo 53
6.8 Scelta dello score e dei pesi delle variabili 53
6.9 Limiti dei risultati 55

7 Conclusioni e sviluppi futuri **56**
7.1 Il problema affrontato 56
7.2 Sintesi dei risultati 56
7.3 Limiti dello studio 56
7.4 Sviluppi futuri 57

Bibliografia **58**

Elenco delle figure

2.1 Schema di STGAN. Il generatore combina tre moduli e produce la stima $\hat{X}_{v,t}$, che sostituisce l'ultimo elemento della sequenza reale; il discriminatore valuta entrambe le sequenze. Lo score somma l'errore di previsione e la differenza fra le due uscite del discriminatore. Ridisegnato a partire da Deng et al. [3]. . . 7

2.2 Intorno di una cella nelle due varianti. A sinistra la convoluzione assegna a ogni vicino un peso legato alla sua posizione. A destra l'attenzione su grafo assegna a ogni arco un coefficiente α_{ij} che dipende dalle feature dei nodi collegati: lo spessore delle frecce ne rappresenta un esempio. 13

2.3 Cinque traiettorie di un'equazione differenziale stocastica lineare con lo stesso drift e due valori della diffusione, integrate con lo schema di Euler–Maruyama. La dispersione fra le traiettorie è la quantità da cui SDE-Net ricava l'incertezza epistemica. Simulazione illustrativa sul modello della figura analoga di Kong et al. [16]; non è un risultato della tesi. 15

3.1 Dominio dei campi ERA5: 81×131 celle di $0.5°$, fra $20°$ e $60°$ di latitudine nord e fra $15°$ di longitudine ovest e $50°$ di longitudine est. Il rettangolo indica il Piemonte, la regione dei dati del lavoro preliminare della Sezione 2.4. Linee di costa da Natural Earth. 22

4.1 Dagli score agli eventi geografici, su un esempio illustrativo. Gli score di un istante sono riportati sulla griglia; le celle sopra soglia formano una maschera, da cui apertura e chiusura rimuovono le celle isolate e le sporgenze; le celle rimaste sono riunite in gruppi di celle adiacenti. I gruppi di istanti consecutivi sono poi collegati: un evento è un insieme di gruppi collegati, e resta unico anche quando un gruppo si separa in due o due gruppi si fondono. 35

6.1 Sovrapposizione fra le segnalazioni del detector e dei tre rilevatori senza modello, al 5% e all'1% delle osservazioni. Ogni casella riporta la quota delle segnalazioni del rilevatore della riga segnalate anche dal rilevatore della colonna. Anni 2005–2025, un istante ogni 29. Valori provvisori. 50
6.2 Conferma dalle stazioni E-OBS per quattro indicatori di perturbazione, nello stesso giorno della segnalazione e nel successivo. Le barre riportano il rapporto R con il suo intervallo al 95%; la linea verticale corrisponde a $R = 1$, una quota pari alla media. Scala logaritmica. Valori provvisori. 52

Capitolo 1

Introduzione

1.1 Contesto e motivazioni

Le condizioni meteorologiche insolite, come una perturbazione intensa, un fronte che attraversa una regione o un'ondata di caldo, sono quelle in cui i modelli addestrati su dati storici sbagliano di più e in cui servono informazioni aggiuntive. Il lavoro è nato in questo contesto, nell'ambito della previsione della produzione fotovoltaica [1], dove un previsore è affidabile nelle condizioni che i dati di addestramento rappresentano bene e meno in quelle poco frequenti. Riconoscere queste condizioni è però un problema a sé, distinto dalla previsione: richiede di stabilire, per ogni luogo e ogni istante, quanto le condizioni osservate si discostano da quelle abituali. È il compito del rilevamento di anomalie, a cui questa tesi è dedicata.

I campi meteorologici delle rianalisi, come ERA5 [2], descrivono lo stato dell'atmosfera su una griglia regolare, con molte variabili e per diversi decenni. Sono quindi una base adatta per cercare condizioni insolite in modo sistematico, su un dominio ampio e senza limitarsi alle grandezze di un singolo impiego.

1.2 Il problema: anomalie meteorologiche senza etichette

Tre caratteristiche dei dati rendono il problema difficile e guidano le scelte dei capitoli successivi.

La prima è l'assenza di etichette. Non esiste un elenco di osservazioni meteorologiche anomale con cui addestrare un classificatore o misurare

direttamente l'accuratezza di un detector. Il rilevamento deve essere non supervisionato e la sua valutazione deve ricorrere a strumenti indiretti.

La seconda è che i dati di training non sono garantiti privi di anomalie. Molti detector apprendono il comportamento normale da un insieme che si assume pulito; con dati meteorologici non etichettati questa ipotesi non è verificabile. Ne segue una scelta di obiettivo: rilevare le condizioni nuove rispetto al periodo di training, trattando come già osservate quelle che il modello ha incontrato durante l'addestramento.

La terza è la struttura spaziale. Le condizioni di un luogo dipendono da quelle dei luoghi vicini, e un valore insolito in un punto può essere ordinario se considerato nel suo intorno. I campi non hanno però una topologia fisica, come una rete stradale: sono disposti su un reticolo regolare, e il modo di rappresentare l'intorno va scelto.

Il termine anomalia indica in questa tesi un'osservazione che si discosta da quanto il modello ha appreso dal periodo di training. Un evento meteorologico estremo è un caso particolare di anomalia, ma non ogni anomalia è un evento estremo.

1.3 Approccio proposto

Il detector parte da STGAN [3], una rete avversaria proposta per il rilevamento di anomalie nel traffico: un generatore stima i valori dell'istante successivo a partire dal contesto spaziale e temporale, un discriminatore giudica se una sequenza è osservata o generata, e uno score combina i due. In questa tesi lo schema è adattato e trasformato per i campi ERA5, con quindici variabili in superficie e a 850 hPa, ogni tre ore, su un dominio che comprende l'Europa e il Mediterraneo. Le modifiche principali sono quattro:

1. un generatore che opera sul campo intero con un'unità ricorrente convoluzionale, mentre il discriminatore resta locale;

2. un ingresso riferito al clima di ogni cella, con una normalizzazione stagionale e pesi che misurano l'errore di ogni variabile in rapporto a quanto essa cambia abitualmente;

3. il dropout Monte Carlo nelle due reti, che associa a ogni score una misura di dispersione;

4. una validazione senza etichette su anni di tempo normale, con cui si scelgono i parametri dell'addestramento avversario senza usare gli anni di test.

1.4 Obiettivi e contributi della tesi

L'obiettivo della tesi è rilevare condizioni meteorologiche anomale in campi privi di etichette e dotati di struttura spaziale, e verificare, con dati indipendenti, che le condizioni segnalate siano davvero insolite. La tesi non propone un nuovo algoritmo di rilevamento: adatta e combina componenti esistenti. I contributi sono i seguenti.

- L'adattamento di STGAN a campi meteorologici privi di topologia fisica, con un generatore sul campo intero che rappresenta l'intorno di una cella con una convoluzione su griglia oppure con l'attenzione su grafo, e la definizione dell'obiettivo come rilevamento di condizioni nuove rispetto al periodo di training.
- Uno score Monte Carlo, con il dropout nel generatore e nel discriminatore, e la ricostruzione di eventi geografici a partire dagli score.
- Un protocollo di addestramento e di scelta della configurazione che non usa etichette né anni di test: una validazione da cui le condizioni insolite sono escluse con un criterio indipendente dal modello, e una misura della distanza fra campi osservati e ricostruiti.
- Una valutazione senza etichette: il confronto con rilevatori che non usano un modello, a parità di segnalazioni, e con le osservazioni di stazione di E-OBS [4], che non derivano da ERA5.

1.5 Organizzazione del documento

Il Capitolo 2 presenta i fondamenti teorici e i lavori su cui la tesi è costruita, compreso il lavoro preliminare sui dati PVGIS da cui il percorso è partito. Il Capitolo 3 descrive i campi ERA5 e la loro preparazione. Il Capitolo 4 presenta il detector nella forma finale. Il Capitolo 5 ripercorre l'evoluzione del detector, dalla prima applicazione ai dati PVGIS fino alla configurazione finale, e descrive le configurazioni, il protocollo di valutazione e i rilevatori di confronto. Il Capitolo 6 riporta e discute i risultati, comprese le ablazioni sullo score e sui pesi delle variabili. Il Capitolo 7 riassume il lavoro, ne indica i limiti e gli sviluppi futuri.

Capitolo 2

Fondamenti teorici e stato dell'arte

Il capitolo presenta i fondamenti teorici e i lavori su cui la tesi è costruita. Per ciascun lavoro di riferimento sono indicati ciò che propone e ciò che non copre, quindi ciò che la tesi ne riprende e il modo in cui ne affronta i limiti. I modelli di uso generale impiegati come componenti sono richiamati nella sezione in cui servono. La trattazione segue l'ordine dei temi del lavoro: il rilevamento delle anomalie, il contesto spaziale su griglie e grafi, la quantificazione dell'incertezza. Una sezione descrive poi il lavoro preliminare sui dati PVGIS, da cui la tesi è partita; l'ultima riassume la posizione della tesi rispetto ai lavori esaminati.

2.1 Rilevamento di anomalie in serie multivariate e spazio-temporali

I metodi di rilevamento di anomalie in serie multivariate basati su reti profonde sono comunemente distinti secondo il segnale da cui ricavano lo score. Wu et al. li classificano in metodi basati su previsione, su ricostruzione e su apprendimento contrastivo [5]. Alnegheimish et al. distinguono in modo analogo modelli di predizione e di ricostruzione, e osservano che molti di essi costruiscono uno score senza definire in modo appropriato la soglia [6]. Zhou et al. mettono in evidenza un'ipotesi comune a gran parte di questi lavori, cioè la disponibilità di un training composto da sole osservazioni normali: quando il training contiene anomalie le prestazioni possono degradare sensibilmente, e la stima della densità dell'intero insieme di training è proposta come alternativa [7].

I lavori esaminati in questa sezione si collocano lungo queste distinzioni: MTGFlow appartiene alla stima di densità, STGAN all'approccio avversario,

che combina l'errore di previsione con il giudizio di un discriminatore, CATCH alla ricostruzione e M2AD alla predizione con uno score aggregato. Due criteri guidano il confronto: la tolleranza alla presenza di anomalie nel training e la rappresentazione del contesto spaziale fra località. Il primo ha portato alla scelta di MTGFlow e all'esclusione di CATCH e M2AD; il secondo al passaggio a STGAN, che offre il contesto spaziale ma non la stessa tolleranza.

2.1.1 MTGFlow

Zhou et al. [7] affrontano il rilevamento di anomalie in serie multivariate senza assumere che i dati di training siano tutti normali. Il metodo stima la densità dell'intero insieme di training e identifica come anomale le osservazioni di test a bassa densità, sotto l'ipotesi che le anomalie occupino regioni più sparse. Le dipendenze fra entità sono apprese come grafo dinamico e un normalizing flow specifico per entità associa a ciascuna una distribuzione normale parametrizzata. La soglia è ricavata dall'intervallo interquartile degli score di training e lo score per entità consente di localizzare l'anomalia. Le entità sono i sensori o le variabili di un unico sistema e la valutazione usa dataset pubblici di riferimento: il grafo è appreso dai dati e descrive relazioni fra variabili, non fra siti geografici distinti. Un'estensione assegna una distribuzione comune alle entità di uno stesso gruppo, quando è noto che hanno caratteristiche simili. Il raggruppamento esprime soltanto che certe entità possono comportarsi allo stesso modo: non modella vicinanza, distanze o propagazione nello spazio, e non rende il metodo un detector spazio-temporale.

MTGFlow è stato scelto per la sua robustezza alla presenza di anomalie nei dati di training: per le condizioni meteorologiche non sono disponibili etichette, quindi non è possibile garantire un training composto da sole osservazioni normali. Nel lavoro preliminare della Sezione 2.4 ne è stata implementata la versione base, senza l'estensione a gruppi, applicata alle tre variabili meteorologiche di ogni località, trattate come entità, con la soglia interquartile dell'articolo. Poiché il metodo non rappresenta il contesto geografico, viene addestrato un modello indipendente per località: gli score possono essere confrontati sulla mappa, ma il modello non apprende relazioni fra località. Per introdurre una componente spaziale, il lavoro è quindi passato a STGAN.

2.1.2 Reti generative avversarie per il rilevamento di anomalie

Una rete generativa avversaria [8] addestra insieme due reti con obiettivi opposti. Il generatore G trasforma un rumore z, estratto da una distribuzione nota p_z, in un campione $G(z)$; i dati reali seguono la distribuzione p_{data} e il discriminatore D restituisce la probabilità $D(x)$ che un campione x provenga dai dati reali anziché dal generatore. Le due reti sono addestrate sulla stessa funzione, che il discriminatore massimizza e il generatore minimizza:

$$\min_G \max_D V(D,G) = \mathbb{E}_{x\sim p_{\text{data}}}\Big[\log D(x)\Big] + \mathbb{E}_{z\sim p_z}\Big[\log\Big(1 - D(G(z))\Big)\Big]. \quad (2.1)$$

Il primo termine cresce quando il discriminatore riconosce i dati reali, il secondo quando riconosce i campioni generati; il generatore è addestrato a rendere i propri campioni indistinguibili da quelli reali. Entrambe le reti sono ottimizzate con la retropropagazione. Lo stesso articolo osserva che, all'inizio dell'addestramento, il secondo termine fornisce al generatore un gradiente debole, e propone in alternativa di addestrarlo a massimizzare $\log D(G(z))$.

Nel detector avversario adottato in questa tesi lo schema è usato in forma condizionata: il generatore riceve il contesto di un'osservazione e ne produce una stima. L'uso per il rilevamento di anomalie poggia su un'ipotesi di lavoro: che la stima sia accurata nelle condizioni frequenti nei dati di training e meno accurata in quelle poco rappresentate. È un'ipotesi e non una proprietà garantita dall'addestramento. Se vale, se ne ricavano due segnali: lo scarto fra l'osservazione e la stima del generatore, e il giudizio del discriminatore sull'osservazione. STGAN, descritto di seguito, li combina in un unico score.

Rispetto all'equazione (2.1), in STGAN il significato dell'uscita del discriminatore è invertito: le sequenze reali sono trattate come normali e quelle generate come anomale, con valore 0 per le prime e 1 per le seconde. Per il discriminatore l'obiettivo è lo stesso a meno di questo scambio, ma la sua uscita cresce con il sospetto di anomalia e può essere usata per costruire lo score. L'obiettivo del generatore è riportato nell'equazione (2.2): il termine avversario ha la forma alternativa appena descritta, scritta nella convenzione invertita, e a esso si aggiunge un termine di ricostruzione.

L'addestramento richiede un equilibrio fra le due reti: nella tesi i tassi di apprendimento delle due reti, il coefficiente β_1 dei loro ottimizzatori e il numero di aggiornamenti per batch sono parametri configurabili, come descritto nel Capitolo 4.

2.1.3 STGAN

Deng et al. [3] propongono una rete avversaria per il rilevamento di anomalie del traffico. Il generatore prevede la dinamica normale combinando tre componenti: un modulo recente, basato su unità ricorrenti con convoluzione su grafo, per le dipendenze spazio-temporali di breve periodo, un modulo per il trend di lungo periodo e uno per le variabili esterne. Il discriminatore stabilisce se una sequenza è reale o generata in funzione dei vicini nello spazio e nel tempo, fornendo un criterio che varia con località e istante. Dopo l'addestramento avversario entrambe le reti agiscono da detector e uno score ne combina i contributi. Il grafo deriva da una topologia fisica, cioè sensori adiacenti sulla stessa strada o regioni con confini comuni, e la valutazione misura il richiamo rispetto a incidenti ed eventi documentati, che gli autori stessi indicano come verità di riferimento incompleta. Il metodo presuppone quindi una rete di adiacenze nota e produce uno score puntuale, privo di una misura di dispersione; la sua valutazione dipende dalla disponibilità di eventi documentati. L'articolo non discute la presenza di anomalie nei dati di training: il discriminatore è addestrato considerando normali le sequenze reali e anomale quelle generate, quindi l'ipotesi di un training normale è implicita. La Figura 2.1 riassume la struttura del metodo.

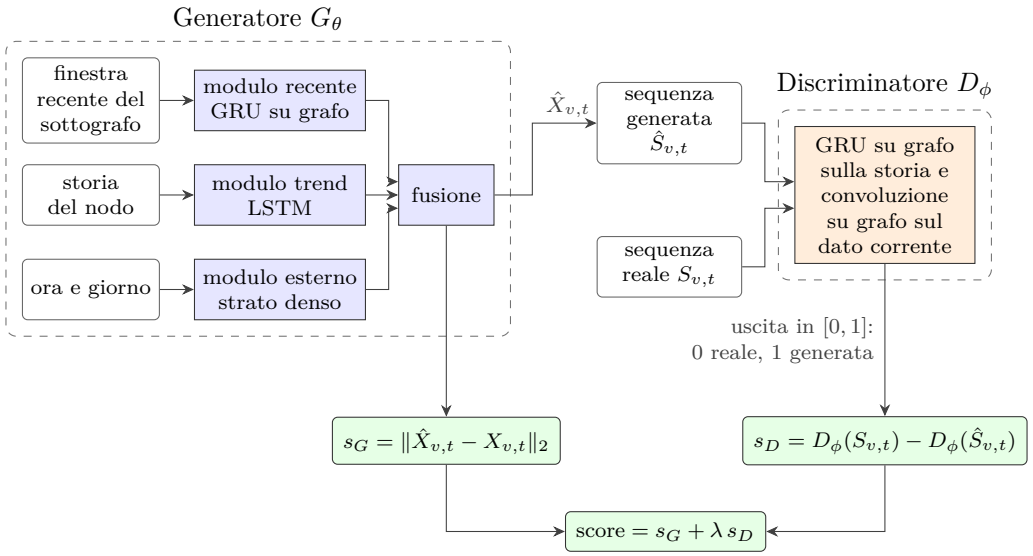


Figura 2.1: Schema di STGAN. Il generatore combina tre moduli e produce la stima $\hat{X}_{v,t}$, che sostituisce l'ultimo elemento della sequenza reale; il discriminatore valuta entrambe le sequenze. Lo score somma l'errore di previsione e la differenza fra le due uscite del discriminatore. Ridisegnato a partire da Deng et al. [3].

Sia $x_{v,t}$ l'osservazione del nodo v all'istante t e $X_{v,t}$ l'insieme delle osservazioni nel sottografo formato da v e dai suoi vicini. Sia poi $S_{v,t}$ la sequenza reale dei valori del sottografo che termina con $X_{v,t}$, e $\hat{S}_{v,t}$ la stessa sequenza in cui l'ultimo elemento è sostituito dalla stima $G_\theta(v,t)$ del generatore. Gli obiettivi di addestramento dell'articolo sono

$$\mathcal{L}_G(\theta) = \sum_s -\log\Big(1 - D_\phi(\hat{S}_{v,t})\Big) + \lambda_G \, \|G_\theta(v,t) - X_{v,t}\|_2, \tag{2.2}$$

$$\mathcal{L}_D(\phi) = \sum_s -\log\Big(D_\phi(\hat{S}_{v,t})\Big) - \log\Big(1 - D_\phi(S_{v,t})\Big), \tag{2.3}$$

dove la somma è sui punti $s = \langle v, t, x_{v,t} \rangle$ e λ_G bilancia l'errore di previsione e il termine avversario. Il discriminatore è quindi spinto verso 1 sulle sequenze generate e verso 0 su quelle reali. Lo score combina le due reti:

$$\begin{aligned} s_D(v,t) &= D_\phi(S_{v,t}) - D_\phi(\hat{S}_{v,t}), \\ s_G(v,t) &= \|G_\theta(v,t) - X_{v,t}\|_2, \\ \text{score}(v,t) &= s_G(v,t) + \lambda \, s_D(v,t). \end{aligned} \tag{2.4}$$

La componente del discriminatore non è la sua uscita sulla sequenza reale ma la differenza rispetto alla sequenza generata: gli autori la introducono per ridurre l'effetto dell'imprevedibilità dei dati reali. Negli esperimenti dell'articolo $\lambda_G = 500$, le due componenti sono normalizzate e $\lambda = 1$.

La tesi riprende l'architettura a tre rami, gli obiettivi avversari e lo score combinato, e li applica a campi meteorologici, per i quali non esiste una topologia fisica: le adiacenze sono sostituite dalla vicinanza sulla griglia. A differenza di MTGFlow, il metodo non tollera per costruzione un training contaminato. La tesi accetta questo limite in cambio del contesto spaziale e lo traduce in una scelta di obiettivo: rilevare condizioni nuove rispetto al periodo di training. Le anomalie presenti negli anni di addestramento sono trattate come già osservate: nella misura in cui il modello le apprende, condizioni simili non vengono segnalate, mentre lo sono quelle poco o per nulla rappresentate in quegli anni. Lo score misura quindi lo scostamento da quanto il modello ha appreso dal periodo di training, non la rarità di una condizione in assoluto. Lo score è continuo e non coincide con la decisione: sono considerate anomale soltanto le osservazioni con score più alto, in una quota che è un parametro del protocollo. Il termine anomalia è usato in questo senso in tutta la tesi: un evento estremo è un caso particolare di anomalia, ma non ogni anomalia è un evento estremo. Su questa base sono costruite le due varianti descritte nella Sezione 2.2 e tre estensioni: uno score Monte Carlo, con il dropout nel generatore e nel discriminatore, che associa a ogni osservazione una misura di dispersione; una validazione priva di etichette su anni di

tempo normale, necessaria perché non sono disponibili eventi documentati con cui misurare il richiamo; l'aggregazione degli score in eventi geografici, un passaggio assente nell'articolo. Gli obiettivi di addestramento e lo score, nella forma implementata, sono riportati nella Sezione 4.1: rispetto alle equazioni (2.2)–(2.4), l'errore di previsione vi compare come errore quadratico medio anziché come norma, mentre $\lambda_G = 500$, la differenza fra le uscite del discriminatore e $\lambda = 1$ sono mantenuti. La scelta segue il codice pubblicato dagli autori, che usa l'errore quadratico medio sia nella loss del generatore sia nella componente di ricostruzione dello score, e dimezza la somma dei due termini della loss del discriminatore.

2.1.4 Alternative considerate: CATCH e M2AD

CATCH. Wu et al. [5] propongono un metodo basato su ricostruzione nel dominio della frequenza. Lo spettro è suddiviso in bande, trattate come patch, per cogliere caratteristiche a grana fine; un modulo di fusione dei canali, con un generatore di maschere e un'attenzione mascherata, seleziona per ciascuna banda le correlazioni fra canali ritenute utili e isola quelle irrilevanti. Il metodo mira a rilevare insieme anomalie puntuali e di sottosequenza ed è valutato su dataset reali e sintetici. Lo score di anomalia è l'errore di ricostruzione: il modello impara a ricostruire i pattern normali, e nei dataset sintetici dell'articolo le anomalie sono inserite soltanto nella serie di test. Il caso di anomalie presenti nei dati di training non è trattato. I canali sono le variabili di una serie multivariata: non è prevista una struttura geografica fra serie di siti diversi, e gli autori segnalano che anomalie più lunghe della finestra osservata non vengono colte efficacemente.

CATCH è stato preso in esame come alternativa a MTGFlow e non è stato adottato, per due ragioni. La prima è che richiede un training privo di anomalie: apprende i pattern normali per ricostruzione e l'articolo non considera un training contaminato, mentre in assenza di etichette questa condizione non è verificabile sui dati meteorologici. La seconda è che, come MTGFlow, non rappresenta relazioni fra località geografiche.

M2AD. Alnegheimish et al. [6] considerano serie multivariate provenienti da più sistemi. Un modello LSTM apprende il comportamento atteso dei sensori; i residui fra valori attesi e osservati sono aggregati in uno score globale mediante un modello a mistura gaussiana e una calibrazione Gamma; la soglia è stimata dagli score osservati in training e i sensori sono ordinati per contributo allo score. Il metodo assume che i dati di training siano privi di anomalie e che training e test abbiano andamenti simili; gli autori indicano

come limite il caso in cui la distribuzione cambia, che richiede un nuovo addestramento.

Anche M2AD è stato preso in esame e non adottato, per le stesse due ragioni: assume esplicitamente un training privo di anomalie, ipotesi opposta a quella che ha guidato la scelta di MTGFlow e non verificabile senza etichette, e i suoi sistemi sono insiemi di sensori senza relazione geografica fra loro. A differenza di STGAN, quindi, né CATCH né M2AD offrono il contesto spaziale in cambio dell'ipotesi sul training. Nessuno dei due è stato eseguito sui dati della tesi e non compaiono fra i risultati.

2.2 Contesto spaziale su griglie e grafi

2.2.1 Unità ricorrenti convoluzionali

Le unità ricorrenti a gate, come quella introdotta da Cho et al. [9] e nota come GRU, aggiornano uno stato nascosto mediante gate che regolano quanta parte dello stato precedente conservare e quanta sostituire. Nella forma originaria ingresso e stato sono vettori e i gate sono trasformazioni dense. Quando l'ingresso è un campo disposto su una griglia, le trasformazioni dense possono essere sostituite da convoluzioni, così che lo stato mantenga la struttura spaziale e i parametri siano condivisi fra le posizioni. L'idea è stata proposta per la LSTM nella previsione a breve termine delle precipitazioni [10] e per la GRU nell'apprendimento di rappresentazioni di sequenze video [11]. STGAN applica la stessa idea a un grafo: nel suo modulo recente i prodotti matriciali della GRU sono sostituiti da convoluzioni su grafo [3].

Sia X_s l'ingresso al passo s e H_{s-1} lo stato precedente, entrambi disposti sulla griglia. Uno strato ricorrente convoluzionale a gate calcola

$$R_s = \sigma(W_r * [X_s, H_{s-1}] + b_r)\,, \tag{2.5}$$

$$U_s = \sigma(W_u * [X_s, H_{s-1}] + b_u)\,, \tag{2.6}$$

$$\widetilde{H}_s = \tanh(W_c * [X_s, R_s \odot H_{s-1}] + b_c)\,, \tag{2.7}$$

$$H_s = U_s \odot H_{s-1} + (1 - U_s) \odot \widetilde{H}_s, \tag{2.8}$$

dove σ è la funzione sigmoidale, $*$ una convoluzione spaziale, $\odot$ il prodotto elemento per elemento e $[\cdot,\cdot]$ la concatenazione sui canali. Il gate di reset R_s regola quanto dello stato precedente entra nello stato candidato $\widetilde{H}_s$; il gate di aggiornamento U_s regola quanto dello stato precedente viene conservato. La forma è quella dell'unità su grafo di STGAN, con la convoluzione su grafo sostituita da una convoluzione spaziale.

Con un kernel di lato k e padding $\lfloor k/2 \rfloor$, ogni convoluzione vede le celle entro $\lfloor k/2 \rfloor$ posizioni. Il gate di reset e lo stato candidato applicano due convoluzioni in sequenza, quindi a ogni passo lo stato precedente si propaga fino a $2\lfloor k/2 \rfloor$ posizioni: l'area che influenza una cella cresce con il numero di passi temporali e di strati. La tesi impiega questo operatore nella variante a griglia di STGAN: la Sezione 4.1.1 descrive il trattamento delle celle assenti, che modifica l'ingresso e l'equazione (2.8) ed è l'adattamento specifico di questo lavoro.

2.2.2 Reti su grafo e Graph Attention Network

Una rete su grafo aggiorna la rappresentazione di ogni nodo aggregando quelle dei suoi vicini. Nella Graph Attention Network [12] i pesi dell'aggregazione non sono fissati dalla struttura del grafo: ogni nodo assegna ai propri vicini coefficienti di attenzione calcolati a partire dalle rispettive feature. Il calcolo non richiede operazioni matriciali costose né la conoscenza anticipata dell'intero grafo, e si applica anche a grafi non osservati durante il training. Più teste di attenzione possono operare in parallelo, e i loro risultati sono concatenati oppure mediati.

Sia h_i il vettore di feature del nodo i e $\mathcal{N}(i)$ l'insieme dei suoi vicini, che negli esperimenti dell'articolo comprende il nodo stesso. Uno strato calcola

$$e_{ij} = \mathrm{LeakyReLU}\Big(\mathbf{a}^\top \left[Wh_i \,\|\, Wh_j\right]\Big), \tag{2.9}$$

$$\alpha_{ij} = \frac{\exp e_{ij}}{\sum_{l \in \mathcal{N}(i)} \exp e_{il}}, \tag{2.10}$$

$$h'_i = \sigma\left(\sum_{j \in \mathcal{N}(i)} \alpha_{ij}\, Wh_j\right), \tag{2.11}$$

dove W è una trasformazione lineare condivisa fra i nodi, $\mathbf{a}$ il vettore dei pesi dell'attenzione, $\|$ la concatenazione e σ una non linearità. Il coefficiente α_{ij} esprime l'importanza del nodo j per il nodo i. Con più teste, ciascuna con parametri propri, le uscite sono concatenate negli strati intermedi e mediate nell'ultimo. Lo strato può essere letto come una convoluzione su grafo in cui i pesi dell'aggregazione sono appresi, invece che fissati dalla struttura del grafo.

Nella tesi il meccanismo compare nei gate dell'unità ricorrente del generatore, nella variante su grafo di STGAN, sul grafo regolare della griglia e senza pesi geografici; il grafo e la configurazione dell'encoder sono descritti nella Sezione 4.8. Nel lavoro preliminare della Sezione 2.4 lo stesso strato era usato nel previsore della produzione, su un grafo geografico con pesi che dipendono dalla distanza.

2.2.3 Dall'articolo alla tesi: le varianti di STGAN

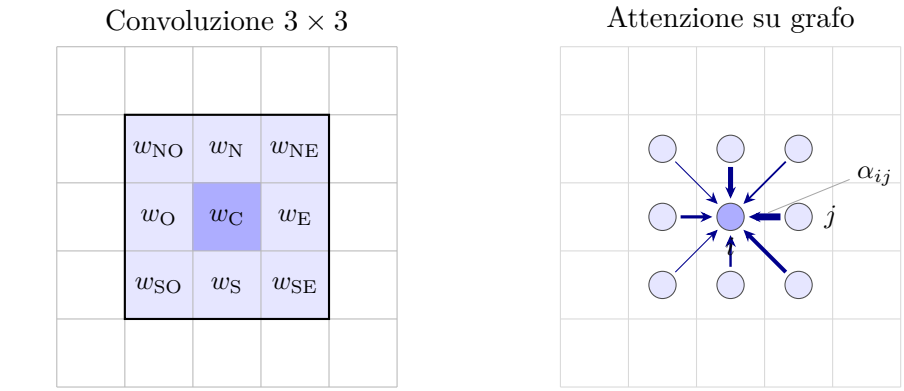
Le due varianti non corrispondono ad articoli distinti: sono adattamenti di STGAN realizzati in questo lavoro. I dati della tesi non hanno una topologia fisica come quella dell'articolo: sono disposti su un reticolo regolare di celle, e le due varianti rappresentano l'intorno di una cella in due modi diversi. Sono riportate qui per chiarire che cosa cambia rispetto all'articolo e quali componenti sono preesistenti.

Variante a griglia: STGAN con ConvGRU. Nell'articolo il contesto spaziale è un grafo, e in assenza di una rete fisica le sue adiacenze devono essere scelte con un criterio di vicinanza. I dati della tesi sono invece disposti su un reticolo regolare, per il quale le posizioni relative dei vicini sono definite. La variante sostituisce quindi la convoluzione su grafo con una ConvGRU su patch geografiche, conservando il ramo LSTM del trend, gli obiettivi avversari e lo score. Rispetto all'articolo aggiunge il trattamento delle celle assenti, con una maschera fornita come canale e l'azzeramento dello stato ricorrente. La variante opera sull'intero campo: il generatore elabora in una sola passata il reticolo completo di un istante, mentre il discriminatore continua a giudicare la patch di ogni cella. L'operatore ricorrente convoluzionale non è un contributo della tesi; lo sono il suo impiego in questo detector e la gestione delle celle mancanti.

Variante con attenzione su grafo: STGAN con GAT-GRU. Nell'articolo i pesi fra vicini derivano da adiacenze fissate. La seconda variante definisce il generatore sul grafo dell'intera griglia, con otto vicini per nodo, e mantiene la struttura dell'unità ricorrente dell'articolo: in ciascun gate la convoluzione su grafo, i cui pesi sono fissati dall'adiacenza, è sostituita da uno strato di attenzione su grafo, i cui pesi sono calcolati dalle feature dei nodi. L'operatore agisce quindi sull'ingresso e sullo stato a ogni passo recente, come nell'articolo e nella variante a griglia. L'unità che ne risulta è indicata nel seguito come GAT-GRU, per analogia con la ConvGRU: una GRU i cui gate sono strati di attenzione su grafo. Un campione è un timestamp con tutti i nodi. Il discriminatore resta quello locale a patch: il criterio di giudizio continua a dipendere dall'intorno di ciascun sito, come nell'articolo. Anche qui il meccanismo di attenzione è preesistente; è della tesi il suo inserimento nei gate dell'unità ricorrente di STGAN, con discriminatore locale invariato.

Che cosa distingue le due varianti. Con otto vicini per nodo, uno strato di attenzione e una convoluzione 3×3 osservano le stesse celle e differiscono nel modo di pesarle, come mostra la Figura 2.2. Nella convoluzione il peso di

un vicino dipende dalla sua posizione relativa ed è lo stesso in ogni punto del campo e in ogni istante; nell'attenzione dipende dalle feature dei due nodi ed è ricalcolato per ogni cella e ogni istante. In cambio l'attenzione tratta i vicini come un insieme non ordinato e non distingue le direzioni, che la convoluzione invece rappresenta. Poiché in entrambe l'operatore sta dentro i gate, l'ampiezza del contesto è la stessa: l'area che influenza una cella cresce allo stesso modo con il numero di passi recenti. Sul campo intero le due varianti differiscono quindi per il modo di pesare i vicini e, di conseguenza, per il numero di parametri. Mettono a confronto due ipotesi sullo stesso intorno, l'una basata sulla posizione dei vicini e l'altra sul loro stato; quale sia più adatta al rilevamento è una questione sperimentale.



peso fissato dalla posizione del vicino, uguale in ogni cella e in ogni istante

peso calcolato dalle feature dei due nodi, diverso per ogni cella e ogni istante

Figura 2.2: Intorno di una cella nelle due varianti. A sinistra la convoluzione assegna a ogni vicino un peso legato alla sua posizione. A destra l'attenzione su grafo assegna a ogni arco un coefficiente α_{ij} che dipende dalle feature dei nodi collegati: lo spessore delle frecce ne rappresenta un esempio.

2.3 Quantificazione dell'incertezza

2.3.1 Dropout Monte Carlo e Deep Ensemble

Gal e Ghahramani [13] interpretano l'addestramento con dropout come un'inferenza bayesiana approssimata. Mantenendo il dropout attivo in previsione e ripetendo più volte il passaggio in avanti si ottiene un insieme di uscite, la cui dispersione fornisce una stima dell'incertezza del modello con un costo aggiuntivo contenuto. Lakshminarayanan et al. [14] propongono un'alternativa

non bayesiana: più reti vengono addestrate in modo indipendente a partire da inizializzazioni diverse e le loro previsioni sono combinate. Il metodo è semplice da realizzare e da eseguire in parallelo, e produce un'incertezza maggiore sugli ingressi lontani dai dati di training.

Nel dropout Monte Carlo, dati J passaggi in avanti $\hat{y}_j(x)$ ottenuti con maschere di dropout diverse, la media predittiva è stimata da

$$\mathbb{E}[y \mid x] \approx \frac{1}{J} \sum_{j=1}^{J} \hat{y}_j(x), \tag{2.12}$$

e la varianza predittiva dalla varianza campionaria dei J passaggi, a cui l'articolo somma l'inverso della precisione del modello. Nei Deep Ensemble ciascuna delle M reti restituisce una media $\mu_m(x)$ e una varianza $\sigma_m^2(x)$ ed è addestrata con la negative log-likelihood gaussiana; l'insieme è trattato come una miscela a pesi uguali, con media e varianza

$$\mu_*(x) = \frac{1}{M} \sum_{m=1}^{M} \mu_m(x), \qquad \sigma_*^2(x) = \frac{1}{M} \sum_{m=1}^{M} \Big(\sigma_m^2(x) + \mu_m^2(x)\Big) - \mu_*^2(x). \tag{2.13}$$

La varianza della miscela è quindi la somma della media delle varianze delle singole reti e della dispersione delle loro medie.

Nella tesi il dropout Monte Carlo è applicato al detector avversario, al generatore e al discriminatore di STGAN, non per stimare l'incertezza di una previsione ma per campionare lo score di anomalia. Durante il calcolo degli score i dropout restano attivi e per ogni osservazione sono riportate la media dello score sui campioni, come nell'equazione (2.12), e la sua deviazione standard, come descritto nella Sezione 4.4. L'articolo di STGAN non prevede questo passaggio: il suo score è un valore unico per osservazione. In questo impiego la dispersione misura la variabilità dello score rispetto alle maschere di dropout e non costituisce una stima calibrata dell'incertezza; il termine di precisione previsto da Gal e Ghahramani non viene aggiunto. Nel lavoro preliminare della Sezione 2.4 dropout Monte Carlo e Deep Ensemble erano applicati al previsore della produzione.

2.3.2 Equazioni differenziali stocastiche neurali

Una rete residua aggiorna lo stato sommando a esso una trasformazione dello stato stesso, $x_{t+1} = x_t + f(x_t, t)$. Interpretando l'aggiornamento come un passo di integrazione, la trasformazione complessiva può essere descritta da un'equazione differenziale ordinaria, $\mathrm{d}x/\mathrm{d}t = f(x, t)$, in cui f è una rete neurale e l'uscita è calcolata da un risolutore numerico [15]. Un modello di

questo tipo è deterministico. Aggiungendo un termine di moto browniano si ottiene un'equazione differenziale stocastica,

$$\mathrm{d}x_t = f(x_t, t)\,\mathrm{d}t + g(x_t, t)\,\mathrm{d}W_t, \tag{2.14}$$

in cui f è il drift e g la diffusione, che regola l'ampiezza della componente casuale [16].

In pratica l'equazione è integrata a passi discreti con lo schema di Euler–Maruyama. Dividendo l'intervallo $[0, T]$ in N passi di ampiezza $\Delta t = T/N$, l'aggiornamento è

$$x_{k+1} = x_k + f(x_k, t_k)\,\Delta t + g(x_k, t_k)\sqrt{\Delta t}\,Z_k, \qquad Z_k \sim \mathcal{N}(0, 1) : \tag{2.15}$$

a ogni passo lo stato avanza del drift moltiplicato per l'ampiezza del passo e di un termine gaussiano scalato dalla diffusione e dalla radice dell'ampiezza del passo. Ripetendo l'integrazione con estrazioni diverse di Z_k si ottengono traiettorie diverse dallo stesso ingresso, tanto più disperse quanto maggiore è la diffusione (Figura 2.3). Il tempo di integrazione è una variabile interna del modello e non coincide con l'orizzonte fisico della previsione. I due lavori descritti di seguito applicano questo schema alla stima dell'incertezza.

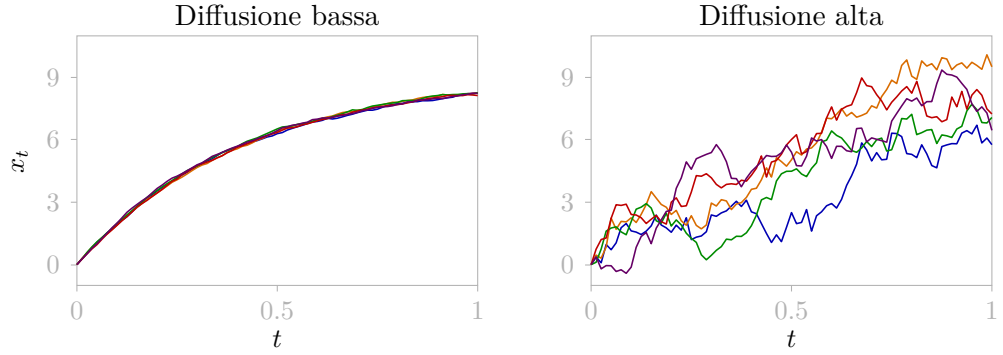


Figura 2.3: Cinque traiettorie di un'equazione differenziale stocastica lineare con lo stesso drift e due valori della diffusione, integrate con lo schema di Euler–Maruyama. La dispersione fra le traiettorie è la quantità da cui SDE-Net ricava l'incertezza epistemica. Simulazione illustrativa sul modello della figura analoga di Kong et al. [16]; non è un risultato della tesi.

2.3.3 SDE-Net

Kong et al. [16] interpretano le trasformazioni di una rete profonda come l'evoluzione dello stato di un sistema dinamico stocastico. Il modello comprende

una rete di drift, che adatta la funzione predittiva, e una rete di diffusione, che scala un termine browniano e rappresenta l'incertezza epistemica. La diffusione è addestrata ad assumere valori bassi sui dati di training e alti su dati fuori distribuzione, ottenuti aggiungendo rumore gaussiano agli ingressi. L'equazione è integrata con lo schema dell'equazione (2.15) a passo fisso, con parametri condivisi fra i passi e diffusione calcolata sul solo stato iniziale, cioè con $g(x_0; \theta_g)$ al posto di $g(x_k, t_k)$; l'uscita della rete di diffusione è una sigmoide moltiplicata per un valore massimo, fissato come iperparametro. Dopo l'addestramento si campionano più traiettorie per lo stesso ingresso: l'incertezza aleatoria è la varianza predittiva media sulle traiettorie, quella epistemica la varianza dello stato finale fra le traiettorie. Il metodo separa così le due incertezze con un unico modello, senza distribuzioni a priori sui pesi e senza addestrare un insieme di reti. La valutazione riguarda il riconoscimento di dati fuori distribuzione, di errori di classificazione e di esempi avversari e l'active learning, su immagini e su un problema di regressione tabellare. Il lavoro non considera serie temporali né dati con struttura spaziale: gli esempi sono indipendenti, e il fuori distribuzione è definito da un dataset diverso o da ingressi perturbati, non da condizioni rare ma ricorrenti nello stesso dominio.

Nel lavoro preliminare della Sezione 2.4 lo schema drift–diffusione di SDE-Net, con l'addestramento alternato delle due reti e la forma gaussiana dell'obiettivo di regressione, è stato applicato al previsore della produzione fotovoltaica, collocando il blocco stocastico sullo stato latente di un insieme di località collegate da un grafo.

2.3.4 SDE U-Net

Monaco et al. [17] adattano SDE-Net a un'architettura U-Net per il post-processing di previsioni numeriche di precipitazione, con mappe di precipitazione cumulata giornaliera sull'Italia nord-occidentale. Poiché i blocchi dell'encoder hanno dimensioni diverse, il numero di passi di integrazione è allineato al numero di blocchi: a ciascun blocco è associato un blocco di diffusione, funzione dell'ingresso iniziale, il cui segnale è sommato alla rispettiva skip connection. La loss di regressione è una MSE e la diffusione è addestrata, come in SDE-Net, a distinguere ingressi originali e ingressi perturbati con rumore gaussiano. Il disegno sperimentale usa per training e validation soltanto eventi non intensi e valuta il modello sia su eventi non intensi sia su eventi intensi, confrontando più architetture probabilistiche in termini di equilibrio fra ampiezza e affidabilità degli intervalli. Il lavoro opera su campi regolari elaborati da un encoder–decoder convoluzionale e su mappe giornaliere: non tratta insiemi irregolari di località, serie temporali per sito o più orizzonti di previsione.

Nel lavoro preliminare ne sono stati ripresi l'allineamento fra passi stocastici e stadi dell'encoder, trasferito agli stadi del previsore della produzione, e il protocollo che esclude dal training gli eventi intensi e li mantiene nel test. Un'idea analoga a quest'ultima è alla base della validazione del detector, da cui le condizioni insolite sono escluse (Sezione 4.6.1).

2.4 Lavoro preliminare sui dati PVGIS

Il lavoro è partito, nell'ambito della previsione della produzione fotovoltaica, da serie orarie ottenute dal Photovoltaic Geographical Information System [18]: 1149 località del Piemonte, disposte su un reticolo con passo di 5 km, con l'irradianza globale e le sue componenti, la temperatura a due metri, la velocità del vento a dieci metri e una produzione teorica calcolata da PVGIS, per gli anni 2005–2023. Su questi dati sono stati esplorati tre approcci, descritti qui per collocare il lavoro; i loro risultati non fanno parte della tesi.

Previsione probabilistica della produzione. Un previsore della produzione all'ora successiva combina un encoder temporale, una LSTM bidirezionale con pooling ad attenzione, con uno strato di attenzione su grafo [12] fra località vicine, su un grafo geografico con pesi decrescenti con la distanza. Per associare un intervallo alla previsione sono stati provati il dropout Monte Carlo [13], il Deep Ensemble [14] e due varianti costruite sugli schemi di SDE U-Net [17] e di SDE-Net [16], la seconda anche con previsione diretta su più orizzonti.

Soglie climatologiche. Come primo criterio per individuare condizioni insolite, un'osservazione è segnalata quando esce dalla banda fra i quantili 0.025 e 0.975 della distribuzione della stessa località e della stessa ora negli anni precedenti, entro quindici giorni di calendario. Le soglie segnalano i valori estremi di ciascuna variabile presa da sola; sono servite a esaminare il previsore nelle condizioni insolite e ad addestrarlo sulle sole finestre normali, secondo il protocollo di SDE U-Net.

Rilevamento con modelli appresi. Per individuare anomalie diverse dai valori estremi è stato applicato MTGFlow, un modello per località sulle tre variabili meteorologiche. Poiché MTGFlow non rappresenta il contesto geografico, il lavoro è passato a STGAN. L'applicazione di STGAN ai dati PVGIS è il primo passo dell'evoluzione del detector, descritta nella Sezione 5.1.1: è da lì che nasce il passaggio ai campi ERA5, perché i dati PVGIS contengono soltanto le grandezze da cui dipende la produzione fotovoltaica.

2.5 Posizionamento del lavoro

2.5.1 Il contributo sostenuto

I lavori esaminati coprono ciascuno una parte del problema affrontato. MTG-Flow tollera la presenza di anomalie nel training, ma descrive relazioni fra le variabili di un sistema e non fra siti geografici. STGAN introduce il contesto spaziale e un criterio avversario, ma presuppone una topologia fisica, la disponibilità di eventi documentati e, implicitamente, un training normale. CATCH e M2AD operano su serie multivariate prive di struttura geografica e non trattano, o escludono per ipotesi, un training contaminato.

La tesi adatta un detector avversario spazio-temporale, nato per il traffico, a campi meteorologici privi di etichette e di topologia fisica, con un generatore che opera sul campo intero e rappresenta l'intorno di una cella con una convoluzione su griglia oppure con l'attenzione su grafo. Poiché un training privo di anomalie non è garantito, ne definisce l'obiettivo come rilevamento di condizioni nuove rispetto al periodo di training. Lo estende con una misura di dispersione dello score, ottenuta con il dropout Monte Carlo nelle due reti, con una validazione senza etichette su anni di tempo normale e con la ricostruzione di eventi geografici; e lo valuta senza etichette, confrontandolo con rilevatori che non usano un modello e con osservazioni di stazione indipendenti dai dati di addestramento. Il contributo consiste nell'adattamento, nella combinazione di questi elementi e nel protocollo di valutazione. I componenti di base sono preesistenti: la tesi non propone un nuovo algoritmo di rilevamento.

2.5.2 Confronto dei detector esaminati

La Tabella 2.1 riassume i quattro detector esaminati e il percorso della tesi rispetto ai criteri usati nel capitolo. Le voci relative agli articoli riportano ciò che gli articoli dichiarano; dove un aspetto non è discusso, è indicato come non trattato. STGAN è la base del detector; MTGFlow è stato eseguito nel lavoro preliminare; CATCH e M2AD sono stati valutati sugli articoli e non eseguiti.

Tabella 2.1: Detector esaminati e percorso della tesi a confronto. La colonna sulle anomalie nel training indica come ciascun lavoro tratta la presenza di osservazioni anomale nei dati di addestramento.

Lavoro	Segnale dello score	Anomalie nel training	Contesto spaziale	Dati	Dispersione
MTGFlow [7]	Densità stimata	Ammesse per costruzione	No: relazioni fra variabili	Dataset pubblici	Non prevista
STGAN [3]	Errore di previsione e discriminatore	Non trattate: dati reali considerati normali	Sì: grafo da topologia fisica	Traffico	Non prevista
CATCH [5]	Errore di ricostruzione in frequenza	Non trattate	No: canali di una serie	Dataset reali e sintetici	Non prevista
M2AD [6]	Residui di previsione aggregati	Escluse per ipotesi	No: sensori di più sistemi	Dataset pubblici e caso industriale	Non prevista
Tesi	Come STGAN: errore di ricostruzione e discriminatore	Trattate come già osservate; escluse dalla validazione	Sì: vicinanza sulla griglia, convoluzione o grafo di griglia	Campi ERA5	Sì: dropout Monte Carlo nelle due reti

Capitolo 3

Dati e preprocessing

Il capitolo descrive i campi meteorologici su cui il detector è addestrato e valutato: le variabili della rianalisi ERA5, il dominio e la cadenza temporale, la preparazione dei dati e la loro suddivisione in anni di addestramento, di validazione e di test. Le trasformazioni che dipendono dal modello, come la normalizzazione stagionale, sono descritte nel Capitolo 4; le osservazioni di stazione usate per la valutazione sono descritte nel Capitolo 5.

3.1 Campi ERA5, allineamento e celle valide

I dati della rianalisi ERA5 [2] provengono da due prodotti distinti: variabili a livello singolo e variabili su livelli di pressione, di cui è usato soltanto il livello di 850 hPa. Le variabili sono quindici. Le dieci variabili a livello singolo sono temperatura a due metri, componenti orizzontali del vento a dieci metri, pressione al livello medio del mare, precipitazione totale, copertura nuvolosa totale, radiazione solare discendente alla superficie, umidità volumetrica del primo strato del suolo, velocità d'attrito e altezza dello strato limite. Le altre cinque sono le componenti orizzontali del vento, la velocità verticale, la temperatura e l'umidità specifica a 850 hPa. La Tabella 3.1 le elenca con le unità di ERA5, che non vengono convertite.

I dati coprono gli anni dal 1980 al 2025. Sono selezionati gli istanti UTC 00, 03, 06, 09, 12, 15, 18 e 21, su una griglia di $0.5° \times 0.5°$ nell'area compresa fra 20° e 60° di latitudine nord e fra 15° di longitudine ovest e 50° di longitudine est (Figura 3.1). Il dominio comprende l'Europa, il Mediterraneo e parte dell'Africa settentrionale e del Medio Oriente. Il campionamento ogni tre ore è una selezione di tempi validi, non un'aggregazione temporale: precipitazione e radiazione conservano gli accumuli di un'ora associati ai tempi selezionati, senza somme triorarie o conversioni locali delle unità.

Tabella 3.1: Le quindici variabili ERA5, con la sigla e l'unità del dataset. Precipitazione e radiazione sono accumuli di un'ora; le altre variabili sono istantanee.

Variabile	Sigla	Livello	Unità
Temperatura a due metri	t2m	Superficie	K
Componente zonale del vento a dieci metri	u10	Superficie	$\mathrm{m\,s^{-1}}$
Componente meridionale del vento a dieci metri	v10	Superficie	$\mathrm{m\,s^{-1}}$
Pressione al livello medio del mare	msl	Superficie	Pa
Precipitazione totale	tp	Superficie	m
Copertura nuvolosa totale	tcc	Superficie	0–1
Radiazione solare discendente alla superficie	ssrd	Superficie	$\mathrm{J\,m^{-2}}$
Umidità volumetrica del primo strato del suolo	swvl1	Superficie	$\mathrm{m^3\,m^{-3}}$
Velocità d'attrito	zust	Superficie	$\mathrm{m\,s^{-1}}$
Altezza dello strato limite	blh	Superficie	m
Componente zonale del vento	u	850 hPa	$\mathrm{m\,s^{-1}}$
Componente meridionale del vento	v	850 hPa	$\mathrm{m\,s^{-1}}$
Velocità verticale	w	850 hPa	$\mathrm{Pa\,s^{-1}}$
Temperatura	t	850 hPa	K
Umidità specifica	q	850 hPa	$\mathrm{kg\,kg^{-1}}$

I file mensili vengono verificati rispetto a tempi, griglia, variabili e livello di pressione richiesti. La preparazione allinea i due prodotti sulle stesse coordinate e sugli stessi timestamp, ordina le latitudini da nord a sud e le longitudini da ovest a est. Il reticolo contiene $81 \times 131 = 10611$ posizioni.

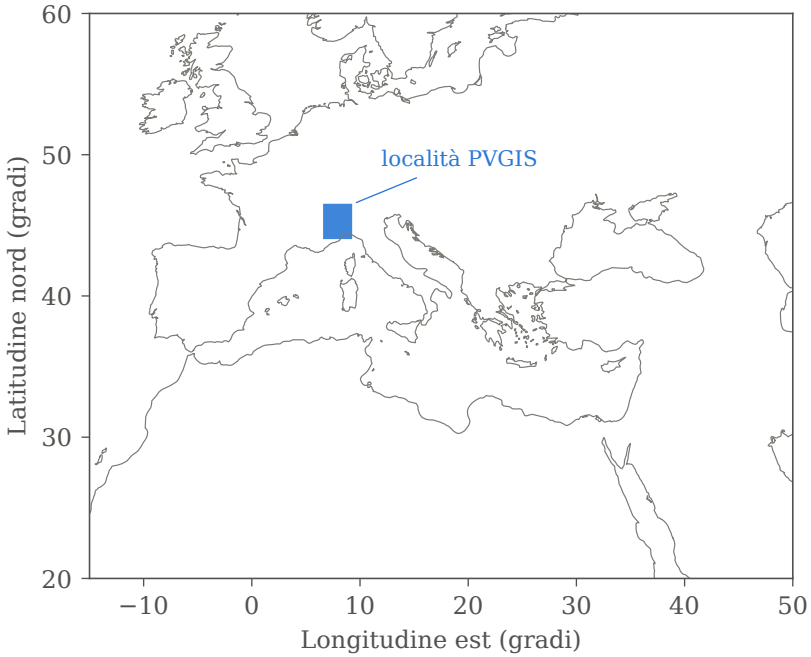


Figura 3.1: Dominio dei campi ERA5: 81×131 celle di 0.5°, fra 20° e 60° di latitudine nord e fra 15° di longitudine ovest e 50° di longitudine est. Il rettangolo indica il Piemonte, la regione dei dati del lavoro preliminare della Sezione 2.4. Linee di costa da Natural Earth.

Sono conservate le celle per le quali tutte le variabili sono definite nel primo istante di training, e si verifica che questo insieme rimanga identico nel resto del periodo; se cambia, la preparazione si interrompe. La selezione non utilizza il test e non viene applicata imputazione. Il criterio è la completezza delle variabili, non una classificazione terra–mare: nei dati usati nessuna cella è esclusa.

3.2 Anni di addestramento, di validazione e di test

I dati preparati hanno forma $[T, N, 15]$, con $N = 10611$ celle, e sono divisi in tre periodi consecutivi. Gli anni 1980–1999 sono usati per l'addestramen-

to, gli anni 2000–2004 per la validazione e gli anni 2005–2025 per il test: rispettivamente 58440, 14616 e 61360 istanti. Tutte le quantità stimate dai dati, cioè la normalizzazione stagionale, la tendenza rimossa, gli estremi del min–max e i pesi delle variabili del Capitolo 4, sono calcolate sui soli anni di addestramento.

La validazione serve a confrontare le configurazioni e a fissare, prima di valutare il test, gli estremi con cui le due componenti dello score sono riportate sulla stessa scala. Gli anni di test non entrano in alcuna scelta di configurazione. L'articolo di STGAN [3] separa i dati in training e test senza un insieme di validazione: la validazione è un'aggiunta di questo lavoro, necessaria perché in assenza di etichette la scelta della configurazione deve basarsi su una misura calcolata fuori dal test.

Il primo istante di ciascun periodo usa come contesto la coda del periodo precedente: le finestre di ingresso del primo istante di validazione contengono gli ultimi istanti di addestramento, e lo stesso vale fra validazione e test. Il contesto non rientra fra gli istanti valutati.

Capitolo 4

Metodologia

Il capitolo descrive il detector nella forma usata sui campi ERA5. La Sezione 4.1 presenta l'architettura, cioè il generatore che opera sul campo intero e il discriminatore locale, e gli obiettivi dell'addestramento avversario. La Sezione 4.2 descrive l'ingresso del modello: finestra recente, codifica temporale e normalizzazione stagionale. Seguono i pesi delle variabili nell'errore di ricostruzione, il dropout Monte Carlo nelle due reti e gli score che ne derivano, la normalizzazione climatologica degli score, la validazione senza etichette e la ricostruzione di eventi geografici a partire dagli score. L'ultima sezione descrive una variante del generatore con attenzione su grafo. Il percorso che ha portato a queste scelte, a partire dalla configurazione dell'articolo, è descritto nel Capitolo 5.

4.1 Architettura e addestramento avversario

Il detector segue lo schema di STGAN [3] descritto nella Sezione 2.1: un generatore stima il campo dell'istante successivo a partire dagli istanti precedenti, e un discriminatore giudica se il campo di un istante, insieme alla sua storia recente, è osservato o generato. Il target del generatore è meteorologico e comprende le quindici variabili della Tabella 3.1. La griglia è definita direttamente in coordinate geografiche, con passo angolare di 0.5°, e la cadenza è di tre ore.

4.1.1 Generatore ConvGRU sul campo intero e celle assenti

Un campione è il campo completo di un istante, disposto sul reticolo $H \times W$ della Sezione 3.1. Il generatore ha tre rami. Il ramo recente elabora gli

R campi che precedono l'istante da stimare con una ConvGRU [10, 11], l'unità ricorrente convoluzionale delle equazioni (2.5)–(2.8), che sostituisce la convoluzione su grafo dell'articolo. Il ramo del trend elabora con una LSTM la serie di ciascuna cella su un periodo più lungo. Il ramo del calendario proietta la codifica temporale. Con R passi recenti, L passi di trend e F variabili, gli ingressi hanno forma $[B, R, F, H, W]$ per il ramo recente e $[B, L, N, F]$ per il trend; l'uscita ha forma $[B, F, H, W]$.

Le convoluzioni scorrono sull'intero reticolo: il campo ricettivo non è troncato al bordo di una regione e ogni cella viene ricostruita una sola volta. La LSTM del trend e la codifica temporale sono calcolate per cella e disposte sul reticolo. Le rappresentazioni dei tre rami sono concatenate cella per cella; una proiezione 1×1 seguita da tanh produce il campo stimato.

Le celle del reticolo prive di dati sono azzerate dopo la normalizzazione, e una maschera binaria M è fornita come canale aggiuntivo a ogni strato ConvGRU. Rispetto alle equazioni (2.5)–(2.8) cambiano l'ingresso e l'ultimo passaggio. I gate e lo stato candidato sono calcolati su X'_s, la concatenazione dei valori mascherati e di M, al posto di X_s; lo stato precedente H_{s-1} è già mascherato e lo stato aggiornato viene moltiplicato per la maschera, replicata sui canali:

$$H_s = M \odot \left[U_s \odot H_{s-1} + (1 - U_s) \odot \widetilde{H}_s \right]. \tag{4.1}$$

Il mascheramento dello stato impedisce alle celle assenti di conservare attivazioni da propagare negli strati o nei passi successivi. Non viene applicata una rinormalizzazione del kernel in funzione delle celle osservate, come avverrebbe in una partial convolution. Su ERA5 nessuna cella del reticolo è priva di dati, ma la maschera resta necessaria per il discriminatore, le cui patch sul bordo del dominio sono incomplete. Lo stato ricorrente è inizializzato a zero per ogni finestra. Il modello ha due strati ConvGRU da 32 canali con kernel 3×3, e una LSTM del trend a due strati con stato nascosto di dimensione 64.

4.1.2 Discriminatore locale

Il discriminatore giudica ogni cella sulla propria patch $P \times P$, con $P = 3$, come nell'articolo, dove giudica ogni nodo sul proprio sottografo. La patch di ogni cella è estratta dal campo, con le celle esterne al reticolo azzerate e indicate dalla maschera. Una ConvGRU codifica la storia recente della patch; la storia codificata è appiattita e proiettata linearmente. Il campo corrente della patch, osservato o generato, passa attraverso una proiezione 1×1 seguita da una sigmoide e da un massimo sulle celle valide. Le due rappresentazioni sono concatenate e alimentano uno strato nascosto e un'uscita sigmoidale. Il discriminatore restituisce quindi un valore per cella e per istante.

Le patch di tutte le celle sono valutate in un'unica passata, con le stesse maschere e gli stessi azzeramenti. L'uscita relativa a una cella è quella che il discriminatore produrrebbe sulla sua patch isolata. Una convoluzione che scorresse liberamente sul campo non darebbe lo stesso valore, perché la ConvGRU del discriminatore applica il padding all'interno di ciascuna patch.

4.1.3 Obiettivi di addestramento

Il discriminatore viene addestrato con reale uguale a zero e generato uguale a uno, come nell'articolo. Indicando con D_{reale} e D_{generato} le uscite sulle patch con il campo osservato e con il campo generato, gli obiettivi sono

$$\mathcal{L}_D = \tfrac{1}{2}\Big[\mathrm{BCE}(D_{\text{reale}}, 0) + \mathrm{BCE}(D_{\text{generato}}, 1)\Big], \tag{4.2}$$

$$\mathcal{L}_G = \lambda_G \ \mathrm{MSE}_w(\hat{x}, x) + \mathrm{BCE}(D_{\text{generato}}, 0), \tag{4.3}$$

dove MSE_w è l'errore quadratico medio sulle celle valide e sulle variabili, con i pesi delle variabili della Sezione 4.3, mediato poi sugli istanti del batch, e la BCE è mediata sulle uscite locali, una per cella. Rispetto alle equazioni (2.2)–(2.3) dell'articolo, l'errore di ricostruzione è un errore quadratico medio anziché una norma e la loss del discriminatore è dimezzata: la scelta segue il codice pubblicato dagli autori.

Generatore e discriminatore vengono aggiornati con ottimizzatori Adam [19] separati. Nel passo del generatore, i parametri del discriminatore sono congelati ma viene mantenuto il gradiente rispetto al campo generato; la storia della patch è ricalcolata con i pesi aggiornati del discriminatore. Il peso di ricostruzione λ_G è un parametro, con valore predefinito 500, quello dell'articolo. I tassi di apprendimento dei due ottimizzatori possono essere distinti: quello del discriminatore è espresso come rapporto rispetto a quello del generatore. Il coefficiente β_1 degli ottimizzatori vale 0.9, il valore del codice degli autori. Con rapporto n_D:n_G, sullo stesso batch vengono eseguiti prima n_D aggiornamenti del discriminatore e poi n_G del generatore, ciascuno con un proprio passaggio in avanti; il rapporto è un conteggio di aggiornamenti e non va confuso con il rapporto fra i tassi di apprendimento. Tassi, rapporto e peso di ricostruzione sono gli strumenti con cui si regola l'equilibrio fra le due reti; i valori usati sono scelti nel Capitolo 5.

Un'epoca comprende $\lceil T/B \rceil$ aggiornamenti per rete, con T istanti di addestramento utili e B istanti per batch, e ogni gradiente è mediato su tutte le celle di un istante. A ogni epoca vengono salvati i pesi e lo stato dei due ottimizzatori; un addestramento interrotto può essere ripreso soltanto con la stessa configurazione, la stessa normalizzazione e gli stessi riferimenti di validazione. Il calcolo usa la precisione mista BF16, con pesi mantenuti in FP32 e loss avversaria calcolata sui logit.

4.2 Ingresso: finestra recente, codifica temporale e normalizzazione stagionale

4.2.1 Finestra recente e trend

La finestra recente contiene gli R istanti che precedono quello da stimare. L'unità ricorrente spaziale la percorre in ordine: parte da uno stato nullo ed esegue un aggiornamento per ogni istante, sicché lo stato finale riassume gli R campi osservati. Con $R = 1$ il ramo recente vede soltanto l'ultimo istante e la ricorrenza si riduce a un solo aggiornamento. Con $R > 1$ il modello riceve anche l'evoluzione del campo negli istanti precedenti, e l'area che può influenzare una cella cresce con R, perché a ogni aggiornamento lo stato si propaga alle celle vicine. Il detector usa $R = 16$ passi, cioè 48 ore; il trend comprende 56 passi, cioè 168 ore, la stessa durata dell'articolo.

4.2.2 Codifica temporale ciclica

La codifica temporale dell'articolo, a 31 elementi, è composta dal giorno della settimana e dall'ora UTC. È pensata per il traffico e su ERA5 è poco adatta, per due motivi. Il primo è che il vettore è lo stesso per tutte le celle, mentre il dominio si estende per 65 gradi di longitudine: alla stessa ora UTC, l'ora solare delle celle più a ovest e quella delle celle più a est differiscono di oltre quattro ore. Il secondo è che non contiene la posizione nell'anno, e non distingue quindi le stagioni. È perciò sostituita da una codifica ciclica a quattro elementi, diversa per cella. Indicando con h_t l'ora UTC, con ℓ_n la longitudine in gradi, con g_t il giorno frazionario dell'anno e con G_t il numero di giorni dell'anno corrispondente, la codifica è

$$c_{tn} = [\sin\phi_{tn},\ \cos\phi_{tn},\ \sin\psi_t,\ \cos\psi_t]\,, \quad \phi_{tn} = \frac{2\pi}{24}\left(h_t + \frac{\ell_n}{15}\right), \quad \psi_t = \frac{2\pi g_t}{G_t}. \tag{4.4}$$

Il primo angolo rappresenta l'ora solare locale, ottenuta dalla sola longitudine senza fusi orari; il secondo la posizione nell'anno. Seno e coseno rendono vicini gli istanti vicini nel ciclo, come le ore 23 e le ore 1 oppure la fine di dicembre e l'inizio di gennaio. La codifica ciclica non contiene il giorno della settimana.

4.2.3 Normalizzazione stagionale

La normalizzazione dell'articolo è un min–max per variabile stimato sul training. Usa un solo intervallo per variabile, valido per tutte le celle e per

tutto l'anno. Su un dominio che va dal Sahara all'Europa settentrionale questo ha un limite: la scala non distingue un valore alto in assoluto, ma abituale per quella cella e quella stagione, da un valore lontano dagli estremi, ma insolito per quella cella e quella stagione. La normalizzazione stagionale riferisce invece ogni valore a ciò che è abituale nella stessa cella, nello stesso periodo dell'anno e alla stessa ora. Per ogni cella n, variabile f, ora del giorno o e giorno dell'anno g il valore è standardizzato,

$$z_{tnf} = \frac{x_{tnf} - \mu_{nfog}}{\sigma_{nfog}}, \tag{4.5}$$

con otto ore del giorno e 366 giorni dell'anno. Media e deviazione standard sono stimate sui soli anni di addestramento, raccogliendo i quindici giorni che precedono g e i quindici che lo seguono. La deviazione standard è calcolata attorno alla media lisciata di ciascun giorno, in modo che la variazione del ciclo stagionale all'interno della finestra non venga contata come variabilità.

La precipitazione richiede un passaggio in più. È nulla nella maggior parte degli istanti e assume di rado valori molto alti: media e deviazione standard dei valori originali sono determinate in larga parte da questi pochi valori. Prima della standardizzazione la precipitazione è quindi sostituita dalla sua radice quarta, che comprime i valori alti e lascia nullo ciò che è nullo; media e deviazione standard descrivono la radice e non il valore originale. A differenza del logaritmo, la radice è definita anche per i valori nulli e non richiede una costante aggiuntiva.

La deviazione standard σ_{nfog} non può scendere sotto una frazione della deviazione standard complessiva della variabile sul training: 0.1 per la precipitazione e per l'umidità del primo strato del suolo, 0.01 per le altre tredici variabili. Il limite evita la divisione per valori quasi nulli, come accade per la radiazione solare di notte.

L'ultimo passaggio riguarda il tempo. Gli anni di test seguono quelli di addestramento, fino a oltre vent'anni dopo. Per una variabile che nel periodo ha una tendenza, la differenza fra il clima degli anni di test e quello degli anni di addestramento entrerebbe in ogni valore standardizzato, e crescerebbe con la distanza dal training. Per tre variabili, temperatura a due metri, temperatura a 850 hPa e umidità del primo strato del suolo, ai valori standardizzati è quindi sottratta una retta nel tempo. La retta è una per variabile, uguale per tutte le celle: passa per le medie annuali dei valori standardizzati sull'intero dominio, è stimata sui soli anni di addestramento e viene prolungata agli anni successivi. La scelta segue la definizione adottata nella tesi: un'anomalia è uno scostamento rispetto al clima del momento, e non rispetto al clima degli anni di addestramento. Per le altre dodici variabili la retta non è sottratta. Fra queste c'è l'umidità specifica: la sua deriva inizia

dopo gli anni di addestramento, e una retta stimata su quegli anni non la descrive. Per questa variabile la correzione non può quindi essere applicata senza usare gli anni di test.

Dopo questi passaggi è applicato un min–max per variabile, stimato sul training, che riporta i valori nell'intervallo $[-1, 1]$ dell'uscita del generatore. Valori successivi esterni all'intervallo del training possono superare questi estremi, perché la trasformazione non applica un clipping.

4.3 Pesi delle variabili nell'errore di ricostruzione

Nell'articolo tutte le variabili contano allo stesso modo nell'errore di ricostruzione. Il detector pesa invece l'errore per variabile, in modo che ciascuna sia misurata in rapporto a quanto cambia abitualmente. Indicando con m_f il quadrato medio della variazione della variabile f su 24 ore, calcolato sui dati di addestramento normalizzati, il peso è

$$w_f = \frac{\bar{m}}{m_f}, \qquad \bar{m} = \frac{1}{F} \sum_{f=1}^{F} m_f, \tag{4.6}$$

con $F = 15$. La differenza a 24 ore confronta istanti alla stessa ora del giorno e non contiene quindi il ciclo giornaliero. Il fattore $\bar{m}$ lascia invariata la loss per un errore proporzionale a m_f. Il peso non misura la difficoltà del modello su una variabile: è una misura di quanto la variabile cambia, fissata prima dell'addestramento e senza usare il modello. I pesi moltiplicano l'errore quadratico di ciascuna variabile nel termine di ricostruzione della loss del generatore e nell'errore di ricostruzione da cui sono calcolati gli score. La scelta della distanza di 24 ore, confrontata con 3 ore e con l'assenza di pesi, è discussa nel Capitolo 6.

4.4 Dropout Monte Carlo nelle due reti e score

4.4.1 Dropout nel generatore e nel discriminatore

Lo score è campionato con il dropout Monte Carlo [13], nella forma che pone il dropout dopo gli encoder e prima degli strati di uscita. Il generatore riceve tre strati di dropout: sulla rappresentazione spaziale del ramo recente, sulla rappresentazione del trend e sulla loro concatenazione con la codifica

temporale, prima della proiezione di uscita. Il discriminatore ne riceve altrettanti, nelle posizioni corrispondenti: sulla storia codificata, sul campo corrente codificato e sullo strato nascosto che precede l'uscita. La probabilità è 0.2 in entrambe le reti. I dropout sono attivi nell'addestramento e nel calcolo degli score. L'articolo e il codice degli autori non usano il dropout: è un'aggiunta di questo lavoro.

Il discriminatore riceve il campo generato senza il dropout del generatore, sia nell'addestramento, nel proprio aggiornamento e nel termine avversario del generatore, sia negli score. Se ricevesse il campo con il dropout, potrebbe distinguere i campi generati da quelli osservati per il rumore che il dropout vi introduce, e non per il loro contenuto. Il dropout del generatore agisce quindi sull'errore di ricostruzione, quello del discriminatore sul suo giudizio.

4.4.2 Campioni Monte Carlo e componenti dello score

Durante il calcolo degli score il modello è in modalità di valutazione, con l'eccezione dei dropout, che restano attivi. Per ogni istante vengono estratti $J = 20$ campioni. Nel campione j il generatore ricostruisce il campo con una propria maschera, e il discriminatore giudica l'osservazione e il campo generato con una propria maschera, la stessa per i due giudizi: il campione corrisponde a un'unica estrazione delle due reti. Gli encoder del generatore e la codifica della storia nel discriminatore non dipendono dal dropout e sono calcolati una sola volta; a ogni campione vengono ripetuti i dropout e gli strati che li seguono.

Per la coppia tempo–località (t, n) e il campione j, la ricostruzione $\hat{x}^{(j)}$ dà l'errore di ricostruzione

$$s^{(j)}_{G,tn} = \frac{1}{|P_n|\,F} \sum_{c \in P_n} \sum_{f=1}^{F} w_f \left(\hat{x}^{(j)}_{tcf} - x_{tcf} \right)^2 , \tag{4.7}$$

dove P_n sono le celle valide della patch di n. La componente del discriminatore è, come nell'articolo, la differenza fra il giudizio sull'osservazione e quello sul campo generato,

$$s^{(j)}_{D,tn} = D^{(j)}_{\text{reale},tn} - D^{(j)}_{\text{generato},tn}. \tag{4.8}$$

La componente di ricostruzione media sui campioni,

$$\bar{s}_{G,tn} = \frac{1}{J} \sum_{j=1}^{J} s^{(j)}_{G,tn}, \tag{4.9}$$

è la media degli errori dei singoli campioni, e non l'errore della ricostruzione media. Per ogni cella e variabile le due quantità differiscono per la varianza

delle ricostruzioni:

$$\frac{1}{J}\sum_{j=1}^{J}\left(\hat{x}^{(j)}-x\right)^2=\left(\bar{\hat{x}}-x\right)^2+\frac{1}{J}\sum_{j=1}^{J}\left(\hat{x}^{(j)}-\bar{\hat{x}}\right)^2,\qquad \bar{\hat{x}}=\frac{1}{J}\sum_{j=1}^{J}\hat{x}^{(j)}. \tag{4.10}$$

La componente cresce quindi sia quando la ricostruzione si allontana dall'osservazione, sia quando i campioni non sono concordi fra loro.

4.4.3 Score combinato e score di ricostruzione

Dalla stessa esecuzione sono ricavati due score. Lo *score combinato* è quello dell'articolo. Le due componenti sono riportate su una scala comune con un min–max e sommate con peso unitario, campione per campione:

$$a_{tn}^{(j)}=\frac{s_{G,tn}^{(j)}-r_{\min}}{r_{\max}-r_{\min}}+\frac{s_{D,tn}^{(j)}-d_{\min}}{d_{\max}-d_{\min}},\qquad \bar{a}_{tn}=\frac{1}{J}\sum_{j=1}^{J}a_{tn}^{(j)}. \tag{4.11}$$

L'articolo indica che le due componenti sono normalizzate prima della somma, senza specificare come, e il codice degli autori salva le componenti senza combinarle: il min–max è quindi una scelta di questo lavoro. Gli estremi $r_{\min}$, $r_{\max}$, $d_{\min}$ e $d_{\max}$ sono quelli delle due componenti medie sui campioni negli anni di validazione, esclusi i valori segnati come insoliti (Sezione 4.6.1), e restano fissi per il test: nessuna quantità dello score è stimata sugli anni valutati. I valori del test possono uscire dall'intervallo $[0,1]$ di ciascuna componente, perché non è applicato un clipping.

Lo *score di ricostruzione* usa la sola componente $\bar{s}_{G,tn}$, espressa poi rispetto alla climatologia della propria località come nella Sezione 4.5. La scelta fra i due score è un risultato del confronto riportato nel Capitolo 6.

4.4.4 Dispersione

La dispersione associata a ciascuno score è la deviazione standard di popolazione dei suoi campioni; per lo score combinato,

$$u_{tn}=\sqrt{\frac{1}{J}\sum_{j=1}^{J}\left(a_{tn}^{(j)}-\bar{a}_{tn}\right)^2}, \tag{4.12}$$

nelle stesse unità dello score, e analogamente per la componente di ricostruzione. Misura quanto lo score cambia con le maschere di dropout delle due reti e non è una probabilità di anomalia; la sua calibrazione come misura di incertezza non è verificata dal metodo. Una segnalazione che resta sopra

la soglia anche con lo score diminuito di u_{tn} non dipende dalle maschere estratte. Le singole estrazioni non vengono conservate: media, deviazione standard e covarianza delle due componenti bastano a ricavare la dispersione di qualunque loro combinazione lineare.

4.5 Normalizzazione climatologica degli score

Una trasformazione successiva al calcolo degli score esprime ogni score rispetto alla climatologia della stessa località. Per la località n, il mese m e l'ora UTC o del timestamp t, appartenente all'anno y,

$$\zeta_{tn} = \frac{a_{tn} - \mu_{nmo}^{(-y)}}{\sigma_{nmo}^{(-y)}}, \tag{4.13}$$

dove media e deviazione standard sono calcolate sugli score della stessa località, mese e ora negli anni di validazione, esclusi i valori segnati come insoliti (Sezione 4.6.1), e restano fisse per il test. Non possono essere stimate sugli anni di addestramento, perché su quegli anni il modello ha già visto i dati e il suo errore è più basso di quello su anni nuovi. I gruppi con meno di trenta valori di riferimento, nel default, o con varianza nulla non ricevono uno score. La dispersione viene divisa per la stessa deviazione standard.

Lo scopo è rendere confrontabili località e stagioni in cui l'errore di ricostruzione ha una grandezza tipica diversa: senza questo passaggio, le segnalazioni si concentrerebbero dove l'errore è grande per natura. La trasformazione agisce sugli score, dopo l'addestramento, e non modifica il detector. È distinta dalla normalizzazione stagionale della Sezione 4.2, che agisce sull'ingresso e richiede un nuovo addestramento.

4.6 Validazione senza etichette

Gli anni di validazione servono a confrontare configurazioni del detector senza usare il test e senza etichette. Il confronto deve misurare quanto il modello ricostruisce il meteo normale: le condizioni insolite presenti negli anni di validazione sono quindi individuate con un criterio che non usa il modello, e tenute fuori dalle misure.

4.6.1 Valori insoliti della validazione

Un valore, cioè una coppia cella–istante, è segnato come insolito con due distanze calcolate sui dati standardizzati della Sezione 4.2. La prima è la

distanza dal normale stagionale: la media sulle variabili del quadrato dei valori standardizzati, con i pesi delle variabili della Sezione 4.3, che dice quanto il valore è lontano dal normale della propria cella, giorno e ora. La seconda è la variazione dall'istante precedente: la stessa media pesata sul quadrato della differenza rispetto a tre ore prima, che coglie i cambiamenti rapidi anche quando il valore resta vicino al normale. Ciascuna distanza è standardizzata con la media e la deviazione standard della stessa cella, dello stesso mese e della stessa ora negli anni di addestramento, così che un luogo o una stagione più variabili non concentrino le segnalazioni. Un valore è segnato quando almeno una delle due distanze standardizzate supera il livello oltrepassato dal 5% dei valori di addestramento. Medie, deviazioni standard e livelli sono stimati sui soli anni di addestramento; la validazione riceve soltanto le segnalazioni.

I valori segnati non entrano nelle misure calcolate sulla validazione, e nelle finestre di ingresso degli istanti di validazione sono sostituiti dal normale stagionale, cioè dal valore standardizzato nullo. In questo modo né il bersaglio né la storia recente da cui il modello parte contengono le condizioni insolite.

4.6.2 Distanza fra campi osservati e ricostruiti nello spazio delle componenti principali

La misura usata per confrontare le configurazioni confronta osservazioni e ricostruzioni in uno spazio indipendente dal modello. Lo spazio è ottenuto da un'analisi delle componenti principali dei campi di addestramento: ogni campione è il campo completo di un istante, normalizzato e appiattito su località e variabili. Sono usati i campi con la quota più bassa di valori insoliti, nello stesso numero per ogni mese, e sono conservate 300 componenti principali. Lo spazio è costruito una sola volta, prima delle esecuzioni, e successivamente soltanto caricato.

Su questo spazio viene definito un riferimento per la validazione: $S = 5$ sottoinsiemi fissi e disgiunti di 512 campi normali, scelti con lo stesso criterio, le coordinate delle loro osservazioni nello spazio e una banda σ pari alla distanza euclidea mediana fra tali coordinate. Anche questo riferimento è fissato prima delle esecuzioni. A ogni epoca, per ciascun sottoinsieme, si calcola la stima non distorta della Maximum Mean Discrepancy [20]

$$\widehat{\mathrm{MMD}}^2 = \frac{1}{n(n-1)} \sum_{i \neq i'} k(x_i, x_{i'}) + \frac{1}{n(n-1)} \sum_{i \neq i'} k(y_i, y_{i'}) - \frac{2}{n^2} \sum_{i,i'} k(x_i, y_{i'}), \tag{4.14}$$

dove x_i sono le coordinate delle osservazioni, y_i quelle delle ricostruzioni del generatore e il kernel è la media di tre RBF,

$$k(a,b) = \frac{1}{3} \sum_{c \in \{0.5,\, 1,\, 2\}} \exp\left(-\frac{\|a-b\|^2}{2(c\sigma)^2} \right). \tag{4.15}$$

Vengono registrate media e varianza della stima sui sottoinsiemi e la media delle ultime cinque epoche, che è la quantità usata per scegliere fra configurazioni. La stima non distorta può assumere valori leggermente negativi. Poiché tutte le esecuzioni confrontate caricano gli stessi riferimenti, le differenze nella misura non dipendono da una nuova stima dello spazio o della banda. Una MMD più bassa indica ricostruzioni più vicine alle osservazioni nello spazio considerato; non misura direttamente la qualità del rilevamento delle anomalie.

4.6.3 Diagnostiche per epoca e misure finali

Al termine di ogni epoca un sottoinsieme fisso della validazione, 32 istanti equispaziati con tutte le celle, viene elaborato con un passaggio deterministico, a dropout spento. Vengono registrate la differenza assoluta media fra le attivazioni del penultimo strato del discriminatore sull'osservazione e sulla ricostruzione e la variazione dello score fra epoche consecutive sulle stesse celle. Queste quantità e la MMD non entrano in una loss, in un aggiornamento dei pesi o negli score; sono calcolate senza gradiente e ripristinando gli stati dei generatori casuali, così da non alterare la traiettoria dell'addestramento.

Dopo l'ultima epoca, su tutti i valori validi e non segnati della validazione, viene calcolata la componente di ricostruzione media sui campioni Monte Carlo, riassunta da media, deviazione standard, mediana e 95-esimo percentile. Gli stessi campioni danno gli estremi delle due componenti usati dallo score combinato.

4.7 Eventi geografici

Gli score di un istante formano un campo sulla griglia. Gli eventi geografici sono ricavati da questi campi in una fase distinta, successiva al calcolo degli score e senza un nuovo aggiornamento dei pesi del detector. La Figura 4.1 riassume i passaggi.

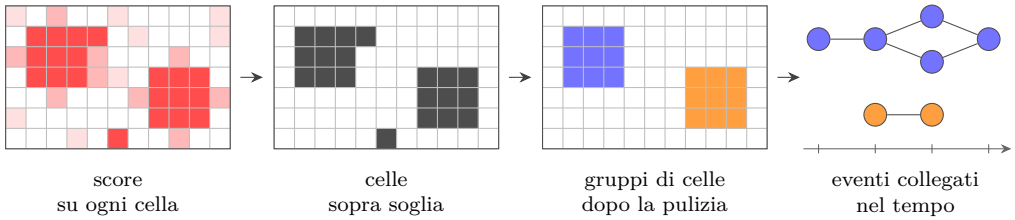


Figura 4.1: Dagli score agli eventi geografici, su un esempio illustrativo. Gli score di un istante sono riportati sulla griglia; le celle sopra soglia formano una maschera, da cui apertura e chiusura rimuovono le celle isolate e le sporgenze; le celle rimaste sono riunite in gruppi di celle adiacenti. I gruppi di istanti consecutivi sono poi collegati: un evento è un insieme di gruppi collegati, e resta unico anche quando un gruppo si separa in due o due gruppi si fondono.

4.7.1 Soglia, morfologia e cluster spaziali

Gli score $[T, N]$ vengono ricollocati sulla griglia $[T, H, W]$. La selezione iniziale può utilizzare una soglia assoluta oppure un percentile degli score finiti, globale per default o distinto per istante. Una cella è selezionata soltanto se lo score è strettamente maggiore della soglia.

Per ogni istante, la maschera binaria viene sottoposta ad apertura e chiusura, rispettando le celle valide. Il default usa un elemento strutturante quadrato 3×3 e un'iterazione per operazione. Le componenti connesse sono individuate con otto vicini e possono essere filtrate per numero minimo di celle. Le operazioni morfologiche possono rimuovere o aggiungere celle rispetto alla selezione iniziale: i cluster risultanti non coincidono necessariamente con l'insieme degli score sopra soglia. Le aree dei cluster sono ottenute sommando le aree sferiche delle celle e i centroidi sono pesati con tali aree.

4.7.2 Collegamento temporale, separazioni e fusioni

I cluster di istanti consecutivi vengono collegati secondo sovrapposizione, sovrapposizione dopo dilatazione, distanza dei centroidi oppure unione dei criteri. Indicando con A e B i supporti di due cluster, il rapporto di sovrapposizione è

$$o(A, B) = \frac{|A \cap B|}{\min(|A|, |B|)}. \tag{4.16}$$

Non si tratta dell'intersezione sull'unione. Nel criterio dilatato, A è sostituito dal supporto ottenuto dopo dilatazione, anche nel denominatore. Il default utilizza una dilatazione di una cella e una soglia di sovrapposizione pari a 0.1.

L'identità di un evento corrisponde a una componente connessa del grafo temporale dei cluster. Il collegamento non è vincolato a essere uno a uno: una separazione mantiene i rami nello stesso evento, mentre una fusione unifica retrospettivamente le identità precedenti. Un salto nella cadenza temporale interrompe i collegamenti. La durata riportata comprende l'intervallo rappresentato dall'ultimo istante,

$$d_{\text{evento}} = t_{\text{fine}} - t_{\text{inizio}} + \Delta t, \qquad \Delta t = 3\,\text{h}. \tag{4.17}$$

La dispersione dello score viene riportata per cluster e per evento, come media e massimo sulle celle; non partecipa alla soglia, alla morfologia o ai collegamenti. L'unificazione retrospettiva degli eventi definisce un'analisi successiva al periodo osservato, non un sistema di allerta in tempo reale.

4.8 Variante del generatore con attenzione su grafo

Nella variante su grafo ogni cella valida è un nodo. Ciascun nodo riceve un arco da ognuno degli otto vicini immediati presenti sulla griglia e da sé stesso. Gli archi sono diretti e memorizzati in forma sparsa; i bordi del dominio non sono collegati fra loro. Gli archi non hanno pesi geografici.

Lo strato di attenzione è quello delle equazioni (2.9)–(2.11), a più teste e con pendenza negativa 0.2 nella LeakyReLU; $\mathcal{N}(i)$ è l'insieme delle sorgenti degli archi entranti in i, compreso i stesso. Lo strato sostituisce la convoluzione nei gate dell'unità ricorrente. Siano $\mathcal{A}_r$, $\mathcal{A}_u$ e $\mathcal{A}_c$ tre strati di attenzione distinti, con le teste mediate e senza non linearità propria, e X'_s l'ingresso del passo s concatenato alla maschera. L'aggiornamento di uno strato ricorrente è

$$R_s = \sigma(\mathcal{A}_r([X'_s, H_{s-1}]))\,, \tag{4.18}$$

$$U_s = \sigma(\mathcal{A}_u([X'_s, H_{s-1}]))\,, \tag{4.19}$$

$$\widetilde{H}_s = \tanh(\mathcal{A}_c([X'_s, R_s \odot H_{s-1}]))\,, \tag{4.20}$$

$$H_s = M \odot \left[U_s \odot H_{s-1} + (1 - U_s) \odot \widetilde{H}_s\right]. \tag{4.21}$$

È la forma delle equazioni (2.5)–(2.8), con l'attenzione su grafo al posto della convoluzione spaziale e con lo stesso trattamento della maschera della Sezione 4.1.1. I default prevedono due strati ricorrenti, quattro teste e 32 canali. Poiché il gate di reset e lo stato candidato applicano l'operatore in sequenza, a ogni passo lo stato si propaga di due archi: con $R \geq 2$ passi recenti e due strati, l'ingresso del primo passo raggiunge i nodi fino a $2R + 1$

archi di distanza. La ConvGRU con kernel 3×3 ha la stessa struttura e lo stesso raggio.

La LSTM del trend elabora una sequenza per nodo e la codifica temporale è proiettata per nodo; seguono i dropout della Sezione 4.4 e la proiezione di uscita, che restituisce $[B, N, F]$. Il discriminatore resta quello locale a patch. Un campione è un istante con tutti i nodi: la variante ha la stessa unità del campione, lo stesso numero di aggiornamenti per epoca, la stessa struttura ricorrente e lo stesso raggio del generatore ConvGRU; cambia il modo di pesare i vicini e, con esso, il numero di parametri.

Capitolo 5

Esperimenti

Il capitolo ripercorre l'evoluzione del detector, dalla prima applicazione di STGAN ai dati PVGIS fino alla configurazione descritta nel Capitolo 4, e definisce poi le configurazioni di addestramento, il protocollo di valutazione, le metriche e i rilevatori senza modello con cui il detector è confrontato. I risultati sono nel Capitolo 6.

5.1 Evoluzione del detector

Il detector non è stato definito in un solo passo. È il risultato di un percorso in cui ogni configurazione ha mostrato un limite misurato, e il limite ha motivato la modifica successiva. La sezione ripercorre i passi in ordine; la Tabella 5.1 li riassume.

5.1.1 STGAN sui dati PVGIS

Il detector è stato applicato per la prima volta alle serie orarie PVGIS del lavoro preliminare (Sezione 2.4): 1149 località del Piemonte, disposte su un reticolo regolare con passo di 5 km nella proiezione UTM del fuso 32, con tre variabili meteorologiche, cioè irradianza globale, temperatura a due metri e velocità del vento a dieci metri. Gli anni 2005–2018 sono usati per l'addestramento e il 2019 per il test. Sono state addestrate due versioni con gli stessi dati e lo stesso protocollo, per sei epoche con il tasso di apprendimento e il peso di ricostruzione dell'articolo. La versione su grafo segue l'articolo: il contesto di una località è il sottografo dei suoi otto vicini più prossimi, con pesi gaussiani delle distanze, il ramo recente contiene un passo e il trend 168 ore. La variante a griglia sostituisce la convoluzione su grafo con una ConvGRU su una patch 3×3 del reticolo, con kernel di lato 1, 3 e 5; sul bordo

Tabella 5.1: Passi dell'evoluzione del detector, con il limite osservato che ha motivato il passo successivo.

Passo	Che cosa cambia	Limite osservato
STGAN sui dati PVGIS	Detector dell'articolo su tre variabili di 1149 località, su grafo e su griglia	Solo grandezze legate al fotovoltaico; decisioni poco stabili fra configurazioni
STGAN su ERA5, a patch	Quindici variabili su un dominio ampio	Milioni di aggiornamenti per epoca; il discriminatore prevale nella prima epoca
Campo intero	Un campione è il campo di un istante; sedici passi recenti	Il discriminatore riconosce il dropout del generatore
Discriminatore senza il dropout del generatore	Il discriminatore giudica la ricostruzione senza dropout	L'errore è dominato da una variabile; lo score combinato è instabile
Configurazione adattata	Normalizzazione stagionale, pesi delle variabili, score di ricostruzione con climatologia	Soglie e scelte calcolate sugli anni di test
Validazione di tempo normale	Anni di validazione senza valori insoliti, ricerca dei parametri, dropout nel discriminatore, estremi dello score dalla validazione	–

della regione 232 località hanno una patch incompleta. Lo score combinato è calcolato con minimo e massimo delle due componenti sull'intero test, e sono segnalate le osservazioni nell'1% più alto.

Due risultati hanno indirizzato il lavoro. Il primo riguarda il contenuto delle segnalazioni. Nella variante a griglia con kernel 3 il 75.5% dell'errore di ricostruzione delle osservazioni segnalate è dovuto all'irradianza, il 15.8% alla temperatura e l'8.6% al vento. I dati PVGIS contengono soltanto le grandezze da cui dipende la produzione fotovoltaica, e un'osservazione segnalata non può essere ricondotta a una condizione meteorologica più generale.

Il secondo riguarda la stabilità delle decisioni. Le configurazioni a griglia e la versione su grafo segnalano osservazioni in gran parte diverse: l'indice di Jaccard fra le segnalazioni di ciascuna configurazione a griglia e quelle della versione su grafo è compreso fra 0.032 e 0.052, da sei a dieci volte il valore atteso per due detector indipendenti, 0.005, ma più del 90% delle osservazioni segnalate da una configurazione a griglia non è segnalato dalla versione su grafo. La loss del discriminatore resta fra 0.60 e 0.63 per tutte le sei epoche, vicina al valore $\ln 2 \approx 0.69$ di un discriminatore che non distingue, e lo score è concentrato in un intervallo stretto: con kernel 3, sulle patch complete, la mediana è 0.489 e il 95-esimo percentile 0.553. Una lettura coerente con queste misure è che su questi dati lo score distingua poco le osservazioni fra loro, e che piccole differenze fra i modelli bastino a cambiare la composizione dell'1% più alto.

Per individuare condizioni meteorologiche insolite di tipo più generale e descriverne l'origine, il lavoro è passato ai campi ERA5 del Capitolo 3: quindici variabili in superficie e a 850 hPa, su un dominio che comprende l'Europa e il Mediterraneo.

5.1.2 Dalla patch al campo intero

Su ERA5 il detector ha mantenuto dapprima l'unità del campione della variante a griglia: una cella con la propria patch. Con questa unità il numero di campioni per epoca è il prodotto fra istanti e celle, e un'epoca comprendeva 3025793 aggiornamenti dei pesi. Con il dropout nel generatore, la loss del discriminatore è scesa da 0.32 a 0.0035 entro la prima epoca, ed è rimasta su quel livello: il discriminatore distingueva quasi perfettamente i campi generati da quelli osservati. Un ramo recente più lungo non risolveva il problema, perché su una patch 3×3 moltiplica il costo di ogni campione senza ampliare l'area osservata.

Il generatore è stato quindi portato sul campo intero (Sezione 4.1.1): un campione è il campo completo di un istante, ogni cella è ricostruita una sola volta e la ConvGRU scorre sull'intero reticolo. Il numero di aggiornamenti

per epoca scende al numero di istanti, 70072, e la finestra recente è portata a sedici passi, cioè 48 ore. Il discriminatore resta locale.

5.1.3 Il discriminatore e il dropout del generatore

Anche sul campo intero il discriminatore tendeva a prevalere. La causa è stata individuata confrontando, a pesi e dati fissati, il giudizio del discriminatore sulla ricostruzione calcolata con e senza il dropout del generatore. Su 400 istanti di test, con il modello alla terza epoca, la mediana del giudizio sulla ricostruzione è 0.007 senza dropout e 0.84 con il dropout dei 20 campioni Monte Carlo; il giudizio sull'osservazione non cambia. Il discriminatore riconosceva quindi i campi generati soprattutto dal rumore del dropout, che il generatore non può eliminare perché è introdotto per costruzione. Da allora il discriminatore riceve la ricostruzione senza il dropout del generatore, nell'addestramento e negli score (Sezione 4.4). Il generatore dell'articolo non contiene dropout, e il problema non si pone.

5.1.4 Dalla configurazione di base a quella adattata

Con il campo intero e la correzione del dropout si ottiene la configurazione di base: normalizzazione min–max, lo stesso peso per tutte le variabili nell'errore di ricostruzione e lo score dell'articolo, somma dell'errore di ricostruzione e del termine del discriminatore. È addestrata per sei epoche e valutata sugli anni 2005–2025. Su questa configurazione sono emersi due limiti, e ciascuno ha motivato una modifica.

Una sola variabile domina l'errore. La Tabella 5.2 riporta quanta parte dell'errore quadratico di ricostruzione è dovuta a ciascuna variabile, su 400 istanti del periodo di test e tutte le 10611 celle. La copertura nuvolosa produce il 77.8% dell'errore, e il 97.5% nell'1% di osservazioni con l'errore più alto; con quote uguali ogni variabile avrebbe il 6.7%. In pratica, le osservazioni con l'errore più alto sono errori sulla copertura nuvolosa.

Lo squilibrio è già nei dati. La copertura nuvolosa produce l'84.5% della variazione quadratica media su 24 ore dei dati normalizzati, e sulle quindici variabili la correlazione di rango fra questa quota e la quota di errore è 0.87: dopo il min–max, una variabile pesa nell'errore quanto cambia da un giorno all'altro. Da qui i pesi della Sezione 4.3, che riportano le variabili sulla stessa scala di variazione.

Lo score combinato è instabile. Il secondo limite riguarda lo score. La Tabella 5.3 confronta lo score dell'articolo con il solo errore di ricostruzione

Tabella 5.2: Configurazione di base su ERA5: quota dell'errore quadratico di ricostruzione dovuta a ciascuna variabile, su tutte le osservazioni e nell'1% con l'errore più alto. 400 istanti del periodo di test. Con quote uguali ogni variabile avrebbe il 6.7%.

Variabile	Quota dell'errore	Quota nell'1% più alto
Copertura nuvolosa totale	77.8%	97.5%
Radiazione solare discendente alla superficie	3.6%	0.6%
Umidità specifica a 850 hPa	3.5%	0.4%
Altezza dello strato limite	2.9%	0.3%
Velocità d'attrito	2.0%	0.2%
Altre dieci variabili, ciascuna	al più 1.6%	al più 0.2%

su due misure che non richiedono etichette: quanto lo score segnala le stesse osservazioni dopo un'epoca di addestramento in più, e quanto durano gli eventi costruiti con la procedura della Sezione 4.7.

Tabella 5.3: Configurazione di base su ERA5: score dell'articolo e solo errore di ricostruzione. La stabilità è la quota delle osservazioni nell'1% più alto di un'epoca che resta nell'1% più alto all'epoca successiva, su 400 istanti: è riportato l'intervallo sulle cinque coppie di epoche consecutive, e due ordinamenti indipendenti darebbero l'1%. Gli eventi sono costruiti sul periodo 2005–2025 segnalando il 5% delle osservazioni con lo score più alto.

Misura	Score dell'articolo	Errore di ricostruzione
Stabilità fra epoche consecutive	30.3%–48.3%	72.5%–82.1%
Eventi di durata superiore a 24 ore	0	1501
Eventi di un solo istante	93.8%	74.3%

Lo score dell'articolo segue quasi soltanto il termine del discriminatore: alla sesta epoca la sua correlazione con questo termine è 0.92, quella con l'errore di ricostruzione -0.03. Cambia molto da un'epoca all'altra e non produce eventi che superano le 24 ore. L'errore di ricostruzione segnala in gran parte le stesse osservazioni e produce eventi che durano nel tempo.

Configurazione adattata. La configurazione adattata mantiene il modello e cambia tre elementi: la normalizzazione stagionale della Sezione 4.2, i pesi delle variabili della Sezione 4.3 e lo score, che diventa il solo errore di

ricostruzione espresso rispetto alla climatologia della propria cella (Sezione 4.5). La climatologia è necessaria perché l'errore di ricostruzione ha una grandezza tipica diversa da luogo a luogo e da stagione a stagione: senza di essa la quota di osservazioni segnalate, che sarebbe del 5% ovunque se luogo e stagione non contassero, va dal 1.5% al 13.7% fra fasce di latitudine e mesi, con il massimo nelle zone più meridionali d'estate; con la climatologia resta fra il 3.6% e il 5.8%. Le osservazioni di questa sezione vengono da una sola esecuzione, con un solo seme; composizione dell'errore e stabilità sono misurate su 400 istanti e non sull'intero periodo di test.

5.1.5 Validazione di tempo normale e dropout nel discriminatore

Nella configurazione adattata le soglie, la climatologia degli score e, per lo score combinato, gli estremi delle due componenti sono calcolati sugli stessi anni su cui il detector è valutato, e le scelte fra configurazioni non hanno una misura calcolata fuori dal test. L'ultimo passo non nasce da un limite del modello ma da questo requisito del protocollo. I dati sono divisi in anni di addestramento, di validazione e di test (Sezione 3.2); dalla validazione sono tolte le condizioni insolite, individuate senza modello (Sezione 4.6.1); le configurazioni sono confrontate con la distanza fra campi osservati e ricostruiti della Sezione 4.6, e i parametri che regolano l'equilibrio fra le due reti sono scelti con una ricerca automatica (Sezione 5.2).

Nello stesso passo il dropout è stato aggiunto anche al discriminatore. Con il discriminatore che riceve la ricostruzione senza il dropout del generatore e privo di dropout proprio, la sua componente dello score era identica in tutti i campioni Monte Carlo, e la dispersione dello score combinato veniva dal solo generatore. Con il dropout nelle due reti entrambe le componenti hanno una dispersione, e gli estremi con cui sono riportate sulla stessa scala sono fissati sulla validazione (Sezione 4.4).

5.2 Configurazioni di addestramento

La configurazione del detector è fissata, a eccezione dei quattro parametri che regolano l'equilibrio fra generatore e discriminatore, scelti con una ricerca bayesiana. La Tabella 5.4 riporta gli uni e gli altri.

L'obiettivo della ricerca è la media delle ultime cinque epoche della distanza fra campi osservati e ricostruiti della Sezione 4.6, da minimizzare. Ogni esecuzione della ricerca è addestrata e misurata sulla validazione, senza calcolare gli score sul test; la configurazione scelta è valutata sul test a partire

Tabella 5.4: Configurazione del detector su ERA5. Nella parte superiore i valori fissati, nella parte inferiore i parametri della ricerca, con l'intervallo esplorato; la distribuzione logaritmica rende equidistanti, per esempio, i rapporti 0.5 e 2.

Elemento	Valore
Anni di addestramento, validazione, test	1980–1999, 2000–2004, 2005–2025
Unità del campione e batch	Campo intero, un istante per batch
Generatore	ConvGRU, due strati da 32 canali, kernel 3×3
Finestra recente e trend	16 e 56 passi, cioè 48 e 168 ore
Codifica temporale	Ciclica, per cella
Normalizzazione	Stagionale, con retta per tre variabili, poi min–max
Pesi delle variabili	Inversi della variazione su 24 ore
Dropout	0.2, nel generatore e nel discriminatore
Campioni Monte Carlo negli score	20
Epoche	6
Precisione	BF16
Tasso di apprendimento del generatore	da 10^{-4} a $3 \cdot 10^{-3}$, logaritmica
Rapporto fra i tassi del discriminatore e del generatore	da 0.25 a 4, logaritmica
Peso di ricostruzione λ_G	da 50 a 2000, logaritmica
Aggiornamenti per batch, n_D:n_G	1:1, 2:1 oppure 1:2

dai pesi salvati. Un'epoca comprende 58384 aggiornamenti per rete, cioè gli istanti di addestramento meno i 56 di contesto del trend, e dura circa 2.4 ore.

I modelli sono implementati in PyTorch [21]. I dati sono letti con xarray [22]; le tabelle di score sono elaborate con pandas [23]. Tutti i modelli sono addestrati su una scheda NVIDIA RTX PRO 6000 Blackwell.

5.3 Protocollo di valutazione

Gli score sono valutati sugli anni 2005–2025, su tutti gli istanti e tutte le 10611 celle. Dalla stessa esecuzione sono ricavati lo score combinato e lo score di ricostruzione della Sezione 4.4. Il protocollo separa ciò che si stima da ciò che si valuta. Le quantità che descrivono l'errore abituale del modello, cioè la climatologia degli score, gli estremi dello score combinato e le soglie, sono stimate sugli anni di validazione e restano fisse per il test; le scelte fra varianti dello score sono fatte anch'esse sulla validazione. Le soglie sono il 95-esimo e il 99-esimo percentile degli score di validazione, che sul test segnalano circa il 5% e l'1% delle osservazioni. Non esistono etichette di anomalia: il detector è confrontato con i rilevatori senza modello della Sezione 5.5, con soglie fissate allo stesso modo, e con le osservazioni di stazione.

Osservazioni di stazione. La conferma esterna viene da E-OBS [4], una griglia giornaliera costruita da osservazioni di stazione sulla terraferma europea e non derivata da ERA5. È usata la media dell'ensemble a 0.25°, versione 33.0e, distribuita dal Climate Data Store di Copernicus; ogni cella riceve la media dei punti E-OBS che contiene. Come indicatori sono usate la precipitazione giornaliera, la pressione al livello del mare, la sua variazione rispetto al giorno precedente, la radiazione solare e la temperatura media giornaliera. Un valore è insolito quando è nel 5% più estremo per la cella e il mese di calendario: il più alto per la precipitazione, il più basso per pressione, variazione della pressione e radiazione, il più alto oppure il più basso per la temperatura. Una coppia cella–giorno è segnalata da un rilevatore se lo è almeno uno degli istanti di quel giorno. Il valore giornaliero di E-OBS segue la convenzione di ciascun fornitore di dati e non coincide necessariamente con il giorno UTC [4]: il confronto è fatto con lo stesso giorno e con il successivo. Le celle con almeno una stazione sono 4670 per la precipitazione, 3518 per la pressione, 3156 per la radiazione e 4421 per la temperatura; le stazioni sono più rade nel sud e nell'est del dominio [4]. Non è stato verificato se le misure di pressione delle stazioni entrino nell'assimilazione di ERA5: per questo indicatore l'indipendenza fra i due insiemi di dati potrebbe essere solo parziale.

Anticipo. L'anticipo è misurato cella per cella. Un episodio di un rilevatore inizia quando una cella è segnalata dopo almeno 24 ore senza segnalazioni; a ogni inizio si verifica se l'altro rilevatore segnalava già la stessa cella senza interruzioni, e da quante ore. Come riferimento, la stessa verifica è svolta negli istanti in cui il primo rilevatore è quieto da altrettanto tempo e non inizia un episodio.

5.4 Metriche

L'accordo fra due rilevatori che segnalano gli insiemi di osservazioni A e B è misurato dall'indice di Jaccard,

$$J(A, B) = \frac{|A \cap B|}{|A \cup B|}, \tag{5.1}$$

che vale 1 quando gli insiemi coincidono e 0 quando sono disgiunti. Quando i rilevatori segnalano la stessa quota di osservazioni è riportata anche la quota delle segnalazioni di A che anche B segnala, $|A \cap B|/|A|$, che a parità di segnalazioni coincide con $|A \cap B|/|B|$. Nessuna delle due è una misura di accuratezza: due rilevatori possono concordare ed entrambi sbagliare.

La conferma da E-OBS di un gruppo G di coppie cella–giorno confronta la quota di coppie con un valore insolito nel gruppo con quella di tutte le coppie misurate:

$$R(G) = \frac{|G \cap U| \,/\, |G|}{|U| \,/\, |\Omega|}, \tag{5.2}$$

dove U è l'insieme delle coppie con un valore insolito e Ω quello di tutte le coppie con un valore misurato. Con $R = 1$ il gruppo ha valori insoliti quanto la media, con $R > 1$ più spesso. Per distinguere una perturbazione dal semplice vicinato di una perturbazione, il gruppo segnalato dal solo detector è confrontato anche con il suo anello: le coppie entro una cella da una coppia del gruppo, nello stesso giorno, non segnalate da alcun rilevatore. Celle e giorni vicini non sono indipendenti; l'intervallo al 95% di ogni rapporto è quindi ottenuto ricampionando con reinserimento gli anni interi, 2000 volte. Un intervallo interamente sopra 1 indica una quota più alta della media non spiegata dalla variabilità fra gli anni.

5.5 Rilevatori di confronto senza modello

Il detector è confrontato con tre rilevatori che non usano un modello appreso. Rappresentano i due modi più semplici di dire che il tempo di una cella è

insolito, e servono a stabilire che cosa il detector aggiunge a ciò che si ottiene senza addestramento. Sono calcolati sugli stessi dati standardizzati della Sezione 4.2.

La *distanza dal normale* è l'errore che si commetterebbe rispondendo, in ogni cella, con il valore normale per quel giorno e quell'ora: misura lo scostamento dal clima, e coglie per esempio il caldo o il freddo prolungati. La *variazione in tre ore* è l'errore che si commetterebbe rispondendo con il valore dell'istante precedente: misura il cambiamento rapido, e coglie per esempio il passaggio di un fronte. Il terzo rilevatore prende, cella per cella, il maggiore dei due. In entrambi gli errori ogni variabile è divisa per il proprio errore medio, così che le quindici variabili contino allo stesso modo, e ai tre score è applicata la stessa forma di normalizzazione climatologica dello score di ricostruzione (Sezione 4.5). Poiché questi rilevatori non usano un modello, errori medi e climatologia possono essere stimati direttamente sugli anni di addestramento, senza il problema dell'errore più basso sui dati già visti. Le soglie sono fissate come per il detector, al 95-esimo e al 99-esimo percentile degli score di validazione: i confronti sono quindi a parità di criterio.

Capitolo 6

Risultati e discussione

Il capitolo segue il protocollo della Sezione 5.3. La prima sezione misura il contributo di ciascun componente del detector, aggiungendoli uno alla volta alla configurazione dell'articolo. La seconda riporta la ricerca dei parametri dell'addestramento avversario e la configurazione scelta. Le sezioni successive analizzano gli score di questa configurazione sugli anni di test 2005–2025: il confronto con i rilevatori senza modello, la conferma dalle osservazioni di stazione di E-OBS, l'anticipo, l'estensione delle perturbazioni e la dispersione Monte Carlo. Le ultime riguardano la scelta dello score e dei pesi delle variabili, fatta sugli anni di validazione, e i limiti dei risultati. Non esistono etichette di anomalia: tutte le misure sono indirette. Salvo dove indicato, lo score del detector è lo score di ricostruzione con la normalizzazione climatologica.

6.1 Contributo dei componenti

Il contributo di ciascun componente è misurato aggiungendo i componenti uno alla volta, a partire dalla configurazione dell'articolo: normalizzazione min–max, nessun peso fra le variabili, discriminatore senza dropout. Le varianti sono la normalizzazione stagionale (Sezione 4.2), i pesi delle variabili (Sezione 4.3) e il dropout nel discriminatore (Sezione 4.4). Ogni variante è addestrata per un'epoca, con la stessa suddivisione degli anni e gli stessi parametri dell'addestramento avversario: il confronto è a parità di addestramento. Per ogni variante sono riportate la distanza fra campi osservati e ricostruiti sulla validazione, la distribuzione delle segnalazioni fra latitudini e mesi e la conferma dalle stazioni E-OBS (Tabella 6.1).

Tabella 6.1: Contributo dei componenti, aggiunti uno alla volta alla configurazione dell'articolo. MMD: distanza fra campi osservati e ricostruiti sulla validazione. Quote: intervallo della quota segnalata fra fasce di latitudine e mesi, 5% se luogo e stagione non contassero. E-OBS: rapporto "solo detector / tutte" nello stesso giorno. Da riempire con le run dell'ablazione.

Configurazione	MMD	Quote	Pioggia forte	Pressione bassa	Caldo
Articolo	–	–	–	–	–
+ normalizzazione stagionale	–	–	–	–	–
+ pesi delle variabili	–	–	–	–	–
+ dropout nel discriminatore	–	–	–	–	–

6.2 Ricerca dei parametri

La ricerca esplora i quattro parametri della Tabella 5.4. Da scrivere a ricerca conclusa: numero di esecuzioni, andamento della distanza fra campi osservati e ricostruiti per epoca, configurazione scelta e suo valore dell'obiettivo.

6.3 Confronto con i rilevatori senza modello

Complementarità. Il detector e i rilevatori senza modello segnalano in parte le stesse osservazioni (Figura 6.1). Al 5%, delle segnalazioni del detector il 50% è segnalato anche dalla distanza dal normale, il 52% dalla variazione in tre ore e il 58% dal maggiore dei due; all'1% le quote scendono a 43, 44 e 51%. I due rilevatori senza modello sono fra loro ancora meno simili: hanno in comune il 34% delle segnalazioni al 5% e il 28% all'1%. Misurano infatti due aspetti diversi del meteo, lo scostamento dal clima e il cambiamento rapido, e il detector condivide una parte delle segnalazioni con ciascuno. Sui cambiamenti più rapidi, l'1% delle variazioni in tre ore, il detector segnala il 75.6% dei valori, la distanza dal normale il 53.1% e il maggiore dei due rilevatori il 89.8%: il detector segue i cambiamenti rapidi più della distanza dal normale, meno del rilevatore costruito proprio su di essi.

Cosa segnala il solo detector. Rispetto al maggiore dei due rilevatori senza modello, il detector segnala da solo il 42% delle proprie osservazioni. Questi valori non sono meteo ordinario: nei due rilevatori senza modello si collocano, in mediana, all'88° e al 91° percentile, appena sotto la loro soglia,

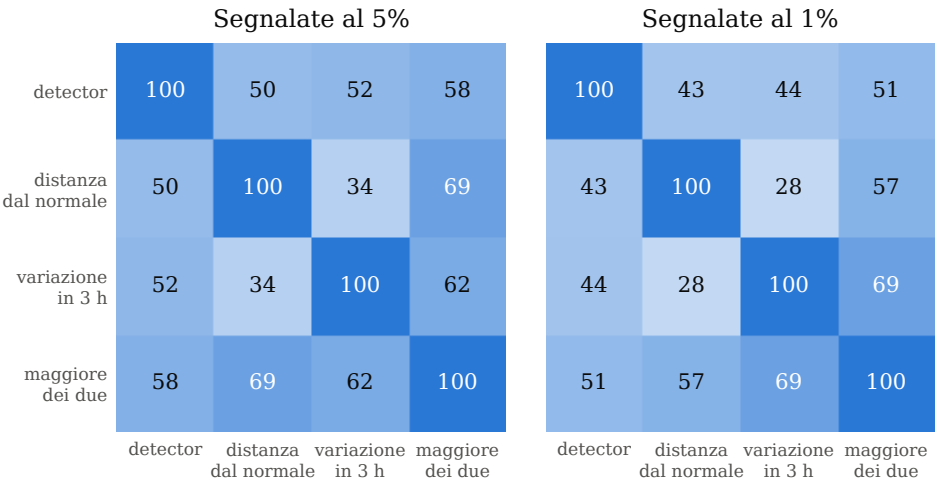


Figura 6.1: Sovrapposizione fra le segnalazioni del detector e dei tre rilevatori senza modello, al 5% e all'1% delle osservazioni. Ogni casella riporta la quota delle segnalazioni del rilevatore della riga segnalate anche dal rilevatore della colonna. Anni 2005–2025, un istante ogni 29. Valori provvisori.

mentre le osservazioni non segnalate da nessuno stanno intorno al 47°. Il 37% è segnalato di nuovo dal detector tre ore dopo, nella stessa cella, contro il 2% delle osservazioni non segnalate. Fra le osservazioni che il detector segnala senza la distanza dal normale, sono più spesso lontane dal normale stagionale, di oltre una deviazione standard, la velocità verticale, la precipitazione e la radiazione solare (49, 42 e 25%, contro 23, 16 e 13% di tutte le osservazioni). Nel 10.6% delle segnalazioni del solo detector la combinazione delle variabili è insolita senza che alcuna variabile lo sia da sola, contro l'1.4% di tutte le osservazioni. Il detector aggiunge quindi soprattutto situazioni in cui più variabili legate alla precipitazione e ai moti verticali si discostano insieme, in misura moderata.

6.4 Conferma dalle stazioni

Perturbazioni. Le osservazioni di stazione confermano che le segnalazioni del solo detector cadono in giornate perturbate (Tabella 6.2). Pioggia forte, pressione bassa e calo di pressione vi sono più frequenti della media, da 1.16 a 1.34 volte, con intervalli interamente sopra 1, e più frequenti che nelle celle immediatamente intorno, da 1.27 a 1.58 volte. Il segnale è debole rispetto a quello delle osservazioni segnalate anche dal rilevatore senza modello, da 2.3 a 3.6 volte la media, ed è dello stesso ordine di quello delle osservazioni

Tabella 6.2: Conferma dalle stazioni E-OBS. Rapporto R fra la quota di coppie cella–giorno con un valore insolito nel gruppo indicato e quella di riferimento, nello stesso giorno della segnalazione; fra parentesi l'intervallo al 95% ottenuto ricampionando gli anni. Il detector è confrontato con il maggiore dei due rilevatori senza modello; le soglie sono al 5%.

Gruppo / riferimento	Pioggia forte	Pressione bassa	Calo di pressione	Radiazione bassa	Caldo	Freddo
Solo detector / tutte	1.17 (1.12–1.21)	1.34 (1.27–1.40)	1.16 (1.11–1.22)	1.04 (1.00–1.07)	1.53 (1.45–1.60)	0.82 (0.79–0.86)
Solo detector / anello	1.58 (1.55–1.62)	1.35 (1.32–1.37)	1.27 (1.25–1.29)	1.22 (1.20–1.25)	1.25 (1.22–1.28)	0.92 (0.90–0.95)
Solo detector / solo rilevatore	1.01 (0.98–1.05)	1.14 (1.09–1.19)	1.00 (0.97–1.04)	0.80 (0.76–0.83)	1.18 (1.11–1.26)	0.54 (0.50–0.58)
Entrambi / tutte	3.61 (3.48–3.74)	3.04 (2.95–3.12)	2.46 (2.39–2.53)	2.25 (2.16–2.34)	1.70 (1.61–1.78)	1.07 (1.00–1.14)

segnalate dal solo rilevatore senza modello: le parti che ciascuno segnala da solo sono confermate in misura simile, con un leggero vantaggio del detector sulla pressione bassa e del rilevatore senza modello sulla radiazione bassa. Il giorno successivo il rapporto del solo detector sale a 1.44 per la pioggia e a 1.18 per la radiazione bassa; poiché il giorno di E-OBS non coincide sempre con il giorno UTC, questo aumento non basta a indicare un anticipo.

Temperatura. Sul caldo insolito le segnalazioni del solo detector sono confermate 1.53 volte la media, e più di quelle del solo rilevatore senza modello (1.18). Sul freddo insolito il rapporto è invece sotto 1, 0.82: le segnalazioni del solo detector cadono nei giorni freddi meno spesso di un giorno qualsiasi, e anche le osservazioni segnalate insieme al rilevatore senza modello sono confermate appena più della media. Il caldo insolito è definito sull'intero periodo di test e si concentra negli anni più recenti, nei quali anche lo score è un poco più alto: questo può aumentare il rapporto sul caldo indipendentemente dal detector.

6.5 Anticipo

All'inizio degli episodi dell'1% dei cambiamenti più rapidi, il detector, al 5%, segnala già la stessa cella nel 50.1% dei casi, e da almeno sei ore nel 19.8%. Nelle stesse condizioni la variazione in tre ore, alla stessa soglia del 5%, segnala già il 38.1% degli inizi e il maggiore dei due rilevatori senza modello il 40.7%; negli istanti senza alcun inizio la quota è del 3%. L'anticipo è in prevalenza di tre ore, un passo temporale, e il detector non segnala affatto il

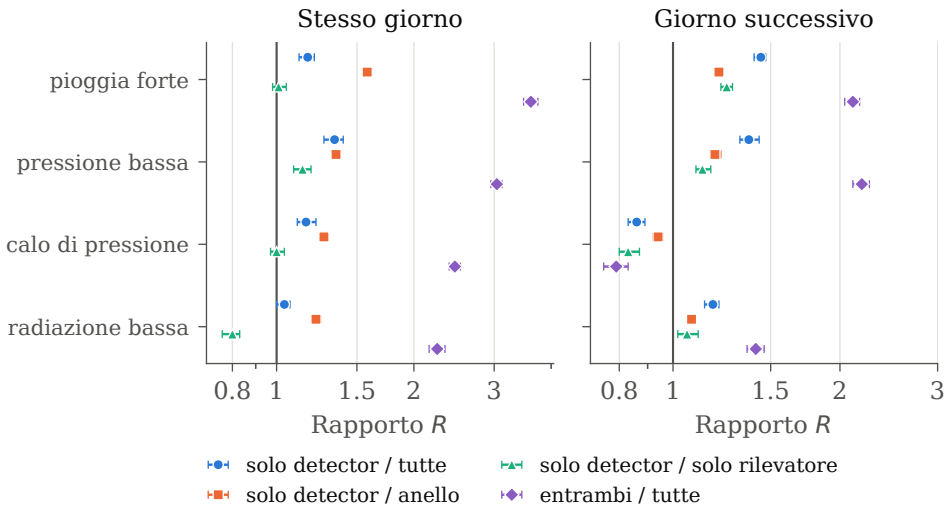


Figura 6.2: Conferma dalle stazioni E-OBS per quattro indicatori di perturbazione, nello stesso giorno della segnalazione e nel successivo. Le barre riportano il rapporto R con il suo intervallo al 95%; la linea verticale corrisponde a $R = 1$, una quota pari alla media. Scala logaritmica. Valori provvisori.

6.4% di questi episodi. Sugli scostamenti lenti dal clima il vantaggio non si ripete: all'inizio degli episodi più forti della distanza dal normale il detector è già attivo nel 45.7% dei casi, contro il 54.8% della stessa distanza dal normale alla soglia del 5%. Si tratta di un anticipo rispetto agli altri rilevatori sugli stessi dati, non di una previsione.

6.6 Estensione delle perturbazioni

Le celle che il detector segnala da solo sono per l'86–94% contigue a una perturbazione segnalata dai rilevatori senza modello. Aggiungendo le segnalazioni del detector, l'area delle perturbazioni di almeno dieci celle cresce in mediana del 30–34%, e più di una su tre cresce di almeno la metà; usando al loro posto le segnalazioni del detector di un mese dopo, che conservano la quota e la struttura spaziale ma non il legame con il giorno, l'area mediana non cresce e solo il 13% delle perturbazioni cresce di almeno la metà. All'1% l'area complessiva cresce del 40–53% contro l'7–10% del riferimento. Il detector estende quindi le perturbazioni già individuate più che segnalarne di nuove.

6.7 Incertezza Monte Carlo

La deviazione standard dei 20 campioni è più alta dove il detector segnala: in mediana circa 0.31–0.41 nelle unità dello score normalizzato, contro 0.09 sulle osservazioni non segnalate da nessuno. Restano sopra la soglia anche abbassando lo score di una deviazione standard l'82–86% delle segnalazioni condivise con un rilevatore senza modello e il 67–72% di quelle del solo detector. Le segnalazioni del solo detector sono più vicine alla soglia, in rapporto alla dispersione dei campioni, e quindi più spesso dipendenti dalle maschere di dropout estratte.

6.8 Scelta dello score e dei pesi delle variabili

Le due scelte del metodo che si discostano di più dall'articolo, lo score e i pesi delle variabili, sono fatte sugli anni di validazione, confrontando ciascuna con le sue alternative sugli stessi controlli: la distribuzione delle segnalazioni fra fasce di latitudine e mesi, che dovrebbe restare vicina al 5% ovunque, e la conferma dalle stazioni E-OBS, che copre anche gli anni di validazione. Tutte le alternative si calcolano dagli score della stessa esecuzione, senza un nuovo addestramento. Un'alternativa prevale su un indicatore E-OBS quando l'intervallo del suo rapporto "solo detector / tutte" sta sopra quelli delle altre senza sovrapporsi.

Score combinato e score di ricostruzione. La Tabella 6.3 confronta lo score di ricostruzione con lo score combinato dell'articolo, con e senza normalizzazione climatologica, sulla stessa esecuzione. Lo score combinato non richiede la climatologia per essere distribuito in modo uniforme fra luoghi e stagioni: senza di essa la quota segnalata resta fra il 4.3% e il 6.7%, mentre lo score di ricostruzione senza climatologia andava dall'1.5% al 13.7%. Le segnalazioni condivise con il rilevatore senza modello sono confermate in misura simile dai tre score. La differenza è nella parte che il detector aggiunge da solo: con lo score combinato le segnalazioni del solo detector cadono nei giorni di pioggia forte, di pressione bassa o di caldo insolito meno spesso della media, con rapporti fra 0.60 e 0.97, contro 1.17–1.53 dello score di ricostruzione. Lo score di ricostruzione prevale su quattro indicatori su sei e non è mai sotto le alternative; resta quindi lo score principale, e lo score combinato è riportato come riferimento dell'articolo. Il risultato è coerente con l'instabilità dello score combinato osservata nella configurazione di base (Sezione 5.1.4).

Tabella 6.3: Score di ricostruzione e score combinato, sulla stessa esecuzione. Per gli indicatori E-OBS è riportato il rapporto "solo detector / tutte" nello stesso giorno, con l'intervallo al 95%; in grassetto i valori il cui intervallo sta sopra quelli delle altre colonne. Quote: intervallo della quota segnalata fra fasce di latitudine e mesi, 5% se luogo e stagione non contassero.

Controllo	Ricostruzione, con climatologia	Combinato	Combinato, con climatologia
Pioggia forte	**1.17** (1.12–1.21)	0.60 (0.58–0.61)	0.59 (0.58–0.60)
Pressione bassa	**1.34** (1.27–1.40)	0.73 (0.71–0.76)	0.71 (0.69–0.74)
Calo di pressione	**1.16** (1.11–1.22)	0.82 (0.80–0.85)	0.81 (0.78–0.83)
Radiazione bassa	1.04 (1.00–1.07)	1.00 (0.97–1.02)	0.96 (0.94–0.99)
Caldo	**1.53** (1.45–1.60)	0.97 (0.94–1.00)	0.95 (0.92–0.98)
Freddo	0.82 (0.79–0.86)	0.87 (0.83–0.90)	0.89 (0.86–0.92)
Quote per latitudine e mese	3.6–5.8%	4.3–6.7%	3.2–5.9%

Pesi delle variabili. La Tabella 6.4 confronta tre modi di pesare le variabili nello score: i pesi della variazione su 24 ore della Sezione 4.3, nessun peso, e pesi calcolati allo stesso modo sulla variazione in tre ore, il passo che il modello ricostruisce. Il confronto è svolto sullo score della singola cella, l'unico che si può ricalcolare dagli errori per variabile salvati, con la stessa normalizzazione climatologica per le tre varianti; il modello è lo stesso, addestrato con i pesi su 24 ore.

Tabella 6.4: Pesi delle variabili nello score, sullo score della singola cella della stessa esecuzione. Stesse convenzioni della Tabella 6.3. L'ultima riga indica la variabile con la quota maggiore dello score nell'1% delle osservazioni con lo score più alto.

Controllo	Pesi su 24 ore	Nessun peso	Pesi su 3 ore
Pioggia forte	0.83 (0.80–0.85)	0.64 (0.62–0.66)	0.87 (0.82–0.92)
Pressione bassa	1.02 (0.97–1.07)	1.03 (0.98–1.09)	**2.40** (2.22–2.61)
Calo di pressione	0.91 (0.88–0.94)	0.86 (0.83–0.90)	**1.13** (1.08–1.19)
Radiazione bassa	0.90 (0.87–0.93)	0.74 (0.71–0.76)	0.94 (0.88–1.00)
Caldo	1.20 (1.15–1.25)	1.46 (1.39–1.52)	1.50 (1.42–1.59)
Freddo	0.91 (0.89–0.94)	0.83 (0.80–0.86)	**1.06** (0.97–1.14)
Quote per latitudine e mese	3.4–6.0%	2.9–6.0%	3.4–6.1%
Variabile più presente nell'1% più alto	Precipitazione, 28%	Precipitazione, 41%	Umidità del suolo, 32%

Le tre varianti distribuiscono le segnalazioni fra luoghi e stagioni in modo simile, con quote fra il 2.9% e il 6.1%. Senza pesi la precipitazione produce il 41% dell'1% più alto dello score; con i pesi su 24 ore la quota scende al 28% e il resto si ripartisce fra più variabili. Rispetto all'assenza di pesi, i pesi su 24

ore hanno l'intervallo sopra su tre indicatori, pioggia forte, radiazione bassa e freddo, e sotto su uno, il caldo: i pesi spostano lo score dal caldo prolungato verso le perturbazioni. I pesi su tre ore prevalgono su tre indicatori, pressione bassa, calo di pressione e freddo, e non sono mai sotto le altre varianti. Il loro vantaggio riguarda però in buona parte la pressione, il cui peso è quasi cinque volte quello su 24 ore e la cui indipendenza da ERA5 non è verificata; con questi pesi, inoltre, l'umidità del suolo, una sola variabile lenta, produce un terzo dell'1% più alto dello score, cioè lo squilibrio che i pesi dovrebbero evitare. Il detector usa quindi i pesi su 24 ore. Il confronto ha due limiti: lo score della singola cella conferma le segnalazioni meno dello score sulla patch, per esempio 0.83 contro 1.17 per la pioggia con gli stessi pesi, e il modello è addestrato con i pesi su 24 ore, che possono quindi risultare favoriti.

6.9 Limiti dei risultati

I risultati vengono da una sola esecuzione per configurazione, con un solo seme. La conferma da E-OBS riguarda la sola terraferma europea, dove le stazioni sono presenti, ed è aggregata per giorno; per la pressione l'indipendenza da ERA5 non è verificata.

Capitolo 7

Conclusioni e sviluppi futuri

7.1 Il problema affrontato

7.2 Sintesi dei risultati

7.3 Limiti dello studio

Assenza di una verità di riferimento. I campi ERA5 non contengono etichette di anomalia, e l'accuratezza del rilevamento non è quindi misurata. I risultati descrivono quanto le segnalazioni del detector coincidono con quelle di rilevatori che non usano un modello, e quanto spesso cadono in giorni in cui le stazioni misurano valori insoliti. Una conferma più frequente della media indica che le segnalazioni riguardano condizioni davvero insolite, non che il detector le trovi tutte.

Una sola esecuzione per configurazione. Ogni configurazione è stata addestrata una sola volta, con un solo seme. Non è noto quanto concorderebbero due esecuzioni identiche con semi diversi, e le differenze fra configurazioni non possono essere attribuite con certezza alla sola scelta confrontata.

Conferma da dati indipendenti. Le osservazioni di stazione coprono la sola terraferma europea, con meno stazioni nel sud e nell'est del dominio, e sono aggregate per giorno, mentre il detector lavora ogni tre ore. Per la pressione non è verificato che le misure delle stazioni siano escluse dall'assimilazione di ERA5.

Score e dispersione. La dispersione dello score dipende dal dropout delle due reti e non è calibrata come misura di incertezza. Le ablazioni sui pesi delle

variabili sono svolte sullo score della singola cella, che le stazioni confermano meno dello score sulla patch, e su un modello addestrato con una sola delle varianti di pesi.

Validazione breve e clima che cambia. Soglie e normalizzazione climatologica sono stimate su cinque anni di validazione e applicate a un periodo di test di ventuno anni. Con la deriva del clima, la quota di osservazioni segnalate negli anni più lontani può scostarsi da quella prevista. La ricostruzione degli eventi, inoltre, unifica a posteriori le identità che si fondono, e non descrive un utilizzo in tempo reale.

7.4 Sviluppi futuri

Il primo sviluppo è ripetere la configurazione scelta con più semi, per avere un riferimento con cui leggere le differenze fra configurazioni e fra varianti del generatore, convoluzionale e con attenzione su grafo.

Il secondo riguarda il protocollo: aggiornare periodicamente soglie e normalizzazione climatologica su una finestra di anni recenti, invece di tenerle fisse dalla validazione, ridurrebbe l'effetto della deriva del clima sulla quota di osservazioni segnalate.

Il terzo riguarda la valutazione. Casi studio su eventi documentati, scelti con fonti meteorologiche indipendenti, mostrerebbero che cosa il detector segnala in situazioni note; un catalogo esterno di eventi su tutto il dominio, o anomalie inserite in posizioni note, darebbe una misura del richiamo, che in questa tesi manca.

Infine, la dispersione dello score potrebbe essere confrontata con l'errore effettivo del generatore, per verificare se può essere usata come misura di incertezza, e le segnalazioni del detector potrebbero essere usate dai modelli di previsione da cui il lavoro è partito.

Bibliografia

[1] J. Antonanzas et al. «Review of photovoltaic power forecasting». In: *Solar Energy* 136 (2016), pp. 78–111. DOI: 10.1016/j.solener.2016.06.069.

[2] Hans Hersbach et al. «The ERA5 global reanalysis». In: *Quarterly Journal of the Royal Meteorological Society* 146.730 (2020), pp. 1999–2049. DOI: 10.1002/qj.3803.

[3] Leyan Deng et al. «Graph Convolutional Adversarial Networks for Spatiotemporal Anomaly Detection». In: *IEEE Transactions on Neural Networks and Learning Systems* 33.6 (2022), pp. 2416–2428. DOI: 10.1109/TNNLS.2021.3136171.

[4] Richard C. Cornes et al. «An Ensemble Version of the E-OBS Temperature and Precipitation Datasets». In: *Journal of Geophysical Research: Atmospheres* (2018). DOI: 10.1029/2017JD028200.

[5] Xingjian Wu et al. «CATCH: Channel-Aware Multivariate Time Series Anomaly Detection via Frequency Patching». In: *International Conference on Learning Representations (ICLR)*. 2025. arXiv: 2410.12261.

[6] Sarah Alnegheimish et al. «M2AD: Multi-Sensor Multi-System Anomaly Detection through Global Scoring and Calibrated Thresholding». In: *Proceedings of the 28th International Conference on Artificial Intelligence and Statistics*. Vol. 258. Proceedings of Machine Learning Research. PMLR, 2025, pp. 4384–4392.

[7] Qihang Zhou et al. «Label-Free Multivariate Time Series Anomaly Detection». In: *IEEE Transactions on Knowledge and Data Engineering* 36.7 (2024), pp. 3166–3179. DOI: 10.1109/TKDE.2024.3349613. arXiv: 2312.11549.

[8] Ian J. Goodfellow et al. «Generative Adversarial Nets». In: *Advances in Neural Information Processing Systems*. Vol. 27. Curran Associates, Inc., 2014. arXiv: 1406.2661.

[9] Kyunghyun Cho et al. «Learning Phrase Representations using RNN Encoder-Decoder for Statistical Machine Translation». In: *Proceedings of the 2014 Conference on Empirical Methods in Natural Language Processing (EMNLP)*. Association for Computational Linguistics, 2014, pp. 1724–1734. DOI: 10.3115/v1/D14-1179. arXiv: 1406.1078.

[10] Xingjian Shi et al. «Convolutional LSTM Network: A Machine Learning Approach for Precipitation Nowcasting». In: *Advances in Neural Information Processing Systems*. Vol. 28. Curran Associates, Inc., 2015. arXiv: 1506.04214.

[11] Nicolas Ballas et al. «Delving Deeper into Convolutional Networks for Learning Video Representations». In: *International Conference on Learning Representations (ICLR)*. 2016. arXiv: 1511.06432.

[12] Petar Veličković et al. «Graph Attention Networks». In: *International Conference on Learning Representations (ICLR)*. 2018. arXiv: 1710.10903.

[13] Yarin Gal e Zoubin Ghahramani. «Dropout as a Bayesian Approximation: Representing Model Uncertainty in Deep Learning». In: *Proceedings of the 33rd International Conference on Machine Learning*. Vol. 48. Proceedings of Machine Learning Research. PMLR, 2016, pp. 1050–1059. arXiv: 1506.02142.

[14] Balaji Lakshminarayanan, Alexander Pritzel e Charles Blundell. «Simple and Scalable Predictive Uncertainty Estimation using Deep Ensembles». In: *Advances in Neural Information Processing Systems*. Vol. 30. Curran Associates, Inc., 2017. arXiv: 1612.01474.

[15] Ricky T. Q. Chen et al. «Neural Ordinary Differential Equations». In: *Advances in Neural Information Processing Systems*. Vol. 31. Curran Associates, Inc., 2018. arXiv: 1806.07366.

[16] Lingkai Kong, Jimeng Sun e Chao Zhang. «SDE-Net: Equipping Deep Neural Networks with Uncertainty Estimates». In: *Proceedings of the 37th International Conference on Machine Learning*. Vol. 119. Proceedings of Machine Learning Research. PMLR, 2020, pp. 5405–5415. arXiv: 2008.10546.

[17] Simone Monaco et al. «Uncertainty-aware methods for enhancing rainfall prediction with deep-learning based post-processing segmentation». In: *Computers & Geosciences* 205 (2025), p. 105992. DOI: 10.1016/j.cageo.2025.105992.

[18] Thomas Huld, Richard Müller e Attilio Gambardella. «A new solar radiation database for estimating PV performance in Europe and Africa». In: *Solar Energy* 86.6 (2012), pp. 1803–1815. DOI: 10.1016/j.solener.2012.03.006.

[19] Diederik P. Kingma e Jimmy Ba. «Adam: A Method for Stochastic Optimization». In: *International Conference on Learning Representations (ICLR)*. 2015. arXiv: 1412.6980.

[20] Arthur Gretton et al. «A Kernel Two-Sample Test». In: *Journal of Machine Learning Research* 13.25 (2012), pp. 723–773.

[21] Adam Paszke et al. «PyTorch: An Imperative Style, High-Performance Deep Learning Library». In: *Advances in Neural Information Processing Systems*. Vol. 32. Curran Associates, Inc., 2019.

[22] Stephan Hoyer e Joe Hamman. «xarray: N-D labeled Arrays and Datasets in Python». In: *Journal of Open Research Software* 5.1 (2017), p. 10. DOI: 10.5334/jors.148.

[23] Wes McKinney. «Data Structures for Statistical Computing in Python». In: *Proceedings of the 9th Python in Science Conference*. 2010, pp. 56–61. DOI: 10.25080/Majora-92bf1922-00a.