Politecnico di Torino

Laurea Magistrale in Computer Engineering – Artificial Intelligence and Data Analytics

A.A. 2025/2026

Sessione di laurea [mese e anno]

[Titolo della tesi]

Relatore:
Simone Monaco

Candidato:
Alberto Pedalino

Indice

Elenco delle figure **v**

1 Introduzione **1**
1.1 Contesto e motivazioni 1
1.2 Il problema: anomalie meteorologiche senza etichette 1
1.3 Obiettivi e contributi della tesi 2
1.4 Percorso sperimentale 3
1.5 Organizzazione del documento 4

2 Fondamenti teorici e stato dell'arte **5**
2.1 Rilevamento di anomalie in serie multivariate e spazio-temporali 5
2.1.1 MTGFlow 6
2.1.2 Reti generative avversarie per il rilevamento di anomalie 7
2.1.3 STGAN 8
2.1.4 Alternative considerate: CATCH e M2AD 10
2.2 Contesto spaziale su griglie e grafi 11
2.2.1 Unità ricorrenti convoluzionali 11
2.2.2 Reti su grafo e Graph Attention Network 12
2.2.3 Dall'articolo alla tesi: le varianti di STGAN 13
2.3 Quantificazione dell'incertezza 15
2.3.1 Monte Carlo Dropout e Deep Ensemble 15
2.3.2 Equazioni differenziali stocastiche neurali 16
2.3.3 SDE-Net 16
2.3.4 SDE U-Net 18
2.4 Posizionamento del lavoro 18
2.4.1 Il contributo sostenuto 18
2.4.2 Confronto dei detector esaminati 19

3 Dati e preprocessing **21**
3.1 Serie PVGIS, località geografiche e target 21
3.2 Feature, trasformazioni fisiche e normalizzazione 21

3.3 Finestre temporali, split cronologici e previsione diretta multiorizzonte . . . 22
3.4 Campi ERA5, allineamento e celle valide . . . 22

4 Metodologia **24**
4.1 Panoramica del percorso metodologico . . . 24
4.2 Backbone BiLSTM–GAT . . . 25
4.2.1 Tensori di input, encoder temporale e attention pooling 25
4.2.2 Grafo geografico Haversine e ablazione della GAT . . . 25
4.2.3 Teste di previsione, funzione di perdita e training . . . 26
4.3 Esperimenti probabilistici preliminari . . . 26
4.3.1 Enhanced Monte Carlo Dropout . . . 26
4.3.2 Deep Ensemble di modelli addestrati indipendentemente 26
4.3.3 Previsioni medie, dispersione e intervalli empirici . . . 26
4.4 SDE-Net true-minimal . . . 26
4.4.1 Backbone paralleli di drift e diffusione . . . 26
4.4.2 Perturbazioni Browniane negli stadi BiLSTM e GAT . 26
4.4.3 Training alternato, pseudo-OOD e inferenza a traiettorie 26
4.5 SDE-Net paper-faithful . . . 26
4.5.1 Campo di drift, diffusione e integrazione Euler–Maruyama 26
4.5.2 Testa gaussiana, negative log-likelihood e training . . . 26
4.5.3 Campionamento e componenti dell'incertezza predittiva 27
4.6 Rilevamento delle anomalie climatiche con MTGFlow . . . 28
4.6.1 Serie storiche per località, variabili climatiche e finestre 28
4.6.2 Grafo dinamico tra entità e normalizing flow condizionale 28
4.6.3 Score aggregato della località, score per variabile e soglie IQR . . . 28
4.6.4 Modelli indipendenti per località e assenza di message passing geografico . . . 28
4.7 STGAN su PVGIS: versione su grafo e variante a griglia . . . 28
4.7.1 Contesto spaziale e architettura GCGRU–LSTM . . . 28
4.7.2 Variante ConvGRU–LSTM e gestione delle celle assenti 28
4.7.3 Ablazione del kernel e supporto spaziale osservato . . . 30
4.7.4 Training avversario, anomaly score e soglia globale . . . 30
4.7.5 Campionamento e riproducibilità del calcolo . . . 31
4.8 Estensione a ERA5 ed estrazione degli eventi . . . 31
4.8.1 Adattamento del detector alla cadenza trioraria . . . 31
4.8.2 Soglia, morfologia e cluster spaziali . . . 32
4.8.3 Collegamento temporale, separazioni e fusioni . . . 32
4.9 STGAN su ERA5: score Monte Carlo e varianti ConvGRU e GAT-GRU . . . 33

4.9.1 Dropout nel generatore e campionamento dello score . 33
4.9.2 Split di validation e bilanciamento dell'addestramento avversario 34
4.9.3 Finestra recente, codifica temporale ciclica e normalizzazione stagionale 35
4.9.4 Monitoraggio senza etichette e spazio PCA di riferimento 36
4.9.5 Generatore GAT-GRU sul grafo della griglia 37
4.9.6 Variante convoluzionale sul campo intero 39
4.9.7 Incertezza negli eventi e normalizzazione climatologica degli score 40

5 Esperimenti **41**
5.1 Configurazione degli esperimenti 41
5.1.1 Split temporali, orizzonti e configurazioni confrontate . 41
5.1.2 Metriche puntuali e probabilistiche 41
5.2 Detector e configurazioni a confronto 41
5.3 Analisi post-hoc e protocollo di valutazione 41
5.3.1 Allineamento e distribuzione spazio-temporale 41
5.3.2 Frequenze geografiche e confronto dei budget di anomalia 42
5.3.3 Sottogruppi meteorologici e direzione degli estremi . . 42
5.3.4 Campioni normali e anomali: quattro casi input–target 43
5.3.5 MAE, RMSE, bande di dispersione e metriche degli intervalli 43

6 Risultati e discussione **45**
6.1 Accuratezza del forecasting 45
6.1.1 Backbone BiLSTM–GAT e ablazione della GAT 45
6.1.2 Enhanced Monte Carlo Dropout 45
6.1.3 Deep Ensemble 45
6.1.4 SDE-Net true-minimal 45
6.1.5 SDE-Net paper-faithful e previsione diretta multiorizzonte 45
6.2 Quantificazione dell'incertezza 45
6.2.1 Intervalli dell'Enhanced Monte Carlo Dropout 45
6.2.2 Intervalli e disaccordo tra membri del Deep Ensemble . 45
6.2.3 Intervalli delle due varianti SDE-Net 45
6.3 Rilevamento delle anomalie con MTGFlow, STGAN e ConvGRU 46
6.3.1 Score e distribuzione spazio-temporale delle anomalie . 46
6.3.2 Soglie IQR, top-K e confronto fra grafo e griglia 46
6.3.3 Ablazione dei kernel convoluzionali 46
6.4 Analisi post-hoc forecasting–anomalie 46
6.4.1 MAE e RMSE sui campioni normali e anomali 46

6.4.2 Confronto a una e sei ore e quattro casi input–target . 46
6.4.3 Errore in funzione della soglia e bande di dispersione . 46
6.4.4 Errori per tipo e direzione dell'estremo meteorologico . 46
6.5 Anomalie ed eventi geografici su ERA5 46
6.5.1 Copertura dei dati e configurazione del detector 46
6.5.2 Score Monte Carlo e dispersione 46
6.5.3 Monitoraggio per epoca e selezione delle configurazioni 46
6.5.4 Confronto fra generatore ConvGRU e GAT e fra unità di training 46
6.5.5 Cluster spaziali, traiettorie e sensibilità del postprocessing 46
6.6 Confronto progressivo degli esperimenti 47
6.6.1 Accuratezza puntuale 47
6.6.2 Copertura e ampiezza degli intervalli 47
6.6.3 Costo computazionale e complessità dei modelli 47

7 Conclusioni e sviluppi futuri **48**
7.1 Il problema affrontato 48
7.2 Sintesi dei risultati 48
7.3 Limiti dello studio 48
7.4 Sviluppi futuri 48

Bibliografia **49**

Elenco delle figure

2.1 Schema di STGAN. Il generatore combina tre moduli e produce la stima $\hat{X}_{v,t}$, che sostituisce l'ultimo elemento della sequenza reale; il discriminatore valuta entrambe le sequenze. Lo score somma l'errore di previsione e la differenza fra le due uscite del discriminatore. Ridisegnato a partire da Deng et al. [5]. . . 8

2.2 Intorno di una cella nelle due varianti. A sinistra la convoluzione assegna a ogni vicino un peso legato alla sua posizione. A destra l'attenzione su grafo assegna a ogni arco un coefficiente α_{ij} che dipende dalle feature dei nodi collegati: lo spessore delle frecce ne rappresenta un esempio. 14

2.3 Cinque traiettorie di un'equazione differenziale stocastica lineare con lo stesso drift e due valori della diffusione, integrate con lo schema di Euler–Maruyama. La dispersione fra le traiettorie è la quantità da cui SDE-Net ricava l'incertezza epistemica. Simulazione illustrativa sul modello della figura analoga di Kong et al. [13]; non è un risultato della tesi. 17

Capitolo 1

Introduzione

1.1 Contesto e motivazioni

La produzione di un impianto fotovoltaico dipende dalle condizioni meteorologiche: irradianza, temperatura e vento ne determinano l'andamento, dalle variazioni entro la giornata a quelle stagionali. La gestione di una rete con una quota crescente di fotovoltaico richiede quindi previsioni della produzione, possibilmente accompagnate da una misura della loro incertezza.

Un previsore addestrato su dati storici è affidabile nelle condizioni che quei dati rappresentano bene. Le condizioni meteorologiche poco frequenti, o mai osservate, sono quelle in cui l'errore di previsione può crescere e in cui una stima dell'incertezza è più utile. Riconoscerle è un problema a sé, distinto dalla previsione: richiede di stabilire, per ogni località e ogni istante, quanto le condizioni osservate si discostano da quelle abituali. È il compito del rilevamento di anomalie, a cui questa tesi è dedicata.

Il lavoro considera due insiemi di dati. Il primo è costituito da serie orarie PVGIS, con la produzione fotovoltaica teorica e le variabili meteorologiche di un insieme di località. Il secondo è costituito dai campi della rianalisi ERA5, con quindici variabili su una griglia regolare e passo di tre ore. Sul primo il rilevamento è collegato a un previsore della produzione; sul secondo è studiato come problema autonomo, su un dominio più ampio.

1.2 Il problema: anomalie meteorologiche senza etichette

Tre caratteristiche dei dati rendono il problema difficile e guidano le scelte dei capitoli successivi.

La prima è l'assenza di etichette. Non esiste un elenco di osservazioni meteorologiche anomale con cui addestrare un classificatore o misurare direttamente l'accuratezza di un detector. Il rilevamento deve essere non supervisionato e la sua valutazione deve ricorrere a strumenti indiretti.

La seconda è che i dati di training non sono garantiti privi di anomalie. Molti detector apprendono il comportamento normale da un insieme che si assume pulito; con dati meteorologici non etichettati questa ipotesi non è verificabile. Ne segue una scelta di obiettivo: rilevare le condizioni nuove rispetto al periodo di training, trattando come già osservate quelle che il modello ha incontrato durante l'addestramento.

La terza è la struttura spaziale. Le condizioni di una località dipendono da quelle delle località vicine, e un valore insolito in un punto può essere ordinario se considerato nel suo intorno. I dati non hanno però una topologia fisica, come una rete stradale: sono disposti su un insieme di siti o su un reticolo regolare, e il modo di rappresentare l'intorno va scelto.

Il termine anomalia indica in questa tesi un'osservazione che si discosta da quanto il modello ha appreso dal periodo di training. Un evento meteorologico estremo è un caso particolare di anomalia, ma non ogni anomalia è un evento estremo.

1.3 Obiettivi e contributi della tesi

L'obiettivo della tesi è rilevare condizioni meteorologiche anomale in dati privi di etichette e dotati di struttura spaziale, e usare le decisioni del detector per esaminare il comportamento di un previsore fotovoltaico probabilistico. I due compiti restano distinti: il detector assegna uno score alle osservazioni meteorologiche, il previsore stima la produzione futura. La tesi non propone un nuovo algoritmo di rilevamento: adatta e combina componenti esistenti. I contributi sono i seguenti.

- L'adattamento di STGAN, un detector avversario spazio-temporale nato per il traffico, a variabili meteorologiche prive di topologia fisica, in due varianti che rappresentano l'intorno di una cella con una convoluzione su griglia oppure con l'attenzione su grafo.
- La definizione dell'obiettivo come rilevamento di condizioni nuove rispetto al periodo di training, con uno score continuo e una quota di osservazioni segnalate che è un parametro del protocollo.
- Tre estensioni del detector sui campi ERA5: uno score Monte Carlo con una misura di dispersione, un monitoraggio dell'addestramento privo di etichette e la ricostruzione di eventi geografici a partire dagli score.

- L'analisi degli errori e degli intervalli di un previsore fotovoltaico probabilistico, costruito sullo schema di SDE-Net, rispetto alle decisioni dei detector.

Le varianti architetturali costituiscono confronti da valutare sperimentalmente; la loro implementazione non implica un miglioramento delle prestazioni.

1.4 Percorso sperimentale

Il rilevamento delle anomalie parte da MTGFlow, scelto perché tollera la presenza di anomalie nei dati di training, e prosegue con STGAN, che aggiunge il contesto spaziale: prima nella forma con convoluzioni sul grafo, poi in un adattamento a griglia, inizialmente basato su CNN e successivamente su ConvGRU, con il ramo LSTM del trend conservato. La versione finale permette di confrontare kernel convoluzionali di diversa ampiezza mantenendo distinta la dimensione della patch osservata.

Il detector viene poi esteso ai campi meteorologici ERA5, con quindici variabili su una griglia regolare e campionamento ogni tre ore. Gli score possono essere trasformati in cluster spaziali e collegati nel tempo per descrivere eventi, comprese separazioni e fusioni. Questo percorso riguarda la caratterizzazione delle anomalie meteorologiche e rimane distinto dalla previsione della produzione fotovoltaica; la disponibilità dell'implementazione non costituisce una validazione empirica degli eventi.

Sul detector ERA5 vengono poi introdotti il dropout nel generatore e uno score Monte Carlo, che associa a ogni coppia tempo–località una media e una misura di dispersione. Un anno di validation, escluso dal training, alimenta un monitoraggio privo di etichette, basato sulle rappresentazioni del discriminatore e su una Maximum Mean Discrepancy calcolata in uno spazio PCA fissato in anticipo. Sono inoltre considerate una codifica ciclica del tempo, una normalizzazione stagionale dell'ingresso e una normalizzazione climatologica degli score. Due varianti modificano il generatore: una applica la ConvGRU al campo completo di un timestamp, l'altra ne mantiene la struttura ricorrente sul grafo dell'intera griglia e sostituisce nei gate la convoluzione con l'attenzione su grafo. In entrambe il discriminatore resta locale; le due varianti cambiano anche l'unità del campione e il numero di aggiornamenti per epoca, e costituiscono configurazioni distinte da confrontare sperimentalmente.

Il previsore della produzione parte dal backbone BiLSTM–GAT e dalle varianti probabilistiche preliminari, per arrivare alle due implementazioni SDE-Net. La linea paper-faithful viene estesa alla previsione diretta multiorizzonte e a un'ablazione senza message passing GAT.

Le analisi successive collegano le previsioni alle decisioni dei detector mediante località e timestamp target. Il confronto considera gli orizzonti di previsione, le fasce di produzione, la distribuzione spazio-temporale delle anomalie e le quattro combinazioni fra input normale o anomalo e target normale o anomalo. Le analisi comprendono inoltre frequenze geografiche, sottogruppi meteorologici e sensibilità delle decisioni alle soglie.

1.5 Organizzazione del documento

Il Capitolo 2 presenta i fondamenti teorici e i lavori su cui la tesi è costruita, indicando per ciascuno ciò che propone, ciò che non copre e ciò che la tesi ne riprende. Il Capitolo 3 descrive i dati e la loro preparazione. Il Capitolo 4 presenta i modelli e i loro adattamenti. Il Capitolo 5 definisce le configurazioni confrontate e il protocollo di valutazione. Il Capitolo 6 riporta e discute i risultati. Il Capitolo 7 riassume il lavoro, ne indica i limiti e gli sviluppi futuri.

Capitolo 2

Fondamenti teorici e stato dell'arte

Il capitolo presenta i fondamenti teorici e i lavori su cui la tesi è costruita. Per ciascun lavoro di riferimento sono indicati ciò che propone e ciò che non copre, quindi ciò che la tesi ne riprende e il modo in cui ne affronta i limiti. I modelli di uso generale impiegati come componenti sono richiamati nella sezione in cui servono. La trattazione segue l'ordine dei temi del lavoro: il rilevamento delle anomalie, il contesto spaziale su griglie e grafi, la quantificazione dell'incertezza, per lo score dei detector e per il previsore. L'ultima sezione riassume la posizione della tesi rispetto a questi lavori.

2.1 Rilevamento di anomalie in serie multivariate e spazio-temporali

I metodi di rilevamento di anomalie in serie multivariate basati su reti profonde sono comunemente distinti secondo il segnale da cui ricavano lo score. Wu et al. li classificano in metodi basati su previsione, su ricostruzione e su apprendimento contrastivo [1]. Alnegheimish et al. distinguono in modo analogo modelli di predizione e di ricostruzione, e osservano che molti di essi costruiscono uno score senza definire in modo appropriato la soglia [2]. Zhou et al. mettono in evidenza un'ipotesi comune a gran parte di questi lavori, cioè la disponibilità di un training composto da sole osservazioni normali: quando il training contiene anomalie le prestazioni possono degradare sensibilmente, e la stima della densità dell'intero insieme di training è proposta come alternativa [3].

I lavori esaminati in questa sezione si collocano lungo queste distinzioni: MTGFlow appartiene alla stima di densità, STGAN all'approccio avversario,

che combina l'errore di previsione con il giudizio di un discriminatore, CATCH alla ricostruzione e M2AD alla predizione con uno score aggregato. Due criteri guidano il confronto: la tolleranza alla presenza di anomalie nel training e la rappresentazione del contesto spaziale fra località. Il primo ha portato alla scelta di MTGFlow e all'esclusione di CATCH e M2AD; il secondo al passaggio a STGAN, che offre il contesto spaziale ma non la stessa tolleranza.

2.1.1 MTGFlow

Zhou et al. [3] affrontano il rilevamento di anomalie in serie multivariate senza assumere che i dati di training siano tutti normali. Il metodo stima la densità dell'intero insieme di training e identifica come anomale le osservazioni di test a bassa densità, sotto l'ipotesi che le anomalie occupino regioni più sparse. Le dipendenze fra entità sono apprese come grafo dinamico e un normalizing flow specifico per entità associa a ciascuna una distribuzione normale parametrizzata. La soglia è ricavata dall'intervallo interquartile degli score di training e lo score per entità consente di localizzare l'anomalia. Le entità sono i sensori o le variabili di un unico sistema e la valutazione usa dataset pubblici di riferimento: il grafo è appreso dai dati e descrive relazioni fra variabili, non fra siti geografici distinti. Un'estensione assegna una distribuzione comune alle entità di uno stesso gruppo, quando è noto che hanno caratteristiche simili. Il raggruppamento esprime soltanto che certe entità possono comportarsi allo stesso modo: non modella vicinanza, distanze o propagazione nello spazio, e non rende il metodo un detector spazio-temporale.

MTGFlow è stato scelto per la sua robustezza alla presenza di anomalie nei dati di training: per le condizioni meteorologiche non sono disponibili etichette, quindi non è possibile garantire un training composto da sole osservazioni normali. La tesi implementa la versione base, senza l'estensione a gruppi, e la applica alle tre variabili climatiche di ogni località, trattate come entità. Poiché il metodo non rappresenta il contesto geografico, viene addestrato un modello indipendente per località: gli score possono essere confrontati sulla mappa, ma il modello non apprende relazioni fra località. Per introdurre anche una componente spaziale, il lavoro è quindi passato a STGAN. La soglia interquartile dell'articolo è mantenuta come protocollo di base e affiancata da una variante esplorativa a budget globale.

2.1.2 Reti generative avversarie per il rilevamento di anomalie

Una rete generativa avversaria [4] addestra insieme due reti con obiettivi opposti. Il generatore G trasforma un rumore z, estratto da una distribuzione nota p_z, in un campione $G(z)$; i dati reali seguono la distribuzione p_{data} e il discriminatore D restituisce la probabilità $D(x)$ che un campione x provenga dai dati reali anziché dal generatore. Le due reti sono addestrate sulla stessa funzione, che il discriminatore massimizza e il generatore minimizza:

$$\min_G \max_D V(D,G) = \mathbb{E}_{x\sim p_{\text{data}}}\Big[\log D(x)\Big] + \mathbb{E}_{z\sim p_z}\Big[\log\Big(1 - D(G(z))\Big)\Big]. \quad (2.1)$$

Il primo termine cresce quando il discriminatore riconosce i dati reali, il secondo quando riconosce i campioni generati; il generatore è addestrato a rendere i propri campioni indistinguibili da quelli reali. Entrambe le reti sono ottimizzate con la retropropagazione. Lo stesso articolo osserva che, all'inizio dell'addestramento, il secondo termine fornisce al generatore un gradiente debole, e propone in alternativa di addestrarlo a massimizzare $\log D(G(z))$.

Nel detector avversario adottato in questa tesi lo schema è usato in forma condizionata: il generatore riceve il contesto di un'osservazione e ne produce una stima. L'uso per il rilevamento di anomalie poggia su un'ipotesi di lavoro: che la stima sia accurata nelle condizioni frequenti nei dati di training e meno accurata in quelle poco rappresentate. È un'ipotesi e non una proprietà garantita dall'addestramento. Se vale, se ne ricavano due segnali: lo scarto fra l'osservazione e la stima del generatore, e il giudizio del discriminatore sull'osservazione. STGAN, descritto di seguito, li combina in un unico score.

Rispetto all'equazione (2.1), in STGAN il significato dell'uscita del discriminatore è invertito: le sequenze reali sono trattate come normali e quelle generate come anomale, con valore 0 per le prime e 1 per le seconde. Per il discriminatore l'obiettivo è lo stesso a meno di questo scambio, ma la sua uscita cresce con il sospetto di anomalia e può essere usata per costruire lo score. L'obiettivo del generatore è riportato nell'equazione (2.2): il termine avversario ha la forma alternativa appena descritta, scritta nella convenzione invertita, e a esso si aggiunge un termine di ricostruzione.

L'addestramento richiede un equilibrio fra le due reti: nella tesi i tassi di apprendimento delle due reti, il coefficiente β_1 dei loro ottimizzatori e il numero di aggiornamenti per batch sono parametri configurabili, come descritto nel Capitolo 4.

2.1.3 STGAN

Deng et al. [5] propongono una rete avversaria per il rilevamento di anomalie del traffico. Il generatore prevede la dinamica normale combinando tre componenti: un modulo recente, basato su unità ricorrenti con convoluzione su grafo, per le dipendenze spazio-temporali di breve periodo, un modulo per il trend di lungo periodo e uno per le variabili esterne. Il discriminatore stabilisce se una sequenza è reale o generata in funzione dei vicini nello spazio e nel tempo, fornendo un criterio che varia con località e istante. Dopo l'addestramento avversario entrambe le reti agiscono da detector e uno score ne combina i contributi. Il grafo deriva da una topologia fisica, cioè sensori adiacenti sulla stessa strada o regioni con confini comuni, e la valutazione misura il richiamo rispetto a incidenti ed eventi documentati, che gli autori stessi indicano come verità di riferimento incompleta. Il metodo presuppone quindi una rete di adiacenze nota e produce uno score puntuale, privo di una misura di dispersione; la sua valutazione dipende dalla disponibilità di eventi documentati. L'articolo non discute la presenza di anomalie nei dati di training: il discriminatore è addestrato considerando normali le sequenze reali e anomale quelle generate, quindi l'ipotesi di un training normale è implicita. La Figura 2.1 riassume la struttura del metodo.

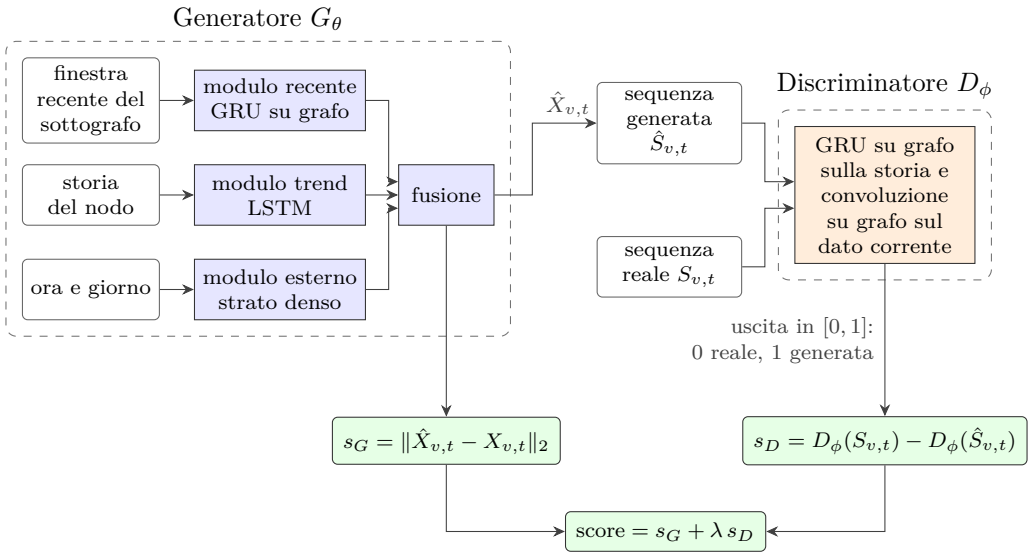


Figura 2.1: Schema di STGAN. Il generatore combina tre moduli e produce la stima $\hat{X}_{v,t}$, che sostituisce l'ultimo elemento della sequenza reale; il discriminatore valuta entrambe le sequenze. Lo score somma l'errore di previsione e la differenza fra le due uscite del discriminatore. Ridisegnato a partire da Deng et al. [5].

Sia $x_{v,t}$ l'osservazione del nodo v all'istante t e $X_{v,t}$ l'insieme delle osservazioni nel sottografo formato da v e dai suoi vicini. Sia poi $S_{v,t}$ la sequenza reale dei valori del sottografo che termina con $X_{v,t}$, e $\hat{S}_{v,t}$ la stessa sequenza in cui l'ultimo elemento è sostituito dalla stima $G_\theta(v,t)$ del generatore. Gli obiettivi di addestramento dell'articolo sono

$$\mathcal{L}_G(\theta) = \sum_s -\log\Big(1 - D_\phi(\hat{S}_{v,t})\Big) + \lambda_G \, \|G_\theta(v,t) - X_{v,t}\|_2, \tag{2.2}$$

$$\mathcal{L}_D(\phi) = \sum_s -\log\Big(D_\phi(\hat{S}_{v,t})\Big) - \log\Big(1 - D_\phi(S_{v,t})\Big), \tag{2.3}$$

dove la somma è sui punti $s = \langle v, t, x_{v,t}\rangle$ e λ_G bilancia l'errore di previsione e il termine avversario. Il discriminatore è quindi spinto verso 1 sulle sequenze generate e verso 0 su quelle reali. Lo score combina le due reti:

$$\begin{aligned} s_D(v,t) &= D_\phi(S_{v,t}) - D_\phi(\hat{S}_{v,t}), \\ s_G(v,t) &= \|G_\theta(v,t) - X_{v,t}\|_2, \\ \text{score}(v,t) &= s_G(v,t) + \lambda \, s_D(v,t). \end{aligned} \tag{2.4}$$

La componente del discriminatore non è la sua uscita sulla sequenza reale ma la differenza rispetto alla sequenza generata: gli autori la introducono per ridurre l'effetto dell'imprevedibilità dei dati reali. Negli esperimenti dell'articolo $\lambda_G = 500$, le due componenti sono normalizzate e $\lambda = 1$.

La tesi riprende l'architettura a tre rami, gli obiettivi avversari e lo score combinato, e li applica a variabili meteorologiche, per le quali non esiste una topologia fisica. Nella versione su grafo le adiacenze sono sostituite da un criterio di vicinanza geografica. A differenza di MTGFlow, il metodo non tollera per costruzione un training contaminato. La tesi accetta questo limite in cambio del contesto spaziale e lo traduce in una scelta di obiettivo: rilevare condizioni nuove rispetto al periodo di training. Le anomalie presenti negli anni di addestramento sono trattate come già osservate: nella misura in cui il modello le apprende, condizioni simili non vengono segnalate, mentre lo sono quelle poco o per nulla rappresentate in quegli anni. Lo score misura quindi lo scostamento da quanto il modello ha appreso dal periodo di training, non la rarità di una condizione in assoluto. Lo score è continuo e non coincide con la decisione: sono considerate anomale soltanto le osservazioni con score più alto, in una quota che è un parametro del protocollo e viene fatta variare nell'analisi di sensibilità del Capitolo 5. Il termine anomalia è usato in questo senso in tutta la tesi: un evento estremo è un caso particolare di anomalia, ma non ogni anomalia è un evento estremo. Su questa base sono costruite le due varianti descritte nella Sezione 2.2 e tre estensioni comuni, introdotte su ERA5: uno score Monte Carlo che associa a ogni osservazione

una misura di dispersione; un monitoraggio privo di etichette, necessario perché non sono disponibili eventi documentati con cui misurare il richiamo; l'aggregazione degli score in eventi geografici, un passaggio assente nell'articolo. Gli obiettivi di addestramento e lo score, nella forma implementata, sono riportati nella Sezione 4.7: rispetto alle equazioni (2.2)–(2.4), l'errore di previsione vi compare come errore quadratico medio anziché come norma, mentre $\lambda_G = 500$, la differenza fra le uscite del discriminatore e $\lambda = 1$ sono mantenuti. La scelta segue il codice pubblicato dagli autori, che usa l'errore quadratico medio sia nella loss del generatore sia nella componente di ricostruzione dello score, e dimezza la somma dei due termini della loss del discriminatore.

2.1.4 Alternative considerate: CATCH e M2AD

CATCH. Wu et al. [1] propongono un metodo basato su ricostruzione nel dominio della frequenza. Lo spettro è suddiviso in bande, trattate come patch, per cogliere caratteristiche a grana fine; un modulo di fusione dei canali, con un generatore di maschere e un'attenzione mascherata, seleziona per ciascuna banda le correlazioni fra canali ritenute utili e isola quelle irrilevanti. Il metodo mira a rilevare insieme anomalie puntuali e di sottosequenza ed è valutato su dataset reali e sintetici. Lo score di anomalia è l'errore di ricostruzione: il modello impara a ricostruire i pattern normali, e nei dataset sintetici dell'articolo le anomalie sono inserite soltanto nella serie di test. Il caso di anomalie presenti nei dati di training non è trattato. I canali sono le variabili di una serie multivariata: non è prevista una struttura geografica fra serie di siti diversi, e gli autori segnalano che anomalie più lunghe della finestra osservata non vengono colte efficacemente.

CATCH è stato preso in esame come alternativa a MTGFlow e non è stato adottato, per due ragioni. La prima è che richiede un training privo di anomalie: apprende i pattern normali per ricostruzione e l'articolo non considera un training contaminato, mentre in assenza di etichette questa condizione non è verificabile sui dati meteorologici. La seconda è che, come MTGFlow, non rappresenta relazioni fra località geografiche.

M2AD. Alnegheimish et al. [2] considerano serie multivariate provenienti da più sistemi. Un modello LSTM apprende il comportamento atteso dei sensori; i residui fra valori attesi e osservati sono aggregati in uno score globale mediante un modello a mistura gaussiana e una calibrazione Gamma; la soglia è stimata dagli score osservati in training e i sensori sono ordinati per contributo allo score. Il metodo assume che i dati di training siano privi di anomalie e che training e test abbiano andamenti simili; gli autori indicano

come limite il caso in cui la distribuzione cambia, che richiede un nuovo addestramento.

Anche M2AD è stato preso in esame e non adottato, per le stesse due ragioni: assume esplicitamente un training privo di anomalie, ipotesi opposta a quella che ha guidato la scelta di MTGFlow e non verificabile senza etichette, e i suoi sistemi sono insiemi di sensori senza relazione geografica fra loro. A differenza di STGAN, quindi, né CATCH né M2AD offrono il contesto spaziale in cambio dell'ipotesi sul training. Nessuno dei due è stato eseguito sui dati della tesi e non compaiono fra i risultati.

2.2 Contesto spaziale su griglie e grafi

2.2.1 Unità ricorrenti convoluzionali

Le unità ricorrenti a gate, come quella introdotta da Cho et al. [6] e nota come GRU, aggiornano uno stato nascosto mediante gate che regolano quanta parte dello stato precedente conservare e quanta sostituire. Nella forma originaria ingresso e stato sono vettori e i gate sono trasformazioni dense. Quando l'ingresso è un campo disposto su una griglia, le trasformazioni dense possono essere sostituite da convoluzioni, così che lo stato mantenga la struttura spaziale e i parametri siano condivisi fra le posizioni. L'idea è stata proposta per la LSTM nella previsione a breve termine delle precipitazioni [7] e per la GRU nell'apprendimento di rappresentazioni di sequenze video [8]. STGAN applica la stessa idea a un grafo: nel suo modulo recente i prodotti matriciali della GRU sono sostituiti da convoluzioni su grafo [5].

Sia X_s l'ingresso al passo s e H_{s-1} lo stato precedente, entrambi disposti sulla griglia. Uno strato ricorrente convoluzionale a gate calcola

$$R_s = \sigma(W_r * [X_s, H_{s-1}] + b_r)\,, \tag{2.5}$$

$$U_s = \sigma(W_u * [X_s, H_{s-1}] + b_u)\,, \tag{2.6}$$

$$\widetilde{H}_s = \tanh(W_c * [X_s, R_s \odot H_{s-1}] + b_c)\,, \tag{2.7}$$

$$H_s = U_s \odot H_{s-1} + (1 - U_s) \odot \widetilde{H}_s, \tag{2.8}$$

dove σ è la funzione sigmoidale, $*$ una convoluzione spaziale, $\odot$ il prodotto elemento per elemento e $[\cdot, \cdot]$ la concatenazione sui canali. Il gate di reset R_s regola quanto dello stato precedente entra nello stato candidato $\widetilde{H}_s$; il gate di aggiornamento U_s regola quanto dello stato precedente viene conservato. La forma è quella dell'unità su grafo di STGAN, con la convoluzione su grafo sostituita da una convoluzione spaziale.

Con un kernel di lato k e padding $\lfloor k/2 \rfloor$, ogni convoluzione vede le celle entro $\lfloor k/2 \rfloor$ posizioni. Il gate di reset e lo stato candidato applicano due convoluzioni in sequenza, quindi a ogni passo lo stato precedente si propaga fino a $2\lfloor k/2 \rfloor$ posizioni: l'area che influenza una cella cresce con il numero di passi temporali e di strati. La tesi impiega questo operatore nella variante a griglia di STGAN: la Sezione 4.7.2 descrive il trattamento delle celle assenti, che modifica l'ingresso e l'equazione (2.8) ed è l'adattamento specifico di questo lavoro.

2.2.2 Reti su grafo e Graph Attention Network

Una rete su grafo aggiorna la rappresentazione di ogni nodo aggregando quelle dei suoi vicini. Nella Graph Attention Network [9] i pesi dell'aggregazione non sono fissati dalla struttura del grafo: ogni nodo assegna ai propri vicini coefficienti di attenzione calcolati a partire dalle rispettive feature. Il calcolo non richiede operazioni matriciali costose né la conoscenza anticipata dell'intero grafo, e si applica anche a grafi non osservati durante il training. Più teste di attenzione possono operare in parallelo, e i loro risultati sono concatenati oppure mediati.

Sia h_i il vettore di feature del nodo i e $\mathcal{N}(i)$ l'insieme dei suoi vicini, che negli esperimenti dell'articolo comprende il nodo stesso. Uno strato calcola

$$e_{ij} = \mathrm{LeakyReLU}\Big(\mathbf{a}^\top \left[Wh_i \,\|\, Wh_j\right]\Big), \tag{2.9}$$

$$\alpha_{ij} = \frac{\exp e_{ij}}{\sum_{l \in \mathcal{N}(i)} \exp e_{il}}, \tag{2.10}$$

$$h'_i = \sigma\left(\sum_{j \in \mathcal{N}(i)} \alpha_{ij}\, Wh_j\right), \tag{2.11}$$

dove W è una trasformazione lineare condivisa fra i nodi, $\mathbf{a}$ il vettore dei pesi dell'attenzione, $\|$ la concatenazione e σ una non linearità. Il coefficiente α_{ij} esprime l'importanza del nodo j per il nodo i. Con più teste, ciascuna con parametri propri, le uscite sono concatenate negli strati intermedi e mediate nell'ultimo. Lo strato può essere letto come una convoluzione su grafo in cui i pesi dell'aggregazione sono appresi, invece che fissati dalla struttura del grafo.

La tesi impiega questo meccanismo in due punti: nel backbone del previsore, su un grafo geografico con pesi che dipendono dalla distanza, e nei gate dell'unità ricorrente del generatore, nella variante su grafo di STGAN, sul grafo regolare della griglia e senza pesi geografici. Il grafo e la configurazione dell'encoder nel generatore sono descritti nella Sezione 4.9.5.

2.2.3 Dall'articolo alla tesi: le varianti di STGAN

Le due varianti non corrispondono ad articoli distinti: sono adattamenti di STGAN realizzati in questo lavoro. I dati della tesi non hanno una topologia fisica come quella dell'articolo: sono disposti su un reticolo regolare di celle, e le due varianti rappresentano l'intorno di una cella in due modi diversi. Sono riportate qui per chiarire che cosa cambia rispetto all'articolo e quali componenti sono preesistenti.

Variante a griglia: STGAN con ConvGRU. Nell'articolo il contesto spaziale è un grafo, e in assenza di una rete fisica le sue adiacenze devono essere scelte con un criterio di vicinanza. I dati della tesi sono invece disposti su un reticolo regolare, per il quale le posizioni relative dei vicini sono definite. La variante sostituisce quindi la convoluzione su grafo con una ConvGRU su patch geografiche, conservando il ramo LSTM del trend, gli obiettivi avversari e lo score. Rispetto all'articolo aggiunge il trattamento delle celle assenti, con una maschera fornita come canale e l'azzeramento dello stato ricorrente, e un'ablazione dell'ampiezza dei kernel. Nella prima forma un campione è una cella con la propria patch. Su ERA5 l'addestramento in questa forma si è rivelato troppo lento e la variante è stata portata sull'intero campo: il generatore elabora in una sola passata il reticolo completo di un timestamp, mentre il discriminatore continua a giudicare la patch di ogni cella. L'operatore ricorrente convoluzionale non è un contributo della tesi; lo sono il suo impiego in questo detector e la gestione delle celle mancanti.

Variante con attenzione su grafo: STGAN con GAT-GRU. Nell'articolo i pesi fra vicini derivano da adiacenze fissate. La seconda variante definisce il generatore sul grafo dell'intera griglia, con otto vicini per nodo, e mantiene la struttura dell'unità ricorrente dell'articolo: in ciascun gate la convoluzione su grafo, i cui pesi sono fissati dall'adiacenza, è sostituita da uno strato di attenzione su grafo, i cui pesi sono calcolati dalle feature dei nodi. L'operatore agisce quindi sull'ingresso e sullo stato a ogni passo recente, come nell'articolo e nella variante a griglia. L'unità che ne risulta è indicata nel seguito come GAT-GRU, per analogia con la ConvGRU: una GRU i cui gate sono strati di attenzione su grafo. Una prima versione applicava invece l'attenzione al solo ingresso di ciascun passo e aggregava i passi con una GRU che opera cella per cella: non essendo una sostituzione uno a uno dell'unità dell'articolo, è stata sostituita dalla GAT-GRU e resta come configurazione di confronto. Un campione è un timestamp con tutti i nodi. Il discriminatore resta quello locale a patch: il criterio di giudizio continua a dipendere dall'intorno di ciascun sito, come nell'articolo. Anche qui il meccanismo di

attenzione è preesistente; è della tesi il suo inserimento nei gate dell'unità ricorrente di STGAN, con discriminatore locale invariato.

Che cosa distingue le due varianti. Con otto vicini per nodo, uno strato di attenzione e una convoluzione 3×3 osservano le stesse celle e differiscono nel modo di pesarle, come mostra la Figura 2.2. Nella convoluzione il peso di un vicino dipende dalla sua posizione relativa ed è lo stesso in ogni punto del campo e in ogni istante; nell'attenzione dipende dalle feature dei due nodi ed è ricalcolato per ogni cella e ogni istante. In cambio l'attenzione tratta i vicini come un insieme non ordinato e non distingue le direzioni, che la convoluzione invece rappresenta. Poiché in entrambe l'operatore sta dentro i gate, l'ampiezza del contesto è la stessa: l'area che influenza una cella cresce allo stesso modo con il numero di passi recenti. Sul campo intero le due varianti differiscono quindi per il modo di pesare i vicini e, di conseguenza, per il numero di parametri. Mettono a confronto due ipotesi sullo stesso intorno, l'una basata sulla posizione dei vicini e l'altra sul loro stato; quale sia più adatta al rilevamento è una questione sperimentale.

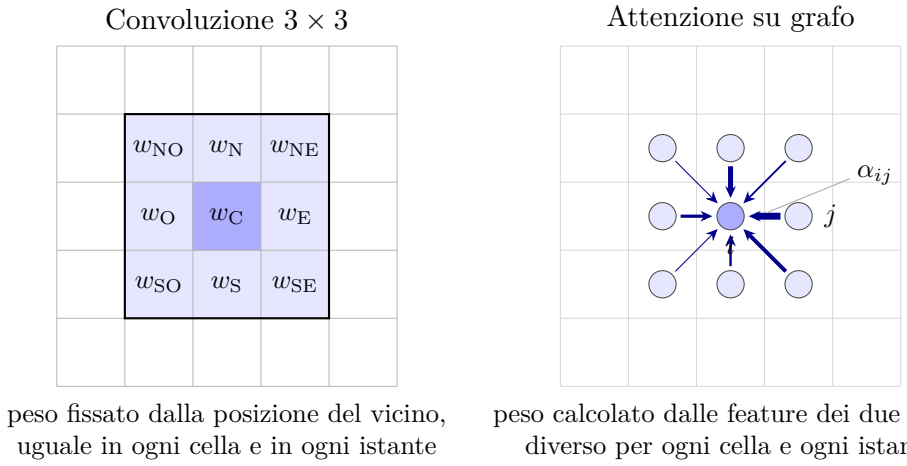


Figura 2.2: Intorno di una cella nelle due varianti. A sinistra la convoluzione assegna a ogni vicino un peso legato alla sua posizione. A destra l'attenzione su grafo assegna a ogni arco un coefficiente α_{ij} che dipende dalle feature dei nodi collegati: lo spessore delle frecce ne rappresenta un esempio.

2.3 Quantificazione dell'incertezza

2.3.1 Monte Carlo Dropout e Deep Ensemble

Gal e Ghahramani [10] interpretano l'addestramento con dropout come un'inferenza bayesiana approssimata. Mantenendo il dropout attivo in previsione e ripetendo più volte il passaggio in avanti si ottiene un insieme di uscite, la cui dispersione fornisce una stima dell'incertezza del modello con un costo aggiuntivo contenuto. Lakshminarayanan et al. [11] propongono un'alternativa non bayesiana: più reti vengono addestrate in modo indipendente a partire da inizializzazioni diverse e le loro previsioni sono combinate. Il metodo è semplice da realizzare e da eseguire in parallelo, e produce un'incertezza maggiore sugli ingressi lontani dai dati di training.

Nel dropout Monte Carlo, dati J passaggi in avanti $\hat{y}_j(x)$ ottenuti con maschere di dropout diverse, la media predittiva è stimata da

$$\mathbb{E}[y \mid x] \approx \frac{1}{J} \sum_{j=1}^{J} \hat{y}_j(x), \tag{2.12}$$

e la varianza predittiva dalla varianza campionaria dei J passaggi, a cui l'articolo somma l'inverso della precisione del modello. Nei Deep Ensemble ciascuna delle M reti restituisce una media $\mu_m(x)$ e una varianza $\sigma_m^2(x)$ ed è addestrata con la negative log-likelihood gaussiana; l'insieme è trattato come una miscela a pesi uguali, con media e varianza

$$\mu_*(x) = \frac{1}{M} \sum_{m=1}^{M} \mu_m(x), \qquad \sigma_*^2(x) = \frac{1}{M} \sum_{m=1}^{M} \Big(\sigma_m^2(x) + \mu_m^2(x)\Big) - \mu_*^2(x). \tag{2.13}$$

La varianza della miscela è quindi la somma della media delle varianze delle singole reti e della dispersione delle loro medie.

Nella tesi il dropout Monte Carlo ha due impieghi. Il principale riguarda il detector avversario: su ERA5 è applicato al generatore di STGAN, in entrambe le varianti, non per stimare l'incertezza di una previsione ma per campionare lo score di anomalia. Durante lo scoring i dropout del generatore restano attivi e per ogni osservazione sono riportate la media dello score sui campioni, come nell'equazione (2.12), e la sua deviazione standard, come descritto nella Sezione 4.9.1. L'articolo di STGAN non prevede questo passaggio: il suo score è un valore unico per osservazione. In questo impiego la dispersione misura la variabilità dello score rispetto alle maschere di dropout e non costituisce una stima calibrata dell'incertezza; il termine di precisione previsto da Gal e Ghahramani non viene aggiunto. Il secondo impiego riguarda il previsore: dropout Monte Carlo e Deep Ensemble sono usati negli esperimenti preliminari.

2.3.2 Equazioni differenziali stocastiche neurali

Una rete residua aggiorna lo stato sommando a esso una trasformazione dello stato stesso, $x_{t+1} = x_t + f(x_t, t)$. Interpretando l'aggiornamento come un passo di integrazione, la trasformazione complessiva può essere descritta da un'equazione differenziale ordinaria, $\mathrm{d}x/\mathrm{d}t = f(x, t)$, in cui f è una rete neurale e l'uscita è calcolata da un risolutore numerico [12]. Un modello di questo tipo è deterministico. Aggiungendo un termine di moto browniano si ottiene un'equazione differenziale stocastica,

$$\mathrm{d}x_t = f(x_t, t)\,\mathrm{d}t + g(x_t, t)\,\mathrm{d}W_t, \tag{2.14}$$

in cui f è il drift e g la diffusione, che regola l'ampiezza della componente casuale [13].

In pratica l'equazione è integrata a passi discreti con lo schema di Euler–Maruyama. Dividendo l'intervallo $[0, T]$ in N passi di ampiezza $\Delta t = T/N$, l'aggiornamento è

$$x_{k+1} = x_k + f(x_k, t_k)\,\Delta t + g(x_k, t_k)\sqrt{\Delta t}\,Z_k, \qquad Z_k \sim \mathcal{N}(0, 1) : \tag{2.15}$$

a ogni passo lo stato avanza del drift moltiplicato per l'ampiezza del passo e di un termine gaussiano scalato dalla diffusione e dalla radice dell'ampiezza del passo. Ripetendo l'integrazione con estrazioni diverse di Z_k si ottengono traiettorie diverse dallo stesso ingresso, tanto più disperse quanto maggiore è la diffusione (Figura 2.3). Il tempo di integrazione è una variabile interna del modello e non coincide con l'orizzonte fisico della previsione. I due lavori descritti di seguito applicano questo schema alla stima dell'incertezza.

2.3.3 SDE-Net

Kong et al. [13] interpretano le trasformazioni di una rete profonda come l'evoluzione dello stato di un sistema dinamico stocastico. Il modello comprende una rete di drift, che adatta la funzione predittiva, e una rete di diffusione, che scala un termine browniano e rappresenta l'incertezza epistemica. La diffusione è addestrata ad assumere valori bassi sui dati di training e alti su dati fuori distribuzione, ottenuti aggiungendo rumore gaussiano agli ingressi. L'equazione è integrata con lo schema dell'equazione (2.15) a passo fisso, con parametri condivisi fra i passi e diffusione calcolata sul solo stato iniziale, cioè con $g(x_0; \theta_g)$ al posto di $g(x_k, t_k)$; l'uscita della rete di diffusione è una sigmoide moltiplicata per un valore massimo, fissato come iperparametro. Dopo l'addestramento si campionano più traiettorie per lo stesso ingresso: l'incertezza aleatoria è la varianza predittiva media sulle traiettorie, quella

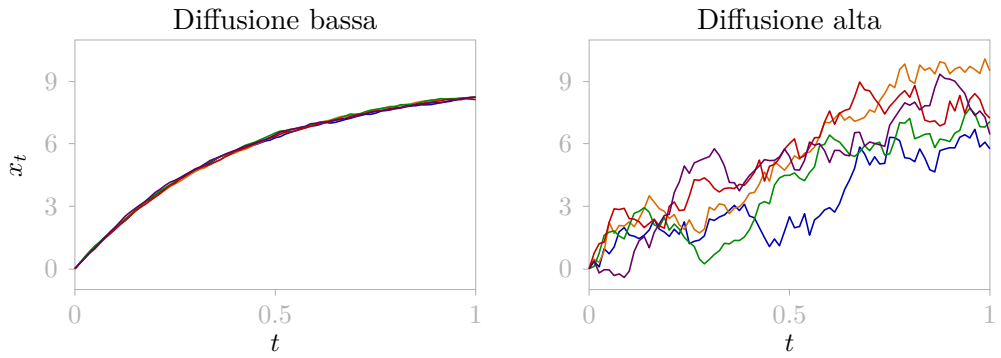


Figura 2.3: Cinque traiettorie di un'equazione differenziale stocastica lineare con lo stesso drift e due valori della diffusione, integrate con lo schema di Euler–Maruyama. La dispersione fra le traiettorie è la quantità da cui SDE-Net ricava l'incertezza epistemica. Simulazione illustrativa sul modello della figura analoga di Kong et al. [13]; non è un risultato della tesi.

epistemica la varianza dello stato finale fra le traiettorie. Il metodo separa così le due incertezze con un unico modello, senza distribuzioni a priori sui pesi e senza addestrare un insieme di reti. La valutazione riguarda il riconoscimento di dati fuori distribuzione, di errori di classificazione e di esempi avversari e l'active learning, su immagini e su un problema di regressione tabellare. Il lavoro non considera serie temporali né dati con struttura spaziale: gli esempi sono indipendenti, e il fuori distribuzione è definito da un dataset diverso o da ingressi perturbati, non da condizioni rare ma ricorrenti nello stesso dominio.

La tesi adotta di SDE-Net lo schema drift–diffusione, l'addestramento alternato delle due reti con pseudo-dati fuori distribuzione e la forma gaussiana dell'obiettivo di regressione. La variante paper-faithful del Capitolo 4 colloca il blocco SDE sullo stato latente prodotto dal backbone BiLSTM–GAT, quindi su un insieme di località collegate da un grafo e su finestre temporali; la diffusione è un coefficiente per esempio, ottenuto aggregando le località, e la testa gaussiana è estesa a più orizzonti di previsione. Il contesto di valutazione è diverso da quello dell'articolo: intervalli predittivi della produzione fotovoltaica e loro comportamento sulle osservazioni che i detector classificano come anomale. In questa applicazione le due componenti dell'incertezza non si sono comportate allo stesso modo: la varianza della testa gaussiana ha prodotto intervalli utilizzabili, mentre la dispersione fra le traiettorie, cioè la componente epistemica generata dalla diffusione, è risultata troppo ridotta per coprire da sola le osservazioni. L'esito è riportato nel Capitolo 6.

2.3.4 SDE U-Net

Monaco et al. [14] adattano SDE-Net a un'architettura U-Net per il post-processing di previsioni numeriche di precipitazione, con mappe di precipitazione cumulata giornaliera sull'Italia nord-occidentale. Poiché i blocchi dell'encoder hanno dimensioni diverse, il numero di passi di integrazione è allineato al numero di blocchi: a ciascun blocco è associato un blocco di diffusione, funzione dell'ingresso iniziale, il cui segnale è sommato alla rispettiva skip connection. La loss di regressione è una MSE e la diffusione è addestrata, come in SDE-Net, a distinguere ingressi originali e ingressi perturbati con rumore gaussiano. Il disegno sperimentale usa per training e validation soltanto eventi non intensi e valuta il modello sia su eventi non intensi sia su eventi intensi, confrontando più architetture probabilistiche in termini di equilibrio fra ampiezza e affidabilità degli intervalli. Il lavoro opera su campi regolari elaborati da un encoder–decoder convoluzionale e su mappe giornaliere: non tratta insiemi irregolari di località, serie temporali per sito o più orizzonti di previsione.

Di questo lavoro la tesi riprende due elementi. Il primo è l'allineamento fra passi stocastici e stadi dell'encoder, trasferito nella variante true-minimal agli stadi BiLSTM e GAT del backbone, con percorsi paralleli di drift e diffusione. Il secondo è il protocollo che esclude dal training gli eventi intensi e li mantiene nel test, realizzato qui con il filtro sulle finestre che contengono osservazioni anomale. Rispetto all'articolo cambiano il supporto spaziale, un grafo di località invece di una griglia, e il compito, la previsione di una serie per località. In questa variante la banda deriva dalla sola dispersione fra le traiettorie, senza una componente aleatoria, e il limite osservato con SDE-Net è più evidente: la banda è risultata troppo stretta rispetto alle osservazioni.

2.4 Posizionamento del lavoro

2.4.1 Il contributo sostenuto

I lavori esaminati coprono ciascuno una parte del problema affrontato. MTG-Flow tollera la presenza di anomalie nel training, ma descrive relazioni fra le variabili di un sistema e non fra siti geografici. STGAN introduce il contesto spaziale e un criterio avversario, ma presuppone una topologia fisica, la disponibilità di eventi documentati e, implicitamente, un training normale. CATCH e M2AD operano su serie multivariate prive di struttura geografica e non trattano, o escludono per ipotesi, un training contaminato. SDE-Net e SDE U-Net forniscono lo schema per l'incertezza del previsore, su esempi

indipendenti o su mappe giornaliere; trasferito a serie fotovoltaiche su un grafo di località, lo schema ha dato una componente epistemica troppo ridotta.

La tesi adatta un detector avversario spazio-temporale, nato per il traffico, a campi meteorologici privi di etichette e di topologia fisica, in due varianti che rappresentano l'intorno di una cella con una convoluzione su griglia oppure con l'attenzione su grafo. Poiché un training privo di anomalie non è garantito, ne definisce l'obiettivo come rilevamento di condizioni nuove rispetto al periodo di training. Lo estende con una misura di dispersione dello score, ottenuta con dropout Monte Carlo, con un monitoraggio senza etichette e con la ricostruzione di eventi geografici; e usa le sue decisioni per analizzare gli errori di un previsore fotovoltaico probabilistico. Il contributo consiste nell'adattamento, nella combinazione di questi elementi e nel protocollo di analisi. I componenti di base sono preesistenti: la tesi non propone un nuovo algoritmo di rilevamento.

2.4.2 Confronto dei detector esaminati

La Tabella 2.1 riassume i quattro detector esaminati e il percorso della tesi rispetto ai criteri usati nel capitolo. Le voci relative agli articoli riportano ciò che gli articoli dichiarano; dove un aspetto non è discusso, è indicato come non trattato. MTGFlow e STGAN sono stati eseguiti sui dati della tesi; CATCH e M2AD sono stati valutati sugli articoli e non eseguiti.

Tabella 2.1: Detector esaminati e percorso della tesi a confronto. La colonna sulle anomalie nel training indica come ciascun lavoro tratta la presenza di osservazioni anomale nei dati di addestramento.

Lavoro	Segnale dello score	Anomalie nel training	Contesto spaziale	Dati	Dispersione
MTGFlow [3]	Densità stimata	Ammesse per costruzione	No: relazioni fra variabili	Dataset pubblici	Non prevista
STGAN [5]	Errore di previsione e discriminatore	Non trattate: dati reali considerati normali	Sì: grafo da topologia fisica	Traffico	Non prevista
CATCH [1]	Errore di ricostruzione in frequenza	Non trattate	No: canali di una serie	Dataset reali e sintetici	Non prevista
M2AD [2]	Residui di previsione aggregati	Escluse per ipotesi	No: sensori di più sistemi	Dataset pubblici e caso industriale	Non prevista
Tesi	Come STGAN; densità per MTGFlow	Ammesse con MTGFlow; trattate come già osservate con STGAN	Sì: vicinanza geografica, griglia o grafo di griglia	PVGIS, ERA5	Sì: dropout Monte Carlo sullo score di STGAN

Capitolo 3

Dati e preprocessing

3.1 Serie PVGIS, località geografiche e target

Nei modelli PVGIS-only, `pv_power_output` rappresenta la produzione fotovoltaica teorica associata a ciascuna località PVGIS, non una misura acquisita da un impianto reale. Il target osservato `ENERGIA` della baseline viene pertanto trattato separatamente.

Il previsore utilizza serie orarie sincronizzate fra località e produce una stima della produzione futura. Il detector STGAN utilizza invece tre variabili meteorologiche: irradianza sul piano inclinato, temperatura a due metri e velocità del vento a dieci metri. La produzione futura non è il target della GAN: il generatore stima le variabili meteorologiche al passo successivo del contesto spaziale considerato.

3.2 Feature, trasformazioni fisiche e normalizzazione

Nel percorso PVGIS del previsore, il set completo comprende temperatura, irradianza sul piano inclinato, vento, seno e coseno dell'elevazione solare, indice di cielo sereno sul piano inclinato, sua deviazione standard mobile su tre ore, differenza temporale dell'irradianza, componenti diretta e diffusa inclinate e produzione storica. L'irradianza effettiva sul piano inclinato è ricostruita dalla somma delle componenti diretta e diffusa inclinate.

La normalizzazione del previsore usa statistiche dei dati di fit: z-score per temperatura, irradianza, vento e differenza temporale dell'irradianza, e una scala della produzione per località ricavata dal percentile 99 dei valori positivi diurni. La produzione storica è causale perché viene inclusa soltanto

nella finestra che precede il target. Le feature mobili possono richiedere anche osservazioni precedenti l'inizio della finestra esplicita.

Per STGAN, la trasformazione delle feature è un min–max stimato sul training, aggregando tempo e località e riportando i valori nel sistema di coordinate $[-1, 1]$. Valori di test esterni all'intervallo del training possono superare questi estremi, poiché la trasformazione non applica un clipping generale. La normalizzazione delle feature è distinta da quella delle componenti dello score, descritta nella sezione dedicata al detector.

3.3 Finestre temporali, split cronologici e previsione diretta multiorizzonte

Indicando con t l'ultimo timestamp della finestra di input, il target dell'orizzonte h è associato a $t + h$. L'ingresso del previsore ha forma $[B, N, L, F]$, con dimensione del batch B, numero di località N, lunghezza della sequenza L e numero di feature F. Il percorso a singolo orizzonte resta disponibile; nell'estensione diretta, un solo modello produce le uscite per l'insieme di orizzonti richiesto, ad esempio da una a sei ore.

Per H orizzonti, i target e le uscite assumono forma $[B, N, H]$. Le previsioni intermedie non vengono reinserite nell'input: tutte le uscite derivano dalla stessa finestra osservata. Ogni previsione conserva località, timestamp di emissione, timestamp target e orizzonte. I confronti a una e sei ore possono quindi essere estratti dallo stesso modello diretto, distinguendoli dalle precedenti esecuzioni con modelli separati per orizzonte.

Nel percorso SDE, un anno viene riservato alla validazione prima di stimare la normalizzazione. Il test viene fornito separatamente. Quando è attivo il filtro di training su finestre normali, vengono escluse le finestre con eventi nel contesto delle feature, nell'input o in almeno uno dei target richiesti. L'estensione degli orizzonti può pertanto cambiare sia il numero di finestre disponibili sia quello delle finestre ammissibili.

La preparazione STGAN prevede periodi storici e test separati; il primo target di test può utilizzare la coda contigua del training come contesto. I periodi e i parametri effettivamente utilizzati nelle esecuzioni devono essere riportati nella configurazione sperimentale.

3.4 Campi ERA5, allineamento e celle valide

Il percorso ERA5 utilizza due prodotti distinti: variabili a livello singolo e variabili su livelli di pressione, selezionando per queste ultime soltanto

850 hPa. Il contratto di ingresso comprende quindici feature, con un ordine condiviso fra acquisizione e preparazione. Le dieci variabili a livello singolo sono temperatura a due metri, componenti orizzontali del vento a dieci metri, pressione al livello medio del mare, precipitazione totale, copertura nuvolosa totale, radiazione solare discendente alla superficie, umidità volumetrica del primo strato del suolo, velocità d'attrito e altezza dello strato limite. Le altre cinque sono le componenti orizzontali del vento, la velocità verticale, la temperatura e l'umidità specifica a 850 hPa.

L'acquisizione predefinita parte dal 1980 e termina all'ultimo anno completo disponibile per entrambi i prodotti. Sono selezionati gli istanti UTC 00, 03, 06, 09, 12, 15, 18 e 21, su una griglia di $0.5^\circ \times 0.5^\circ$ nell'area $[60, -15, 20, 50]$, espressa nell'ordine nord, ovest, sud, est. Il campionamento ogni tre ore è una selezione di tempi validi, non un'aggregazione temporale: precipitazione e radiazione conservano gli accumuli di un'ora associati ai tempi selezionati, senza somme triorarie o conversioni locali delle unità.

I file mensili vengono verificati rispetto a tempi, griglia, variabili e livello di pressione richiesti. La preparazione allinea i due prodotti sulle stesse coordinate e sugli stessi timestamp, ordina le latitudini da nord a sud e le longitudini da ovest a est. Nell'area predefinita il reticolo contiene 81×131 posizioni; ciascun blocco è rappresentato come $[T_{\text{blocco}}, 81, 131, 15]$ prima della selezione delle celle.

La politica predefinita conserva le celle per le quali tutte le feature sono finite nel primo frame di training e richiede che questa maschera rimanga identica nel resto del periodo. La selezione iniziale non utilizza il test; la verifica successiva interrompe la preparazione se la completezza cambia nel tempo. Non viene applicata imputazione. La maschera può escludere celle marine per l'assenza dell'umidità del suolo, ma il criterio implementato è la completezza delle feature, non una classificazione terra–mare.

I cubi preparati hanno forma $[T, N_{\text{valide}}, 15]$. La prima versione della preparazione assegnava il periodo 1980–2004 al training e gli anni dal 2005 all'ultimo anno completo consecutivo presente localmente al test. La versione successiva introduce una terza partizione: training 1980–2003, validation 2004 e test dal 2005. Quando la validation è tenuta fuori dal training, viene letta soltanto dal monitoraggio e dalle statistiche descritte nella Sezione 4.9.4; in caso contrario il 2004 rientra nel training, come nella configurazione precedente. La validation non contribuisce alla normalizzazione dello score del test, alle soglie o agli eventi. Questi estremi descrivono la configurazione implementata; copertura effettiva e numero di celle valide devono essere riportati per le esecuzioni valutate. La normalizzazione delle feature rimane stimata soltanto sul training.

Capitolo 4

Metodologia

4.1 Panoramica del percorso metodologico

La metodologia comprende il backbone deterministico BiLSTM–GAT, gli esperimenti preliminari con Enhanced MC Dropout e Deep Ensemble e le varianti SDE-Net true-minimal e paper-faithful. La linea paper-faithful include una previsione diretta multiorizzonte e un'ablazione della GAT. Il rilevamento delle anomalie costituisce una linea distinta, basata su MTGFlow, STGAN e un adattamento STGAN a griglia, evoluto da una CNN senza ricorrenza a un encoder ConvGRU. La versione finale conserva la LSTM del trend e permette un'ablazione della dimensione dei kernel. Un'estensione separata applica lo stesso detector a ERA5 e introduce la ricostruzione di eventi geografici a partire dagli score. Su ERA5 il detector viene poi dotato di dropout nel generatore e di uno score Monte Carlo con una misura di dispersione associata. Due varianti intervengono sul generatore: la prima sostituisce, nei gate dell'unità ricorrente, la convoluzione con l'attenzione su grafo definita sull'intera griglia; la seconda applica la ConvGRU al campo completo invece che a singole patch. In entrambe il discriminatore rimane locale.

Le analisi post-hoc utilizzano previsioni e score già prodotti. Il cambiamento della soglia o del raggruppamento delle osservazioni modifica il protocollo di valutazione, senza comportare un nuovo addestramento del previsore.

4.2 Backbone BiLSTM–GAT

4.2.1 Tensori di input, encoder temporale e attention pooling

L'encoder temporale elabora la sequenza di ciascuna località con parametri condivisi. La rappresentazione BiLSTM, aggregata mediante pooling temporale, viene proiettata nello spazio latente utilizzato dai componenti successivi.

4.2.2 Grafo geografico Haversine e ablazione della GAT

Nel previsore con GAT, gli archi esprimono relazioni di vicinanza geografica e i pesi gaussiani forniscono un prior ai coefficienti di attenzione. Nel percorso paper-faithful, il logaritmo del peso geografico viene aggiunto al logit appreso e_{ij} dell'equazione (2.9), prima della softmax sugli archi entranti.

L'ablazione senza GAT rimuove gli strati di attenzione sul grafo: la proiezione dell'encoder temporale diventa direttamente lo stato iniziale della SDE. Il grafo continua a essere costruito e passato nelle interfacce, ma i suoi archi non sono utilizzati dal forward. L'ablazione riduce anche il numero di parametri, senza introdurre un blocco sostitutivo di pari dimensione.

L'assenza di message passing non implica completa indipendenza fra le distribuzioni predittive delle località. La diffusione SDE conserva un pooling degli stati iniziali sui siti e produce una scala comune per esempio. In inferenza stocastica, il contenuto degli altri siti può quindi influire sull'ampiezza delle perturbazioni di una località. Il confronto isola la rimozione della GAT, mantenendo questa componente condivisa.

4.2.3 Teste di previsione, funzione di perdita e training

4.3 Esperimenti probabilistici preliminari

4.3.1 Enhanced Monte Carlo Dropout

4.3.2 Deep Ensemble di modelli addestrati indipendentemente

4.3.3 Previsioni medie, dispersione e intervalli empirici

4.4 SDE-Net true-minimal

4.4.1 Backbone paralleli di drift e diffusione

4.4.2 Perturbazioni Browniane negli stadi BiLSTM e GAT

4.4.3 Training alternato, pseudo-OOD e inferenza a traiettorie

4.5 SDE-Net paper-faithful

4.5.1 Campo di drift, diffusione e integrazione Euler–Maruyama

Il backbone BiLSTM–GAT produce lo stato iniziale z_0 della dinamica latente. Il drift applica una trasformazione lineare seguita da ReLU. La rete di diffusione media lo stato iniziale sulle località e restituisce un coefficiente sigmoidale $g(z_0)$ per esempio, condiviso fra nodi e canali. L'integrazione implementata specializza l'equazione (2.15) ed è

$$z_{k+1} = z_k + f(z_k)\Delta\tau + s_{\max} g(z_0)\sqrt{\Delta\tau}\,\varepsilon_k, \qquad \varepsilon_k \sim \mathcal{N}(0, I). \tag{4.1}$$

La scala della diffusione viene calcolata una volta sullo stato iniziale e mantenuta lungo la traiettoria. Il tempo latente τ e il suo passo di integrazione sono distinti dall'orizzonte fisico h della previsione.

4.5.2 Testa gaussiana, negative log-likelihood e training

La testa PV restituisce una media non negativa e una deviazione standard positiva mediante trasformazioni softplus. Nell'estensione multiorizzonte, lo

stato finale condiviso alimenta H coppie (μ_h, σ_h). Non viene appresa una matrice di covarianza esplicita fra orizzonti.

L'obiettivo di regressione utilizza la forma

$$\mathcal{L}_{\mathrm{PV}} = \mathrm{media}_{b,n,h}\left[\log \sigma_{bnh}^2 + \frac{(y_{bnh} - \mu_{bnh})^2}{\sigma_{bnh}^2}\right], \tag{4.2}$$

equivalente alla negative log-likelihood gaussiana a meno di una costante e di un fattore moltiplicativo. Quando abilitata, una testa ausiliaria stima l'indice di cielo sereno sul piano inclinato e aggiunge un termine MSE pesato.

Il training alterna due aggiornamenti: il primo ottimizza encoder, eventuale GAT, drift e teste; il secondo aggiorna soltanto la rete di diffusione. Quest'ultimo usa una BCE con dati di ingresso etichettati zero e pseudo-OOD etichettati uno, ottenuti aggiungendo rumore gaussiano all'intero input. Le rappresentazioni del secondo passo sono staccate dall'encoder. La procedura prevede inoltre warm-up della scala SDE e selezione del modello tramite validazione.

4.5.3 Campionamento e componenti dell'incertezza predittiva

Ogni traiettoria browniana m produce una componente gaussiana con parametri $(\mu^{(m)}, \sigma^{(m)})$ per ciascuna uscita. La media e la varianza predittiva sono calcolate come

$$\bar{\mu} = \frac{1}{M}\sum_{m=1}^{M} \mu^{(m)}, \tag{4.3}$$

$$v_{\mathrm{tot}} = \mathrm{Var}_m\left(\mu^{(m)}\right) + \frac{1}{M}\sum_{m=1}^{M}\left(\sigma^{(m)}\right)^2. \tag{4.4}$$

La varianza v_{tot} ha la forma della varianza di miscela dell'equazione (2.13), con le traiettorie al posto delle reti di un insieme. Il codice conserva separatamente la dispersione delle medie lungo le traiettorie e la varianza delle teste gaussiane, indicate rispettivamente come componenti epistemica e aleatorica.

L'intervallo principale è ottenuto dai quantili a code uguali della miscela gaussiana equiponderata rappresentata dalle traiettorie. La banda $\bar{\mu} \pm z\sqrt{v_{\mathrm{tot}}}$ è mantenuta come approssimazione gaussiana diagnostica. Il percorso senza rumore integra invece il solo drift e non coincide, in generale, con la media esatta delle traiettorie stocastiche.

4.6 Rilevamento delle anomalie climatiche con MTGFlow

4.6.1 Serie storiche per località, variabili climatiche e finestre

4.6.2 Grafo dinamico tra entità e normalizing flow condizionale

4.6.3 Score aggregato della località, score per variabile e soglie IQR

4.6.4 Modelli indipendenti per località e assenza di message passing geografico

4.7 STGAN su PVGIS: versione su grafo e variante a griglia

4.7.1 Contesto spaziale e architettura GCGRU–LSTM

La versione STGAN basata su grafo costruisce un sottografo locale comprendente la località centrale e i vicini geografici, con nove siti nella configurazione di riferimento. Gli archi diretti derivano da un criterio kNN, con pesi gaussiani delle distanze, self-loop e normalizzazione dell'adiacenza.

Il generatore combina un ramo GCGRU sul contesto recente, una LSTM sulla storia della località centrale e una codifica one-hot dell'ora e del giorno della settimana. Nella configurazione di riferimento, il contesto recente contiene un passo e il trend 168 passi orari. L'uscita stima le tre variabili meteorologiche al timestamp successivo per tutti i nodi del sottografo.

Il discriminatore combina una rappresentazione GCGRU della storia con una convoluzione sul dato corrente, reale o generato, e restituisce un valore sigmoidale. I due componenti operano sullo stesso contesto locale; il generatore non stima direttamente la produzione fotovoltaica.

4.7.2 Variante ConvGRU–LSTM e gestione delle celle assenti

L'adattamento a griglia sostituisce gli operatori sul grafo con convoluzioni su una patch geografica $P \times P$. Le coordinate vengono proiettate e verificate

rispetto a un reticolo prima di assegnare righe e colonne: l'ordine originario dei siti non viene semplicemente rimodellato come un'immagine. Nel percorso PVGIS, la configurazione predefinita usa EPSG:32632 e passo di 5 km; sono ammesse patch con $P = 1, 3, 5$. Le celle assenti non vengono sostituite da località più lontane.

Il primo adattamento utilizzava un encoder CNN senza ricorrenza. La versione finale impiega invece una ConvGRU sia nel ramo recente del generatore sia in quello storico del discriminatore. Le denominazioni delle due versioni non identificano quindi architetture intercambiabili. Con R passi recenti, L passi di trend e F feature, gli ingressi hanno forma $[B, R, F, P, P]$ per la patch recente e $[B, L, F]$ per la storia del sito centrale; maschera e calendario hanno rispettivamente forma $[B, 1, P, P]$ e $[B, 31]$.

Le feature delle celle assenti sono azzerate dopo normalizzazione e la maschera binaria M viene fornita come canale aggiuntivo a ogni strato ConvGRU. Rispetto alle equazioni (2.5)–(2.8) cambiano l'ingresso e l'ultimo passaggio. I gate e lo stato candidato sono calcolati su X'_s, la concatenazione dei valori mascherati e di M, al posto di X_s; lo stato precedente H_{s-1} è già mascherato e lo stato aggiornato viene moltiplicato per la maschera, replicata sui canali:

$$H_s = M \odot \left[U_s \odot H_{s-1} + (1 - U_s) \odot \widetilde{H}_s \right]. \tag{4.5}$$

Il mascheramento dello stato impedisce alle celle assenti di conservare attivazioni da propagare negli strati o nei passi successivi. Non viene applicata una rinormalizzazione del kernel in funzione delle celle osservate, come avverrebbe in una partial convolution.

Lo stato ricorrente è inizializzato a zero per ogni finestra. I default prevedono due strati ConvGRU da 32 canali, $R = 1$ e una LSTM del trend a due strati con stato nascosto di dimensione 64. Nel caso orario $L = 168$. Con un solo passo recente la ConvGRU esegue un solo aggiornamento dallo stato nullo: la ricorrenza sul lungo periodo rimane affidata alla LSTM. Finestre recenti più lunghe sono configurabili, ma il loro impiego effettivo non viene dedotto dai default.

Nel generatore, l'uscita ConvGRU viene concatenata alla rappresentazione del trend centrale e a quella del calendario, replicate sulle posizioni della patch. Una proiezione 1×1 seguita da tanh produce il target meteorologico $[B, F, P, P]$, azzerando le celle assenti. Nel discriminatore, la storia codificata viene appiattita su tutta la patch e proiettata linearmente; il dato corrente passa attraverso una proiezione 1×1 e un massimo sulle celle valide. Le due rappresentazioni alimentano la classificazione sigmoidale.

Il numero di celle osservate può variare fra patch. La loss generativa e lo score di errore sono mediati sulle sole celle valide e sulle feature, prima di

aggregare gli esempi. Le patch complete e incomplete vengono mantenute distinte nel confronto dei detector. La presenza delle stesse località, quando verificata, non rende equivalenti gli operatori convoluzionali e quelli sul grafo.

4.7.3 Ablazione del kernel e supporto spaziale osservato

La dimensione k del kernel è indipendente dal lato P della patch. L'ablazione consente $k = 1, 3, 5$ nei gate reset, update e candidato delle ConvGRU del generatore e del discriminatore, con padding $\lfloor k/2 \rfloor$. Le proiezioni finali 1×1 rimangono tali in tutte le configurazioni. Il caso predefinito è $k = 3$, mentre la patch predefinita conserva $P = 3$.

Con $k = 1$ i gate non mescolano celle geografiche diverse mediante convoluzione. Il detector continua tuttavia a utilizzare una patch: il discriminatore aggrega la storia appiattita e il massimo sulle celle valide, mentre loss e score generativo considerano l'intero supporto osservato. L'ablazione elimina quindi il mixing convoluzionale locale, senza rendere l'intero detector indipendente dalle altre celle.

Con $k = 5$ aumenta l'ampiezza del kernel, ma non il numero di siti forniti in ingresso. Su una patch 3×3 rimangono al massimo nove siti osservati e la parte esterna è gestita dal padding. Modificare P costituirebbe un diverso intervento, perché cambierebbe il supporto geografico e la dimensione della proiezione storica del discriminatore.

A parità di canali e strati, la dimensione del kernel modifica anche il numero di parametri. Il confronto deve pertanto riportare capacità parametrica, patch, lunghezza delle finestre e configurazione di training: non isola automaticamente il solo effetto dell'estensione spaziale a capacità costante.

4.7.4 Training avversario, anomaly score e soglia globale

Il discriminatore viene addestrato con reale uguale a zero e generato uguale a uno. Gli obiettivi sono

$$\mathcal{L}_D = \tfrac{1}{2}\Big[\mathrm{BCE}(D_{\text{reale}}, 0) + \mathrm{BCE}(D_{\text{generato}}, 1)\Big], \tag{4.6}$$

$$\mathcal{L}_G = \lambda_G \ \mathrm{MSE}(\hat{x}, x) + \mathrm{BCE}(D_{\text{generato}}, 0). \tag{4.7}$$

Il peso di ricostruzione predefinito è $\lambda_G = 500$; nella variante ConvGRU la MSE applica la riduzione mascherata descritta sopra. Generatore e discriminatore vengono aggiornati con ottimizzatori Adam separati, prima D e poi G. Nel passo del generatore, i parametri del discriminatore sono congelati ma viene mantenuto il gradiente rispetto alla predizione generata. La storia

usata per questa loss è ricalcolata con i pesi aggiornati di D; il riuso del forward del generatore non sostituisce questo aggiornamento. Il valore del discriminatore non viene interpretato come probabilità di anomalia calibrata mediante etichette reali.

Lo score combina l'errore quadratico medio sul contesto spaziale e la differenza $D_{\text{reale}} - D_{\text{generato}}$. Le due componenti vengono normalizzate separatamente con min–max sull'intero insieme di test località–timestamp e sommate. I residui per feature della sola località centrale sono conservati come diagnostica distinta.

La decisione utilizza un ranking globale stabile: con percentuale p, vengono selezionate $\lceil np/100 \rceil$ osservazioni fra le n disponibili. Il valore predefinito è $p = 1$. Non viene applicato un budget dell'1% separatamente a ogni sito. Poiché normalizzazione dello score e ranking dipendono dal test completo, il protocollo è retrospettivo; non definisce da solo una soglia causale per uso online.

4.7.5 Campionamento e riproducibilità del calcolo

Il training predefinito visita il prodotto completo fra tempi target e località con ordine casuale. La modalità globale conserva l'ordine del percorso di riferimento; una modalità alternativa mescola blocchi e campioni al loro interno. Quest'ultima conserva insieme e molteplicità dei campioni, ma cambia l'ordine e la distribuzione delle permutazioni: deve essere indicata come parte del protocollo, non soltanto come scelta di memoria.

Estrazione vettoriale delle finestre, cache normalizzata e scoring su disco permettono di elaborare i dati a blocchi. Gli estremi delle due componenti dello score rimangono globali sull'intero test; non vengono stimati separatamente per blocco. Il ranking esterno conserva l'ordinamento decrescente e risolve i pareggi secondo l'indice originale. Il batch di inferenza è configurabile separatamente da quello di training. L'equivalenza prevista dalle implementazioni e dai relativi controlli non costituisce una misura di accelerazione o di riduzione della memoria nelle esecuzioni reali.

4.8 Estensione a ERA5 ed estrazione degli eventi

4.8.1 Adattamento del detector alla cadenza trioraria

L'estensione utilizza i cubi e la maschera descritti nella Sezione 3.4, mantenendo l'architettura ConvGRU–LSTM e le loss della Sezione 4.7. Il target del

generatore resta meteorologico e comprende ora quindici feature. La griglia è definita direttamente in coordinate geografiche, con EPSG:4326 e passo angolare di 0.5°.

La cadenza diventa di tre ore e il trend viene impostato a 56 passi, conservando una durata di 168 ore. Il ramo recente mantiene un passo nel default; la codifica di ora e giorno della settimana rimane di dimensione 31. Lunghezza del ramo recente e codifica temporale diventano configurabili negli sviluppi della Sezione 4.9. Preparazione, training con scoring e analisi degli eventi costituiscono fasi distinte: gli eventi vengono ricavati dagli score già disponibili, senza un nuovo aggiornamento dei pesi del detector.

4.8.2 Soglia, morfologia e cluster spaziali

Gli score $[T, N_{\text{valide}}]$ vengono ricollocati sulla griglia $[T, H, W]$, mantenendo non valide le celle escluse. La selezione iniziale può utilizzare una soglia assoluta oppure un percentile degli score finiti, globale per default o distinto per frame. Una cella è selezionata soltanto se lo score è strettamente maggiore della soglia. In presenza di pareggi, questa regola non garantisce lo stesso numero di selezionati del top-K esatto degli export PVGIS.

Per ogni frame, la maschera binaria viene sottoposta ad apertura e chiusura, rispettando le celle valide. Il default usa un elemento strutturante quadrato 3×3 e un'iterazione per operazione. Le componenti connesse sono individuate con otto vicini e possono essere filtrate per numero minimo di celle. Le operazioni morfologiche possono rimuovere o aggiungere celle rispetto alla selezione iniziale: i cluster risultanti non coincidono necessariamente con l'insieme degli score sopra soglia.

Il kernel della morfologia e quello della ConvGRU sono parametri di fasi diverse. Un confronto fra kernel neurali 1×1 e 5×5 non implica una modifica dell'elemento strutturante usato sugli eventi. Le aree dei cluster sono ottenute sommando le aree sferiche delle celle e i centroidi sono pesati con tali aree. Questa correzione geometrica nel postprocessing non rende uniforme in chilometri la patch neurale, la cui estensione fisica varia con la latitudine.

4.8.3 Collegamento temporale, separazioni e fusioni

I cluster di frame consecutivi vengono collegati secondo sovrapposizione, sovrapposizione dopo dilatazione, distanza dei centroidi oppure unione dei criteri. Indicando con A e B i supporti di due cluster, il rapporto di sovrapposizione

è

$$o(A, B) = \frac{|A \cap B|}{\min(|A|, |B|)}. \tag{4.8}$$

Non si tratta dell'intersezione sull'unione. Nel criterio dilatato, A è sostituito dal supporto ottenuto dopo dilatazione, anche nel denominatore. Il default utilizza una dilatazione di una cella e una soglia di sovrapposizione pari a 0.1; la distanza dei centroidi è un criterio alternativo configurabile.

L'identità di un evento corrisponde a una componente connessa del grafo temporale dei cluster. Il collegamento non è vincolato a essere uno a uno: una separazione mantiene i rami nello stesso evento, mentre una fusione unifica retrospettivamente le identità precedenti. Un salto nella cadenza temporale interrompe i collegamenti, evitando di unire automaticamente osservazioni separate da intervalli mancanti.

La durata riportata comprende l'intervallo rappresentato dall'ultimo frame,

$$d_{\text{evento}} = t_{\text{fine}} - t_{\text{inizio}} + \Delta t, \qquad \Delta t = 3\,\text{h} \tag{4.9}$$

nel default ERA5; il solo tempo trascorso fra primo e ultimo frame viene conservato separatamente. La normalizzazione degli score sull'intero test, la soglia globale quando utilizzata e l'unificazione retrospettiva degli eventi definiscono un protocollo di analisi successiva al periodo osservato, non un sistema causale di allerta.

4.9 STGAN su ERA5: score Monte Carlo e varianti ConvGRU e GAT-GRU

Gli sviluppi di questa sezione riguardano il solo percorso ERA5. Feature, griglia, maschera delle celle ed estrazione degli eventi restano quelle delle Sezioni 3.4 e 4.8. Il lavoro procede su due linee parallele, che condividono protocollo di training, score e monitoraggio e si distinguono per l'encoder spaziale del generatore: una ConvGRU, come nella Sezione 4.7.2, oppure una Graph Attention Network. Nessuna delle due linee è la continuazione dell'altra.

4.9.1 Dropout nel generatore e campionamento dello score

Il generatore riceve tre strati di dropout: sulla rappresentazione spaziale del ramo recente, sulla rappresentazione del trend e sulla loro concatenazione

con la codifica temporale, prima della proiezione di uscita. La probabilità predefinita è 0.2. Il discriminatore non contiene dropout.

Durante lo scoring il modello è in modalità di valutazione, con l'eccezione dei dropout del generatore, che restano attivi. Per ogni osservazione vengono estratti J campioni, 20 nel default. Gli encoder del generatore, la codifica della storia nel discriminatore e il valore D_{reale} non dipendono dal dropout e sono calcolati una sola volta; a ogni campione vengono ripetuti i dropout, la proiezione di uscita e la valutazione del dato generato.

Per la coppia tempo–località (t, n) e il campione j, le due componenti sono l'errore quadratico medio $s^{(j)}_{G,tn}$ sulle celle valide del contesto spaziale e la differenza $s^{(j)}_{D,tn} = D_{\text{reale}} - D^{(j)}_{\text{generato}}$. Indicando con $\bar{s}_G$ e $\bar{s}_D$ le rispettive medie sui J campioni, lo score è

$$a_{tn} = \frac{\bar{s}_{G,tn} - \min \bar{s}_G}{\max \bar{s}_G - \min \bar{s}_G} + \frac{\bar{s}_{D,tn} - \min \bar{s}_D}{\max \bar{s}_D - \min \bar{s}_D}, \tag{4.10}$$

dove minimi e massimi sono presi sull'intero prodotto tempo–località del test. La fusione mantiene quindi lo schema della Sezione 4.7, applicato alle mappe medie. Una componente costante contribuisce zero.

Gli stessi estremi trasformano ciascun campione, producendo $a^{(j)}_{tn}$. La dispersione associata allo score è la deviazione standard di popolazione

$$u_{tn} = \sqrt{\frac{1}{J} \sum_{j=1}^{J} \left(a^{(j)}_{tn} - a_{tn} \right)^2}. \tag{4.11}$$

Con $J = 1$ lo score coincide con quello deterministico e u_{tn} è nulla. Vengono conservati anche media e deviazione standard delle due componenti non normalizzate e la loro covarianza.

La quantità u_{tn} misura la variabilità dello score rispetto alle maschere di dropout del generatore. È espressa nelle unità dello score normalizzato e non è una probabilità di anomalia; la sua calibrazione come misura di incertezza non è verificata dal metodo. Come nel caso deterministico, la normalizzazione dipende da tutti gli score del test, senza uso di etichette: estendere il periodo di test può modificare estremi e ordinamento.

4.9.2 Split di validation e bilanciamento dell'addestramento avversario

Gli obiettivi $\mathcal{L}_D$ e $\mathcal{L}_G$ sono quelli della Sezione 4.7. Il peso di ricostruzione λ_G diventa un parametro, con valore predefinito invariato. I tassi di apprendimento dei due ottimizzatori Adam possono essere distinti: quello

del discriminatore è espresso come rapporto rispetto a quello del generatore oppure come valore indipendente, e le due forme non possono essere indicate insieme. Anche il coefficiente β_1 dei due ottimizzatori, che regola quanto gli aggiornamenti precedenti pesano nella media dei gradienti, è un parametro: il valore predefinito è 0.9, quello usato dal codice degli autori di STGAN.

Un secondo controllo riguarda il numero di aggiornamenti per batch. Con rapporto n_D:n_G, sullo stesso batch vengono eseguiti prima n_D aggiornamenti del discriminatore e poi n_G del generatore, ciascuno con un proprio forward completo; il default è 1:1. Il passo del discriminatore e quello del generatore utilizzano forward indipendenti del generatore, quindi maschere di dropout distinte. Questo rapporto è un conteggio di aggiornamenti e non va confuso con il rapporto fra i tassi di apprendimento.

A ogni epoca vengono salvati i pesi e lo stato dei due ottimizzatori. Un training interrotto può essere ripreso soltanto con la stessa configurazione, la stessa normalizzazione e gli stessi riferimenti di monitoraggio. È disponibile un'esecuzione in precisione mista BF16, con pesi mantenuti in FP32 e loss avversaria calcolata sui logit; si tratta di una scelta numerica, da riportare insieme alla configurazione.

Rapporti fra tassi, numero di aggiornamenti e peso di ricostruzione sono strumenti per studiare l'equilibrio fra le due reti. La loro disponibilità non indica quale combinazione sia preferibile.

4.9.3 Finestra recente, codifica temporale ciclica e normalizzazione stagionale

Il numero R di passi recenti è configurabile anche nel percorso ERA5. Con $R > 1$ la ConvGRU esegue più aggiornamenti sulla finestra recente, mentre il trend conserva 56 passi.

La codifica temporale predefinita resta quella a 31 elementi, composta dal giorno della settimana e dall'ora UTC. In alternativa è disponibile una codifica ciclica a quattro elementi, diversa per località. Indicando con h_t l'ora UTC, con ℓ_n la longitudine in gradi, con g_t il giorno frazionario dell'anno e con G_t il numero di giorni dell'anno corrispondente, la codifica è

$$c_{tn} = [\sin\phi_{tn},\ \cos\phi_{tn},\ \sin\psi_t,\ \cos\psi_t]\,, \quad \phi_{tn} = \frac{2\pi}{24}\left(h_t + \frac{\ell_n}{15}\right), \quad \psi_t = \frac{2\pi g_t}{G_t}. \tag{4.12}$$

Il primo angolo rappresenta l'ora solare locale, ottenuta dalla sola longitudine senza fusi orari; il secondo la posizione nell'anno. La codifica ciclica non contiene il giorno della settimana.

La normalizzazione predefinita rimane il min–max per feature stimato sul training. La variante stagionale applica prima una standardizzazione per località n, feature f, ora del giorno o e giorno dell'anno g,

$$z_{tnf} = \frac{x_{tnf} - \mu_{nfog}}{\sigma_{nfog}}, \tag{4.13}$$

e poi lo stesso min–max. Media e deviazione standard sono stimate sul solo training, raggruppando una finestra circolare di giorni attorno a g, di quindici giorni per lato nel default. La dispersione è calcolata attorno alla media lisciata di ciascun giorno, in modo che la variazione del ciclo stagionale all'interno della finestra non venga contata come variabilità. Un valore minimo, pari a una frazione della deviazione standard complessiva della feature, limita la divisione dove una variabile è quasi costante, come la radiazione solare notturna.

Finestra recente, codifica temporale e normalizzazione modificano l'ingresso del modello: ciascuna scelta richiede un nuovo addestramento e identifica una configurazione distinta.

4.9.4 Monitoraggio senza etichette e spazio PCA di riferimento

Le quantità di questa sezione servono a osservare l'addestramento e a confrontare configurazioni. Non entrano in una loss, in un aggiornamento dei pesi, nello score o nella valutazione sul test, e non utilizzano etichette di anomalia. Il loro calcolo avviene senza gradiente e ripristina gli stati dei generatori casuali, così da non alterare la traiettoria del training.

Al termine di ogni epoca, un sottoinsieme fisso della validation viene elaborato con un forward deterministico, a dropout spento. Il sottoinsieme comprende 32 timestamp equispaziati nel default, ciascuno con tutte le località. Vengono registrate tre diagnostiche: la differenza assoluta media fra le attivazioni del penultimo strato del discriminatore sull'osservazione e sulla ricostruzione; la variazione dello score fra epoche consecutive sulle stesse celle, riassunta da media, mediana e correlazione di Spearman; la Maximum Mean Discrepancy fra le stesse attivazioni, con kernel RBF e banda scelta con l'euristica della mediana.

Una seconda misura confronta osservazioni e ricostruzioni in uno spazio indipendente dal modello. Lo spazio è ottenuto da un'analisi delle componenti principali dei campi di training: ogni campione è il campo completo di un timestamp, normalizzato e appiattito su località e feature. La PCA è calcolata in forma esatta su un insieme di timestamp equispaziati sull'intero training,

4096 nel default, e viene salvata con le componenti principali e la varianza spiegata. È costruita una sola volta, prima delle esecuzioni, e successivamente soltanto caricata.

Su questo spazio viene definito un riferimento per la validation: S sottoinsiemi fissi di timestamp, cinque da 512 nel default e disgiunti quando il numero di timestamp lo consente, le feature PCA delle loro osservazioni e una banda σ pari alla distanza euclidea mediana fra tali feature. Anche questo riferimento è fissato prima delle esecuzioni. A ogni epoca, per ciascun sottoinsieme, si calcola la stima non distorta

$$\widehat{\mathrm{MMD}}^2 = \frac{1}{n(n-1)} \sum_{i \neq i'} k(x_i, x_{i'}) + \frac{1}{n(n-1)} \sum_{i \neq i'} k(y_i, y_{i'}) - \frac{2}{n^2} \sum_{i,i'} k(x_i, y_{i'}), \tag{4.14}$$

dove x_i sono le feature PCA delle osservazioni, y_i quelle delle ricostruzioni del generatore e il kernel è la media di tre RBF,

$$k(a, b) = \frac{1}{3} \sum_{c \in \{0.5,\, 1,\, 2\}} \exp\left(-\frac{\|a - b\|^2}{2(c\sigma)^2} \right). \tag{4.15}$$

Vengono registrate media e varianza della stima sui sottoinsiemi e la media mobile delle ultime epoche, cinque nel default. Quest'ultima è la quantità proposta per la selezione fra configurazioni. La stima non distorta può assumere valori leggermente negativi.

Dopo l'ultima epoca viene inoltre calcolato, su tutti i punti validi della validation, l'errore di ricostruzione medio sui campioni Monte Carlo, riassunto da media, deviazione standard, mediana e 95-esimo percentile.

Numero di componenti principali, sottoinsiemi e banda fanno parte del protocollo e devono essere riportati. Poiché tutte le esecuzioni confrontate caricano gli stessi riferimenti, le differenze nella misura non dipendono da una nuova stima dello spazio o della banda. Una MMD più bassa indica ricostruzioni più vicine alle osservazioni nello spazio considerato; non misura direttamente la qualità del rilevamento delle anomalie.

4.9.5 Generatore GAT-GRU sul grafo della griglia

Nella variante su grafo ogni località valida è un nodo. Ciascun nodo riceve un arco da ognuno degli otto vicini immediati presenti sulla griglia e da sé stesso. Gli archi sono diretti e memorizzati in forma sparsa; i bordi non sono collegati fra loro e una cella senza località non genera archi. A differenza del grafo del previsore, gli archi non hanno pesi geografici.

Lo strato di attenzione è quello delle equazioni (2.9)–(2.11), a più teste e con pendenza negativa 0.2 nella LeakyReLU; $\mathcal{N}(i)$ è l'insieme delle sorgenti

degli archi entranti in i, compreso i stesso. Nella GAT-GRU lo strato sostituisce la convoluzione nei gate dell'unità ricorrente. Siano $\mathcal{A}_r$, $\mathcal{A}_u$ e $\mathcal{A}_c$ tre strati di attenzione distinti, con le teste mediate e senza non linearità propria, e X'_s l'ingresso del passo s concatenato alla maschera. L'aggiornamento di uno strato ricorrente è

$$R_s = \sigma(\mathcal{A}_r([X'_s, H_{s-1}]))\,, \tag{4.16}$$

$$U_s = \sigma(\mathcal{A}_u([X'_s, H_{s-1}]))\,, \tag{4.17}$$

$$\widetilde{H}_s = \tanh(\mathcal{A}_c([X'_s, R_s \odot H_{s-1}]))\,, \tag{4.18}$$

$$H_s = M \odot \left[U_s \odot H_{s-1} + (1 - U_s) \odot \widetilde{H}_s\right]. \tag{4.19}$$

È la forma delle equazioni (2.5)–(2.8), con l'attenzione su grafo al posto della convoluzione spaziale e con lo stesso trattamento della maschera della Sezione 4.7.2. I default prevedono due strati ricorrenti, quattro teste e 32 canali. Poiché il gate di reset e lo stato candidato applicano l'operatore in sequenza, a ogni passo lo stato si propaga di due archi: con $R \geq 2$ passi recenti e due strati, l'ingresso del primo passo raggiunge i nodi fino a $2R + 1$ archi di distanza. La ConvGRU con kernel 3×3 ha la stessa struttura e lo stesso raggio.

Una prima versione del generatore, mantenuta come opzione, applica a ciascun passo recente un encoder di due strati di attenzione, con le teste concatenate e seguite da ELU nel primo e mediate nel secondo, e aggrega i passi con una GRU a gate puntuali, cioè con la ConvGRU della Sezione 4.7.2 con kernel 1×1. In questa versione il mixing spaziale riguarda il solo ingresso di ciascun passo e il raggio osservato resta di due archi per qualunque R: non è una sostituzione uno a uno dell'unità ricorrente dell'articolo. Le due versioni sono configurazioni distinte e i rispettivi checkpoint non sono intercambiabili. In entrambe la LSTM del trend elabora una sequenza per nodo e la codifica temporale è proiettata per nodo o condivisa; seguono gli stessi tre dropout e la stessa proiezione di uscita, che restituisce $[B, N, F]$.

Il discriminatore resta quello a patch. Per ogni nodo vengono estratte le patch $P \times P$ della storia recente, dell'osservazione e della ricostruzione globale del generatore, con le celle assenti azzerate e la relativa maschera. I centri sono elaborati a blocchi per limitare la memoria. La loss di ricostruzione è la media, sui centri, dell'errore quadratico medio sulla patch di ciascun centro: l'errore di un nodo entra quindi attraverso tutte le patch che lo contengono. Le loss dei blocchi sono pesate per la rispettiva frazione di centri, in modo che la loro somma coincida con la media su tutti i centri, e i gradienti vengono accumulati prima di un unico aggiornamento per rete.

Un campione è un timestamp con tutti i nodi e il batch predefinito contiene un solo timestamp. Un'epoca comprende quindi $\lceil T/B \rceil$ aggiorna-

menti per rete, con T timestamp utili, contro $\lceil TN/B \rceil$ del modello a patch. Score, campionamento Monte Carlo e fusione delle componenti seguono la Sezione 4.9.1.

Rispetto alla variante ConvGRU sul campo intero della Sezione 4.9.6, il generatore GAT-GRU ha la stessa unità del campione, lo stesso numero di aggiornamenti per epoca, la stessa struttura ricorrente e lo stesso raggio: cambia il modo di pesare i vicini e, con esso, il numero di parametri. Rispetto alla variante ConvGRU a patch cambiano invece anche l'unità del campione e il numero di aggiornamenti per epoca.

4.9.6 Variante convoluzionale sul campo intero

La seconda variante nasce dal tempo di addestramento del modello a patch su ERA5, in cui il numero di aggiornamenti per epoca cresce con il prodotto fra timestamp e località. Mantiene la ConvGRU e modifica l'unità del campione: invece di una cella con la propria patch, un campione è l'intero campo di un timestamp, disposto sul reticolo $H \times W$. Moduli e parametri sono quelli del modello a patch; cambia ciò a cui vengono applicati.

Il generatore opera sul campo completo, da $[B, R, F, H, W]$ a $[B, F, H, W]$. Le convoluzioni scorrono sull'intero reticolo, quindi il campo ricettivo non è più troncato al bordo di una patch e ogni cella viene ricostruita una sola volta. La LSTM del trend e la codifica temporale sono calcolate per cella e disposte sul reticolo, dove il modello a patch replicava quelle del sito centrale sulle posizioni della patch.

Il discriminatore rimane locale. La patch di ogni cella viene estratta dal campo e il discriminatore a patch le valuta tutte in un'unica passata, con le stesse maschere e gli stessi azzeramenti. L'uscita relativa a una cella è quella che il discriminatore a patch produrrebbe sulla sua patch. Una convoluzione che scorre liberamente sul campo non darebbe lo stesso valore, perché la ConvGRU del discriminatore applica il padding all'interno di ciascuna patch. Il costo del discriminatore per cella resta pertanto quello del modello a patch.

La loss di ricostruzione è la media su celle con località e feature del campo, poi sui timestamp del batch. La loss avversaria è la media della BCE sugli output locali, uno per cella. Lo score conserva le definizioni per coppia tempo–località: la componente di ricostruzione è l'errore medio sulla patch della cella, calcolato sul campo ricostruito.

Come nella variante su grafo, un'epoca comprende $\lceil T/B \rceil$ aggiornamenti per rete invece di $\lceil TN/B \rceil$. A parità di epoche i due regimi non sono confrontabili: il numero di aggiornamenti dei pesi differisce di un fattore dell'ordine di N e ogni gradiente è mediato su tutte le celle di un timestamp.

La variante va quindi trattata come configurazione di training distinta, non come ottimizzazione del modello a patch.

4.9.7 Incertezza negli eventi e normalizzazione climatologica degli score

L'estrazione degli eventi della Sezione 4.8 può operare sullo score combinato oppure su una sola componente. La dispersione u_{tn} viene ricollocata sulla griglia e riportata per cluster, come media e massimo sulle celle, e per evento, come media pesata sulle celle e massimo. Non partecipa alla soglia, alla morfologia o ai collegamenti temporali: è un'annotazione degli eventi già individuati.

Una trasformazione successiva allo scoring esprime ogni score rispetto alla climatologia della stessa località. Per la località n, il mese m e l'ora UTC o del timestamp t, appartenente all'anno y,

$$\zeta_{tn} = \frac{a_{tn} - \mu_{nmo}^{(-y)}}{\sigma_{nmo}^{(-y)}}, \tag{4.20}$$

dove media e deviazione standard sono calcolate sugli score della stessa località, mese e ora negli altri anni del test. Un anno non contribuisce quindi alla propria climatologia. I gruppi con meno di trenta valori di riferimento, nel default, o con varianza nulla non ricevono uno score. La dispersione u_{tn} viene divisa per la stessa deviazione standard. Gli eventi possono essere estratti da questi score normalizzati con lo stesso algoritmo.

Questa trasformazione agisce sugli score, dopo l'addestramento, e non modifica il detector. È distinta dalla normalizzazione stagionale della Sezione 4.9.3, che agisce sull'ingresso e richiede un nuovo training. Le due operazioni rimuovono componenti cicliche in punti diversi della catena e il loro uso congiunto deve essere dichiarato.

Capitolo 5

Esperimenti

5.1 Configurazione degli esperimenti

5.1.1 Split temporali, orizzonti e configurazioni confrontate

5.1.2 Metriche puntuali e probabilistiche

5.2 Detector e configurazioni a confronto

5.3 Analisi post-hoc e protocollo di valutazione

5.3.1 Allineamento e distribuzione spazio-temporale

Le previsioni sono associate alle decisioni dei detector tramite località e timestamp target. Nel caso multiorizzonte, la chiave completa della previsione include anche l'orizzonte, mentre l'etichetta del detector rimane unica per località e timestamp. La stessa osservazione target può quindi essere associata a previsioni emesse in ore diverse.

Il protocollo STGAN prevede un'esclusione opzionale degli azzeramenti solari regionali isolati e del passo immediatamente successivo, seguito dal ricalcolo del top-K sulle osservazioni ammissibili. Il percorso NetCDF controlla più variabili solari e la produzione; quello basato sui dati preparati controlla la sola POA. La sorgente utilizzata deve essere indicata, poiché i due criteri non sono identici.

La serie locale mostra tempo e anomaly score, con le decisioni evidenziate e interruzioni nei periodi senza score. La rappresentazione regionale mostra

invece, per ogni ora, la percentuale di siti anomali rispetto ai siti con score valido; una matrice sito–giorno mostra la percentuale di ore anomale rispetto alle ore valide di quel sito e giorno. Queste quote aggregano le decisioni puntuali senza stimare una nuova soglia regionale. I periodi senza osservazioni non vengono convertiti in normalità.

5.3.2 Frequenze geografiche e confronto dei budget di anomalia

Le mappe di frequenza associano a ciascun sito la quota di ore anomale sulle ore con score valido. La copertura è distinta da questa quota e rapporta le ore effettivamente valutate a quelle ammissibili. Un sito privo di score non viene rappresentato come privo di anomalie. Nel confronto diurno, il filtro POA maggiore di $10\,\mathrm{W\,m^{-2}}$ viene applicato dopo le decisioni del detector: il ranking STGAN non viene ricalcolato sulle sole ore diurne.

Per MTGFlow, il protocollo di base conserva le soglie per sito stimate dalle statistiche di training. Una variante esplorativa assegna invece un budget globale di anomalie ordinando la coordinata firmata

$$c_{nt} = \frac{s_{nt} - \theta_n}{\mathrm{IQR}_{n,\mathrm{train}}}, \tag{5.1}$$

dove s_{nt} è lo score e θ_n la soglia salvata del sito. Non viene applicato un troncamento a zero: anche i valori sotto soglia mantengono il proprio ordinamento. La selezione usa un numero esatto di osservazioni determinato dalla percentuale richiesta, prima dell'eventuale filtro diurno. Questa variante deve essere distinta sia dalle decisioni native MTGFlow sia dalla coordinata centrata in Q_3 usata nell'analisi di sensibilità.

5.3.3 Sottogruppi meteorologici e direzione degli estremi

Le anomalie STGAN possono essere ulteriormente suddivise intersecando la decisione del detector con flag climatologici delle variabili meteorologiche, alla stessa località e al timestamp target. Per temperatura e vento vengono distinti i lati alto e basso confrontando il valore con le bande climatologiche della relativa osservazione; per l'irradianza viene verificata anche la variabile associata al flag. Il criterio non confonde quindi un estremo della produzione con un estremo dell'irradianza.

I sottogruppi possono sovrapporsi. Una stessa osservazione può soddisfare più condizioni meteorologiche, mentre un'anomalia non associata ad alcuna

condizione rimane anomala e viene conteggiata separatamente. I normali conservano la decisione STGAN e non vengono ridefiniti come complemento di ciascuna categoria. Le statistiche per categoria non costituiscono pertanto una partizione disgiunta di tutte le osservazioni.

L'analisi degli errori tipizzati considera i target diurni con POA maggiore di $10\,\mathrm{W\,m^{-2}}$. Per le fasce di produzione utilizza un riferimento condiviso fra orizzonti: il percentile 99 della produzione positiva diurna, contando una sola volta ciascuna coppia località–timestamp target, e intervalli di ampiezza 20 punti percentuali. Oltre agli errori aggregati, calcola il RMSE per località e ne riassume mediana e quartili. La banda fra siti descrive l'eterogeneità geografica del RMSE; è distinta dai quartili degli errori assoluti individuali e dagli intervalli di confidenza di una metrica.

5.3.4 Campioni normali e anomali: quattro casi input–target

Oltre al raggruppamento secondo l'etichetta del target, l'analisi considera quattro casi: input normale e target normale, input normale e target anomalo, input anomalo e target normale, input anomalo e target anomalo. La normalità del target riguarda l'osservazione futura classificata dal detector, non una classificazione della previsione numerica del modello.

Con una sequenza di 24 ore e ultimo input al tempo t, la finestra considerata è $[t - 23\,\mathrm{h}, t]$, estremi inclusi. Nel criterio predefinito, almeno un timestamp anomalo rende anomala la finestra. Sono considerate tutte le ore disponibili, anche notturne, della stessa località del target.

La classificazione descrive la sequenza esplicita del sito centrale: non comprende automaticamente le altre località del grafo né le ore aggiuntive necessarie alle feature derivate. Le finestre incomplete e i target privi di score sono esclusi con conteggi separati. Il numero di righe indica previsioni località–timestamp per orizzonte, non giorni statisticamente indipendenti.

5.3.5 MAE, RMSE, bande di dispersione e metriche degli intervalli

Per un gruppo di n previsioni, le metriche puntuali sono

$$\mathrm{MAE} = \frac{1}{n}\sum_{i=1}^{n} |y_i - \hat{y}_i|, \qquad \mathrm{RMSE} = \sqrt{\frac{1}{n}\sum_{i=1}^{n}(y_i - \hat{y}_i)^2}. \tag{5.2}$$

Le aggregazioni per orizzonte, fascia di produzione, etichetta o caso input–target utilizzano i campioni appartenenti al gruppo. Il RMSE complessivo non viene ottenuto mediando i RMSE dei giorni o dei sottogruppi.

Nell'analisi di sensibilità MTGFlow, gli anomali soddisfano la soglia per sito $Q_3 + k\,\mathrm{IQR}$, usando le statistiche di riferimento del training. Per STGAN si varia la percentuale del ranking globale. A ogni soglia vengono ricalcolati i gruppi e i rispettivi MAE e RMSE: l'asse orizzontale descrive la soglia, non il tempo.

Le curve MAE sono accompagnate da due fasce degli errori assoluti: una fascia più scura fra primo e terzo quartile e una più chiara fra i baffi di Tukey. I baffi corrispondono agli estremi osservati entro $Q_1 - 1.5\,\mathrm{IQR}$ e $Q_3 + 1.5\,\mathrm{IQR}$; non comprendono necessariamente tutto l'intervallo dei valori. Gli outlier continuano a contribuire al MAE.

Queste fasce descrivono la dispersione degli errori individuali. Non sono intervalli di confidenza del MAE e non sono intervalli predittivi della rete. La stessa distinzione vale per i boxplot degli errori assoluti nei quattro casi; il RMSE è rappresentato come metrica aggregata. La sovrapposizione delle fasce non costituisce un test di significatività.

La valutazione probabilistica considera separatamente copertura e ampiezza degli intervalli predittivi del previsore. Il confronto fra STGAN su grafo e variante ConvGRU sulle coordinate comuni riporta inoltre concordanze, discordanze e Jaccard delle anomalie, distinguendo patch complete e incomplete. L'accordo fra detector non equivale ad accuratezza rispetto a una verità di riferimento indipendente.

Capitolo 6

Risultati e discussione

6.1 Accuratezza del forecasting

6.1.1 Backbone BiLSTM–GAT e ablazione della GAT

6.1.2 Enhanced Monte Carlo Dropout

6.1.3 Deep Ensemble

6.1.4 SDE-Net true-minimal

6.1.5 SDE-Net paper-faithful e previsione diretta multiorizzonte

6.2 Quantificazione dell'incertezza

6.2.1 Intervalli dell'Enhanced Monte Carlo Dropout

6.2.2 Intervalli e disaccordo tra membri del Deep Ensemble

6.2.3 Intervalli delle due varianti SDE-Net

6.3 Rilevamento delle anomalie con MTG-Flow, STGAN e ConvGRU

6.3.1 Score e distribuzione spazio-temporale delle anomalie

6.3.2 Soglie IQR, top-K e confronto fra grafo e griglia

6.3.3 Ablazione dei kernel convoluzionali

6.4 Analisi post-hoc forecasting–anomalie

6.4.1 MAE e RMSE sui campioni normali e anomali

6.4.2 Confronto a una e sei ore e quattro casi input–target

6.4.3 Errore in funzione della soglia e bande di dispersione

6.4.4 Errori per tipo e direzione dell'estremo meteorologico

6.5 Anomalie ed eventi geografici su ERA5

6.5.1 Copertura dei dati e configurazione del detector

6.5.2 Score Monte Carlo e dispersione

6.5.3 Monitoraggio per epoca e selezione delle configurazioni

6.5.4 Confronto fra generatore ConvGRU e GAT e fra unità di training

6.5.5 Cluster spaziali, traiettorie e sensibilità del post-processing

6.6 Confronto progressivo degli esperimenti

6.6.1 Accuratezza puntuale

6.6.2 Copertura e ampiezza degli intervalli

6.6.3 Costo computazionale e complessità dei modelli

Capitolo 7

Conclusioni e sviluppi futuri

7.1 Il problema affrontato

7.2 Sintesi dei risultati

7.3 Limiti dello studio

7.4 Sviluppi futuri

Bibliografia

[1] Xingjian Wu et al. «CATCH: Channel-Aware Multivariate Time Series Anomaly Detection via Frequency Patching». In: *International Conference on Learning Representations*. 2025.

[2] Sarah Alnegheimish et al. «M2AD: Multi-Sensor Multi-System Anomaly Detection through Global Scoring and Calibrated Thresholding». In: *Proceedings of the 28th International Conference on Artificial Intelligence and Statistics*. Vol. 258. Proceedings of Machine Learning Research. 2025.

[3] Qihang Zhou et al. «Label-Free Multivariate Time Series Anomaly Detection». In: *IEEE Transactions on Knowledge and Data Engineering* 36.7 (2024), pp. 3166–3179. DOI: 10.1109/TKDE.2024.3349613. arXiv: 2312.11549.

[4] Ian J. Goodfellow et al. «Generative Adversarial Nets». In: *Advances in Neural Information Processing Systems*. Vol. 27. Curran Associates, Inc., 2014. arXiv: 1406.2661.

[5] Leyan Deng et al. «Graph Convolutional Adversarial Networks for Spatiotemporal Anomaly Detection». In: *IEEE Transactions on Neural Networks and Learning Systems* 33.6 (2022), pp. 2416–2428. DOI: 10.1109/TNNLS.2021.3136171.

[6] Kyunghyun Cho et al. «Learning Phrase Representations using RNN Encoder-Decoder for Statistical Machine Translation». In: *Conference on Empirical Methods in Natural Language Processing (EMNLP)*. 2014. arXiv: 1406.1078.

[7] Xingjian Shi et al. «Convolutional LSTM Network: A Machine Learning Approach for Precipitation Nowcasting». In: *Advances in Neural Information Processing Systems*. Vol. 28. Curran Associates, Inc., 2015. arXiv: 1506.04214.

[8] Nicolas Ballas et al. «Delving Deeper into Convolutional Networks for Learning Video Representations». In: *International Conference on Learning Representations (ICLR)*. 2016. arXiv: 1511.06432.

[9] Petar Veličković et al. «Graph Attention Networks». In: *International Conference on Learning Representations (ICLR)*. 2018. arXiv: 1710.10903.

[10] Yarin Gal e Zoubin Ghahramani. «Dropout as a Bayesian Approximation: Representing Model Uncertainty in Deep Learning». In: *International Conference on Machine Learning (ICML)*. 2016. arXiv: 1506.02142.

[11] Balaji Lakshminarayanan, Alexander Pritzel e Charles Blundell. «Simple and Scalable Predictive Uncertainty Estimation using Deep Ensembles». In: *Advances in Neural Information Processing Systems (NIPS)*. 2017. arXiv: 1612.01474.

[12] Ricky T. Q. Chen et al. «Neural Ordinary Differential Equations». In: *Advances in Neural Information Processing Systems*. Vol. 31. Curran Associates, Inc., 2018. arXiv: 1806.07366.

[13] Lingkai Kong, Jimeng Sun e Chao Zhang. «SDE-Net: Equipping Deep Neural Networks with Uncertainty Estimates». In: *Proceedings of the 37th International Conference on Machine Learning*. Vol. 119. Proceedings of Machine Learning Research. 2020. arXiv: 2008.10546.

[14] Simone Monaco et al. «Uncertainty-aware methods for enhancing rainfall prediction with deep-learning based post-processing segmentation». In: *Computers & Geosciences* 205 (2025), p. 105992. DOI: 10.1016/j.cageo.2025.105992.