

Politecnico di Torino

Politecnico di Torino

Laurea Magistrale in Ingegneria Informatica – Ingegneria del software

A.A. 2025/2026

Sessione di laurea Novembre/Dicembre 2026

Rilevamento unsupervised di anomalie meteorologiche con reti generative avversarie spazio-temporali

Relatore:
Simone Monaco

Candidato:
Alberto Pedalino

Indice

Elenco delle figure **iv**

1 Introduzione **1**
1.1 Contesto e motivazioni 1
1.2 Il problema: anomalie meteorologiche senza etichette 1
1.3 Approccio proposto 2
1.4 Obiettivi e contributi della tesi 3
1.5 Organizzazione del documento 3

2 Fondamenti teorici e stato dell'arte **5**
2.1 Rilevamento di anomalie in serie multivariate e spazio-temporali 5
2.1.1 Dalla deviazione dal valore atteso ai modelli profondi . 6
2.1.2 Relazioni fra le serie e dati di addestramento contaminati 7
2.1.3 Reti generative avversarie per il rilevamento di anomalie 9
2.1.4 STGAN 10
2.1.5 Il problema della valutazione 12
2.2 Apprendimento automatico e dati meteorologici 13
2.2.1 Dalla previsione numerica ai modelli basati sui dati . . 13
2.2.2 Eventi estremi e anomalie nei campi meteorologici . . . 14
2.3 Contesto spaziale su griglie e grafi 15
2.4 Quantificazione dell'incertezza 17
2.5 Da STGAN al detector della tesi 18
2.6 Posizionamento del lavoro 19

3 Dati e preprocessing **21**
3.1 Campi ERA5 e dominio 21
3.2 Acquisizione e preparazione dei dati 24
3.3 Anni di addestramento, di validazione e di test 25
3.4 Caratteristiche dei campi 26
3.5 Qualità e limiti dei dati 29
3.6 I dati PVGIS del lavoro preliminare 30

4 Metodologia **33**
4.1 Formulazione del problema 33
4.2 Architettura e addestramento avversario 34
4.2.1 Generatore ConvGRU sul campo intero 34
4.2.2 Discriminatore locale 36
4.2.3 Obiettivi di addestramento 37
4.3 Ingresso: finestra recente, codifica temporale e normalizzazione stagionale 38
4.3.1 Finestra recente e trend 38
4.3.2 Codifica temporale ciclica 38
4.3.3 Normalizzazione stagionale 38
4.4 Pesi delle variabili nell'errore di ricostruzione 40
4.5 Valori esclusi negli anni di validazione 41
4.6 Componenti dello score e dropout Monte Carlo 42
4.6.1 Dropout nel generatore e nel discriminatore 42
4.6.2 Estrazioni Monte Carlo e componenti dello score 42
4.6.3 Score combinato e score di ricostruzione 43
4.7 Normalizzazione climatologica degli score 44
4.8 Validazione senza etichette 45
4.8.1 Distanza fra campi osservati e ricostruiti nello spazio delle componenti principali 45
4.8.2 Diagnostiche per epoca e misure finali 47

5 Esperimenti **48**
5.1 Configurazione e ricerca degli iperparametri 48
5.2 Protocollo di valutazione 50

6 Risultati e discussione **52**
6.1 Ricerca degli iperparametri 52
6.2 G e D: un legame debole 54
6.3 La normalizzazione climatologica 56
6.4 Che cosa giudica il discriminatore 58
6.5 Conferma sul test e scelta dello score 64
6.6 Confronto con le baseline 66
6.7 Cluster di segnalazioni per tipo e dimensione 71
6.7.1 Un cluster per tipo 79
6.8 La dispersione del dropout 83
6.9 Anomalie meteorologiche note 90
6.10 Sensibilità alla soglia 90

7 Conclusioni e sviluppi futuri **93**
7.1 Il problema affrontato 93
7.2 Sintesi dei risultati 93
7.3 Sviluppi futuri 93

Bibliografia **95**

Elenco delle figure

2.1 Schema di STGAN. Il generatore combina tre rami e produce la stima $\hat{X}_{v,t} = G_\theta(v, t)$, che sostituisce l'ultimo elemento della sequenza reale; il discriminatore valuta entrambe le sequenze. Lo score somma l'errore di previsione e la differenza fra le due uscite del discriminatore. Ridisegnato a partire da Deng et al. [3]. 11

3.1 Dominio dei campi ERA5: 81×131 celle di 0.5°, fra 20° e 60° di latitudine nord e fra 15° di longitudine ovest e 50° di longitudine est. Il rettangolo indica l'area delle località PVGIS della Sezione 3.6, in Piemonte. Linee di costa da Natural Earth. 23

3.2 Dai file di ERA5 ai dati letti dal modello. I campi sono scaricati mese per mese dal Climate Data Store e conservati solo se superano la verifica; la preparazione li riunisce in array su disco, da cui il modello legge le sole finestre che usa. 24

3.3 Ciclo stagionale e giornaliero della temperatura a due metri e della copertura nuvolosa in tre celle: Europa settentrionale (55°N, 10°E), Pianura Padana (45°N, 9°E) e Sahara (25°N, 10°E). A sinistra la media per mese, con le linee punteggiate a una deviazione standard dei valori triorari del mese; a destra la media per ora UTC in gennaio e in luglio. La temperatura è in gradi Celsius (in kelvin nei dati). Lo stesso mese ha livelli e variabilità diversi da una cella all'altra. Anni 1980–1999. . . 27

3.4 Quota di ciascuna variabile nella variazione quadratica media su 24 ore (equazione (3.1)), dopo il min–max di STGAN e dopo la normalizzazione stagionale e il min–max del detector, in scala logaritmica. Anni 1980–1999; la seconda quota è ricavata dai pesi della Sezione 4.4, che sono proporzionali all'inverso di m_f. La linea tratteggiata indica la quota uguale per tutte le variabili, un quindicesimo. Con il min–max di STGAN la copertura nuvolosa domina; dopo la normalizzazione stagionale le quote sono dello stesso ordine. 28

3.5 Correlazione degli scarti dalla media climatologica di due celle in funzione della loro distanza: mediana e quartili per fasce di 100 km, su 300 celle scelte a caso e un istante ogni nove degli anni 1980–1999 (un passo dispari, che legge tutte le ore del giorno). Il primo punto, entro 100 km, si basa su 36 coppie di celle. Precipitazione e copertura nuvolosa perdono la correlazione entro poche celle. 29
3.6 Le 1149 località dei dati PVGIS. Ogni punto è una posizione del reticolo con passo di 5 km per la quale sono disponibili le serie orarie. 31

4.1 Ordine dei passaggi del detector su un istante, dai campi ERA5 alla segnalazione. In corsivo, gli anni su cui è stimata ciascuna quantità: le scale della normalizzazione stagionale e i pesi sugli anni di addestramento, la climatologia dello score e la soglia sugli anni di validazione. 34
4.2 Struttura del generatore (a) e del discriminatore (b). Il generatore unisce cella per cella i tre rami, recente, trend e calendario, e produce il campo stimato dell'istante. Il discriminatore giudica ogni cella sulla propria patch, a partire dalla storia recente e dal campo corrente, osservato o generato. I riquadri tratteggiati indicano i dropout, con probabilità 0.2 (Sezione 4.6). 35

6.1 Le prove della ricerca degli iperparametri nel piano delle prime due componenti principali dei quattro iperparametri (71% della varianza). Il colore è la distanza MMD sulla validazione, più scuro dove è più bassa; i cerchi arancioni indicano le tre prove della regione migliore. Nel riquadro, la direzione in cui cresce ciascun iperparametro: lr G e lr D sono i tassi di apprendimento del generatore e del discriminatore, peso λ il peso della ricostruzione, agg. D:G gli aggiornamenti del discriminatore e del generatore per batch. Le prove non si avvicinano via via alla regione migliore: una volta stimata, la ricerca esplora le zone meno note. 53
6.2 Correlazione spaziale fra G e D in ogni istante degli anni di validazione, calcolata sulle 10611 celle: media giornaliera (linea sottile) e media mobile su 30 giorni (linea spessa). La correlazione di Spearman (in blu) oscilla attorno a zero con la stagione; quella di Pearson (in arancione) è negativa in circa due giorni su tre, soprattutto in estate. 56

6.3 Correlazione temporale di Spearman fra G e D in ogni cella, sugli anni di validazione. Il blu indica che D scende quando G sale, il rosso che i due salgono insieme; la scala va da -0.3 a 0.3, e la freccia indica che alcune celle superano 0.3. La correlazione è vicina a zero quasi ovunque: è negativa in due celle su tre, soprattutto a sud, e positiva in molte celle fra 35° e 50°N. La cornice rossa lungo il bordo è probabilmente un effetto del modello. Linee di costa da Natural Earth. 57

6.4 Quota dei valori segnalati, per fascia di latitudine e mese, sugli anni di validazione: G senza (in alto) e con (in basso) la normalizzazione climatologica, calcolata per cella, giorno dell'anno, con una finestra di ± 15 giorni, e ora. La soglia di ciascuno score è il suo 95-esimo percentile sugli stessi anni. La scala dei colori non è lineare: il bianco corrisponde al 5%, il blu a quote minori, il rosso a quote maggiori. Senza normalizzazione le segnalazioni si concentrano a sud e in estate, con la normalizzazione sono distribuite in modo quasi uniforme. 59

6.5 Correlazione temporale di Spearman, in ogni cella, fra G e il giudizio del discriminatore sull'osservazione, D_{reale} (a sinistra), e sulla ricostruzione, D_{generato} (a destra), sugli anni di validazione, su una scala da -1 a 1. Tutte le celle sono blu, con valori intorno a -0.7: in ogni luogo entrambi i giudizi scendono quando G sale. Linee di costa da Natural Earth. 60

6.6 Le tre zone attorno a un cluster, in un istante, su una porzione della griglia: il nucleo, il contorno e la zona lontana; le celle intermedie non rientrano in nessuna. Ogni quadrato è una cella. 61

6.7 Percentile mediano di G senza normalizzazione, di D_{reale}, di D_{generato} e di D nel nucleo dei cluster di G_{n}, nel loro contorno e lontano da essi, sugli anni di validazione. La linea tratteggiata indica 50, il valore atteso senza legame con i cluster. G, alto nel nucleo quasi per costruzione, serve da riferimento. Nel nucleo D_{reale} e D_{generato} sono entrambi molto bassi, e D, la loro differenza, è al percentile 27. 62

6.8 G, D_{reale}, D_{generato} e D il 9 agosto 2003 alle 12 UTC, l'istante con la media di G più alta degli anni di validazione. La linea arancione racchiude l'1% delle celle con G più alto nell'istante; ogni mappa ha una propria scala, dal primo al 99-esimo percentile dei suoi valori. Dentro la linea D_{reale}, D_{generato} e D sono fra i valori più bassi (colori scuri): osservazione e ricostruzione sono giudicate reali, e D è basso. Linee di costa da Natural Earth. 63

6.9 Indice di Jaccard delle segnalazioni di ogni coppia di rilevatori sugli anni di test, in percentuale, con la soglia di ciascuno al 95-esimo percentile del proprio score sulla validazione. I metodi che leggono il punto formano un gruppo, la variazione in tre ore resta da parte, e G_n si sovrappone a entrambi. 69
6.10 I cluster di G_n sugli anni di test, per numero di valori: quota dei cluster (a sinistra) e quota dei valori segnalati che contengono (a destra). I cluster sono quasi tutti piccoli, ma circa tre quarti dei valori stanno in pochi cluster enormi. 72
6.11 Valori segnalati sugli anni di test, per tipo di cluster e numero di valori del cluster: nei cluster di G_n (in alto a sinistra, bordato) e in quelli di ciascuna baseline, ognuno formato dalle proprie segnalazioni. Più il colore è scuro, più i valori sono numerosi; la scala è logaritmica e comune a tutti i pannelli. Le caselle grigie non contengono cluster; i tipi sono nell'ordine di G_n. In G_n e nella variazione in tre ore dominano velocità verticale e precipitazione, nella distanza dal normale e in CBLOF l'umidità del suolo. 74
6.12 G con la normalizzazione (a sinistra) e le sue zone (a destra) il 23 novembre 2017 alle 00 UTC. Il nucleo è fatto delle celle sopra la soglia, il contorno delle otto celle attorno, la zona lontana delle celle a più di tre celle da ogni nucleo; le celle intermedie stanno fra le ultime due. È l'istante dell'esempio di velocità verticale della Sezione 6.7.1. Linee di costa da Natural Earth. 75
6.13 Profilo attraverso i cluster, sugli anni di test, con la soglia di ciascun metodo al 95-esimo percentile del proprio score sulla validazione: percentile mediano dello score secondo le celle di distanza dal bordo del cluster più vicino, per G_n e per ciascuna baseline, ognuna sui propri cluster. I sei modelli shallow sono in grigio. Che le celle dentro stiano sopra la soglia e quelle fuori sotto è per costruzione. Tutti i metodi tornano verso un valore tipico dopo circa sei celle; G_n cala più gradualmente di quasi tutte le baseline. Per G_n è riportato anche il punto a 8 o più celle dal bordo. La linea viola tratteggiata è la distanza dal normale letta sui cluster di G_n invece che sui propri. . . . 76

6.14 Per ogni tipo di cluster, scarto mediano della variabile che dà il nome al tipo, secondo le celle di distanza dal bordo del cluster, sugli anni di test: 0 è il valore normale, 1 uno scostamento pari alla variabilità abituale. Il punto finale raccoglie tutte le celle a 8 o più celle dal bordo. Sono colorati i tre tipi con più valori nei cluster di almeno 20 valori (velocità verticale, precipitazione e copertura nuvolosa) e la temperatura a 2 m, citata nel testo; gli altri tipi sono in grigio, e le curve usano tutti i cluster del tipo. Non sono tracciati i punti calcolati su meno di 1000 valori, e l'asse è limitato a 3.5. Precipitazione e copertura nuvolosa tornano presto vicine ai valori di fondo, la velocità verticale un po' più lentamente; la temperatura resta lontana dal normale anche a molte celle. 78
6.15 Velocità verticale, 23 novembre 2017 alle 00 UTC. Il nucleo è una fascia stretta in cui la velocità verticale è per lo più sotto il normale; nella cella seguita G_{n} resta oltre la soglia, salvo una breve pausa, per circa un giorno e mezzo, e la distanza dal normale sale e scende insieme a G_{n}; il cluster dura 63 ore, dal 21 al 24 novembre 2017, con il massimo nell'istante delle mappe. Linee di costa da Natural Earth. 81
6.16 Precipitazione, 19 maggio 2006 alle 03 UTC. Il nucleo è diviso in più parti, in cui la precipitazione è quasi ovunque sopra il normale; nella cella seguita la distanza dal normale è alta già nei giorni prima, e G_{n} supera la soglia solo quando arriva la precipitazione; il cluster dura 72 ore, dal 16 al 19 maggio 2006, e finisce poche ore dopo il massimo. Linee di costa da Natural Earth. 82
6.17 Copertura nuvolosa, 15 giugno 2024 alle 12 UTC. Il nucleo è una fascia stretta sull'Africa nord-occidentale in cui la copertura nuvolosa è quasi ovunque sopra il normale; nella cella seguita G_{n} e la distanza dal normale salgono e scendono insieme, e G_{n} resta oltre la soglia per dodici ore; il cluster dura 66 ore, dal 14 al 17 giugno 2024. Linee di costa da Natural Earth. 84

6.18 Il rapporto fra la dispersione del dropout e l'errore del generatore, sugli anni di test, con la soglia di G_{n} al 95-esimo percentile. A sinistra: per percentile dell'errore su tutti i valori. Al centro: secondo le celle di distanza dal bordo del cluster; l'asse non parte da zero. A destra: i valori segnalati, divisi a parità di errore in cinque classi uguali per rapporto, da quella con le estrazioni più concordi a quella con le più discordi; per ogni classe, la quota oltre la soglia della distanza dal normale. Il rapporto è quasi costante e scende solo nell'1% più alto degli errori; a parità di errore, la quota oltre la soglia sale dalla classe 1 alla 4 e cala nella 5. 86
6.19 Il dropout per tipo di cluster, sugli anni di test. A sinistra: rapporto fra dispersione ed errore secondo le celle di distanza dal bordo, con evidenziati, nella legenda, i tre tipi con più valori nei cluster di almeno 20 valori; gli altri tipi sono in grigio, e non sono tracciati i punti calcolati su meno di 1000 valori né quelli a 8 o più celle dal bordo. A destra: a parità di errore, quota dei valori oltre la soglia della distanza dal normale nella classe 1, con le estrazioni più concordi, nella classe 4 e nella classe 5, con le più discordi; i tipi sono ordinati per la classe 4, e dove le classi 4 e 5 coincidono il segno della classe 5 nasconde quello della 4. Il rapporto è più basso poco dentro il bordo in quasi tutti i tipi; la classe 1 ha sempre la quota più bassa, la 5 quasi mai la più alta. 88
6.20 La deviazione standard delle estrazioni di dropout cella per cella. In alto: la sua media sugli anni di test e il rapporto medio con l'errore; lungo il bordo del dominio si vede la cornice descritta nel testo. In basso: la deviazione standard negli istanti dei tre esempi della Sezione 6.7.1 (23 novembre 2017, 19 maggio 2006 e 15 giugno 2024), con una scala comune ai tre e il nucleo del cluster racchiuso dalla linea arancione. Linee di costa da Natural Earth. 89

Capitolo 1

Introduzione

1.1 Contesto e motivazioni

Le anomalie meteorologiche, cioè condizioni dell'atmosfera lontane da quelle abituali, come una perturbazione intensa, un fronte che attraversa una regione o un'ondata di caldo, sono i casi in cui i modelli addestrati su dati storici sbagliano di più e in cui servono informazioni aggiuntive. Il lavoro è nato in questo contesto, nell'ambito della previsione della produzione fotovoltaica [1], dove un previsore è affidabile nelle condizioni che i dati di addestramento rappresentano bene e meno in quelle poco frequenti. Riconoscerle è però un problema a sé, distinto dalla previsione: richiede di stabilire, per ogni luogo e ogni istante, quanto le condizioni osservate si discostano da quelle abituali. È il compito del rilevamento di anomalie, a cui questa tesi è dedicata.

I campi meteorologici delle rianalisi, come ERA5 [2], descrivono lo stato dell'atmosfera su una griglia regolare, con molte variabili e per diversi decenni. Sono quindi una base adatta per cercare anomalie in modo sistematico, su un dominio ampio e senza limitarsi alle grandezze di un singolo impiego.

1.2 Il problema: anomalie meteorologiche senza etichette

Tre caratteristiche dei dati rendono il problema difficile e guidano le scelte dei capitoli successivi.

La prima è l'assenza di etichette. Non esiste un elenco completo di anomalie meteorologiche con cui addestrare un classificatore o misurare direttamente l'accuratezza di un detector. Il rilevamento deve essere unsupervised e la sua valutazione deve ricorrere a strumenti indiretti.

La seconda è che i dati di addestramento non sono garantiti privi di anomalie. Molti detector apprendono il comportamento normale da un insieme che si assume pulito; con dati meteorologici non etichettati questa ipotesi non è verificabile. Ne segue una scelta di obiettivo: rilevare le condizioni nuove rispetto al periodo di addestramento, trattando come già osservate quelle che il modello ha incontrato durante l'addestramento.

La terza è la struttura spaziale. Le condizioni di un luogo dipendono da quelle dei luoghi vicini, e un valore insolito in un punto può essere ordinario se considerato nel suo intorno. I campi non hanno però una topologia fisica, come una rete stradale: sono disposti su un reticolo regolare, e il modo di rappresentare l'intorno va scelto.

Il termine anomalia meteorologica indica in questa tesi una condizione dell'atmosfera che si discosta da quella abituale per il luogo e il periodo dell'anno. Il detector non la osserva direttamente: uno score misura quanto un'osservazione si discosta da ciò che il modello ha appreso dal periodo di addestramento, e sono segnalate le osservazioni con lo score più alto. Una segnalazione indica quindi una possibile anomalia meteorologica, non un'anomalia accertata. Un evento meteorologico estremo è un caso particolare di anomalia meteorologica, ma non ogni anomalia è un evento estremo.

1.3 Approccio proposto

Il detector parte da STGAN [3], una rete avversaria proposta per il rilevamento di anomalie nel traffico: un generatore stima i valori dell'istante successivo a partire dal contesto spaziale e temporale, un discriminatore giudica se una sequenza è osservata o generata, e uno score, cioè un numero che dice quanto un'osservazione è insolita, combina i due. In questa tesi lo schema è adattato e trasformato per i campi ERA5, con quindici variabili in superficie e a 850 hPa, ogni tre ore, su un dominio che comprende l'Europa, il Mediterraneo e il Nord Africa. Le modifiche principali sono quattro:

1. un generatore che opera sul campo intero con un'unità ricorrente convoluzionale, mentre il discriminatore resta locale;

2. un ingresso riferito al clima di ogni cella, con una normalizzazione stagionale e pesi che misurano l'errore di ogni variabile in rapporto a quanto essa cambia abitualmente;

3. uno score riferito alla climatologia di ogni cella e il dropout Monte Carlo nelle due reti, che associa a ogni score una misura di dispersione;

4. una validazione senza etichette, in cui i valori più insoliti sono esclusi dalle misure con cui si scelgono i parametri dell'addestramento avversario, senza usare gli anni di test.

1.4 Obiettivi e contributi della tesi

L'obiettivo della tesi è rilevare anomalie meteorologiche in campi privi di etichette e dotati di struttura spaziale, e studiare, senza riferimenti esterni, come si comportano le parti dello score e quale usare. La tesi non propone un nuovo algoritmo di rilevamento: adatta e combina componenti esistenti. I contributi sono i seguenti.

- L'adattamento di STGAN a campi meteorologici privi di topologia fisica, con un generatore sul campo intero che rappresenta l'intorno di una cella con una convoluzione su griglia, e la definizione dell'obiettivo come rilevamento di condizioni nuove rispetto al periodo di addestramento.
- Uno score Monte Carlo, con il dropout nel generatore e nel discriminatore.
- Un protocollo di addestramento e di scelta della configurazione che non usa etichette né anni di test: una validazione da cui i valori più insoliti sono esclusi con un criterio indipendente dal modello, e una misura della distanza fra campi osservati e ricostruiti.
- Una valutazione senza etichette: lo studio delle componenti dello score nello spazio e nel tempo; il confronto, a parità di segnalazioni, con otto baseline (due rilevatori che non usano un modello e sei modelli shallow); il raggruppamento delle segnalazioni in cluster, cioè insiemi di valori segnalati vicini nello spazio e nel tempo; la dispersione del dropout e la dipendenza dalla soglia.

Il risultato principale è che l'errore del generatore e il giudizio del discriminatore non concordano: dove il primo segnala un valore insolito, il secondo in genere non lo segnala. Sommarli rende lo score difficile da interpretare: la tesi usa quindi il solo errore del generatore, il cui significato è chiaro.

1.5 Organizzazione del documento

Il Capitolo 2 presenta i fondamenti teorici e i lavori su cui la tesi è costruita, per temi e in ordine cronologico all'interno di ciascun tema; si chiude con il

modo in cui la tesi adatta STGAN e con la sua posizione rispetto ai lavori esaminati. Il Capitolo 3 descrive i campi ERA5 e la loro preparazione, e i dati PVGIS da cui il lavoro è partito. Il Capitolo 4 presenta il detector nella forma finale. Il Capitolo 5 descrive come il detector è addestrato e valutato: la configurazione e la ricerca degli iperparametri, e il protocollo di valutazione. Il Capitolo 6 studia le componenti dello score e sceglie quella da usare, confronta le segnalazioni con otto baseline più semplici, le raggruppa in cluster di valori segnalati vicini ed esamina la dispersione del dropout e la dipendenza dalla soglia. Il Capitolo 7 riassume il lavoro e ne indica gli sviluppi futuri.

Capitolo 2

Fondamenti teorici e stato dell'arte

Il capitolo presenta i fondamenti teorici e i lavori su cui la tesi è costruita. Ogni tema è trattato come un percorso: dai lavori che ne hanno definito il problema a quelli più recenti, fino al metodo che la tesi riprende. Per ciascun lavoro sono indicati ciò che propone, ciò che ottiene e il limite che lascia aperto, che spesso è il punto da cui parte il lavoro successivo; i lavori su cui il *detector* si basa direttamente sono descritti più a fondo, con le relative formule. I temi sono quattro: il rilevamento di anomalie in serie temporali, l'apprendimento automatico applicato ai dati meteorologici, il contesto spaziale su griglie e grafi, la quantificazione dell'incertezza. Una sezione descrive poi il modo in cui la tesi adatta STGAN, e l'ultima riassume la posizione della tesi rispetto ai lavori esaminati. Il percorso del capitolo segue quello del lavoro: partito da dati fotovoltaici PVGIS (Sezione 3.6) con il detector MTGFlow, è passato a STGAN sui campi ERA5 per rappresentare il contesto spaziale fra luoghi diversi.

2.1 Rilevamento di anomalie in serie multivariate e spazio-temporali

Questa sezione va dalle definizioni di anomalia ai metodi basati su reti profonde, e arriva a STGAN, la base del detector. Lungo il percorso due criteri guidano la scelta del detector: la tolleranza alla presenza di anomalie nei dati di addestramento, che senza etichette non si possono escludere, e la rappresentazione del contesto spaziale fra luoghi diversi. La sezione si chiude con il problema della valutazione e con i metodi semplici usati come confronto.

2.1.1 Dalla deviazione dal valore atteso ai modelli profondi

Nella rassegna di Gupta et al. [4] sui dati temporali, un'anomalia è definita in generale come uno scostamento dal valore atteso o previsto. Per i dati spazio-temporali la rassegna riprende una definizione più specifica: un'osservazione è anomala quando le sue grandezze differiscono in modo significativo da quelle degli oggetti vicini nello spazio e nel tempo. I metodi che la rassegna raccoglie per questi dati procedono per lo più in due passi, prima cercando le anomalie spaziali e poi verificandole rispetto ai vicini temporali, con intorni fissati a mano; fra le applicazioni figurano anche dati ambientali e meteorologici, come serie di precipitazione e campi di rianalisi. I metodi esaminati precedono l'uso diffuso delle reti profonde e trattano grandezze scalari o singoli oggetti, non campi multivariati considerati insieme.

La rassegna di Zamanzadeh Darban et al. [5] raccoglie i metodi profondi per serie temporali e li divide secondo il segnale da cui ricavano lo *score*: la *previsione* del valore successivo, la *ricostruzione* dell'osservazione, una rappresentazione appresa, oppure una combinazione delle prime due. Distinzioni analoghe compaiono nei lavori più recenti esaminati più avanti [6, 7]. Le reti generative avversarie vi figurano fra i metodi a ricostruzione; gli autori ne indicano come limite l'addestramento, che richiede di bilanciare generatore e discriminatore ed è instabile e difficile da far convergere. Nella rassegna il termine spaziale indica le dipendenze fra le variabili di una serie, non fra luoghi geografici; fra i dataset raccolti non compaiono campi meteorologici su griglia, e i lavori su dati geografici, come STGAN, sono citati soltanto fra le applicazioni urbane e al traffico.

Due lavori mostrano i due segnali principali e il loro limite comune, cioè l'assenza di relazioni fra le serie. Malhotra et al. [8] propongono un *encoder–decoder* basato su LSTM, addestrato a ricostruire finestre di serie normali: una finestra anomala, che il modello non ha imparato a ricostruire, produce un errore più alto, e lo score è la distanza di Mahalanobis del vettore degli errori dalla loro distribuzione sui dati normali. La soglia di decisione è però scelta massimizzando un indice di accuratezza su sequenze anomale etichettate, e negli esperimenti con più sensori le serie sono ridotte alla prima componente principale: il metodo, quindi, non è interamente unsupervised e non modella più variabili insieme. Hundman et al. [9] seguono la via della previsione per la telemetria di veicoli spaziali: una LSTM per canale prevede il valore successivo, e gli errori, smussati, sono confrontati con una soglia scelta senza etichette, che separa i valori più alti dal resto della distribuzione degli errori. Sui due insiemi di dati dell'articolo il metodo raggiunge una precisione dell'87.5% e un richiamo dell'80.0% [9]. Gli autori indicano fra i limiti le interazioni fra i

canali, che un modello per canale non rappresenta, e osservano che la qualità del rilevamento dipende da quella della previsione.

Anche i modelli più complessi non risolvono questo limite. Xu et al. [10] introducono Anomaly Transformer, in cui l'attenzione di un Transformer è affiancata da una distribuzione a priori concentrata sui punti vicini. Il criterio è che un'osservazione anomala, essendo rara, non riesce a stabilire legami con il resto della serie e concentra l'attenzione sui punti adiacenti; lo score moltiplica l'errore di ricostruzione per una funzione della differenza fra le due distribuzioni. La soglia è fissata senza etichette, come la quota di score più alti su un periodo di validazione. Le variabili sono riunite in un unico vettore per istante e lo score è uno per istante: il metodo non rappresenta relazioni spaziali e non localizza l'anomalia fra le variabili. I risultati dell'articolo sono misurati con un criterio che considera rilevato un intero segmento anomalo quando ne è segnalato anche un solo punto [10].

In questa tesi lo score misura lo scostamento da ciò che il modello ha appreso dal periodo di addestramento, non dai vicini fissati a mano, come precisato nella Sezione 2.5.

2.1.2 Relazioni fra le serie e dati di addestramento contaminati

Una linea di lavori rappresenta le relazioni fra le serie con un grafo appreso dai dati, quando queste relazioni non sono note. Deng e Hooi [11] propongono GDN per i sensori di impianti industriali: a ogni sensore è associato un vettore appreso, i vicini di ciascun sensore sono i più simili secondo questi vettori, e un'attenzione su grafo prevede il valore successivo di ogni sensore. L'errore di ogni sensore è normalizzato con la sua mediana e il suo intervallo interquartile, e lo score di un istante è il massimo sui sensori, perché un'anomalia può interessarne anche uno soltanto; la soglia è il massimo dello score su un periodo di validazione. Il grafo collega sensori di uno stesso impianto, non luoghi, e si assume che i dati di addestramento siano normali.

Zhou et al. [12] rimuovono questa ipotesi: osservano che gran parte dei metodi presuppone dati di addestramento composti da sole osservazioni normali, e che quando contengono anomalie le prestazioni possono degradare sensibilmente. Il loro metodo, MTGFlow, stima la densità dell'intero insieme di addestramento e identifica come anomale le osservazioni di test a bassa densità, sotto l'ipotesi che le anomalie occupino regioni più sparse. Le dipendenze fra entità sono apprese come grafo dinamico e un *normalizing flow* specifico per entità associa a ciascuna una distribuzione normale parametrizzata. La

soglia è ricavata dall'intervallo interquartile degli score di addestramento e lo score per entità consente di localizzare l'anomalia.

Le entità di MTGFlow sono i sensori o le variabili di un unico sistema e la valutazione usa dataset pubblici di riferimento: il grafo è appreso dai dati e descrive relazioni fra variabili, non fra siti geografici distinti. Un'estensione assegna una distribuzione comune alle entità di uno stesso gruppo, quando è noto che hanno caratteristiche simili. Il raggruppamento esprime soltanto che certe entità possono comportarsi allo stesso modo: non modella vicinanza, distanze o propagazione nello spazio, e non rende il metodo un detector spazio-temporale.

MTGFlow è stato il primo detector esaminato nel lavoro, per la sua robustezza alla presenza di anomalie nei dati di addestramento: per le condizioni meteorologiche non sono disponibili etichette, quindi non è possibile garantire dati di addestramento composti da sole osservazioni normali. È stato applicato ai dati PVGIS del lavoro preliminare (Sezione 3.6). Non rappresenta però il contesto geografico.

I due lavori più recenti esaminati tornano all'ipotesi di dati di addestramento normali. Wu et al. [6] propongono CATCH, un metodo basato su ricostruzione nel dominio della frequenza. Lo spettro è suddiviso in bande, trattate come *patch*, per cogliere caratteristiche a grana fine; un modulo di fusione dei canali, con un generatore di maschere e un'attenzione mascherata, seleziona per ciascuna banda le correlazioni fra canali ritenute utili e isola quelle irrilevanti. Il metodo mira a rilevare insieme anomalie puntuali e di sottosequenza ed è valutato su dataset reali e sintetici. Lo score di anomalia è l'errore di ricostruzione: il modello impara a ricostruire i pattern normali, e nei dataset sintetici dell'articolo le anomalie sono inserite soltanto nella serie di test. Il caso di anomalie presenti nei dati di addestramento non è trattato. I canali sono le variabili di una serie multivariata: non è prevista una struttura geografica fra serie di siti diversi. Gli autori segnalano inoltre che anomalie più lunghe della finestra osservata non vengono colte efficacemente.

Alnegheimish et al. [7] propongono M2AD, per serie multivariate provenienti da più sistemi. Un modello LSTM apprende il comportamento atteso dei sensori. I residui fra valori attesi e osservati sono aggregati in uno score globale mediante un modello a miscela gaussiana e una calibrazione Gamma. La soglia è stimata dagli score osservati in addestramento, e i sensori sono ordinati per contributo allo score. Il metodo assume che i dati di addestramento siano privi di anomalie e che addestramento e test abbiano andamenti simili; gli autori indicano come limite il caso in cui la distribuzione cambia, che richiede un nuovo addestramento.

CATCH e M2AD sono stati presi in esame come alternative a MTGFlow e non sono stati adottati, per due ragioni. Richiedono dati di addestramento

privi di anomalie, una condizione che senza etichette non è verificabile sui dati meteorologici; e, come MTGFlow, non rappresentano relazioni fra luoghi geografici. Nessuno dei due è stato eseguito sui dati della tesi. Dei due criteri della sezione, quindi, il primo ha portato a MTGFlow, il secondo, che nessuno di questi metodi soddisfa, a STGAN, che offre il contesto spaziale al prezzo di presupporre dati di addestramento normali.

2.1.3 Reti generative avversarie per il rilevamento di anomalie

Una rete generativa avversaria [13] è formata da due reti, addestrate insieme con obiettivi opposti. Il generatore G trasforma un rumore z, estratto da una distribuzione nota p_z, in un campione $G(z)$; i dati reali seguono la distribuzione p_{data} e il discriminatore D restituisce la probabilità $D(x)$ che un campione x provenga dai dati reali anziché dal generatore. Le due reti sono addestrate sulla stessa funzione, che il discriminatore massimizza e il generatore minimizza:

$$\min_G \max_D V(D,G) = \mathbb{E}_{x\sim p_{\text{data}}}\Big[\log D(x)\Big] + \mathbb{E}_{z\sim p_z}\Big[\log\Big(1 - D(G(z))\Big)\Big]. \quad (2.1)$$

Il primo termine cresce quando il discriminatore riconosce i dati reali, il secondo quando riconosce i campioni generati; il generatore è addestrato a rendere i propri campioni indistinguibili da quelli reali. Entrambe le reti sono ottimizzate con la retropropagazione. Lo stesso articolo osserva che, all'inizio dell'addestramento, il secondo termine fornisce al generatore un gradiente debole, e propone in alternativa di addestrarlo a massimizzare $\log D(G(z))$.

Schlegl et al. [14] usano per primi questo schema per il rilevamento di anomalie, con AnoGAN, su immagini di tomografia della retina. La rete è addestrata soltanto su immagini sane; poiché una GAN non fornisce la trasformazione inversa da un'immagine al rumore che la genera, per ogni immagine da valutare il rumore è cercato con un'ottimizzazione iterativa, a reti fissate. Lo score somma due termini: lo scarto fra l'immagine e quella generata, e la distanza fra le rispettive caratteristiche in uno strato intermedio del discriminatore. Sui dati dell'articolo lo score completo raggiunge un'area sotto la curva ROC di 0.89; preso da solo, il termine di ricostruzione arriva a 0.88, quello del discriminatore a 0.74 [14]. Li et al. [15] estendono l'idea alle serie temporali multivariate di impianti industriali con MAD-GAN, in cui generatore e discriminatore sono LSTM e tutte le variabili sono modellate insieme, dopo una riduzione con le componenti principali. Lo score combina, con un peso, lo scarto di ricostruzione, ottenuto ancora con un'inversione iterativa nello spazio latente, e l'uscita del discriminatore. L'articolo non

indica come scegliere quel peso né la soglia, e i risultati migliori sono selezionati fra più configurazioni; gli autori segnalano inoltre una forte oscillazione del richiamo da un'epoca all'altra, che attribuiscono all'instabilità del rilevamento basato su GAN [15]. Nessuno dei due metodi rappresenta relazioni spaziali fra le serie.

Nel detector della tesi lo schema è usato in forma condizionata: il generatore riceve il contesto di un'osservazione e ne produce una stima. L'uso per il rilevamento di anomalie poggia su un'ipotesi di lavoro: che la stima sia accurata nelle condizioni frequenti nei dati di addestramento e meno accurata in quelle poco rappresentate. È un'ipotesi e non una proprietà garantita dall'addestramento. Se vale, se ne ricavano due segnali: lo scarto fra l'osservazione e la stima del generatore, e il giudizio del discriminatore sull'osservazione. STGAN, descritto di seguito, li combina in un unico score. Il risultato di AnoGAN, in cui il termine del discriminatore preso da solo rileva meno di quello di ricostruzione, è coerente con la scelta dello score di questa tesi (Sezione 6.5).

2.1.4 STGAN

Deng et al. [3] propongono una rete avversaria per il rilevamento di anomalie del traffico. Il generatore prevede la dinamica normale combinando tre componenti: un ramo recente, basato su unità ricorrenti con convoluzione su grafo, per le dipendenze spazio-temporali di breve periodo, un ramo per il trend di lungo periodo e uno per le variabili esterne. Il discriminatore stabilisce se una sequenza è reale o generata in funzione dei vicini nello spazio e nel tempo, fornendo un criterio che varia con località e istante. Dopo l'addestramento avversario entrambe le reti agiscono da detector e uno score ne combina i contributi. Il grafo deriva da una topologia fisica, cioè sensori adiacenti sulla stessa strada o regioni con confini comuni, e la valutazione misura il richiamo rispetto a incidenti ed eventi documentati, che gli autori stessi indicano come verità di riferimento incompleta. L'articolo non discute la presenza di anomalie nei dati di addestramento: il discriminatore è addestrato considerando normali le sequenze reali e anomale quelle generate, quindi l'ipotesi di dati di addestramento normali è implicita. La Figura 2.1 riassume la struttura del metodo.

Sia $x_{v,t}$ l'osservazione del nodo v all'istante t e $X_{v,t}$ l'insieme delle osservazioni nel sottografo formato da v e dai suoi vicini. Sia poi $S_{v,t}$ la sequenza reale dei valori del sottografo che termina con $X_{v,t}$, e $\hat{S}_{v,t}$ la stessa sequenza in cui l'ultimo elemento è sostituito dalla stima $\hat{X}_{v,t} = G_\theta(v,t)$ del generatore.

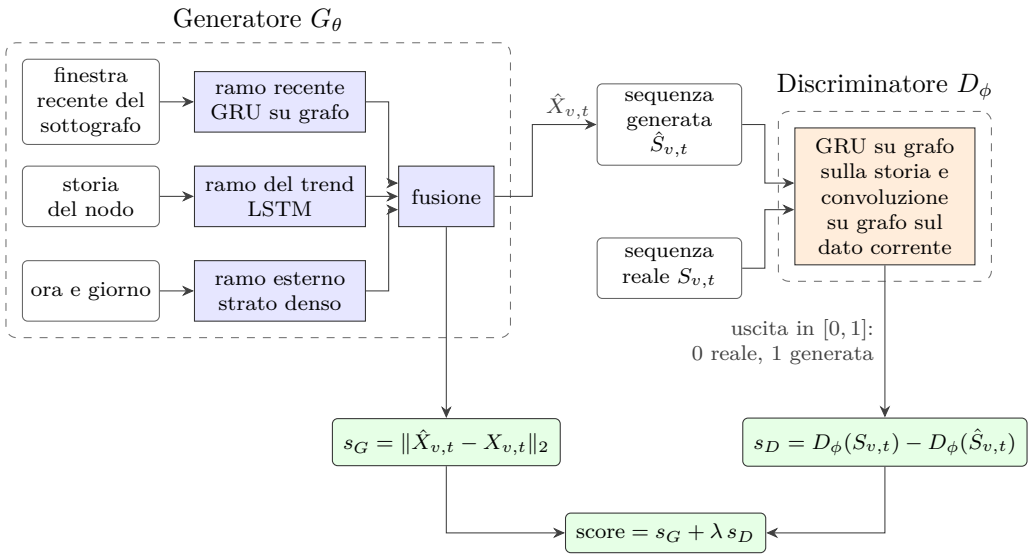


Figura 2.1: Schema di STGAN. Il generatore combina tre rami e produce la stima $\hat{X}_{v,t} = G_\theta(v,t)$, che sostituisce l'ultimo elemento della sequenza reale; il discriminatore valuta entrambe le sequenze. Lo score somma l'errore di previsione e la differenza fra le due uscite del discriminatore. Ridisegnato a partire da Deng et al. [3].

Gli obiettivi di addestramento dell'articolo sono

$$\mathcal{L}_G(\theta) = \sum_s -\log\Big(1 - D_\phi(\hat{S}_{v,t})\Big) + \lambda_G \, \|G_\theta(v,t) - X_{v,t}\|_2, \tag{2.2}$$

$$\mathcal{L}_D(\phi) = \sum_s -\log\Big(D_\phi(\hat{S}_{v,t})\Big) - \log\Big(1 - D_\phi(S_{v,t})\Big), \tag{2.3}$$

dove la somma è sui punti $s = \langle v, t, x_{v,t}\rangle$ e λ_G bilancia l'errore di previsione e il termine avversario. Lo score combina le due reti:

$$\begin{aligned} s_D(v,t) &= D_\phi(S_{v,t}) - D_\phi(\hat{S}_{v,t}), \\ s_G(v,t) &= \|G_\theta(v,t) - X_{v,t}\|_2, \\ \text{score}(v,t) &= s_G(v,t) + \lambda\, s_D(v,t). \end{aligned} \tag{2.4}$$

La componente del discriminatore non è la sua uscita sulla sequenza reale ma la differenza rispetto alla sequenza generata: gli autori la introducono per ridurre l'effetto dell'imprevedibilità dei dati reali. Negli esperimenti dell'articolo $\lambda_G = 500$, le due componenti sono normalizzate e $\lambda = 1$.

Rispetto all'equazione (2.1), in STGAN il significato dell'uscita del discriminatore è invertito: le sequenze reali sono trattate come normali e quelle

generate come anomale, e il discriminatore è spinto verso 1 sulle sequenze generate e verso 0 su quelle reali. Per il discriminatore l'obiettivo è lo stesso a meno di questo scambio, ma la sua uscita cresce con il sospetto di anomalia e può essere usata per costruire lo score. Il termine avversario dell'equazione (2.2) è la forma alternativa dell'obiettivo del generatore proposta da Goodfellow et al., scritta in questa convenzione, a cui si aggiunge l'errore di previsione.

Il generatore di STGAN stima i valori dell'istante corrente a partire dagli istanti precedenti, e l'articolo chiama *errore di previsione* lo scarto fra stima e osservazione. Nella tesi il generatore stima allo stesso modo il campo di un istante dal contesto che lo precede, e lo stesso scarto è chiamato *errore di ricostruzione*: i due termini indicano la stessa grandezza.

La tesi riprende l'architettura a tre rami e gli obiettivi avversari, e mantiene lo score combinato come riferimento; il modo in cui li adatta ai campi meteorologici è descritto nella Sezione 2.5. Gli obiettivi di addestramento e lo score, nella forma implementata, sono riportati nella Sezione 4.2: rispetto alle equazioni (2.2)–(2.4), l'errore vi compare come errore quadratico medio anziché come norma, mentre la differenza fra le uscite del discriminatore e $\lambda = 1$ sono mantenuti; λ_G è un parametro, con valore predefinito 500. La scelta segue il codice pubblicato dagli autori, che usa l'errore quadratico medio sia nella *loss* del generatore sia nella componente di ricostruzione dello score, e dimezza la somma dei due termini della loss del discriminatore. L'addestramento richiede un equilibrio fra le due reti: nella tesi i tassi di apprendimento delle due reti, il numero di aggiornamenti per *batch* e il peso di ricostruzione λ_G sono parametri configurabili (Capitolo 4).

2.1.5 Il problema della valutazione

I risultati dei lavori precedenti sono misurati su dataset etichettati, e la loro affidabilità dipende da quella delle etichette. Wu e Keogh [16] esaminano i dataset più usati per le serie temporali univariate e vi riscontrano quattro difetti ricorrenti. Il primo è che molti problemi si risolvono con una sola riga di codice basata su operazioni elementari, come media, deviazione standard e differenze successive: una riga di questo tipo risolve 316 delle 367 serie di uno dei dataset. Gli altri sono una densità di anomalie poco realistica, etichette errate o mancanti, e anomalie concentrate verso la fine delle serie. Gli autori ne concludono che parte dei progressi riportati può essere apparente, e raccomandano di confrontare ogni metodo con soluzioni banali e di esaminare sempre visivamente dati e score. L'analisi riguarda serie univariate e non tratta campi multivariati su griglia; le sue indicazioni valgono però anche in

assenza di etichette, dove il confronto con metodi semplici e l'esame diretto di mappe e serie degli score restano gli strumenti disponibili.

Liu e Paparrizos [17] riprendono il problema con TSB-AD, un insieme di 1070 serie, univariate e multivariate, ricontrollate a mano, su cui confrontano quaranta detector con gli stessi dati e la stessa procedura di scelta dei parametri. Mostrano che il criterio che considera rilevato un intero segmento quando ne è segnalato un solo punto premia anche uno score casuale, e adottano misure che non dipendono da una soglia. Con queste misure i metodi statistici sono spesso fra i migliori, con un'analisi per componenti principali in testa fra le serie univariate; fra le multivariate prevalgono reti semplici, convoluzionali o ricorrenti, e lo stesso metodo per componenti principali, mentre Anomaly Transformer risulta ultimo in entrambi i gruppi. Anche TSB-AD richiede etichette, non contiene campi su griglia e non studia dati di addestramento contaminati da anomalie; ne resta l'indicazione che un detector appreso va sempre confrontato con metodi semplici, perché la sua superiorità non è scontata.

Per questi motivi le segnalazioni del detector sono confrontate con sei modelli shallow, scelti fra i metodi statistici valutati in TSB-AD, cioè l'analisi per componenti principali, CBLOF, MCD, HBOS, COPOD e Isolation Forest, e con due metodi statistici semplici, la distanza dal normale stagionale e la variazione in tre ore (Sezione 6.6).

2.2 Apprendimento automatico e dati meteorologici

Questa sezione descrive come l'apprendimento automatico è stato applicato ai campi meteorologici, prima per prevederli e poi per riconoscerne gli eventi estremi, e mostra che il rilevamento unsupervised di anomalie su tutti gli stati di una rianalisi non è stato affrontato nei lavori esaminati.

2.2.1 Dalla previsione numerica ai modelli basati sui dati

La previsione meteorologica numerica tratta l'evoluzione dell'atmosfera come un problema ai valori iniziali: le equazioni che la governano sono integrate a partire dallo stato osservato, e i processi di scala inferiore alla griglia, come convezione, radiazione e nubi, sono rappresentati da parametrizzazioni. Bauer et al. [18] ne ricostruiscono i progressi, che attribuiscono soprattutto a parametrizzazioni migliori, alla previsione d'insieme e all'assimilazione dei

dati, e stimano che l'accuratezza fra tre e dieci giorni sia cresciuta di circa un giorno per decennio. Fra le sfide aperte indicano la verifica delle code della distribuzione, per cui servono misure adatte a statistiche scarse. Le rianalisi come ERA5 [2] nascono dallo stesso apparato: combinano un modello di previsione con le osservazioni disponibili per stimare lo stato dell'atmosfera in ogni istante.

Rasp et al. [19] rendono ERA5 il riferimento comune per i modelli di previsione basati sui dati, con WeatherBench: un insieme di campi ERA5 a risoluzione ridotta, periodi di addestramento, validazione e test contigui nel tempo e confronti con persistenza, climatologia e previsione numerica. Nella discussione gli autori osservano che gli eventi estremi, essendo rari, contano poco nelle metriche medie come l'errore quadratico, che le reti estrapolano male a stati diversi da quelli visti in addestramento e che una rete addestrata con l'errore quadratico produce campi troppo regolari; propongono le GAN come possibile rimedio a quest'ultimo problema. Lam et al. [20] portano l'approccio alla risoluzione nativa di ERA5 con GraphCast, una rete su grafo addestrata sui campi ERA5 dal 1979 al 2017, che supera la previsione deterministica operativa sul 90.3% delle combinazioni di variabile, livello e orizzonte esaminate. Gli autori riconoscono che l'addestramento con l'errore quadratico porta il modello a esprimere l'incertezza sfumando i campi, e che il modello migliora quando è riaddestrato su anni più recenti, per ragioni non del tutto chiarite. Per valutare gli eventi estremi definiscono come tali i valori oltre un percentile di una climatologia per luogo, ora del giorno e mese.

Questi lavori usano ERA5 per prevedere; la tesi lo usa per riconoscere anomalie meteorologiche. Alcune loro osservazioni valgono anche per questo impiego: un modello addestrato su anni passati con un errore medio rappresenta meglio le condizioni frequenti, tende a smussare quelle rare, e il suo comportamento può cambiare quando i dati si allontanano dal periodo di addestramento.

2.2.2 Eventi estremi e anomalie nei campi meteorologici

I primi lavori che applicano reti profonde agli eventi meteorologici estremi lo fanno in modo supervised. Liu et al. [21] classificano con reti convoluzionali poco profonde ritagli di campi centrati su cicloni tropicali, fiumi atmosferici e fronti, con etichette ottenute da criteri a soglia e da esperti, e riportano accuratezze di test fra l'89% e il 99%; il metodo classifica ritagli già centrati e non localizza gli eventi. Gli autori indicano nella scarsità di dati etichettati un limite, e la necessità di approcci unsupervised. Racah et al. [22] passano alla localizzazione con ExtremeWeather, un insieme di simulazioni climatiche in cui i riquadri degli eventi sono ottenuti da criteri a soglia: un encoder–decoder

convoluzionale nello spazio e nel tempo unisce una perdita supervised sui riquadri a una di ricostruzione su tutti i campi, così che contribuiscano anche quelli senza etichette. Gli autori osservano che etichette prodotte da criteri a soglia sono incomplete, e che un metodo supervised addestrato su di esse può al più imitarli; lasciano esplicitamente aperto il rilevamento di anomalie.

Prabhat, Kashinath et al. [23] affrontano il problema delle etichette con ClimateNet, un insieme di campi annotati a mano da esperti. La campagna ha coinvolto circa ottanta esperti e ha prodotto 459 immagini etichettate; l'accordo fra due esperti sulla stessa immagine, misurato come sovrapposizione delle aree annotate, è in media di 0.51, e il modello di segmentazione addestrato su queste etichette ottiene un valore analogo rispetto agli esperti. Le etichette sono quindi costose e, sui contorni degli eventi, incerte anche per gli esperti. Il modello è addestrato e valutato su simulazioni climatiche, e l'applicazione alle rianalisi è lasciata a lavori futuri.

La scarsità di etichette motiva i lavori più recenti, che applicano modelli generativi unsupervised a ERA5. Zaninelli et al. [24] addestrano un autoencoder variazionale sui campi giornalieri di temperatura a due metri di un clima di riferimento, preindustriale in un modello climatico oppure i primi decenni di ERA5, e trattano come anomalo ciò che il modello non ricostruisce nei campi recenti; l'obiettivo è l'attribuzione delle ondate di calore al cambiamento climatico, e l'anomalia è quindi lo scostamento da un clima di riferimento, su una sola variabile. Paçal et al. [25] addestrano un autoencoder variazionale spazio-temporale su nove variabili ERA5, con addestramento sugli anni 1941–1990 e test sugli anni 2001–2022, e raggruppano nello spazio latente le configurazioni atmosferiche delle ondate di calore in Europa occidentale; i campioni sono però selezionati in anticipo con una soglia sulla temperatura, e gli autori notano che le ricostruzioni del modello smussano gli estremi.

Nelle ricerche condotte per questa tesi non è emerso un lavoro che assegni uno score di anomalia a tutti gli stati dell'atmosfera di una rianalisi, su più variabili insieme e con un modello spazio-temporale avversario: i lavori supervised richiedono etichette che sono scarse e incerte, quelli unsupervised su ERA5 riguardano una sola variabile oppure eventi già selezionati. La ricerca non è esaustiva, e l'assenza va intesa in questo senso.

2.3 Contesto spaziale su griglie e grafi

STGAN rappresenta il contesto spaziale con convoluzioni su grafo, che presuppongono una rete di adiacenze. Le convoluzioni su grafo si sono diffuse nella previsione del traffico: Yu et al. [26] propongono STGCN, in cui blocchi formati da una convoluzione temporale, una convoluzione su grafo e una se-

conda convoluzione temporale prevedono la velocità del traffico sulle stazioni di una rete stradale. Il grafo è dato dalla rete stradale oppure costruito con un nucleo sulla distanza fra le stazioni, con parametri fissati a mano. Gli autori motivano il grafo osservando che una convoluzione ordinaria limita il modello a dati disposti su una griglia, come immagini e video. È proprio il caso dei campi della tesi, disposti su un reticolo regolare: questa sezione richiama l'operatore che sul reticolo svolge il ruolo della convoluzione su grafo, l'unità ricorrente convoluzionale.

Le unità ricorrenti a gate, come quella introdotta da Cho et al. [27] e nota come GRU, aggiornano uno stato nascosto mediante gate che regolano quanta parte dello stato precedente conservare e quanta sostituire. Nella forma originaria ingresso e stato sono vettori e i gate sono trasformazioni dense. Quando l'ingresso è un campo disposto su una griglia, le trasformazioni dense possono essere sostituite da convoluzioni, così che lo stato mantenga la struttura spaziale e i parametri siano condivisi fra le posizioni. L'idea è stata proposta per la LSTM nella previsione a breve termine delle precipitazioni [28] e per la GRU nell'apprendimento di rappresentazioni di sequenze video [29]. STGAN applica la stessa idea a un grafo: nel suo ramo recente i prodotti matriciali della GRU sono sostituiti da convoluzioni su grafo [3].

Sia X_s l'ingresso al passo s e H_{s-1} lo stato precedente, entrambi disposti sulla griglia. Uno strato ricorrente convoluzionale a gate calcola

$$R_s = \sigma(W_r * [X_s, H_{s-1}] + b_r)\,, \tag{2.5}$$

$$U_s = \sigma(W_u * [X_s, H_{s-1}] + b_u)\,, \tag{2.6}$$

$$\widetilde{H}_s = \tanh(W_c * [X_s, R_s \odot H_{s-1}] + b_c)\,, \tag{2.7}$$

$$H_s = U_s \odot H_{s-1} + (1 - U_s) \odot \widetilde{H}_s, \tag{2.8}$$

dove W_r, W_u, W_c sono i nuclei delle convoluzioni e b_r, b_u, b_c i termini costanti, appresi durante l'addestramento, σ è la funzione sigmoidale, $*$ una convoluzione spaziale, $\odot$ il prodotto elemento per elemento e $[\cdot, \cdot]$ la concatenazione sui canali. Il gate di reset R_s regola quanto dello stato precedente entra nello stato candidato $\widetilde{H}_s$; il gate di aggiornamento U_s regola quanto dello stato precedente viene conservato. La forma è quella dell'unità su grafo di STGAN, con la convoluzione su grafo sostituita da una convoluzione spaziale.

Con un *kernel* di lato k e *padding* $\lfloor k/2 \rfloor$, ogni convoluzione vede le celle entro $\lfloor k/2 \rfloor$ posizioni. Il gate di reset e lo stato candidato applicano due convoluzioni in sequenza, quindi a ogni passo lo stato precedente si propaga fino a $2\lfloor k/2 \rfloor$ posizioni: l'area che influenza una cella cresce con il numero di passi temporali e di strati. La tesi impiega questo operatore nel generatore e nel discriminatore di STGAN (Sezione 4.2.1).

2.4 Quantificazione dell'incertezza

Lo score di STGAN è un valore unico per osservazione, senza una misura della sua variabilità. Nella rassegna di Abdar et al. [30] l'incertezza di una previsione è distinta in due componenti: quella aleatoria, propria dei dati e non riducibile, e quella epistemica, dovuta alla conoscenza limitata del modello e ai dati insufficienti. Gli autori indicano le approssimazioni bayesiane e gli insiemi di modelli come i due metodi più usati, e il riconoscimento di dati lontani da quelli di addestramento come un problema ancora aperto; è la componente epistemica quella che ci si attende cresca per stati poco rappresentati nei dati, come le condizioni meteorologiche rare per un modello addestrato su anni passati. Questa sezione presenta il *dropout* Monte Carlo, applicato al detector, e le principali alternative.

Gal e Ghahramani [31] interpretano l'addestramento con dropout come un'inferenza bayesiana approssimata. Mantenendo il dropout attivo in previsione e ripetendo più volte il passaggio in avanti si ottiene un insieme di uscite, la cui dispersione fornisce una stima dell'incertezza del modello con un costo aggiuntivo contenuto. Dati J passaggi in avanti $\hat{y}_j(x)$ ottenuti con maschere di dropout diverse, la media predittiva è stimata da

$$\mathbb{E}[y \mid x] \approx \frac{1}{J} \sum_{j=1}^{J} \hat{y}_j(x), \tag{2.9}$$

e la varianza predittiva dalla varianza campionaria dei J passaggi, a cui l'articolo somma l'inverso della precisione del modello.

Nella tesi il dropout Monte Carlo è applicato alle due reti del detector, il generatore e il discriminatore di STGAN, non per stimare l'incertezza di una previsione ma per campionare lo score di anomalia. Durante il calcolo degli score i dropout restano attivi e per ogni osservazione sono riportate la media dello score sui campioni, come nell'equazione (2.9), e la sua deviazione standard, come descritto nella Sezione 4.6. In questo impiego la dispersione misura la variabilità dello score rispetto alle maschere di dropout e non costituisce una stima calibrata dell'incertezza; il termine di precisione previsto da Gal e Ghahramani non viene aggiunto.

Le alternative principali richiedono di cambiare l'addestramento. Lakshminarayanan et al. [32] propongono il Deep Ensemble, un'alternativa non bayesiana: più reti vengono addestrate in modo indipendente a partire da inizializzazioni diverse, e le loro previsioni sono combinate come una miscela a pesi uguali. Il metodo è semplice da realizzare, produce un'incertezza maggiore sugli ingressi lontani dai dati di addestramento, ma richiede di addestrare una rete per ogni membro dell'insieme: per il detector, ciascun

addestramento dura circa quattordici ore, mentre il dropout Monte Carlo ottiene la dispersione da un solo addestramento. Una terza famiglia di metodi ottiene la dispersione rendendo stocastica la dinamica interna della rete, con una rete di diffusione che scala un termine casuale: SDE-Net [33] e il suo adattamento SDE U-Net [34], considerati nel lavoro preliminare sui dati PVGIS. Il detector non li adotta: aggiungere a STGAN una rete di diffusione e una dinamica stocastica si sarebbe discostato molto dall'architettura dell'articolo, che il lavoro ha seguito il più fedelmente possibile, mentre il dropout Monte Carlo richiede soltanto di aggiungere strati di dropout alle reti esistenti, senza cambiarne l'architettura. L'applicazione di questi metodi al detector è indicata fra gli sviluppi futuri.

2.5 Da STGAN al detector della tesi

STGAN è nato per il traffico: il grafo deriva da una rete fisica, lo score è un valore unico per osservazione e la valutazione misura il richiamo su incidenti documentati (Sezione 2.1.4). La tesi ne riprende l'architettura a tre rami e gli obiettivi avversari, e lo adatta lungo questi assi a campi meteorologici privi di etichette.

Griglia e campo intero. Nell'articolo il contesto spaziale è un grafo, e in assenza di una rete fisica le sue adiacenze andrebbero scelte con un criterio di vicinanza. Sul reticolo regolare dei campi della tesi, invece, le posizioni relative dei vicini sono definite. La convoluzione su grafo del ramo recente è quindi sostituita da una ConvGRU (Sezione 2.3), e il ramo LSTM del trend è conservato. Il generatore elabora in una sola passata il reticolo completo di un istante, mentre il discriminatore continua a giudicare l'intorno di ogni cella, una patch al posto del sottografo dell'articolo (Sezione 4.2.1).

Ingresso e pesi. L'ingresso è riferito al normale stagionale di ogni cella, e l'errore di ogni variabile è pesato in rapporto a quanto essa cambia abitualmente (Sezioni 4.3 e 4.4).

Obiettivo: condizioni nuove rispetto all'addestramento. L'articolo tratta come normali le sequenze reali dei dati di addestramento, mentre per i campi meteorologici dati di addestramento privi di anomalie non sono garantiti. A differenza di MTGFlow, STGAN non tollera per costruzione dati contaminati: la tesi accetta questo limite in cambio del contesto spaziale e lo traduce in una scelta di obiettivo, cioè rilevare condizioni nuove rispetto al periodo di addestramento. Le anomalie meteorologiche presenti negli anni

di addestramento sono trattate come già osservate: nella misura in cui il modello le apprende, condizioni simili non vengono segnalate, mentre lo sono quelle poco o per nulla rappresentate in quegli anni. Lo score misura quindi lo scostamento da quanto il modello ha appreso dal periodo di addestramento (per tre variabili al netto di una tendenza lineare, Sezione 4.3), non la rarità di una condizione in assoluto.

Lo score è continuo e non coincide con la decisione: sono segnalate soltanto le osservazioni con score più alto, in una quota che è un parametro del protocollo. Una segnalazione indica una possibile anomalia meteorologica, non un'anomalia accertata (Capitolo 1).

Score e dispersione. Accanto allo score combinato dell'articolo, la tesi considera uno *score di ricostruzione*: l'errore di ricostruzione del generatore riferito ai valori abituali di questo stesso errore nella cella, nel periodo dell'anno e nell'ora, perché la grandezza tipica dell'errore cambia da luogo a luogo e da stagione a stagione (Sezione 4.7). Quale dei due score usare è studiato nel Capitolo 6. Il dropout Monte Carlo nel generatore e nel discriminatore (Sezione 2.4) associa a ogni score una misura di dispersione, che l'articolo non prevede.

Validazione senza etichette. L'articolo valuta il detector su eventi documentati, che per i campi meteorologici non sono disponibili in modo sistematico. La tesi introduce quindi anni di validazione, da cui i valori insoliti sono esclusi con un criterio che non dipende dal modello (Sezione 4.5). L'idea è analoga al protocollo di Monaco et al. [34], che nella correzione delle previsioni di precipitazione escludono gli eventi intensi dall'addestramento e li mantengono nel test. Sulla validazione sono confrontate le configurazioni e fissate soglie e climatologia degli score, prima di valutare gli anni di test.

2.6 Posizionamento del lavoro

La tesi adatta un detector avversario spazio-temporale, nato per il traffico, a campi meteorologici privi di etichette e di topologia fisica, lungo gli assi della Sezione 2.5, e lo valuta senza etichette, confrontandolo con i metodi più semplici della Sezione 2.1.5. Il contributo consiste nell'adattamento, nella combinazione di questi elementi e nel protocollo di valutazione. I componenti di base sono preesistenti: la tesi non propone un nuovo algoritmo di rilevamento.

La Tabella 2.1 riassume i quattro candidati considerati per il detector e il percorso della tesi, secondo i criteri usati nel capitolo. Le voci relative

Tabella 2.1: Candidati considerati per il detector e percorso della tesi a confronto. La colonna sulle anomalie nell'addestramento indica come ciascun lavoro tratta la presenza di osservazioni anomale nei dati di addestramento; la colonna sulla valutazione indica i dati e il riferimento con cui il lavoro misura il rilevamento.

Lavoro	Segnale dello score	Anomalie nei dati di addestramento	Contesto spaziale	Valutazione	Dispersione
STGAN [3]	Errore di previsione e discriminatore	Non trattate: dati reali considerati normali	Sì: grafo da topologia fisica	Traffico; richiamo su eventi documentati	Non prevista
MTGFlow [12]	Densità stimata	Ammesse per costruzione	No: relazioni fra variabili	Sensori; dataset etichettati	Non prevista
CATCH [6]	Errore di ricostruzione in frequenza	Non trattate	No: canali di una serie	Serie multivariate; dataset etichettati, reali e sintetici	Non prevista
M2AD [7]	Residui di previsione aggregati	Escluse per ipotesi	No: sensori di più sistemi	Sensori di più sistemi; dataset etichettati e un caso industriale	Non prevista
Tesi	Score di ricostruzione; score di STGAN come riferimento	Trattate come già osservate	Sì: vicini sulla griglia	Campi ERA5; nessuna etichetta: componenti dello score e baseline	Dropout Monte Carlo

agli articoli riportano ciò che gli articoli dichiarano; dove un aspetto non è discusso, è indicato come non trattato. STGAN è la base del detector; MTGFlow è stato eseguito nel lavoro preliminare (Sezione 3.6); CATCH e M2AD sono stati valutati sugli articoli e non eseguiti.

I capitoli seguenti descrivono i dati e il detector costruito su queste scelte.

Capitolo 3

Dati e preprocessing

Il capitolo descrive i campi meteorologici su cui il detector è addestrato e valutato: le variabili della rianalisi ERA5, il dominio e la cadenza temporale, la preparazione dei dati e la loro suddivisione in anni di addestramento, di validazione e di test. L'ultima sezione descrive i dati PVGIS da cui il lavoro è partito: serie orarie di poche località, con irradianza, temperatura e vento soltanto, che non permettono di risalire alla condizione meteorologica che le ha prodotte, e per questo il lavoro è passato ai campi ERA5. Le trasformazioni che dipendono dal modello, come la normalizzazione stagionale, sono descritte nel Capitolo 4.

3.1 Campi ERA5 e dominio

I dati della rianalisi ERA5 [2] provengono da due prodotti distinti: variabili a livello singolo e variabili su livelli di pressione, di cui è usato soltanto il livello di 850 hPa. Le variabili sono quindici, scelte per descrivere le perturbazioni seguendo le variabili usate comunemente in climatologia. Si possono raggruppare per ruolo: la temperatura, a due metri e a 850 hPa (un livello in quota, sopra lo strato vicino al suolo), e l'umidità specifica a 850 hPa descrivono lo stato termodinamico; la pressione al livello del mare, il vento a dieci metri e a 850 hPa e la velocità verticale descrivono la circolazione; la copertura nuvolosa, la radiazione solare alla superficie e la precipitazione descrivono nubi e fenomeni associati; l'umidità del primo strato del suolo, la velocità d'attrito e l'altezza dello strato limite descrivono la superficie e lo strato più basso dell'atmosfera. La Tabella 3.1 le elenca con le unità di ERA5, che non vengono convertite.

I dati coprono gli anni dal 1980 al 2025. Sono selezionati gli istanti UTC 00, 03, 06, 09, 12, 15, 18 e 21, su una griglia di $0.5° \times 0.5°$ nell'area

Tabella 3.1: Le quindici variabili ERA5, con la sigla e l'unità del dataset. Precipitazione e radiazione sono accumuli di un'ora; le altre variabili sono istantanee.

Variabile	Sigla	Livello	Unità
Temperatura a due metri	t2m	Superficie	K
Componente zonale del vento a dieci metri	u10	Superficie	$\mathrm{m\,s^{-1}}$
Componente meridionale del vento a dieci metri	v10	Superficie	$\mathrm{m\,s^{-1}}$
Pressione al livello medio del mare	msl	Superficie	Pa
Precipitazione totale	tp	Superficie	m
Copertura nuvolosa totale	tcc	Superficie	0–1
Radiazione solare discendente alla superficie	ssrd	Superficie	$\mathrm{J\,m^{-2}}$
Umidità volumetrica del primo strato del suolo	swvl1	Superficie	$\mathrm{m^3\,m^{-3}}$
Velocità d'attrito	zust	Superficie	$\mathrm{m\,s^{-1}}$
Altezza dello strato limite	blh	Superficie	m
Componente zonale del vento	u	850 hPa	$\mathrm{m\,s^{-1}}$
Componente meridionale del vento	v	850 hPa	$\mathrm{m\,s^{-1}}$
Velocità verticale	w	850 hPa	$\mathrm{Pa\,s^{-1}}$
Temperatura	t	850 hPa	K
Umidità specifica	q	850 hPa	$\mathrm{kg\,kg^{-1}}$

compresa fra 20° e 60° di latitudine nord e fra 15° di longitudine ovest e 50° di longitudine est (Figura 3.1). Il dominio comprende l'Europa, il Mediterraneo e parte dell'Africa settentrionale e del Medio Oriente. La griglia di 0.5° e la cadenza di tre ore sono più rade di quelle originali di ERA5, di 0.25° e di un'ora: sono scelte per contenere la memoria occupata e i tempi di calcolo. Il campionamento ogni tre ore è una selezione di tempi validi, non un'aggregazione temporale: precipitazione e radiazione conservano gli accumuli di un'ora associati ai tempi selezionati, senza somme triorarie o conversioni locali delle unità.

Il reticolo contiene $81 \times 131 = 10611$ celle. Nel seguito i dati sono indicati come un tensore $X \in \mathbb{R}^{T \times N \times F}$, con T istanti, $N = 10611$ celle e $F = 15$ variabili.

Sono conservate le celle per le quali tutte le variabili sono definite nel primo istante dei dati, e si verifica che questo insieme rimanga identico in tutto il periodo; se cambia, la preparazione si interrompe, e non viene applicata imputazione. Il criterio è la completezza delle variabili, non una classificazione terra–mare: nei dati usati tutte le variabili, anche l'umidità del suolo, sono definite su tutte le celle, mare compreso, e nessuna cella è esclusa.

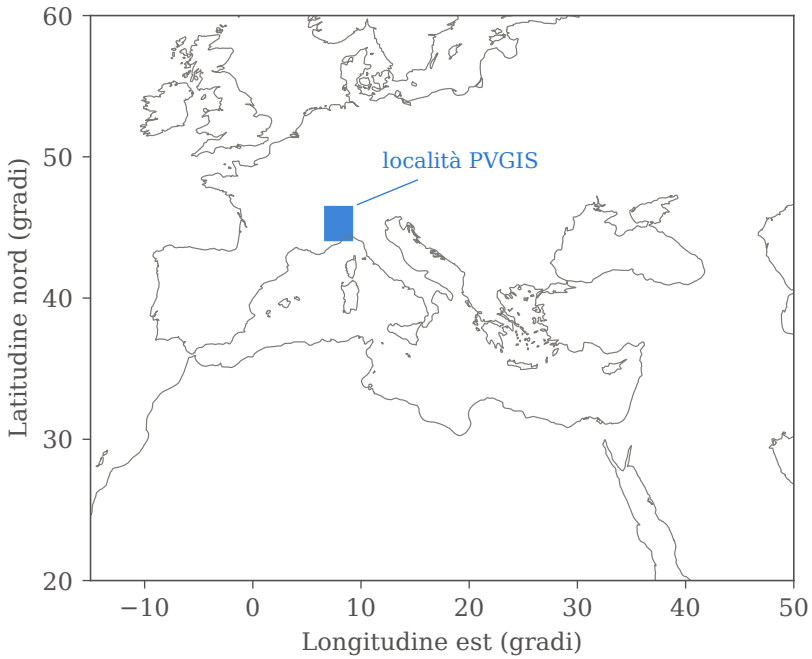


Figura 3.1: Dominio dei campi ERA5: 81 × 131 celle di 0.5°, fra 20° e 60° di latitudine nord e fra 15° di longitudine ovest e 50° di longitudine est. Il rettangolo indica l'area delle località PVGIS della Sezione 3.6, in Piemonte. Linee di costa da Natural Earth.

3.2 Acquisizione e preparazione dei dati

I dati comprendono 134416 istanti, 10611 celle e 15 variabili: circa 2.1×10^{10} valori, 85.6 GB in precisione singola. Il passaggio dai file di ERA5 ai dati letti dal modello è quindi automatizzato, in modo che nessun passo richieda di tenere in memoria l'intero periodo. Si articola in quattro fasi: scarico, verifica, preparazione e lettura (Figura 3.2).

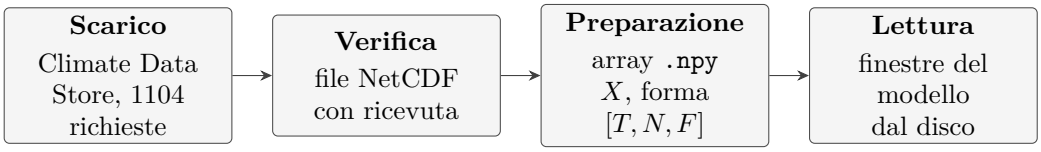


Figura 3.2: Dai file di ERA5 ai dati letti dal modello. I campi sono scaricati mese per mese dal Climate Data Store e conservati solo se superano la verifica; la preparazione li riunisce in array su disco, da cui il modello legge le sole finestre che usa.

Scarico. I campi sono richiesti al Climate Data Store di Copernicus attraverso la sua interfaccia di programmazione, con una richiesta per mese e per prodotto: 552 mesi e 1104 richieste. Ogni richiesta fissa le variabili, gli otto istanti del giorno, la griglia di 0.5°, il dominio e, per il secondo prodotto, il livello di 850 hPa. Il passaggio alla griglia di 0.5° è svolto dal servizio; i file ricevuti, in formato NetCDF [35], non vengono riscritti. Prima dello scarico i nomi delle variabili sono confrontati con quelli accettati dal servizio. Fino a otto richieste sono eseguite in parallelo, e una richiesta respinta per un limite temporaneo del servizio viene ripetuta dopo un'attesa crescente.

Verifica. Un mese è conservato solo se supera tutti i controlli. Gli istanti devono essere esattamente quelli richiesti, senza mancanti né duplicati; latitudini e longitudini devono essere quelle del dominio, con passo di 0.5°; il livello di pressione deve essere soltanto 850 hPa. Devono essere presenti tutte le variabili, senza valori infiniti e senza campi interamente mancanti in un istante; il controllo tollera campi mancanti per la sola umidità del suolo, una grandezza di terra, ma nei file usati non se ne sono presentati. Per ogni mese è salvata una *ricevuta*, un piccolo file con la richiesta e l'impronta SHA-256 di ciascun file scaricato, che permette di riconoscere i mesi già scaricati e integri. Quando lo scarico viene ripreso, i mesi con ricevuta e impronta corrette sono saltati e gli altri sono scaricati di nuovo.

Preparazione. La preparazione, svolta da un programma distinto da quello di scarico, controlla prima che tutti i mesi del periodo siano presenti, poi legge i file mese per mese, a blocchi di 32 istanti. Ripete i controlli su istanti, griglia e livello di pressione, allinea i due prodotti sugli stessi istanti e sulle stesse coordinate, e ordina le latitudini da nord a sud e le longitudini da ovest a est. Ogni blocco diventa la parte corrispondente del tensore X, in precisione singola, senza conversioni di unità né imputazione, ed è scritto direttamente nella sua posizione in file in formato `.npy` di NumPy [36]. Un file di metadati registra la griglia, le variabili, gli anni e il numero di celle escluse.

Lettura. I file sono aperti in mappatura di memoria: durante l'addestramento e il calcolo degli score si leggono dal disco soltanto gli istanti e le celle di ciascuna finestra. La suddivisione negli anni della Sezione 3.3 è applicata alla lettura.

3.3 Anni di addestramento, di validazione e di test

Il tensore X è diviso in tre periodi consecutivi. Gli anni 1980–1999 sono usati per l'addestramento, gli anni 2000–2004 per la validazione e gli anni 2005–2025 per il test: rispettivamente 58440, 14616 e 61360 istanti, cioè il 43%, l'11% e il 46% del totale. La divisione è cronologica: il modello non vede mai anni successivi a quelli su cui è valutato. Il test comincia nel 2005, il primo anno dei dati PVGIS della Sezione 3.6. Tutte le quantità che il Capitolo 4 stima dai dati per l'ingresso e la loss del modello sono calcolate sui soli anni di addestramento.

La validazione serve a confrontare le configurazioni e a fissare, prima di valutare il test, tutte le quantità che descrivono il comportamento abituale degli score. Queste quantità, fra cui le soglie, sono elencate nel Capitolo 5. Gli anni di test non entrano in alcuna scelta: ricevono senza modificarle le quantità stimate sugli anni di addestramento e su quelli di validazione. L'articolo di STGAN [3] separa i dati in training e test senza un insieme di validazione: la validazione è un'aggiunta di questo lavoro, necessaria perché in assenza di etichette la scelta della configurazione deve basarsi su una misura calcolata fuori dal test.

Il modello legge, per ogni istante, fino a 56 istanti precedenti, cioè sette giorni. I primi istanti di ciascun periodo usano quindi come contesto la coda del periodo precedente: le finestre di ingresso dei primi istanti di validazione

contengono gli ultimi istanti di addestramento, e lo stesso vale fra validazione e test. Il contesto non rientra fra gli istanti valutati.

3.4 Caratteristiche dei campi

Tre proprietà dei campi motivano altrettante scelte del Capitolo 4. Sono misurate sugli anni di addestramento, senza il detector; solo il confronto della Figura 3.4 anticipa i pesi del Capitolo 4.

Cicli diversi da luogo a luogo. La temperatura a due metri e la copertura nuvolosa hanno un ciclo stagionale e uno giornaliero, con livello e ampiezza diversi da una cella all'altra (Figura 3.3). La media mensile della temperatura va da 1 a 17 °C in una cella dell'Europa settentrionale, da 2 a 24 °C nella Pianura Padana e da 11 a 32 °C nel Sahara; la copertura nuvolosa media sta fra 0.60 e 0.78 nella prima cella e fra 0.04 e 0.29 nell'ultima. Lo stesso valore è quindi abituale in un luogo e in una stagione e insolito in altri. Per questo i valori in ingresso sono riferiti al normale stagionale della propria cella, del giorno e dell'ora (Sezione 4.3), e gli score alla climatologia della propria cella (Sezione 4.7).

Variazioni di grandezza diversa. Per una variabile f, la variazione quadratica media su 24 ore è

$$m_f = \frac{1}{TN} \sum_{t,n} \left(\tilde{x}_{t,n,f} - \tilde{x}_{t-8,n,f} \right)^2, \tag{3.1}$$

dove $\tilde{x}$ è il valore dopo la trasformazione considerata e $t - 8$ l'istante di 24 ore prima; la quota di f è $m_f / \sum_{f'} m_{f'}$. Le 24 ore confrontano istanti alla stessa ora e non contengono quindi il ciclo giornaliero. La quota dice quanto ciascuna variabile pesa in un errore di ricostruzione che somma le variabili con lo stesso peso. Con il min–max di STGAN, che riporta ogni variabile fra il minimo e il massimo degli anni di addestramento, la copertura nuvolosa produce l'84.1% della variazione quadratica media su 24 ore delle quindici variabili, e nessuna delle altre supera il 3.3% (Figura 3.4). La copertura nuvolosa passa spesso da sereno a coperto nel corso di un giorno e attraversa quasi tutto il proprio intervallo; la temperatura cambia di pochi gradi, in un intervallo che comprende tutte le celle e tutte le stagioni. Un errore di ricostruzione che somma le variabili con lo stesso peso sarebbe quindi in gran parte un errore sulla copertura nuvolosa. Dopo la normalizzazione stagionale e il min–max del detector le quote vanno dallo 0.9% dell'umidità del suolo al

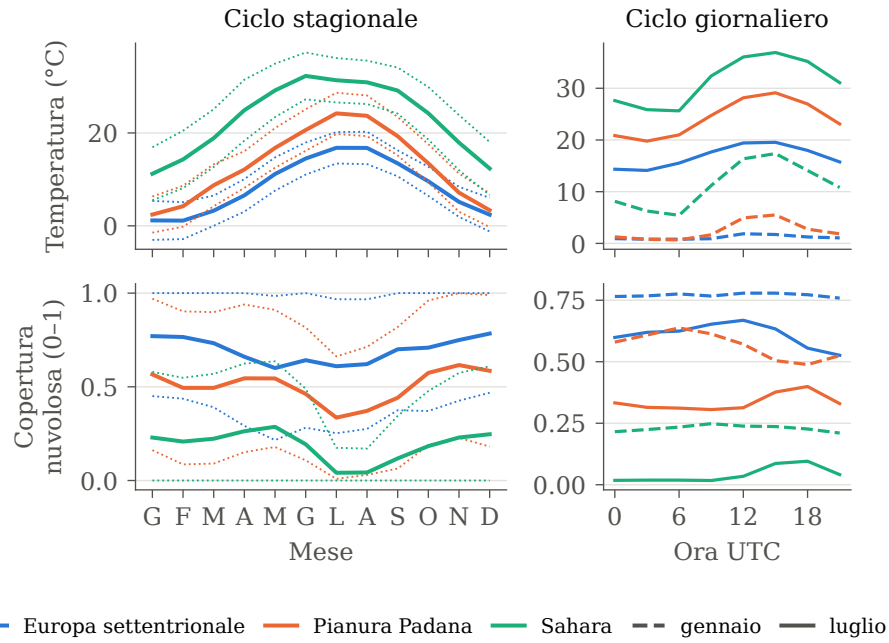


Figura 3.3: Ciclo stagionale e giornaliero della temperatura a due metri e della copertura nuvolosa in tre celle: Europa settentrionale (55°N, 10°E), Pianura Padana (45°N, 9°E) e Sahara (25°N, 10°E). A sinistra la media per mese, con le linee punteggiate a una deviazione standard dei valori triorari del mese; a destra la media per ora UTC in gennaio e in luglio. La temperatura è in gradi Celsius (in kelvin nei dati). Lo stesso mese ha livelli e variabilità diversi da una cella all'altra. Anni 1980–1999.

16.6% dell'umidità specifica, e la copertura nuvolosa ha il 6.7%, la quota di una variabile media: la normalizzazione stagionale rende confrontabili anche le variabili fra loro. Le differenze che restano sono corrette dai pesi della Sezione 4.4.

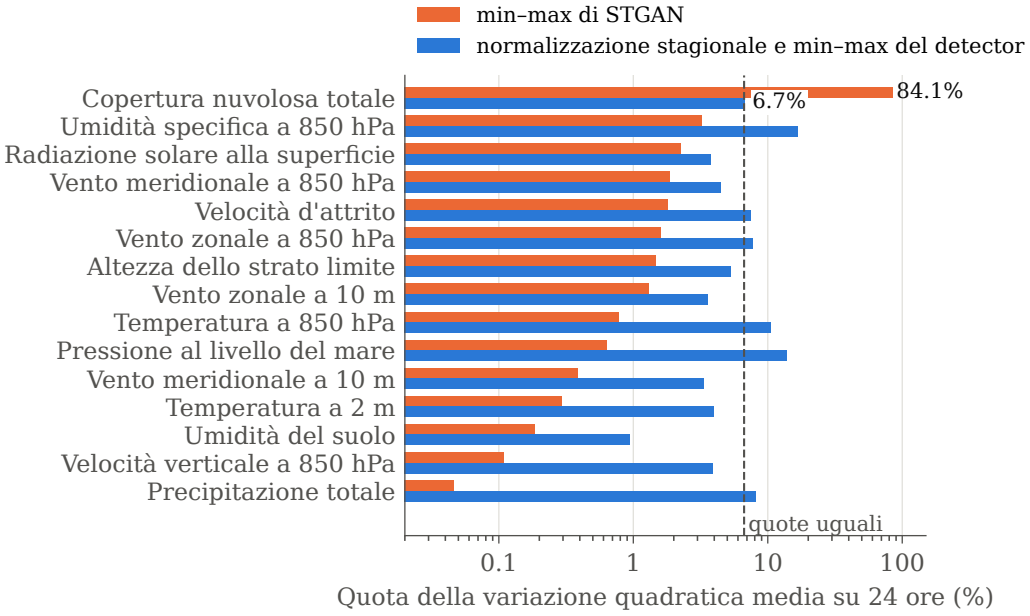


Figura 3.4: Quota di ciascuna variabile nella variazione quadratica media su 24 ore (equazione (3.1)), dopo il min–max di STGAN e dopo la normalizzazione stagionale e il min–max del detector, in scala logaritmica. Anni 1980–1999; la seconda quota è ricavata dai pesi della Sezione 4.4, che sono proporzionali all'inverso di m_f. La linea tratteggiata indica la quota uguale per tutte le variabili, un quindicesimo. Con il min–max di STGAN la copertura nuvolosa domina; dopo la normalizzazione stagionale le quote sono dello stesso ordine.

Legame spaziale a corto raggio. Gli scarti dalla media climatologica di due celle, cioè le differenze fra il valore e la media della propria cella, del mese e dell'ora, sono tanto meno correlati quanto più le celle sono lontane (Figura 3.5). Qui la media è per mese, una stima più semplice di quella per giorno usata nel Capitolo 4. Sono confrontate due variabili di grande scala, pressione e temperatura, e due legate alle perturbazioni, copertura nuvolosa e precipitazione; la distanza è misurata lungo la superficie terrestre. La correlazione mediana scende sotto 0.5 oltre circa 1300 km per la pressione al livello del mare e 900 km per la temperatura a due metri, ma già oltre 200 km per la copertura nuvolosa e 100 km per la precipitazione. Le variabili

legate alle perturbazioni dipendono quindi dalle celle vicine, entro poche celle di 0.5°: è il contesto che il detector rappresenta con la ConvGRU del generatore e con la patch del discriminatore (Sezione 4.2). Una cella misura circa 55 km in latitudine: la patch 3×3 del discriminatore copre le celle entro circa 55 km, e la ConvGRU allarga il raggio di alcune celle a ogni passo della finestra recente.

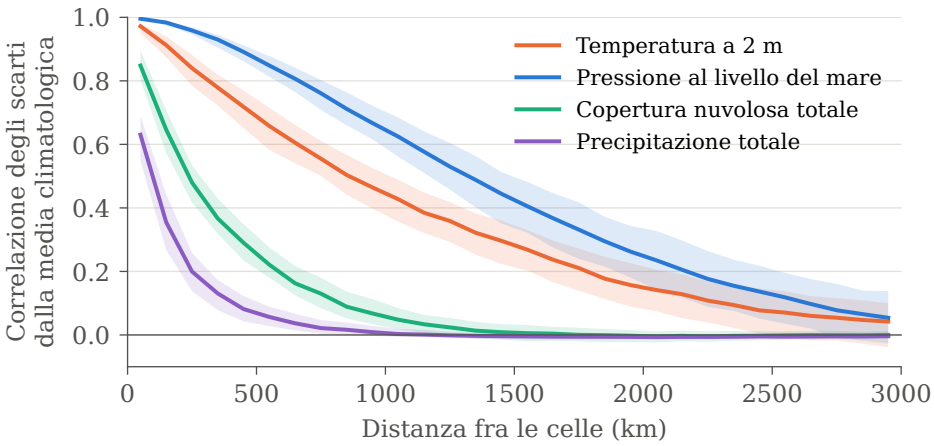


Figura 3.5: Correlazione degli scarti dalla media climatologica di due celle in funzione della loro distanza: mediana e quartili per fasce di 100 km, su 300 celle scelte a caso e un istante ogni nove degli anni 1980–1999 (un passo dispari, che legge tutte le ore del giorno). Il primo punto, entro 100 km, si basa su 36 coppie di celle. Precipitazione e copertura nuvolosa perdono la correlazione entro poche celle.

3.5 Qualità e limiti dei dati

ERA5 è una rianalisi: i campi sono stime di un modello vincolato dalle osservazioni disponibili, non misure dirette (Sezione 2.2). I dati usati sono completi, senza istanti o celle mancanti, e non è applicata imputazione. Due loro proprietà vanno però tenute presenti nella lettura dei risultati.

Variabili lontane da una distribuzione gaussiana. La precipitazione è nulla nella maggior parte degli istanti e assume di rado valori molto alti; la copertura nuvolosa è limitata fra 0 e 1. Il Capitolo 4 tratta la precipitazione con una radice quarta prima della standardizzazione (Sezione 4.3).

Cambiamenti dopo gli anni di addestramento. Riferite al normale stagionale degli anni 1980–1999, le medie annuali delle variabili sull'intero dominio non restano costanti negli anni successivi. Per l'umidità specifica a 850 hPa la media resta fra -0.13 e $+0.06$ deviazioni standard negli anni di addestramento e sale a $+0.17$ negli ultimi cinque anni: è una deriva reale, che la normalizzazione del Capitolo 4 non toglie. Per la precipitazione totale la media passa da circa 0 a valori fra $+0.09$ e $+0.26$ dal 2000 in poi; nei dati grezzi non c'è alcun salto, e lo spostamento è un effetto della standardizzazione di una variabile molto asimmetrica fuori dagli anni su cui è stimata, non un cambiamento del clima. In entrambi i casi gli anni di test si allontanano da quelli di addestramento, e un detector unsupervised può segnalare in parte questa distanza invece di anomalie meteorologiche di un singolo istante. La quota segnalata sul test è riportata nella Sezione 6.5.

3.6 I dati PVGIS del lavoro preliminare

Il lavoro è partito, nell'ambito della previsione della produzione fotovoltaica, da serie orarie ottenute dal Photovoltaic Geographical Information System [37] con la banca dati di radiazione SARAH3, provenienti dal progetto SentinelPV del Politecnico di Torino. Coprono 1149 località del Piemonte, comprese fra 44.08° e 46.47° di latitudine nord e fra 6.66° e 9.20° di longitudine est. Nella proiezione UTM del fuso 32 le località occupano 1149 delle 41×54 posizioni di un reticolo regolare con passo di 5 km: quelle che ricadono nel territorio regionale (Figura 3.6), cioè il rettangolo della Figura 3.1. Sono disponibili gli anni dal 2005 al 2023, con 8760 ore per anno (8784 negli anni bisestili) e senza valori mancanti; i valori sono riferiti al minuto 10 di ciascuna ora, in tempo universale.

Per ogni località e ogni istante sono disponibili l'irradianza globale con le sue componenti diretta, diffusa e riflessa, l'altezza del sole, la temperatura dell'aria a due metri, la velocità del vento a dieci metri e la potenza prodotta (Tabella 3.2). L'irradianza è riferita al piano orizzontale: l'inclinazione indicata nei dati è nulla, la componente riflessa risulta nulla e l'irradianza globale coincide con la somma delle componenti diretta e diffusa. Circa la metà dei valori di irradianza è nulla, perché notturna. La potenza è una produzione teorica calcolata da PVGIS, non la misura di un impianto reale.

Queste sono le sole grandezze disponibili, e sono quelle che determinano la produzione fotovoltaica. Un valore segnalato su questi dati non può essere ricondotto a una condizione meteorologica più generale: per rilevare anomalie meteorologiche di tipo diverso e descriverne l'origine il lavoro è passato ai campi ERA5 descritti nelle sezioni precedenti. Su questi dati il lavoro

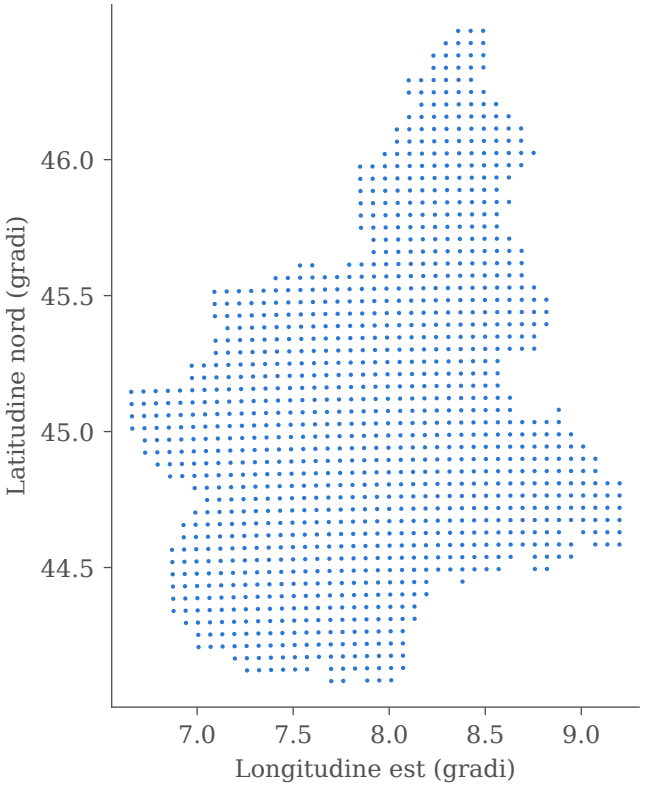


Figura 3.6: Le 1149 località dei dati PVGIS. Ogni punto è una posizione del reticolo con passo di 5 km per la quale sono disponibili le serie orarie.

Tabella 3.2: Grandezze dei dati PVGIS e loro unità.

Grandezza	Unità
Irradianza globale (diretta più diffusa)	$\mathrm{W\,m^{-2}}$
Irradianza diretta	$\mathrm{W\,m^{-2}}$
Irradianza diffusa	$\mathrm{W\,m^{-2}}$
Irradianza riflessa (nulla)	$\mathrm{W\,m^{-2}}$
Altezza del sole	gradi
Temperatura dell'aria a due metri	°C
Velocità del vento a dieci metri	$\mathrm{m\,s^{-1}}$
Potenza prodotta (teorica)	W

preliminare ha sviluppato un previsore della produzione e i primi detector, che la tesi non riporta.

Capitolo 4

Metodologia

Il capitolo descrive il detector nella forma usata sui campi ERA5. La Sezione 4.1 formula il problema: che cosa entra nel detector, che cosa ne esce e quando un valore è segnalato. Seguono l'architettura del generatore e del discriminatore con gli obiettivi dell'addestramento avversario (Sezione 4.2), l'ingresso del modello (Sezione 4.3), i pesi delle variabili nell'errore di ricostruzione, i valori esclusi dalle misure sulla validazione, le componenti dello score con il dropout Monte Carlo, la normalizzazione climatologica dello score e la misura con cui si confrontano le configurazioni. Il capitolo si ferma allo score: ciò che se ne ricava, come il raggruppamento delle segnalazioni in cluster di valori segnalati vicini, è descritto nel Capitolo 6.

La Figura 4.1 riporta l'ordine in cui questi passaggi agiscono su un istante, e per ogni quantità stimata gli anni su cui è stimata: normalizzazione stagionale e pesi sugli anni di addestramento, prima di addestrare il modello; climatologia e soglia sugli anni di validazione, dopo l'addestramento. Il discriminatore non compare nella catena: serve all'addestramento del generatore.

4.1 Formulazione del problema

I dati sono una sequenza di campi X_t, uno per istante t, su un reticolo di $N_y = 81$ righe e $N_x = 131$ colonne, cioè $N = 10611$ celle, con $F = 15$ variabili (Capitolo 3); x_{tnf} indica il valore della variabile f nella cella n. Per ogni istante il generatore riceve il contesto che lo precede, cioè gli R campi più recenti, una serie più lunga di ciascuna cella per il trend e la codifica temporale, e restituisce una stima $\hat{X}_t$ del campo, con valori $\hat{x}_{tnf}$. Lo scarto fra stima e osservazione, pesato per variabile e mediato sulla patch 3×3 di ogni cella e su più estrazioni Monte Carlo, è la *componente di ricostruzione* $\bar{s}_{G,tn}$ (Sezione 4.6). Espressa rispetto ai valori abituali di questo stesso errore

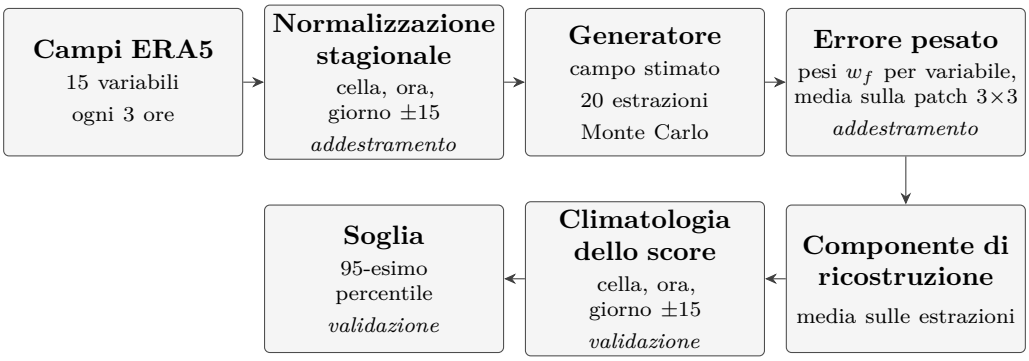


Figura 4.1: Ordine dei passaggi del detector su un istante, dai campi ERA5 alla segnalazione. In corsivo, gli anni su cui è stimata ciascuna quantità: le scale della normalizzazione stagionale e i pesi sugli anni di addestramento, la climatologia dello score e la soglia sugli anni di validazione.

nella cella, nel periodo dell'anno e nell'ora, diventa lo *score di ricostruzione* ζ_{tn} (Sezione 4.7). Una coppia istante–cella è *segnalata* quando $\zeta_{tn} > \tau$, con la soglia τ pari al 95-esimo percentile di ζ sugli anni di validazione. Lo score misura quindi lo scostamento da ciò che il modello ha appreso negli anni di addestramento (Sezione 2.5), e una segnalazione indica una possibile anomalia meteorologica, non un'anomalia accertata. Il discriminatore serve all'addestramento del generatore e allo score combinato dell'articolo, calcolato dalla stessa esecuzione per confronto.

4.2 Architettura e addestramento avversario

Il detector segue lo schema di STGAN [3] descritto nella Sezione 2.1.4: un generatore stima il campo dell'istante successivo a partire dagli istanti precedenti, e un discriminatore giudica se il campo di un istante, insieme alla sua storia recente, è osservato o generato. Il generatore stima le quindici variabili della Tabella 3.1, su una griglia con passo di 0.5° e con una cadenza di tre ore. La Figura 4.2 riporta la struttura delle due reti, descritta nelle sottosezioni seguenti.

4.2.1 Generatore ConvGRU sul campo intero

Un campione di addestramento è il campo completo di un istante, disposto sul reticolo $N_y \times N_x$ della Sezione 3.1. Il generatore ha tre rami. Il ramo recente elabora gli R campi che precedono l'istante da stimare con una

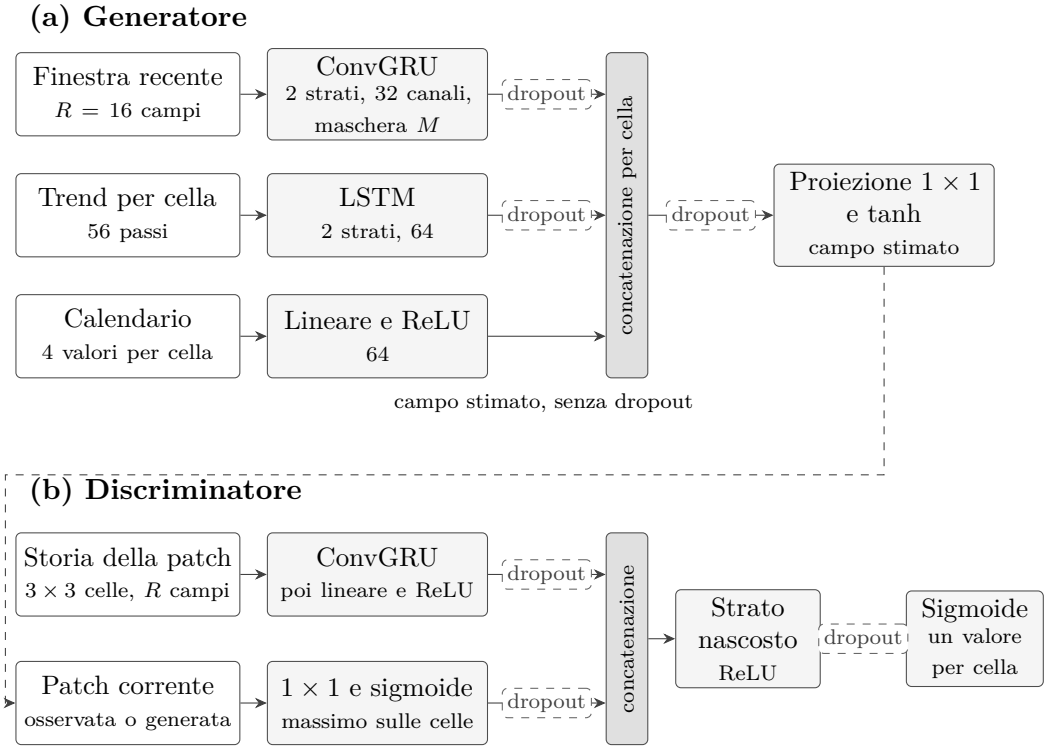


Figura 4.2: Struttura del generatore (a) e del discriminatore (b). Il generatore unisce cella per cella i tre rami, recente, trend e calendario, e produce il campo stimato dell'istante. Il discriminatore giudica ogni cella sulla propria patch, a partire dalla storia recente e dal campo corrente, osservato o generato. I riquadri tratteggiati indicano i dropout, con probabilità 0.2 (Sezione 4.6).

ConvGRU [28, 29], l'unità ricorrente convoluzionale delle equazioni (2.5)–(2.8), che sostituisce la convoluzione su grafo dell'articolo. Il ramo del trend elabora con una LSTM [38] la serie di ciascuna cella su un periodo più lungo. Il ramo del calendario proietta la codifica temporale con uno strato lineare seguito da una ReLU. Con b istanti per batch, R passi recenti, L passi di trend e F variabili, gli ingressi hanno forma $[b, R, F, N_y, N_x]$ per il ramo recente e $[b, L, N, F]$ per il trend; l'uscita ha forma $[b, F, N_y, N_x]$.

Le convoluzioni scorrono sull'intero reticolo: il campo ricettivo non è troncato al bordo di una regione e ogni cella viene ricostruita una sola volta. La LSTM del trend e la codifica temporale sono calcolate per cella e disposte sul reticolo. Le rappresentazioni dei tre rami sono concatenate cella per cella; una proiezione 1×1 seguita da tanh produce il campo stimato.

Lo stato ricorrente è inizializzato a zero per ogni finestra. Il modello ha due strati ConvGRU da 32 canali con kernel 3×3, e una LSTM del trend a due strati con stato nascosto di dimensione 64.

4.2.2 Discriminatore locale

Il discriminatore giudica ogni cella sulla propria patch $P \times P$, con $P = 3$, così come nell'articolo giudica ogni nodo sul proprio sottografo: la patch comprende la cella e le sue otto vicine dirette, così che il giudizio tenga conto dell'intorno immediato. La patch di ogni cella è estratta dal campo. Sul bordo del dominio la patch è incompleta: le celle della patch esterne al reticolo sono azzerate dopo la normalizzazione, e una maschera binaria M è fornita come canale aggiuntivo a ogni strato ConvGRU. Rispetto alle equazioni (2.5)–(2.8) cambiano l'ingresso e l'ultimo passaggio. I gate e lo stato candidato sono calcolati su X'_s, la concatenazione dei valori mascherati e di M, al posto di X_s; lo stato precedente H_{s-1} è già mascherato e lo stato aggiornato viene moltiplicato per la maschera, replicata sui canali:

$$H_s = M \odot \left[U_s \odot H_{s-1} + (1 - U_s) \odot \widetilde{H}_s \right]. \tag{4.1}$$

Il mascheramento dello stato impedisce alle celle assenti di conservare attivazioni da propagare negli strati o nei passi successivi. La ConvGRU del generatore ha la stessa forma; su ERA5 nessuna cella del reticolo è priva di dati, e la sua maschera vale uno ovunque.

Una ConvGRU codifica la storia recente della patch; la storia codificata è appiattita e proiettata con uno strato lineare seguito da una ReLU. Il campo corrente della patch, osservato o generato, passa attraverso una proiezione 1×1 seguita da una sigmoide e da un massimo sulle celle valide. Le due rappresentazioni sono concatenate e alimentano uno strato nascosto e un'uscita sigmoidale. Il discriminatore restituisce quindi un valore per cella e per istante.

Le patch di tutte le celle sono valutate in un'unica passata, con le stesse maschere e gli stessi azzeramenti. L'uscita relativa a una cella è quella che il discriminatore produrrebbe sulla sua patch isolata.

4.2.3 Obiettivi di addestramento

Il discriminatore viene addestrato con etichetta zero per il campo reale e uno per il campo generato, come nell'articolo. Indicando con D_{reale} e D_{generato} le uscite sulle patch con il campo osservato e con il campo generato, cioè le $D_\phi(S_{v,t})$ e $D_\phi(\hat{S}_{v,t})$ dell'articolo (Sezione 2.1.4), gli obiettivi sono

$$\mathcal{L}_D = \tfrac{1}{2}\Big[\mathrm{BCE}(D_{\text{reale}}, 0) + \mathrm{BCE}(D_{\text{generato}}, 1)\Big], \tag{4.2}$$

$$\mathcal{L}_G = \lambda_G \ \mathrm{MSE}_w(\hat{x}, x) + \mathrm{BCE}(D_{\text{generato}}, 0), \tag{4.3}$$

dove MSE_w è l'errore quadratico medio sulle celle valide e sulle variabili, con i pesi delle variabili della Sezione 4.4, mediato poi sugli istanti del batch, e la BCE è mediata sulle uscite locali, una per cella. Rispetto alle equazioni (2.2)–(2.3) dell'articolo, l'errore di ricostruzione è un errore quadratico medio anziché una norma e la loss del discriminatore è dimezzata: la scelta segue il codice pubblicato dagli autori.

Generatore e discriminatore vengono aggiornati con ottimizzatori Adam [39] separati. Nel passo del generatore, i parametri del discriminatore sono congelati ma viene mantenuto il gradiente rispetto al campo generato; la storia della patch è ricalcolata con i pesi aggiornati del discriminatore. Il peso di ricostruzione λ_G, che nell'articolo vale 500, è un parametro. I tassi di apprendimento dei due ottimizzatori sono distinti e fissati separatamente. Il coefficiente β_1 degli ottimizzatori vale 0.9, il valore del codice degli autori. Con rapporto n_D:n_G, sullo stesso batch vengono eseguiti prima n_D aggiornamenti del discriminatore e poi n_G del generatore, ciascuno con un proprio passaggio in avanti. Il rapporto è un conteggio di aggiornamenti e non va confuso con il rapporto fra i tassi di apprendimento. Tassi, rapporto e peso di ricostruzione sono gli strumenti con cui si regola l'equilibrio fra le due reti; i valori usati sono scelti nel Capitolo 5.

Un'epoca comprende $\lceil T_{\mathrm{a}}/b \rceil$ batch, con T_{a} istanti di addestramento utili e b istanti per batch, e ogni gradiente è mediato su tutte le celle di un istante.

In sintesi. Il generatore stima il campo di un istante su tutto il reticolo, a partire dai campi recenti, dal trend di ogni cella e dal calendario; il discriminatore giudica ogni cella sulla propria patch 3×3. Le due reti sono addestrate con gli obiettivi dell'articolo, nella forma del codice degli autori.

4.3 Ingresso: finestra recente, codifica temporale e normalizzazione stagionale

4.3.1 Finestra recente e trend

La finestra recente contiene gli R istanti che precedono quello da stimare. L'unità ricorrente spaziale la percorre in ordine: parte da uno stato nullo ed esegue un aggiornamento per ogni istante, sicché lo stato finale riassume gli R campi osservati. Con $R = 1$ il ramo recente vede soltanto l'ultimo istante e la ricorrenza si riduce a un solo aggiornamento. Con $R > 1$ il modello riceve anche l'evoluzione del campo negli istanti precedenti, e l'area che può influenzare una cella cresce con R, perché a ogni aggiornamento lo stato si propaga alle celle vicine. Il detector usa $R = 16$ passi, cioè 48 ore; il trend comprende 56 passi, cioè 168 ore, la stessa durata dell'articolo.

4.3.2 Codifica temporale ciclica

La codifica temporale dell'articolo, a 31 elementi, è composta dal giorno della settimana e dall'ora UTC. È pensata per il traffico e su ERA5 è poco adatta, per due motivi. Il primo è che il vettore è lo stesso per tutte le celle, mentre il dominio si estende per 65 gradi di longitudine: alla stessa ora UTC, l'ora solare delle celle più a ovest e quella delle celle più a est differiscono di oltre quattro ore. Il secondo è che non contiene la posizione nell'anno, e non distingue quindi le stagioni. È perciò sostituita da una codifica ciclica a quattro elementi, diversa per cella. Indicando con h_t l'ora UTC, con ℓ_n la longitudine in gradi, con g_t il giorno frazionario dell'anno e con G_t il numero di giorni dell'anno corrispondente, la codifica è

$$\begin{aligned} c_{tn} &= [\sin\phi_{tn},\ \cos\phi_{tn},\ \sin\psi_t,\ \cos\psi_t]\,, \\ \phi_{tn} &= \frac{2\pi}{24}\left(h_t + \frac{\ell_n}{15}\right), \qquad \psi_t = \frac{2\pi g_t}{G_t}, \end{aligned} \tag{4.4}$$

Il primo angolo rappresenta l'ora solare locale, ottenuta dalla sola longitudine senza fusi orari; il secondo la posizione nell'anno. Seno e coseno rendono vicini gli istanti vicini nel ciclo, come le ore 23 e le ore 1 oppure la fine di dicembre e l'inizio di gennaio. La codifica ciclica non contiene il giorno della settimana.

4.3.3 Normalizzazione stagionale

La normalizzazione dell'articolo è un min–max per variabile stimato sui dati di addestramento. Usa un solo intervallo per variabile, valido per tutte le celle

e per tutto l'anno. Su un dominio che va dal Sahara all'Europa settentrionale questo ha un limite: lo stesso valore riceve la stessa scala ovunque e in ogni stagione. Una temperatura di 20 °C, per esempio, è insolitamente alta a gennaio in Europa settentrionale e insolitamente bassa a luglio nel Sahara (Sezione 3.4), ma con un solo min–max per variabile riceve in entrambi i casi lo stesso valore normalizzato. La normalizzazione stagionale riferisce invece ogni valore a ciò che è abituale nella stessa cella, nello stesso periodo dell'anno e alla stessa ora (Figura 3.3). Per ogni cella n, variabile f, ora del giorno o e giorno dell'anno g il valore è standardizzato,

$$z_{tnf} = \frac{x_{tnf} - \mu_{nfog}}{\sigma_{nfog}}, \tag{4.5}$$

con otto ore del giorno e 366 giorni dell'anno. Media e deviazione standard sono quindi due tensori di forma $[8, 366, N, F]$, con una voce per ogni ora, giorno, cella e variabile, e la standardizzazione è un unico passaggio: ogni valore è confrontato direttamente con la media e la deviazione della propria ora, del proprio giorno, della propria cella e della propria variabile, senza una normalizzazione nel tempo seguita da una nello spazio. Media e deviazione standard sono stimate sui soli anni di addestramento, raccogliendo i quindici giorni che precedono g e i quindici che lo seguono. La deviazione standard è calcolata attorno alla media lisciata di ciascun giorno, in modo che la variazione del ciclo stagionale all'interno della finestra non venga contata come variabilità. Espresse in deviazioni standard del proprio normale, le variabili diventano confrontabili anche fra loro: la copertura nuvolosa, che con il solo min–max produce l'84.1% della variazione su 24 ore, ne produce il 6.7% (Sezione 3.4).

La precipitazione richiede un passaggio in più. È nulla nella maggior parte degli istanti e assume di rado valori molto alti: media e deviazione standard dei valori originali sono determinate in larga parte da questi pochi valori. Prima della standardizzazione la precipitazione è quindi sostituita dalla sua radice quarta, che comprime i valori alti e lascia nullo ciò che è nullo; media e deviazione standard descrivono la radice e non il valore originale. A differenza del logaritmo, la radice è definita anche per i valori nulli e non richiede una costante aggiuntiva.

La deviazione standard σ_{nfog} non può scendere sotto una frazione della deviazione standard complessiva della variabile sugli anni di addestramento: 0.1 per la precipitazione e per l'umidità del primo strato del suolo, 0.01 per le altre tredici variabili. Il limite evita la divisione per valori quasi nulli, come accade per la radiazione solare di notte.

L'ultimo passaggio riguarda il tempo. Gli anni di test seguono quelli di addestramento, fino a oltre vent'anni dopo. Per una variabile che nel periodo

ha una tendenza, la differenza fra il clima degli anni di test e quello degli anni di addestramento entrerebbe in ogni valore standardizzato, e crescerebbe con la distanza dagli anni di addestramento. Per tre variabili (temperatura a due metri, temperatura a 850 hPa e umidità del primo strato del suolo) ai valori standardizzati è quindi sottratta una retta nel tempo. Sono le variabili in cui un controllo della media sull'intero dominio ha mostrato una deriva evidente, a partire dagli anni di addestramento; per le altre lo spostamento resta piccolo, con le eccezioni dell'umidità specifica, discussa più avanti, e della precipitazione (Sezione 3.5).

La retta è una per variabile, uguale per tutte le celle: passa per le medie annuali dei valori standardizzati sull'intero dominio, è stimata sui soli anni di addestramento e viene prolungata agli anni successivi. Per queste tre variabili, quindi, la tendenza lineare stimata sugli anni di addestramento non conta come condizione nuova; per le altre il riferimento resta il clima di quegli anni. Per le altre dodici variabili la retta non è sottratta. Fra queste c'è l'umidità specifica: la sua deriva inizia dopo gli anni di addestramento, e una retta stimata su quegli anni non la descrive. Per questa variabile la correzione non può quindi essere applicata senza usare gli anni di test.

Dopo questi passaggi è applicato un min–max per variabile, stimato sugli anni di addestramento, che riporta i valori nell'intervallo $[-1, 1]$ dell'uscita del generatore. Negli anni successivi, i valori esterni all'intervallo degli anni di addestramento possono superare questi estremi, perché la trasformazione non applica un clipping. Nel seguito x_{tnf} indica il valore dopo tutti questi passaggi e $\hat{x}_{tnf}$ la sua stima da parte del generatore.

4.4 Pesi delle variabili nell'errore di ricostruzione

Nell'articolo tutte le variabili contano allo stesso modo nell'errore di ricostruzione. Il detector pesa invece l'errore per variabile, in modo che ciascuna sia misurata in rapporto a quanto cambia abitualmente. Dopo la normalizzazione stagionale le variabili hanno già variazioni dello stesso ordine, ma non uguali: le loro quote della variazione su 24 ore vanno dallo 0.9% al 16.6% (Figura 3.4). I pesi correggono queste differenze. Indicando con m_f il quadrato medio della variazione della variabile f su 24 ore, calcolato sui dati di addestramento normalizzati, il peso è

$$w_f = \frac{\bar{m}}{m_f}, \qquad \bar{m} = \frac{1}{F} \sum_{f=1}^{F} m_f, \tag{4.6}$$

con $F = 15$. La differenza a 24 ore confronta istanti alla stessa ora del giorno e non contiene quindi il ciclo giornaliero. Con il fattore $\bar{m}$, un errore quadratico pari a m_f in ogni variabile dà la stessa loss con e senza pesi. Il peso non misura la difficoltà del modello su una variabile: è una misura di quanto la variabile cambia, fissata prima dell'addestramento e senza usare il modello. Nella configurazione scelta vanno da 0.40 per l'umidità specifica a 7.14 per l'umidità del primo strato del suolo, che cambia lentamente. I pesi moltiplicano l'errore quadratico di ciascuna variabile nel termine di ricostruzione della loss del generatore e nell'errore di ricostruzione da cui sono calcolati gli score.

In sintesi. Ogni valore entra nel modello riferito al normale stagionale della propria cella, giorno e ora, con la codifica dell'ora solare locale e del periodo dell'anno, e l'errore di ciascuna variabile pesa in proporzione inversa a quanto la variabile cambia abitualmente.

4.5 Valori esclusi negli anni di validazione

Gli anni di validazione servono a confrontare configurazioni e a stimare le quantità dello score prima di valutare il test. Perché queste misure dipendano soprattutto dal tempo ordinario, i valori più insoliti della validazione sono individuati prima, con un criterio che non usa il modello.

Un valore, cioè una coppia istante–cella, è detto *escluso* in base a due distanze calcolate sui dati standardizzati della Sezione 4.3. La prima è la distanza dal normale stagionale: la media sulle variabili del quadrato dei valori standardizzati, con i pesi delle variabili della Sezione 4.4, che dice quanto il valore è lontano dal normale della propria cella, giorno e ora. La seconda è la variazione dall'istante precedente: la stessa media pesata sul quadrato della differenza rispetto a tre ore prima, che coglie i cambiamenti rapidi anche quando il valore resta vicino al normale. Ciascuna distanza è standardizzata con la media e la deviazione standard della stessa cella, dello stesso mese e della stessa ora negli anni di addestramento, così che un luogo o una stagione più variabili non concentrino i valori esclusi. Un valore è escluso quando almeno una delle due distanze standardizzate supera il livello oltrepassato dal 5% dei valori di addestramento. Medie, deviazioni standard e livelli sono stimati sui soli anni di addestramento; la validazione riceve soltanto l'indicazione di quali valori sono esclusi. Il criterio è approssimato: non pretende di individuare tutte le anomalie meteorologiche, ma di togliere le più evidenti, così che le misure dipendano soprattutto dal tempo ordinario. La soglia del 5% è una scelta, ed esclude il 9.75% dei valori di validazione.

I valori esclusi sono trattati in due modi. Come valori da valutare, non entrano nella misura con cui si confrontano le configurazioni, negli estremi dello score combinato e nella climatologia degli score; entrano invece nella soglia (Sezione 5.2). Come storia recente da cui il modello parte, nelle finestre di ingresso degli istanti di validazione sono sostituiti dal normale stagionale, cioè dal valore standardizzato nullo, solo per la misura con cui si confrontano le configurazioni e per il passaggio che chiude l'addestramento; climatologia e soglia usano la storia reale (Sezione 4.7). In questo modo, nella misura con cui si confrontano le configurazioni, né il bersaglio né la storia recente da cui il modello parte contengono i valori esclusi.

4.6 Componenti dello score e dropout Monte Carlo

4.6.1 Dropout nel generatore e nel discriminatore

Lo score è calcolato più volte con il dropout Monte Carlo [31], nella forma che pone il dropout dopo gli encoder e prima degli strati di uscita. Il generatore riceve tre strati di dropout: sulla rappresentazione spaziale del ramo recente, sulla rappresentazione del trend e sulla loro concatenazione con la codifica temporale, prima della proiezione di uscita. Il discriminatore ne riceve altrettanti, nelle posizioni corrispondenti: sulla storia codificata, sul campo corrente codificato e sullo strato nascosto che precede l'uscita. La probabilità è 0.2 in entrambe le reti, un valore fissato e non ottimizzato. I dropout sono attivi nell'addestramento e nel calcolo degli score. L'articolo e il codice degli autori non usano il dropout: è un'aggiunta di questo lavoro.

Il discriminatore riceve il campo generato senza il dropout del generatore: nell'addestramento, sia nel proprio aggiornamento sia nel termine avversario del generatore, e nel calcolo degli score. Se ricevesse il campo con il dropout, potrebbe distinguere i campi generati da quelli osservati per il rumore che il dropout vi introduce, e non per il loro contenuto. Il dropout del generatore agisce quindi sull'errore di ricostruzione, quello del discriminatore sul suo giudizio.

4.6.2 Estrazioni Monte Carlo e componenti dello score

Durante il calcolo degli score il modello è in modalità di valutazione, con l'eccezione dei dropout, che restano attivi. Per ogni istante sono fatte $J = 20$ estrazioni, un valore fissato e non ottimizzato. Nell'estrazione j il generatore ricostruisce il campo con una propria maschera di dropout, e il discriminatore

giudica l'osservazione e il campo generato senza dropout con una propria maschera, la stessa per i due giudizi.

Per la coppia istante–cella (t, n) e l'estrazione j, la ricostruzione $\hat{x}^{(j)}$ dà l'errore di ricostruzione

$$s_{G,tn}^{(j)} = \frac{1}{|\mathcal{P}_n|\, F} \sum_{c \in \mathcal{P}_n} \sum_{f=1}^{F} w_f \left(\hat{x}_{tcf}^{(j)} - x_{tcf} \right)^2, \tag{4.7}$$

dove $\mathcal{P}_n$ sono le celle valide della patch 3×3 di n. L'errore di una cella è quindi la media su sé stessa e sulle celle vicine, come nell'articolo, dove l'errore di un nodo è misurato sul suo sottografo. La componente del discriminatore è, come nell'articolo, la differenza fra il giudizio sull'osservazione e quello sul campo generato,

$$s_{D,tn}^{(j)} = D_{\text{reale},tn}^{(j)} - D_{\text{generato},tn}^{(j)}. \tag{4.8}$$

La componente di ricostruzione, media sulle estrazioni,

$$\bar{s}_{G,tn} = \frac{1}{J} \sum_{j=1}^{J} s_{G,tn}^{(j)}, \tag{4.9}$$

è la media degli errori delle singole estrazioni, e non l'errore della ricostruzione media. Per ogni cella e variabile le due quantità differiscono per la varianza delle ricostruzioni:

$$\frac{1}{J} \sum_{j=1}^{J} \left(\hat{x}^{(j)} - x \right)^2 = \left(\bar{\hat{x}} - x \right)^2 + \frac{1}{J} \sum_{j=1}^{J} \left(\hat{x}^{(j)} - \bar{\hat{x}} \right)^2, \qquad \bar{\hat{x}} = \frac{1}{J} \sum_{j=1}^{J} \hat{x}^{(j)}. \tag{4.10}$$

La componente cresce quindi sia quando la ricostruzione si allontana dall'osservazione, sia quando le estrazioni non sono concordi fra loro. Dalle stesse estrazioni si ricava anche la deviazione standard di ciascuna componente e dello score, chiamata nel seguito *dispersione*: misura quanto essi dipendono dalle maschere di dropout; non è una probabilità di anomalia né una stima calibrata dell'incertezza.

4.6.3 Score combinato e score di ricostruzione

Dalla stessa esecuzione sono ricavati due score. Lo *score combinato* è quello dell'articolo; non è usato come score del detector, ed è confrontato con le due componenti (Sezione 6.5). Le due componenti sono riportate su una scala comune con un min–max e sommate con peso unitario, estrazione per estrazione:

$$a_{tn}^{(j)} = \frac{s_{G,tn}^{(j)} - r_{\min}}{r_{\max} - r_{\min}} + \frac{s_{D,tn}^{(j)} - d_{\min}}{d_{\max} - d_{\min}}, \qquad \bar{a}_{tn} = \frac{1}{J} \sum_{j=1}^{J} a_{tn}^{(j)}. \tag{4.11}$$

L'articolo indica che le due componenti sono normalizzate prima della somma, senza specificare come, e il codice degli autori salva le componenti senza combinarle: il min–max è quindi una scelta di questo lavoro. Gli estremi $r_{\min}$, $r_{\max}$, $d_{\min}$ e $d_{\max}$ sono quelli delle due componenti medie sulle estrazioni negli anni di validazione, senza i valori esclusi (Sezione 4.5), e restano fissi per il test: nessuna quantità dello score è stimata sugli anni valutati. I valori del test possono uscire dall'intervallo $[0, 1]$ di ciascuna componente, perché non è applicato un clipping.

Lo *score di ricostruzione* ζ_{tn} è la sola componente $\bar{s}_{G,tn}$, espressa rispetto alla propria climatologia (Sezione 4.7). Quale dei due score usare è discusso nel Capitolo 6.

4.7 Normalizzazione climatologica degli score

Una trasformazione successiva al calcolo degli score esprime ogni score rispetto alla climatologia della stessa cella. Per la cella n, il giorno dell'anno g e l'ora UTC o dell'istante t,

$$\zeta_{tn} = \frac{s_{tn} - \mu^{s}_{nog}}{\sigma^{s}_{nog}}, \tag{4.12}$$

dove s_{tn} è lo score da trasformare, la componente di ricostruzione $\bar{s}_{G,tn}$ o lo score combinato $\bar{a}_{tn}$. Media e deviazione standard sono calcolate con la stessa ricetta della normalizzazione stagionale della Sezione 4.3: sugli score della stessa cella e della stessa ora nei quindici giorni che precedono g e nei quindici che lo seguono, con una finestra che scavalca la fine dell'anno, e con la deviazione standard calcolata attorno alla media lisciata di ciascun giorno. Lo score è uno per cella e non ha la dimensione delle variabili: media e deviazione standard sono due tensori di forma $[8, 366, N]$. Sono stimate negli anni di validazione, senza i valori esclusi (Sezione 4.5), e restano fisse per il test. Non possono essere stimate sugli anni di addestramento, perché su quegli anni il modello ha già visto i dati e il suo errore è più basso di quello su anni nuovi. Quando lo score trasformato serve sugli anni di validazione stessi, per le scelte e per fissare le soglie, media e deviazione standard di un anno y sono calcolate sugli altri quattro anni di validazione, $\mu^{s,(-y)}_{nog}$ e $\sigma^{s,(-y)}_{nog}$: nessun valore entra nella propria climatologia. I gruppi con meno di trenta valori di riferimento o con varianza nulla non ricevono uno score.

Gli score di validazione da cui sono stimate queste quantità sono calcolati con la storia reale degli istanti di validazione, come quelli del test. La sostituzione dei valori esclusi nella storia (Sezione 4.5) serve alla misura con cui si confrontano le configurazioni durante l'addestramento e al passaggio di validazione che chiude l'addestramento, da cui vengono gli estremi dello score

combinato; non entra nella climatologia. Una climatologia stimata su errori calcolati da una storia ripulita descriverebbe un errore più basso di quello che il modello commette sul test, dove la storia contiene anche i valori che sulla validazione sono esclusi.

Lo scopo è rendere confrontabili celle e stagioni in cui l'errore di ricostruzione ha una grandezza tipica diversa: senza questo passaggio, le segnalazioni si concentrerebbero dove l'errore è grande per natura. La trasformazione applica la stessa idea della normalizzazione stagionale, cioè esprimere un valore rispetto a ciò che è abituale per quella cella, quel periodo dell'anno e quell'ora, ma a un oggetto diverso. La normalizzazione stagionale agisce sui campi in ingresso, prima del modello, ed è stimata sugli anni di addestramento: toglie il ciclo stagionale e giornaliero dei dati, ma non la differenza di prevedibilità fra celle e stagioni. Dove il tempo cambia più rapidamente il generatore sbaglia di più anche su dati standardizzati. La normalizzazione climatologica agisce sull'errore del generatore, dopo l'addestramento, è stimata sugli anni di validazione e toglie questa seconda differenza senza modificare il detector.

Score finale. Riassumendo, lo score usato nei risultati è lo score di ricostruzione

$$\zeta_{tn} = \frac{\bar{s}_{G,tn} - \mu^{s}_{nog}}{\sigma^{s}_{nog}}, \tag{4.13}$$

con $\bar{s}_{G,tn}$ dell'equazione (4.9): l'errore pesato del generatore, medio sulla patch 3×3 della cella e sulle 20 estrazioni Monte Carlo, riferito ai valori abituali dello stesso errore nella cella, nel periodo dell'anno e nell'ora. Una coppia istante–cella è segnalata quando ζ_{tn} supera la soglia τ, il 95-esimo percentile di ζ sugli anni di validazione.

4.8 Validazione senza etichette

Gli anni di validazione servono a confrontare configurazioni del detector senza usare il test e senza etichette. Il confronto deve misurare quanto bene il modello ricostruisce il tempo normale: i valori esclusi degli anni di validazione (Sezione 4.5) sono tenuti fuori dalle misure.

4.8.1 Distanza fra campi osservati e ricostruiti nello spazio delle componenti principali

La misura usata per confrontare le configurazioni confronta osservazioni e ricostruzioni in uno spazio indipendente dal modello. Lo spazio è ottenuto da un'analisi delle componenti principali dei campi di addestramento: ogni

campione è il campo completo di un istante, normalizzato e appiattito su celle e variabili. Sono usati i campi con la quota più bassa di valori esclusi, nello stesso numero per ogni mese, e sono conservate 300 componenti principali: oltre questo numero la varianza spiegata cresce poco, e 300 componenti ne spiegano il 78.8%, contro il 67.4% di 100 componenti. Lo spazio è costruito una sola volta, prima delle esecuzioni, e successivamente soltanto caricato.

I campi di tempo normale sono scelti, non corretti. Sostituire i valori esclusi con il normale stagionale darebbe campi più lisci di qualunque campo osservato, e una distanza calcolata su di essi premierebbe un generatore che ricostruisce campi lisci. Un campo scelto può contenere ancora qualche valore escluso, entro la quota che lo fa rientrare fra i campi normali del suo mese. Per lo stesso motivo il valore da ricostruire, quando è fra quelli esclusi, non è sostituito ma tenuto fuori dalle misure: si sostituisce soltanto la storia da cui il modello parte.

Su questo spazio viene definito un riferimento per la validazione. È formato da $S = 5$ sottoinsiemi fissi e disgiunti di 512 campi normali degli anni di validazione, scelti con lo stesso criterio, dalle coordinate delle loro osservazioni nello spazio e da una banda h pari alla distanza euclidea mediana fra tali coordinate. Anche questo riferimento è fissato prima delle esecuzioni. La Maximum Mean Discrepancy (MMD) misura quanto differiscono due insiemi di campioni: è vicina a zero quando seguono la stessa distribuzione. A ogni epoca, per ciascun sottoinsieme, si calcola la stima non distorta della MMD [40]

$$\widehat{\mathrm{MMD}}^2 = \frac{1}{n(n-1)} \sum_{i \neq i'} k(x_i, x_{i'}) + \frac{1}{n(n-1)} \sum_{i \neq i'} k(y_i, y_{i'}) - \frac{2}{n^2} \sum_{i,i'} k(x_i, y_{i'}), \tag{4.14}$$

dove x_i sono le coordinate delle osservazioni, y_i quelle delle ricostruzioni del generatore e il kernel è la media di tre RBF,

$$k(a, b) = \frac{1}{3} \sum_{c \in \{0.5,\, 1,\, 2\}} \exp\left(-\frac{\|a - b\|^2}{2(ch)^2} \right). \tag{4.15}$$

Vengono registrate media e varianza della stima sui sottoinsiemi e la media delle ultime cinque epoche, che è la quantità usata per scegliere fra configurazioni. La stima non distorta può assumere valori leggermente negativi. Poiché tutte le esecuzioni confrontate caricano gli stessi riferimenti, le differenze nella misura non dipendono da una nuova stima dello spazio o della banda. Una MMD più bassa indica ricostruzioni più vicine alle osservazioni nello spazio considerato; non misura direttamente la qualità del rilevamento delle anomalie meteorologiche.

4.8.2 Diagnostiche per epoca e misure finali

Al termine di ogni epoca un sottoinsieme fisso della validazione, 32 istanti equispaziati con tutte le celle, viene elaborato con un passaggio deterministico, a dropout spento. Vengono registrate due quantità: la differenza assoluta media fra le attivazioni del penultimo strato del discriminatore sull'osservazione e sulla ricostruzione, e la variazione dello score fra epoche consecutive sulle stesse celle. Queste quantità e la MMD non entrano in una loss, in un aggiornamento dei pesi o negli score; sono calcolate senza gradiente e ripristinando gli stati dei generatori di numeri casuali, così da non alterare la traiettoria dell'addestramento.

Dopo l'ultima epoca, su tutti i valori validi e non esclusi della validazione, viene calcolata la componente di ricostruzione media sulle estrazioni Monte Carlo, riassunta da media, deviazione standard, mediana e 95-esimo percentile. Le stesse estrazioni danno gli estremi delle due componenti usati dallo score combinato.

Il Capitolo 5 riporta i valori scelti e il protocollo con cui lo score è valutato.

Capitolo 5

Esperimenti

Il capitolo descrive come il detector del Capitolo 4 è addestrato e valutato sui campi ERA5. La Sezione 5.1 riporta la configurazione fissata e la ricerca dei quattro iperparametri che regolano l'equilibrio fra generatore e discriminatore; la Sezione 5.2 descrive il protocollo di valutazione: che cosa si stima sugli anni di validazione e che cosa si valuta sul test. I risultati, compresi quelli della ricerca, sono nel Capitolo 6.

5.1 Configurazione e ricerca degli iperparametri

La configurazione del detector è fissata, a eccezione di quattro iperparametri che regolano l'equilibrio fra generatore e discriminatore, scelti con una ricerca bayesiana. La Tabella 5.1 riporta i valori fissati e gli iperparametri cercati, con la sezione del Capitolo 4 che li descrive.

Obiettivo. L'obiettivo della ricerca è la distanza MMD fra campi osservati e ricostruiti nello spazio delle componenti principali (Sezione 4.8), mediata sulle ultime cinque epoche, da minimizzare: la prima epoca è esclusa perché, all'inizio dell'addestramento, è poco indicativa della configurazione. Ogni esecuzione è addestrata sugli anni 1980–1999 e misurata sugli anni di validazione, senza calcolare score sul test. Ogni configurazione è addestrata una sola volta, con lo stesso seme per tutte le esecuzioni. Le esecuzioni interrotte perché una loss ha assunto valori infiniti o indefiniti (NaN) non hanno un obiettivo e sono escluse dalla scelta.

La ricerca. Le prove sono proposte con un metodo bayesiano: un processo gaussiano stima l'obiettivo in funzione degli iperparametri, a partire dalle

Tabella 5.1: Configurazione del detector su ERA5. Nella parte superiore i valori fissati, nella parte inferiore gli iperparametri della ricerca, con l'intervallo esplorato e il valore della configurazione scelta. In scala logaritmica, per esempio, i valori 50 e 200 sono equidistanti da 100.

Elemento	Valore	Sezione
Anni di addestramento, validazione, test	1980–1999, 2000–2004, 2005–2025	3.3
Unità del campione e batch	Campo intero, un istante per batch	4.2.1
Generatore	ConvGRU a due strati da 32 canali, kernel 3×3; LSTM del trend a due strati da 64	4.2.1
Discriminatore	Patch 3×3; ConvGRU a due strati da 32 canali; strato nascosto da 64	4.2
Finestra recente e trend	16 e 56 passi, cioè 48 e 168 ore	4.3
Codifica temporale	Ora solare locale e posizione nell'anno, per cella	4.3
Normalizzazione dell'ingresso	Rispetto al normale di cella, giorno e ora; retta nel tempo tolta a tre variabili; poi min–max	4.3
Pesi delle variabili	Inversi della variazione quadratica media su 24 ore	4.4
Dropout	0.2, nel generatore e nel discriminatore	4.6
Estrazioni Monte Carlo negli score	20	4.6
Ottimizzatore	Adam, $\beta_1 = 0.9$, $\beta_2 = 0.999$, tasso costante	4.2
Epoche	6, come nel codice degli autori di STGAN	–
Precisione	BF16, pesi in FP32	–
Tasso di apprendimento del generatore	da 10^{-4} a $3 \cdot 10^{-3}$, in scala logaritmica; scelto $7.65 \cdot 10^{-4}$	4.2
Tasso di apprendimento del discriminatore	da $2.5 \cdot 10^{-5}$ a $5 \cdot 10^{-3}$, in scala logaritmica; scelto $3.06 \cdot 10^{-3}$	4.2
Peso di ricostruzione λ_G	da 25 a 2000, in scala logaritmica; scelto 63.7	4.2
Aggiornamenti per batch, n_D:n_G	1:1, 2:1 oppure 1:2; scelto 1:1	4.2

prove già completate, e la prova successiva è scelta dove il miglioramento atteso è più alto. La ricerca è fermata quando più prove consecutive non migliorano il miglior obiettivo di almeno 0.0004, un valore vicino al rumore dell'obiettivo stimato dal processo gaussiano. È scelta la configurazione con l'obiettivo più basso fra le esecuzioni completate. Le esecuzioni, il loro andamento e la configurazione scelta sono riportati nella Sezione 6.1.

Pesi e calcolo. Del modello scelto si usano i pesi dell'ultima epoca, come nel codice degli autori[1], che salva i pesi a ogni epoca e valuta quelli dell'ultima: nessuna epoca è scelta in base al risultato. Un'epoca comprende 58384 batch di un istante, cioè gli istanti di addestramento meno i 56 di contesto del trend. Nella configurazione scelta un'epoca dura circa 2.4 ore, quindi un'esecuzione di sei epoche poco più di 14 ore. I modelli sono implementati in PyTorch [41]. Nella preparazione dei dati (Sezione 3.2) i file mensili in formato NetCDF [35] sono letti con xarray [42]; durante l'addestramento e il calcolo degli score i file `.npy` sono letti con NumPy [36] in mappatura di memoria; le tabelle di score sono elaborate con pandas [43]; il Capitolo 6 usa anche SciPy [44]. Tutti i modelli sono addestrati su una scheda NVIDIA RTX PRO 6000 Blackwell.

5.2 Protocollo di valutazione

Che cosa si calcola. Gli score della configurazione scelta sono calcolati sugli anni di validazione 2000–2004 e di test 2005–2025, su tutti gli istanti e tutte le celle: 14616×10611 coppie istante–cella sulla validazione e 61360×10611 sul test, ciascuna con le 20 estrazioni Monte Carlo della Sezione 4.6. In entrambi i periodi le finestre di ingresso contengono la storia reale, compresi i valori esclusi, e i primi istanti prendono il contesto dal periodo precedente (Sezione 3.3).

Che cosa si stima sulla validazione. Le quantità che descrivono il comportamento abituale degli score sono stimate sugli anni di validazione e restano fisse per il test: la climatologia degli score (Sezione 4.7) e la soglia. La soglia di uno score è il 95-esimo percentile dello stesso score sugli anni di validazione,

$$\tau = Q_{0.95}\Big\{\zeta_{tn} \,:\, t \in \text{validazione},\ n = 1, \ldots, N\Big\}, \tag{5.1}$$

calcolato su un istante ogni dieci degli anni di validazione e su tutte le celle, una soglia per ciascuno score confrontato. Sugli anni di validazione ζ di

[1] `https://github.com/dleyan/STGAN`

ogni anno è calcolato con la climatologia degli altri quattro (Sezione 4.7), e i valori senza score sono esclusi. Nella soglia entrano anche i valori esclusi dalle altre misure (Sezione 4.5), perché valori come questi sono presenti anche negli anni di test. Sul test la soglia segnala una quota che può scostarsi dal 5%, ed è riportata nei risultati. Le analisi principali sono ripetute con il 99-esimo percentile, per verificare quanto le conclusioni dipendano dalla soglia (Sezione 6.10). Gli estremi con cui le due componenti dello score combinato sono riportate su una scala comune vengono invece dal passaggio di validazione che chiude l'addestramento, con la storia in cui i valori esclusi sono sostituiti dal normale (Sezioni 4.5 e 4.6).

Score usato e baseline. Lo score del detector è lo score di ricostruzione ζ dell'equazione (4.13), che nel Capitolo 6 è indicato con G_{n}, cioè G con la normalizzazione climatologica. Lo score combinato dell'articolo, che somma la componente di ricostruzione e quella del discriminatore, non è usato: la scelta di ζ è motivata nella Sezione 6.5: le due componenti non concordano sugli anni di validazione, e la componente di ricostruzione ha un significato chiaro. Non esistono etichette di anomalia. Gli anni di test non intervengono né nell'addestramento né nella scelta della configurazione; il comportamento degli score e il loro confronto con otto baseline, metodi più semplici (Sezione 6.6), sono descritti nel Capitolo 6.

Capitolo 6

Risultati e discussione

Il capitolo riporta e discute i risultati del detector sui campi ERA5, nella configurazione scelta dalla ricerca degli iperparametri. In assenza di etichette, la domanda centrale è quale parte dello score di STGAN usare, e il comportamento del detector è studiato in più passi. Senza etichette, inoltre, una segnalazione indica dove lo score è alto, non che lì ci sia davvero un'anomalia meteorologica: questo vale per tutto il capitolo. Nel capitolo un valore è una coppia di cella e istante; salvo dove indicato, è segnalato quando supera il 95-esimo percentile del proprio score sugli anni di validazione. La Sezione 6.1 riguarda la scelta della configurazione. La Sezione 6.2 confronta le due componenti dello score, del generatore e del discriminatore, nello spazio e nel tempo, la Sezione 6.3 esamina la normalizzazione climatologica e la Sezione 6.4 che cosa giudica il discriminatore. La Sezione 6.5 conferma questi risultati sugli anni di test e fissa la scelta dello score, che discende da queste analisi e dal significato chiaro di G: G_{n}, cioè G con la normalizzazione climatologica, lo score di ricostruzione ζ della Sezione 4.7. La Sezione 6.6 confronta le segnalazioni del detector con quelle di otto metodi più semplici, le baseline, la Sezione 6.7 le raggruppa in cluster per tipo e dimensione, studia come cala G_{n} attorno a ciò che segnala, confrontandolo con quello delle baseline sui propri cluster, e mostra un cluster per tipo, la Sezione 6.8 esamina la dispersione del dropout, in generale e per tipo di cluster, la Sezione 6.9 confronta le segnalazioni con anomalie meteorologiche note, e la Sezione 6.10 verifica quanto i risultati dipendano dalla soglia.

6.1 Ricerca degli iperparametri

La ricerca della Sezione 5.1 conta 29 prove, quattro delle quali interrotte per una loss non finita. La Figura 6.1 le mostra nel piano delle prime due

componenti principali dei quattro iperparametri, presi in scala logaritmica e standardizzati. Il piano tiene il 71% della varianza: due prove vicine nel piano possono essere lontane nei quattro parametri, e per questo la regione migliore è indicata sulle sue prove e non come un'area.

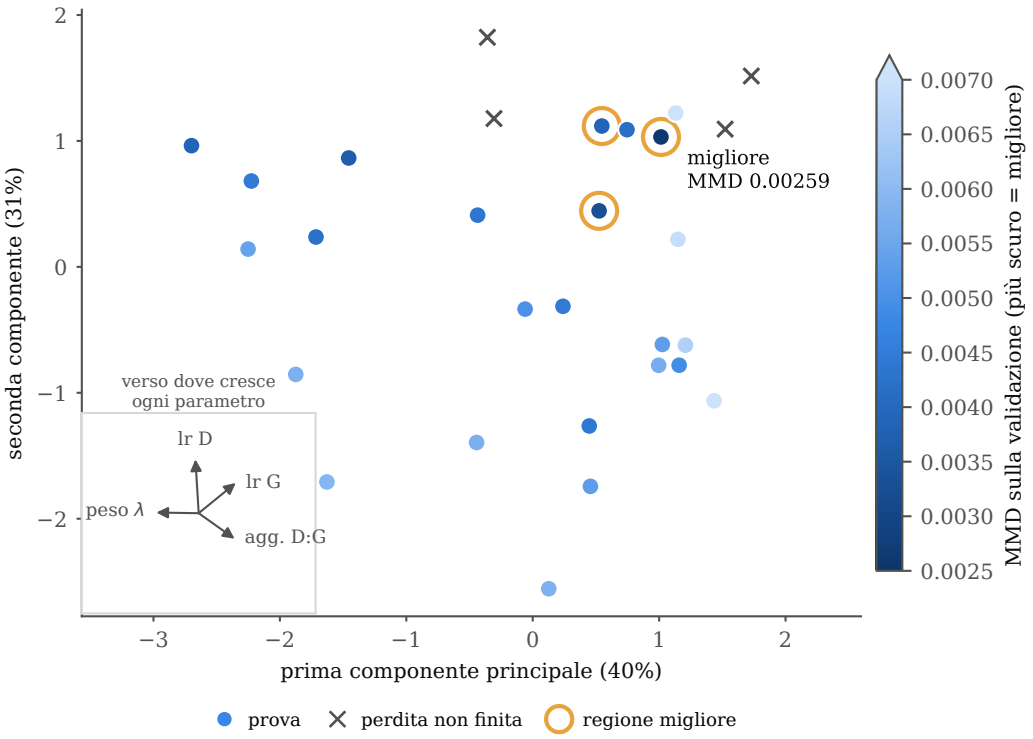


Figura 6.1: Le prove della ricerca degli iperparametri nel piano delle prime due componenti principali dei quattro iperparametri (71% della varianza). Il colore è la distanza MMD sulla validazione, più scuro dove è più bassa; i cerchi arancioni indicano le tre prove della regione migliore. Nel riquadro, la direzione in cui cresce ciascun iperparametro: lr G e lr D sono i tassi di apprendimento del generatore e del discriminatore, peso λ il peso della ricostruzione, agg. D:G gli aggiornamenti del discriminatore e del generatore per batch. Le prove non si avvicinano via via alla regione migliore: una volta stimata, la ricerca esplora le zone meno note.

La regione migliore. Tre prove formano la regione migliore: tasso di apprendimento del generatore fra 5.7×10^{-4} e 8.2×10^{-4}, del discriminatore fra 1.5×10^{-3} e 3.3×10^{-3}, peso della ricostruzione fra 64 e 173, aggiornamenti 1:1. Le loro distanze MMD sono 0.00259, 0.00327 e 0.00384: le prime due sono le più basse dell'intera ricerca, e le tre prove sono l'una la più vicina

all'altra. Fuori dalla regione la prova migliore vale 0.00367, ma è isolata e le prove più vicine hanno dato fra 0.0038 e 0.0044: è un risultato singolo, non una regione. Anche oltre la regione, con il tasso del discriminatore fino a 50 volte quello del generatore e il peso della ricostruzione fino a 60, le distanze non scendono: la prova con rapporto 9.6 fra i due tassi e peso 60, per esempio, vale 0.0041. La configurazione scelta è la prova con 0.00259. Per questa prova il processo gaussiano della ricerca stima un valore atteso di 0.0032 ± 0.0004, con un rumore dell'obiettivo di circa 0.0005: parte del suo vantaggio sulle prove vicine dipende quindi dal seme, ed è un limite di una ricerca con un solo seme per configurazione.

Esplorare, non convergere. Le prove non si avvicinano via via alla regione migliore, e la figura non mostra un percorso che migliora piano piano. Ogni prova è scelta dove il miglioramento atteso è più alto, che dipende sia dal valore atteso sia dall'incertezza. Vicino alla regione migliore il processo non si aspetta miglioramenti oltre il rumore, e il miglioramento atteso più alto cade nelle zone che conosce meno: le ultime prove, con peso della ricostruzione fino a 2000 e tasso del generatore sceso fino a 10^{-4}, hanno dato distanze fra 0.0037 e 0.0054.

6.2 G e D: un legame debole

Lo score di STGAN somma due componenti, e prima di sceglierne una conviene capire se segnalano gli stessi valori. Questa sezione e le due seguenti riguardano gli anni di validazione 2000–2004 della configurazione scelta: 14616 istanti su 10611 celle. Sono gli anni su cui si sceglie lo score del detector (Sezione 5.2); la Sezione 6.5 ripete le stesse misure sugli anni di test. Le grandezze usate sono riassunte nella Tabella 6.1. G e D sono le due componenti dello score, medie sulle 20 estrazioni (Sezione 4.6); D_{reale} e D_{generato} sono le due uscite del discriminatore da cui D è calcolata, e servono nella Sezione 6.4. Il discriminatore è addestrato a dare 1 al campo generato e 0 a quello osservato: un valore alto delle sue uscite significa quindi "giudicato generato". Va fatta attenzione al nome: D_{reale} è il giudizio sull'osservazione, e un suo valore alto significa che l'osservazione è giudicata generata. Nell'idea di STGAN un'osservazione di questo tipo non somiglia a quelle viste in addestramento, e per questo un valore alto di D, come di G, significa "più insolito".

I due score sono confrontati con due correlazioni. Quella di Spearman è calcolata sui ranghi: dice se i due score mettono i valori nello stesso ordine, e pochi valori estremi pesano poco. Quella di Pearson è calcolata sui valori,

Tabella 6.1: Le grandezze del capitolo e il significato di un loro valore alto. Tutte sono calcolate per ogni cella e ogni istante.

Grandezza	Che cosa misura	Valore alto
G ($\bar{s}_G$)	errore di ricostruzione del generatore, medio sulla patch 3×3 della cella	osservazione più insolita
G_{n} (ζ)	G con la normalizzazione climatologica, lo score di ricostruzione della Sezione 4.7, lo score del detector: G rispetto a ciò che è abituale per quella cella, periodo dell'anno e ora	osservazione più insolita per quel luogo e periodo
D_{reale}	giudizio del discriminatore sull'osservazione, fra 0 e 1	osservazione giudicata generata
D_{generato}	giudizio del discriminatore sulla ricostruzione, fra 0 e 1	ricostruzione giudicata generata
D	$D_{\text{reale}} - D_{\text{generato}}$, la componente del discriminatore	osservazione più insolita

e dà più peso ai valori estremi. Entrambe valgono 1 se i due score vanno insieme, -1 se vanno in senso opposto, 0 se non hanno legame.

Nello spazio, G e D ordinano i luoghi quasi senza legame. La correlazione spaziale è calcolata in ogni istante sulle celle, e dice se i due score segnalano gli stessi luoghi nello stesso istante. Fra G e D la correlazione di Spearman vale in media 0.015 ed è negativa nel 44% degli istanti (Figura 6.2). Il segno segue la stagione: la media è 0.10 da dicembre a febbraio e -0.06 da giugno ad agosto. Sull'insieme delle celle, quindi, i due score ordinano i luoghi quasi in modo indipendente, e il poco legame che c'è cambia segno con la stagione.

Nel tempo, il legame è debole e non ha lo stesso segno in ogni cella. La correlazione temporale è calcolata in ogni cella sugli istanti, e dice se in quel luogo i due score salgono e scendono insieme. Fra G e D la correlazione di Spearman ha mediana -0.05 ed è negativa nel 67% delle celle (Figura 6.3). Il legame è un po' più forte nel sud del dominio, con una mediana di -0.11 fra 20° e 30°N, e più debole fra 40° e 50°N, con -0.02. Escludendo le tre file vicino al bordo, la correlazione è positiva nel 26% delle celle, per lo più fra 35° e 50°N.[1] Anche nel tempo, quindi, i due score sono quasi indipendenti, e il segno del loro legame dipende dal luogo.

[1]Nelle tre file di celle più vicine al bordo del dominio la correlazione è invece in genere positiva, con una mediana fra 0.08 e 0.17, e nella Figura 6.3 forma una cornice rossa. È

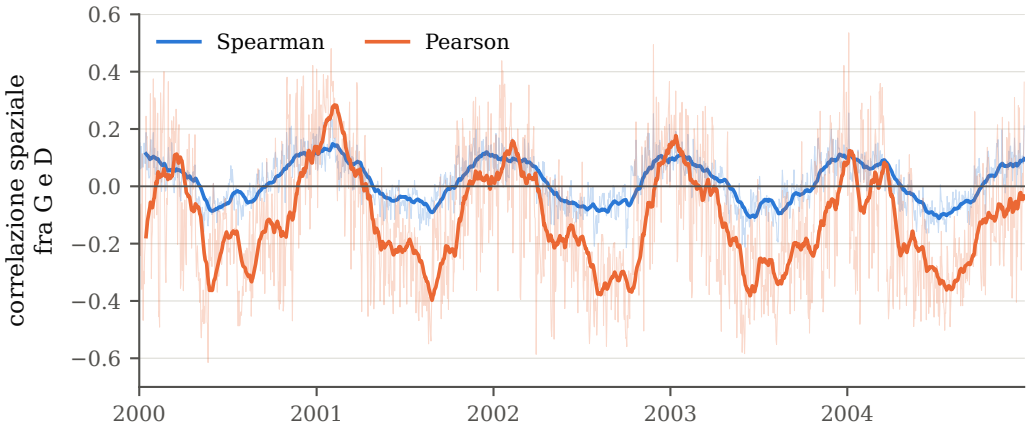


Figura 6.2: Correlazione spaziale fra G e D in ogni istante degli anni di validazione, calcolata sulle 10611 celle: media giornaliera (linea sottile) e media mobile su 30 giorni (linea spessa). La correlazione di Spearman (in blu) oscilla attorno a zero con la stagione; quella di Pearson (in arancione) è negativa in circa due giorni su tre, soprattutto in estate.

L'unico legame di segno costante: dove G è più alto, D tende a essere più basso. La correlazione di Pearson, che dà più peso ai valori estremi, è più negativa di quella di Spearman. Nello spazio vale in media -0.12 ed è negativa nel 65% degli istanti, soprattutto in estate (-0.28 da giugno ad agosto); nel tempo ha mediana -0.25 ed è negativa nell'83% delle celle. Questo suggerisce che il legame riguardi i valori più alti di G, come verifica la Sezione 6.4: quando e dove il generatore sbaglia di più, il discriminatore tende a dare uno score più basso, cioè giudica l'osservazione meno insolita. La stessa sezione cerca di capire perché.

6.3 La normalizzazione climatologica

Il valore di G dipende anche da dove e quando è calcolato: dove l'errore è grande per natura, G segnala di più. La normalizzazione climatologica (Sezione 4.7) toglie questa differenza, esprimendo ogni score rispetto a ciò che è abituale per la stessa cella, lo stesso periodo dell'anno e la stessa ora; G così normalizzato è indicato con G_{n} (Tabella 6.1). Questa sezione verifica se la normalizzazione cambia il legame fra G e D della Sezione 6.2, e dove cadono le segnalazioni.

probabilmente un effetto del modello, che vicino al bordo completa il campo con zeri; il meccanismo non è verificato in dettaglio.

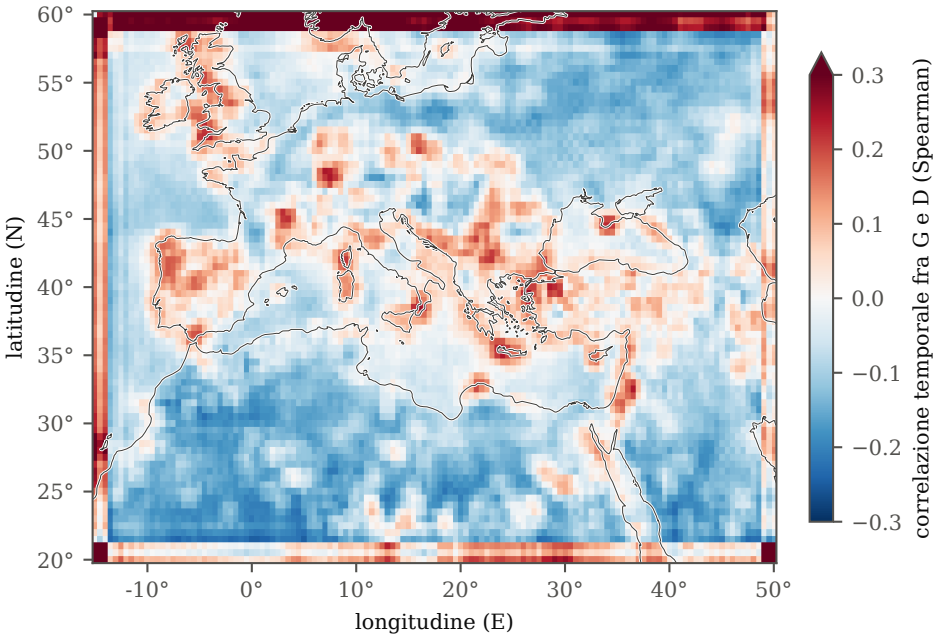


Figura 6.3: Correlazione temporale di Spearman fra G e D in ogni cella, sugli anni di validazione. Il blu indica che D scende quando G sale, il rosso che i due salgono insieme; la scala va da -0.3 a 0.3, e la freccia indica che alcune celle superano 0.3. La correlazione è vicina a zero quasi ovunque: è negativa in due celle su tre, soprattutto a sud, e positiva in molte celle fra 35° e 50°N. La cornice rossa lungo il bordo è probabilmente un effetto del modello. Linee di costa da Natural Earth.

Il legame fra G e D resta debole. Dopo la normalizzazione la correlazione di Spearman fra G e D vale in media 0.01 nello spazio e ha mediana -0.01 nel tempo: resta vicina a zero. Ciascuno score conserva quasi lo stesso ordine: la correlazione di Spearman fra lo score prima e dopo la normalizzazione è 0.91 per G e 0.89 per D, in media in ogni istante sulle celle.

Le segnalazioni di G diventano quasi uniformi. La normalizzazione cambia invece dove cadono le segnalazioni (Figura 6.4). Come nel resto del capitolo, un valore è segnalato quando supera la soglia del proprio score, il 95-esimo percentile dello stesso score sugli anni di validazione (Sezione 5.2): sugli stessi anni ciascuno score segnala quindi il 5% dei valori. Senza normalizzazione G segnala soprattutto a sud e in estate, dove il suo errore è alto per natura: la quota va dall'1.6% fra 50° e 60°N in dicembre all'11.1% fra 20° e 30°N in agosto. Con la normalizzazione resta fra il 3.7% e il 6.3% in ogni fascia e in ogni mese. È l'effetto atteso dalla Sezione 4.7: la normalizzazione toglie la differenza di prevedibilità fra luoghi e stagioni. La normalizzazione riduce le differenze fra luoghi e stagioni di circa tre quarti con il 5% e di circa tre quinti con l'1% (Sezione 6.10).

6.4 Che cosa giudica il discriminatore

Le sezioni precedenti mostrano che G e D sono quasi indipendenti, con un solo legame di segno costante: dove G è più alto, D tende a essere più basso. Questa sezione cerca di capire perché, scomponendo D nei suoi due termini, D_{reale} e D_{generato} (Tabella 6.1): D è alta quando il discriminatore giudica generata l'osservazione più della sua ricostruzione.

Quando G sale, entrambi i termini scendono. La correlazione temporale di Spearman fra G e D_{reale} ha mediana -0.73, quella fra G e D_{generato} ha mediana -0.69, ed entrambe sono negative in tutte le celle (Figura 6.5). Quando il generatore sbaglia di più, il discriminatore giudica più reali del consueto sia l'osservazione sia la sua ricostruzione.

I due termini si compensano. Poiché scendono insieme, i due termini sono legati fra loro, con una correlazione di Spearman mediana di 0.73. D è la loro differenza, e di questo movimento comune conserva solo una piccola parte: per questo il suo legame con G è debole. Nei valori più alti di G, però, D_{reale} scende un po' più di D_{generato}, e D scende: è il legame negativo che la correlazione di Pearson mette in luce nella Sezione 6.2.

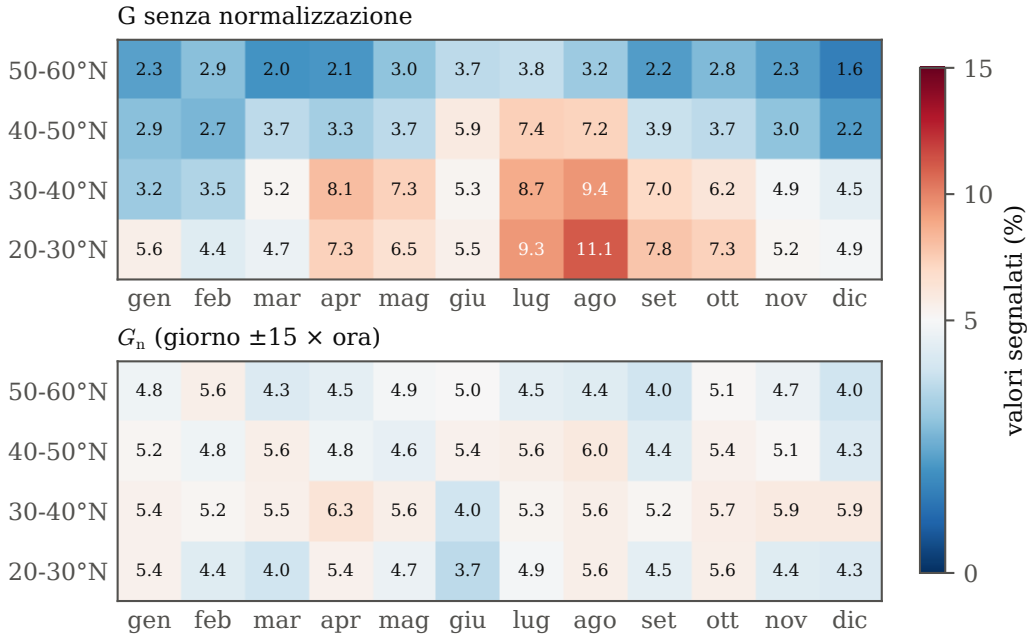


Figura 6.4: Quota dei valori segnalati, per fascia di latitudine e mese, sugli anni di validazione: G senza (in alto) e con (in basso) la normalizzazione climatologica, calcolata per cella, giorno dell'anno, con una finestra di ±15 giorni, e ora. La soglia di ciascuno score è il suo 95-esimo percentile sugli stessi anni. La scala dei colori non è lineare: il bianco corrisponde al 5%, il blu a quote minori, il rosso a quote maggiori. Senza normalizzazione le segnalazioni si concentrano a sud e in estate, con la normalizzazione sono distribuite in modo quasi uniforme.

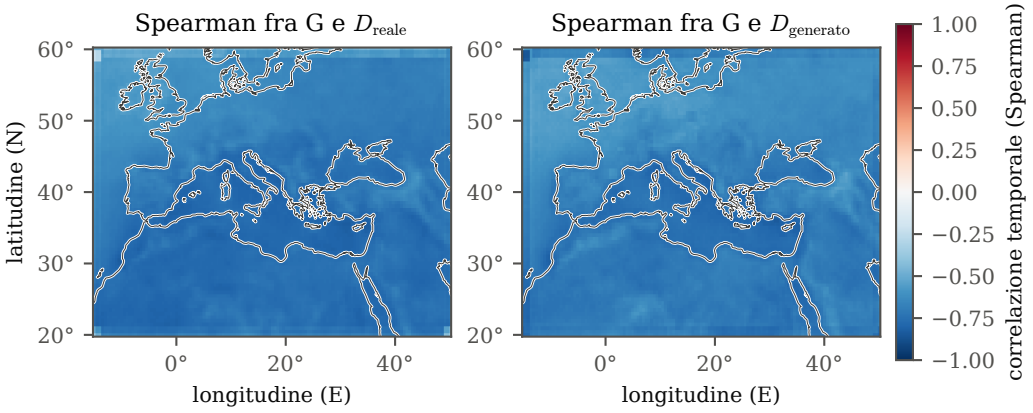


Figura 6.5: Correlazione temporale di Spearman, in ogni cella, fra G e il giudizio del discriminatore sull'osservazione, D_{reale} (a sinistra), e sulla ricostruzione, D_{generato} (a destra), sugli anni di validazione, su una scala da -1 a 1. Tutte le celle sono blu, con valori intorno a -0.7: in ogni luogo entrambi i giudizi scendono quando G sale. Linee di costa da Natural Earth.

Cluster di segnalazioni. Le correlazioni riguardano tutti i valori. Per vedere che cosa fa il discriminatore proprio dove G_{n} segnala, gli score sono letti attorno ai *cluster di segnalazioni* di G_{n}, o semplicemente cluster. Un cluster è un insieme di valori di G_{n} sopra la sua soglia, collegati nello spazio e nel tempo: due valori fanno parte dello stesso cluster se in un istante le loro celle si toccano, anche in diagonale, o se sono la stessa cella in due istanti consecutivi. Un cluster indica dove il detector segnala, non un'anomalia meteorologica: più anomalie vicine possono finire nello stesso cluster, e un cluster può non corrispondere ad alcuna anomalia. Sugli anni di validazione risultano 184877 cluster, con 7.7 milioni di valori in tutto, in media circa 42 valori per cluster.

Le zone e la misura. In ogni istante le celle sono divise in tre zone (Figura 6.6): il *nucleo*, le celle di un cluster; il *contorno*, le otto celle attorno a una cella del nucleo, le stesse della patch 3×3 letta dal discriminatore, escluse quelle del nucleo; e la zona *lontana*, le celle a più di tre celle da ogni nucleo. Le celle intermedie non sono considerate. Nucleo e contorno sono definiti dalle sole segnalazioni di G_{n}: indicano dove G_{n} segnala, non dove c'è davvero un'anomalia: senza un riferimento esterno non si può stabilire. In ciascuna zona ogni score è riassunto dal suo *percentile mediano*: per ogni valore si calcola a quale percentile sta fra tutti i valori dello stesso score sugli anni di validazione, da 0 (il più basso) a 100 (il più alto), e se ne prende

la mediana. In una zona senza legame con i cluster il percentile mediano sarebbe vicino a 50.

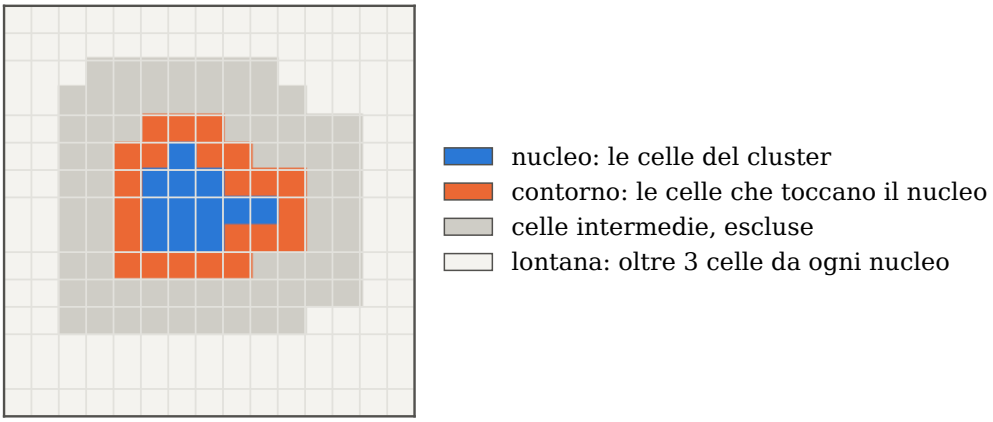


Figura 6.6: Le tre zone attorno a un cluster, in un istante, su una porzione della griglia: il nucleo, il contorno e la zona lontana; le celle intermedie non rientrano in nessuna. Ogni quadrato è una cella.

Dove G_{n} segnala, il discriminatore giudica reali l'osservazione e la ricostruzione. La Figura 6.7 riporta il risultato. Come riferimento è mostrato G senza normalizzazione, molto legato allo score che definisce il nucleo (correlazione di Spearman 0.91, Sezione 6.3), e quindi alto nel nucleo quasi per costruzione; nel contorno è alto in parte perché lo score di una cella è l'errore medio sulla sua patch 3×3, che contiene celle del nucleo. I due termini del discriminatore fanno il contrario, e questo non dipende dalla definizione delle zone: nel nucleo D_{reale} ha un percentile mediano di 5 e D_{generato} di 6, cioè sia le osservazioni segnalate da G_{n} sia le loro ricostruzioni sono giudicate più reali del consueto, anche se di poco in valore assoluto. Nel contorno restano bassi, con 12 e 15, anche perché il discriminatore legge la stessa patch; lontano dai cluster salgono a 58 e 57. In D i due effetti in parte si compensano, e nel nucleo il percentile mediano è 27.

Nel nucleo D si divide. Metà dei valori del nucleo ha D sotto il suo 27-esimo percentile, ma il 25.0% supera la soglia di D, contro il 2.9% della zona lontana: D segnala nel nucleo circa otto volte più che lontano dai cluster, ma solo in un valore su quattro; negli altri tre è basso. Il giudizio sull'osservazione va invece nel senso opposto: solo lo 0.5% dei valori del nucleo supera la soglia di D_{reale}, contro il 6.1% lontano dai cluster. Anche fra i valori segnalati da

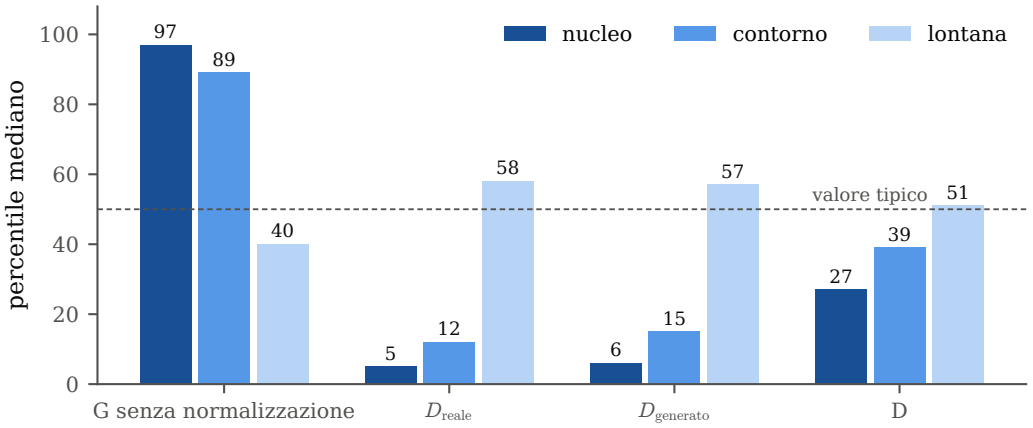


Figura 6.7: Percentile mediano di G senza normalizzazione, di D_{reale}, di D_{generato} e di D nel nucleo dei cluster di G_{n}, nel loro contorno e lontano da essi, sugli anni di validazione. La linea tratteggiata indica 50, il valore atteso senza legame con i cluster. G, alto nel nucleo quasi per costruzione, serve da riferimento. Nel nucleo D_{reale} e D_{generato} sono entrambi molto bassi, e D, la loro differenza, è al percentile 27.

G_{n} il legame è lo stesso: il terzo con D_{reale} più basso, cioè con l'osservazione giudicata più reale, è quello con G_{n} più alto, con una mediana di G_{n} di 7.0, circa il doppio della soglia di 3.4, contro 4.8 e 4.4 degli altri due terzi. Con una soglia più alta il comportamento è lo stesso e più marcato (Sezione 6.10).

Un esempio: l'istante con G più alto. La Figura 6.8 mostra i termini il 9 agosto 2003 alle 12 UTC, l'istante con la media di G più alta della validazione. Nell'area principale del Nord Africa in cui G è alto, D_{reale} è vicino a zero, con una mediana di 0.07, e anche D_{generato} è fra i valori più bassi dell'istante, con una mediana di 0.19: il discriminatore giudica reali sia l'osservazione sia la ricostruzione, l'osservazione di più, e D è fra i valori più bassi del dominio. Su un'area più piccola più a sud-ovest, anch'essa con G alto, il giudizio sull'osservazione è meno netto (D_{reale} ha una mediana di 0.15), ma anche lì D è basso. D_{reale} è basso anche nella penisola arabica, dove G è intorno al 94-esimo percentile dell'istante.

Le ricostruzioni non sono più lisce delle osservazioni. Una spiegazione possibile del comportamento di D è che il discriminatore riconosca le ricostruzioni dal loro aspetto più liscio: in letteratura i modelli addestrati con un errore quadratico [19, 20], come in parte il generatore della tesi, e le ricostruzioni di un autoencoder variazionale [25] producono campi troppo

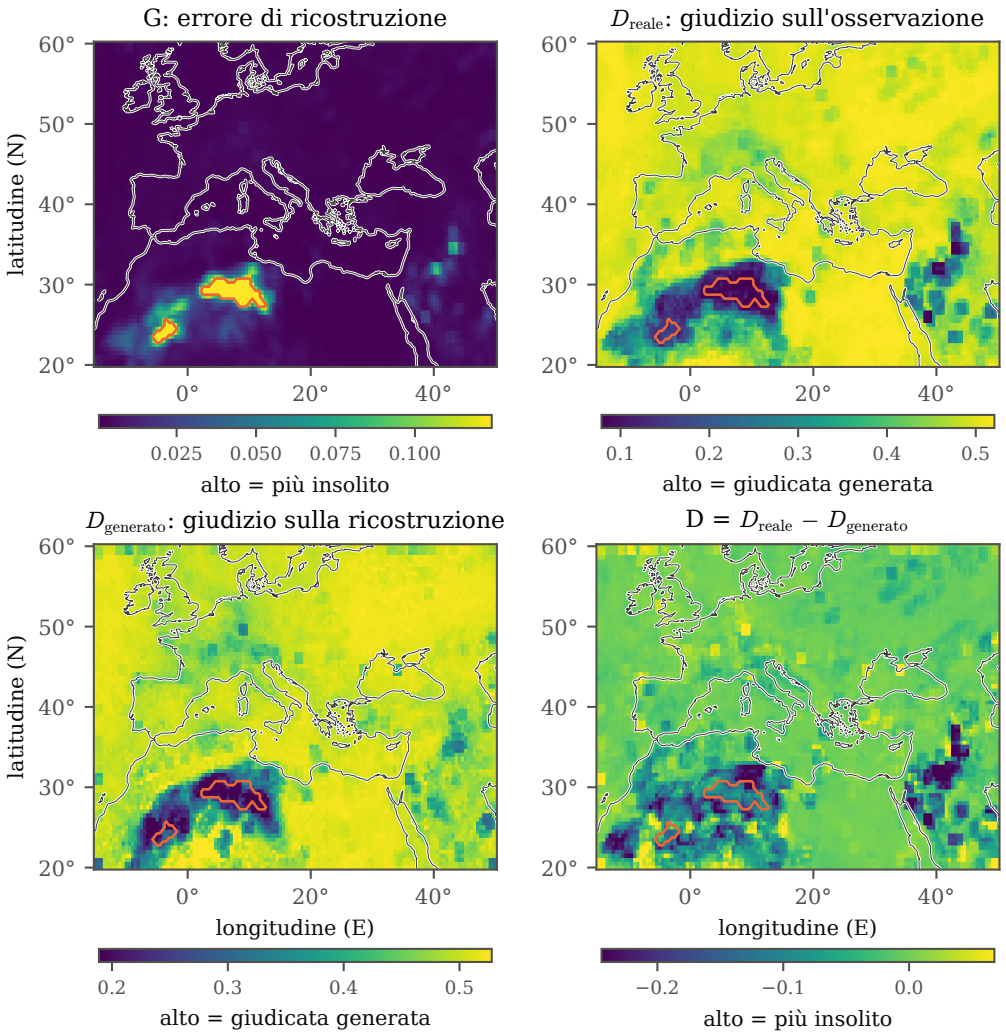


Figura 6.8: G, D_{reale}, D_{generato} e D il 9 agosto 2003 alle 12 UTC, l'istante con la media di G più alta degli anni di validazione. La linea arancione racchiude l'1% delle celle con G più alto nell'istante; ogni mappa ha una propria scala, dal primo al 99-esimo percentile dei suoi valori. Dentro la linea D_{reale}, D_{generato} e D sono fra i valori più bassi (colori scuri): osservazione e ricostruzione sono giudicate reali, e D è basso. Linee di costa da Natural Earth.

regolari e smussano gli estremi. L'ipotesi è messa alla prova su 240 istanti della validazione (Tabella 6.2), misurando la rugosità, cioè la differenza quadratica media fra celle adiacenti; il modello è usato senza dropout, perché il giudizio non cambi con la maschera di dropout. Le ricostruzioni non sono però più lisce delle osservazioni: la loro rugosità è in mediana 1.10 volte quella osservata, ed è minore solo nel 22% degli istanti. La levigatezza della ricostruzione non spiega quindi il comportamento di D.

Tabella 6.2: Rugosità e giudizio medio del discriminatore sull'osservazione, sulla ricostruzione e sulle loro versioni lisciate con la media della patch 3×3: mediane su 240 istanti degli anni di validazione, con il modello senza dropout. Un giudizio più alto significa "più generato". Ricostruzione e osservazione hanno una rugosità simile; lisciare un campo ne riduce molto la rugosità e alza un poco il giudizio.

Campo	Rugosità	Giudizio del discriminatore
Osservazione	0.00082	0.502
Ricostruzione	0.00089	0.502
Osservazione lisciata	0.00021	0.512
Ricostruzione lisciata	0.00019	0.513

Una lettura: i campi rugosi sono giudicati reali. La stessa verifica suggerisce un'altra lettura. Lisciando l'osservazione con la media della sua patch 3×3, il discriminatore la giudica più generata nel 99% delle celle, e nel 99.6% di quelle con G più alto. La rugosità locale ordina il giudizio sulle osservazioni: la correlazione di Spearman mediana fra le due è -0.61, negativa in tutti gli istanti, cioè le celle più rugose sono giudicate più reali. Le stesse celle tendono ad avere anche G alto, con una correlazione mediana di 0.49: dove il campo è rugoso, il generatore tende a sbagliare di più. Coerentemente, nei 240 istanti il giudizio sull'osservazione vale in media 0.45 nel 5% più alto di G, contro 0.50 su tutte le celle. La rugosità potrebbe quindi spiegare in parte perché, dove G segnala, il discriminatore giudica reali le osservazioni. È una lettura di correlazioni, non una prova: il lisciamento, per esempio, riduce anche i valori più estremi, un effetto che la verifica non separa.

6.5 Conferma sul test e scelta dello score

Le Sezioni 6.2–6.4 riguardano gli anni di validazione, su cui si sceglie lo score. Questa sezione verifica che i loro risultati valgano anche sugli anni di test e fissa la scelta.

Sugli anni di test i risultati sono gli stessi. Le stesse analisi, ripetute sugli anni di test 2005–2025 con la climatologia e le soglie stimate sulla validazione, danno gli stessi risultati (Tabella 6.3): le correlazioni cambiano di al più tre centesimi, i percentili mediani di al più quattro punti. Sul test G_{n} segnala il 5.5% dei valori, un po' più del 5%, probabilmente perché negli anni di test l'errore del generatore è in media un po' più alto; per lo stesso motivo le quote per luogo arrivano al 7.8%.

Tabella 6.3: Le principali misure delle Sezioni 6.2–6.4 sugli anni di validazione, dove si sceglie lo score, e sugli anni di test. Sul test climatologia e soglie sono quelle stimate sulla validazione. Fra parentesi, la correlazione di Pearson.

Misura	Validazione	Test
Correlazione spaziale di Spearman fra G e D, media	0.015	−0.001
Correlazione temporale di Spearman fra G e D, mediana	−0.05	−0.07
Correlazione temporale fra G e D_{generato}, mediana	−0.69	−0.69
Correlazione temporale fra G e D_{reale}, mediana (Pearson)	−0.73 (−0.77)	−0.73 (−0.75)
Cluster di G_{n}	184877	794206
Percentile mediano nel nucleo: D_{reale}, D_{generato}, D	5, 6, 27	5, 6, 23
D_{reale} sopra la propria soglia: nucleo, lontano	0.5%, 6.1%	0.5%, 6.2%
Quota per luogo di G_{n}	3.7–6.3%	3.6–7.8%
Rugosità della ricostruzione rispetto all'osservazione, mediana dei rapporti	1.10	1.08
Celle del 5% più alto di G in cui D_{reale} sale lisciando l'osservazione	99.6%	99.6%

D non porta un'informazione stabile e coerente con G. Su validazione e test il quadro è lo stesso. Dove G_{n} segnala, il discriminatore giudica reali sia l'osservazione sia la ricostruzione, e i due giudizi si compensano. D segue quindi G solo in una parte dei valori: nel nucleo dei cluster un quarto supera la soglia di D, ma tre quarti no, e su tutti i valori il legame fra i due è debole e cambia segno con la stagione e con il luogo (Sezione 6.2). Senza etichette questo disaccordo, da solo, non dice quale delle due componenti abbia ragione.

Lo score combinato dell'articolo è, di fatto, D. Lo score di STGAN somma le due componenti dopo averle riportate su una scala comune (Sezione 4.6). Sugli anni di validazione ordina i valori quasi come D e poco come G: la correlazione di Spearman con D è 0.99 sia nello spazio sia nel tempo,

quella con G è 0.13 nello spazio e 0.07 nel tempo, e con la normalizzazione climatologica i valori restano quasi gli stessi (0.99 con D, 0.12 e 0.10 con G). Anche le segnalazioni sono quelle di D: il 94% dei valori segnalati dallo score combinato è segnalato anche da D, solo il 32% anche da G_{n}, e all'1% le quote sono 93% e 19%. Usare lo score dell'articolo vorrebbe dire, quindi, usare il discriminatore.

Lo score del detector è G_{n}. La scelta poggia sul significato delle due componenti. G ha un significato chiaro: misura quanto un campo si allontana da ciò che il modello si aspetta. D dipende anche dal giudizio sulla ricostruzione, e il suo comportamento si spiega solo in parte. Sommarle, come nel metodo originale, darebbe di fatto D, come mostra il paragrafo precedente. Il detector usa quindi G_{n}, lo score di ricostruzione ζ della Sezione 4.7, che distribuisce le segnalazioni in modo quasi uniforme fra luoghi e stagioni (Sezione 6.3).

6.6 Confronto con le baseline

Le sezioni precedenti scelgono lo score del detector, G_{n}; questa ne confronta le segnalazioni con quelle di metodi più semplici, le baseline. È un controllo di coerenza, come raccomandato da Wu e Keogh (Sezione 2.1.5), e non una misura di accuratezza: senza etichette l'accordo non dice quale rilevatore abbia ragione, e due rilevatori possono concordare ed entrambi sbagliare. Serve a vedere quali segnalazioni del detector si ottengono anche senza un modello profondo, e quali no.

I metodi. Le baseline sono otto (Tabella 6.4). Sei sono modelli shallow, scelti fra i metodi statistici valutati in TSB-AD [17], con i valori predefiniti della libreria PyOD: leggono una cella in un istante, cioè il vettore delle sue quindici variabili, senza le celle attorno né gli istanti prima: in questo senso leggono il punto. Ciascuno è stimato una sola volta, su 200000 vettori estratti da 2000 istanti a caso degli anni di addestramento. Le altre due sono rilevatori semplici, che non richiedono un modello. La *distanza dal normale* è l'errore che si commetterebbe rispondendo, in ogni cella, con il valore normale per quel giorno e quell'ora: misura lo scostamento dal clima. La *variazione in tre ore* è l'errore che si commetterebbe rispondendo con il valore dell'istante precedente: misura il cambiamento rapido. Nei due errori le variabili hanno gli stessi pesi dell'errore di ricostruzione (Sezione 4.4). Sono le stesse due distanze con cui la Sezione 4.5 individua i valori esclusi della validazione; qui sono usate come score, ciascuna con la propria soglia. Nessuna delle otto baseline legge le celle vicine: G_{n} è l'unico rilevatore che usa lo spazio.

Tabella 6.4: I rilevatori confrontati e ciò che leggono di ogni valore. Le descrizioni dei modelli shallow seguono TSB-AD. Per COPOD le distribuzioni di riferimento sono stimate solo sul campione di addestramento, così che lo score di un valore non dipenda dagli altri valori valutati con esso.

Rilevatore	Legge	Score
Distanza dal normale	il punto	errore della risposta "normale stagionale per quel giorno e quell'ora"
PCA	il punto	distanza dal centro lungo le componenti principali, ciascuna divisa per la quota di varianza che spiega
CBLOF	il punto	distanza dal centro del proprio gruppo (8 gruppi), o del gruppo grande più vicino se il proprio è piccolo
MCD	il punto	distanza dal centro dei dati che tiene conto di come le variabili variano insieme (distanza di Mahalanobis con stime robuste)
HBOS	il punto	quanto sono rari i valori della cella, variabile per variabile, letti da un istogramma (10 intervalli)
COPOD	il punto	probabilità di coda di ogni variabile, dalle distribuzioni empiriche
Isolation Forest	il punto	brevità del percorso che isola il valore in 100 alberi casuali, di 256 valori ciascuno
Variazione in tre ore	il tempo	errore della risposta "valore di tre ore prima"
G_{n}	spazio e tempo	errore del generatore (Sezioni 4.6 e 4.7)

Il confronto. Ogni rilevatore è trattato come il detector: il suo score è espresso rispetto alla propria climatologia per cella, giorno dell'anno e ora (Sezione 4.7), e la sua soglia è il 95-esimo percentile dello stesso score sugli anni di validazione. Il confronto non serve a scegliere lo score, e riguarda gli anni di test 2005–2025: 651 milioni di valori, con ogni rilevatore che ne segnala fra il 5.1% e il 5.6% (Tabella 6.5). Se due rilevatori segnalano gli insiemi di valori A e B, la quota delle segnalazioni di A condivise con B è $|A \cap B|/|A|$; l'indice di Jaccard,

$$J(A, B) = \frac{|A \cap B|}{|A \cup B|}, \tag{6.1}$$

vale 1 quando i due insiemi coincidono e 0 quando sono disgiunti. Due rilevatori indipendenti condividerebbero circa il 5% delle segnalazioni, con un indice di Jaccard di circa il 3%.

Tabella 6.5: Segnalazioni dei rilevatori sugli anni di test, con la soglia di ciascuno al 95-esimo percentile del proprio score sulla validazione. "Segnalati": quota dei valori che il rilevatore segnala. "Da solo": quota delle sue segnalazioni che nessun altro segnala. "Di G_{n}": quota delle segnalazioni di G_{n} segnalate anche dal rilevatore, che dà l'ordine della tabella. "Jaccard": indice di Jaccard con G_{n}.

Rilevatore	Segnalati	Da solo	Di G_{n}	Jaccard
Variazione in tre ore	5.48%	31.8%	53.9%	37.2%
MCD	5.43%	7.9%	52.1%	35.7%
PCA	5.31%	0.6%	48.7%	33.1%
Isolation Forest	5.17%	4.1%	44.0%	29.4%
CBLOF	5.41%	7.7%	43.4%	28.2%
COPOD	5.16%	6.9%	43.4%	29.0%
Distanza dal normale	5.62%	14.0%	40.8%	25.4%
HBOS	5.14%	9.5%	39.2%	25.5%
G_{n}	5.54%	18.1%	–	–

I metodi che leggono il punto concordano fra loro. La Figura 6.9 riporta l'indice di Jaccard di ogni coppia. I sei modelli shallow e la distanza dal normale formano un gruppo, con valori fra il 35% e il 63%: leggono lo stesso vettore, e tutti misurano quanto è lontano da ciò che è abituale. La variazione in tre ore resta da parte, con valori fra il 17% e il 26%: segnala soprattutto altri valori.

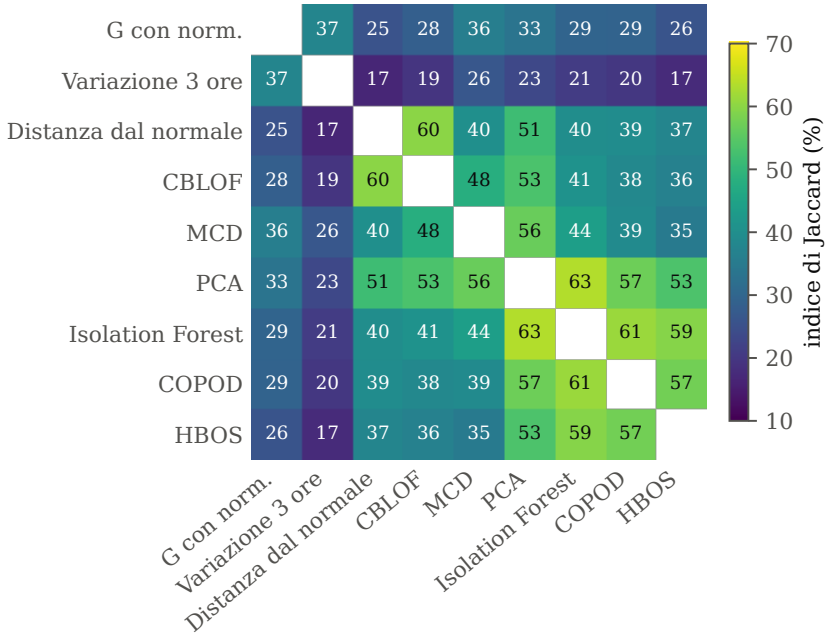


Figura 6.9: Indice di Jaccard delle segnalazioni di ogni coppia di rilevatori sugli anni di test, in percentuale, con la soglia di ciascuno al 95-esimo percentile del proprio score sulla validazione. I metodi che leggono il punto formano un gruppo, la variazione in tre ore resta da parte, e G_n si sovrappone a entrambi.

G si sovrappone a entrambi. Il 54% delle segnalazioni di G_{n} è segnalato anche dalla variazione in tre ore, e fra il 39% e il 52% da ciascuno dei metodi che leggono il punto, contro il 5% atteso fra rilevatori indipendenti. Il rilevatore più vicino alla variazione in tre ore è G_{n}, con un indice di Jaccard del 37%; fra gli altri il più vicino è MCD, con il 26%. Il risultato è coerente con la definizione di G: il generatore risponde a partire dagli istanti precedenti, quindi il suo errore può crescere sia quando un valore si allontana dal consueto sia quando cambia in fretta. L'accordo da solo non dimostra però questo meccanismo. Nessun singolo metodo semplice riproduce le segnalazioni di G_{n}: il più vicino ne condivide poco più della metà.

Il voto a maggioranza. Il 4.22% dei valori è segnalato da almeno cinque rilevatori su nove, e il 48.3% delle segnalazioni di G_{n} è condiviso da questa maggioranza. Sette rilevatori su nove leggono il punto, quindi il voto misura soprattutto quanto si è vicini a quel gruppo, non quale rilevatore sia migliore.

Le segnalazioni del solo G_{n}. Il 18.1% delle segnalazioni di G_{n} non è segnalato da nessun altro rilevatore, circa l'1% di tutti i valori; l'81.9% è quindi segnalato anche da almeno un altro, contro circa il 14% atteso se G_{n} fosse indipendente da loro: tanti sono i valori segnalati da almeno uno degli altri otto. La quota esclusiva di G_{n} è intermedia: è il 31.8% per la variazione in tre ore, il 14.0% per la distanza dal normale, meno del 10% per i modelli shallow. Una quota esclusiva non è di per sé un pregio: può indicare ciò che solo il generatore coglie, per esempio perché legge le celle vicine, oppure un suo errore. Il confronto non permette di distinguere i due casi.

La stabilità dei modelli shallow. I modelli shallow dipendono dal campione su cui sono stimati. Per verificarlo sono stati stimati altre tre volte, e le segnalazioni sono confrontate sulla validazione: con un campione cinque volte più grande, con un altro seme e con un campione cento volte più grande, di 20 milioni di vettori presi da tutti gli istanti di addestramento, al più 350 celle per istante. Tutti i vettori degli anni di addestramento, circa 620 milioni, non sono stati usati per motivi di memoria: la sola matrice dei dati occuperebbe circa 74 GB. PCA, MCD e COPOD non cambiano, con un indice di Jaccard fra il 98% e il 99% anche con il campione più grande. CBLOF dipende dalla dimensione del campione: con un altro seme l'indice è dell'86%, con il campione più grande del 58%. Isolation Forest e HBOS cambiano anche con il solo seme, e il campione più grande non li cambia di più: Isolation Forest con sé stesso arriva al 70–72%, HBOS al 52–58%. Il 25.5% fra G_{n} e HBOS va quindi confrontato con questo valore, non con il 100%. L'accordo

di G_{n} con la variazione in tre ore, MCD e PCA non ne risente, perché la variazione in tre ore non dipende da un campione, e MCD e PCA sono stabili.

Sintesi. I metodi che leggono il punto segnalano in larga parte gli stessi valori, la variazione in tre ore ne segnala altri, e G_{n} si sovrappone a entrambi senza coincidere con nessuno. Oltre otto segnalazioni di G_{n} su dieci sono segnalate anche da almeno una baseline, contro circa il 14% atteso se G_{n} fosse indipendente da loro. Questo sostiene la coerenza del detector, ma non ne misura l'accuratezza.

6.7 Cluster di segnalazioni per tipo e dimensione

Scelto lo score, resta da descrivere che cosa segnala: quanto sono grandi i cluster, quali variabili vi si scostano di più e come cala G_{n} attorno a ciò che segnala. Le segnalazioni sono raggruppate nei cluster della Sezione 6.4: sugli anni di test se ne contano 794206, con 36.1 milioni di valori, dove un valore è, come nel resto del capitolo, una cella in un istante. Come livello di riferimento, le stesse misure sono ripetute sui cluster che ciascuna delle otto baseline della Sezione 6.6 forma con le proprie segnalazioni, anch'esse al 5% con la soglia stimata sulla validazione (Tabella 6.6). Le baseline leggono ogni cella da sola e non dipendono dal modello addestrato.

Pochi cluster enormi contengono circa tre quarti dei valori. La dimensione di un cluster è il numero dei suoi valori. Il 91% dei cluster ha meno di 20 valori, e insieme contengono solo il 7% dei valori segnalati; lo 0.5% dei cluster, quelli con almeno 1000 valori, ne contiene il 75% (Figura 6.10). Le baseline formano più cluster minuscoli: fra il 94.7% e il 97.1% dei loro cluster ha meno di 20 valori, contro il 90.6% di G_{n}, le cui segnalazioni sono quindi più raggruppate.

Il tipo di cluster. Il tipo di un cluster è la variabile d'ingresso più lontana dal proprio normale stagionale, in media sul nucleo: dice quale variabile si scosta di più, non di quale anomalia meteorologica si tratti, e le variabili con valori molto estremi, come la precipitazione, possono risultare più spesso le più lontane. La velocità verticale e la precipitazione raccolgono da sole il 61% dei valori segnalati di G_{n}; segue, molto distante, la copertura nuvolosa, con il 7% (Figura 6.11). Il tipo dominante dipende dal metodo. La variazione in tre ore ha quasi gli stessi tipi di G_{n}, con velocità verticale e precipitazione

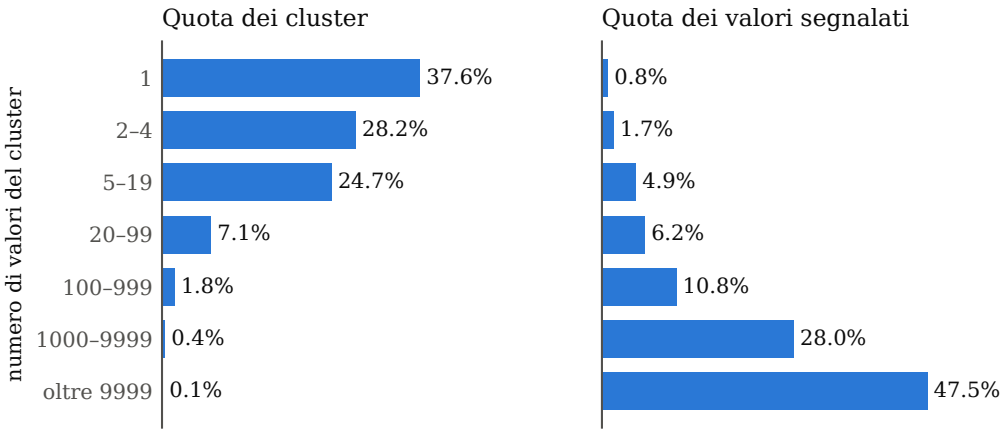


Figura 6.10: I cluster di G_{n} sugli anni di test, per numero di valori: quota dei cluster (a sinistra) e quota dei valori segnalati che contengono (a destra). I cluster sono quasi tutti piccoli, ma circa tre quarti dei valori stanno in pochi cluster enormi.

Tabella 6.6: I cluster di G_{n} e quelli di ciascuna baseline della Sezione 6.6, ognuno formato dalle proprie segnalazioni, sugli anni di test, con la soglia di ciascun metodo al 95-esimo percentile del proprio score sulla validazione. "Cluster < 20": quota dei cluster con meno di 20 valori. "Valori in cluster ≥ 1000": quota dei valori segnalati che sta nei cluster con almeno 1000 valori. "1, 2, 6 fuori": percentile mediano dello score a una, due e sei celle fuori dal bordo dei propri cluster. I tipi sono nella Figura 6.11.

Metodo	Cluster	Cluster < 20	Valori in cluster ≥ 1000	1 fuori	2 fuori	6 fuori
G_{n}	794 k	90.6%	75.5%	90	79	50
Distanza dal normale	768 k	95.1%	85.6%	87	73	47
Variazione in tre ore	2.80 M	96.5%	60.2%	84	64	41
PCA	1.16 M	95.8%	79.4%	88	75	47
MCD	1.73 M	96.4%	73.7%	87	70	43
CBLOF	980 k	95.3%	81.5%	87	71	45
COPOD	697 k	94.7%	84.5%	91	82	56
HBOS	1.58 M	97.1%	78.1%	88	76	48
Isolation Forest	1.19 M	96.0%	79.0%	89	77	49

al 65% dei valori e la copertura nuvolosa al terzo posto. Nella distanza dal normale e in CBLOF il tipo principale è l'umidità del suolo, con il 64% e il 41% dei valori: è una variabile che cambia lentamente e forma cluster lunghi. In COPOD e HBOS è la velocità di attrito, con il 22%, seguita dallo strato limite. Negli shallow, in generale, i valori sono divisi fra più tipi.

I cluster più grandi sono catene. Due valori fanno parte dello stesso cluster se si toccano, nello spazio o nel tempo. Quando è segnalato il 5% dei valori, segnalazioni dovute ad anomalie diverse possono toccarsi e unirsi in un solo cluster; i più grandi durano settimane: il più grande di precipitazione dura 40 giorni, quello di velocità verticale 23, e in quasi tutti i loro istanti contano centinaia di celle, con una mediana rispettivamente di 472 e 723. Un cluster così lungo difficilmente corrisponde a un'unica anomalia: è piuttosto una catena, cioè una successione di gruppi di segnalazioni, ciascuno a contatto con il seguente, e la sua dimensione dice quanto si estende la catena. Le catene non sono una particolarità di G_{n}: in tutti i metodi i cluster con almeno 1000 valori contengono fra il 60% e l'86% dei valori segnalati (Tabella 6.6). Sono quindi soprattutto un effetto della quota segnalata e del modo in cui le segnalazioni sono collegate.

Le zone su una mappa. Resta da vedere se G_{n} distingue da solo il centro di ciò che segnala, il contorno e ciò che non segnala. La Figura 6.12 mostra le zone della Sezione 6.4 in un istante: G_{n} è più alto nel nucleo, sfuma nel contorno e nella zona lontana è basso in mediana (42 in questo istante, Tabella 6.7).

G cala in modo graduale. Una mappa è un solo esempio. La Figura 6.13 riassume tutti gli anni di test: per ogni cella si conta a quante celle sta dal bordo del cluster più vicino, verso l'interno o verso l'esterno, e si legge il percentile mediano dello score sugli stessi anni, dove 100 è il valore più alto e 50 un valore tipico. La prima cella dentro è l'ultima del nucleo; la prima fuori è il contorno. Che le celle segnalate stiano sopra la soglia e le altre sotto è vero per costruzione; il risultato è la forma della curva. Una cella dentro il bordo G_{n} vale 96, una cella fuori 90, due celle fuori 79, tre celle fuori 68, e torna a un valore tipico dopo circa sei celle, cioè tre gradi, circa 300 km. Oltre scende ancora, perché lontano dai cluster restano soprattutto i valori bassi. G_{n} distingue quindi centro, contorno ed esterno in modo graduale, senza un confine proprio: la soglia taglia una curva continua. Le baseline, ciascuna sui propri cluster, hanno la stessa forma, ma quasi tutte calano più in fretta: due celle fuori G_{n} vale 79, le baseline fra 64 (variazione in tre ore) e 77 (Isolation

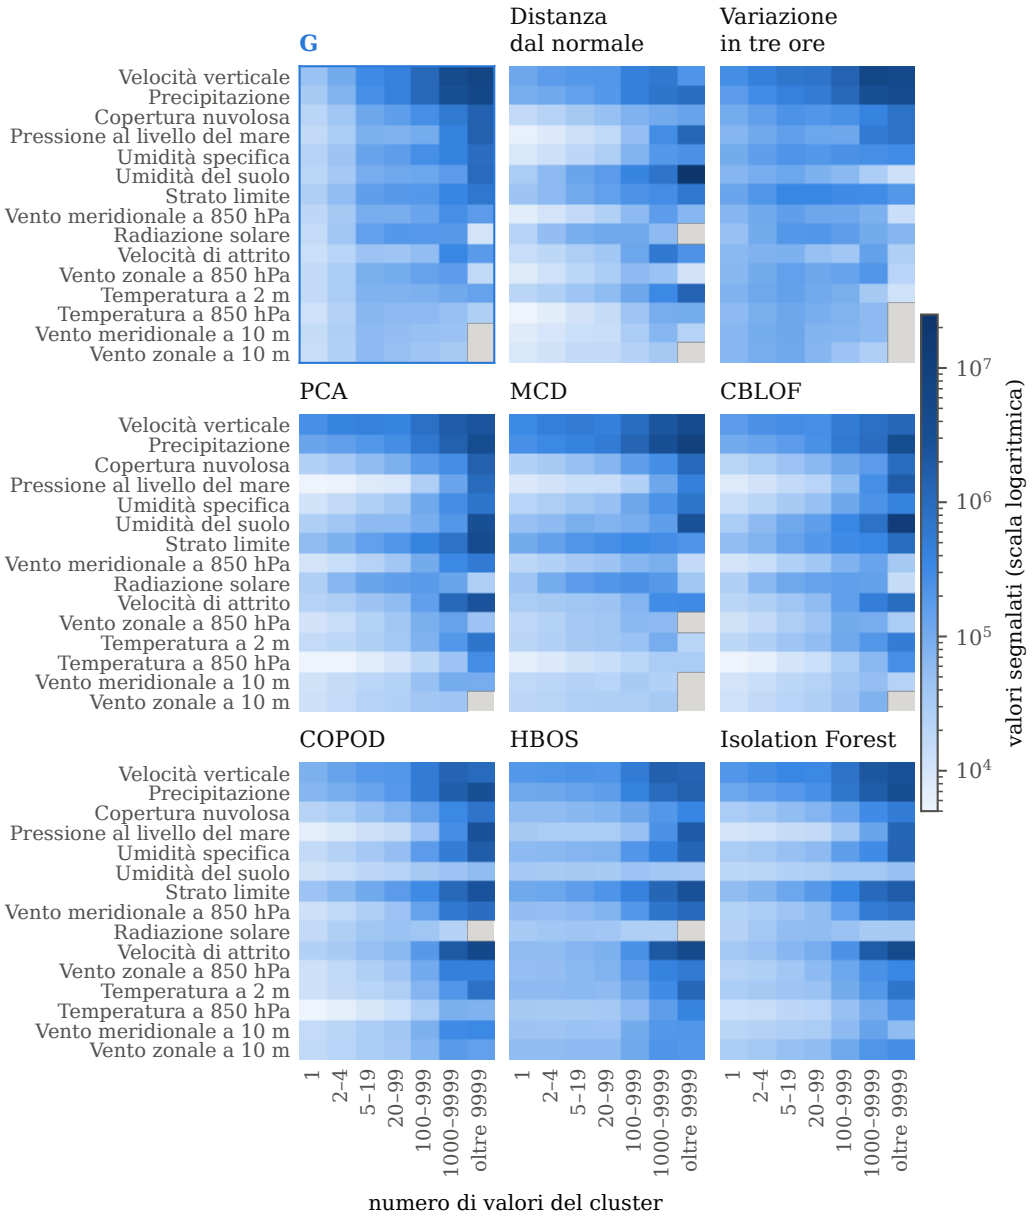


Figura 6.11: Valori segnalati sugli anni di test, per tipo di cluster e numero di valori del cluster: nei cluster di G_n (in alto a sinistra, bordato) e in quelli di ciascuna baseline, ognuno formato dalle proprie segnalazioni. Più il colore è scuro, più i valori sono numerosi; la scala è logaritmica e comune a tutti i pannelli. Le caselle grigie non contengono cluster; i tipi sono nell'ordine di G_n. In G_n e nella variazione in tre ore dominano velocità verticale e precipitazione, nella distanza dal normale e in CBLOF l'umidità del suolo.

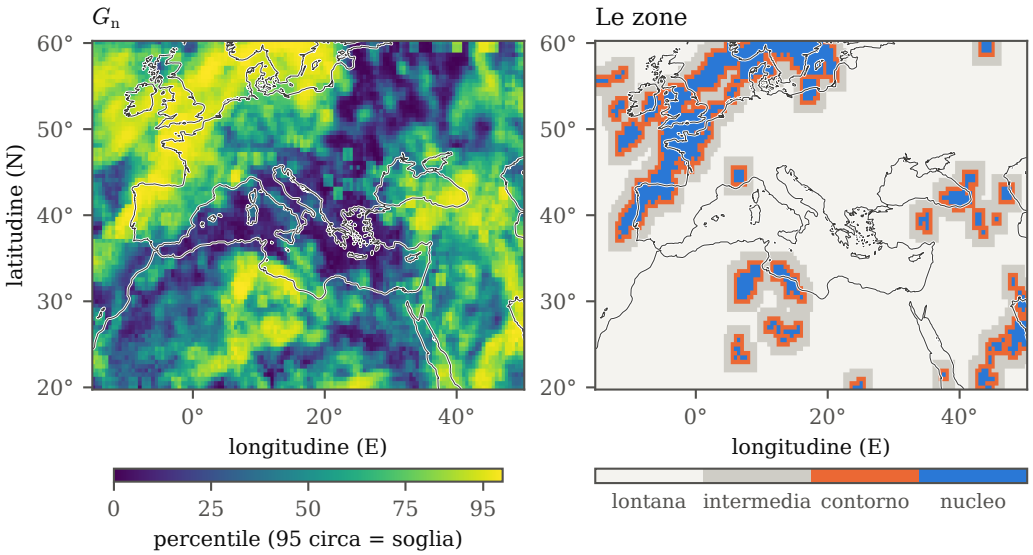


Figura 6.12: G con la normalizzazione (a sinistra) e le sue zone (a destra) il 23 novembre 2017 alle 00 UTC. Il nucleo è fatto delle celle sopra la soglia, il contorno delle otto celle attorno, la zona lontana delle celle a più di tre celle da ogni nucleo; le celle intermedie stanno fra le ultime due. È l'istante dell'esempio di velocità verticale della Sezione 6.7.1. Linee di costa da Natural Earth.

Forest); solo COPOD, con 82, è simile a G_{n}. A sei celle tutti i metodi sono fra 41 e 56. Per G_{n} parte della gradualità vicino al bordo dipende dalla patch 3×3 su cui lo score è mediato, che le baseline, lette cella per cella, non hanno. Il nucleo, inoltre, è sottile: il 67% dei valori segnalati sta sul suo bordo, a una sola cella dall'esterno.

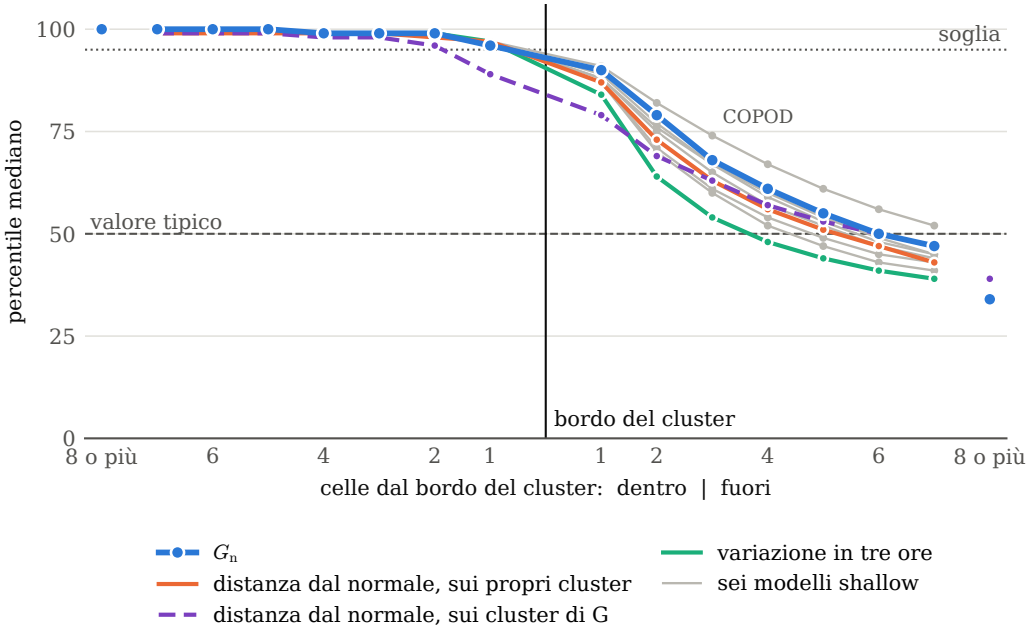


Figura 6.13: Profilo attraverso i cluster, sugli anni di test, con la soglia di ciascun metodo al 95-esimo percentile del proprio score sulla validazione: percentile mediano dello score secondo le celle di distanza dal bordo del cluster più vicino, per G_{n} e per ciascuna baseline, ognuna sui propri cluster. I sei modelli shallow sono in grigio. Che le celle dentro stiano sopra la soglia e quelle fuori sotto è per costruzione. Tutti i metodi tornano verso un valore tipico dopo circa sei celle; G_{n} cala più gradualmente di quasi tutte le baseline. Per G_{n} è riportato anche il punto a 8 o più celle dal bordo. La linea viola tratteggiata è la distanza dal normale letta sui cluster di G_{n} invece che sui propri.

Anche la distanza dal normale segue il profilo di G_{n}. Letta sui cluster di G_{n} invece che sui propri, la distanza dal normale non giudica G_{n}: dice quanto erano lontani dal clima i dati dove G_{n} segnala. È la linea viola tratteggiata della Figura 6.13; la linea arancione continua segue invece i cluster della distanza dal normale stessa. La linea tratteggiata ha lo stesso

andamento di G_n: 99–100 nelle celle più interne, 89 una cella dentro il bordo, 79 una cella fuori, 50 dopo sei celle. Anche dentro il nucleo continua a salire verso l'interno, da 89 a 96 in una sola cella, e questo non dipende dal taglio della soglia. Che le due grandezze salgano insieme mostra che le segnalazioni non cadono a caso, non che siano giuste.

Insolito, ma non sempre estremo. Nel nucleo solo il 41% dei valori supera la soglia della distanza dal normale, contro il 16% nel contorno e il 2% nella zona lontana. Il restante 59% resta sotto quella soglia: G_n segnala anche valori che, presi uno per uno, non sono fra i più lontani dal clima. In parte è atteso, perché i due score misurano cose diverse. Anche la dimensione conta: il percentile mediano della distanza dal normale nel nucleo va da 79–80 nei cluster con meno di 20 valori a 95 in quelli con più di 9999, quindi i cluster piccoli sono i meno estremi.

Per tipo di cluster, G_n è simile, le variabili no. Vicino al bordo G_n è quasi uguale per tutti i tipi: una cella fuori vale fra 89 e 91. Più lontano si separa di poco: a sei celle va da 43 per la radiazione solare a 58 per la pressione. Le differenze grandi riguardano invece lo *scarto* della variabile del tipo (Figura 6.14). A differenza della distanza dal normale, che riassume tutte le variabili di una cella, lo scarto riguarda una sola variabile: dice di quante volte la sua variabilità abituale, per quel luogo e periodo, essa si allontana dal normale, in valore assoluto. La variabile del tipo è per definizione la più lontana dal normale nel nucleo: è in parte atteso che lì lo scarto sia alto e fuori scenda, e il confronto utile è fra i tipi. Per precipitazione, copertura nuvolosa e radiazione solare lo scarto torna vicino ai valori di fondo entro due celle dal bordo: per la precipitazione scende da 1.33 nell'ultima cella del nucleo a 0.48 due celle fuori, per la copertura nuvolosa da 1.62 a 0.52. La velocità verticale scende più lentamente, da 1.38 a 0.78. Per la temperatura a 2 m resta alto a lungo: a sette celle fuori lo scarto è ancora 1.33. La pressione e la temperatura a 850 hPa, fra le curve grigie, si comportano allo stesso modo, con 1.38 e 1.58 a sette celle; i venti e l'umidità specifica stanno in mezzo. Lo scarto mediano non è mai zero: a otto o più celle dal bordo vale 0.42 per la precipitazione e 0.98 per la pressione, e questi sono i valori di fondo.

Il risultato è coerente con il modo in cui queste variabili cambiano nello spazio, anche se la verifica non lo dimostra: precipitazione e nuvole possono cambiare da una cella all'altra, mentre temperatura e pressione variano su aree più ampie. Nel primo gruppo il nucleo di G_n racchiude lo scostamento. Nel secondo lo scostamento continua oltre il nucleo: G_n ne segnala solo una parte, e le celle attorno, pur lontane dal normale, restano sotto la sua soglia.

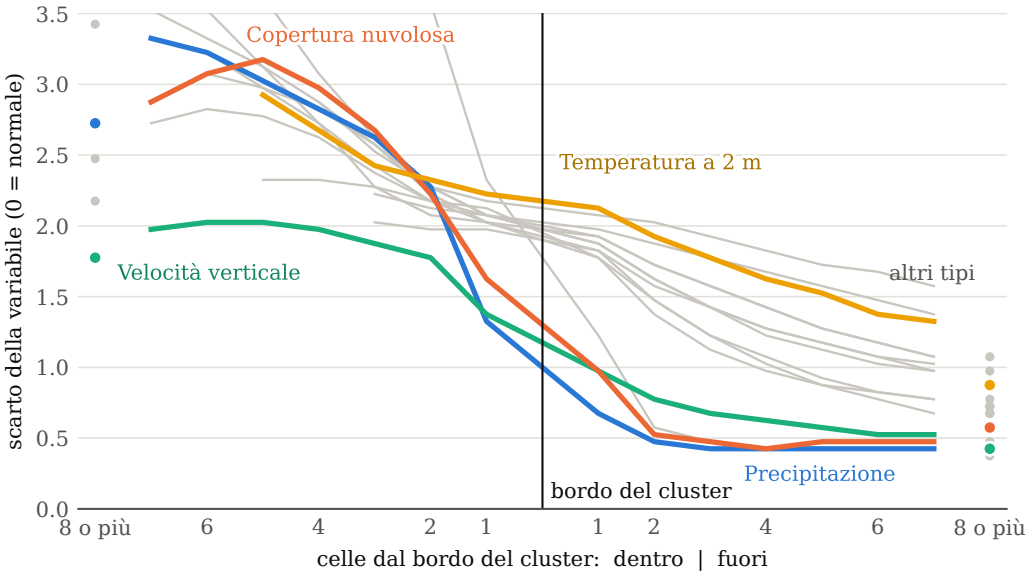


Figura 6.14: Per ogni tipo di cluster, scarto mediano della variabile che dà il nome al tipo, secondo le celle di distanza dal bordo del cluster, sugli anni di test: 0 è il valore normale, 1 uno scostamento pari alla variabilità abituale. Il punto finale raccoglie tutte le celle a 8 o più celle dal bordo. Sono colorati i tre tipi con più valori nei cluster di almeno 20 valori (velocità verticale, precipitazione e copertura nuvolosa) e la temperatura a 2 m, citata nel testo; gli altri tipi sono in grigio, e le curve usano tutti i cluster del tipo. Non sono tracciati i punti calcolati su meno di 1000 valori, e l'asse è limitato a 3.5. Precipitazione e copertura nuvolosa tornano presto vicine ai valori di fondo, la velocità verticale un po' più lentamente; la temperatura resta lontana dal normale anche a molte celle.

Sintesi. Circa tre quarti dei valori segnalati stanno in pochi cluster enormi, per lo più di velocità verticale o precipitazione; queste catene si formano con tutti i metodi. G_{n} fa meno cluster minuscoli delle baseline, e i suoi tipi somigliano a quelli della variazione in tre ore. G_{n} cala gradualmente attorno a ciò che segnala, senza un confine proprio, più lentamente di quasi tutte le baseline, in parte per la patch su cui è mediato; il nucleo è sottile. Letta sui cluster di G_{n}, la distanza dal normale ha lo stesso andamento, ma solo il 41% dei valori segnalati ne supera la soglia. Vicino al bordo G_{n} è quasi uguale per tutti i tipi, mentre le variabili si comportano in modo diverso.

6.7.1 Un cluster per tipo

Fin qui i cluster sono descritti tutti insieme e per tipo; resta da vedere un cluster per ciascuno dei tre tipi principali, per vedere su una mappa che cosa riassumono i numeri. Gli esempi sono scelti con una regola fissata prima di esaminarli, così che nessuno sia preso per il suo aspetto: i tipi sono i tre con più valori nei cluster di almeno 20 valori, cioè velocità verticale, precipitazione e copertura nuvolosa; per ciascuno l'esempio è il cluster con più valori fra quelli che durano al massimo tre giorni, letto nell'istante in cui conta più celle. Il limite di durata esclude le catene descritte sopra, che non corrispondono a un'unica anomalia. Gli esempi non sono quindi i casi più importanti né i più tipici: mostrano come appare un cluster compatto di ciascun tipo.

Come leggere le figure. Le Figure 6.15–6.17 hanno la stessa struttura. In alto a sinistra c'è lo scarto della variabile del tipo, qui con il suo segno (nel profilo per tipo è in valore assoluto): bianco vuol dire normale, rosso sopra il normale, blu sotto. In alto a destra c'è G_{n} in percentile, con la stessa scala in tutti gli esempi: il giallo è oltre la soglia. La linea nera nelle due mappe racchiude il nucleo di questo cluster in quell'istante; fuori possono esserci celle gialle di altri cluster. In basso a sinistra si segue nel tempo la cella del nucleo con G_{n} più alto nell'istante delle mappe, da tre giorni prima a tre giorni dopo, confrontando G_{n} con la distanza dal normale di tutte le variabili e, sull'asse a destra, con lo scarto della variabile del tipo: la linea tratteggiata è la soglia di G_{n}, le bande azzurre sono gli istanti in cui la cella fa parte del cluster. In basso a destra c'è il numero di celle del cluster in ogni istante; la linea verticale, anche a sinistra, segna l'istante delle mappe. La Tabella 6.7 riassume le tre zone.

Velocità verticale. Il 23 novembre 2017 il nucleo forma una fascia stretta che, a una lettura della mappa, va dall'Atlantico al largo del Portogallo fino

Tabella 6.7: I tre esempi nell'istante delle mappe, con le celle del nucleo. Le colonne G_n e Distanza riportano il percentile mediano di G_n e della distanza dal normale nel nucleo e nel contorno di questo cluster e nella zona lontana, a più di tre celle da ogni cella segnalata, in quest'ordine. "Oltre soglia" è la quota dei valori del nucleo oltre la soglia della distanza dal normale.

Tipo	Celle	G_n	Distanza	Oltre soglia	Durata (ore)
Velocità verticale	549	97, 91, 42	97, 94, 40	65%	63
Precipitazione	576	97, 91, 33	91, 87, 44	34%	72
Copertura nuvolosa	404	98, 89, 43	93, 56, 33	46%	66

alla Scandinavia meridionale, passando sul Golfo di Biscaglia, sulla Manica e sul Mare del Nord (Figura 6.15). Lungo la fascia la velocità verticale, che in ERA5 è in $\mathrm{Pa\,s^{-1}}$ e quindi è negativa quando l'aria sale, è per lo più sotto il normale: lo scarto è negativo nel 73% delle celle del nucleo, e nel 34% è vicino al normale, inferiore a 1 in valore assoluto. Una parte del nucleo, 25 celle, sta sulla prima fila del dominio, a 60°N, cioè sul bordo del dominio, dove il modello si comporta probabilmente in modo diverso (Sezione 6.2): quella parte va letta con cautela. Nella cella seguita, a 58.5°N e 8.5°E, G_n supera la soglia nelle prime ore del 22 novembre e vi resta, salvo una breve pausa, per circa un giorno e mezzo, finché la cella fa parte del cluster; la distanza dal normale sale insieme a G_n e supera il 90-esimo percentile per circa un giorno. Poi entrambi tornano a valori tipici. Il cluster cresce e cala in modo abbastanza regolare, con il massimo nell'istante delle mappe.

Precipitazione. Il 19 maggio 2006 il nucleo è diviso in più parti (Figura 6.16). A una lettura della mappa, la maggiore va dalle Alpi orientali, attraverso l'Europa centro-orientale, fino al Baltico; una seconda copre l'Inghilterra meridionale, la Manica e il Benelux; altre più piccole stanno fra le due, sulle Alpi e attorno alle Baleari. La precipitazione è sopra il normale nel 91% delle celle del nucleo, con uno scarto mediano di 2.2, e lo scarto supera 3 nel 28% delle celle. È l'esempio meno estremo per la distanza dal normale di tutte le variabili: nel nucleo ha un percentile mediano di 91, e il 34% dei valori ne supera la soglia, contro il 41% di tutti i valori segnalati. La cella seguita, a 56.5°N e 23°E, mostra che G_n e la distanza dal normale non vanno sempre insieme. La distanza dal normale vi è sopra il 90-esimo percentile fin dall'inizio della serie, tre giorni prima, mentre la precipitazione è vicina al normale e G_n resta sotto la soglia: a scostarsi dal normale sono quindi altre variabili. G_n supera la soglia solo la sera del 18 maggio, quando la precipitazione sale sopra il normale, e la cella fa parte del cluster per tre

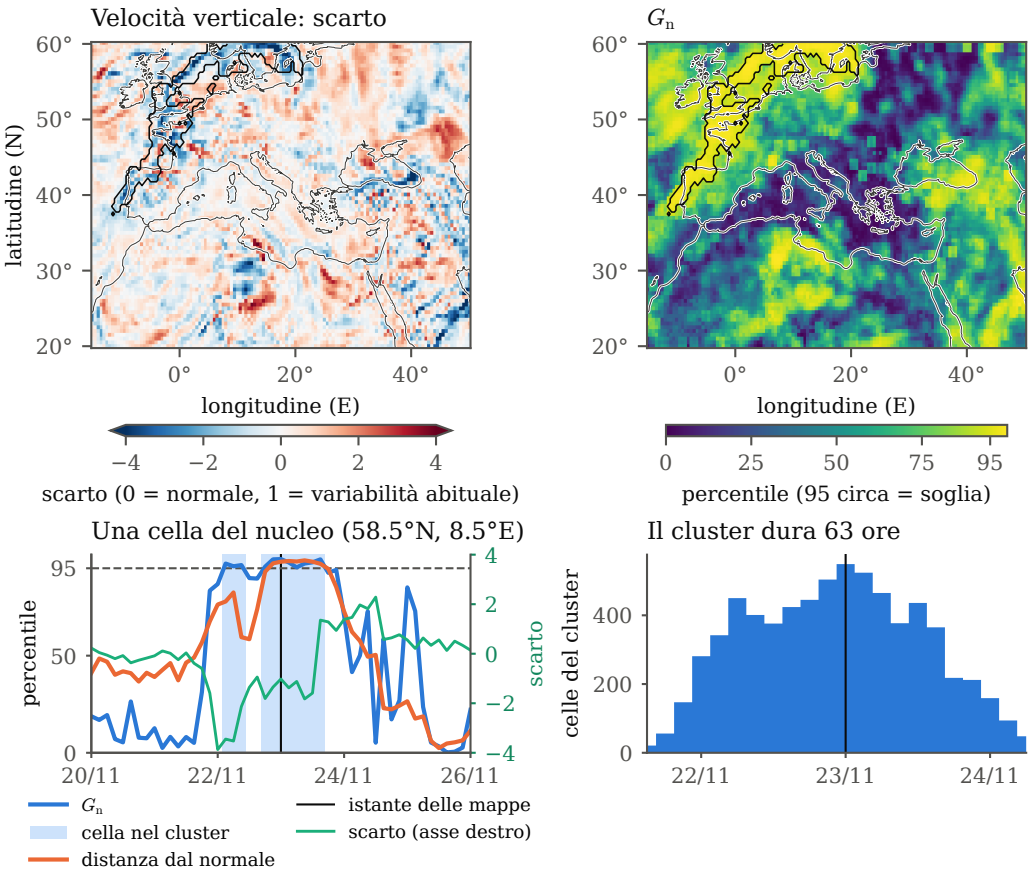


Figura 6.15: Velocità verticale, 23 novembre 2017 alle 00 UTC. Il nucleo è una fascia stretta in cui la velocità verticale è per lo più sotto il normale; nella cella seguita G_n resta oltre la soglia, salvo una breve pausa, per circa un giorno e mezzo, e la distanza dal normale sale e scende insieme a G_n; il cluster dura 63 ore, dal 21 al 24 novembre 2017, con il massimo nell'istante delle mappe. Linee di costa da Natural Earth.

istanti, fino all'istante delle mappe. La stessa cella torna oltre la soglia il 21 maggio, quando il cluster è già finito, e fa quindi parte di un altro.

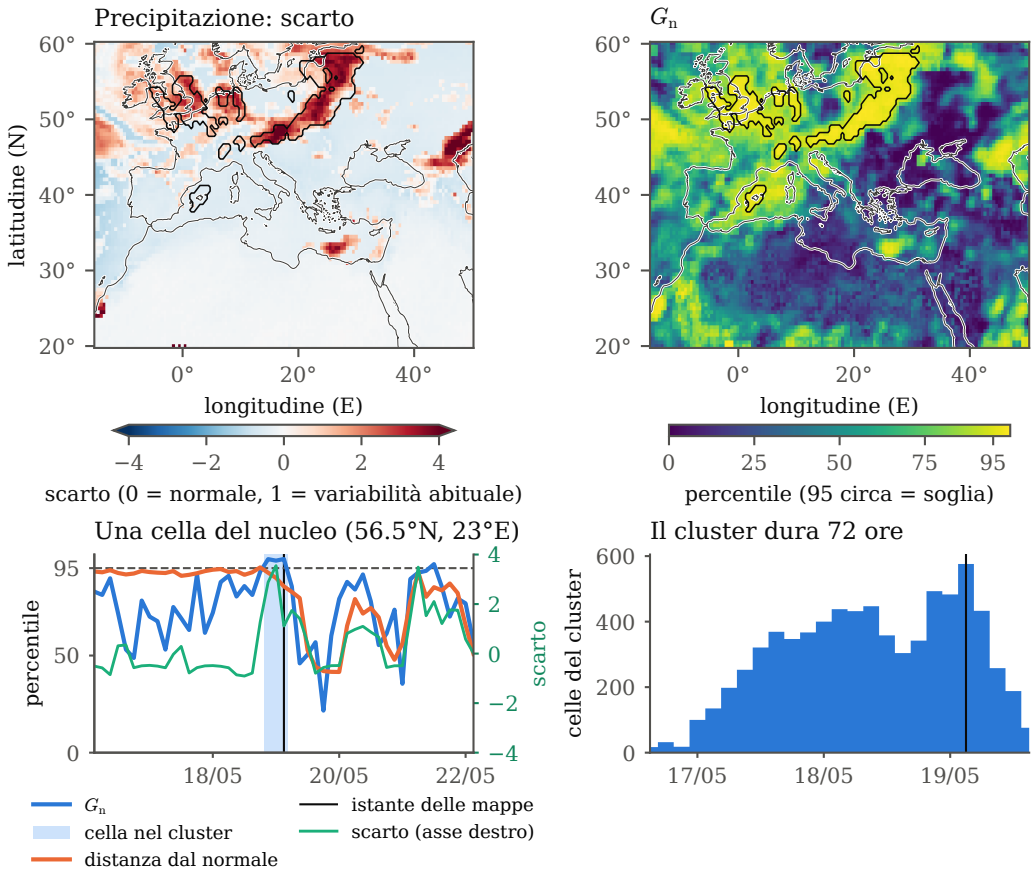


Figura 6.16: Precipitazione, 19 maggio 2006 alle 03 UTC. Il nucleo è diviso in più parti, in cui la precipitazione è quasi ovunque sopra il normale; nella cella seguita la distanza dal normale è alta già nei giorni prima, e G_n supera la soglia solo quando arriva la precipitazione; il cluster dura 72 ore, dal 16 al 19 maggio 2006, e finisce poche ore dopo il massimo. Linee di costa da Natural Earth.

Copertura nuvolosa. Il 15 giugno 2024 il nucleo forma una fascia stretta che, a una lettura della mappa, va dalla costa atlantica del Sahara occidentale, attraverso il Marocco e l'Algeria, fino alla costa mediterranea dell'Algeria, con una piccola parte sul mare fra le Baleari e la Sardegna (Figura 6.17). La copertura nuvolosa è sopra il normale nel 92% delle celle del nucleo, con uno scarto mediano di 2.1, e lo scarto supera 3 nel 19% delle celle. Il nucleo segue

lo scostamento da vicino: la distanza dal normale ha un percentile mediano di 93 nel nucleo e di 56 nel contorno, il calo più netto dei tre esempi. Sulla stessa mappa G_{n} è alto anche altrove, soprattutto sul Mediterraneo orientale: nell'istante delle mappe 911 celle sono segnalate fuori da questo nucleo, e appartengono ad altri cluster. Nella cella seguita, a 23.5°N e 13°W, G_{n} supera la soglia per cinque istanti, dalle 03 alle 15 UTC del 15 giugno, gli stessi in cui la cella fa parte del cluster; lo scarto della copertura nuvolosa vi è fra 1.9 e 3.5, e la distanza dal normale supera il 90-esimo percentile dalle 06 alle 12 UTC. Prima e dopo, G_{n} e la distanza dal normale tornano a valori tipici. Il cluster resta fra circa 200 e 320 celle per quasi due giorni, con il massimo nell'istante delle mappe.

Che cosa mostrano gli esempi. In due delle tre celle seguite, scelte fra quelle con G_{n} più alto, G_{n} e la distanza dal normale salgono e scendono insieme; nella cella della precipitazione la distanza dal normale è alta già nei giorni prima, e G_{n} supera la soglia solo quando arriva la precipitazione. Il nucleo, inoltre, non contiene tutte le celle in cui la variabile del tipo è più lontana dal normale: di quelle con uno scarto oltre 3 contiene il 37% per la velocità verticale, il 62% per la precipitazione e il 57% per la copertura nuvolosa. Per la velocità verticale quasi una cella su cinque di queste sta nella zona lontana, senza alcuna segnalazione; per gli altri due tipi solo l'1%. Negli esempi si vede anche quanto mostrano i numeri aggregati: il tipo non descrive ogni cella, perché in una parte del nucleo la variabile del tipo è vicina al normale, e G_{n} segnala anche valori che, per la distanza dal normale, non sono fra i più estremi. Sono esempi scelti con una regola, non una prova che le segnalazioni corrispondano ad anomalie, che senza un riferimento esterno non si può dare.

6.8 La dispersione del dropout

Fin qui si è usata la media delle estrazioni di dropout; questa sezione guarda quanto differiscono fra loro. Lo score è la media di 20 estrazioni con maschere diverse, e la deviazione standard delle estrazioni ne misura la *dispersione* (Sezione 4.6). Non è una probabilità di anomalia: senza etichette non si può stabilire se una segnalazione con estrazioni concordi sia più giusta di una con estrazioni discordi. Si può però vedere quanto le segnalazioni dipendono dalle maschere, e dove le estrazioni si separano. Poiché la dispersione cresce con l'errore da cui nasce, con una correlazione di Spearman di 0.86, conviene leggerla in proporzione: il *rapporto* è la dispersione dell'errore del generatore

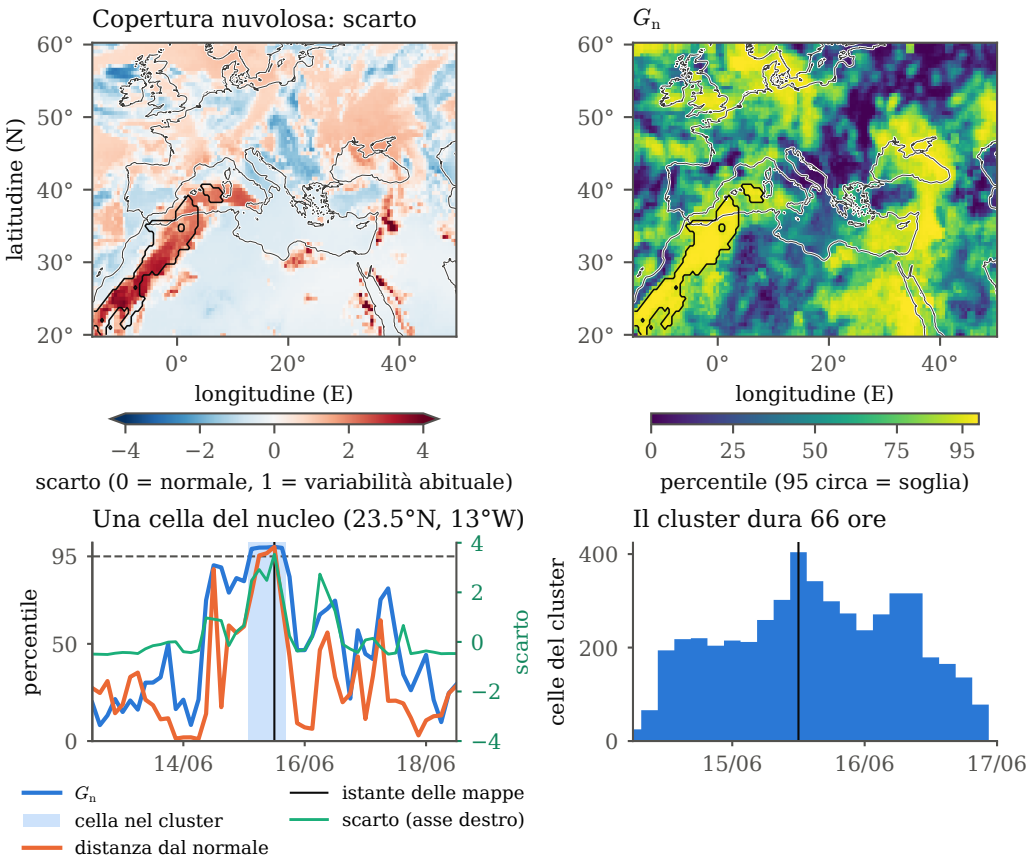


Figura 6.17: Copertura nuvolosa, 15 giugno 2024 alle 12 UTC. Il nucleo è una fascia stretta sull'Africa nord-occidentale in cui la copertura nuvolosa è quasi ovunque sopra il normale; nella cella seguita G_n e la distanza dal normale salgono e scendono insieme, e G_n resta oltre la soglia per dodici ore; il cluster dura 66 ore, dal 14 al 17 giugno 2024. Linee di costa da Natural Earth.

divisa per l'errore stesso, cioè G senza normalizzazione. La sezione riguarda gli anni di test.

Le segnalazioni dipendono poco dalle maschere. Il 75% dei valori segnalati resta sopra la soglia togliendo allo score, cioè a G_{n}, una deviazione standard delle estrazioni, misurata nella stessa scala; il 55% togliendone due; dei valori non segnalati, solo l'1.8% la supererebbe aggiungendone una. È una prova severa, perché la deviazione standard riguarda le singole estrazioni, mentre lo score ne è la media.

In proporzione, la dispersione cala solo sugli errori più grandi. In valore assoluto la dispersione cresce con l'errore, ma in proporzione resta quasi costante (Figura 6.18, a sinistra): il rapporto è fra l'11.1% e l'11.8% in tutte le fasce fino al 99-esimo percentile dell'errore, e scende solo oltre, al 9.7% fra il 99-esimo e il 99.9-esimo percentile e al 9.1% nello 0.1% più alto. Le maschere incidono quindi sull'errore in proporzione quasi uguale, tranne sui valori con l'errore più grande, su cui incidono un po' meno.

Attraverso i cluster il rapporto è minimo poco dentro il bordo. La dispersione assoluta ha quasi lo stesso profilo di G_{n}: il percentile mediano è 94 sul bordo interno del nucleo, 85 una cella fuori e 49 dopo sei celle, contro 96, 90 e 50 di G_{n}. Il rapporto si comporta diversamente (Figura 6.18, al centro): è circa il 10.3% a tre o più celle fuori dai cluster, il 10.2% nel contorno, scende al 9.6% due celle dentro il nucleo, poi risale verso l'interno, fino all'11.2% nelle pochissime celle a 8 o più celle dal bordo, lo 0.09% dei valori segnalati. Nel nucleo, nel contorno e fuori, quindi, le differenze ci sono ma sono piccole: fra il 9.6% e l'11.2%. Il motivo della risalita al centro non è verificato.

A parità di errore, più dispersione va con dati più lontani dal normale, ma non nella classe più discorde. Per confrontare valori con lo stesso errore, i valori segnalati sono divisi prima in 20 fasce di errore e poi, in ogni fascia, in cinque classi uguali per rapporto; il rapporto mediano va dal 5% della classe 1, con le estrazioni più concordi, al 19% della classe 5, con le più discordi (Figura 6.18, a destra). Dalla classe 1 alla 4 la quota oltre la soglia della distanza dal normale sale dal 24% al 50%; nella classe 5 scende al 45%. La quota di valori in cui nessuna variabile si allontana dal normale più di due volte la variabilità abituale fa il contrario: è il 13% nella classe 1, circa il 9% nelle classi 3 e 4 e di nuovo il 12% nella 5. Il risultato è quasi uguale dividendo a parità di G_{n}: dal 27% della classe 1 al 49% della 4, e il 45% nella 5. Fino alla classe 4, dunque, le estrazioni si separano di più dove i dati sono

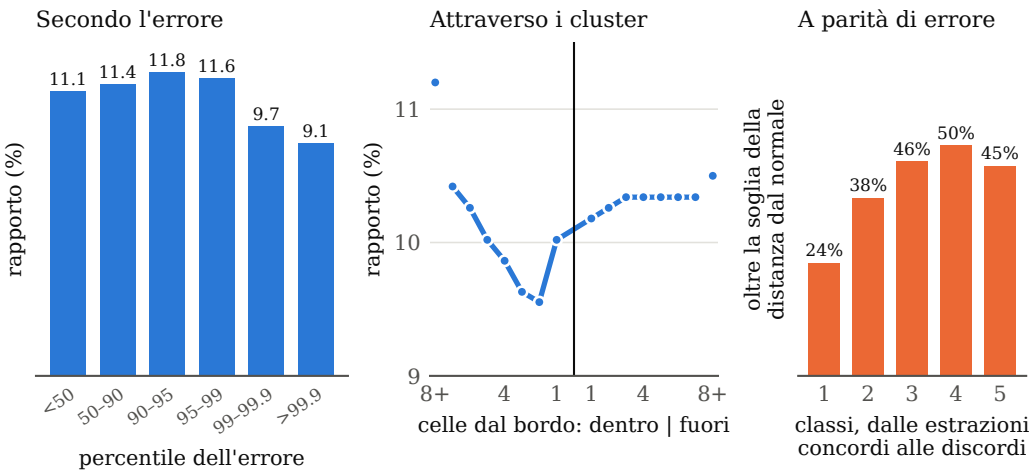


Figura 6.18: Il rapporto fra la dispersione del dropout e l'errore del generatore, sugli anni di test, con la soglia di G_{n} al 95-esimo percentile. A sinistra: per percentile dell'errore su tutti i valori. Al centro: secondo le celle di distanza dal bordo del cluster; l'asse non parte da zero. A destra: i valori segnalati, divisi a parità di errore in cinque classi uguali per rapporto, da quella con le estrazioni più concordi a quella con le più discordi; per ogni classe, la quota oltre la soglia della distanza dal normale. Il rapporto è quasi costante e scende solo nell'1% più alto degli errori; a parità di errore, la quota oltre la soglia sale dalla classe 1 alla 4 e cala nella 5.

più lontani dal normale, e quelle più concordi cadono più spesso dove nessuna variabile della cella è lontana dal normale. Questo è coerente con l'idea che il modello sia meno stabile sui dati più diversi da quelli visti in addestramento. La classe più discorde, però, non segue l'andamento, e il legame non è quindi un semplice "più dispersione, dati più insoliti"; il motivo del calo nell'ultima classe non è verificato, e la verifica, nel complesso, non dimostra quell'idea.

Per tipo di cluster il quadro è simile. Con gli stessi tipi della Sezione 6.7, il rapporto è quasi ovunque più basso dentro il nucleo, in genere due o tre celle dentro il bordo, e sale verso l'esterno (Figura 6.19, a sinistra); la radiazione solare ha il minimo più basso, il 7.1%. Fa eccezione l'umidità del suolo, con il rapporto più alto, che scende verso l'esterno. A parità di errore, in ogni tipo la classe 1 ha la quota più bassa di valori oltre la soglia della distanza dal normale, ma la più alta è la classe 3 o 4 (la classe 3 non è mostrata nella figura), non la 5 (Figura 6.19, a destra): per la velocità verticale, per esempio, la quota va dal 20% della classe 1 al 45% della classe 4, e scende al 40% nella 5. Solo per precipitazione e umidità del suolo la classe 5 è alla pari con la 4.

La dispersione cella per cella. La Figura 6.20 mostra la deviazione standard delle estrazioni in ogni cella. In media sugli anni di test è più alta a sud, dove è più alto anche l'errore: 2.28×10^{-4} fra 20° e 30°N contro 1.85×10^{-4} fra 50° e 60°N, circa il 23% in più a sud. Il rapporto medio varia poco, fra l'11.0% e l'11.4% da una fascia all'altra, senza un andamento con la latitudine. Lungo il bordo del dominio si vede una cornice: sulla fila di celle più esterna la deviazione standard è in media 1.8 volte quella delle celle a otto o più celle dal bordo, probabilmente un effetto del modello simile a quello della Sezione 6.2. Due terzi delle celle sopra il 97-esimo percentile della media stanno entro tre celle dal bordo. All'interno i valori più alti cadono in poche aree che, a una lettura della mappa, sembrano corrispondere a rilievi come Alpi, Caucaso, Anatolia orientale e Zagros; il legame con l'orografia non è misurato. Negli istanti dei tre esempi della Sezione 6.7.1, uno per ciascuno dei tre tipi evidenziati, la deviazione standard è più alta nel nucleo, come ci si aspetta dal fatto che segue G: in mediana da quattro a sei volte e mezzo quella della zona lontana.

Sintesi. Nelle segnalazioni di G_{n} il dropout ha un comportamento definito, che si ripete in quasi tutti i tipi di cluster. In valore assoluto la dispersione cresce con G, e la maggior parte delle segnalazioni dipende poco dalle maschere. In proporzione all'errore la dispersione è quasi costante, e cala solo sugli errori più grandi. Attraverso i cluster il rapporto è più basso poco dentro il bordo e

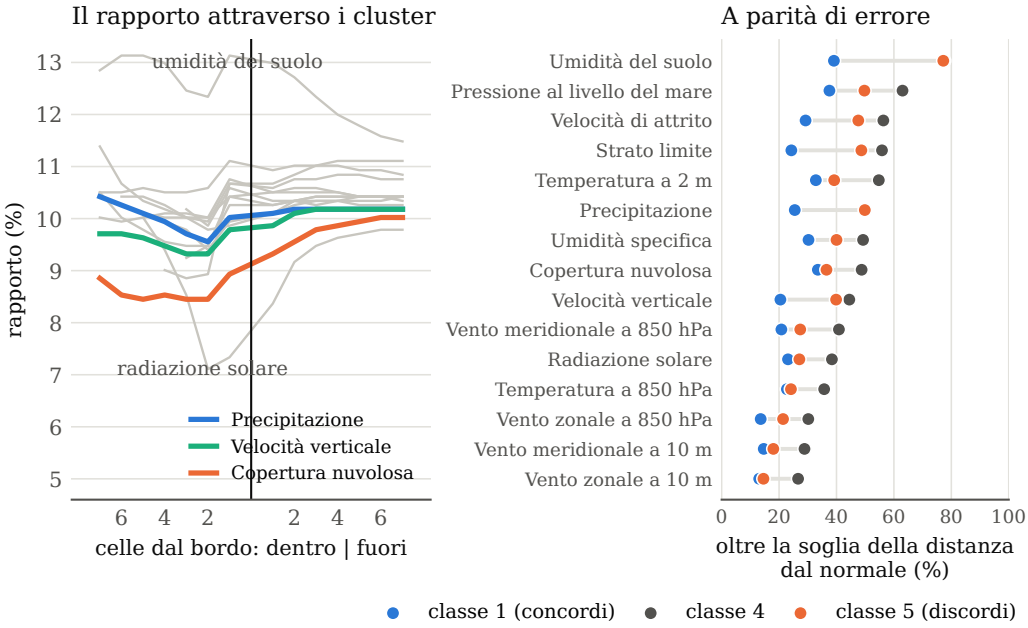


Figura 6.19: Il dropout per tipo di cluster, sugli anni di test. A sinistra: rapporto fra dispersione ed errore secondo le celle di distanza dal bordo, con evidenziati, nella legenda, i tre tipi con più valori nei cluster di almeno 20 valori; gli altri tipi sono in grigio, e non sono tracciati i punti calcolati su meno di 1000 valori né quelli a 8 o più celle dal bordo. A destra: a parità di errore, quota dei valori oltre la soglia della distanza dal normale nella classe 1, con le estrazioni più concordi, nella classe 4 e nella classe 5, con le più discordi; i tipi sono ordinati per la classe 4, e dove le classi 4 e 5 coincidono il segno della classe 5 nasconde quello della 4. Il rapporto è più basso poco dentro il bordo in quasi tutti i tipi; la classe 1 ha sempre la quota più bassa, la 5 quasi mai la più alta.

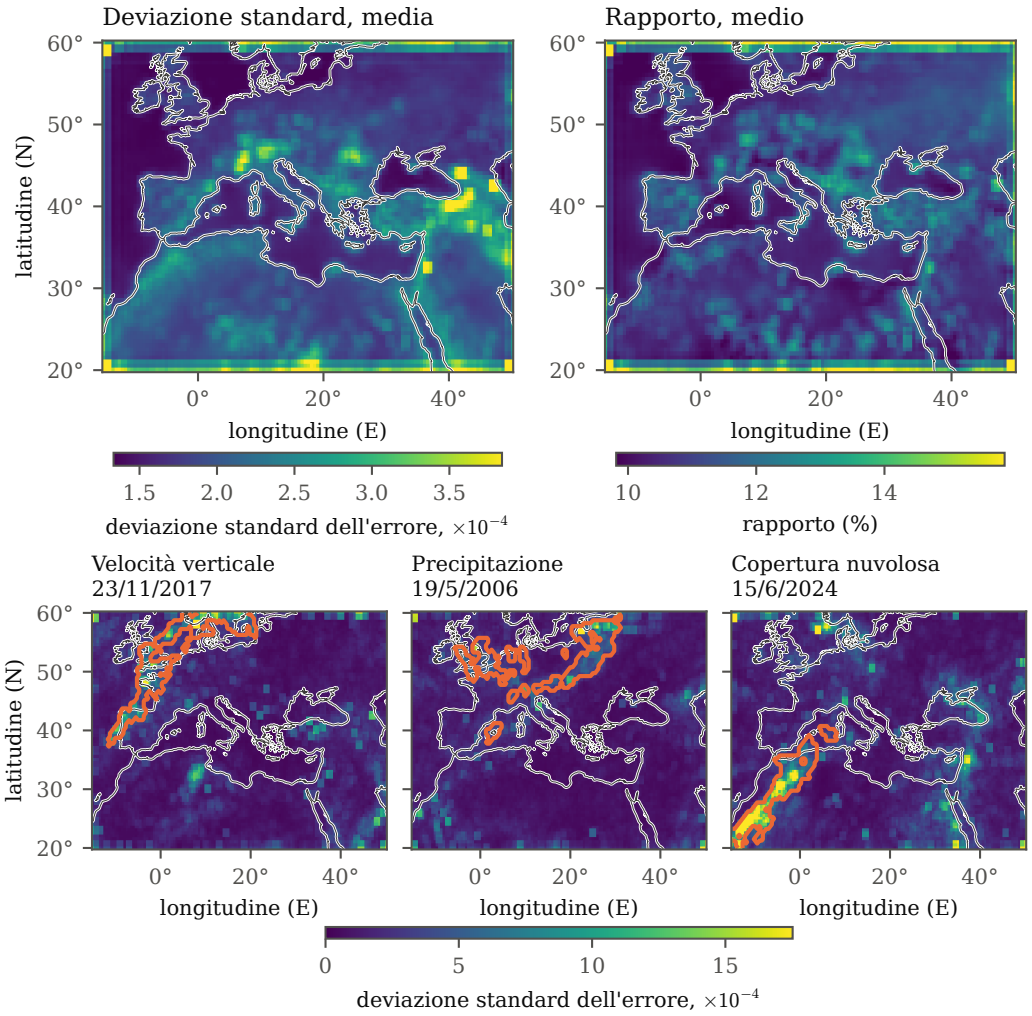


Figura 6.20: La deviazione standard delle estrazioni di dropout cella per cella. In alto: la sua media sugli anni di test e il rapporto medio con l'errore; lungo il bordo del dominio si vede la cornice descritta nel testo. In basso: la deviazione standard negli istanti dei tre esempi della Sezione 6.7.1 (23 novembre 2017, 19 maggio 2006 e 15 giugno 2024), con una scala comune ai tre e il nucleo del cluster racchiuso dalla linea arancione. Linee di costa da Natural Earth.

risale di poco verso l'interno. A parità di errore, le estrazioni concordano di meno dove i dati sono più lontani dal normale, fino alla classe 4; la classe più discorde non segue questo andamento. Questo descrive il comportamento del modello e non rende una segnalazione più o meno affidabile.

6.9 Anomalie meteorologiche note

Sezione da scrivere. Anomalie meteorologiche note, con un riferimento esterno da decidere con il relatore: le segnalazioni più evidenti del detector, confrontate con una lista di anomalie meteorologiche note (per esempio le intrusioni di polvere sahariana) compilata senza guardare le segnalazioni, e giudicate da esperti del settore energetico. Il riferimento esterno serve solo a questa verifica finale, non alla scelta del modello, dello score o della soglia.

6.10 Sensibilità alla soglia

Tutti i risultati precedenti usano la soglia del 95-esimo percentile degli score di validazione. È una scelta convenzionale, non ottimizzata. Questa sezione ripete le analisi principali con il 99-esimo percentile, cioè segnalando l'1% dei valori della validazione, per verificare quanto le conclusioni dipendano dalla soglia (Tabella 6.8).

La normalizzazione climatologica nella coda. Con la soglia più alta la normalizzazione riduce ancora molto le differenze fra luoghi e stagioni, ma non le annulla: resta un eccesso di segnalazioni a sud, dove la quota media è circa il doppio di quella a nord. La normalizzazione allinea media e deviazione standard dell'errore di ogni cella, non la frequenza dei suoi valori più estremi; con il 5% questa differenza si vede appena, con l'1% sì.

Il comportamento del discriminatore. Con la soglia più alta i cluster sono meno della metà, e il comportamento del discriminatore è lo stesso e più marcato. Nel nucleo D_{reale} scende dal percentile 5 all'1 e D dal 27 al 2. Anche nel contorno D_{reale} scende, da 12 a 4: con la soglia più alta i cluster sono più estremi, e anche le celle attorno sono fra i valori più alti di G_{n}.

Cluster e catene. Con la soglia più alta le catene si accorciano ma restano: i cluster più grandi dei tre tipi con più valori durano fra 8 e 24 giorni, contro 23–40 giorni con il 5%, e i cluster con almeno 20 valori contengono ancora l'85% dei valori segnalati, contro il 93% con il 5%. I tre tipi con più valori

Tabella 6.8: Le analisi delle sezioni precedenti con la soglia al 95-esimo e al 99-esimo percentile degli score di validazione: quota per luogo e zone sugli anni di validazione, confronti sugli anni di test. La differenza relativa è la differenza media delle quote per fascia di latitudine e mese dalla loro media, divisa per la media.

Analisi	Misura	95-esimo	99-esimo
Quota per luogo (Sez. 6.3)	G senza normalizzazione, intervallo fra fasce e mesi	1.6–11.1%	0.2–3.6%
	G_{n}, intervallo	3.7–6.3%	0.5–2.1%
	differenza relativa, G $\to$ G_{n}	0.39 $\to$ 0.11	0.70 $\to$ 0.28
Zone dei cluster (Sez. 6.4)	cluster di G_{n}	184877	70954
	D_{reale} nel nucleo, percentile mediano	5	1
	D_{reale} nel contorno, percentile mediano	12	4
	D nel nucleo, percentile mediano	27	2
Confronti (Sez. 6.6)	segnalazioni di G_{n} condivise con la variazione in tre ore	53.9%	46.4%
	condivise con MCD	52.1%	45.8%
	condivise con HBOS	39.2%	24.3%
	segnalazioni del solo G_{n}	18.1%	27.4%
	valori segnalati da almeno 5 rilevatori su 9	4.22%	0.72%

nei cluster di almeno 20 valori restano velocità verticale, precipitazione e copertura nuvolosa, ma la precipitazione passa al primo posto.

Confronti con le baseline. Con la soglia più alta il quadro resta lo stesso, con un accordo più basso. La variazione in tre ore e MCD restano i rilevatori più vicini a G_{n}, con il 46% delle sue segnalazioni condivise; il metodo più lontano resta HBOS, che scende dal 39.2% al 24.3%. La quota del solo G_{n} sale al 27.4%, e quella della variazione in tre ore al 38.3%. I valori segnalati da almeno cinque rilevatori su nove sono lo 0.72%: il calo è in gran parte automatico, perché ogni rilevatore segnala circa cinque volte meno. L'accordo resta molto sopra il caso: con l'1% due rilevatori indipendenti condividerebbero circa l'1% delle segnalazioni, mentre G_{n} ne condivide il 46% con la variazione in tre ore.

Sintesi. Le conclusioni sul discriminatore non dipendono dalla soglia, e con una soglia più alta diventano più nette. Anche il quadro del confronto con le baseline non cambia, con un accordo più basso e una quota esclusiva di G_{n} più alta. Le catene si accorciano, ma restano. L'effetto della normalizzazione climatologica dipende invece dalla soglia: la normalizzazione riduce le differenze fra luoghi e stagioni di circa tre quarti con il 5% e di circa tre quinti con l'1%.

Capitolo 7

Conclusioni e sviluppi futuri

7.1 Il problema affrontato

7.2 Sintesi dei risultati

7.3 Sviluppi futuri

Il primo sviluppo è ripetere la configurazione scelta con più semi, per avere un riferimento con cui leggere le differenze fra configurazioni.

Il secondo riguarda il protocollo: aggiornare periodicamente soglie e normalizzazione climatologica su una finestra di anni recenti, invece di tenerle fisse dalla validazione, ridurrebbe l'effetto della deriva del clima sulla quota di osservazioni segnalate.

Il terzo riguarda la valutazione. Il confronto con le anomalie meteorologiche note della Sezione 6.9 si limita a pochi casi; un catalogo esterno di anomalie su tutto il dominio, o anomalie artificiali inserite in posizioni note, darebbe una misura del richiamo, che in questa tesi manca.

Il quarto riguarda l'incertezza dello score. La Sezione 6.8 descrive come la dispersione varia con l'errore; resta da verificare, con un riferimento esterno, se può essere usata come misura di incertezza. I metodi basati su equazioni differenziali stocastiche, considerati nel lavoro preliminare, potrebbero inoltre essere applicati al detector: richiedono di aggiungere a STGAN una rete di diffusione, una modifica che questa tesi ha evitato per restare vicina all'architettura dell'articolo.

Ritorno alla previsione fotovoltaica. Il lavoro è partito dalla previsione della produzione fotovoltaica sui dati PVGIS, ed è passato ai campi ERA5 perché quei dati non permettevano di riconoscere anomalie meteorologiche

di tipo generale. Il detector può ora essere riportato a quel problema in più modi. Il primo passo è allineare i due insiemi di dati: le località PVGIS, su un reticolo di 5 km, ricadono in poche decine di celle ERA5 di 0.5°, e lo score, calcolato ogni tre ore, va riportato alle ore del previsore. Con questo allineamento le segnalazioni del detector possono servire a valutare il previsore separatamente sui valori non segnalati e su quelli segnalati, misurando se l'errore del previsore cresce quando il detector segnala. Possono servire poi all'addestramento, per escludere dal training le finestre segnalate, secondo il protocollo di SDE U-Net, oppure per dare loro un peso diverso. Lo score può infine entrare nel previsore come ingresso aggiuntivo, oppure regolare l'incertezza delle sue previsioni, aumentandola quando lo score è alto. In ciascun caso la verifica più diretta sarebbe sulle misure di impianti reali, dove disponibili.

Bibliografia

[1] J. Antonanzas et al. «Review of photovoltaic power forecasting». In: *Solar Energy* 136 (2016), pp. 78–111. DOI: 10.1016/j.solener.2016.06.069.

[2] Hans Hersbach et al. «The ERA5 global reanalysis». In: *Quarterly Journal of the Royal Meteorological Society* 146.730 (2020), pp. 1999–2049. DOI: 10.1002/qj.3803.

[3] Leyan Deng et al. «Graph Convolutional Adversarial Networks for Spatiotemporal Anomaly Detection». In: *IEEE Transactions on Neural Networks and Learning Systems* 33.6 (2022), pp. 2416–2428. DOI: 10.1109/TNNLS.2021.3136171.

[4] Manish Gupta et al. «Outlier Detection for Temporal Data: A Survey». In: *IEEE Transactions on Knowledge and Data Engineering* 26.9 (2014), pp. 2250–2267. DOI: 10.1109/TKDE.2013.184.

[5] Zahra Zamanzadeh Darban et al. «Deep Learning for Time Series Anomaly Detection: A Survey». In: *ACM Computing Surveys* 57.1 (2024), pp. 1–42. DOI: 10.1145/3691338.

[6] Xingjian Wu et al. «CATCH: Channel-Aware Multivariate Time Series Anomaly Detection via Frequency Patching». In: *International Conference on Learning Representations (ICLR)*. 2025. arXiv: 2410.12261.

[7] Sarah Alnegheimish et al. «M^{2}AD: Multi-Sensor Multi-System Anomaly Detection through Global Scoring and Calibrated Thresholding». In: *Proceedings of the 28th International Conference on Artificial Intelligence and Statistics*. Vol. 258. Proceedings of Machine Learning Research. PMLR, 2025, pp. 4384–4392.

[8] Pankaj Malhotra et al. *LSTM-based Encoder-Decoder for Multi-sensor Anomaly Detection*. Presentato all'ICML 2016 Anomaly Detection Workshop. 2016. arXiv: 1607.00148.

[9] Kyle Hundman et al. «Detecting Spacecraft Anomalies Using LSTMs and Nonparametric Dynamic Thresholding». In: *Proceedings of the 24th ACM SIGKDD International Conference on Knowledge Discovery & Data Mining*. ACM, 2018, pp. 387–395. DOI: 10.1145/3219819.3219845.

[10] Jiehui Xu et al. «Anomaly Transformer: Time Series Anomaly Detection with Association Discrepancy». In: *International Conference on Learning Representations (ICLR)*. 2022. arXiv: 2110.02642.

[11] Ailin Deng e Bryan Hooi. «Graph Neural Network-Based Anomaly Detection in Multivariate Time Series». In: *Proceedings of the AAAI Conference on Artificial Intelligence*. Vol. 35. 5. 2021, pp. 4027–4035. DOI: 10.1609/aaai.v35i5.16523.

[12] Qihang Zhou et al. «Label-Free Multivariate Time Series Anomaly Detection». In: *IEEE Transactions on Knowledge and Data Engineering* 36.7 (2024), pp. 3166–3179. DOI: 10.1109/TKDE.2024.3349613. arXiv: 2312.11549.

[13] Ian J. Goodfellow et al. «Generative Adversarial Nets». In: *Advances in Neural Information Processing Systems*. Vol. 27. Curran Associates, Inc., 2014. arXiv: 1406.2661.

[14] Thomas Schlegl et al. «Unsupervised Anomaly Detection with Generative Adversarial Networks to Guide Marker Discovery». In: *Information Processing in Medical Imaging (IPMI 2017)*. Vol. 10265. Lecture Notes in Computer Science. Springer, 2017, pp. 146–157. DOI: 10.1007/978-3-319-59050-9_12.

[15] Dan Li et al. «MAD-GAN: Multivariate Anomaly Detection for Time Series Data with Generative Adversarial Networks». In: *Artificial Neural Networks and Machine Learning – ICANN 2019: Text and Time Series*. Vol. 11730. Lecture Notes in Computer Science. Springer, 2019, pp. 703–716. DOI: 10.1007/978-3-030-30490-4_56.

[16] Renjie Wu e Eamonn J. Keogh. «Current Time Series Anomaly Detection Benchmarks are Flawed and are Creating the Illusion of Progress». In: *IEEE Transactions on Knowledge and Data Engineering* (2021). DOI: 10.1109/TKDE.2021.3112126. arXiv: 2009.13807.

[17] Qinghua Liu e John Paparrizos. «The Elephant in the Room: Towards A Reliable Time-Series Anomaly Detection Benchmark». In: *Advances in Neural Information Processing Systems 37 (NeurIPS 2024), Datasets and Benchmarks Track*. Vol. 37. 2024, pp. 108231–108261. DOI: 10.52202/079017-3437.

[18] Peter Bauer, Alan Thorpe e Gilbert Brunet. «The quiet revolution of numerical weather prediction». In: *Nature* 525.7567 (2015), pp. 47–55. DOI: 10.1038/nature14956.

[19] Stephan Rasp et al. «WeatherBench: A Benchmark Data Set for Data-Driven Weather Forecasting». In: *Journal of Advances in Modeling Earth Systems* 12.11 (2020), e2020MS002203. DOI: 10.1029/2020MS002203.

[20] Remi Lam et al. «Learning skillful medium-range global weather forecasting». In: *Science* 382.6677 (2023), pp. 1416–1421. DOI: 10.1126/science.adi2336.

[21] Yunjie Liu et al. *Application of Deep Convolutional Neural Networks for Detecting Extreme Weather in Climate Datasets*. 2016. arXiv: 1605.01156.

[22] Evan Racah et al. «ExtremeWeather: A large-scale climate dataset for semi-supervised detection, localization, and understanding of extreme weather events». In: *Advances in Neural Information Processing Systems*. Vol. 30. Curran Associates, Inc., 2017.

[23] Prabhat et al. «ClimateNet: an expert-labeled open dataset and deep learning architecture for enabling high-precision analyses of extreme weather». In: *Geoscientific Model Development* 14 (2021), pp. 107–124. DOI: 10.5194/gmd-14-107-2021.

[24] Pablo G. Zaninelli et al. «AI-Based Anomaly Detection for Extreme Event Attribution: An Analysis of European Heatwaves». In: *Earth Systems and Environment* 10.8 (2026), pp. 9949–9969. DOI: 10.1007/s41748-026-01122-6.

[25] Aytaç Paçal et al. «A multivariate analysis of atmospheric drivers for Western European heatwaves». In: *Earth System Dynamics* 17 (2026), pp. 955–986. DOI: 10.5194/esd-17-955-2026.

[26] Bing Yu, Haoteng Yin e Zhanxing Zhu. «Spatio-Temporal Graph Convolutional Networks: A Deep Learning Framework for Traffic Forecasting». In: *Proceedings of the Twenty-Seventh International Joint Conference on Artificial Intelligence (IJCAI-18)*. 2018, pp. 3634–3640. DOI: 10.24963/ijcai.2018/505.

[27] Kyunghyun Cho et al. «Learning Phrase Representations using RNN Encoder–Decoder for Statistical Machine Translation». In: *Proceedings of the 2014 Conference on Empirical Methods in Natural Language Processing (EMNLP)*. Association for Computational Linguistics, 2014, pp. 1724–1734. DOI: 10.3115/v1/D14-1179. arXiv: 1406.1078.

[28] Xingjian Shi et al. «Convolutional LSTM Network: A Machine Learning Approach for Precipitation Nowcasting». In: *Advances in Neural Information Processing Systems*. Vol. 28. Curran Associates, Inc., 2015. arXiv: 1506.04214.

[29] Nicolas Ballas et al. «Delving Deeper into Convolutional Networks for Learning Video Representations». In: *International Conference on Learning Representations (ICLR)*. 2016. arXiv: 1511.06432.

[30] Moloud Abdar et al. «A review of uncertainty quantification in deep learning: Techniques, applications and challenges». In: *Information Fusion* 76 (2021), pp. 243–297. DOI: 10.1016/j.inffus.2021.05.008.

[31] Yarin Gal e Zoubin Ghahramani. «Dropout as a Bayesian Approximation: Representing Model Uncertainty in Deep Learning». In: *Proceedings of the 33rd International Conference on Machine Learning*. Vol. 48. Proceedings of Machine Learning Research. PMLR, 2016, pp. 1050–1059. arXiv: 1506.02142.

[32] Balaji Lakshminarayanan, Alexander Pritzel e Charles Blundell. «Simple and Scalable Predictive Uncertainty Estimation using Deep Ensembles». In: *Advances in Neural Information Processing Systems*. Vol. 30. Curran Associates, Inc., 2017. arXiv: 1612.01474.

[33] Lingkai Kong, Jimeng Sun e Chao Zhang. «SDE-Net: Equipping Deep Neural Networks with Uncertainty Estimates». In: *Proceedings of the 37th International Conference on Machine Learning*. Vol. 119. Proceedings of Machine Learning Research. PMLR, 2020, pp. 5405–5415. arXiv: 2008.10546.

[34] Simone Monaco et al. «Uncertainty-aware methods for enhancing rainfall prediction with deep-learning based post-processing segmentation». In: *Computers & Geosciences* 205 (2025), p. 105992. DOI: 10.1016/j.cageo.2025.105992.

[35] Russ Rew e Glenn Davis. «NetCDF: An Interface for Scientific Data Access». In: *IEEE Computer Graphics and Applications* 10.4 (1990), pp. 76–82. DOI: 10.1109/38.56302.

[36] Charles R. Harris et al. «Array Programming with NumPy». In: *Nature* 585.7825 (2020), pp. 357–362. DOI: 10.1038/s41586-020-2649-2.

[37] Thomas Huld, Richard Müller e Attilio Gambardella. «A new solar radiation database for estimating PV performance in Europe and Africa». In: *Solar Energy* 86.6 (2012), pp. 1803–1815. DOI: 10.1016/j.solener.2012.03.006.

[38] Sepp Hochreiter e Jürgen Schmidhuber. «Long Short-Term Memory». In: *Neural Computation* 9.8 (1997), pp. 1735–1780. DOI: 10.1162/neco.1997.9.8.1735.

[39] Diederik P. Kingma e Jimmy Ba. «Adam: A Method for Stochastic Optimization». In: *International Conference on Learning Representations (ICLR)*. 2015. arXiv: 1412.6980.

[40] Arthur Gretton et al. «A Kernel Two-Sample Test». In: *Journal of Machine Learning Research* 13.25 (2012), pp. 723–773.

[41] Adam Paszke et al. «PyTorch: An Imperative Style, High-Performance Deep Learning Library». In: *Advances in Neural Information Processing Systems*. Vol. 32. Curran Associates, Inc., 2019.

[42] Stephan Hoyer e Joe Hamman. «xarray: N-D labeled Arrays and Datasets in Python». In: *Journal of Open Research Software* 5.1 (2017), p. 10. DOI: 10.5334/jors.148.

[43] Wes McKinney. «Data Structures for Statistical Computing in Python». In: *Proceedings of the 9th Python in Science Conference*. 2010, pp. 56–61. DOI: 10.25080/Majora-92bf1922-00a.

[44] Pauli Virtanen et al. «SciPy 1.0: Fundamental Algorithms for Scientific Computing in Python». In: *Nature Methods* 17.3 (2020), pp. 261–272. DOI: 10.1038/s41592-019-0686-2.