

Politecnico di Torino

Politecnico di Torino

Laurea Magistrale in Ingegneria Informatica – Ingegneria del software

A.A. 2025/2026

Sessione di laurea Novembre/Dicembre 2026

Rilevamento unsupervised di anomalie meteorologiche con reti generative avversarie spazio-temporali

Relatore:
Simone Monaco

Candidato:
Alberto Pedalino

Indice

Elenco delle figure **iv**

1 Introduzione **1**
1.1 Contesto e motivazioni 1
1.2 Anomalie meteorologiche senza etichette 1
1.3 Approccio proposto 2
1.4 Obiettivi e contributi della tesi 3
1.5 Organizzazione del documento 4

2 Fondamenti teorici e stato dell'arte **5**
2.1 Rilevamento di anomalie in serie multivariate e spazio-temporali 5
2.1.1 Dalla deviazione dal valore atteso ai modelli profondi . 6
2.1.2 Relazioni fra le serie e dati di addestramento contaminati 7
2.1.3 Reti generative avversarie per il rilevamento di anomalie 9
2.1.4 STGAN 10
2.1.5 Il problema della valutazione 12
2.2 Apprendimento automatico e dati meteorologici 13
2.2.1 Dalla previsione numerica ai modelli basati sui dati . . 13
2.2.2 Eventi estremi e anomalie nei campi meteorologici . . . 14
2.3 Contesto spaziale su griglie e grafi 15
2.4 Quantificazione dell'incertezza 17
2.5 Da STGAN al rilevatore della tesi 18
2.6 Posizionamento del lavoro 20

3 Dati e preprocessing **22**
3.1 Campi ERA5 e dominio 22
3.2 Acquisizione e preparazione dei dati 24
3.3 Anni di addestramento, di validazione e di test 27
3.4 Caratteristiche dei campi 28
3.5 Qualità e limiti dei dati 31
3.6 I dati PVGIS del lavoro preliminare 32

4 Metodologia **35**
4.1 Formulazione del problema 35
4.2 Architettura e addestramento avversario 36
4.2.1 Generatore ConvGRU sul campo intero 36
4.2.2 Discriminatore locale 38
4.2.3 Obiettivi di addestramento 39
4.3 Ingresso: storia recente, codifica temporale e normalizzazione stagionale 40
4.3.1 Storia recente e trend 40
4.3.2 Codifica temporale ciclica 40
4.3.3 Normalizzazione stagionale 41
4.4 Pesi delle variabili nell'errore di ricostruzione del generatore . 42
4.5 Valori esclusi negli anni di validazione 43
4.6 Componenti dello score e dropout Monte Carlo 45
4.6.1 Dropout nel generatore e nel discriminatore 45
4.6.2 Estrazioni Monte Carlo e componenti dello score 45
4.6.3 Score combinato e score del rilevatore 46
4.7 Normalizzazione climatologica degli score 47

5 Esperimenti **49**
5.1 Distanza MMD per la scelta della configurazione 49
5.2 Configurazione e ricerca degli iperparametri 50
5.3 Protocollo di valutazione 52
5.3.1 Misure usate nei risultati 53
5.4 Baseline 55
5.5 Segnalazioni concordate 56

6 Risultati e discussione **63**
6.1 Ricerca degli iperparametri 63
6.2 G e D: un legame debole 65
6.3 La normalizzazione climatologica 67
6.4 Che cosa giudica il discriminatore 69
6.5 Conferma sugli anni di test e scelta dello score 74
6.6 Confronto con le baseline 76
6.7 Cluster di segnalazioni per tipo e dimensione 79
6.7.1 Un cluster per tipo 86
6.8 Segnalazioni concordate 94
6.8.1 Il cubo e i cluster concordati 94
6.8.2 Quanto ogni metodo concorda 96
6.8.3 Inizio, fine e direzione 97
6.8.4 Che cosa c'è attorno ai cluster 100

6.8.5 Probabilità di superamento 102
6.9 La dispersione del dropout 103
6.10 Variabili che nessuno score legge 106

7 Conclusioni e sviluppi futuri **109**
7.1 Il problema affrontato 109
7.2 Sintesi dei risultati 109
7.3 Sviluppi futuri 109

A Sensibilità alla soglia **111**
A.1 Le analisi principali con il 99-esimo percentile 111
A.2 Le segnalazioni concordate con il 97-esimo e il 99-esimo percentile 113
A.3 Curve precision–recall rispetto al cubo concordato 116

Bibliografia **117**

Elenco delle figure

2.1 Schema di STGAN. Il generatore combina tre rami e produce la stima $\hat{X}_{v,t}$, che sostituisce l'ultimo elemento della sequenza reale; il discriminatore valuta le due sequenze. Ridisegnato a partire da Deng et al. [5]. 11

3.1 Dominio dei campi ERA5: 81×131 celle di 0.5°, fra 20° e 60° di latitudine nord e fra 15° di longitudine ovest e 50° di longitudine est. Il rettangolo indica l'area delle località PVGIS, in Piemonte. Linee di costa da Natural Earth. 25

3.2 Le quattro fasi dai file di ERA5 ai dati letti dal modello: scarico dal Climate Data Store, verifica dei file, preparazione in array su disco e lettura delle sole finestre usate. 26

3.3a Ciclo stagionale della temperatura a due metri e della copertura nuvolosa in tre celle: media per mese, con una fascia a una deviazione standard. 29

3.3b Ciclo giornaliero della temperatura a due metri e della copertura nuvolosa in Europa settentrionale (blu), Pianura Padana (arancio) e Sahara (verde): media per ora UTC in gennaio (tratteggio) e in luglio (linea continua). 29

3.4 Percentuale di ciascuna variabile nella variazione quadratica media su 24 ore, dopo il min–max di STGAN e dopo la normalizzazione stagionale e il min–max del rilevatore, in scala logaritmica; il tratteggio indica un quindicesimo. Anni 1980–1999. Con il solo min–max domina la copertura nuvolosa. 30

3.5 Correlazione fra due celle delle differenze dal normale per mese e ora, in funzione della loro distanza: mediana (linea) e quartili (fascia) per fasce di 100 km. Anni 1980–1999. Precipitazione e copertura nuvolosa perdono la correlazione entro poche celle. . 31

3.6 Le 1149 località dei dati PVGIS. Ogni punto è una posizione del reticolo con passo di 5 km per la quale sono disponibili le serie orarie. 33

4.1 Passaggi del rilevatore su un istante, dai campi ERA5 alla segnalazione. In corsivo gli anni su cui è stimata ciascuna quantità. 36
4.2 Struttura del generatore (a) e del discriminatore (b). I riquadri tratteggiati indicano i dropout, con probabilità 0.2. 37

5.1 Le tre zone attorno a un cluster in un istante, su una porzione della griglia. Ogni quadrato è una cella; le celle intermedie non rientrano in nessuna zona. 54

6.1 Le prove della ricerca degli iperparametri nel piano delle prime due componenti principali dei quattro iperparametri, colorate secondo la distanza MMD sugli anni di validazione, più scura dove è più bassa. I cerchi arancioni indicano le tre prove della regione migliore, il riquadro la direzione in cui cresce ciascun iperparametro. 64
6.2 Correlazione spaziale fra G e D in ogni istante degli anni di validazione, calcolata sulle 10611 celle: media giornaliera (linea sottile) e media mobile su 30 giorni (linea spessa). Le due correlazioni restano vicine a zero; quella di Pearson è più negativa in estate. 67
6.3 Correlazione temporale di Spearman fra G e D in ogni cella, sugli anni di validazione: blu dove D scende quando G sale, rosso dove salgono insieme; la freccia indica correlazioni oltre 0.3. Il legame è debole quasi ovunque. Linee di costa da Natural Earth. 68
6.4a Percentuale dei valori segnalati da G, senza normalizzazione climatologica, per fascia di latitudine e mese, sugli anni di validazione; il bianco corrisponde al 5%. 70
6.4b Percentuale dei valori segnalati da G_{n}, con la normalizzazione climatologica, per fascia di latitudine e mese, sugli anni di validazione; il bianco corrisponde al 5%. 70
6.5a Correlazione temporale di Spearman fra G e D_{reale}, il giudizio del discriminatore sull'osservazione, in ogni cella, sugli anni di validazione. 71
6.5b Correlazione temporale di Spearman fra G e D_{generato}, il giudizio del discriminatore sulla ricostruzione, in ogni cella, sugli anni di validazione. 71

6.6 Percentile mediano di G_{n}, G, D_{reale}, D_{generato} e D nel nucleo dei cluster di G_{n}, nel contorno e nella zona lontana, sugli anni di validazione; il tratteggio indica 50, il valore tipico. Nel nucleo il discriminatore giudica reali sia l'osservazione sia la ricostruzione. 72
6.7a G il 9 agosto 2003 alle 12 UTC, l'istante con la media di G più alta degli anni di validazione, come percentile fra le celle dell'istante; la linea arancione racchiude l'1% delle celle con G più alto. 73
6.7b D il 9 agosto 2003 alle 12 UTC, come percentile fra le celle dell'istante; la linea arancione racchiude l'1% delle celle con G più alto. 73
6.8 Indice di Jaccard delle segnalazioni di ogni coppia di metodi sugli anni di test, in percentuale. I metodi che leggono una cella in un istante formano un gruppo (nel riquadro); la variazione in tre ore resta da parte. 77
6.9 I cluster di G_{n} sugli anni di test per dimensione, cioè per numero di valori: piccoli (meno di 20), medi (da 20 a 999) ed enormi (1000 o più). In alto la percentuale dei cluster, in basso quella dei valori segnalati. Pochi cluster enormi contengono la maggior parte dei valori. 79
6.10 Percentuale dei valori segnalati per tipo di cluster, sugli anni di test, nei cluster di G_{n} (prima colonna) e in quelli di ciascuna baseline; ogni colonna somma a 100. Il tipo principale dipende dal metodo. 81
6.11a Percentile mediano dello score secondo la distanza in celle dal bordo del cluster più vicino, per ogni metodo sui propri cluster, sugli anni di test; la fascia grigia va dal più basso al più alto dei sei modelli shallow. 83
6.11b Percentile mediano dello score secondo la distanza in celle dal bordo del cluster più vicino, per tutti i metodi sui cluster di G_{n}, sugli anni di test; la fascia grigia va dal più basso al più alto dei sei modelli shallow. 83
6.12a Percentile mediano di G_{n} secondo la distanza in celle dal bordo del cluster, per tipo di cluster, sugli anni di test: velocità verticale (rosa), precipitazione (viola), copertura nuvolosa (grigio scuro), temperatura a due metri (ocra), altri tipi in grigio chiaro. 85
6.12b Scarto standardizzato mediano, in valore assoluto, della variabile del tipo, secondo la distanza in celle dal bordo del cluster, per ogni tipo di cluster, sugli anni di test. 85

6.12c Percentile mediano di ogni score a due celle fuori dal bordo dei propri cluster, un pallino per tipo di cluster, sugli anni di test; il segmento va dal tipo più basso al più alto e il numero a destra è la loro differenza. 85
6.13a Scarto standardizzato della velocità verticale il 23 novembre 2017 alle 00 UTC, con il nucleo del cluster in arancione e la cella seguita nel cerchio. 88
6.13b G_{n} come percentile il 23 novembre 2017 alle 00 UTC, con il nucleo del cluster in arancione e la cella seguita nel cerchio. . 88
6.13c Percentile di ogni score nella cella seguita (58.5°N, 8.5°E), in alto, e scarto standardizzato della velocità verticale (negativo se l'aria sale), in basso; in azzurro gli istanti in cui la cella è nel cluster. 88
6.14a Scarto standardizzato della precipitazione il 19 maggio 2006 alle 03 UTC, con il nucleo del cluster in arancione e la cella seguita nel cerchio. 90
6.14b G_{n} come percentile il 19 maggio 2006 alle 03 UTC, con il nucleo del cluster in arancione e la cella seguita nel cerchio. . 90
6.14c Percentile di ogni score nella cella seguita (56.5°N, 23°E), in alto, e scarto standardizzato della precipitazione, in basso; in azzurro gli istanti in cui la cella è nel cluster. 90
6.15a Scarto standardizzato della copertura nuvolosa il 15 giugno 2024 alle 12 UTC, con il nucleo del cluster in arancione e la cella seguita nel cerchio. 92
6.15b G_{n} come percentile il 15 giugno 2024 alle 12 UTC, con il nucleo del cluster in arancione e la cella seguita nel cerchio. 92
6.15c Percentile di ogni score nella cella seguita (23.5°N, 13°W), in alto, e scarto standardizzato della copertura nuvolosa, in basso; in azzurro gli istanti in cui la cella è nel cluster. 92
6.16a Velocità verticale, 23 novembre 2017 alle 00 UTC: percentile mediano di ogni score secondo la distanza in celle dal bordo del cluster. 93
6.16b Precipitazione, 19 maggio 2006 alle 03 UTC: percentile mediano di ogni score secondo la distanza in celle dal bordo del cluster. 93
6.16c Copertura nuvolosa, 15 giugno 2024 alle 12 UTC: percentile mediano di ogni score secondo la distanza in celle dal bordo del cluster. 93

6.17a Spostamento lungo il moto delle segnalazioni di ogni metodo rispetto ai cluster concordati brevi, secondo la velocità del cluster: mediana sui cluster, positiva davanti al cluster; la fascia grigia va dal più basso al più alto dei sei modelli shallow. 99
6.17b Spostamento lungo il moto delle segnalazioni di ogni metodo rispetto ai cluster concordati lunghi, secondo la velocità del cluster: mediana sui cluster, positiva davanti al cluster; la fascia grigia va dal più basso al più alto dei sei modelli shallow. 99
6.18a Dispersione media divisa per G medio, per fascia di percentile di G, sugli anni di test. 104
6.18b Mediana del rapporto fra dispersione e G secondo la distanza in celle dal bordo del cluster di G_{n}, sugli anni di test. 104
6.18c Valori segnalati da G_{n} divisi a parità di G in cinque classi, dalle estrazioni più concordi (1) alle più discordi (5), e percentuale di ciascuna classe oltre la soglia della distanza dal normale. . 104
6.19a Dispersione di G fra le 20 estrazioni in ogni cella, in media sugli anni di test. 106
6.19b Rapporto medio fra dispersione e G in ogni cella, sugli anni di test. 106

Capitolo 1

Introduzione

1.1 Contesto e motivazioni

Le anomalie meteorologiche, cioè condizioni dell'atmosfera lontane da quelle abituali per il luogo e il periodo dell'anno, come una perturbazione intensa, una tempesta di vento o un'ondata di caldo, sono i casi in cui i modelli addestrati su dati storici tendono a sbagliare di più [1]. Il lavoro è nato in questo contesto, nell'ambito della previsione della produzione fotovoltaica [2], dove un previsore è affidabile nelle condizioni che i dati di addestramento rappresentano bene e meno in quelle poco frequenti. Riconoscere queste condizioni è però un problema a sé, distinto dalla previsione: richiede di stabilire, per ogni luogo e ogni istante, quanto le condizioni osservate si allontanano da quelle abituali. È il compito del rilevamento di anomalie, a cui questa tesi è dedicata.

I campi meteorologici delle rianalisi, come ERA5 [3], descrivono lo stato dell'atmosfera su una griglia regolare, con molte variabili e per diversi decenni. Sono quindi una base adatta per cercare anomalie in modo sistematico, su un dominio ampio e senza limitarsi alle grandezze di un singolo impiego.

1.2 Anomalie meteorologiche senza etichette

Tre caratteristiche dei dati rendono il problema difficile e guidano le scelte dei capitoli successivi.

La prima è l'assenza di etichette. Non esiste un elenco completo di anomalie meteorologiche con cui addestrare un classificatore o misurare direttamente l'accuratezza di un rilevatore. Il rilevamento deve essere *unsupervised* e la sua valutazione deve ricorrere a strumenti indiretti.

La seconda è che i dati di addestramento non sono garantiti privi di anomalie. Molti rilevatori apprendono il comportamento normale da un insieme che si assume pulito [4]; con dati meteorologici non etichettati questa ipotesi non è verificabile. Ne segue una scelta di obiettivo: rilevare le condizioni nuove rispetto agli anni di addestramento. Le anomalie presenti negli anni di addestramento, nella misura in cui il modello le apprende, non vengono segnalate.

La terza è la struttura spaziale. Le condizioni di un luogo dipendono da quelle dei luoghi vicini, e una condizione ordinaria, presa da sola, può essere insolita rispetto a ciò che accade nei luoghi vicini. I campi non hanno però una topologia fisica, come il grafo di sensori stradali o di regioni confinanti su cui è costruito STGAN [5]: sono disposti su una griglia regolare, e il modo di rappresentare l'intorno va scelto.

Il termine anomalia meteorologica indica in questa tesi una condizione dell'atmosfera che si allontana da quella abituale per il luogo e il periodo dell'anno. Il rilevatore non la osserva direttamente: uno score misura quanto un valore, cioè una coppia cella–istante, si allontana da ciò che il modello ha appreso dagli anni di addestramento, e sono segnalati i valori con lo score più alto. Una segnalazione indica quindi una possibile anomalia meteorologica, non un'anomalia accertata. Un evento meteorologico estremo è un caso particolare di anomalia meteorologica, ma non ogni anomalia è un evento estremo.

1.3 Approccio proposto

Il rilevatore parte da STGAN [5], una rete avversaria proposta per il rilevamento di anomalie nel traffico: un generatore ricostruisce i valori dell'istante successivo a partire dal contesto spaziale e temporale, un discriminatore giudica se una sequenza è osservata o generata, e lo score combina i due. In questa tesi lo schema è portato sui campi ERA5, con quindici variabili in superficie e a 850 hPa, ogni tre ore, su un dominio che comprende l'Europa, il Mediterraneo e parte dell'Africa settentrionale e del Medio Oriente; rispetto a STGAN il rilevatore cambia in quattro punti:

1. un generatore che opera sul campo intero con un'unità ricorrente convoluzionale, la ConvGRU [6, 7], mentre il discriminatore resta locale e giudica ogni cella sulla sua *patch* 3×3;

2. un ingresso riferito al clima di ogni cella, con una normalizzazione stagionale, e un errore di ricostruzione del generatore in cui ogni variabile pesa in proporzione inversa a quanto essa cambia abitualmente;

3. uno score riferito alla climatologia di ogni cella e il dropout Monte Carlo [8] nelle due reti, che associa a ogni score una misura di dispersione;

4. una validazione senza etichette, in cui i valori più insoliti, individuati con un criterio che non usa il modello, sono in gran parte tenuti fuori dalla misura con cui si scelgono gli iperparametri dell'addestramento avversario e tolti dalla climatologia dello score; gli anni di test non entrano in alcuna scelta.

1.4 Obiettivi e contributi della tesi

Obiettivo della tesi è rilevare anomalie meteorologiche nei campi ERA5 senza etichette, adattando STGAN. Più precisamente, il lavoro si pone tre domande: quale delle due componenti dello score, l'errore di ricostruzione del generatore e la componente del discriminatore, riconosca le anomalie meteorologiche; se abbia senso sommarle, come fa lo score combinato dell'articolo; come rendere lo score confrontabile fra luoghi e stagioni. La tesi mostra anzitutto che le due componenti non concordano: dove l'errore di ricostruzione del generatore segnala un valore insolito, la componente del discriminatore in genere non lo segnala. Sommati, come nello score combinato dell'articolo, mescolano due segnali in disaccordo e danno uno score che ordina i valori quasi come la sola componente del discriminatore. Poiché l'errore di ricostruzione del generatore ha un significato chiaro, mentre la componente del discriminatore si spiega solo in parte, il rilevatore usa l'errore di ricostruzione del generatore riferito alla climatologia di ogni cella, G_{n}, che rende quasi uniforme la percentuale di segnalazioni fra luoghi e stagioni.

G_{n} è poi confrontato con otto metodi più semplici, le baseline, ciascuno con la soglia allo stesso percentile. Si sovrappone sia ai metodi che leggono soltanto le quindici variabili di una cella in un istante sia alla variazione in tre ore, che misura il cambiamento rapido, senza coincidere con nessuno: la baseline più vicina, la variazione in tre ore, segnala il 54% dei valori segnalati da G_{n}.

Le segnalazioni a contatto nello spazio e nel tempo formano cluster di segnalazioni. Circa tre quarti dei valori segnalati stanno in pochi cluster molto estesi, per lo più catene di segnalazioni a contatto più che singole anomalie meteorologiche; in tutti i metodi i cluster con almeno 1000 valori contengono fra il 60% e l'86% dei valori segnalati. Infine, tre valori segnalati su quattro restano sopra la soglia anche togliendo a G_{n} la sua dispersione, cioè quanto lo score cambia ripetendo il calcolo con maschere di dropout diverse.

1.5 Organizzazione del documento

Il resto della tesi è organizzato come segue.

- **Capitolo 2 (Fondamenti teorici e stato dell'arte):** presenta i lavori su cui la tesi è costruita, per temi, dai lavori che hanno definito ciascun problema ai più recenti, e si chiude con il modo in cui la tesi adatta STGAN e con la sua posizione rispetto ai lavori esaminati.
- **Capitolo 3 (Dati e preprocessing):** descrive i campi ERA5, il dominio, la loro preparazione, la divisione in anni di addestramento, di validazione e di test, le caratteristiche e i limiti dei campi, e i dati PVGIS da cui il lavoro è partito.
- **Capitolo 4 (Metodologia):** descrive il rilevatore: l'architettura e l'addestramento avversario, l'ingresso con la normalizzazione stagionale, i pesi delle variabili, i valori esclusi dalle misure sugli anni di validazione, lo score con il dropout Monte Carlo e la normalizzazione climatologica.
- **Capitolo 5 (Esperimenti):** descrive la misura usata per scegliere la configurazione senza etichette, la configurazione, la ricerca degli iperparametri e il protocollo di valutazione.
- **Capitolo 6 (Risultati e discussione):** riporta l'esito della ricerca degli iperparametri, studia le componenti dello score e sceglie quella da usare, confronta le segnalazioni con le otto baseline, descrive i cluster di segnalazioni per tipo e dimensione con un esempio per ciascuno dei tre tipi principali, legge le segnalazioni attorno a quelle su cui la maggior parte dei metodi concorda, esamina la dispersione del dropout e guarda, in via preliminare, grandezze di ERA5 che nessuno score legge.
- **Capitolo 7 (Conclusioni e sviluppi futuri):** riassume il lavoro e ne indica gli sviluppi futuri.
- **Appendice A (Sensibilità alla soglia):** ripete le analisi principali e le segnalazioni concordate con soglie più alte.

Capitolo 2

Fondamenti teorici e stato dell'arte

Il capitolo presenta i fondamenti teorici e i lavori su cui la tesi è costruita. Ogni tema è trattato come un percorso: dai lavori che ne hanno definito il problema a quelli più recenti, fino al metodo che la tesi riprende. Il percorso del capitolo segue quello del lavoro: partito da dati fotovoltaici PVGIS (Sezione 3.6) con il rilevatore MTGFlow, è passato a STGAN sui campi ERA5 per rappresentare il contesto spaziale fra luoghi diversi. Per ciascun lavoro sono indicati ciò che propone, ciò che ottiene e il limite che lascia aperto, che spesso è il punto da cui parte il lavoro successivo. Che cosa ne prende la tesi è detto alla fine di ogni tema e, per STGAN, nella Sezione 2.5. I lavori su cui il rilevatore si basa direttamente sono descritti più a fondo, con le relative formule. I temi sono quattro: il rilevamento di anomalie in serie temporali, l'apprendimento automatico applicato ai dati meteorologici, il contesto spaziale su griglie e grafi, la quantificazione dell'incertezza. Una sezione descrive poi il modo in cui la tesi adatta STGAN, e l'ultima riassume la posizione della tesi rispetto ai lavori esaminati.

2.1 Rilevamento di anomalie in serie multivariate e spazio-temporali

Questa sezione va dalle definizioni di anomalia ai metodi basati su reti profonde, e arriva a STGAN, la base del rilevatore. Lungo il percorso due criteri guidano la scelta del rilevatore: la tolleranza alla presenza di anomalie nei dati di addestramento, che senza etichette non si possono escludere, e la rappresentazione del contesto spaziale fra luoghi diversi. La sezione si

chiude con il problema della valutazione e con i metodi semplici usati come confronto.

2.1.1 Dalla deviazione dal valore atteso ai modelli profondi

Nella rassegna di Gupta et al. [9] sui dati temporali, un'anomalia è definita in generale come una deviazione dal valore atteso o previsto. Per i dati spazio-temporali la rassegna riprende una definizione più specifica: un'osservazione è anomala quando le sue grandezze differiscono in modo significativo da quelle degli oggetti vicini nello spazio e nel tempo. I metodi che la rassegna raccoglie per questi dati procedono per lo più in due passi, prima cercando le anomalie spaziali e poi verificandole rispetto ai vicini temporali, con intorni fissati a mano; fra le applicazioni figurano anche dati ambientali e meteorologici, come serie di precipitazione e campi di rianalisi. I metodi esaminati precedono l'uso diffuso delle reti profonde e trattano grandezze scalari o singoli oggetti, non campi multivariati considerati insieme.

La rassegna di Zamanzadeh Darban et al. [10] raccoglie i metodi profondi per serie temporali e li divide secondo il segnale da cui ricavano lo *score*: la *previsione* del valore successivo, la *ricostruzione* dell'osservazione, una rappresentazione appresa, oppure una combinazione delle prime due. Distinzioni analoghe compaiono nei lavori più recenti esaminati più avanti [11, 12]. Le reti generative avversarie vi figurano fra i metodi a ricostruzione; gli autori ne indicano come limite l'addestramento, che richiede di bilanciare generatore e discriminatore ed è instabile e difficile da far convergere. Nella rassegna il termine spaziale indica le dipendenze fra le variabili di una serie, non fra luoghi geografici; fra i dataset raccolti non compaiono campi meteorologici su griglia, e i lavori su dati geografici, come STGAN, sono citati soltanto fra le applicazioni urbane e al traffico.

Due lavori mostrano i due segnali principali e il loro limite comune, cioè l'assenza di relazioni fra le serie. Malhotra et al. [13] propongono un *encoder–decoder* basato su LSTM (*long short-term memory*), addestrato a ricostruire finestre di serie normali: una finestra anomala, che il modello non ha imparato a ricostruire, produce un errore più alto, e lo score è la distanza di Mahalanobis del vettore degli errori dalla loro distribuzione sui dati normali. La soglia di decisione è però scelta massimizzando un indice di accuratezza su sequenze anomale etichettate, e negli esperimenti con più sensori le serie sono ridotte alla prima componente principale: il metodo, quindi, non è interamente unsupervised e non modella più variabili insieme. Hundman et al. [14] seguono la via della previsione per la telemetria di veicoli spaziali:

una LSTM per canale prevede il valore successivo, e gli errori, smussati, sono confrontati con una soglia scelta senza etichette, che separa i valori più alti dal resto della distribuzione degli errori. Sui due insiemi di dati dell'articolo il metodo raggiunge una precisione dell'87.5% e un richiamo dell'80.0% [14]. Gli autori indicano fra i limiti le interazioni fra i canali, che un modello per canale non rappresenta, e osservano che la qualità del rilevamento dipende da quella della previsione.

Anche i modelli più complessi non risolvono questo limite. Xu et al. [15] introducono Anomaly Transformer, in cui l'attenzione di un Transformer è affiancata da una distribuzione a priori concentrata sui punti vicini. Il criterio è che un'osservazione anomala, essendo rara, non riesce a stabilire legami con il resto della serie e concentra l'attenzione sui punti adiacenti; lo score moltiplica l'errore di ricostruzione per una funzione della differenza fra le due distribuzioni. La soglia è fissata senza etichette, come la percentuale di score più alti su un periodo di validazione. Le variabili sono riunite in un unico vettore per istante e lo score è uno per istante: il metodo non rappresenta relazioni spaziali e non localizza l'anomalia fra le variabili. I risultati dell'articolo sono misurati con un criterio che considera rilevato un intero segmento anomalo quando ne è segnalato anche un solo punto [15].

2.1.2 Relazioni fra le serie e dati di addestramento contaminati

Una linea di lavori rappresenta le relazioni fra le serie con un grafo appreso dai dati, quando queste relazioni non sono note. Deng e Hooi [16] propongono GDN per i sensori di impianti industriali: a ogni sensore è associato un vettore appreso, i vicini di ciascun sensore sono i più simili secondo questi vettori, e un'attenzione su grafo prevede il valore successivo di ogni sensore. L'errore di ogni sensore è normalizzato con la sua mediana e il suo intervallo interquartile, e lo score di un istante è il massimo sui sensori, perché un'anomalia può interessarne anche uno soltanto; la soglia è il massimo dello score su un periodo di validazione. Il grafo collega sensori di uno stesso impianto, non luoghi, e si assume che i dati di addestramento siano normali.

Zhou et al. [4] rimuovono questa ipotesi: osservano che gran parte dei metodi presuppone dati di addestramento composti da sole osservazioni normali, e che quando contengono anomalie le prestazioni possono degradare sensibilmente. Il loro metodo, MTGFlow, stima la densità dell'intero insieme di addestramento e identifica come anomale le osservazioni di test a bassa densità, sotto l'ipotesi che le anomalie occupino regioni più sparse. Le dipendenze fra entità sono apprese come grafo dinamico e un *normalizing flow* specifico

per entità associa a ciascuna una distribuzione normale parametrizzata. La soglia è ricavata dall'intervallo interquartile degli score di addestramento e lo score per entità consente di localizzare l'anomalia.

Le entità di MTGFlow sono i sensori o le variabili di un unico sistema e la valutazione usa dataset pubblici di riferimento: il grafo è appreso dai dati e descrive relazioni fra variabili, non fra siti geografici distinti. Un'estensione assegna una distribuzione comune alle entità di uno stesso gruppo, quando è noto che hanno caratteristiche simili. Il raggruppamento esprime soltanto che certe entità possono comportarsi allo stesso modo: non modella vicinanza, distanze o propagazione nello spazio, e non rende il metodo un rilevatore spazio-temporale.

MTGFlow è stato il primo rilevatore esaminato nel lavoro, per la sua robustezza alla presenza di anomalie nei dati di addestramento: per le condizioni meteorologiche non sono disponibili etichette, quindi non è possibile garantire dati di addestramento composti da sole osservazioni normali. È stato applicato ai dati PVGIS del lavoro preliminare. Non rappresenta però il contesto geografico.

I due lavori più recenti esaminati tornano all'ipotesi di dati di addestramento normali. Wu et al. [11] propongono CATCH, un metodo basato su ricostruzione nel dominio della frequenza. Lo spettro è suddiviso in bande, trattate come *patch*, per cogliere caratteristiche a grana fine; un modulo di fusione dei canali, con un generatore di maschere e un'attenzione mascherata, seleziona per ciascuna banda le correlazioni fra canali ritenute utili e isola quelle irrilevanti. Il metodo mira a rilevare insieme anomalie puntuali e di sottosequenza ed è valutato su dataset reali e sintetici. Lo score di anomalia è l'errore di ricostruzione: il modello impara a ricostruire i pattern normali, e nei dataset sintetici dell'articolo le anomalie sono inserite soltanto nella serie di test. Il caso di anomalie presenti nei dati di addestramento non è trattato. I canali sono le variabili di una serie multivariata: non è prevista una struttura geografica fra serie di siti diversi. Gli autori segnalano inoltre che anomalie più lunghe della finestra osservata non vengono colte efficacemente.

Alnegheimish et al. [12] propongono M2AD, per serie multivariate provenienti da più sistemi. Un modello LSTM apprende il comportamento atteso dei sensori. I residui fra valori attesi e osservati sono aggregati in uno score globale mediante un modello a miscela gaussiana e una calibrazione Gamma. La soglia è stimata dagli score osservati in addestramento, e i sensori sono ordinati per contributo allo score. Il metodo assume che i dati di addestramento siano privi di anomalie e che addestramento e test abbiano andamenti simili; gli autori indicano come limite il caso in cui la distribuzione cambia, che richiede un nuovo addestramento.

CATCH e M2AD sono stati presi in esame come alternative a MTGFlow

e non sono stati adottati, per due ragioni. Richiedono dati di addestramento privi di anomalie, una condizione che senza etichette non è verificabile sui dati meteorologici; e, come MTGFlow, non rappresentano relazioni fra luoghi geografici. Nessuno dei due è stato eseguito sui dati della tesi. Dei due criteri della sezione, quindi, il primo ha portato a MTGFlow, il secondo, che nessuno di questi metodi soddisfa, a STGAN, che offre il contesto spaziale al prezzo di presupporre dati di addestramento normali.

2.1.3 Reti generative avversarie per il rilevamento di anomalie

Una rete generativa avversaria [17] è formata da due reti, addestrate insieme con obiettivi opposti. Il generatore G trasforma un rumore z, estratto da una distribuzione nota p_z, in un campione $G(z)$; i dati reali seguono la distribuzione p_{data} e il discriminatore D restituisce la probabilità $D(x)$ che un campione x provenga dai dati reali anziché dal generatore. Le due reti sono addestrate sulla stessa funzione, che il discriminatore massimizza e il generatore minimizza:

$$\min_G \max_D V(D,G) = \mathbb{E}_{x\sim p_{\text{data}}}\Big[\log D(x)\Big] + \mathbb{E}_{z\sim p_z}\Big[\log\Big(1 - D(G(z))\Big)\Big]. \quad (2.1)$$

Il primo termine cresce quando il discriminatore riconosce i dati reali, il secondo quando riconosce i campioni generati; il generatore è addestrato a rendere i propri campioni indistinguibili da quelli reali. Entrambe le reti sono ottimizzate con la retropropagazione. Lo stesso articolo osserva che, all'inizio dell'addestramento, il secondo termine fornisce al generatore un gradiente debole, e propone in alternativa di addestrarlo a massimizzare $\log D(G(z))$.

Schlegl et al. [18] usano per primi questo schema per il rilevamento di anomalie, con AnoGAN, su immagini di tomografia della retina. La rete è addestrata soltanto su immagini sane; poiché una GAN non fornisce la trasformazione inversa da un'immagine al rumore che la genera, per ogni immagine da valutare il rumore è cercato con un'ottimizzazione iterativa, a reti fissate. Lo score somma due termini: la differenza fra l'immagine e quella generata, e la distanza fra le rispettive caratteristiche in uno strato intermedio del discriminatore. Sui dati dell'articolo lo score completo raggiunge un'area sotto la curva ROC di 0.89; preso da solo, il termine di ricostruzione arriva a 0.88, quello del discriminatore a 0.74 [18]. Li et al. [19] estendono l'idea alle serie temporali multivariate di impianti industriali con MAD-GAN, in cui generatore e discriminatore sono LSTM e tutte le variabili sono modellate insieme, dopo una riduzione con le componenti principali. Lo score combina, con un peso, l'errore di ricostruzione, ottenuto ancora con un'inversione

iterativa nello spazio latente, e l'uscita del discriminatore. L'articolo non indica come scegliere quel peso né la soglia, e i risultati migliori sono selezionati fra più configurazioni; gli autori segnalano inoltre una forte oscillazione del richiamo da un'epoca all'altra, che attribuiscono all'instabilità del rilevamento basato su GAN [19]. Nessuno dei due metodi rappresenta relazioni spaziali fra le serie.

Nel rilevatore della tesi lo schema è usato in forma condizionata: il generatore riceve il contesto di un'osservazione e ne produce una ricostruzione. L'uso per il rilevamento di anomalie poggia su un'ipotesi di lavoro: che la ricostruzione sia accurata nelle condizioni frequenti nei dati di addestramento e meno accurata in quelle poco rappresentate. È un'ipotesi e non una proprietà garantita dall'addestramento. Se vale, se ne ricavano due segnali: l'errore fra l'osservazione e la sua ricostruzione, e il giudizio del discriminatore sull'osservazione. Già in AnoGAN, preso da solo, il termine del discriminatore rileva meno di quello di ricostruzione. STGAN, descritto di seguito, li combina in un unico score.

2.1.4 STGAN

Deng et al. [5] propongono una rete avversaria per il rilevamento di anomalie del traffico. Il generatore prevede la dinamica normale combinando tre rami: un ramo recente, basato su unità ricorrenti con convoluzione su grafo, per le dipendenze spazio-temporali di breve periodo, un ramo per il trend di lungo periodo e uno per le variabili esterne. Il discriminatore stabilisce se una sequenza è reale o generata in funzione dei vicini nello spazio e nel tempo, fornendo un criterio che varia con località e istante. Dopo l'addestramento avversario entrambe le reti agiscono da rilevatore e uno score ne combina i contributi. Il grafo deriva da una topologia fisica, cioè sensori adiacenti sulla stessa strada o regioni con confini comuni, e la valutazione misura il richiamo rispetto a incidenti ed eventi documentati, che gli autori stessi indicano come verità di riferimento incompleta. L'articolo non discute la presenza di anomalie nei dati di addestramento: il discriminatore è addestrato considerando normali le sequenze reali e anomale quelle generate, quindi l'ipotesi di dati di addestramento normali è implicita. La Figura 2.1 riassume la struttura del metodo.

Sia $x_{v,t}$ l'osservazione del nodo v all'istante t e $X_{v,t}$ l'insieme delle osservazioni nel sottografo formato da v e dai suoi vicini. Sia poi $S_{v,t}$ la sequenza reale dei valori del sottografo che termina con $X_{v,t}$, e $\hat{S}_{v,t}$ la stessa sequenza in cui l'ultimo elemento è sostituito dalla stima $\hat{X}_{v,t} = G_\theta(v,t)$ del generatore.

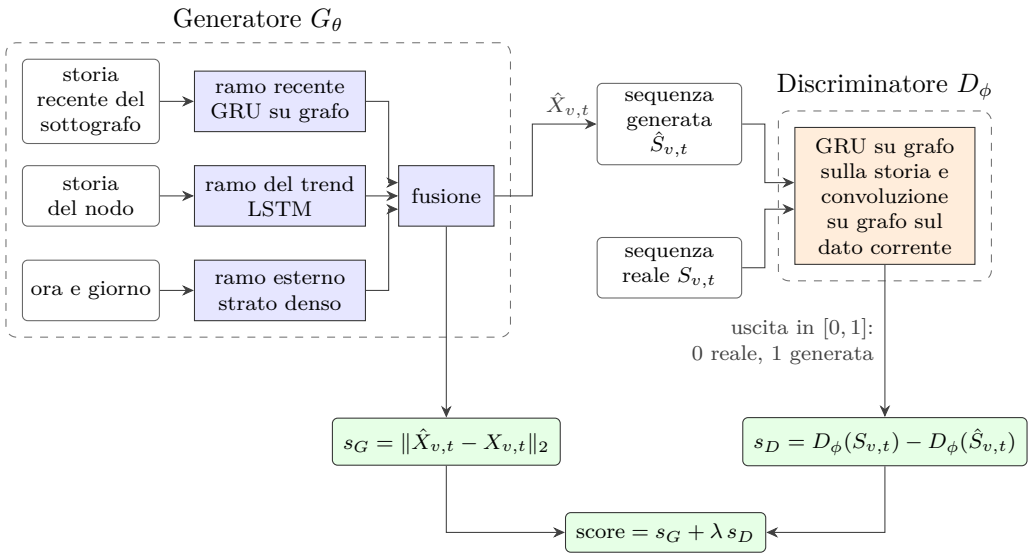


Figura 2.1: Schema di STGAN. Il generatore combina tre rami e produce la stima $\hat{X}_{v,t}$, che sostituisce l'ultimo elemento della sequenza reale; il discriminatore valuta le due sequenze. Ridisegnato a partire da Deng et al. [5].

Gli obiettivi di addestramento dell'articolo sono

$$\mathcal{L}_G(\theta) = \sum_s -\log\Big(1 - D_\phi(\hat{S}_{v,t})\Big) + \lambda_G \, \|G_\theta(v,t) - X_{v,t}\|_2, \tag{2.2}$$

$$\mathcal{L}_D(\phi) = \sum_s -\log\Big(D_\phi(\hat{S}_{v,t})\Big) - \log\Big(1 - D_\phi(S_{v,t})\Big), \tag{2.3}$$

dove la somma è sui punti $s = \langle v, t, x_{v,t}\rangle$ e λ_G bilancia l'errore di previsione e il termine avversario. Lo score combina le due reti:

$$\begin{aligned} s_D(v,t) &= D_\phi(S_{v,t}) - D_\phi(\hat{S}_{v,t}), \\ s_G(v,t) &= \|G_\theta(v,t) - X_{v,t}\|_2, \\ \text{score}(v,t) &= s_G(v,t) + \lambda\, s_D(v,t). \end{aligned} \tag{2.4}$$

La componente del discriminatore non è la sua uscita sulla sequenza reale ma la differenza rispetto alla sequenza generata: gli autori la introducono per ridurre l'effetto dell'imprevedibilità dei dati reali. Negli esperimenti dell'articolo $\lambda_G = 500$, le due componenti sono normalizzate e $\lambda = 1$.

Rispetto all'equazione (2.1), in STGAN il significato dell'uscita del discriminatore è invertito: le sequenze reali sono trattate come normali e quelle generate come anomale, e il discriminatore è spinto verso 1 sulle sequenze generate e verso 0 su quelle reali. Per il discriminatore l'obiettivo è lo stesso a meno di questo scambio, ma la sua uscita cresce con il sospetto di anomalia

e può essere usata per costruire lo score. Il termine avversario dell'equazione (2.2) è la forma alternativa dell'obiettivo del generatore proposta da Goodfellow et al., scritta in questa convenzione, a cui si aggiunge l'errore di previsione.

Il generatore di STGAN stima i valori dell'istante corrente a partire dagli istanti precedenti, e l'articolo chiama *errore di previsione* la differenza fra stima e osservazione. Nella tesi il generatore ricostruisce allo stesso modo il campo di un istante dalla storia recente, e la stessa differenza è chiamata *errore di ricostruzione del generatore*: i due termini indicano la stessa grandezza. Nella classificazione della rassegna di Zamanzadeh Darban et al. lo score rientrerebbe quindi fra quelli basati sulla previsione, anche se le reti avversarie vi figurano fra i metodi a ricostruzione.

La tesi riprende l'architettura a tre rami e gli obiettivi avversari, e mantiene lo score combinato come riferimento; il modo in cui li adatta ai campi meteorologici è descritto nella Sezione 2.5. Rispetto alle equazioni (2.2)–(2.4), la forma implementata segue il codice pubblicato dagli autori, con l'errore quadratico medio al posto della norma e la loss del discriminatore dimezzata (Sezione 4.2.3); lo score è descritto nella Sezione 4.6. L'addestramento richiede un equilibrio fra le due reti: il peso di ricostruzione λ_G, 500 negli esperimenti dell'articolo, i tassi di apprendimento delle due reti e gli aggiornamenti D:G, cioè quanti aggiornamenti di ciascuna rete sono eseguiti su ogni *batch*, sono scelti nella tesi con la ricerca degli iperparametri (Sezione 5.2).

2.1.5 Il problema della valutazione

I risultati dei lavori precedenti sono misurati su dataset etichettati, e la loro affidabilità dipende da quella delle etichette. Wu e Keogh [20] esaminano i dataset più usati per le serie temporali univariate e vi riscontrano quattro difetti ricorrenti. Il primo è che molti problemi si risolvono con una sola riga di codice basata su operazioni elementari, come media, deviazione standard e differenze successive: una riga di questo tipo risolve 316 delle 367 serie di uno dei dataset. Gli altri sono una densità di anomalie poco realistica, etichette errate o mancanti, e anomalie concentrate verso la fine delle serie. Gli autori ne concludono che parte dei progressi riportati può essere apparente, e raccomandano di confrontare ogni metodo con soluzioni banali e di esaminare sempre visivamente dati e score. L'analisi riguarda serie univariate e non tratta campi multivariati su griglia; le sue indicazioni valgono però anche in assenza di etichette, dove il confronto con metodi semplici e l'esame diretto di mappe e serie degli score restano gli strumenti disponibili.

Liu e Paparrizos [21] riprendono il problema con TSB-AD, un insieme di 1070 serie, univariate e multivariate, ricontrollate a mano, su cui confrontano

quaranta rilevatori con gli stessi dati e la stessa procedura di scelta dei parametri. Mostrano che il criterio che considera rilevato un intero segmento quando ne è segnalato un solo punto premia anche uno score casuale, e adottano misure che non dipendono da una soglia. Con queste misure i metodi non neurali sono spesso fra i migliori, con un'analisi per componenti principali in testa fra le serie univariate; fra le multivariate prevalgono reti semplici, convoluzionali o ricorrenti, e lo stesso metodo per componenti principali, mentre Anomaly Transformer risulta ultimo in entrambi i gruppi. Anche TSB-AD richiede etichette, non contiene campi su griglia e non studia dati di addestramento contaminati da anomalie; ne resta l'indicazione che un rilevatore appreso va sempre confrontato con metodi semplici, perché la sua superiorità non è scontata.

Per questi motivi le segnalazioni del rilevatore sono confrontate con sei modelli shallow, scelti fra i metodi non neurali valutati in TSB-AD, cioè l'analisi per componenti principali (PCA), CBLOF (*cluster-based local outlier factor*), MCD (*minimum covariance determinant*), HBOS (*histogram-based outlier score*), COPOD (*copula-based outlier detection*) e Isolation Forest, e con due metodi statistici semplici, la distanza dal normale e la variazione in tre ore: in tutto otto baseline (Sezione 5.4).

2.2 Apprendimento automatico e dati meteorologici

Questa sezione descrive come l'apprendimento automatico è stato applicato ai campi meteorologici, prima per prevederli e poi per riconoscerne gli eventi estremi, e mostra che il rilevamento unsupervised di anomalie su tutti gli stati di una rianalisi non è stato affrontato nei lavori esaminati.

2.2.1 Dalla previsione numerica ai modelli basati sui dati

La previsione meteorologica numerica tratta l'evoluzione dell'atmosfera come un problema ai valori iniziali: le equazioni che la governano sono integrate a partire dallo stato osservato, e i processi di scala inferiore alla griglia, come convezione, radiazione e nubi, sono rappresentati da parametrizzazioni. Bauer et al. [22] ne ricostruiscono i progressi, che attribuiscono soprattutto a parametrizzazioni migliori, alla previsione d'insieme e all'assimilazione dei dati, e stimano che l'accuratezza fra tre e dieci giorni sia cresciuta di circa un giorno per decennio. Fra le sfide aperte indicano la verifica delle code della

distribuzione, per cui servono misure adatte a statistiche scarse. Le rianalisi come ERA5 [3] nascono dallo stesso apparato: combinano un modello di previsione con le osservazioni disponibili per stimare lo stato dell'atmosfera in ogni istante.

Rasp et al. [1] rendono ERA5 il riferimento comune per i modelli di previsione basati sui dati, con WeatherBench: un insieme di campi ERA5 a risoluzione ridotta, periodi di addestramento, validazione e test contigui nel tempo e confronti con persistenza, climatologia e previsione numerica. Nella discussione gli autori osservano che gli eventi estremi, essendo rari, contano poco nelle metriche medie come l'errore quadratico, che le reti estrapolano male a stati diversi da quelli visti in addestramento e che una rete addestrata con l'errore quadratico produce campi troppo regolari; propongono le GAN come possibile rimedio a quest'ultimo problema. Lam et al. [23] portano l'approccio alla risoluzione nativa di ERA5 con GraphCast, una rete su grafo addestrata sui campi ERA5 dal 1979 al 2017, che supera la previsione deterministica operativa sul 90.3% delle combinazioni di variabile, livello e orizzonte esaminate. Gli autori riconoscono che l'addestramento con l'errore quadratico porta il modello a esprimere l'incertezza sfumando i campi, e che il modello migliora quando è riaddestrato su anni più recenti, per ragioni non del tutto chiarite. Per valutare gli eventi estremi definiscono come tali i valori oltre un percentile di una climatologia per luogo, ora del giorno e mese.

Questi lavori usano ERA5 per prevedere; la tesi lo usa per riconoscere anomalie meteorologiche. Alcune loro osservazioni valgono anche per questo impiego: un modello addestrato su anni passati con un errore medio rappresenta meglio le condizioni frequenti, tende a smussare quelle rare, e il suo comportamento può cambiare quando i dati si allontanano dal periodo di addestramento.

2.2.2 Eventi estremi e anomalie nei campi meteorologici

I primi lavori che applicano reti profonde agli eventi meteorologici estremi lo fanno in modo supervised. Liu et al. [24] classificano con reti convoluzionali poco profonde ritagli di campi centrati su cicloni tropicali, fiumi atmosferici e fronti, con etichette ottenute da criteri a soglia e da esperti, e riportano accuratezze di test fra l'89% e il 99%; il metodo classifica ritagli già centrati e non localizza gli eventi. Gli autori indicano nella scarsità di dati etichettati un limite, e la necessità di approcci unsupervised. Racah et al. [25] passano alla localizzazione con ExtremeWeather, un insieme di simulazioni climatiche in cui i riquadri degli eventi sono ottenuti da criteri a soglia: un encoder–decoder convoluzionale nello spazio e nel tempo unisce una loss supervised sui riquadri a una di ricostruzione su tutti i campi, così che contribuiscano anche quelli

senza etichette. Gli autori osservano che etichette prodotte da criteri a soglia sono incomplete, e che un metodo supervised addestrato su di esse può al più imitarli; lasciano esplicitamente aperto il rilevamento di anomalie.

Prabhat et al. [26] affrontano il problema delle etichette con ClimateNet, un insieme di campi annotati a mano da esperti. La campagna ha coinvolto circa ottanta esperti e ha prodotto 459 immagini etichettate; l'accordo fra due esperti sulla stessa immagine, misurato come sovrapposizione delle aree annotate, è in media di 0.51, e il modello di segmentazione addestrato su queste etichette ottiene un accordo analogo con gli esperti. Le etichette sono quindi costose e, sui confini degli eventi, incerte anche per gli esperti. Il modello è addestrato e valutato su simulazioni climatiche, e l'applicazione alle rianalisi è lasciata a lavori futuri.

La scarsità di etichette motiva i lavori più recenti, che applicano modelli generativi unsupervised a ERA5. Zaninelli et al. [27] addestrano un autoencoder variazionale sui campi giornalieri di temperatura a due metri di un clima di riferimento, preindustriale in un modello climatico oppure i primi decenni di ERA5, e trattano come anomalo ciò che il modello non ricostruisce nei campi recenti; l'obiettivo è l'attribuzione delle ondate di calore al cambiamento climatico, e l'anomalia è quindi la distanza da un clima di riferimento, su una sola variabile. Paçal et al. [28] addestrano un autoencoder variazionale spazio-temporale su nove variabili ERA5, con addestramento sugli anni 1941–1990 e test sugli anni 2001–2022, e raggruppano nello spazio latente le configurazioni atmosferiche delle ondate di calore in Europa occidentale; i campioni sono però selezionati in anticipo con una soglia sulla temperatura, e gli autori notano che le ricostruzioni del modello smussano gli estremi.

Nelle ricerche condotte per questa tesi non è emerso un lavoro che assegni uno score di anomalia a tutti gli stati dell'atmosfera di una rianalisi, su più variabili insieme e con un modello spazio-temporale avversario: i lavori supervised richiedono etichette che sono scarse e incerte, quelli unsupervised su ERA5 riguardano una sola variabile oppure eventi già selezionati. La ricerca non è esaustiva, e l'assenza va intesa in questo senso.

2.3 Contesto spaziale su griglie e grafi

STGAN rappresenta il contesto spaziale con convoluzioni su grafo, che presuppongono una rete di adiacenze. Le convoluzioni su grafo si sono diffuse nella previsione del traffico: Yu et al. [29] propongono STGCN, in cui blocchi formati da una convoluzione temporale, una convoluzione su grafo e una seconda convoluzione temporale prevedono la velocità del traffico sulle stazioni di una rete stradale. Il grafo è dato dalla rete stradale oppure costruito con

un kernel sulla distanza fra le stazioni, con parametri fissati a mano. Gli autori motivano il grafo osservando che una convoluzione ordinaria limita il modello a dati disposti su una griglia, come immagini e video. È proprio il caso dei campi della tesi, disposti su una griglia regolare: questa sezione richiama l'operatore che sulla griglia svolge il ruolo della convoluzione su grafo, l'unità ricorrente convoluzionale.

Le unità ricorrenti a *gate*, come quella introdotta da Cho et al. [30] e nota come GRU, aggiornano uno stato nascosto mediante gate che regolano quanta parte dello stato precedente conservare e quanta sostituire. Nella forma originaria ingresso e stato sono vettori e i gate sono trasformazioni dense. Quando l'ingresso è un campo disposto su una griglia, le trasformazioni dense possono essere sostituite da convoluzioni, così che lo stato mantenga la struttura spaziale e i parametri siano condivisi fra le posizioni. L'idea è stata proposta per la LSTM nella previsione a breve termine delle precipitazioni [6] e per la GRU nell'apprendimento di rappresentazioni di sequenze video [7]. STGAN applica la stessa idea a un grafo: nel suo ramo recente i prodotti matriciali della GRU sono sostituiti da convoluzioni su grafo [5].

Sia X_s l'ingresso all'istante s e H_{s-1} lo stato precedente, entrambi disposti sulla griglia. Uno strato ricorrente convoluzionale a gate calcola

$$R_s = \sigma(W_r * [X_s, H_{s-1}] + b_r)\,, \tag{2.5}$$

$$U_s = \sigma(W_u * [X_s, H_{s-1}] + b_u)\,, \tag{2.6}$$

$$\widetilde{H}_s = \tanh(W_c * [X_s, R_s \odot H_{s-1}] + b_c)\,, \tag{2.7}$$

$$H_s = U_s \odot H_{s-1} + (1 - U_s) \odot \widetilde{H}_s, \tag{2.8}$$

dove W_r, W_u, W_c sono i kernel delle convoluzioni e b_r, b_u, b_c i termini costanti, appresi durante l'addestramento, σ è la funzione sigmoidale, $*$ una convoluzione spaziale, $\odot$ il prodotto elemento per elemento e $[\cdot, \cdot]$ la concatenazione sui canali. Il gate di reset R_s regola quanto dello stato precedente entra nello stato candidato $\widetilde{H}_s$; il gate di aggiornamento U_s regola quanto dello stato precedente viene conservato. La forma è quella dell'unità su grafo di STGAN, con la convoluzione su grafo sostituita da una convoluzione spaziale.

Con un *kernel* di lato k e *padding* $\lfloor k/2 \rfloor$, ogni convoluzione vede le celle entro $\lfloor k/2 \rfloor$ posizioni. Il gate di reset e lo stato candidato applicano due convoluzioni in sequenza, quindi a ogni istante lo stato precedente si propaga fino a $2\lfloor k/2 \rfloor$ posizioni: l'area che influenza una cella cresce con il numero di istanti e di strati. La tesi impiega questo operatore nel generatore e nel discriminatore di STGAN (Sezioni 4.2.1 e 4.2.2).

2.4 Quantificazione dell'incertezza

Lo score di STGAN è un numero unico per osservazione, senza una misura della sua variabilità. Nella rassegna di Abdar et al. [31] l'incertezza di una previsione è distinta in due tipi: quella aleatoria, propria dei dati e non riducibile, e quella epistemica, dovuta alla conoscenza limitata del modello e ai dati insufficienti. Gli autori indicano le approssimazioni bayesiane e gli insiemi di modelli come i due metodi più usati, e il riconoscimento di dati lontani da quelli di addestramento come un problema ancora aperto; è l'incertezza epistemica quella che ci si attende cresca per stati poco rappresentati nei dati, come le condizioni meteorologiche rare per un modello addestrato su anni passati. Questa sezione presenta il *dropout* Monte Carlo, applicato al rilevatore, e le principali alternative.

Gal e Ghahramani [8] interpretano l'addestramento con dropout come un'inferenza bayesiana approssimata. Mantenendo il dropout attivo in previsione e ripetendo più volte il passaggio in avanti si ottiene un insieme di uscite, la cui dispersione fornisce una stima dell'incertezza del modello con un costo aggiuntivo contenuto. L'equivalenza è ricavata per una rete con il dropout prima di ogni strato con parametri; nell'esperimento con una rete convoluzionale gli autori lo applicano, come d'uso in queste reti, soltanto prima dell'ultimo strato completamente connesso. Dati J passaggi in avanti $\hat{y}_j(x)$ ottenuti con maschere di dropout diverse, la media predittiva è stimata da

$$\mathbb{E}[y \mid x] \approx \frac{1}{J} \sum_{j=1}^{J} \hat{y}_j(x), \tag{2.9}$$

e la varianza predittiva dalla varianza campionaria dei J passaggi, a cui l'articolo somma l'inverso della precisione del modello.

Nella tesi il dropout Monte Carlo è applicato alle due reti del rilevatore, il generatore e il discriminatore di STGAN, non per stimare l'incertezza di una previsione ma per campionare lo score di anomalia. Durante il calcolo degli score i dropout restano attivi e il calcolo è ripetuto con maschere di dropout diverse, le *estrazioni*: per ogni valore sono riportate la media dello score sulle estrazioni, come nell'equazione (2.9), e la sua deviazione standard, la *dispersione*, come descritto nella Sezione 4.6. In questo impiego la dispersione misura la variabilità dello score rispetto alle maschere di dropout e non costituisce una stima calibrata dell'incertezza; il termine di precisione previsto da Gal e Ghahramani non viene aggiunto.

Le alternative principali richiedono di cambiare l'addestramento. Lakshminarayanan et al. [32] propongono il Deep Ensemble, un'alternativa non bayesiana: più reti vengono addestrate in modo indipendente a partire da

inizializzazioni diverse, e le loro previsioni sono combinate come una miscela a pesi uguali. Il metodo è semplice da realizzare, produce un'incertezza maggiore sugli ingressi lontani dai dati di addestramento, ma richiede di addestrare una rete per ogni membro dell'insieme: per il rilevatore, ciascun addestramento dura circa quattordici ore, mentre il dropout Monte Carlo ottiene la dispersione da un solo addestramento. Una terza famiglia di metodi ottiene la dispersione rendendo stocastica la dinamica interna della rete, modellando l'evoluzione dello stato nascosto come un'equazione differenziale stocastica, in cui una rete di drift ne descrive l'andamento e una rete di diffusione scala un termine casuale: SDE-Net [33] e il suo adattamento SDE U-Net [34]. Il rilevatore non li adotta: aggiungere a STGAN una rete di diffusione e una dinamica stocastica si sarebbe discostato molto dall'architettura dell'articolo, mentre il dropout Monte Carlo richiede soltanto di aggiungere strati di dropout alle reti esistenti. L'applicazione di questi metodi al rilevatore è indicata fra gli sviluppi futuri.

2.5 Da STGAN al rilevatore della tesi

STGAN è nato per il traffico: il grafo deriva da una rete fisica, lo score combina due componenti e la valutazione misura il richiamo su incidenti documentati (Sezione 2.1.4). La tesi ne riprende l'architettura a tre rami e gli obiettivi avversari e la porta su campi meteorologici privi di etichette, con le modifiche descritte nei paragrafi seguenti.

Griglia e campo intero. Nell'articolo il contesto spaziale è un grafo, e in assenza di una rete fisica le sue adiacenze andrebbero scelte con un criterio di vicinanza. Sulla griglia regolare dei campi della tesi, invece, le posizioni relative dei vicini sono definite. La convoluzione su grafo del ramo recente è quindi sostituita da una ConvGRU (Sezione 2.3), e il ramo LSTM del trend è conservato. Il ramo delle variabili esterne riceve la codifica del tempo: nell'articolo il giorno della settimana e l'ora, qui una codifica temporale ciclica, diversa per cella (Sezione 4.3); nel Capitolo 4 è chiamato ramo del calendario. Il generatore elabora in una sola passata il campo intero di un istante, mentre il discriminatore continua a giudicare l'intorno di ogni cella, una patch al posto del sottografo dell'articolo (Sezioni 4.2.1 e 4.2.2).

Ingresso e pesi. L'ingresso è riferito al normale stagionale di ogni cella, con una codifica del tempo per cella, ora solare locale e posizione nell'anno, al posto di quella pensata per il traffico, e l'errore di ogni variabile è pesato in proporzione inversa a quanto essa cambia abitualmente (Sezioni 4.3 e 4.4).

Obiettivo: condizioni nuove rispetto all'addestramento. L'articolo tratta come normali le sequenze reali dei dati di addestramento, mentre per i campi meteorologici dati di addestramento privi di anomalie non sono garantiti. A differenza di MTGFlow, STGAN non tollera per costruzione dati contaminati: la tesi accetta questo limite in cambio del contesto spaziale e lo traduce in una scelta di obiettivo, cioè rilevare condizioni nuove rispetto agli anni di addestramento. Le anomalie meteorologiche presenti negli anni di addestramento sono trattate come già osservate: nella misura in cui il modello le apprende, condizioni simili non vengono segnalate, mentre lo sono quelle poco o per nulla rappresentate in quegli anni. Lo score misura quindi la distanza da quanto il modello ha appreso dagli anni di addestramento (per tre variabili al netto di una tendenza lineare, Sezione 4.3), non la rarità di una condizione in assoluto.

Lo score è continuo e non coincide con la decisione: sono segnalati soltanto i valori, cioè le coppie cella–istante, con score più alto, in una percentuale che è un parametro del protocollo (Sezione 5.3). Una segnalazione indica una possibile anomalia meteorologica, non un'anomalia accertata (Capitolo 1).

Score e dispersione. Accanto allo score combinato dell'articolo, la tesi considera un secondo score: l'errore di ricostruzione del generatore riferito ai valori abituali di questo stesso errore nella cella, nel giorno dell'anno e nell'ora, perché la grandezza tipica dell'errore cambia da luogo a luogo e da stagione a stagione (Sezione 4.7); è indicato con G_{n}. Se sommare le due componenti o usare G_{n} è studiato nel Capitolo 6, che sceglie G_{n}. Il dropout Monte Carlo nel generatore e nel discriminatore (Sezione 2.4) associa a ogni score una misura di dispersione, che l'articolo non prevede.

Validazione senza etichette. L'articolo valuta il rilevatore su eventi documentati, che per i campi meteorologici non sono disponibili in modo sistematico. La tesi introduce quindi anni di validazione, su cui, prima di valutare gli anni di test, si sceglie la configurazione con la distanza MMD fra campi osservati e ricostruiti nello spazio delle componenti principali (Sezione 5.1) e si stimano climatologia e soglia degli score. I valori più insoliti degli anni di validazione, individuati con un criterio che non dipende dal modello, pesano il meno possibile nella distanza MMD e sono tolti dalla climatologia, mentre la soglia li include (Tabella 4.1). Monaco et al. [34] seguono un'idea simile, ma sull'addestramento: nella correzione delle previsioni di precipitazione escludono gli eventi intensi dall'addestramento e li mantengono nel test. La tesi invece addestra su tutti i dati degli anni di addestramento.

2.6 Posizionamento del lavoro

La tesi adatta un rilevatore avversario spazio-temporale, nato per il traffico, a campi meteorologici privi di etichette e di topologia fisica, lungo gli assi della Sezione 2.5, e lo valuta senza etichette, confrontandolo con i metodi più semplici della Sezione 2.1.5. Il contributo consiste nell'adattamento, nella combinazione di questi elementi e nel protocollo di valutazione, e nello studio delle due componenti dello score di STGAN su questi dati: non concordano, sommate danno uno score che ordina i valori quasi come la sola componente del discriminatore, e la tesi usa quindi l'errore di ricostruzione del generatore riferito alla propria climatologia, G_{n} (Capitolo 6). Gli elementi di base sono preesistenti: la tesi non propone un nuovo algoritmo di rilevamento.

La Tabella 2.1 riassume i quattro candidati considerati per il rilevatore e il percorso della tesi, secondo i criteri usati nel capitolo. Le voci relative agli articoli riportano ciò che gli articoli dichiarano; dove un aspetto non è discusso, è indicato come non trattato. STGAN è la base del rilevatore; MTGFlow è stato eseguito nel lavoro preliminare sui dati PVGIS; CATCH e M2AD sono stati valutati sugli articoli e non eseguiti.

I capitoli seguenti descrivono i dati e il rilevatore costruito su queste scelte.

Tabella 2.1: Candidati considerati per il rilevatore e percorso della tesi a confronto.

Lavoro	Segnale dello score	Anomalie nei dati di addestramento	Contesto spaziale	Dati e riferimento della valutazione	Dispersione
STGAN [5]	Errore di previsione e discriminatore	Non trattate: dati reali considerati normali	Sì: grafo da topologia fisica	Traffico; richiamo su eventi documentati	Non prevista
MTGFlow [4]	Densità stimata	Ammesse per costruzione	No: relazioni fra variabili	Sensori; dataset etichettati	Non prevista
CATCH [11]	Errore di ricostruzione in frequenza	Non trattate	No: canali di una serie	Serie multivariate; dataset etichettati, reali e sintetici	Non prevista
M2AD [12]	Residui di previsione aggregati	Escluse per ipotesi	No: sensori di più sistemi	Sensori di più sistemi; dataset etichettati e un caso industriale	Non prevista
Tesi	Score del rilevatore G_{n}, scelto dopo lo studio delle due componenti; score combinato di STGAN come confronto	Trattate come già osservate	Sì: vicini sulla griglia	Campi ERA5; nessuna etichetta: componenti dello score e baseline	Dropout Monte Carlo

Capitolo 3

Dati e preprocessing

Il capitolo descrive i campi meteorologici su cui il rilevatore è addestrato e valutato: le variabili della rianalisi ERA5, il dominio e la cadenza temporale, la preparazione dei dati, la loro suddivisione in anni di addestramento, di validazione e di test, le loro caratteristiche e i loro limiti. L'ultima sezione descrive i dati PVGIS da cui il lavoro è partito: serie orarie di una sola regione, con irradianza, temperatura e vento come sole grandezze meteorologiche, che non permettono di risalire alla condizione meteorologica che le ha prodotte, e per questo il lavoro è passato ai campi ERA5. Le trasformazioni che dipendono dal modello, come la normalizzazione stagionale, sono descritte nel Capitolo 4.

3.1 Campi ERA5 e dominio

I dati sono quelli della rianalisi ERA5 [3], cioè stime dello stato dell'atmosfera prodotte da un modello vincolato dalle osservazioni, e provengono da due prodotti distinti: variabili a livello singolo e variabili su livelli di pressione, di cui è usato soltanto il livello di 850 hPa. Le variabili sono quindici, scelte per descrivere le perturbazioni da più lati. Si possono raggruppare per ruolo: la temperatura, a due metri e a 850 hPa (un livello in quota, sopra lo strato vicino al suolo), e l'umidità specifica a 850 hPa descrivono lo stato termodinamico; la pressione al livello del mare, il vento a dieci metri e a 850 hPa e la velocità verticale descrivono la circolazione; la copertura nuvolosa, la radiazione solare alla superficie e la precipitazione descrivono nubi e fenomeni associati; l'umidità del primo strato del suolo, la velocità d'attrito, che misura lo sforzo del vento sulla superficie, e l'altezza dello strato limite, lo strato vicino al suolo rimescolato dalla turbolenza, descrivono la superficie e lo strato più basso dell'atmosfera. La Tabella 3.1 le elenca con le unità di ERA5, che non vengono convertite.

Tabella 3.1: Le quindici variabili ERA5, con la sigla e l'unità del dataset. Precipitazione e radiazione sono accumuli di un'ora; le altre variabili sono istantanee. Nel seguito si usano nomi brevi: vento zonale e meridionale, umidità specifica, umidità del suolo, strato limite, radiazione solare, precipitazione e copertura nuvolosa.

Variabile	Sigla	Livello	Unità
Temperatura a due metri	t2m	Livello singolo	K
Componente zonale del vento a dieci metri	u10	Livello singolo	$\mathrm{m\,s^{-1}}$
Componente meridionale del vento a dieci metri	v10	Livello singolo	$\mathrm{m\,s^{-1}}$
Pressione al livello medio del mare	msl	Livello singolo	Pa
Precipitazione totale	tp	Livello singolo	m
Copertura nuvolosa totale	tcc	Livello singolo	0–1
Radiazione solare discendente alla superficie	ssrd	Livello singolo	$\mathrm{J\,m^{-2}}$
Umidità volumetrica del primo strato del suolo	swvl1	Livello singolo	$\mathrm{m^3\,m^{-3}}$
Velocità d'attrito	zust	Livello singolo	$\mathrm{m\,s^{-1}}$
Altezza dello strato limite	blh	Livello singolo	m
Componente zonale del vento	u	850 hPa	$\mathrm{m\,s^{-1}}$
Componente meridionale del vento	v	850 hPa	$\mathrm{m\,s^{-1}}$
Velocità verticale	w	850 hPa	$\mathrm{Pa\,s^{-1}}$
Temperatura	t	850 hPa	K
Umidità specifica	q	850 hPa	$\mathrm{kg\,kg^{-1}}$

I dati coprono gli anni dal 1980 al 2025: partono dall'era dei satelliti, in cui le osservazioni assimilate dalla rianalisi comprendono i dati da satellite [3]. Sono selezionati gli istanti UTC 00, 03, 06, 09, 12, 15, 18 e 21, su una griglia di $0.5° \times 0.5°$ nell'area compresa fra 20° e 60° di latitudine nord e fra 15° di longitudine ovest e 50° di longitudine est (Figura 3.1). Il dominio comprende l'Europa, il Mediterraneo e parte dell'Africa settentrionale e del Medio Oriente: è il più ampio, centrato sull'Europa, compatibile con la memoria e i tempi di calcolo disponibili. La griglia di 0.5° e la cadenza di tre ore sono più rade di quelle originali di ERA5, di 0.25° e di un'ora: sono scelte per contenere la memoria occupata e i tempi di calcolo. Il campionamento ogni tre ore è una selezione di istanti, non un'aggregazione: precipitazione e radiazione conservano l'accumulo di un'ora associato a ciascun istante selezionato, senza somme triorarie. Le due ore fra istanti consecutivi non sono lette, e un breve rovescio che cade lì può non comparire.

Il dominio. Il dominio unisce climi molto diversi: a sud il Sahara e le coste del Nord Africa, al centro il Mediterraneo, a nord l'Europa atlantica e continentale fino alla Scandinavia meridionale, con rilievi come le Alpi, i Pirenei e l'Atlante. A ovest si affaccia sull'Atlantico, da cui arriva gran parte delle perturbazioni che attraversano l'Europa. Gli stessi valori delle variabili hanno quindi significati diversi da un luogo all'altro e da una stagione all'altra: una temperatura ordinaria in estate nel Sahara sarebbe eccezionale in Europa settentrionale, e un cielo coperto, abituale d'inverno a nord, è raro nel deserto (Sezione 3.4). Per questo il rilevatore riferisce sia i dati in ingresso sia lo score a ciò che è abituale per ogni cella, giorno dell'anno e ora (Sezioni 4.3 e 4.7), invece di confrontare fra loro celle lontane.

La griglia contiene $81 \times 131 = 10611$ celle. Nel seguito i dati sono indicati come un tensore $X \in \mathbb{R}^{T \times N \times F}$, con T istanti, $N = 10611$ celle e $F = 15$ variabili.

Sono conservate le celle per le quali tutte le variabili sono definite nel primo istante dei dati, e si verifica che questo insieme rimanga identico in tutto il periodo; se cambia, la preparazione si interrompe, e non viene applicata imputazione. Il criterio è la completezza delle variabili, non una classificazione terra–mare: nei dati usati tutte le variabili, anche l'umidità del suolo, sono definite su tutte le celle, mare compreso, e nessuna cella è esclusa.

3.2 Acquisizione e preparazione dei dati

I dati comprendono 134416 istanti, 10611 celle e 15 variabili: circa 2.1×10^{10} numeri, 85.6 GB in precisione singola. Il passaggio dai file di ERA5 ai dati

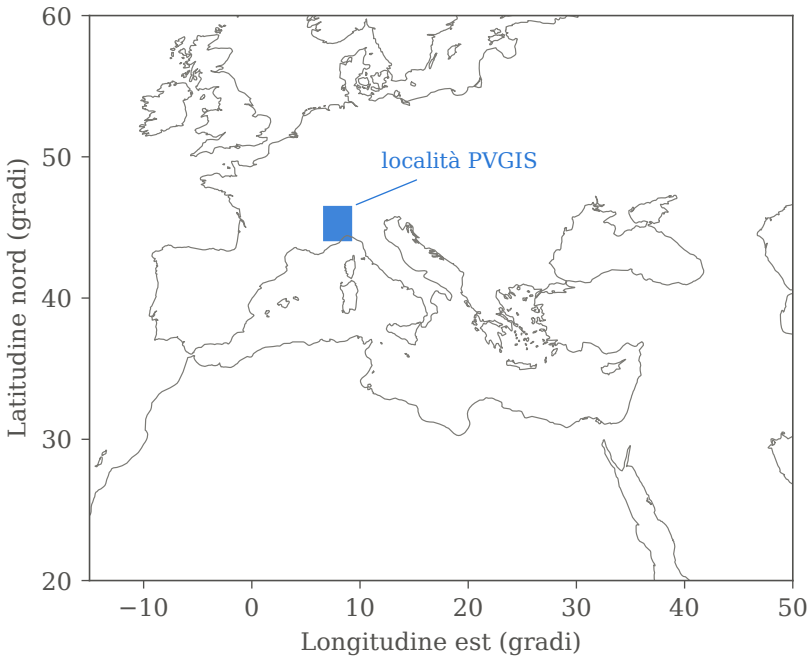


Figura 3.1: Dominio dei campi ERA5: 81 × 131 celle di 0.5°, fra 20° e 60° di latitudine nord e fra 15° di longitudine ovest e 50° di longitudine est. Il rettangolo indica l'area delle località PVGIS, in Piemonte. Linee di costa da Natural Earth.

letti dal modello è quindi automatizzato, in modo che nessun passo richieda di tenere in memoria l'intero periodo. Si articola in quattro fasi: scarico, verifica, preparazione e lettura (Figura 3.2).

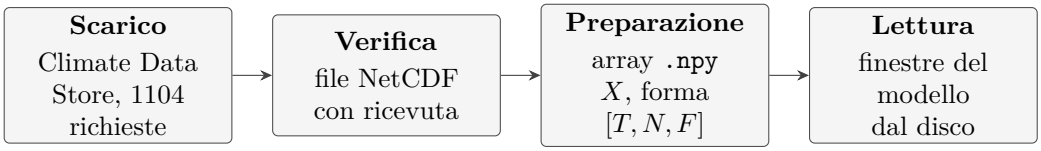


Figura 3.2: Le quattro fasi dai file di ERA5 ai dati letti dal modello: scarico dal Climate Data Store, verifica dei file, preparazione in array su disco e lettura delle sole finestre usate.

Scarico. I campi sono richiesti al Climate Data Store di Copernicus attraverso la sua interfaccia di programmazione, con una richiesta per mese e per prodotto: 552 mesi e 1104 richieste. Ogni richiesta fissa le variabili, gli otto istanti del giorno, la griglia di 0.5°, il dominio e, per il secondo prodotto, il livello di 850 hPa. Il passaggio alla griglia di 0.5° è svolto dal servizio; i file ricevuti, in formato NetCDF [35], non vengono riscritti. Prima dello scarico i nomi delle variabili sono confrontati con quelli accettati dal servizio. Fino a otto richieste sono eseguite in parallelo, e una richiesta respinta per un limite temporaneo del servizio viene ripetuta dopo un'attesa crescente.

Verifica. Un mese è conservato solo se supera tutti i controlli. Gli istanti devono essere esattamente quelli richiesti, senza mancanti né duplicati; latitudini e longitudini devono essere quelle del dominio, con passo di 0.5°; il livello di pressione deve essere soltanto 850 hPa. Devono essere presenti tutte le variabili, senza valori infiniti e senza campi interamente mancanti in un istante. Per ogni mese è salvata una *ricevuta*, un piccolo file con la richiesta e l'impronta SHA-256 di ciascun file scaricato, che permette di riconoscere i mesi già scaricati e integri. Quando lo scarico viene ripreso, i mesi con ricevuta e impronta corrette sono saltati e gli altri sono scaricati di nuovo.

Preparazione. La preparazione, svolta da un programma distinto da quello di scarico, controlla prima che tutti i mesi del periodo siano presenti, poi legge i file mese per mese, a blocchi di 32 istanti. Ripete i controlli su istanti, griglia e livello di pressione, allinea i due prodotti sugli stessi istanti e sulle stesse coordinate, e ordina le latitudini da nord a sud e le longitudini da ovest a est. Ogni blocco diventa la parte corrispondente del tensore X, in precisione

singola, senza conversioni di unità né imputazione, ed è scritto direttamente nella sua posizione in file in formato `.npy` di NumPy [36]. Un file di metadati registra la griglia, le variabili, gli anni e il numero di celle escluse.

Lettura. I file sono aperti in mappatura di memoria: durante l'addestramento e il calcolo degli score si leggono dal disco soltanto gli istanti e le celle di ciascuna finestra. La suddivisione negli anni della Sezione 3.3 è applicata alla lettura.

3.3 Anni di addestramento, di validazione e di test

Il tensore X è diviso in tre periodi consecutivi. Gli anni 1980–1999 sono usati per l'addestramento, gli anni 2000–2004 per la validazione e gli anni 2005–2025 per il test: rispettivamente 58440, 14616 e 61360 istanti, cioè il 43%, l'11% e il 46% del totale. La divisione è cronologica: il modello non vede mai anni successivi a quelli su cui è valutato. Gli anni di test cominciano nel 2005, il primo anno dei dati PVGIS della Sezione 3.6, così che i due insiemi di dati si sovrappongono negli anni di test. Tutte le quantità che il Capitolo 4 stima dai dati per l'ingresso e la loss del modello sono calcolate sui soli anni di addestramento.

Gli anni di validazione servono a confrontare le configurazioni e a fissare, prima di valutare gli anni di test, tutte le quantità che descrivono il comportamento abituale degli score. Queste quantità, fra cui le soglie, sono elencate nella Tabella 4.1. Gli anni di test non entrano in alcuna scelta: ricevono senza modificarle le quantità stimate sugli anni di addestramento e su quelli di validazione. L'articolo di STGAN [5] separa i dati in addestramento e test senza un insieme di validazione: gli anni di validazione sono un'aggiunta di questo lavoro, necessaria perché in assenza di etichette la scelta della configurazione deve basarsi su una misura calcolata fuori dagli anni di test.

Il modello legge, per ogni istante, fino a 56 istanti precedenti, cioè sette giorni. I primi istanti di ciascun periodo leggono quindi la coda del periodo precedente: la storia recente e il trend dei primi istanti degli anni di validazione contengono gli ultimi istanti degli anni di addestramento, e lo stesso vale fra gli anni di validazione e quelli di test. Gli istanti letti dal periodo precedente non rientrano fra quelli valutati.

3.4 Caratteristiche dei campi

Tre proprietà dei campi motivano altrettante scelte del Capitolo 4. Sono misurate sugli anni di addestramento, senza il rilevatore; solo il confronto della Figura 3.4 anticipa i pesi del Capitolo 4.

Cicli diversi da luogo a luogo. La temperatura a due metri e la copertura nuvolosa hanno un ciclo stagionale e uno giornaliero, con livello e ampiezza diversi da una cella all'altra (Figura 3.3). La media mensile della temperatura va da 1 a 17 °C in una cella dell'Europa settentrionale (55°N, 10°E), da 2 a 24 °C nella Pianura Padana (45°N, 9°E) e da 11 a 32 °C nel Sahara (25°N, 10°E); la copertura nuvolosa media sta fra 0.60 e 0.78 nella prima cella e fra 0.04 e 0.29 nell'ultima. Anche il ciclo giornaliero cambia con il luogo e con la stagione: l'escursione media della temperatura nel giorno è di 1 °C in gennaio e di 5 °C in luglio in Europa settentrionale, di 5 e 9 °C nella Pianura Padana, di 12 e 11 °C nel Sahara. Lo stesso valore di una variabile è quindi abituale in un luogo e in una stagione e insolito in altri. Per questo i valori delle variabili in ingresso sono riferiti al normale stagionale della propria cella, del giorno e dell'ora (Sezione 4.3), e gli score alla climatologia della propria cella (Sezione 4.7).

Variazioni di grandezza diversa. Per una variabile f, la variazione quadratica media su 24 ore è

$$m_f = \frac{1}{TN} \sum_{t,n} \left(\tilde{x}_{t,n,f} - \tilde{x}_{t-8,n,f} \right)^2, \tag{3.1}$$

dove $\tilde{x}$ è il valore dopo la trasformazione considerata e $t - 8$ l'istante di 24 ore prima; il rilevatore la stima su 720 coppie di istanti equispaziati degli anni di addestramento; la percentuale di f è $100\, m_f / \sum_{f'} m_{f'}$. Le 24 ore confrontano istanti alla stessa ora e non contengono quindi il ciclo giornaliero. La percentuale dice quanto ciascuna variabile pesa in un errore di ricostruzione del generatore che somma le variabili con lo stesso peso. Con il min–max di STGAN, che riporta ogni variabile fra il minimo e il massimo degli anni di addestramento, la copertura nuvolosa produce l'84.1% della variazione quadratica media su 24 ore delle quindici variabili, e la seconda, l'umidità specifica, ha appena il 3.2% (Figura 3.4). La copertura nuvolosa passa spesso da sereno a coperto nel corso di un giorno e attraversa quasi tutto il proprio intervallo; la temperatura cambia di pochi gradi, in un intervallo che comprende tutte le celle e tutte le stagioni. Un errore di ricostruzione del generatore che somma le variabili con lo stesso peso sarebbe quindi in gran

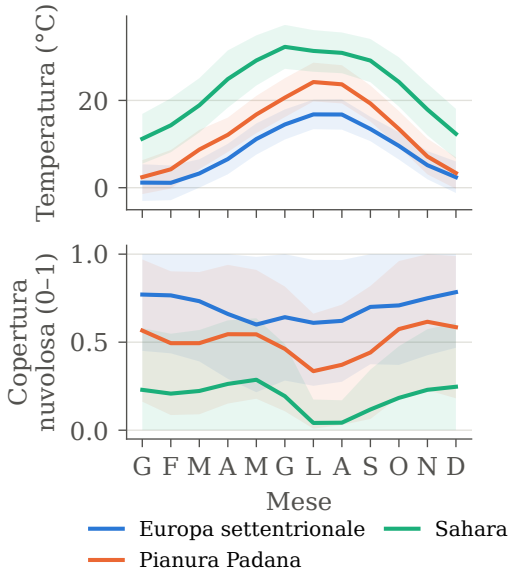


Figura 3.3a: Ciclo stagionale della temperatura a due metri e della copertura nuvolosa in tre celle: media per mese, con una fascia a una deviazione standard. Anni 1980–1999. Livello e ampiezza del ciclo cambiano da una cella all'altra.

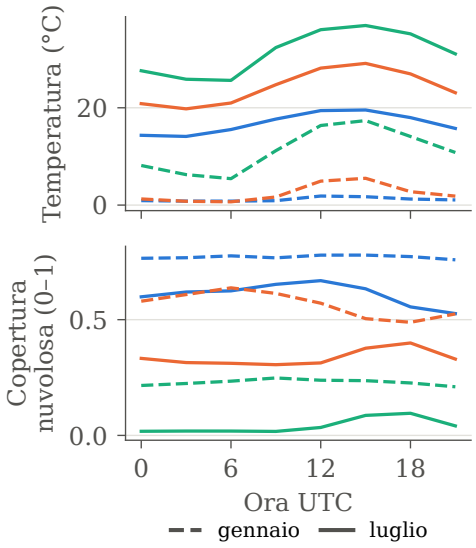


Figura 3.3b: Ciclo giornaliero della temperatura a due metri e della copertura nuvolosa in Europa settentrionale (blu), Pianura Padana (arancio) e Sahara (verde): media per ora UTC in gennaio (tratteggio) e in luglio (linea continua). Anni 1980–1999. Il ciclo cambia con il luogo e con la stagione.

parte un errore sulla copertura nuvolosa. Dopo la normalizzazione stagionale e il min–max del rilevatore le percentuali vanno dallo 0.9% dell'umidità del suolo al 16.6% dell'umidità specifica, e la copertura nuvolosa ha il 6.7%, quasi esattamente un quindicesimo, la percentuale che spetterebbe a ogni variabile se contassero tutte allo stesso modo: la normalizzazione stagionale rende confrontabili anche le variabili fra loro. Queste percentuali sono ricavate dai pesi della Sezione 4.4, che sono proporzionali all'inverso di m_f e correggono le differenze che restano.

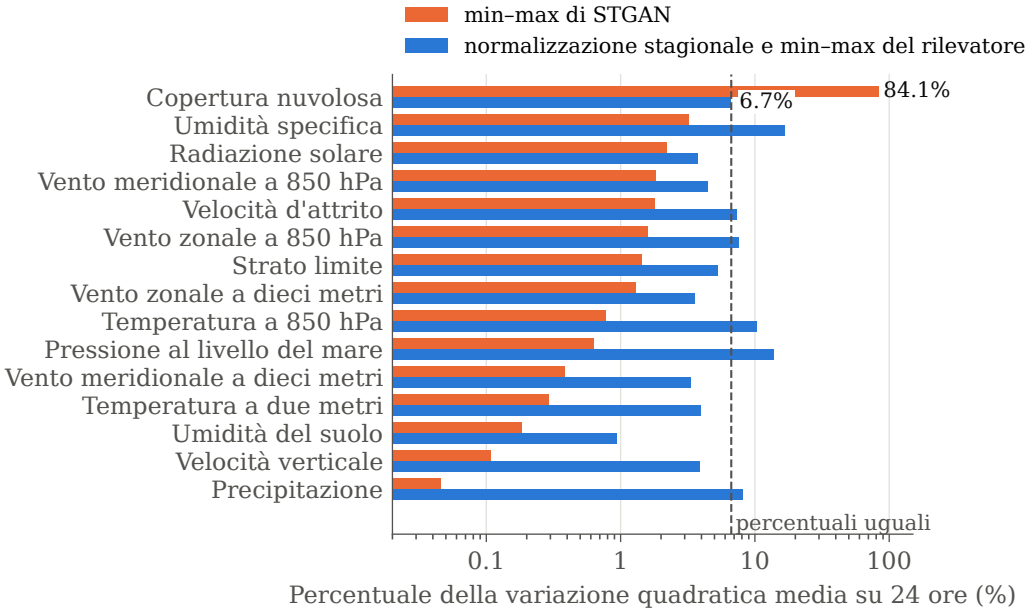


Figura 3.4: Percentuale di ciascuna variabile nella variazione quadratica media su 24 ore, dopo il min–max di STGAN e dopo la normalizzazione stagionale e il min–max del rilevatore, in scala logaritmica; il tratteggio indica un quindicesimo. Anni 1980–1999. Con il solo min–max domina la copertura nuvolosa.

Legame spaziale a corto raggio. Le differenze dal normale per mese e ora di due celle, cioè le differenze fra il valore della variabile e la media della propria cella, del mese e dell'ora, non divise per la deviazione standard e quindi diverse dallo scarto standardizzato della Sezione 4.3, sono tanto meno correlate quanto più le celle sono lontane (Figura 3.5). Qui la media è per mese, una stima più semplice di quella per giorno usata nel Capitolo 4. Sono confrontate due variabili di grande scala, pressione e temperatura, e due legate alle perturbazioni, copertura nuvolosa e precipitazione; la distanza è misurata

lungo la superficie terrestre. Le coppie sono formate da 300 celle scelte a caso, su un istante ogni nove degli anni di addestramento, un passo dispari che legge tutte le ore del giorno; la mediana e i quartili sono calcolati per fasce di 100 km, e la prima fascia si basa su 36 coppie di celle. La correlazione mediana scende sotto 0.5 oltre circa 1300 km per la pressione al livello del mare e 900 km per la temperatura a due metri, ma già oltre 200 km per la copertura nuvolosa e 100 km per la precipitazione. Le variabili legate alle perturbazioni dipendono quindi dalle celle vicine, con una correlazione che cala già nelle prime centinaia di chilometri: è il contesto spaziale che il rilevatore rappresenta con la ConvGRU del generatore e con la patch del discriminatore (Sezione 4.2). Una cella misura circa 55 km in latitudine: la patch 3×3 del discriminatore copre le celle entro circa 55 km, e la ConvGRU allarga il raggio di alcune celle a ogni istante della storia recente.

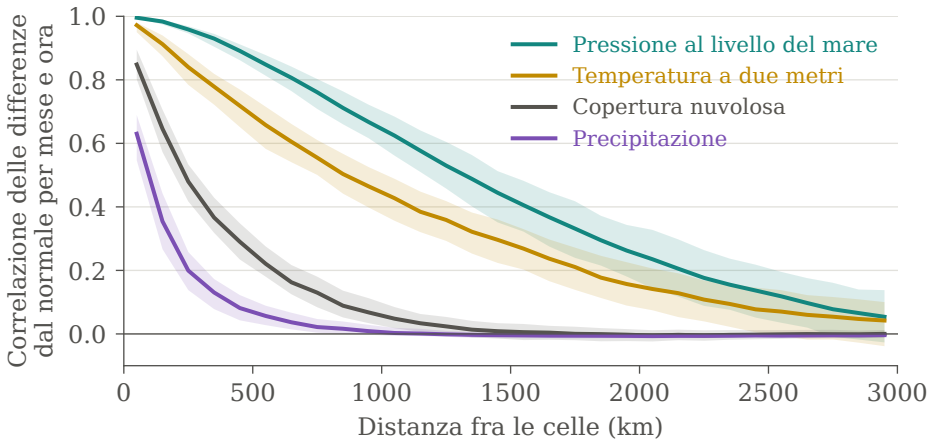


Figura 3.5: Correlazione fra due celle delle differenze dal normale per mese e ora, in funzione della loro distanza: mediana (linea) e quartili (fascia) per fasce di 100 km. Anni 1980–1999. Precipitazione e copertura nuvolosa perdono la correlazione entro poche celle.

3.5 Qualità e limiti dei dati

ERA5 è una rianalisi: i campi sono stime di un modello vincolato dalle osservazioni disponibili, non misure dirette (Sezione 2.2). Due proprietà dei dati vanno tenute presenti nella lettura dei risultati.

Variabili lontane da una distribuzione gaussiana. La precipitazione è nulla nella maggior parte degli istanti e assume di rado valori molto alti; la

copertura nuvolosa è limitata fra 0 e 1. Il Capitolo 4 tratta la precipitazione con una radice quarta prima della normalizzazione stagionale (Sezione 4.3).

Deriva dopo gli anni di addestramento. Riferite al normale per mese e ora degli anni 1980–1999, le medie annuali delle variabili sull'intero dominio non restano costanti negli anni successivi. Negli ultimi cinque anni la media è $+0.60$ deviazioni standard per la temperatura a due metri e $+0.37$ per quella a 850 hPa, $+0.81$ e $+0.50$ in estate, e -0.20 per l'umidità del suolo; per la pressione, la radiazione solare e la copertura nuvolosa resta entro ± 0.03. La tendenza lineare che la Sezione 4.3 sottrae a tre variabili, stimata sugli anni 1980–1999, riduce la deriva a $+0.07$ e $+0.09$ per le due temperature; per l'umidità del suolo, che negli anni di addestramento ha una tendenza debole e deriva soprattutto dal 2000, solo a -0.13. Per l'umidità specifica a 850 hPa la media resta fra -0.13 e $+0.06$ deviazioni standard negli anni di addestramento e sale a $+0.17$ negli ultimi cinque anni: è una deriva reale, che la normalizzazione stagionale del Capitolo 4 non toglie. Per la precipitazione, standardizzata senza la radice quarta, la media passa da circa 0 a valori fra $+0.09$ e $+0.26$ dal 2000 in poi, senza alcun salto nei dati grezzi: è un effetto della normalizzazione stagionale di una variabile molto asimmetrica fuori dagli anni su cui è stimata, non un cambiamento del clima. Il rilevatore usa una radice quarta, che riduce l'asimmetria; quanta parte della deriva resti nei suoi ingressi non è stato misurato. In tutti questi casi gli anni di test si allontanano da quelli di addestramento, e un rilevatore unsupervised può segnalare in parte questa distanza invece di anomalie meteorologiche di un singolo istante.

3.6 I dati PVGIS del lavoro preliminare

Il lavoro è partito, nell'ambito della previsione della produzione fotovoltaica, da serie orarie ottenute dal Photovoltaic Geographical Information System [37] con la banca dati di radiazione SARAH3, provenienti dal progetto SentinelPV del Politecnico di Torino. Coprono 1149 località del Piemonte, comprese fra $44.08°$ e $46.47°$ di latitudine nord e fra $6.66°$ e $9.20°$ di longitudine est. Nella proiezione UTM del fuso 32 le località occupano 1149 delle 41×54 posizioni di un reticolo regolare con passo di 5 km: quelle che ricadono nel territorio regionale (Figura 3.6), racchiuso nel rettangolo della Figura 3.1. Sono disponibili gli anni dal 2005 al 2023, con 8760 ore per anno (8784 negli anni bisestili) e senza valori mancanti; i valori sono riferiti al minuto 10 di ciascuna ora, in tempo universale.

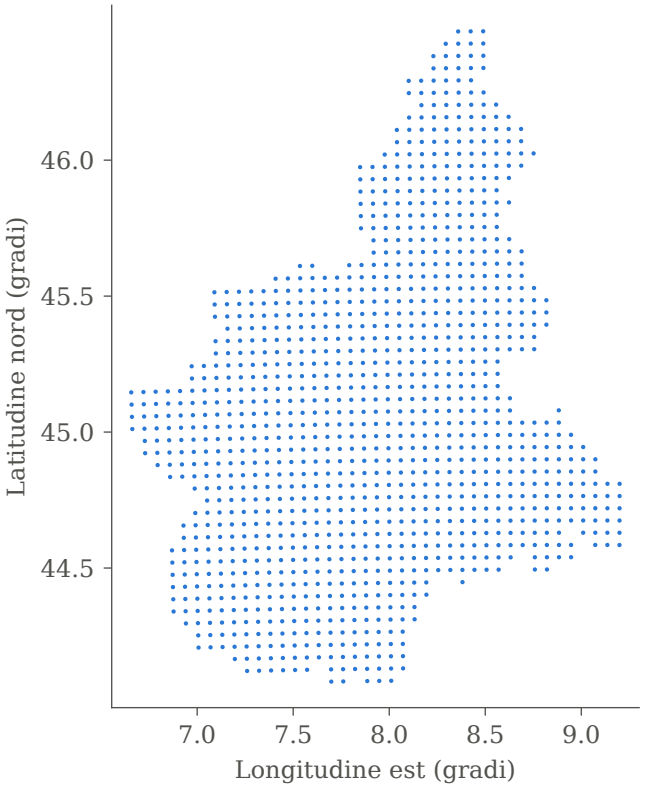


Figura 3.6: Le 1149 località dei dati PVGIS. Ogni punto è una posizione del reticolo con passo di 5 km per la quale sono disponibili le serie orarie.

Per ogni località e ogni istante sono disponibili l'irradianza globale con le sue componenti diretta, diffusa e riflessa, l'altezza del sole, la temperatura dell'aria a due metri, la velocità del vento a dieci metri e la potenza prodotta (Tabella 3.2). L'irradianza è riferita al piano orizzontale: l'inclinazione indicata nei dati è nulla, la componente riflessa risulta nulla e l'irradianza globale coincide con la somma delle componenti diretta e diffusa. Circa la metà dei valori di irradianza è nulla, perché notturna. La potenza è una produzione teorica calcolata da PVGIS, non la misura di un impianto reale.

Tabella 3.2: Grandezze dei dati PVGIS e loro unità.

Grandezza	Unità
Irradianza globale (diretta più diffusa)	$\mathrm{W\,m^{-2}}$
Irradianza diretta	$\mathrm{W\,m^{-2}}$
Irradianza diffusa	$\mathrm{W\,m^{-2}}$
Irradianza riflessa (nulla)	$\mathrm{W\,m^{-2}}$
Altezza del sole	gradi
Temperatura dell'aria a due metri	°C
Velocità del vento a dieci metri	$\mathrm{m\,s^{-1}}$
Potenza prodotta (teorica)	W

Queste sono le sole grandezze disponibili, e sono quelle che determinano la produzione fotovoltaica. Una segnalazione su questi dati non può essere ricondotta a una condizione meteorologica più generale: per rilevare anomalie meteorologiche di tipo diverso e descriverne l'origine il lavoro è passato ai campi ERA5 descritti nelle sezioni precedenti. Su questi dati il lavoro preliminare ha sviluppato un previsore della produzione e i primi rilevatori, che la tesi non riporta.

Capitolo 4

Metodologia

Il capitolo descrive il rilevatore nella forma usata sui campi ERA5. La Sezione 4.1 formula il problema: che cosa entra nel rilevatore, che cosa ne esce e quando un valore è segnalato. Seguono l'architettura del generatore e del discriminatore con gli obiettivi dell'addestramento avversario (Sezione 4.2), l'ingresso del modello (Sezione 4.3), i pesi delle variabili nell'errore di ricostruzione del generatore, i valori esclusi dalle misure sugli anni di validazione, le componenti dello score con il dropout Monte Carlo e la normalizzazione climatologica dello score. Il capitolo si ferma allo score: la misura con cui si confrontano le configurazioni è descritta nel Capitolo 5, e ciò che si ricava dallo score, come il raggruppamento delle segnalazioni in cluster di segnalazioni, nel Capitolo 6.

La Figura 4.1 riporta l'ordine in cui questi passaggi agiscono su un istante, e per ogni quantità stimata gli anni su cui è stimata: normalizzazione stagionale e pesi sugli anni di addestramento, prima di addestrare il modello; climatologia e soglia sugli anni di validazione, dopo l'addestramento. Il discriminatore non compare nella catena: serve all'addestramento del generatore e allo score combinato, calcolato solo per confronto.

4.1 Formulazione del problema

I dati sono una sequenza di campi X_t, uno per istante t, su una griglia di $N_y = 81$ righe e $N_x = 131$ colonne, cioè $N = 10611$ celle, con $F = 15$ variabili (Capitolo 3); x_{tnf} indica il valore della variabile f nella cella n. Per ogni istante il generatore riceve la storia recente, cioè gli R campi che lo precedono, una serie più lunga di ciascuna cella per il trend e la codifica temporale, e restituisce una stima $\hat{X}_t$ del campo, la *ricostruzione*, con valori $\hat{x}_{tnf}$. L'errore quadratico fra ricostruzione e osservazione, pesato per variabile e mediato

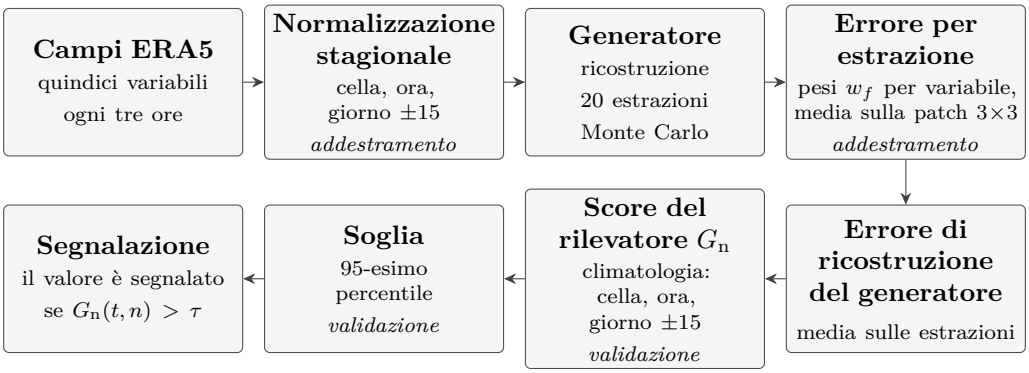


Figura 4.1: Passaggi del rilevatore su un istante, dai campi ERA5 alla segnalazione. In corsivo gli anni su cui è stimata ciascuna quantità.

sulla patch 3×3 di ogni cella e su più estrazioni Monte Carlo, è l'*errore di ricostruzione del generatore* $\bar{s}_{G,tn}$, una delle due componenti dello score combinato di STGAN (Sezione 4.6). Espressa rispetto ai valori abituali di questo stesso errore nella cella, nel giorno dell'anno e nell'ora, diventa lo *score del rilevatore* $G_n(t,n)$ (Sezione 4.7), nel testo semplicemente G_n. Una coppia cella–istante, nel seguito un *valore*, è *segnalata* quando $G_n(t,n) > \tau$, con la soglia τ pari al 95-esimo percentile di G_n sugli anni di validazione (Sezione 5.3). Lo score misura quindi la distanza da ciò che il modello ha appreso negli anni di addestramento (Sezione 2.5), e una segnalazione indica una possibile anomalia meteorologica, non un'anomalia accertata.

4.2 Architettura e addestramento avversario

Il rilevatore segue lo schema di STGAN [5] descritto nella Sezione 2.1.4: un generatore ricostruisce il campo dell'istante successivo a partire dagli istanti precedenti, e un discriminatore giudica se il campo di un istante, insieme alla sua storia recente, è osservato o generato. Il generatore ricostruisce le quindici variabili della Tabella 3.1, su una griglia con passo di 0.5° e con una cadenza di tre ore. La Figura 4.2 riporta la struttura delle due reti, descritta nelle sottosezioni seguenti.

4.2.1 Generatore ConvGRU sul campo intero

Un campione di addestramento è il campo intero di un istante, disposto sulla griglia $N_y \times N_x$ della Sezione 3.1. Il generatore ha tre rami. Il ramo recente elabora gli R campi che precedono l'istante da ricostruire con una ConvGRU [6, 7], l'unità ricorrente convoluzionale delle equazioni (2.5)–(2.8),

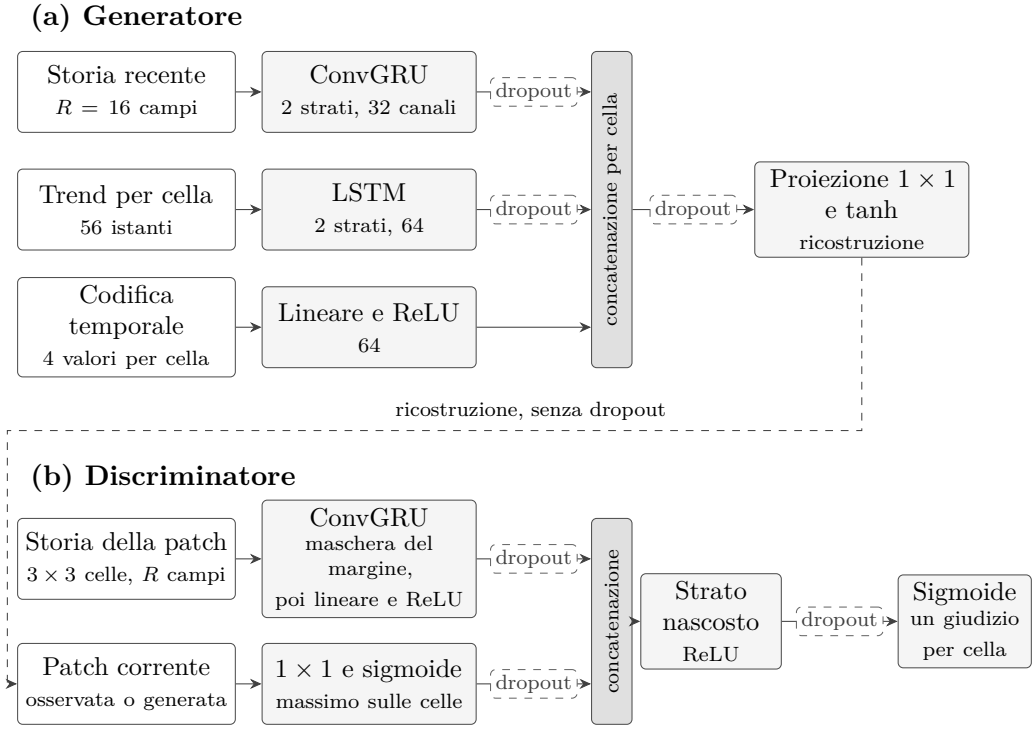


Figura 4.2: Struttura del generatore (a) e del discriminatore (b). I riquadri tratteggiati indicano i dropout, con probabilità 0.2.

che sostituisce la convoluzione su grafo dell'articolo. Il ramo del trend elabora con una LSTM [38] la serie di ciascuna cella su un periodo più lungo. Il ramo del calendario proietta la codifica temporale con uno strato lineare seguito da una ReLU (*rectified linear unit*). Con b istanti per batch, R istanti recenti, L istanti di trend e F variabili, gli ingressi hanno forma $[b, R, F, N_y, N_x]$ per il ramo recente e $[b, L, N, F]$ per il trend; l'uscita ha forma $[b, F, N_y, N_x]$.

Le convoluzioni scorrono sull'intera griglia: il campo ricettivo non è limitato a una parte del dominio e ogni cella viene ricostruita una sola volta. La LSTM del trend e la codifica temporale sono calcolate per cella e disposte sulla griglia. Le rappresentazioni dei tre rami sono concatenate cella per cella; una proiezione 1×1 seguita da tanh produce la ricostruzione.

Lo stato ricorrente è inizializzato a zero per ogni campione. Il modello ha due strati ConvGRU da 32 canali con kernel 3×3, e una LSTM del trend a due strati con stato nascosto di dimensione 64.

4.2.2 Discriminatore locale

Il discriminatore giudica ogni cella sulla propria patch $P \times P$, con $P = 3$, così come nell'articolo giudica ogni nodo sul proprio sottografo: la patch comprende la cella e le sue otto vicine dirette, così che il giudizio tenga conto dell'intorno immediato. La patch di ogni cella è estratta dal campo. Sul margine del dominio la patch è incompleta: le celle della patch esterne alla griglia sono azzerate dopo il min–max, e una maschera binaria M, la *maschera del margine*, è fornita come canale aggiuntivo a ogni strato ConvGRU. Rispetto alle equazioni (2.5)–(2.8) cambiano l'ingresso e l'ultimo passaggio. I gate e lo stato candidato sono calcolati su X'_s, la concatenazione degli ingressi mascherati e di M, al posto di X_s; lo stato precedente H_{s-1} è già mascherato e lo stato aggiornato viene moltiplicato per la maschera del margine, replicata sui canali:

$$H_s = M \odot \left[U_s \odot H_{s-1} + (1 - U_s) \odot \widetilde{H}_s \right]. \tag{4.1}$$

Il mascheramento dello stato impedisce alle celle assenti di conservare attivazioni da propagare negli strati o negli istanti successivi. La ConvGRU del generatore ha la stessa forma; su ERA5 nessuna cella della griglia è priva di dati, e la maschera del margine vale uno ovunque.

Una ConvGRU codifica la storia recente della patch; la storia codificata è appiattita e proiettata con uno strato lineare seguito da una ReLU. Il campo corrente della patch, osservato o generato, passa attraverso una proiezione 1×1 seguita da una sigmoide e da un massimo sulle celle valide. Le due rappresentazioni sono concatenate e alimentano uno strato nascosto e un'uscita

sigmoidale. Il discriminatore restituisce quindi un giudizio per cella e per istante.

Le patch di tutte le celle sono valutate in un'unica passata, con la stessa maschera del margine e gli stessi azzeramenti. L'uscita relativa a una cella è quella che il discriminatore produrrebbe sulla sua patch isolata.

4.2.3 Obiettivi di addestramento

Il discriminatore viene addestrato con etichetta zero per l'osservazione e uno per la ricostruzione, come nell'articolo. Indicando con D_{reale} e D_{generato} i giudizi sulle patch con l'osservazione e con la ricostruzione, il campo generato dell'articolo, cioè le $D_\phi(S_{v,t})$ e $D_\phi(\hat{S}_{v,t})$ dell'articolo (Sezione 2.1.4), gli obiettivi sono

$$\mathcal{L}_D = \tfrac{1}{2}\Big[\mathrm{BCE}(D_{\text{reale}}, 0) + \mathrm{BCE}(D_{\text{generato}}, 1)\Big], \tag{4.2}$$

$$\mathcal{L}_G = \lambda_G \ \mathrm{MSE}_w(\hat{x}, x) + \mathrm{BCE}(D_{\text{generato}}, 0), \tag{4.3}$$

dove MSE_w è l'errore quadratico medio sulle celle valide e sulle variabili, con i pesi delle variabili della Sezione 4.4, e la BCE, l'entropia incrociata binaria, è mediata sulle uscite locali, una per cella. Rispetto alle equazioni (2.2)–(2.3) dell'articolo, l'errore di ricostruzione del generatore è un errore quadratico medio anziché una norma e la loss del discriminatore è dimezzata: la scelta segue il codice pubblicato dagli autori.

Generatore e discriminatore hanno ciascuno un proprio ottimizzatore Adam [39]. Nell'aggiornamento del generatore, i parametri del discriminatore sono congelati ma viene mantenuto il gradiente rispetto alla ricostruzione; la storia della patch è codificata di nuovo, con i parametri del discriminatore appena aggiornati. Il peso di ricostruzione λ_G, che nell'articolo vale 500, è un iperparametro. I tassi di apprendimento dei due ottimizzatori sono distinti e fissati separatamente. Il coefficiente β_1 degli ottimizzatori vale 0.9, il valore del codice degli autori. Con gli *aggiornamenti D:G* n_D:n_G, sullo stesso batch vengono eseguiti prima n_D aggiornamenti del discriminatore e poi n_G del generatore, ciascuno con un proprio passaggio in avanti; è un conteggio di aggiornamenti e non riguarda i tassi di apprendimento. Tassi, aggiornamenti e peso di ricostruzione sono gli strumenti con cui si regola l'equilibrio fra le due reti; i valori di questi iperparametri sono scelti nel Capitolo 5.

Ogni batch contiene un istante, e ogni gradiente è mediato su tutte le celle dell'istante.

In sintesi. Il generatore ricostruisce il campo di un istante su tutta la griglia, a partire dalla storia recente, dal trend di ogni cella e dalla codifica

temporale; il discriminatore giudica ogni cella sulla propria patch 3×3. Le due reti sono addestrate con gli obiettivi dell'articolo, nella forma del codice degli autori.

4.3 Ingresso: storia recente, codifica temporale e normalizzazione stagionale

4.3.1 Storia recente e trend

La storia recente contiene gli R istanti che precedono quello da ricostruire. La ConvGRU la percorre in ordine: parte da uno stato nullo ed esegue un aggiornamento per ogni istante, sicché lo stato finale riassume gli R campi osservati. Con $R > 1$ il modello riceve anche l'evoluzione del campo negli istanti precedenti, e l'area che può influenzare una cella cresce con R, perché a ogni aggiornamento lo stato si propaga alle celle vicine. Il rilevatore usa $R = 16$ istanti, cioè 48 ore; il trend comprende 56 istanti, cioè 168 ore, la stessa durata dell'articolo.

4.3.2 Codifica temporale ciclica

La codifica temporale dell'articolo, a 31 elementi, è composta dal giorno della settimana e dall'ora UTC. È pensata per il traffico e su ERA5 è poco adatta, per due motivi. Il primo è che il vettore è lo stesso per tutte le celle, mentre il dominio si estende per 65 gradi di longitudine: alla stessa ora UTC, l'ora solare delle celle più a ovest e quella delle celle più a est differiscono di oltre quattro ore. Il secondo è che non contiene la posizione nell'anno, e non distingue quindi le stagioni. È perciò sostituita da una codifica temporale ciclica a quattro elementi, diversa per cella. Indicando con h_t l'ora UTC, con ℓ_n la longitudine in gradi, con g_t il giorno frazionario dell'anno e con A_t il numero di giorni dell'anno corrispondente, la codifica è

$$\begin{aligned} c_{tn} &= \left[\sin\phi_{tn},\ \cos\phi_{tn},\ \sin\psi_t,\ \cos\psi_t\right], \\ \phi_{tn} &= \frac{2\pi}{24}\left(h_t + \frac{\ell_n}{15}\right), \qquad \psi_t = \frac{2\pi g_t}{A_t}. \end{aligned} \tag{4.4}$$

Il primo angolo rappresenta l'ora solare locale, ottenuta dalla sola longitudine senza fusi orari; il secondo la posizione nell'anno. Seno e coseno rendono vicini gli istanti vicini nel ciclo, come le ore 23 e le ore 1 oppure la fine di dicembre e l'inizio di gennaio. La codifica temporale non contiene il giorno della settimana.

4.3.3 Normalizzazione stagionale

La normalizzazione dell'articolo è un min–max per variabile stimato sui dati di addestramento. Usa un solo intervallo per variabile, valido per tutte le celle e per tutto l'anno. Su un dominio che va dal Sahara all'Europa settentrionale questo ha un limite: lo stesso valore di una variabile riceve la stessa scala ovunque e in ogni stagione. Una temperatura di 20 °C, per esempio, è insolitamente alta a gennaio in Europa settentrionale e insolitamente bassa a luglio nel Sahara (Sezione 3.4), ma con un solo min–max per variabile riceve in entrambi i casi lo stesso valore normalizzato. La normalizzazione stagionale riferisce invece ogni valore di una variabile a ciò che è abituale nella stessa cella, nello stesso giorno dell'anno e alla stessa ora (Figura 3.3). Per ogni cella n, variabile f, ora del giorno o e giorno dell'anno g il valore della variabile è standardizzato,

$$u_{tnf} = \frac{x_{tnf} - \mu_{nfog}}{\sigma_{nfog}}, \tag{4.5}$$

con otto ore del giorno e 366 giorni dell'anno. Il valore u_{tnf} è lo *scarto standardizzato*: dice di quante deviazioni standard il valore della variabile si allontana dal suo normale stagionale, ed è positivo sopra il normale e negativo sotto; 0 corrisponde al normale, +2 a due deviazioni standard sopra. Media e deviazione standard sono due tensori di forma $[8, 366, N, F]$, una voce per ogni ora, giorno, cella e variabile. Media e deviazione standard sono stimate sui soli anni di addestramento, raccogliendo i quindici giorni che precedono g e i quindici che lo seguono. La deviazione standard misura la variabilità attorno al ciclo stagionale: ogni valore della variabile nella finestra di ± 15 giorni è confrontato con la media su ± 15 giorni del proprio giorno, non con quella di g, e così la variazione del ciclo stagionale dentro questa finestra non è contata come variabilità. Espresse in deviazioni standard del proprio normale, le variabili diventano confrontabili anche fra loro: la copertura nuvolosa, che con il solo min–max produce l'84.1% della variazione su 24 ore, ne produce il 6.7% (Sezione 3.4).

La precipitazione richiede un passaggio in più. È nulla nella maggior parte degli istanti e assume di rado valori molto alti: media e deviazione standard dei valori originali sono determinate in larga parte da questi pochi valori. Prima della normalizzazione stagionale la precipitazione è quindi sostituita dalla sua radice quarta, che comprime i valori alti e lascia nullo ciò che è nullo; media e deviazione standard descrivono la radice e non il valore originale. A differenza del logaritmo, la radice è definita anche per i valori nulli e non richiede una costante aggiuntiva.

La deviazione standard σ_{nfog} non può scendere sotto una frazione della deviazione standard complessiva della variabile sugli anni di addestramento:

0.1 per la precipitazione e per l'umidità del suolo, 0.01 per le altre tredici variabili. Il limite evita la divisione per valori quasi nulli, come accade per la radiazione solare di notte.

L'ultimo passaggio riguarda il tempo. Gli anni di test seguono quelli di addestramento, fino a oltre vent'anni dopo. Per una variabile che nel periodo ha una tendenza, la differenza fra il clima degli anni di test e quello degli anni di addestramento entrerebbe in ogni scarto standardizzato, e crescerebbe con la distanza dagli anni di addestramento. Per tre variabili (temperatura a due metri, temperatura a 850 hPa e umidità del suolo) agli scarti standardizzati è quindi sottratta una tendenza lineare nel tempo. Sono le variabili in cui la media sull'intero dominio deriva di più negli anni successivi a quelli di addestramento (Sezione 3.5); fra le altre variabili controllate la deriva resta piccola, con le eccezioni dell'umidità specifica, discussa più avanti, e della precipitazione (Sezione 3.5).

La tendenza lineare è una per variabile, uguale per tutte le celle: passa per le medie annuali degli scarti standardizzati sull'intero dominio, è stimata sui soli anni di addestramento e viene prolungata agli anni successivi. Per queste tre variabili, quindi, la tendenza lineare stimata sugli anni di addestramento non conta come condizione nuova. Per le altre dodici variabili la tendenza lineare non è sottratta e il riferimento resta il clima degli anni di addestramento. Fra queste c'è l'umidità specifica: la sua deriva inizia dopo gli anni di addestramento, e una tendenza lineare stimata su quegli anni non la descrive. Per questa variabile la correzione non può quindi essere applicata senza usare gli anni di test.

Dopo questi passaggi è applicato un min–max per variabile, stimato sugli anni di addestramento, che riporta i valori delle variabili nell'intervallo $[-1, 1]$ dell'uscita del generatore. Negli anni successivi, i valori esterni all'intervallo degli anni di addestramento possono superare questi estremi, perché la trasformazione non tronca i valori. Nel seguito x_{tnf} indica il valore della variabile dopo tutti questi passaggi e $\hat{x}_{tnf}$ la sua ricostruzione.

4.4 Pesi delle variabili nell'errore di ricostruzione del generatore

Nell'articolo tutte le variabili contano allo stesso modo nell'errore di ricostruzione del generatore. Il rilevatore pesa invece l'errore per variabile, in modo che ciascuna sia misurata rispetto a quanto cambia abitualmente. Dopo la normalizzazione stagionale le variabili hanno variazioni più vicine fra loro, ma non uguali: le loro percentuali della variazione su 24 ore vanno dallo 0.9%

al 16.6% (Figura 3.4). I pesi correggono queste differenze. Indicando con m_f la variazione quadratica media su 24 ore della variabile f (equazione (3.1)), calcolata sugli anni di addestramento dopo la normalizzazione stagionale, il peso è

$$w_f = \frac{\bar{m}}{m_f}, \qquad \bar{m} = \frac{1}{F}\sum_{f=1}^{F} m_f, \tag{4.6}$$

con $F = 15$. La differenza a 24 ore confronta istanti alla stessa ora del giorno e non contiene quindi il ciclo giornaliero. Con il fattore $\bar{m}$, un errore quadratico pari a m_f in ogni variabile dà la stessa loss con e senza pesi. Il peso non misura la difficoltà del modello su una variabile: è una misura di quanto la variabile cambia, fissata prima dell'addestramento e senza usare il modello. I pesi vanno da 0.40 per l'umidità specifica a 7.14 per l'umidità del suolo, che cambia lentamente. I pesi moltiplicano l'errore quadratico di ciascuna variabile nel termine di ricostruzione della loss del generatore e nell'errore di ricostruzione del generatore da cui sono calcolati gli score.

In sintesi. Ogni variabile entra nel modello riferita al normale stagionale della propria cella, giorno e ora, con la codifica temporale dell'ora solare locale e della posizione nell'anno, e l'errore di ciascuna variabile pesa in proporzione inversa a quanto la variabile cambia abitualmente.

4.5 Valori esclusi negli anni di validazione

Gli anni di validazione servono a confrontare configurazioni e a stimare le quantità dello score prima di valutare gli anni di test. Perché queste misure dipendano soprattutto dal tempo ordinario, i valori più insoliti degli anni di validazione sono individuati prima, con un criterio che non usa il modello.

Un valore, cioè una coppia cella–istante, è detto *escluso* in base a due distanze calcolate sugli scarti standardizzati della Sezione 4.3. La prima è la *distanza dal normale*: la media sulle variabili del quadrato degli scarti standardizzati, con i pesi delle variabili della Sezione 4.4, che dice quanto il valore è lontano dal normale della propria cella, giorno e ora. La seconda è la variazione in tre ore: la stessa media pesata sul quadrato della differenza rispetto a tre ore prima, che coglie i cambiamenti rapidi anche quando il valore resta vicino al normale.

Il criterio. Ciascuna distanza è standardizzata con la media e la deviazione standard della stessa cella, dello stesso mese e della stessa ora negli anni di addestramento, così che un luogo o una stagione più variabili non concentrino

i valori esclusi. Un valore è escluso quando almeno una delle due distanze standardizzate supera la *soglia del criterio*, oltrepassata dal 5% dei valori degli anni di addestramento. Medie, deviazioni standard e soglie del criterio sono stimate sui soli anni di addestramento; gli anni di validazione ricevono soltanto l'indicazione di quali valori sono esclusi.

Quanti valori esclude. La stessa indicazione è calcolata sugli anni di addestramento, dove esclude l'8.62% dei valori e serve a scegliere i campi della distanza MMD (Sezione 5.1). Il criterio è approssimato: non pretende di individuare tutte le anomalie meteorologiche, ma di togliere le più evidenti, così che le misure dipendano soprattutto dal tempo ordinario. La soglia del criterio al 5% è una scelta, ed esclude il 9.75% dei valori degli anni di validazione: più del 5%, perché basta che una delle due distanze superi la propria soglia del criterio.

I valori esclusi entrano in modo diverso nelle quantità stimate sugli anni di validazione (Tabella 4.1). Nella storia recente che il modello legge, in due casi i valori esclusi sono sostituiti dal normale stagionale, cioè dallo scarto standardizzato nullo: è la *storia ripulita*. I due casi sono la misura con cui si confrontano le configurazioni e il calcolo degli score sugli anni di validazione eseguito al termine dell'addestramento, da cui vengono gli estremi dello score combinato. Climatologia e soglia usano invece la storia non ripulita, come sugli anni di test (Sezione 4.7).

Tabella 4.1: Come entrano i valori esclusi nelle quantità stimate sugli anni di validazione: come valore da valutare e nella storia recente da cui il modello parte.

Quantità	Valori esclusi fra quelli valutati	Storia recente
Distanza MMD (Sezione 5.1)	solo campi in cui la percentuale di valori esclusi non supera la mediana dei campi dello stesso mese	ripulita
Estremi dello score combinato (Sezione 4.6)	tolti	ripulita
Climatologia degli score (Sezione 4.7)	tolti	non ripulita
Soglia (Sezione 5.3)	inclusi	non ripulita

4.6 Componenti dello score e dropout Monte Carlo

4.6.1 Dropout nel generatore e nel discriminatore

Lo score è calcolato più volte con il dropout Monte Carlo [8]. Gli strati di dropout sono posti dopo le reti che codificano gli ingressi e prima degli strati di uscita, una forma più semplice di quella con il dropout prima di ogni strato con parametri. Il generatore riceve tre strati di dropout: sulla rappresentazione spaziale del ramo recente, sulla rappresentazione del trend e sulla loro concatenazione con la codifica temporale, prima della proiezione di uscita. Il discriminatore ne riceve altrettanti, nelle posizioni corrispondenti: sulla storia codificata, sul campo corrente codificato e sullo strato nascosto che precede l'uscita. La probabilità è 0.2 in entrambe le reti, fissata e non ottimizzata. I dropout sono attivi nell'addestramento e nel calcolo degli score. L'articolo e il codice degli autori non usano il dropout: la sua aggiunta, come la sua posizione, è una scelta di questo lavoro.

Il discriminatore riceve la ricostruzione calcolata senza dropout: nell'addestramento, sia nel proprio aggiornamento sia nel termine avversario del generatore, e nel calcolo degli score. Se ricevesse la ricostruzione con il dropout, potrebbe distinguere le ricostruzioni dai campi osservati per il rumore che il dropout vi introduce, e non per il loro contenuto. Il dropout del generatore agisce quindi sull'errore di ricostruzione del generatore, quello del discriminatore sul suo giudizio.

4.6.2 Estrazioni Monte Carlo e componenti dello score

Durante il calcolo degli score il modello è in modalità di valutazione, con l'eccezione dei dropout, che restano attivi. Per ogni istante sono fatte $J = 20$ estrazioni, come le 20 previsioni campionate con cui Monaco et al. [34] valutano la loro U-Net con dropout Monte Carlo; il numero è fissato e non ottimizzato. Nell'estrazione j il generatore ricostruisce il campo con una propria maschera di dropout, e da questa ricostruzione si calcola l'errore di ricostruzione del generatore. Al discriminatore va invece la ricostruzione senza dropout, come in addestramento, uguale in tutte le estrazioni. In ogni estrazione il discriminatore usa una propria maschera di dropout, la stessa per i due giudizi, e giudica sia l'osservazione sia questa ricostruzione.

Per la coppia cella–istante (t, n) e l'estrazione j, la ricostruzione $\hat{x}^{(j)}$ dà

l'errore di ricostruzione del generatore

$$s_{G,tn}^{(j)} = \frac{1}{|\mathcal{P}_n|\, F} \sum_{c \in \mathcal{P}_n} \sum_{f=1}^{F} w_f \left(\hat{x}_{tcf}^{(j)} - x_{tcf} \right)^2, \tag{4.7}$$

dove $\mathcal{P}_n$ sono le celle valide della patch 3×3 di n. L'errore di una cella è quindi la media su sé stessa e sulle celle vicine, come nell'articolo, dove l'errore di un nodo è misurato sul suo sottografo. La componente del discriminatore è, come nell'articolo, la differenza fra il giudizio sull'osservazione e quello sulla ricostruzione,

$$s_{D,tn}^{(j)} = D_{\text{reale},tn}^{(j)} - D_{\text{generato},tn}^{(j)}. \tag{4.8}$$

L'errore di ricostruzione del generatore, medio sulle estrazioni,

$$\bar{s}_{G,tn} = \frac{1}{J} \sum_{j=1}^{J} s_{G,tn}^{(j)}, \tag{4.9}$$

è la media degli errori delle singole estrazioni, e non l'errore della ricostruzione media. Per ogni cella e variabile le due quantità differiscono per la varianza delle ricostruzioni:

$$\frac{1}{J} \sum_{j=1}^{J} \left(\hat{x}^{(j)} - x \right)^2 = \left(\bar{\hat{x}} - x \right)^2 + \frac{1}{J} \sum_{j=1}^{J} \left(\hat{x}^{(j)} - \bar{\hat{x}} \right)^2, \qquad \bar{\hat{x}} = \frac{1}{J} \sum_{j=1}^{J} \hat{x}^{(j)}. \tag{4.10}$$

La componente cresce quindi sia quando la ricostruzione si allontana dall'osservazione, sia quando le estrazioni non sono concordi fra loro. Dalle stesse estrazioni si ricava anche la deviazione standard di ciascuna componente e dello score, chiamata nel seguito *dispersione*: misura quanto essi dipendono dalle maschere di dropout; non è una probabilità di anomalia né una stima calibrata dell'incertezza.

4.6.3 Score combinato e score del rilevatore

Dalle stesse estrazioni sono ricavati due score. Lo *score combinato* è quello dell'articolo; non è usato come score del rilevatore, ed è confrontato con le due componenti (Sezione 6.5). Le due componenti sono riportate su una scala comune con un min–max e sommate con peso unitario, estrazione per estrazione:

$$a_{tn}^{(j)} = \frac{s_{G,tn}^{(j)} - r_{\min}}{r_{\max} - r_{\min}} + \frac{s_{D,tn}^{(j)} - d_{\min}}{d_{\max} - d_{\min}}, \qquad \bar{a}_{tn} = \frac{1}{J} \sum_{j=1}^{J} a_{tn}^{(j)}. \tag{4.11}$$

L'articolo indica che le due componenti sono normalizzate prima della somma, senza specificare come, e il codice degli autori salva le componenti senza

combinarle: il min–max è quindi una scelta di questo lavoro. Gli estremi $r_{\min}$, $r_{\max}$, $d_{\min}$ e $d_{\max}$ sono quelli delle due componenti medie sulle estrazioni negli anni di validazione, senza i valori esclusi (Sezione 4.5), e restano fissi per gli anni di test: quindi nessuna quantità dello score è stimata sugli anni di test. A differenza della climatologia della Sezione 4.7, vengono dalla storia ripulita (Tabella 4.1): la differenza riguarda soltanto il peso delle due componenti nello score combinato, che non è lo score del rilevatore. Gli score degli anni di test possono uscire dall'intervallo $[0, 1]$ di ciascuna componente, perché gli score non sono troncati.

Lo *score del rilevatore* $G_{\mathrm{n}}(t, n)$ è la sola componente $\bar{s}_{G,tn}$, espressa rispetto alla propria climatologia (Sezione 4.7). Se sommare le due componenti o usare G_{n} è discusso nel Capitolo 6, dove l'errore di ricostruzione del generatore $\bar{s}_{G,tn}$ è indicato con G e la componente del discriminatore con D.

4.7 Normalizzazione climatologica degli score

Una trasformazione successiva al calcolo degli score esprime ogni score rispetto alla climatologia della stessa cella. Per la cella n, il giorno dell'anno g e l'ora UTC o dell'istante t,

$$z_{tn} = \frac{s_{tn} - \mu^{s}_{nog}}{\sigma^{s}_{nog}}, \tag{4.12}$$

dove s_{tn} è lo score da trasformare: l'errore di ricostruzione del generatore $\bar{s}_{G,tn}$, la componente del discriminatore, media sulle estrazioni, o lo score combinato $\bar{a}_{tn}$; la stessa trasformazione è applicata agli score delle baseline (Sezione 5.4). Media e deviazione standard sono calcolate con la stessa ricetta della normalizzazione stagionale della Sezione 4.3: sugli score della stessa cella e della stessa ora nei quindici giorni che precedono g e nei quindici che lo seguono, con una finestra che scavalca la fine dell'anno, e con la deviazione standard calcolata attorno alla media $\mu^{s}_{nog'}$ di ciascun giorno g' della finestra. Lo score è uno per cella e non ha la dimensione delle variabili: media e deviazione standard sono due tensori di forma $[8, 366, N]$. Sono stimate negli anni di validazione, senza i valori esclusi (Sezione 4.5), e restano fisse per gli anni di test. Non possono essere stimate sugli anni di addestramento, perché su quegli anni il modello ha già visto i dati e il suo errore è più basso di quello su anni nuovi. Quando lo score trasformato serve sugli anni di validazione stessi, per le scelte e per fissare le soglie, media e deviazione standard di un anno y sono calcolate sugli altri quattro anni di validazione, $\mu^{s,(-y)}_{nog}$ e $\sigma^{s,(-y)}_{nog}$: nessun valore entra nella propria climatologia. Le combinazioni di cella, giorno dell'anno e ora con meno di trenta valori di riferimento o con varianza nulla non ricevono uno score.

Gli score degli anni di validazione da cui sono stimate queste quantità sono calcolati con la storia non ripulita, come quelli degli anni di test (Tabella 4.1): una climatologia stimata su errori calcolati da una storia ripulita descriverebbe un errore più basso di quello che il modello commette sugli anni di test, dove la storia contiene anche i valori che sugli anni di validazione sono esclusi.

Lo scopo è rendere confrontabili celle e stagioni in cui l'errore di ricostruzione del generatore ha una grandezza tipica diversa: senza questo passaggio, le segnalazioni si concentrerebbero dove l'errore è grande per natura. La trasformazione applica la stessa idea della normalizzazione stagionale, cioè esprimere un valore rispetto a ciò che è abituale per quella cella, quel giorno dell'anno e quell'ora, ma a un oggetto diverso. La normalizzazione stagionale agisce sui campi in ingresso, prima del modello, ed è stimata sugli anni di addestramento: toglie il ciclo stagionale e giornaliero dei dati, ma non la differenza di prevedibilità fra celle e stagioni. Dove il tempo cambia più rapidamente il generatore sbaglia di più anche sugli scarti standardizzati. La normalizzazione climatologica agisce sull'errore di ricostruzione del generatore, dopo l'addestramento, è stimata sugli anni di validazione e toglie questa seconda differenza senza modificare il rilevatore.

Score finale. Riassumendo, lo score del rilevatore, usato nei risultati, è

$$G_{\mathrm{n}}(t, n) = \frac{\bar{s}_{G,tn} - \mu^{s}_{nog}}{\sigma^{s}_{nog}}, \tag{4.13}$$

con $\bar{s}_{G,tn}$ dell'equazione (4.9): l'errore di ricostruzione del generatore, pesato per variabile e medio sulla patch 3×3 della cella e sulle 20 estrazioni Monte Carlo, riferito ai valori abituali dello stesso errore nella cella, nel giorno dell'anno e nell'ora. La soglia con cui un valore è segnalato è definita nella Sezione 5.3.

Il Capitolo 5 riporta i valori scelti e il protocollo con cui lo score è valutato.

Capitolo 5

Esperimenti

Il capitolo descrive come il rilevatore del Capitolo 4 è addestrato e valutato sui campi ERA5. La Sezione 5.1 descrive la misura con cui si confrontano le configurazioni, la Sezione 5.2 la configurazione fissata e la ricerca dei quattro iperparametri che regolano l'equilibrio fra generatore e discriminatore; la Sezione 5.3 descrive il protocollo di valutazione: che cosa si stima sugli anni di validazione, che cosa si valuta sugli anni di test e con quali misure. La Sezione 5.4 descrive le otto baseline con cui il rilevatore è confrontato, e la Sezione 5.5 il riferimento comune costruito dall'accordo dei metodi e le misure con cui ogni metodo è letto attorno a esso. I risultati, compresi quelli della ricerca, sono nel Capitolo 6.

5.1 Distanza MMD per la scelta della configurazione

Le configurazioni del rilevatore sono confrontate sugli anni di validazione, senza usare gli anni di test e senza etichette, con una misura di quanto bene il modello ricostruisce il tempo ordinario. La misura confronta osservazioni e ricostruzioni in uno spazio indipendente dal modello, ottenuto da un'analisi delle componenti principali dei campi degli anni di addestramento: ogni campione è il campo intero di un istante, normalizzato e appiattito su celle e variabili. Sono usati campi estratti a caso, con un seme fisso e nello stesso numero per ogni mese, fra quelli in cui la percentuale di valori esclusi (Sezione 4.5) non supera la mediana di questa percentuale fra i campi dello stesso mese. Sono conservate 300 componenti principali, che spiegano il 78.8% della varianza, contro il 67.4% di 100; oltre questo numero la varianza spiegata cresce poco. Lo spazio è costruito una sola volta, prima delle prove, e successivamente soltanto caricato.

I campi di tempo ordinario sono scelti, non corretti. Sostituire i valori esclusi con il normale stagionale darebbe campi più lisci di qualunque campo osservato, e una distanza calcolata su di essi premierebbe un generatore che ricostruisce campi lisci. Un campo scelto può quindi contenere ancora qualche valore escluso, entro la mediana del suo mese: i valori esclusi sono sostituiti soltanto nella storia da cui il modello parte (Tabella 4.1).

Su questo spazio viene definito un riferimento per la validazione, fissato anch'esso prima delle prove: $S = 5$ sottoinsiemi fissi e disgiunti di $m = 512$ campi di tempo ordinario degli anni di validazione, scelti con lo stesso criterio, con le coordinate delle loro osservazioni nello spazio. La Maximum Mean Discrepancy (MMD) misura quanto differiscono due insiemi di campioni: è vicina a zero quando seguono la stessa distribuzione. A ogni epoca il generatore, senza dropout, ricostruisce i campi di ciascun sottoinsieme, e si calcola la stima non distorta della MMD [40]

$$\widehat{\mathrm{MMD}}^2 = \frac{1}{m(m-1)} \sum_{i \neq i'} k(x_i, x_{i'}) + \frac{1}{m(m-1)} \sum_{i \neq i'} k(y_i, y_{i'}) - \frac{2}{m^2} \sum_{i,i'} k(x_i, y_{i'}), \tag{5.1}$$

dove x_i sono le coordinate delle osservazioni, y_i quelle delle ricostruzioni e il kernel è la media di tre kernel gaussiani (RBF, *radial basis function*),

$$k(a, b) = \frac{1}{3} \sum_{\kappa \in \{0.5,\, 1,\, 2\}} \exp\left(-\frac{\|a - b\|^2}{2(\kappa\gamma)^2} \right), \tag{5.2}$$

con la banda γ uguale alla distanza euclidea mediana fra le coordinate delle osservazioni del riferimento. La stima è mediata sui sottoinsiemi. La stima non distorta può assumere valori leggermente negativi. Poiché tutte le prove confrontate caricano gli stessi riferimenti, le differenze nella misura non dipendono da una nuova stima dello spazio o della banda. La misura non entra in una loss, in un aggiornamento dei parametri o negli score: è calcolata senza gradiente e ripristinando gli stati dei generatori di numeri casuali, così da non alterare la traiettoria dell'addestramento. Una MMD più bassa indica ricostruzioni più vicine alle osservazioni nello spazio considerato; non misura direttamente la qualità del rilevamento delle anomalie meteorologiche.

5.2 Configurazione e ricerca degli iperparametri

La configurazione del rilevatore è fissata, a eccezione di quattro iperparametri che regolano l'equilibrio fra generatore e discriminatore, scelti con una ricerca

bayesiana. La Tabella 5.1 riporta i valori fissati e gli iperparametri cercati, con la sezione del Capitolo 4 che li descrive.

Tabella 5.1: Configurazione del rilevatore su ERA5. Nella parte superiore i valori fissati, nella parte inferiore gli iperparametri della ricerca, con l'intervallo esplorato e il valore della configurazione scelta.

Elemento	Valore	Sezione
Anni di addestramento, validazione, test	1980–1999, 2000–2004, 2005–2025	3.3
Unità del campione e batch	Campo intero, un istante per batch	4.2.1
Generatore	ConvGRU a due strati da 32 canali, kernel 3×3; LSTM del trend a due strati da 64	4.2.1
Discriminatore	Patch 3×3; ConvGRU a due strati da 32 canali; strato nascosto da 64	4.2.2
Storia recente e trend	16 e 56 istanti, cioè 48 e 168 ore	4.3
Codifica temporale	Ora solare locale e posizione nell'anno, per cella	4.3
Ingresso del modello	Rispetto al normale di cella, giorno e ora; tendenza lineare tolta a tre variabili; poi min–max	4.3
Pesi delle variabili	Inversi della variazione quadratica media su 24 ore	4.4
Dropout	0.2, nel generatore e nel discriminatore	4.6
Estrazioni Monte Carlo negli score	20	4.6
Ottimizzatore	Adam, $\beta_1 = 0.9$, $\beta_2 = 0.999$, tasso costante	4.2
Epoche	6, come nel codice degli autori di STGAN	–
Precisione	bfloat16 (BF16) nei calcoli, parametri a 32 bit (FP32)	–
Tasso di apprendimento del generatore	da 10^{-4} a $3 \cdot 10^{-3}$, in scala logaritmica; scelto $7.65 \cdot 10^{-4}$	4.2
Tasso di apprendimento del discriminatore	da $2.5 \cdot 10^{-5}$ a $5 \cdot 10^{-3}$, in scala logaritmica; scelto $3.06 \cdot 10^{-3}$	4.2
Peso di ricostruzione λ_G	da 25 a 2000, in scala logaritmica; scelto 63.7	4.2
Aggiornamenti D:G, n_D:n_G	1:1, 2:1 oppure 1:2; scelto 1:1	4.2

Obiettivo. L'obiettivo della ricerca è la distanza MMD fra campi osservati e ricostruiti nello spazio delle componenti principali (Sezione 5.1), mediata sulle ultime cinque epoche, da minimizzare: la prima epoca è esclusa perché, all'inizio dell'addestramento, è poco indicativa della configurazione. Ogni prova è addestrata sugli anni 1980–1999 e misurata sugli anni di validazione, senza calcolare score sugli anni di test. Ogni configurazione è addestrata una

sola volta, con lo stesso seme per tutte le prove. Le prove interrotte perché una loss ha assunto valori infiniti o indefiniti (NaN) non hanno una distanza MMD e sono escluse dalla scelta.

La ricerca. Le prove sono gestite con la libreria Optuna [41] e proposte con un metodo bayesiano: un processo gaussiano stima la distanza MMD in funzione degli iperparametri, a partire dalle prove già completate, e la prova successiva è scelta dove il miglioramento atteso è più alto. La ricerca è fermata quando più prove consecutive non migliorano di almeno 0.0004 la distanza MMD più bassa, un valore vicino al rumore stimato dal processo gaussiano. È scelta la configurazione con la distanza MMD più bassa fra le prove completate. Le prove della ricerca e la configurazione scelta sono riportate nella Sezione 6.1.

Parametri e calcolo. Del modello scelto si usano i parametri dell'ultima epoca, come nel codice degli autori[1], che salva i parametri a ogni epoca e valuta quelli dell'ultima: nessuna epoca è scelta in base al risultato. Un'epoca comprende 58384 batch di un istante, cioè gli istanti degli anni di addestramento meno i primi 56, che servono al trend. Nella configurazione scelta un'epoca dura circa 2.4 ore, quindi un addestramento di sei epoche poco più di 14 ore. I modelli sono implementati in PyTorch [42]. Nella preparazione dei dati (Sezione 3.2) i file mensili in formato NetCDF [35] sono letti con xarray [43]; durante l'addestramento e il calcolo degli score i file `.npy` sono letti con NumPy [36] in mappatura di memoria; le tabelle di score sono elaborate con pandas [44]; il Capitolo 6 usa anche SciPy [45]. Tutti i modelli sono addestrati su una scheda NVIDIA RTX PRO 6000 Blackwell.

5.3 Protocollo di valutazione

Che cosa si calcola. Gli score della configurazione scelta sono calcolati sugli anni di validazione 2000–2004 e di test 2005–2025, su tutti gli istanti e tutte le celle: 14616×10611 coppie cella–istante sugli anni di validazione e 61360×10611 sugli anni di test, ciascuna con le 20 estrazioni Monte Carlo della Sezione 4.6. In entrambi i periodi la storia recente non è ripulita e comprende i valori esclusi, e per i primi istanti viene dal periodo precedente (Sezione 3.3).

[1] `https://github.com/dleyan/STGAN`

Che cosa si stima sugli anni di validazione. Le quantità che descrivono il comportamento abituale degli score sono stimate sugli anni di validazione e restano fisse per gli anni di test: la climatologia degli score (Sezione 4.7) e la soglia. La soglia di uno score è il 95-esimo percentile dello stesso score sugli anni di validazione,

$$\tau = Q_{0.95}\Big\{ z_{tn} \,:\, t \in \text{validazione},\ n = 1, \ldots, N \Big\}, \tag{5.3}$$

calcolato su un istante ogni dieci degli anni di validazione e su tutte le celle, una soglia per ciascuno score confrontato. Sugli anni di validazione lo score normalizzato z di ogni anno è calcolato con la climatologia degli altri quattro (Sezione 4.7), e i valori senza score non entrano nella soglia. Nella soglia entrano anche i valori esclusi dalle altre misure (Sezione 4.5), perché valori come questi sono presenti anche negli anni di test. Sugli anni di test la soglia segnala una percentuale di valori che può differire dal 5%, ed è riportata nei risultati.

Altre soglie. Per G e D senza normalizzazione climatologica, usati nel Capitolo 6 per studiare le due componenti, la soglia è allo stesso modo il 95-esimo percentile della componente stessa sugli anni di validazione. Le analisi principali sono ripetute con il 99-esimo percentile, per verificare quanto le conclusioni dipendano dalla soglia (Appendice A).

Score usato e baseline. Lo score del rilevatore è G_{n}, dell'equazione (4.13), cioè G con la normalizzazione climatologica. Lo score combinato dell'articolo, che somma l'errore di ricostruzione del generatore e la componente del discriminatore, non è usato come score del rilevatore; è calcolato per confronto nel Capitolo 6. La scelta di G_{n} è fatta sugli anni di validazione (Sezioni 6.2–6.5), dove le due componenti non concordano e l'errore di ricostruzione del generatore ha un significato chiaro; gli anni di test la confermano (Sezione 6.5). Gli anni di test non intervengono né nell'addestramento né nella scelta della configurazione; il comportamento degli score e il loro confronto con otto baseline, metodi più semplici (Sezione 5.4), sono descritti nel Capitolo 6.

5.3.1 Misure usate nei risultati

Le misure seguenti descrivono dove e come segnalano gli score; sono definite nell'ordine in cui il Capitolo 6 le usa.

Differenza relativa. Per sapere se uno score segnala di più in alcuni luoghi o in alcune stagioni, i valori sono divisi in quattro fasce di latitudine larghe

10°, da 20° a 60°N, e nei dodici mesi, e in ognuna delle 48 caselle si conta la percentuale di valori segnalati. La *differenza relativa* è la differenza assoluta media fra la percentuale di ogni casella e la media delle caselle, divisa per questa media: vale 0 se tutte le caselle segnalano la stessa percentuale.

Cluster di segnalazioni. Le segnalazioni di un metodo sono raggruppate in *cluster di segnalazioni*, o semplicemente cluster: due valori segnalati fanno parte dello stesso cluster se in un istante le loro celle si toccano, anche in diagonale, o se sono la stessa cella in due istanti consecutivi. La *dimensione* di un cluster è il numero dei suoi valori. Un cluster indica dove il metodo segnala, non un'anomalia meteorologica: più anomalie vicine possono finire nello stesso cluster, e un cluster può non corrispondere ad alcuna anomalia.

Zone e percentile mediano. Rispetto ai cluster di uno score, in ogni istante le celle sono divise in tre zone (Figura 5.1): il *nucleo*, le celle di un cluster in quell'istante; il *contorno*, le otto celle vicine a una cella del nucleo, le stesse della patch 3×3 letta dal discriminatore, escluse quelle del nucleo; e la zona *lontana*, le celle a più di tre celle da ogni nucleo. Le celle intermedie non sono considerate. In ciascuna zona ogni score è riassunto dal suo *percentile mediano*: per ogni valore si calcola a quale percentile sta fra tutti i valori dello stesso score sugli stessi anni, da 0 (il più basso) a 100 (il più alto), e se ne prende la mediana. In una zona senza legame con i cluster il percentile mediano sarebbe vicino a 50.

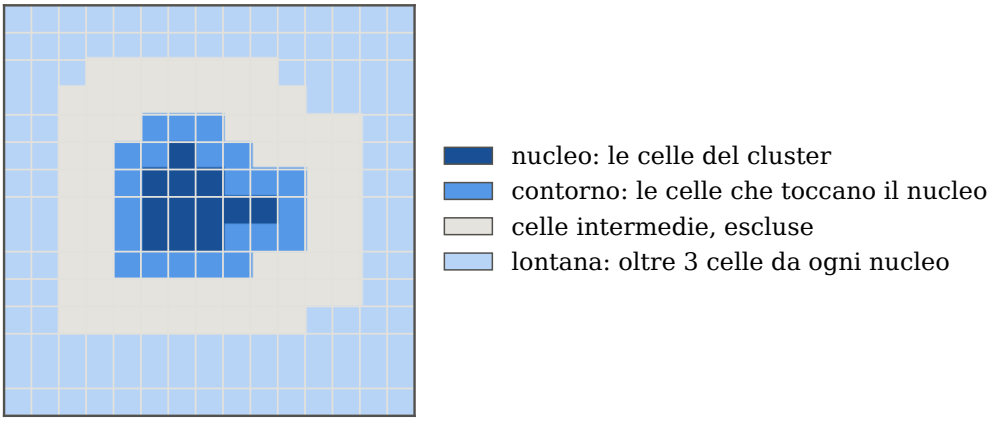


Figura 5.1: Le tre zone attorno a un cluster in un istante, su una porzione della griglia. Ogni quadrato è una cella; le celle intermedie non rientrano in nessuna zona.

Rugosità. La *rugosità* di un campo è la differenza quadratica media fra celle adiacenti. Un campo è *lisciato* sostituendo ogni valore con la media della sua patch 3×3. La *rugosità locale* di una cella è la media sulle variabili del quadrato della differenza fra il valore di ogni variabile e la sua media sulla patch 3×3.

Tipo di un cluster. Il *tipo* di un cluster è la variabile d'ingresso con la media più alta del valore assoluto dello scarto standardizzato (Sezione 4.3), su tutte le celle del cluster e in tutti i suoi istanti. Dice quale variabile si allontana di più dal normale, non di quale anomalia meteorologica si tratti, e le variabili con valori molto estremi, come la precipitazione, possono risultare più spesso le più lontane. Il *tipo principale* di un metodo è il tipo dei cluster che contengono più valori segnalati.

Profilo e livello di fondo. Il *profilo* di uno score è il suo percentile mediano secondo la distanza dal bordo dei cluster: per ogni cella si conta a quante celle sta dal bordo del cluster più vicino, verso l'interno o verso l'esterno, e si legge il percentile mediano dello score sugli stessi anni. La prima cella dentro il bordo è l'ultima del nucleo; la prima fuori è il contorno. Allo stesso modo si legge, per ogni tipo, il profilo della mediana del valore assoluto dello scarto standardizzato della variabile del tipo; il *livello di fondo* di un tipo è questa mediana a otto o più celle dal bordo.

Rapporto e classi del rapporto. Il *rapporto* di un valore è la dispersione di G fra le estrazioni (Sezione 4.6) divisa per G stesso, senza normalizzazione climatologica. Per confrontare valori con lo stesso G, i valori segnalati sono divisi in 20 fasce di G e, in ogni fascia, in cinque *classi del rapporto* con lo stesso numero di valori, ordinate per rapporto: dalla classe 1, con le estrazioni più concordi, alla classe 5, con le più discordi.

5.4 Baseline

Le segnalazioni di G_{n} sono confrontate con quelle di otto metodi più semplici, le *baseline*, come raccomandato da Wu e Keogh (Sezione 2.1.5). Il confronto è un controllo di coerenza e non una misura di accuratezza: senza etichette l'accordo non dice quale metodo abbia ragione, e due metodi possono concordare ed entrambi sbagliare. Serve a vedere quali segnalazioni del rilevatore si ottengono anche senza un modello profondo, e quali no.

I metodi. Le baseline sono otto (Tabella 5.2). Sei sono modelli shallow, scelti fra i metodi valutati in TSB-AD [21], con i parametri predefiniti della libreria Python PyOD: leggono una cella in un istante, cioè il vettore delle sue quindici variabili, senza le celle vicine né gli istanti prima. Ciascuno è stimato su 200000 vettori estratti da 2000 istanti a caso degli anni di addestramento; quanto il risultato dipenda da questo campione è verificato nel Capitolo 6. Le altre due sono più semplici e non richiedono un modello. La *distanza dal normale* è l'errore che si commetterebbe rispondendo, in ogni cella, con il valore normale per quel giorno e quell'ora: misura quanto i dati si allontanano dal clima. La *variazione in tre ore* è l'errore che si commetterebbe rispondendo con il valore dell'istante precedente: misura il cambiamento rapido. Nei due errori le variabili hanno gli stessi pesi dell'errore di ricostruzione del generatore (Sezione 4.4). Sono le stesse due distanze con cui la Sezione 4.5 individua i valori esclusi degli anni di validazione; qui sono usate come score, ciascuna con la propria soglia. Nessuna delle otto baseline legge le celle vicine: G_{n} è l'unico metodo che usa lo spazio.

Soglie e misure di accordo. Ogni metodo è trattato come il rilevatore: il suo score è espresso rispetto alla propria climatologia per cella, giorno dell'anno e ora (Sezione 4.7), e la sua soglia è il 95-esimo percentile dello stesso score sugli anni di validazione (equazione (5.3)). Se due metodi segnalano gli insiemi di valori A e B, la percentuale delle segnalazioni di A condivise con B è $100\,|A \cap B|/|A|$; l'indice di Jaccard,

$$\mathrm{Jac}(A, B) = \frac{|A \cap B|}{|A \cup B|}, \tag{5.4}$$

vale 1 quando i due insiemi coincidono e 0 quando sono disgiunti; nei risultati è espresso in percentuale. Due metodi indipendenti che segnalano ciascuno il 5% dei valori condividerebbero circa il 5% delle segnalazioni, con un indice di Jaccard di circa il 3%. Le *segnalazioni esclusive* di un metodo sono quelle non segnalate da nessun altro metodo. Nel *voto a maggioranza* un valore è segnalato quando lo segnalano almeno cinque dei nove metodi, G_{n} compreso.

5.5 Segnalazioni concordate

Le misure della Sezione 5.4 contano i valori in comune, cella per cella. Non dicono se, attorno a un'area in cui gli altri metodi concordano, un metodo segnala la stessa area o un'area più ampia, se comincia prima o finisce dopo, se le sue segnalazioni stanno davanti o dietro rispetto al moto dell'area. Questa

Tabella 5.2: I metodi confrontati e ciò che leggono di ogni valore. Le descrizioni dei modelli shallow seguono TSB-AD. Per COPOD le distribuzioni di riferimento sono stimate solo sul campione degli anni di addestramento, così che lo score di un valore non dipenda dagli altri valori valutati con esso.

Metodo	Legge	Score
G_{n}	celle vicine e istanti prima	errore di ricostruzione del generatore (Sezioni 4.6 e 4.7)
Distanza dal normale	una cella in un istante	errore della risposta "normale stagionale per quel giorno e quell'ora"
PCA	una cella in un istante	distanza dal centro lungo le componenti principali, ciascuna divisa per la percentuale di varianza che spiega
CBLOF	una cella in un istante	distanza dal centro del proprio gruppo (8 gruppi), o del gruppo grande più vicino se il proprio è piccolo
MCD	una cella in un istante	distanza dal centro dei dati che tiene conto di come le variabili variano insieme (distanza di Mahalanobis con stime robuste)
HBOS	una cella in un istante	quanto sono rari i valori della cella, variabile per variabile, letti da un istogramma (10 intervalli)
COPOD	una cella in un istante	probabilità di coda di ogni variabile, dalle distribuzioni empiriche
Isolation Forest	una cella in un istante	brevità del percorso che isola il valore in 100 alberi casuali, di 256 valori ciascuno
Variazione in tre ore	una cella, ora e tre ore prima	errore della risposta "valore di tre ore prima"

sezione definisce un riferimento comune, le segnalazioni concordate, e le misure con cui ogni metodo è letto attorno a esso.

Anche in meteorologia, quando manca un catalogo osservato, più algoritmi di rilevamento sono applicati agli stessi dati e il loro consenso fa da riferimento per confrontarli [46]; le differenze fra algoritmi restano però un'incertezza, e nessuno di essi è considerato la verità [47, 48]. Nel rilevamento di anomalie senza etichette, il voto a maggioranza fra rilevatori è usato allo stesso modo come pseudo verità, per scegliere quali rilevatori combinare [49]. Il riferimento definito qui non è quindi una verità, ma l'accordo dei metodi; sette dei nove metodi leggono una cella in un istante (Tabella 5.2), e l'accordo riflette soprattutto il loro punto di vista. Le misure descrivono come le segnalazioni di un metodo si dispongono attorno a questo accordo, non quale metodo sia migliore.

Il cubo concordato. Le segnalazioni di un metodo k formano un cubo binario M_k, con $M_k(t, n) = 1$ se il metodo segnala la cella n all'istante t, ordinato per istante, riga e colonna della griglia. Una segnalazione può mancare in una sola cella o in un solo istante dentro un'area segnalata, perché lo score vi scende appena sotto la soglia. Prima del voto, a ogni cubo è quindi applicata una chiusura morfologica binaria, cioè una dilatazione seguita da un'erosione con lo stesso elemento B, di 3×3 celle per tre istanti:

$$\bar{M}_k = (M_k \oplus B) \ominus B. \tag{5.5}$$

La chiusura riempie queste lacune e non toglie alcuna segnalazione. Il cubo è esteso con zeri oltre i margini del dominio e del periodo e ritagliato dopo la chiusura, così che lungo i margini non siano aggiunte segnalazioni. Il numero di voti di un valore è

$$v(t, n) = \sum_{k=1}^{9} \bar{M}_k(t, n), \tag{5.6}$$

e un valore è una *segnalazione concordata* quando $v(t, n) \geq 5$, cioè quando lo segnala la maggioranza semplice dei nove metodi. L'insieme delle segnalazioni concordate è il *cubo concordato* C; senza la chiusura coinciderebbe con il voto a maggioranza della Sezione 5.4.

Voto decisivo e controllo senza il proprio voto. Ogni metodo vota nel riferimento con cui è poi confrontato. Il *voto decisivo* di un metodo è l'insieme delle segnalazioni concordate con esattamente cinque voti, uno dei quali è il suo: senza di esso non sarebbero concordate. Per ogni metodo k le misure di sovrapposizione sono quindi ripetute anche contro il cubo formato

dai soli altri otto metodi,

$$C^{(-k)} = \Big\{(t,n) \,:\, \sum_{j\neq k} \bar{M}_j(t,n) \geq 5\Big\}, \tag{5.7}$$

che differisce da C solo nel voto decisivo di k.

Cluster concordati. Le segnalazioni concordate sono raggruppate in cluster con la regola della Sezione 5.3.1. È la regola predefinita con cui TempestExtremes collega nel tempo le aree rilevate, unite quando condividono almeno un punto della griglia in istanti successivi [50]. Sono studiati i *cluster concordati* con almeno 20 valori; come negli studi che seguono le ondate di calore come insiemi connessi nello spazio e nel tempo, è fissata una dimensione minima e non una durata massima [51, 52]. Per un cluster concordato c, t_0^c e t_1^c sono il primo e l'ultimo istante. Il cluster è *breve* se dura al più tre giorni, cioè se $t_1^c - t_0^c \leq 72$ ore, e *lungo* altrimenti; i due gruppi sono sempre riportati separatamente.

Intorno del cluster. Ogni metodo è letto nell'*intorno* di ciascun cluster concordato: il cluster dilatato di cinque celle in ogni direzione a ogni istante e di otto istanti, cioè 24 ore, prima e dopo, con un elemento a forma di parallelepipedo. L'intorno segue così la forma del cluster in ogni istante. Dilatare il riferimento a ogni istante, per tollerare piccole differenze di posizione, è ciò che fanno Lagerquist et al. con i fronti [53]; Bourdin et al. associano a ogni punto di una traccia rilevata i punti osservati allo stesso istante entro 300 km [54], una distanza vicina alle cinque celle, circa 275 km in latitudine. Le 24 ore sono una scelta di questo lavoro. Gli intorni di cluster vicini possono sovrapporsi: ogni valore è quindi attribuito al cluster concordato più vicino, con una distanza euclidea in cui gli istanti sono divisi per otto e le celle per cinque. È l'idea delle zone di affiliazione di Huet et al., che dividono l'asse dei tempi assegnando ogni istante all'evento più vicino [55], qui estesa allo spazio. Ogni valore è così contato per un solo cluster, e le segnalazioni concordate di un intorno sono quelle del suo cluster.

Sovrapposizione. Nell'intorno Z di un cluster concordato, con $M = \bar{M}_k$ le segnalazioni di un metodo dopo la chiusura, sono contate l'intersezione $I = |M \cap C \cap Z|$ e l'unione $U = |(M \cup C) \cap Z|$, e se ne ricava l'indice di Jaccard I/U dell'equazione (5.4). Lo stesso indice può essere basso perché il metodo segnala poco del cluster o perché segnala molto attorno a esso; le due cose sono separate dalla *copertura* e dall'*estensione*,

$$\mathrm{cop} = \frac{I}{|C \cap Z|}, \qquad \mathrm{est} = \frac{|(M \setminus C) \cap Z|}{|C \cap Z|}, \qquad \frac{I}{U} = \frac{\mathrm{cop}}{1 + \mathrm{est}}. \tag{5.8}$$

La copertura è la parte del cluster che il metodo segnala; l'estensione è il numero di valori che il metodo segnala nell'intorno fuori dal cubo concordato, in proporzione alla dimensione del cluster. Questi valori sono le *segnalazioni non concordate* del metodo attorno al cluster. Di ogni misura sono riportate mediana e quartili sui cluster, per i cluster brevi e per i lunghi, contro C e contro $C^{(-k)}$.

Cluster sovrapposto, inizio e fine. Le segnalazioni di un metodo nell'intorno sono raggruppate con la stessa regola dei cluster. Il *cluster sovrapposto* al cluster concordato è l'insieme dei gruppi che hanno almeno un valore in comune con esso, comprese le loro parti che ne escono, entro l'intorno. Con t_0^s e t_1^s il suo primo e il suo ultimo istante, le differenze all'inizio e alla fine sono

$$\Delta_0 = t_0^s - t_0^c, \qquad \Delta_1 = t_1^s - t_1^c, \tag{5.9}$$

in ore: $\Delta_0 < 0$ se il metodo comincia prima del cluster concordato, $\Delta_1 > 0$ se finisce dopo; per costruzione dell'intorno entrambe sono comprese fra -24 e $+24$ ore. Il confronto delle date iniziali e finali di tracce abbinate è quello di Bourdin et al. [54], che confrontano le tracce di cicloni rilevate con quelle osservate; il primo e l'ultimo istante di un oggetto sono attributi anche in MODE-TD [56]. Inizio e fine sono anche le fasi in cui algoritmi diversi applicati agli stessi dati differiscono di più [48]. Due metodi sono confrontati cluster per cluster, sui cluster concordati a cui entrambi hanno un cluster sovrapposto: si conta in quanti l'uno comincia prima, insieme o dopo l'altro, e in quanti finisce dopo, insieme o prima, con un test dei segni a due code sui cluster in cui differiscono.

Spostamento lungo il moto. Le posizioni sono espresse in chilometri, con la longitudine moltiplicata per il coseno della latitudine. Siano $\mathbf{x}_c(t)$ il centroide del cluster concordato all'istante t e $\mathbf{x}_s(t)$ quello delle segnalazioni del cluster sovrapposto nello stesso istante. La direzione del moto è quella della traslazione media del cluster [57], dal primo all'ultimo centroide,

$$\mathbf{u} = \frac{\mathbf{x}_c(t_1^c) - \mathbf{x}_c(t_0^c)}{\|\mathbf{x}_c(t_1^c) - \mathbf{x}_c(t_0^c)\|}, \tag{5.10}$$

e lo *spostamento lungo il moto* è la media, sugli istanti in cui il cluster concordato e il cluster sovrapposto hanno entrambi valori, di $(\mathbf{x}_s(t) - \mathbf{x}_c(t)) \cdot \mathbf{u}$. È la componente lungo il moto con cui si scompone l'errore di posizione delle tracce dei cicloni rispetto al loro moto osservato, separata da quella perpendicolare [58]: uno spostamento lungo il moto positivo indica che il metodo segnala più dove il cluster va che dove è stato. La velocità media del

cluster è la distanza fra il primo e l'ultimo centroide divisa per la durata, in celle di 0.5° di latitudine ogni tre ore; i risultati sono riportati per classi di velocità, da 0 a 0.5, da 0.5 a 1, da 1 a 2 e almeno 2 celle ogni tre ore, perché un cluster quasi fermo non ha una direzione definita.

Probabilità di superamento. G_{n} è calcolato dalla media delle 20 estrazioni Monte Carlo (Sezione 4.6). La dispersione delle estrazioni, divisa per la deviazione standard della climatologia dello score, è indicata con $s(t, n)$ ed è nelle stesse unità di G_{n}. Le estrazioni sono approssimate con una gaussiana di media G_{n} e deviazione standard s, come si fa per un insieme di modelli [32]; nelle previsioni d'insieme si usa allo stesso modo una gaussiana costruita dalla media e dalla varianza dei membri, con coefficienti stimati [59]. La *probabilità di superamento* di un valore è la probabilità che un'estrazione superi la soglia τ:

$$p(t, n) = \Phi\left(\frac{G_{\mathrm{n}}(t, n) - \tau}{s(t, n)}\right), \tag{5.11}$$

con Φ la funzione di ripartizione della normale standard. Ogni segnalazione di G_{n} ha $p > 0.5$, perché la media delle estrazioni è sopra la soglia. Per ogni livello $L \in \{0.6, 0.7, 0.8, 0.9, 0.95\}$ le segnalazioni di G_{n} con $p \geq L$ sono trattate come un metodo che non vota, con le misure dei paragrafi precedenti. Il risultato è letto su tutti i livelli e non a un solo taglio, come nei lavori che scartano progressivamente le previsioni più incerte [60, 61, 62]. A ogni livello le segnalazioni sono meno numerose, e un insieme più piccolo tende per questo solo motivo a cominciare dopo e a finire prima; ogni livello ha quindi un controllo, lo stesso numero di segnalazioni di G_{n} estratte a caso. La probabilità di superamento dice qualcosa sulle segnalazioni solo dove il livello si discosta dal suo controllo.

Che cosa c'è attorno ai cluster. Le segnalazioni non concordate di un metodo nell'intorno di un cluster concordato sono divise per *posizione*: prima dell'inizio del cluster, dopo la sua fine e, mentre il cluster dura, *davanti* o *dietro* rispetto al moto. Davanti vuol dire dalla parte del centroide del cluster, in quell'istante, verso cui il cluster va lungo la direzione $\mathbf{u}$; dietro, dalla parte da cui viene. Sono divise anche secondo chi altro le segnala: il metodo da solo, cioè le sue segnalazioni esclusive, oppure insieme ad altri metodi, meno dei cinque che servono al voto; e, per G_{n}, secondo la probabilità di superamento. Di ogni valore si leggono gli scarti standardizzati delle quindici variabili d'ingresso (Sezione 4.3), nell'istante del valore e 3, 6, 12 e 24 ore dopo nella stessa cella: il massimo del loro valore assoluto e la percentuale di valori con almeno una variabile oltre due deviazioni standard. Si legge anche

quale variabile è la più lontana dal normale nell'istante del valore. Un valore è *lontano dal normale* se almeno una variabile supera due deviazioni standard, *moderato* altrimenti. Per entrambi si legge l'andamento prima del valore: la variazione più grande, in valore assoluto, dello scarto standardizzato di una variabile rispetto a tre ore prima e rispetto a 24 ore prima. Il termine di confronto sono i valori degli stessi intorni, nelle stesse posizioni, che nessun metodo segnala, letti su un quinto di essi estratto a caso. Le stesse misure sono ripetute dentro i cluster concordati, separando le segnalazioni concordate che il metodo segnala da quelle che non segnala. Le variabili d'ingresso sono quelle che i metodi leggono: queste misure descrivono come i valori si allontanano dal normale, ma non dicono se si tratti di anomalie meteorologiche.

Variabili che nessuno score legge. Come verifica preliminare si usano otto grandezze di ERA5 che nessuno score legge: l'energia potenziale convettiva disponibile (CAPE), la raffica di vento a dieci metri, la precipitazione convettiva, il vapore acqueo nella colonna, l'indice K, la temperatura di rugiada a due metri e la temperatura massima e la minima a due metri. Una grandezza è *insolita* in un valore quando sta nel suo 5% più estremo per quella cella, quel mese dell'anno e quell'ora, calcolato sugli anni di test: nel 5% più alto, nel più basso per la temperatura minima, in entrambe le code per la temperatura di rugiada. Per ogni posizione si confronta la percentuale di valori in cui una grandezza è insolita con quella del termine di confronto, anche anno per anno. La verifica è preliminare: le grandezze non sono state scelte per un tipo di anomalia, e un valore insolito non è di per sé un'anomalia meteorologica.

Capitolo 6

Risultati e discussione

Il capitolo riporta e discute i risultati del rilevatore sui campi ERA5, nella configurazione scelta dalla ricerca degli iperparametri. Senza etichette, una segnalazione indica dove lo score è alto, non che lì ci sia davvero un'anomalia meteorologica: questo vale per tutto il capitolo. Nel capitolo un valore è una coppia cella–istante; salvo dove indicato, è segnalato quando supera il 95-esimo percentile del proprio score sugli anni di validazione.

La Sezione 6.1 fissa la configurazione; il resto del capitolo ha due parti. Le Sezioni 6.2–6.5 scelgono quale componente dello score combinato usare: G, l'errore di ricostruzione del generatore, o D, la componente del discriminatore. Ne studiano il legame, l'effetto della normalizzazione climatologica e che cosa giudica il discriminatore, e confermano i risultati sugli anni di test. Lo score scelto è G_{n}, l'errore di ricostruzione del generatore con la normalizzazione climatologica (Sezione 4.7). Le Sezioni 6.6–6.9 descrivono che cosa segnala G_{n}: il confronto con otto metodi più semplici, le baseline, i cluster di segnalazioni per tipo e dimensione, le segnalazioni concordate e la dispersione del dropout; la Sezione 6.10 guarda, in via preliminare, grandezze di ERA5 che nessuno score legge. L'Appendice A verifica i risultati al variare della soglia.

6.1 Ricerca degli iperparametri

La ricerca della Sezione 5.2 conta 29 prove, quattro delle quali interrotte per una loss non finita. Ogni prova è giudicata dalla distanza MMD fra i campi osservati e quelli ricostruiti sugli anni di validazione (Sezione 5.1): più è bassa, più le ricostruzioni somigliano alle osservazioni. La Figura 6.1 mostra le prove nel piano delle prime due componenti principali dei quattro iperparametri, presi in scala logaritmica e standardizzati. Il piano spiega il 71% della varianza: due prove vicine nel piano possono essere lontane nei

quattro iperparametri, e per questo la *regione migliore*, le tre prove vicine fra loro con le distanze più basse (Tabella 6.1), è indicata sulle sue prove e non come un'area.

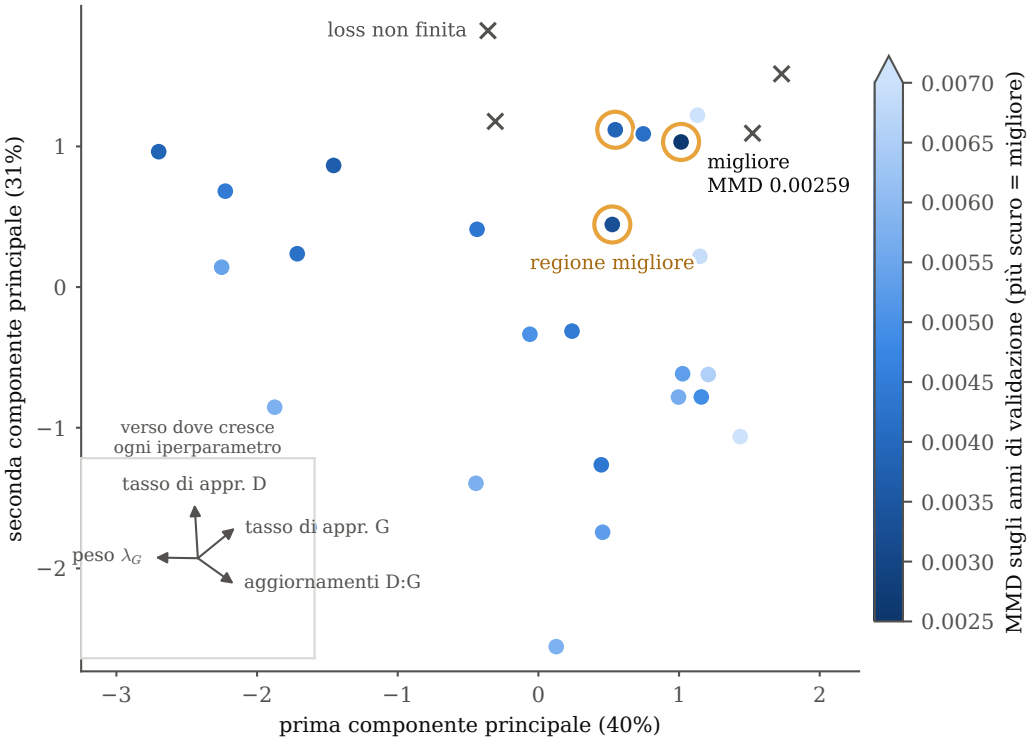


Figura 6.1: Le prove della ricerca degli iperparametri nel piano delle prime due componenti principali dei quattro iperparametri, colorate secondo la distanza MMD sugli anni di validazione, più scura dove è più bassa. I cerchi arancioni indicano le tre prove della regione migliore, il riquadro la direzione in cui cresce ciascun iperparametro.

La regione migliore. Tre prove formano la regione migliore (Tabella 6.1). Le loro distanze MMD sono 0.00259, 0.00327 e 0.00384: le prime due sono le più basse dell'intera ricerca. Le tre prove sono vicine fra loro nei quattro iperparametri, standardizzati come nella Figura 6.1, e sono le sole di quella zona sotto 0.004: per questo la regione comprende anche la terza, con 0.00384. Fuori dalla regione la prova migliore vale 0.00367, ma è isolata e le prove più vicine hanno dato fra 0.0038 e 0.0044: è un risultato singolo, non una regione.

Le prove vicine alla configurazione scelta. La prova più vicina alla configurazione scelta ha un tasso del generatore poco più basso (5.2×10^{-4})

Tabella 6.1: Le tre prove della regione migliore della ricerca degli iperparametri, con la distanza MMD sugli anni di validazione. La prima è la configurazione scelta.

Prova	Tasso di appr. G	Tasso di appr. D	Peso λ_G	Aggiornamenti D:G	MMD
Scelta	7.6×10^{-4}	3.1×10^{-3}	64	1:1	0.00259
Seconda	5.7×10^{-4}	1.5×10^{-3}	115	1:1	0.00327
Terza	8.2×10^{-4}	3.3×10^{-3}	173	1:1	0.00384

e quasi lo stesso peso di ricostruzione (60), ma il tasso del discriminatore al massimo della ricerca, 5×10^{-3}: la distanza sale a 0.0041. Le due prove con il tasso del discriminatore pari a 50 volte quello del generatore danno 0.0044 e 0.0054. Per la configurazione scelta il processo gaussiano della ricerca stima un valore atteso di 0.0032 ± 0.0004, con un rumore della distanza MMD di circa 0.0005: parte del suo vantaggio sulle prove vicine dipende quindi dal seme.

Le ultime prove esplorano. Le prove non si avvicinano via via alla regione migliore: vicino a essa la ricerca non si aspetta miglioramenti oltre il rumore, e sceglie le regioni che conosce meno. Le ultime prove, con peso di ricostruzione fino a 2000 e tasso del generatore sceso fino a 10^{-4}, hanno dato distanze fra 0.0037 e 0.0054.

6.2 G e D: un legame debole

Lo score combinato di STGAN somma due componenti, e prima di sceglierne una conviene capire se segnalano gli stessi valori. Questa sezione e le due seguenti riguardano gli anni di validazione 2000–2004 della configurazione scelta: 14616 istanti su 10611 celle. Sono gli anni su cui si sceglie lo score del rilevatore (Sezione 5.3); la Sezione 6.5 ripete le stesse misure sugli anni di test. Le grandezze usate sono riassunte nella Tabella 6.2. G e D sono le due componenti dello score, medie sulle 20 estrazioni (Sezione 4.6); D_{reale} e D_{generato} sono i due giudizi del discriminatore da cui D è calcolata, e servono nella Sezione 6.4. Il discriminatore è addestrato a dare 1 alla ricostruzione e 0 al campo osservato: un'uscita alta significa quindi "giudicato generato". Va fatta attenzione al nome: D_{reale} è il giudizio sull'osservazione, e se è alto l'osservazione è giudicata generata. Nell'idea di STGAN un'osservazione di

questo tipo non somiglia a quelle viste in addestramento, e per questo una D alta, come un G alto, significa "più insolito".

Tabella 6.2: Le grandezze del capitolo e il significato di un loro valore alto. Tutte sono calcolate per ogni cella e ogni istante.

Grandezza	Che cosa misura	Se è alto
G ($\bar{s}_G$)	errore di ricostruzione del generatore, medio sulla patch 3×3 della cella	osservazione più insolita
G_{n}	lo score del rilevatore (Sezione 4.7): G rispetto a ciò che è abituale per quella cella, giorno dell'anno e ora	osservazione più insolita per quel luogo e periodo
D_{reale}	giudizio del discriminatore sull'osservazione, fra 0 e 1	osservazione giudicata generata
D_{generato}	giudizio del discriminatore sulla ricostruzione, fra 0 e 1	ricostruzione giudicata generata
D	$D_{\text{reale}} - D_{\text{generato}}$, la componente del discriminatore	osservazione più insolita

Le due componenti sono confrontate con due correlazioni. Quella di Spearman è calcolata sui ranghi: dice se le due componenti mettono i valori nello stesso ordine, e pochi valori estremi pesano poco. Quella di Pearson è calcolata sulle componenti stesse, e dà più peso ai valori estremi. Entrambe valgono 1 se le due componenti vanno insieme, -1 se vanno in senso opposto, 0 se non hanno legame.

Nello spazio, G e D ordinano i luoghi quasi senza legame. La correlazione spaziale è calcolata in ogni istante sulle celle, e dice se le due componenti segnalano gli stessi luoghi nello stesso istante. Fra G e D la correlazione di Spearman vale in media 0.015 ed è negativa nel 44% degli istanti (Figura 6.2). Il segno segue la stagione: la media è 0.10 da dicembre a febbraio e -0.06 da giugno ad agosto. Sull'insieme delle celle, quindi, le due componenti ordinano i luoghi quasi in modo indipendente, e il poco legame che c'è cambia segno con la stagione.

Nel tempo, il legame è debole e non ha lo stesso segno in ogni cella. La correlazione temporale è calcolata in ogni cella sugli istanti, e dice se in quel luogo le due componenti salgono e scendono insieme. Fra G e D la correlazione di Spearman ha mediana -0.05 ed è negativa nel 67% delle celle (Figura 6.3). Il legame è un po' più forte nel sud del dominio, con una mediana di -0.11 fra 20° e 30°N, e più debole fra 40° e 50°N, con -0.02. Escludendo le tre file vicino al margine del dominio, la correlazione è negativa

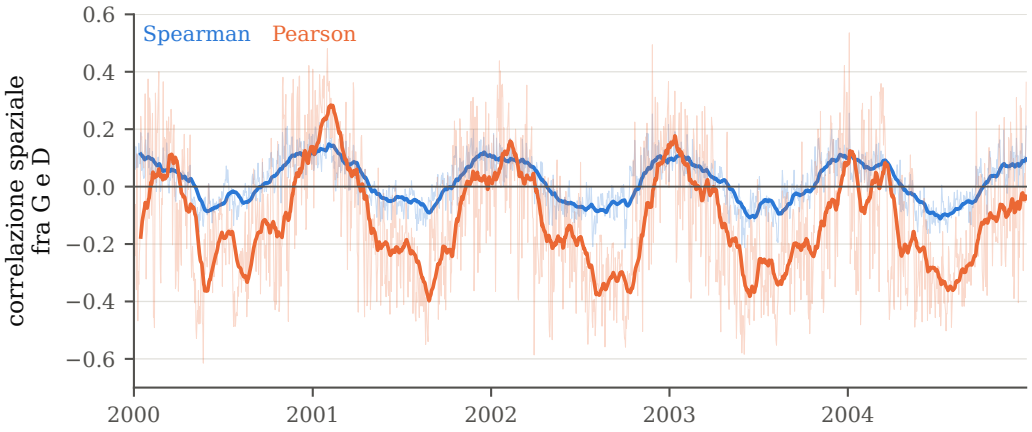


Figura 6.2: Correlazione spaziale fra G e D in ogni istante degli anni di validazione, calcolata sulle 10611 celle: media giornaliera (linea sottile) e media mobile su 30 giorni (linea spessa). Le due correlazioni restano vicine a zero; quella di Pearson è più negativa in estate.

nel 74% delle celle; le positive stanno per lo più fra 35° e 50°N.[1] Anche nel tempo, quindi, le due componenti sono quasi indipendenti, e il segno del loro legame dipende dal luogo.

L'unico legame di segno prevalente: dove G è più alto, D tende a essere più bassa. La correlazione di Pearson, che dà più peso ai valori estremi, è più negativa di quella di Spearman. Nello spazio vale in media -0.12 ed è negativa nel 65% degli istanti, soprattutto in estate (-0.28 da giugno ad agosto); nel tempo ha mediana -0.25 ed è negativa nell'83% delle celle. Questo suggerisce che il legame riguardi i valori più alti di G, come verifica la Sezione 6.4: quando e dove il generatore sbaglia di più, D tende a essere più bassa, cioè il discriminatore giudica l'osservazione meno insolita. La stessa sezione cerca di capire perché.

6.3 La normalizzazione climatologica

Il valore di G dipende anche da dove e quando è calcolato: dove G è grande per natura, G segnala di più. La normalizzazione climatologica (Sezione 4.7) toglie questa differenza, esprimendo ogni score rispetto a ciò che è abituale per

[1] Nelle tre file di celle più vicine al margine del dominio la correlazione è invece in genere positiva, con una mediana fra 0.08 e 0.17, e nella Figura 6.3 forma una cornice rossa. È probabilmente un effetto del modello, che vicino al margine completa il campo con zeri; il meccanismo non è verificato in dettaglio.

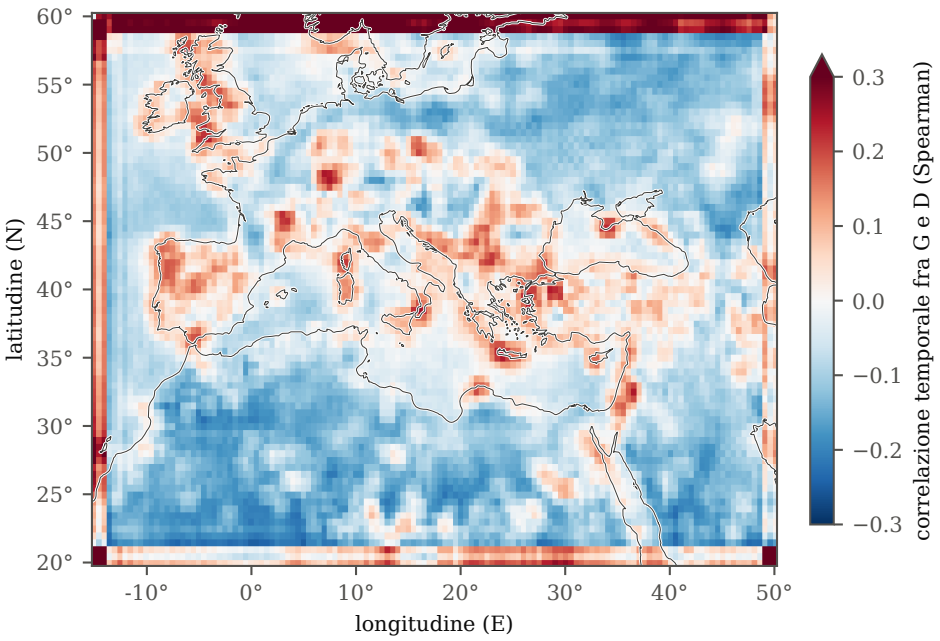


Figura 6.3: Correlazione temporale di Spearman fra G e D in ogni cella, sugli anni di validazione: blu dove D scende quando G sale, rosso dove salgono insieme; la freccia indica correlazioni oltre 0.3. Il legame è debole quasi ovunque. Linee di costa da Natural Earth.

la stessa cella, lo stesso giorno dell'anno e la stessa ora; G così normalizzato è indicato con G_{n} (Tabella 6.2). Questa sezione verifica se la normalizzazione climatologica cambia il legame fra G e D della Sezione 6.2, e dove cadono le segnalazioni.

Il legame fra G e D resta debole. Dopo la normalizzazione climatologica la correlazione di Spearman fra G_{n} e D, anch'essa normalizzata, vale in media 0.01 nello spazio e ha mediana -0.01 nel tempo: resta vicina a zero. Ciascuna componente conserva quasi lo stesso ordine: la correlazione di Spearman fra la componente prima e dopo la normalizzazione climatologica, applicata allo stesso modo anche a D, è 0.91 per G e 0.89 per D, calcolata sulle celle in ogni istante e poi mediata sugli istanti.

Con la normalizzazione climatologica le segnalazioni diventano quasi uniformi. La normalizzazione climatologica cambia invece dove cadono le segnalazioni (Figura 6.4). Con la soglia al 95-esimo percentile, sugli anni di validazione ciascuno score segnala il 5% dei valori. Senza normalizzazione climatologica G segnala soprattutto a sud e in estate, dove il suo errore è alto per natura: la percentuale va dall'1.6% fra 50° e 60°N in dicembre all'11.1% fra 20° e 30°N in agosto. Con G_{n} resta fra il 3.7% e il 6.3% in ogni fascia e in ogni mese. È l'effetto atteso dalla Sezione 4.7: la normalizzazione climatologica toglie la differenza di prevedibilità fra luoghi e stagioni. Lo si misura con la differenza relativa fra fasce di latitudine e mesi (Sezione 5.3.1): da G a G_{n} scende da 0.39 a 0.11, cioè di circa tre quarti; con la soglia al 99-esimo percentile, che segnala l'1% dei valori, da 0.70 a 0.28, circa tre quinti (Appendice A.1).

6.4 Che cosa giudica il discriminatore

Le sezioni precedenti mostrano che G e D sono quasi indipendenti, con un solo legame di segno prevalente: dove G è più alto, D tende a essere più bassa. Questa sezione cerca di capire perché, scomponendo D nei suoi due giudizi, D_{reale} e D_{generato} (Tabella 6.2): D è alta quando il discriminatore giudica generata l'osservazione più della sua ricostruzione. Come nella Sezione 6.2, G è qui senza normalizzazione climatologica, come nello score combinato; i cluster (Sezione 5.3.1) sono invece quelli di G_{n}, cioè di G con la normalizzazione climatologica della Sezione 6.3.

Quando G sale, entrambi i giudizi scendono. La correlazione temporale di Spearman fra G e D_{reale} ha mediana -0.73, quella fra G e D_{generato} ha

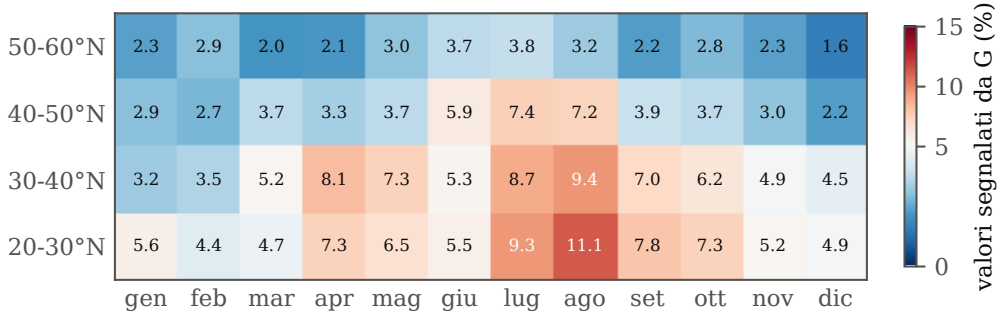


Figura 6.4a: Percentuale dei valori segnalati da G, senza normalizzazione climatologica, per fascia di latitudine e mese, sugli anni di validazione; il bianco corrisponde al 5%. Le segnalazioni si concentrano a sud e in estate.

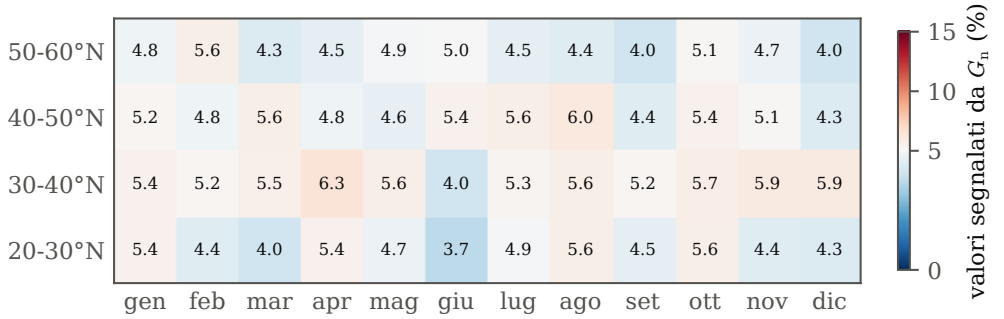


Figura 6.4b: Percentuale dei valori segnalati da G_n, con la normalizzazione climatologica, per fascia di latitudine e mese, sugli anni di validazione; il bianco corrisponde al 5%. Le segnalazioni sono distribuite in modo quasi uniforme.

mediana -0.69, ed entrambe sono negative in tutte le celle (Figura 6.5). Quando il generatore sbaglia di più, il discriminatore giudica più reali di quanto è abituale sia l'osservazione sia la sua ricostruzione.

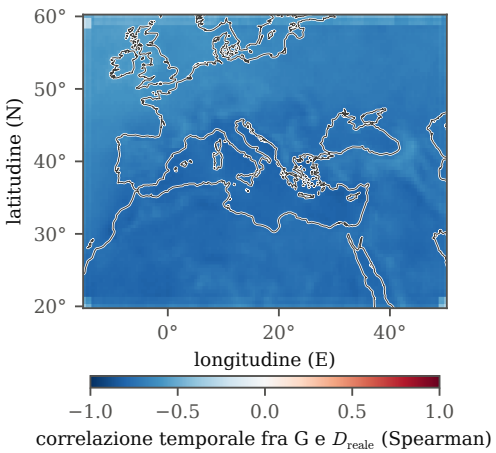


Figura 6.5a: Correlazione temporale di Spearman fra G e D_{reale}, il giudizio del discriminatore sull'osservazione, in ogni cella, sugli anni di validazione. È negativa in tutte le celle, intorno a -0.7. Linee di costa da Natural Earth.

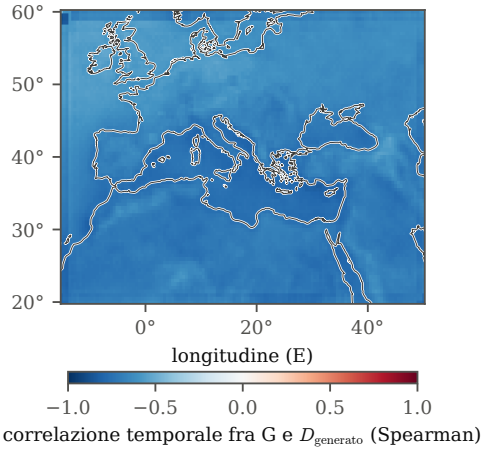


Figura 6.5b: Correlazione temporale di Spearman fra G e D_{generato}, il giudizio del discriminatore sulla ricostruzione, in ogni cella, sugli anni di validazione. È negativa in tutte le celle, intorno a -0.7. Linee di costa da Natural Earth.

I due giudizi si compensano. Poiché scendono insieme, i due giudizi sono legati fra loro, con una correlazione di Spearman mediana di 0.73. D è la loro differenza, e di questo movimento comune conserva solo una piccola parte: per questo il suo legame con G è debole. Nei valori più alti di G, però, D_{reale} scende un po' più di D_{generato}, e D scende: è il legame negativo che la correlazione di Pearson mette in luce nella Sezione 6.2.

Cluster di segnalazioni. Le correlazioni riguardano tutti i valori. Per vedere che cosa fa il discriminatore proprio dove G_{n} segnala, gli score sono letti attorno ai cluster di segnalazioni di G_{n} (Sezione 5.3.1). Sugli anni di validazione risultano 184877 cluster, con 7.7 milioni di valori in tutto, in media circa 42 valori per cluster.

Le zone. Attorno ai cluster di G_{n} le celle sono divise in nucleo, contorno e zona lontana, e in ogni zona ciascuno score è riassunto dal suo percentile mediano sugli anni di validazione (Sezione 5.3.1, Figura 5.1). Nucleo e contorno sono definiti dalle sole segnalazioni di G_{n}.

Dove G_n segnala, il discriminatore giudica reali l'osservazione e la ricostruzione. La Figura 6.6 riporta il risultato. Come riferimento sono mostrati G_n, lo score che definisce il nucleo, e G senza normalizzazione climatologica, molto legato a G_n (correlazione di Spearman 0.91, Sezione 6.3) e quindi anch'esso alto nel nucleo quasi per costruzione; nel contorno entrambi sono alti in parte perché G di una cella è la media dell'errore sulla sua patch 3×3, che contiene celle del nucleo.

D_{reale} e D_{generato} fanno il contrario, e questo non dipende dalla definizione delle zone, che usano solo G_n. Nel nucleo D_{reale} ha un percentile mediano di 5 e D_{generato} di 6: nei valori segnalati da G_n sia l'osservazione sia la ricostruzione sono giudicate più reali di quanto è abituale, anche se di poco in valore assoluto. Nel contorno restano bassi, con 12 e 15, anche perché il discriminatore legge la stessa patch; lontano dai cluster salgono a 58 e 57. In D i due effetti in parte si compensano, e nel nucleo il percentile mediano è 27.

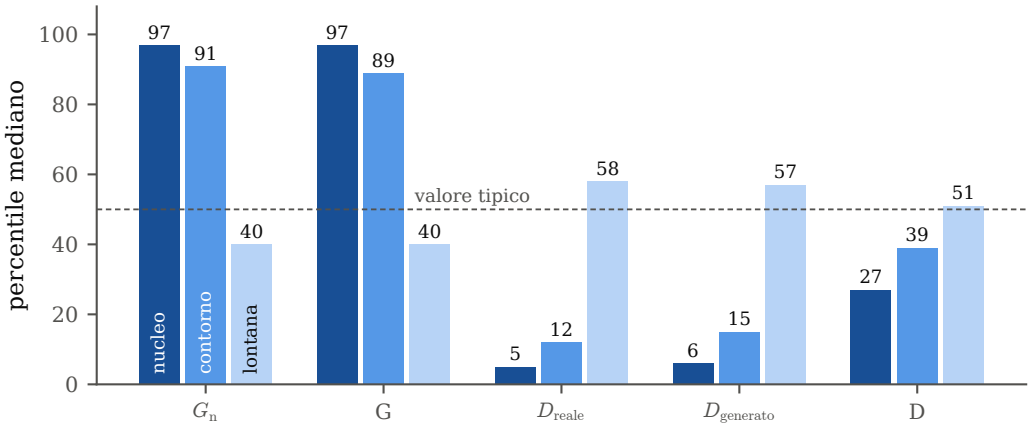


Figura 6.6: Percentile mediano di G_n, G, D_{reale}, D_{generato} e D nel nucleo dei cluster di G_n, nel contorno e nella zona lontana, sugli anni di validazione; il tratteggio indica 50, il valore tipico. Nel nucleo il discriminatore giudica reali sia l'osservazione sia la ricostruzione.

Nel nucleo D segnala un valore su quattro. Pur con un percentile mediano di 27, nel nucleo il 25.0% dei valori supera la soglia di D, contro il 2.9% della zona lontana: D segnala nel nucleo circa otto volte più che lontano dai cluster, ma solo in un valore su quattro; negli altri tre resta sotto la soglia. Il giudizio sull'osservazione va invece nel senso opposto: solo lo 0.5% dei valori del nucleo supera la soglia di D_{reale}, contro il 6.1% lontano dai cluster. Anche fra i valori segnalati da G_n il legame è lo stesso: divisi in tre gruppi con lo stesso numero di valori secondo D_{reale}, quello con D_{reale} più

basso, cioè con l'osservazione giudicata più reale, è quello con G_n più alto. In quel gruppo G_n, che è in deviazioni standard di G per quella cella, giorno dell'anno e ora, ha mediana 7.0, circa il doppio della soglia (3.4); negli altri due 4.8 e 4.4. Con una soglia più alta il comportamento è lo stesso e più marcato (Appendice A.1).

Un esempio: l'istante con G più alto. La Figura 6.7 mostra G e D il 9 agosto 2003 alle 12 UTC, l'istante con la media di G più alta degli anni di validazione. Nell'area principale del Nord Africa in cui G è alto, D_{reale} è vicino a zero, con una mediana di 0.07, e anche D_{generato} è fra i valori più bassi dell'istante, con una mediana di 0.19: il discriminatore giudica reali sia l'osservazione sia la ricostruzione, l'osservazione di più, e D è fra i valori più bassi del dominio. Su un'area più piccola più a sud-ovest, anch'essa con G alto, il giudizio sull'osservazione è meno netto (D_{reale} ha una mediana di 0.15), ma anche lì D è bassa. Dentro la linea della Figura 6.7, che racchiude l'1% delle celle con G più alto, il percentile mediano di D fra le celle dell'istante è 6. D_{reale} è basso anche nella penisola arabica, dove G è intorno al 94-esimo percentile dell'istante.

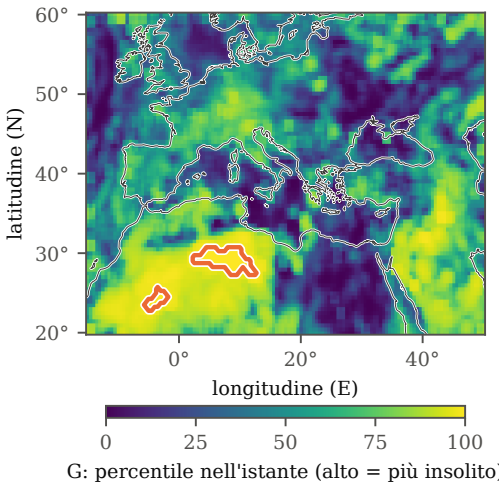


Figura 6.7a: G il 9 agosto 2003 alle 12 UTC, l'istante con la media di G più alta degli anni di validazione, come percentile fra le celle dell'istante; la linea arancione racchiude l'1% delle celle con G più alto. Linee di costa da Natural Earth.

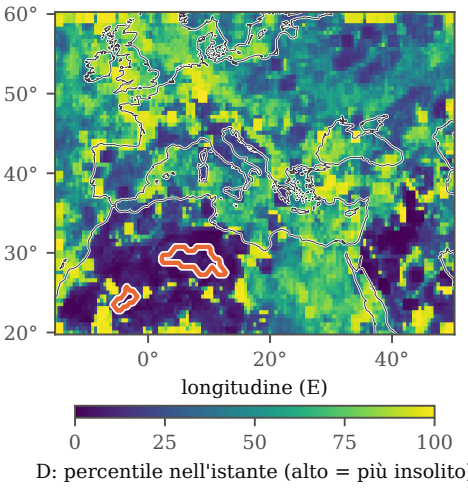


Figura 6.7b: D il 9 agosto 2003 alle 12 UTC, come percentile fra le celle dell'istante; la linea arancione racchiude l'1% delle celle con G più alto. Dentro la linea D è fra i valori più bassi. Linee di costa da Natural Earth.

Le ricostruzioni non sono più lisce delle osservazioni. Una spiegazione possibile del comportamento di D è che il discriminatore riconosca le ricostruzioni dal loro aspetto più liscio: i modelli addestrati con un errore quadratico producono campi troppo regolari, e le ricostruzioni di un autoencoder variazionale smussano gli estremi (Sezione 2.2). La rugosità (Sezione 5.3.1) è misurata su 240 istanti degli anni di validazione (Tabella 6.3) con il modello senza dropout, per non mescolarla con il rumore delle maschere di dropout. In mediana sugli istanti, la rugosità delle ricostruzioni è però 1.10 volte quella osservata: l'ipotesi non regge.

Tabella 6.3: Rugosità e giudizio medio del discriminatore sull'osservazione e sulla ricostruzione, intere e lisciate: mediane su 240 istanti degli anni di validazione, con il modello senza dropout.

Campo	Rugosità	Giudizio medio (1 = generato)
Osservazione	0.00082	0.502
Ricostruzione	0.00089	0.502
Osservazione lisciata	0.00021	0.512
Ricostruzione lisciata	0.00019	0.513

Una lettura: le celle rugose sono giudicate reali. Le celle con la rugosità locale più alta sono giudicate più reali (correlazione di Spearman mediana -0.61 fra rugosità locale e giudizio sull'osservazione) e tendono ad avere G alto (correlazione mediana 0.49). Lisciare l'osservazione la fa giudicare appena più generata: su tutte le celle il giudizio medio passa, in mediana sugli istanti, da 0.502 a 0.512 (Tabella 6.3), e sale nel 99.6% dei valori con G nel 5% più alto. La rugosità potrebbe quindi spiegare in parte perché, dove G è più alto, il discriminatore giudica reali le osservazioni. È una lettura di correlazioni, non una dimostrazione: il lisciamento riduce anche i valori più estremi, un effetto che la verifica non separa.

6.5 Conferma sugli anni di test e scelta dello score

Le Sezioni 6.2–6.4 riguardano gli anni di validazione, su cui si sceglie lo score. Questa sezione verifica che i loro risultati valgano anche sugli anni di test e fissa la scelta.

Sugli anni di test i risultati sono gli stessi. Le stesse analisi, ripetute sugli anni di test 2005–2025 con la climatologia e le soglie stimate sugli anni di validazione, danno gli stessi risultati (Tabella 6.4): le correlazioni cambiano di al più tre centesimi, i percentili mediani di al più 4 su 100. Sugli anni di test G_{n} segnala il 5.5% dei valori, un po' più del 5%, probabilmente perché negli anni di test l'errore di ricostruzione del generatore è in media un po' più alto; per lo stesso motivo le percentuali per luogo arrivano al 7.8%.

Tabella 6.4: Le principali misure delle Sezioni 6.2–6.4 sugli anni di validazione, dove si sceglie lo score, e sugli anni di test. Sugli anni di test climatologia e soglie sono quelle stimate sugli anni di validazione. Fra parentesi, la correlazione di Pearson.

Misura	Validazione	Test
Correlazione spaziale di Spearman fra G e D, media	0.015	−0.001
Correlazione temporale di Spearman fra G e D, mediana	−0.05	−0.07
Correlazione temporale di Spearman fra G e D_{generato}, mediana	−0.69	−0.69
Correlazione temporale di Spearman fra G e D_{reale}, mediana (di Pearson)	−0.73 (−0.77)	−0.73 (−0.75)
Cluster di G_{n}	184877	794206
Percentile mediano nel nucleo: D_{reale}, D_{generato}, D	5, 6, 27	5, 6, 23
D_{reale} sopra la propria soglia: nucleo, zona lontana	0.5%, 6.1%	0.5%, 6.2%
Percentuale per fascia di latitudine e mese di G_{n}	3.7–6.3%	3.6–7.8%
Rugosità della ricostruzione divisa per quella dell'osservazione, mediana	1.10	1.08
Celle del 5% più alto di G in cui D_{reale} sale lisciando l'osservazione	99.6%	99.6%

D concorda con G solo in parte. Sugli anni di validazione e di test il quadro è lo stesso: dove G_{n} segnala, il discriminatore giudica reali sia l'osservazione sia la ricostruzione, e D supera la propria soglia solo in un quarto del nucleo. Senza etichette questo disaccordo, da solo, non dice quale delle due componenti abbia ragione.

Lo score combinato dell'articolo è, di fatto, D. Lo score combinato somma le due componenti dopo averle riportate su una scala comune (Sezione 4.6). Sugli anni di validazione ordina i valori quasi come D e poco come G: la correlazione di Spearman con D è 0.99 sia nello spazio sia nel tempo,

quella con G è 0.13 nello spazio e 0.07 nel tempo, e con la normalizzazione climatologica i valori restano quasi gli stessi (0.99 con D normalizzata, 0.12 e 0.10 con G_{n}). Anche le segnalazioni sono quelle di D: con i tre score normalizzati, il 94% dei valori segnalati dallo score combinato è segnalato anche da D, solo il 32% anche da G_{n}, e con la soglia al 99-esimo percentile le percentuali sono 93% e 19%. Usare lo score combinato vorrebbe dire, quindi, usare il discriminatore.

Lo score del rilevatore è G_{n}. La scelta poggia sul significato delle due componenti. G ha un significato chiaro: misura quanto un campo si allontana da ciò che il modello si aspetta. D dipende anche dal giudizio sulla ricostruzione, e il suo comportamento si spiega solo in parte. Sommarle, come nello score combinato, darebbe di fatto D, come mostra il paragrafo precedente. Il rilevatore usa quindi G_{n} (Sezione 4.7), che distribuisce le segnalazioni in modo quasi uniforme fra luoghi e stagioni (Sezione 6.3).

6.6 Confronto con le baseline

Le sezioni precedenti scelgono lo score del rilevatore, G_{n}; questa ne confronta le segnalazioni con quelle delle otto baseline, con le soglie e le misure di accordo della Sezione 5.4. Il confronto riguarda gli anni di test 2005–2025: 651 milioni di valori, con ogni metodo che ne segnala fra il 5.1% e il 5.6% (Tabella 6.5).

I metodi che leggono una cella in un istante concordano fra loro. La Figura 6.8 riporta l'indice di Jaccard di ogni coppia. I sei modelli shallow e la distanza dal normale formano un gruppo, con indici fra il 35% e il 63%: leggono lo stesso vettore, e tutti misurano quanto il valore è lontano da ciò che è abituale. La variazione in tre ore resta da parte, con indici fra il 17% e il 26%: segnala soprattutto altri valori.

G_{n} si sovrappone a entrambi. Il 54% delle segnalazioni di G_{n} è segnalato anche dalla variazione in tre ore, e fra il 39% e il 52% da ciascuno dei metodi che leggono una cella in un istante, contro il 5% atteso fra metodi indipendenti. Il metodo più vicino alla variazione in tre ore è G_{n}, con un indice di Jaccard del 37%; fra gli altri metodi il più vicino alla variazione in tre ore è MCD, con il 26%. Il risultato è coerente con la definizione di G: il generatore risponde a partire dagli istanti precedenti, quindi il suo errore può crescere sia quando un valore si allontana da ciò che è abituale sia quando cambia in fretta. L'accordo da solo non dimostra però questo meccanismo. Nessun singolo

Tabella 6.5: Segnalazioni dei metodi sugli anni di test, con la soglia di ciascuno al 95-esimo percentile del proprio score sugli anni di validazione. Esclusive: non segnalate da nessun altro metodo. Baseline in ordine di segnalazioni di G_n condivise.

Metodo	Valori segnalati	Segnalazioni esclusive	Segnalazioni di G_n condivise	Jaccard con G_n
G_n	5.54%	18.1%	–	–
Variazione in tre ore	5.48%	31.8%	53.9%	37.2%
MCD	5.43%	7.9%	52.1%	35.7%
PCA	5.31%	0.6%	48.7%	33.1%
Isolation Forest	5.17%	4.1%	44.0%	29.4%
CBLOF	5.41%	7.7%	43.4%	28.2%
COPOD	5.16%	6.9%	43.4%	29.0%
Distanza dal normale	5.62%	14.0%	40.8%	25.4%
HBOS	5.14%	9.5%	39.2%	25.5%

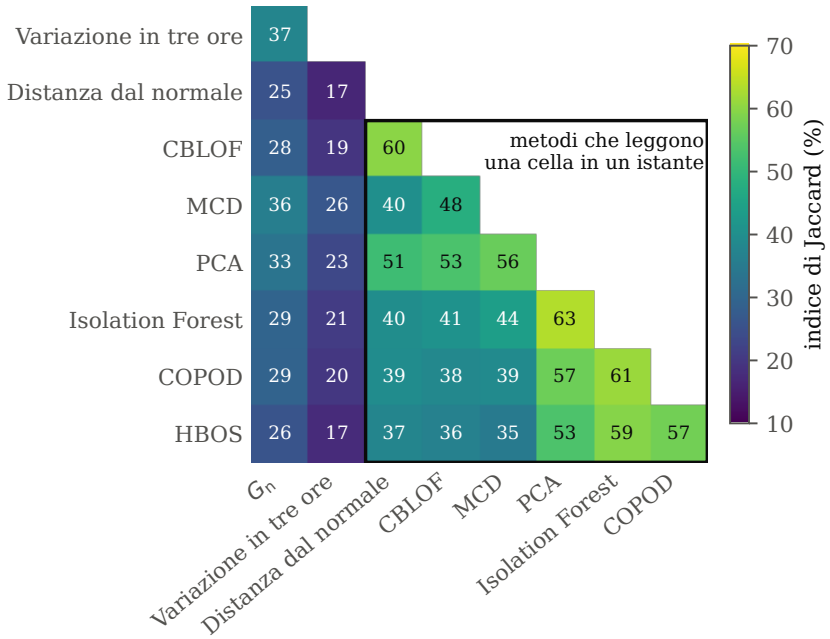


Figura 6.8: Indice di Jaccard delle segnalazioni di ogni coppia di metodi sugli anni di test, in percentuale. I metodi che leggono una cella in un istante formano un gruppo (nel riquadro); la variazione in tre ore resta da parte.

metodo semplice riproduce le segnalazioni di G_{n}: il più vicino ne condivide poco più della metà.

Il voto a maggioranza. Il 4.22% dei valori è segnalato da almeno cinque metodi su nove, G_{n} compreso, e il 48.3% delle segnalazioni di G_{n} è condiviso da questa maggioranza, che riflette soprattutto i metodi che leggono una cella in un istante. Con le lacune di ogni metodo chiuse, lo stesso voto definisce le segnalazioni concordate (Sezione 5.5).

Le segnalazioni esclusive di G_{n}. Per G_{n} le segnalazioni esclusive sono il 18.1% delle sue segnalazioni, circa l'1% di tutti i valori; l'81.9% è quindi segnalato anche da almeno un altro metodo. Gli altri otto insieme segnalano circa il 14% dei valori: se G_{n} fosse indipendente da loro, solo circa il 14% delle sue segnalazioni sarebbe condiviso, contro l'81.9% osservato. La percentuale di segnalazioni esclusive di G_{n} è intermedia fra quelle delle baseline: 31.8% per la variazione in tre ore, il 14.0% per la distanza dal normale, meno del 10% per i modelli shallow. Segnalare molto da solo non è di per sé un pregio: può indicare ciò che solo il generatore coglie, per esempio perché legge le celle vicine, oppure un suo errore. Il confronto non permette di distinguere i due casi.

La stabilità dei modelli shallow. I modelli shallow dipendono dal campione su cui sono stimati. Stimati di nuovo con campioni più grandi e con un altro seme e confrontati sugli anni di validazione, PCA, MCD e COPOD segnalano quasi gli stessi valori, con un indice di Jaccard fra il 98% e il 99%; CBLOF, Isolation Forest e HBOS cambiano di più, e HBOS con sé stesso arriva solo al 54–58%. Il 25.5% fra G_{n} e HBOS va quindi confrontato con questo valore, non con il 100%. L'accordo di G_{n} con MCD e PCA non ne risente.

Sintesi. I metodi che leggono una cella in un istante segnalano in larga parte gli stessi valori, la variazione in tre ore ne segnala altri, e G_{n} si sovrappone a entrambi senza coincidere con nessuno: la maggior parte delle sue segnalazioni è condivisa da almeno una baseline. Questo sostiene la coerenza del rilevatore, ma non ne misura l'accuratezza.

6.7 Cluster di segnalazioni per tipo e dimensione

Scelto lo score, resta da descrivere che cosa segnala: quanto sono grandi i cluster, quali variabili vi si allontanano di più dal normale e come cala G_n attorno a ciò che segnala. Le segnalazioni sono raggruppate in cluster come nella Sezione 6.4: sugli anni di test se ne contano 794206, con 36.1 milioni di valori. Come termine di confronto, le stesse misure sono ripetute sui cluster che ciascuna delle otto baseline della Sezione 5.4 forma con le proprie segnalazioni, anch'esse al 5% con la soglia stimata sugli anni di validazione (Tabella 6.6). Le baseline leggono una cella alla volta, senza le celle vicine, e non dipendono dal modello addestrato.

Pochi cluster enormi contengono circa tre quarti dei valori. Il 90.6% dei cluster ha meno di 20 valori, e insieme contengono solo il 7.5% dei valori segnalati; lo 0.5% dei cluster, quelli con almeno 1000 valori, ne contiene il 75.5% (Figura 6.9). Le baseline formano più cluster piccoli: fra il 94.7% e il 97.1% dei loro cluster ha meno di 20 valori. Le segnalazioni di G_n sono quindi più raggruppate, in parte perché lo score di una cella è mediato sulla sua patch 3×3.

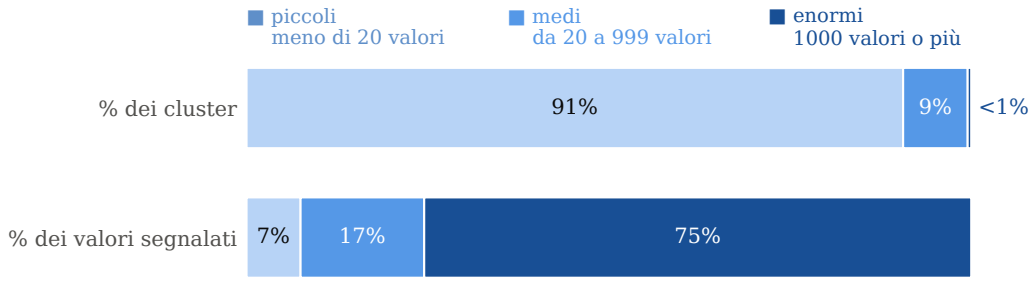


Figura 6.9: I cluster di G_n sugli anni di test per dimensione, cioè per numero di valori: piccoli (meno di 20), medi (da 20 a 999) ed enormi (1000 o più). In alto la percentuale dei cluster, in basso quella dei valori segnalati. Pochi cluster enormi contengono la maggior parte dei valori.

Il tipo di cluster. Divisi per tipo (Sezione 5.3.1), i cluster di velocità verticale e di precipitazione raccolgono da soli il 61% dei valori segnalati di G_n; segue, molto distante, la copertura nuvolosa, con il 7% (Figura 6.10).

Tabella 6.6: I cluster di ciascun metodo, formati dalle sue segnalazioni, sugli anni di test, con la soglia di ciascun metodo al 95-esimo percentile del proprio score sugli anni di validazione.

				Percentile mediano dello score fuori dal bordo		
Metodo	Cluster	Cluster con meno di 20 valori	Valori in cluster con almeno 1000 valori	1 cella	2 celle	6 celle
G_{n}	794 k	90.6%	75.5%	90	79	50
Distanza dal normale	768 k	95.1%	85.6%	87	73	47
Variazione in tre ore	2.80 M	96.5%	60.2%	84	64	41
PCA	1.16 M	95.8%	79.4%	88	75	47
MCD	1.73 M	96.4%	73.7%	87	70	43
CBLOF	980 k	95.3%	81.5%	87	71	45
COPOD	697 k	94.7%	84.5%	91	82	56
HBOS	1.58 M	97.1%	78.1%	88	76	48
Isolation Forest	1.19 M	96.0%	79.0%	89	77	49

Il tipo principale dipende dal metodo. La variazione in tre ore ha quasi gli stessi tipi di G_{n}, con velocità verticale e precipitazione al 65% dei valori e la copertura nuvolosa al terzo posto. Anche MCD raccoglie in queste due variabili il 68% dei valori, ma con la precipitazione al primo posto (43%) e l'umidità del suolo al terzo. Negli altri metodi il tipo principale cambia: nella distanza dal normale e in CBLOF è l'umidità del suolo, che cambia lentamente e forma cluster lunghi; in COPOD e HBOS è la velocità d'attrito; in PCA e Isolation Forest i valori sono divisi fra più tipi.

I cluster più grandi sono catene. Quando è segnalato il 5% dei valori, segnalazioni dovute ad anomalie meteorologiche diverse possono toccarsi e unirsi in un solo cluster; i più grandi durano settimane: il più grande di precipitazione dura 40 giorni, quello di velocità verticale 23, e in quasi tutti i loro istanti contano centinaia di celle, con una mediana rispettivamente di 472 e 723. Un cluster così lungo difficilmente corrisponde a un'unica anomalia: è piuttosto una catena, cioè una successione di gruppi di segnalazioni, ciascuno a contatto con il seguente, e la sua dimensione dice quanto si estende la catena. Le catene non sono una particolarità di G_{n}: in tutti i metodi i cluster con almeno 1000 valori contengono fra il 60% e l'86% dei valori segnalati (Tabella 6.6). Le catene dipendono poco dal collegamento nello spazio e molto da quello nel tempo: senza le diagonali la percentuale dei valori nei cluster con almeno 1000 valori resta al 74%; se invece due istanti consecutivi si collegano

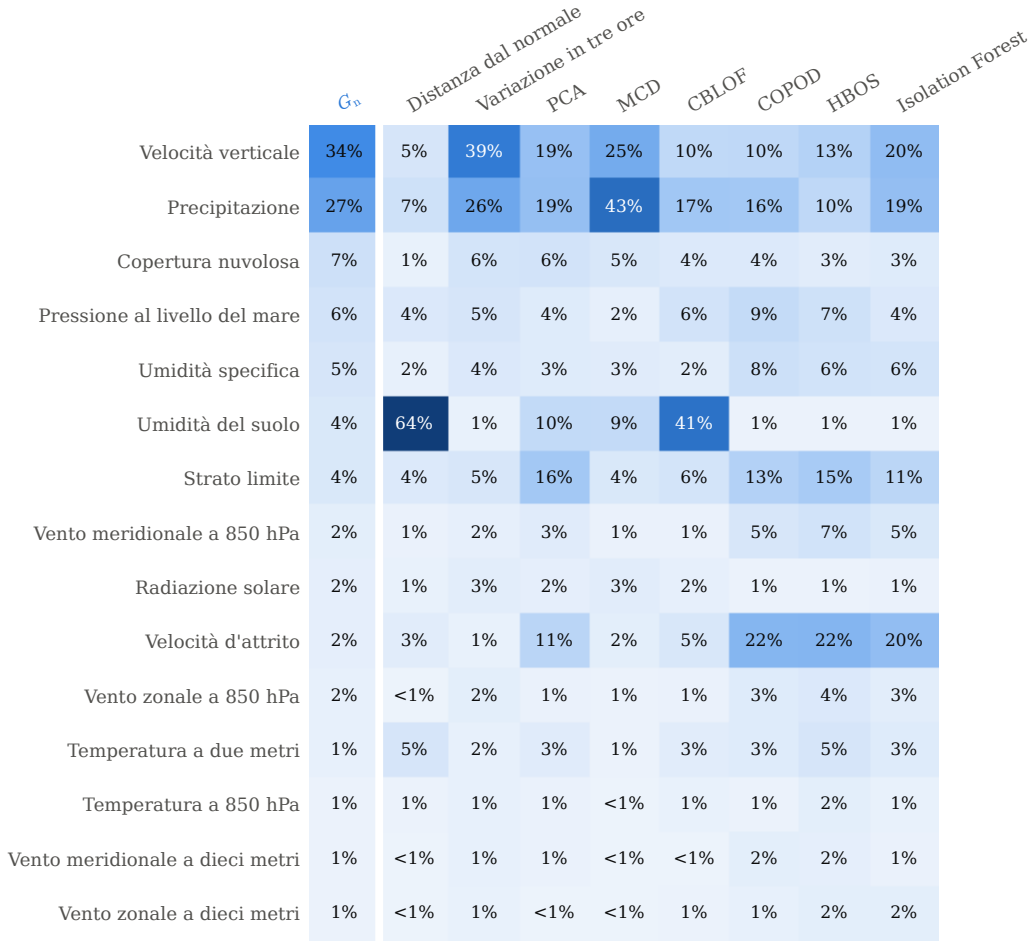


Figura 6.10: Percentuale dei valori segnalati per tipo di cluster, sugli anni di test, nei cluster di G_{n} (prima colonna) e in quelli di ciascuna baseline; ogni colonna somma a 100. Il tipo principale dipende dal metodo.

solo quando le celle in comune sono almeno la metà di quelle dell'istante con meno celle, la percentuale scende al 57%, e senza alcun collegamento nel tempo sarebbe l'1%. Vengono quindi soprattutto dalla persistenza nel tempo delle aree segnalate, e in parte dalla percentuale segnalata: con la soglia più alta si accorciano (Appendice A.1).

G_n cala in modo graduale. Resta da vedere come G_n cala dal nucleo verso l'esterno; un esempio su una mappa è nella Figura 6.13. La Figura 6.11 riassume tutti gli anni di test nel profilo di ogni score (Sezione 5.3.1), dove 50 è un valore tipico. Che le celle segnalate stiano sopra la soglia e le altre sotto è vero per costruzione; il risultato è la forma della curva. A una cella dentro il bordo G_n vale 96, a una cella fuori 90, due celle fuori 79, tre celle fuori 68, e torna a un valore tipico dopo circa sei celle, cioè tre gradi, circa 300 km. Oltre scende ancora, perché lontano dai cluster restano soprattutto i valori bassi. G_n distingue quindi nucleo, contorno e zona lontana in modo graduale, senza un confine proprio: la soglia taglia una curva continua. Le baseline, ciascuna sui propri cluster, hanno la stessa forma, ma quasi tutte calano più in fretta: a due celle fuori G_n vale 79 e le baseline fra 64 (variazione in tre ore) e 77 (Isolation Forest); solo COPOD, con 82, cala ancora più lentamente di G_n. A sei celle tutti i metodi sono fra 41 e 56. Per G_n parte della gradualità vicino al bordo dipende dalla patch 3×3 su cui lo score è mediato, che le baseline, lette cella per cella, non hanno. Il nucleo, inoltre, è sottile: il 67% dei valori segnalati sta sul bordo del cluster, a una sola cella dall'esterno.

Anche le baseline seguono il profilo di G_n. Letti sui cluster di G_n invece che sui propri, gli score delle baseline non giudicano G_n: dicono quanto erano insoliti, per ciascun metodo, i dati dove G_n segnala. È la Figura 6.11b; nella Figura 6.11a ogni metodo segue invece i propri cluster. Sui cluster di G_n tutte le baseline hanno lo stesso andamento di G_n: valgono 99–100 nelle celle più interne, fra 89 e 93 una cella dentro il bordo, fra 79 e 84 una cella fuori (G_n: 96 e 90) e fra 49 e 53 dopo sei celle. La distanza dal normale è fra le più basse e continua a salire anche dentro il nucleo, da 89 a 96 in una sola cella: la sua soglia non coincide con il bordo, quindi la salita non è un effetto della soglia. Che le grandezze salgano insieme mostra che le segnalazioni non cadono a caso, non che siano giuste.

Insolito, ma non sempre estremo. Nel nucleo solo il 41% dei valori supera la soglia della distanza dal normale, contro il 16% nel contorno e il 2% nella zona lontana. Il restante 59% è sotto quella soglia: G_n segnala anche valori che, presi uno per uno, non sono fra i più lontani dal clima. In parte è

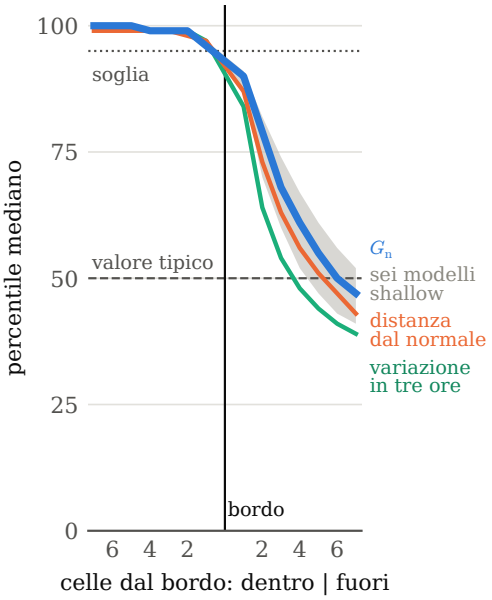


Figura 6.11a: Percentile mediano dello score secondo la distanza in celle dal bordo del cluster più vicino, per ogni metodo sui propri cluster, sugli anni di test; la fascia grigia va dal più basso al più alto dei sei modelli shallow. G_n cala più lentamente di quasi tutte le baseline.

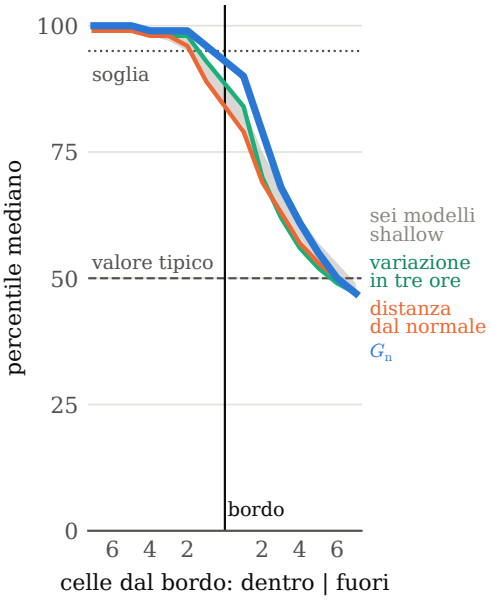


Figura 6.11b: Percentile mediano dello score secondo la distanza in celle dal bordo del cluster più vicino, per tutti i metodi sui cluster di G_n, sugli anni di test; la fascia grigia va dal più basso al più alto dei sei modelli shallow. Tutte le baseline calano allo stesso modo di G_n.

atteso, perché i due score misurano cose diverse. Anche la dimensione conta: il percentile mediano della distanza dal normale nel nucleo va da 79–80 nei cluster con meno di 20 valori a 95 in quelli con almeno 10000, quindi i cluster piccoli sono i meno estremi.

Per tipo di cluster, G_n cala in modo simile, come diverse baseline. Vicino al bordo G_n è quasi uguale per tutti i tipi: una cella fuori vale fra 89 e 91. Più lontano si separa di poco: a sei celle va da 43 per la radiazione solare a 58 per la pressione. Non è una proprietà del solo G_n. A due celle fuori dal bordo dei propri cluster (Figura 6.12c, senza i tipi con meno di 1000 valori a quella distanza), il percentile mediano di G_n va dal 74 all'82 a seconda del tipo. Intervalli altrettanto stretti hanno la variazione in tre ore (da 60 a 67), HBOS (da 73 a 81) e COPOD (da 76 a 85); la distanza dal normale, MCD e PCA vanno invece da poco più di 60 a oltre 80. Per sette metodi su nove il tipo più basso è la radiazione solare.

Lo scarto standardizzato della variabile del tipo cala invece in modo diverso. Le differenze grandi riguardano lo scarto standardizzato della variabile del tipo (Figura 6.12). Nella figura sono in colore i tre tipi con più valori nei cluster di almeno 20 valori, velocità verticale, precipitazione e copertura nuvolosa, e la temperatura a due metri; ogni punto è la mediana dei valori a quella distanza in tutti i cluster del tipo, e i punti con meno di 1000 valori non sono tracciati, perché la mediana sarebbe poco affidabile. A differenza della distanza dal normale, che riassume tutte le variabili di una cella, lo scarto standardizzato riguarda una sola variabile. La variabile del tipo è per definizione la più lontana dal normale nel nucleo: è in parte atteso che lì lo scarto standardizzato sia alto e fuori scenda, e il confronto utile è fra i tipi. Il livello di fondo (Sezione 5.3.1) non è mai zero: vale per esempio 0.42 per la precipitazione e 0.98 per la pressione. Per precipitazione, copertura nuvolosa e radiazione solare lo scarto standardizzato torna vicino al livello di fondo entro due celle dal bordo: per la precipitazione scende da 1.33 nell'ultima cella del nucleo a 0.48 due celle fuori, per la copertura nuvolosa da 1.62 a 0.52. La velocità verticale scende più lentamente, da 1.38 a 0.78. Per la temperatura a due metri resta alto a lungo: a sette celle fuori lo scarto standardizzato è ancora 1.33. La pressione e la temperatura a 850 hPa si comportano allo stesso modo, con 1.38 e 1.58 a sette celle; i venti e l'umidità specifica stanno in mezzo.

Il risultato è coerente con il modo in cui queste variabili cambiano nello spazio, anche se la verifica non lo dimostra: precipitazione e nuvole possono cambiare da una cella all'altra, mentre temperatura e pressione variano su

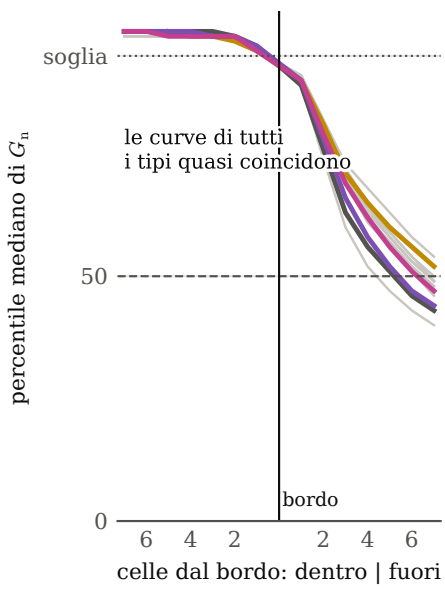


Figura 6.12a: Percentile mediano di G_n secondo la distanza in celle dal bordo del cluster, per tipo di cluster, sugli anni di test: velocità verticale (rosa), precipitazione (viola), copertura nuvolosa (grigio scuro), temperatura a due metri (ocra), altri tipi in grigio chiaro. Le curve quasi coincidono.

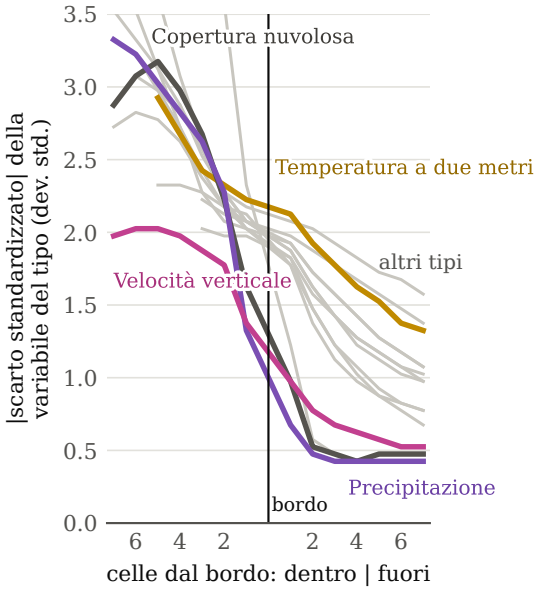


Figura 6.12b: Scarto standardizzato mediano, in valore assoluto, della variabile del tipo, secondo la distanza in celle dal bordo del cluster, per ogni tipo di cluster, sugli anni di test. Alcune variabili tornano ai livelli di fondo entro due celle, altre restano a lungo lontane dal normale.

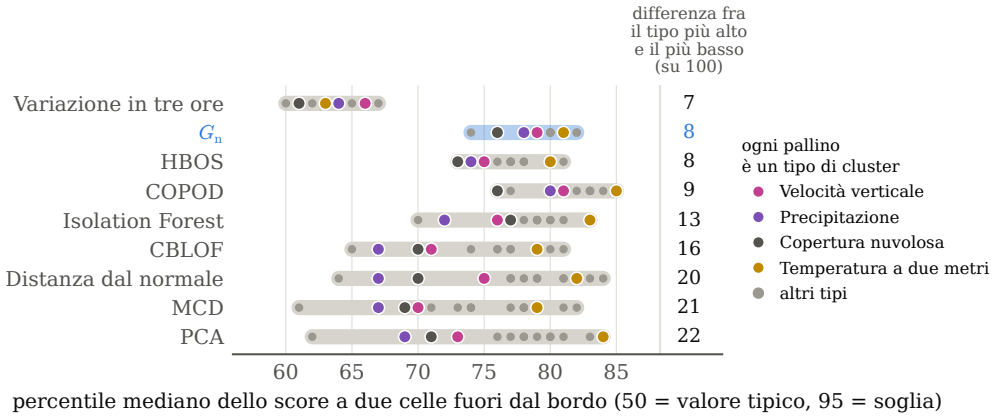


Figura 6.12c: Percentile mediano di ogni score a due celle fuori dal bordo dei propri cluster, un pallino per tipo di cluster, sugli anni di test; il segmento va dal tipo più basso al più alto e il numero a destra è la loro differenza. G_n è fra i metodi più uniformi.

aree più ampie. Nel primo gruppo il nucleo di G_n contiene quasi tutta l'area in cui lo scarto standardizzato è alto. Nel secondo lo scarto standardizzato continua oltre il nucleo: G_n ne segnala solo una parte, e le celle vicine, pur lontane dal normale, restano sotto la sua soglia.

Sintesi. In tutti i metodi la maggior parte dei valori segnalati, fra il 60% e l'86%, sta in pochi cluster enormi; in G_n circa tre quarti, per lo più di velocità verticale o precipitazione; i tipi di G_n somigliano a quelli della variazione in tre ore e, in parte, di MCD. G_n cala gradualmente attorno a ciò che segnala, senza un confine proprio e più lentamente di quasi tutte le baseline, in parte per la patch su cui è mediato. Letta sui cluster di G_n, la distanza dal normale ha lo stesso andamento, ma solo il 41% dei valori segnalati ne supera la soglia.

6.7.1 Un cluster per tipo

Fin qui i cluster sono descritti tutti insieme e per tipo; resta da vedere su una mappa che cosa riassumono i numeri, con un cluster per ciascuno dei tre tipi con più valori. Gli esempi sono scelti con una regola fissata prima di esaminarli, così che nessuno sia preso per il suo aspetto. I tipi sono i tre con più valori nei cluster di almeno 20 valori: velocità verticale, precipitazione e copertura nuvolosa. Per ciascuno l'esempio è il cluster con più valori fra quelli che durano al massimo tre giorni, letto nell'istante in cui conta più celle. Il limite di durata esclude le catene descritte sopra, che difficilmente corrispondono a un'unica anomalia meteorologica. Gli esempi non sono quindi i cluster più importanti né i più tipici: mostrano come appare un cluster compatto di ciascun tipo.

In ogni esempio la cella seguita nel tempo è quella del nucleo con G_n più alto. La Tabella 6.7 riassume le tre zone. I luoghi del nucleo nominati nel testo sono letti sulla mappa.

Velocità verticale. Il 23 novembre 2017 il nucleo forma una fascia stretta che va dall'Atlantico al largo del Portogallo fino alla Scandinavia meridionale, passando sul Golfo di Biscaglia, sulla Manica e sul Mare del Nord (Figura 6.13). Lungo la fascia la velocità verticale è per lo più sotto il normale. In ERA5 è in $\mathrm{Pa\,s^{-1}}$, quindi è negativa quando l'aria sale: lo scarto standardizzato è negativo, cioè l'aria sale più o scende meno di quanto è abituale, nel 73% delle celle del nucleo. Nel 34% delle celle è inferiore a 1 in valore assoluto, vicino al normale. Una parte del nucleo, 25 celle, sta sulla prima fila a 60°N, cioè sul margine del dominio, dove il modello si comporta probabilmente in modo diverso (Sezione 6.2): quella parte va letta con cautela. Nella cella seguita, a

Tabella 6.7: I tre esempi, nell'istante delle mappe. La zona lontana è a più di tre celle da ogni cella segnalata.

	Velocità verticale	Precipitazione	Copertura nuvolosa
Celle del nucleo	549	576	404
Durata del cluster (ore)	63	72	66
Percentile mediano di G_n			
nel nucleo	97	97	98
nel contorno	91	91	89
nella zona lontana	42	33	43
Percentile mediano della distanza dal normale			
nel nucleo	97	91	93
nel contorno	94	87	56
nella zona lontana	40	44	33
Valori del nucleo oltre la soglia della distanza dal normale	65%	34%	46%

58.5°N e 8.5°E, G_n supera la soglia nelle prime ore del 22 novembre e vi resta, salvo una breve pausa, per circa un giorno e mezzo, finché la cella fa parte del cluster; la distanza dal normale sale insieme a G_n e supera il 90-esimo percentile per circa un giorno. Poi entrambi tornano a valori tipici. Il cluster cresce e cala in modo abbastanza regolare, con il massimo nell'istante delle mappe.

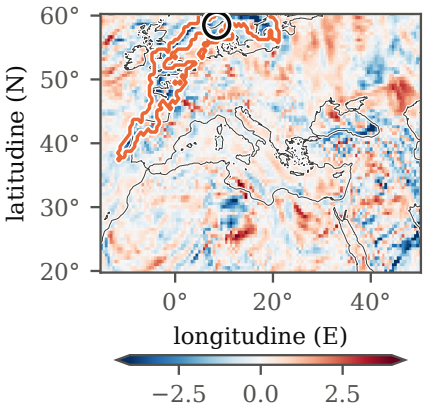


Figura 6.13a: Scarto standardizzato della velocità verticale il 23 novembre 2017 alle 00 UTC, con il nucleo del cluster in arancione e la cella seguita nel cerchio. Il nucleo è una fascia stretta in cui la velocità verticale è per lo più sotto il normale. Linee di costa da Natural Earth.

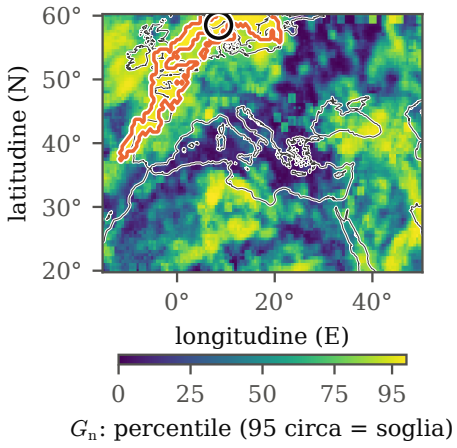


Figura 6.13b: G_n come percentile il 23 novembre 2017 alle 00 UTC, con il nucleo del cluster in arancione e la cella seguita nel cerchio. Linee di costa da Natural Earth.

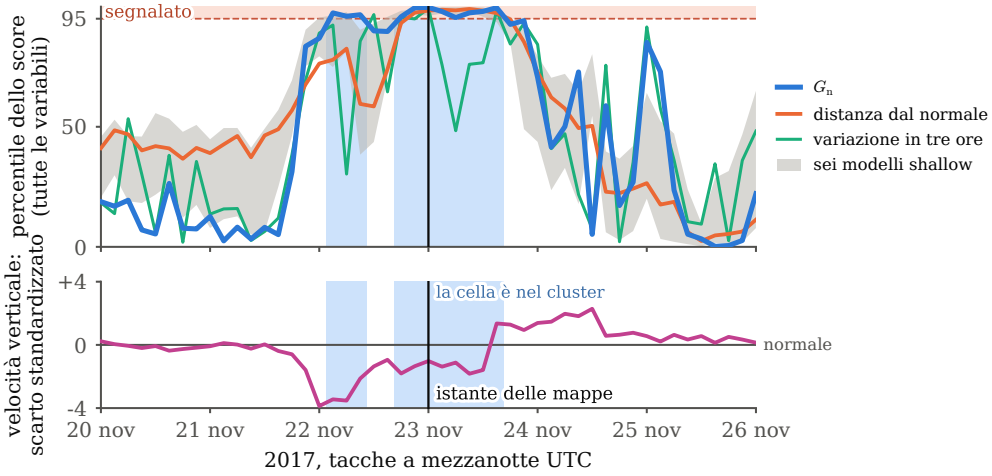


Figura 6.13c: Percentile di ogni score nella cella seguita (58.5°N, 8.5°E), in alto, e scarto standardizzato della velocità verticale (negativo se l'aria sale), in basso; in azzurro gli istanti in cui la cella è nel cluster. G_n resta oltre la soglia per circa un giorno e mezzo, e la distanza dal normale sale e scende con esso.

Precipitazione. Il 19 maggio 2006 il nucleo è diviso in più parti (Figura 6.14). La maggiore va dalle Alpi orientali, attraverso l'Europa centro-orientale, fino al Baltico; una seconda copre l'Inghilterra meridionale, la Manica e il Benelux; altre più piccole stanno fra le due, sulle Alpi e attorno alle Baleari. La precipitazione è sopra il normale nel 91% delle celle del nucleo, con uno scarto standardizzato mediano di 2.2, e lo scarto standardizzato supera 3 nel 28% delle celle. Dei tre esempi è il meno estremo per la distanza dal normale, che riassume tutte le variabili: nel nucleo la distanza dal normale ha un percentile mediano di 91, e il 34% dei valori ne supera la soglia, contro il 41% di tutti i valori segnalati. La cella seguita, a 56.5°N e 23°E, mostra che G_{n} e la distanza dal normale non vanno sempre insieme. La distanza dal normale vi è sopra il 90-esimo percentile fin dall'inizio della serie, tre giorni prima, mentre la precipitazione è vicina al normale e G_{n} resta sotto la soglia, pur alto: lontane dal normale sono quindi altre variabili. G_{n} supera la soglia solo la sera del 18 maggio, quando la precipitazione sale sopra il normale, e la cella fa parte del cluster per tre istanti, fino all'istante delle mappe. La stessa cella torna oltre la soglia il 21 maggio, quando il cluster è già finito, e fa quindi parte di un altro.

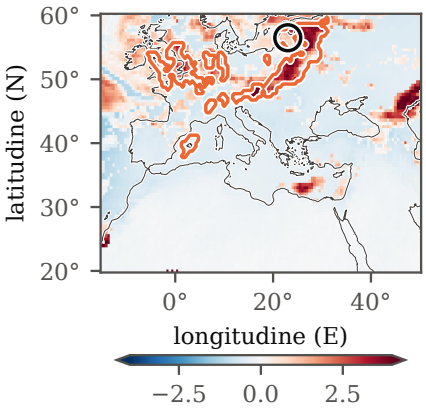


Figura 6.14a: Scarto standardizzato della precipitazione il 19 maggio 2006 alle 03 UTC, con il nucleo del cluster in arancione e la cella seguita nel cerchio. Il nucleo è diviso in più parti, in cui la precipitazione è quasi ovunque sopra il normale. Linee di costa da Natural Earth.

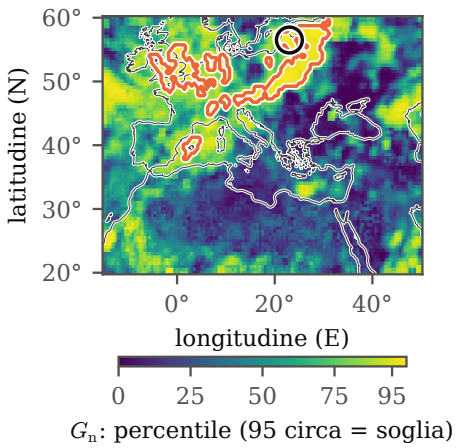


Figura 6.14b: G_n come percentile il 19 maggio 2006 alle 03 UTC, con il nucleo del cluster in arancione e la cella seguita nel cerchio. Linee di costa da Natural Earth.

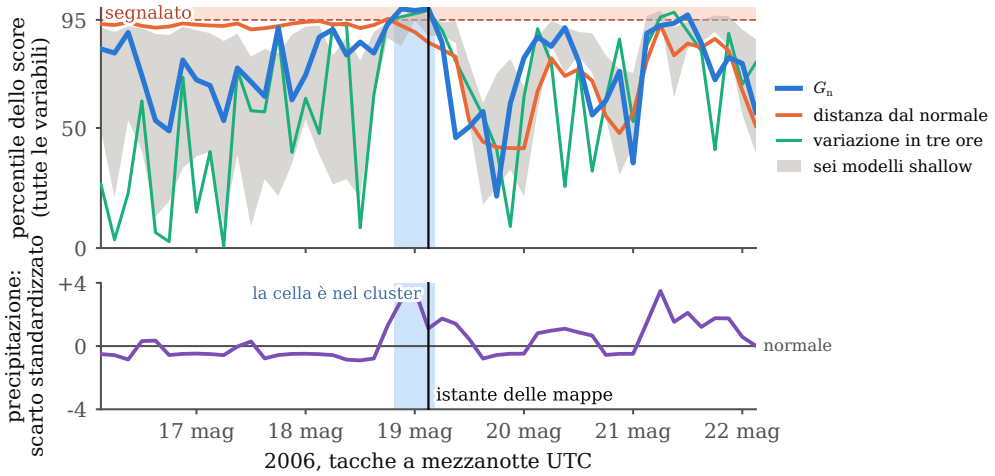


Figura 6.14c: Percentile di ogni score nella cella seguita (56.5°N, 23°E), in alto, e scarto standardizzato della precipitazione, in basso; in azzurro gli istanti in cui la cella è nel cluster. La distanza dal normale è alta già nei giorni prima; G_n supera la soglia solo con la precipitazione.

Copertura nuvolosa. Il 15 giugno 2024 il nucleo forma una fascia stretta che va dalla costa atlantica del Sahara occidentale, attraverso il Marocco e l'Algeria, fino alla costa mediterranea dell'Algeria, con una piccola parte sul mare fra le Baleari e la Sardegna (Figura 6.15). La copertura nuvolosa è sopra il normale nel 92% delle celle del nucleo, con uno scarto standardizzato mediano di 2.1, e lo scarto standardizzato supera 3 nel 19% delle celle. Il nucleo segue lo scarto standardizzato da vicino: fra i tre esempi è quello in cui la distanza dal normale cala di più dal nucleo al contorno (Tabella 6.7). Sulla stessa mappa G_{n} è alto anche altrove, soprattutto sul Mediterraneo orientale, in altri cluster. Nella cella seguita, a 23.5°N e 13°W, G_{n} supera la soglia per cinque istanti, dalle 03 alle 15 UTC del 15 giugno, gli stessi in cui la cella fa parte del cluster; lo scarto standardizzato della copertura nuvolosa vi è fra 1.9 e 3.5, e la distanza dal normale supera il 90-esimo percentile dalle 06 alle 12 UTC. Prima e dopo, G_{n} e la distanza dal normale tornano a valori tipici. Il cluster conta fra circa 200 e 400 celle per quasi due giorni, con il massimo, 404 celle, nell'istante delle mappe.

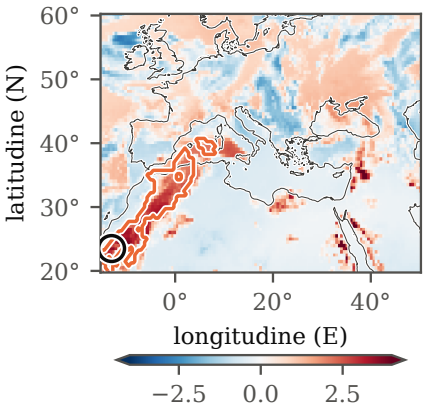


Figura 6.15a: Scarto standardizzato della copertura nuvolosa il 15 giugno 2024 alle 12 UTC, con il nucleo del cluster in arancione e la cella seguita nel cerchio. Il nucleo è una fascia stretta sull'Africa nord-occidentale in cui la copertura nuvolosa è quasi ovunque sopra il normale. Linee di costa da Natural Earth.

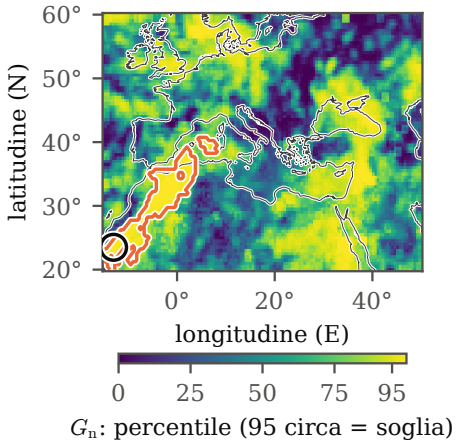


Figura 6.15b: G_n come percentile il 15 giugno 2024 alle 12 UTC, con il nucleo del cluster in arancione e la cella seguita nel cerchio. Linee di costa da Natural Earth.

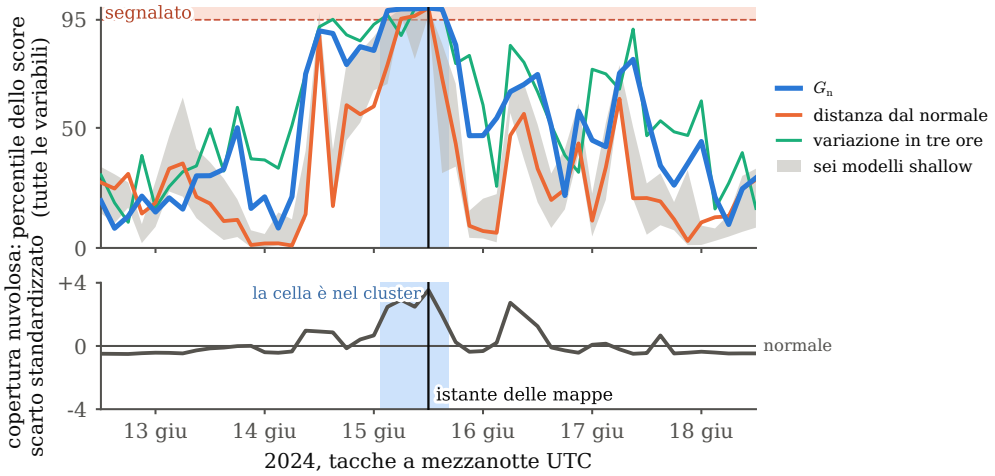


Figura 6.15c: Percentile di ogni score nella cella seguita (23.5°N, 13°W), in alto, e scarto standardizzato della copertura nuvolosa, in basso; in azzurro gli istanti in cui la cella è nel cluster. G_n e la distanza dal normale salgono e scendono insieme.

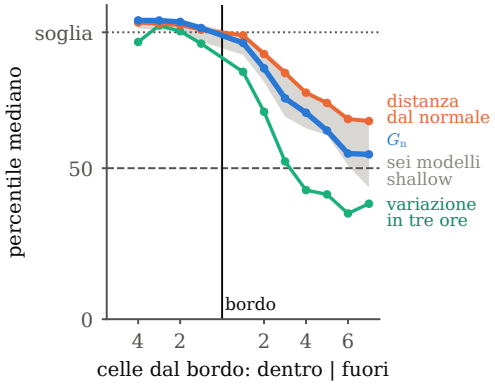


Figura 6.16a: Velocità verticale, 23 novembre 2017 alle 00 UTC: percentile mediano di ogni score secondo la distanza in celle dal bordo del cluster. G_n cala gradualmente.

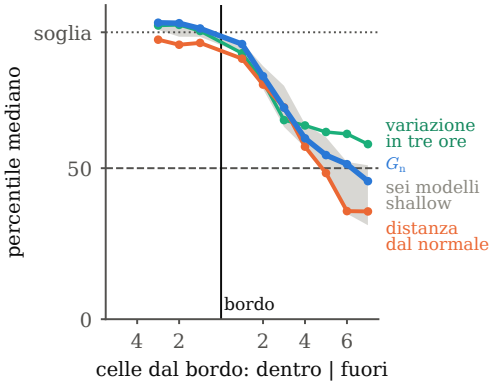


Figura 6.16b: Precipitazione, 19 maggio 2006 alle 03 UTC: percentile mediano di ogni score secondo la distanza in celle dal bordo del cluster. G_n cala gradualmente.

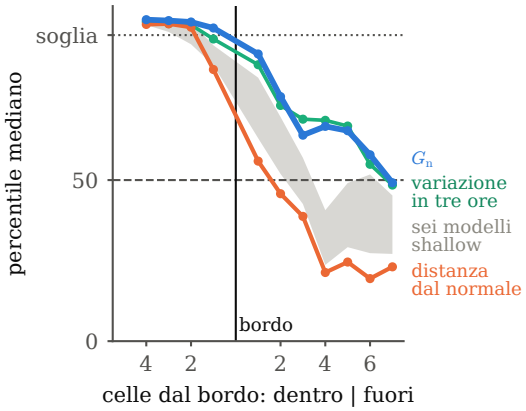


Figura 6.16c: Copertura nuvolosa, 15 giugno 2024 alle 12 UTC: percentile mediano di ogni score secondo la distanza in celle dal bordo del cluster. La distanza dal normale cala più in fretta di G_n.

Che cosa mostrano gli esempi. In due delle tre celle seguite G_{n} e la distanza dal normale salgono e scendono insieme; nella cella della precipitazione la distanza dal normale è alta già nei giorni prima, e G_{n} supera la soglia solo quando arriva la precipitazione. Il nucleo, inoltre, non contiene tutte le celle in cui la variabile del tipo è più lontana dal normale. Delle celle del dominio con uno scarto standardizzato oltre 3 in valore assoluto, nell'istante delle mappe, il nucleo ne contiene il 37% per la velocità verticale, il 62% per la precipitazione e il 57% per la copertura nuvolosa. Per la velocità verticale quasi una cella su cinque di queste sta nella zona lontana, senza alcuna segnalazione; per gli altri due tipi solo l'1%. Negli esempi si vede anche quanto mostrano i numeri aggregati: il tipo non descrive ogni cella, perché in una parte del nucleo la variabile del tipo è vicina al normale, e G_{n} segnala anche valori che, per la distanza dal normale, non sono fra i più estremi. Nei profili dei tre esempi (Figura 6.16) fuori dal bordo contano solo le celle più vicine al nucleo dell'esempio che ad altre segnalazioni. Anche lì G_{n} cala gradualmente dal nucleo verso l'esterno, come nell'insieme dei cluster (Figura 6.11); nella copertura nuvolosa la distanza dal normale cala invece molto più in fretta di G_{n} già fuori dal bordo. Sono esempi scelti con una regola, non una dimostrazione che le segnalazioni corrispondano ad anomalie meteorologiche, che senza un riferimento esterno non si può dare.

6.8 Segnalazioni concordate

Le sezioni precedenti descrivono le segnalazioni di ogni metodo prese da sole, oppure contate valore per valore. Questa sezione le legge attorno alle segnalazioni concordate della Sezione 5.5, che non sono una verità ma l'accordo dei metodi. Le misure dicono come G_{n} si colloca rispetto a ciò su cui i metodi concordano: quanta parte ne segnala, quanto aggiunge attorno, quando comincia e quando finisce, da che parte sta rispetto al moto. Come nelle sezioni precedenti si usano gli anni di test 2005–2025 e la soglia al 95-esimo percentile.

6.8.1 Il cubo e i cluster concordati

Il cubo concordato. Le segnalazioni concordate sono il 6.20% dei valori degli anni di test. Senza la chiusura sarebbero il 4.22%, la stessa percentuale del voto a maggioranza della Sezione 6.6. La chiusura aumenta le segnalazioni degli altri metodi fra il 29% (COPOD) e il 49% (HBOS), quelle di G_{n} del 31%; fa eccezione la variazione in tre ore, che cresce del 67.5% perché le sue segnalazioni hanno più lacune. Il voto decisivo di G_{n} è l'8.4% del cubo

concordato. È meno di ogni modello shallow e della distanza dal normale, fra il 9.1% (distanza dal normale) e il 15.3% (PCA), e più soltanto della variazione in tre ore, con il 7.5%: il riferimento dipende poco dal voto di G_{n}.

Pochi cluster lunghi contengono quasi tutti i valori. La Tabella 6.8 riassume i cluster concordati. I 2142 cluster lunghi, di oltre tre giorni, contengono l'85.4% dei valori concordati; i 27233 brevi l'11.9%; i cluster con meno di 20 valori, che non sono studiati, il 2.7%. Un cluster breve tipico dura 12 ore e contiene 48 valori; un cluster lungo tipico dura cinque giorni, contiene 5450 valori e tocca circa 39 righe e 59 colonne della griglia, cioè su una parte ampia del dominio. Il più lungo dura 97.8 giorni.

Tabella 6.8: I cluster concordati sugli anni di test, con la soglia di ogni metodo al 95-esimo percentile. Durata, valori, righe e colonne sono mediane sui cluster; righe e colonne sono quelle della griglia toccate dal cluster.

Cluster	Numero	Valori concordati contenuti [%]	Durata	Valori	Righe × colonne
Brevi (al più tre giorni)	27233	11.9	12 h	48	7×9
Lunghi (oltre tre giorni)	2142	85.4	5 giorni	5450	39×59
Con meno di 20 valori	419566	2.7	–	–	–

I cluster lunghi. Il tipo dei cluster lunghi, definito come nella Sezione 6.7, è la precipitazione nel 23% dei cluster e la velocità verticale nel 22%; seguono lo strato limite e la velocità d'attrito, con il 10% ciascuno, e la copertura nuvolosa, la pressione e l'umidità specifica, con il 5%. L'umidità del suolo, che cambia lentamente, è il tipo del 4.5% soltanto. I cluster lunghi non sono quindi stati che persistono nella stessa area: durano giorni, ma sono legati a variabili che cambiano in fretta. È un quadro compatibile con sistemi che si spostano sul dominio, come le perturbazioni. La durata dipende poco dalla regola di unione. Contando anche i cluster di oltre tre giorni con meno di 20 valori, i valori concordati in cluster di oltre tre giorni sono l'86.2%; chiedendo che il cluster di un istante e quello del successivo condividano almeno il 20% o il 50% dei valori, scendono all'84.7% e al 78.9%, e il cluster più lungo non cambia. Dipende invece dalla soglia: con il 99-esimo percentile i cluster lunghi contengono il 50.6% dei valori concordati (Appendice A.2).

6.8.2 Quanto ogni metodo concorda

La Tabella 6.9 riporta, per ogni metodo, la copertura, l'estensione e l'indice di Jaccard nell'intorno dei cluster concordati. Tutti i metodi concordano di più nei cluster lunghi che nei brevi.

Tabella 6.9: Copertura (cop), estensione (est) e indice di Jaccard di ogni metodo nell'intorno dei cluster concordati, brevi e lunghi: mediane sui cluster. Per i cluster brevi anche l'indice di Jaccard contro il cubo concordato senza il voto del metodo.

	Cluster brevi				Cluster lunghi		
Metodo	cop	est	Jaccard	Jaccard senza il proprio voto	cop	est	Jaccard
G_{n}	0.69	0.91	0.27	0.20	0.71	0.37	0.49
Distanza dal normale	0.64	0.06	0.45	0.38	0.75	0.14	0.62
PCA	0.97	0.32	0.69	0.51	0.95	0.17	0.81
CBLOF	0.83	0.26	0.51	0.41	0.80	0.21	0.63
MCD	0.96	0.90	0.45	0.33	0.87	0.32	0.64
HBOS	0.70	0.43	0.38	0.29	0.85	0.34	0.61
COPOD	0.67	0.13	0.44	0.36	0.82	0.20	0.65
Isolation Forest	0.87	0.34	0.54	0.41	0.90	0.25	0.71
Variazione in tre ore	0.77	1.80	0.21	0.15	0.67	0.58	0.40

Tre comportamenti. Separare copertura ed estensione distingue tre comportamenti. PCA e Isolation Forest ricalcano il cubo concordato: ne segnalano quasi tutto, con una copertura fra 0.87 e 0.97, e aggiungono poco attorno. La distanza dal normale e COPOD ne mancano una parte, con una copertura fra 0.64 e 0.82, ma non aggiungono quasi nulla, con un'estensione fra 0.06 e 0.20. La variazione in tre ore allarga il cubo concordato: nei cluster brevi segnala attorno a essi 1.8 valori per ogni valore concordato.

G_{n} nei cluster brevi allarga e manca. Nei cluster brevi l'indice di Jaccard di G_{n}, 0.27, è il più basso dopo quello della variazione in tre ore, per due motivi insieme. Il primo è l'estensione, 0.91 come quella di MCD: attorno al cluster G_{n} segnala quasi tanti valori quanti il cluster ne contiene. Il secondo è la copertura, 0.69 come quelle di HBOS, COPOD e della distanza dal normale: G_{n} manca circa un terzo del cluster, mentre MCD e PCA ne segnalano il 96–97%. Da cluster a cluster il comportamento varia molto: i quartili di G_{n} vanno da 0.34 a 0.90 per la copertura e da 0.36 a 1.80 per l'estensione. L'indice di Jaccard di G_{n} dipende dal tipo del cluster: è 0.38

nei cluster di radiazione solare, 0.34 in quelli di copertura nuvolosa e 0.32 in quelli di precipitazione, ma solo 0.16 in quelli di temperatura.

Nei cluster lunghi G_n manca una parte. Nei cluster lunghi l'estensione di G_n è ordinaria, 0.37, come quelle di HBOS e MCD. Il suo indice di Jaccard, più basso di quello della maggior parte dei metodi, viene dalla copertura, 0.71: dopo la variazione in tre ore, G_n è il metodo che segnala la parte più piccola dei cluster lunghi.

Il proprio voto non cambia il quadro. Contro il cubo concordato senza il proprio voto l'indice di Jaccard di ogni metodo scende, perché il metodo non conta più nel riferimento, ma il quadro resta lo stesso: G_n passa da 0.27 a 0.20 e resta penultimo, davanti alla variazione in tre ore; PCA resta il primo.

Che cosa manca ogni metodo. Sommando i valori di tutti i cluster, G_n segnala il 65.7% dei valori concordati dei cluster brevi e il 70.8% di quelli dei lunghi, quasi quanto la variazione in tre ore, con il 65.5% e il 63.5%; PCA ne segnala il 92.3% e il 95.0%. I metodi mancano valori di due tipi diversi. I valori concordati che G_n e la variazione in tre ore non segnalano hanno molte variabili lontane dal normale, in media 3.4–3.6 oltre due deviazioni standard, ma meno estreme: il più grande scarto standardizzato in valore assoluto è in media 3.3–3.5, contro 4.0–4.2 dei valori che segnalano. Sono anche cambiati poco: nelle tre ore prima la variazione più grande di uno scarto standardizzato è 1.7–2.2 per i valori che G_n manca, contro 3.1–3.3 per quelli che segnala. HBOS, COPOD e Isolation Forest mancano invece valori in cui una sola variabile è molto lontana dal normale: il più grande scarto standardizzato è in media 3.7–4.2, con circa due variabili oltre due deviazioni standard. PCA manca pochi valori, il 5–8%, poco estremi.

6.8.3 Inizio, fine e direzione

G_n non anticipa l'inizio dei cluster concordati. Nei cluster brevi il cluster sovrapposto di G_n comincia prima del cluster concordato nel 37.9% dei cluster, quello di MCD nel 56% e quello della variazione in tre ore nel 61%. Cluster per cluster (Tabella 6.10), MCD e la variazione in tre ore cominciano prima di G_n in circa metà dei cluster, e G_n prima di loro in meno di uno su cinque; con gli altri metodi l'inizio è vicino, e G_n comincia più spesso prima solo di COPOD e, di poco, della distanza dal normale. Nei cluster lunghi il quadro è lo stesso: MCD e la variazione in tre ore cominciano prima di G_n nel

54% e nel 58% dei cluster, G_n prima di loro nel 16% e nell'11%. Il risultato è lo stesso con la soglia al 97-esimo e al 99-esimo percentile (Appendice A.2).

Tabella 6.10: Inizio e fine di G_n rispetto a ogni baseline, cluster per cluster, sui cluster concordati brevi a cui entrambi i metodi hanno un cluster sovrapposto: percentuale dei cluster in cui G_n comincia prima e dopo la baseline, e in cui finisce dopo e prima. Le restanti percentuali sono i cluster in cui i due metodi cominciano o finiscono insieme. L'asterisco indica un test dei segni con $p < 0.01$.

	Inizio		Fine	
Baseline	G_n prima [%]	G_n dopo [%]	G_n dopo [%]	G_n prima [%]
Distanza dal normale	37	35 *	42	39 *
PCA	30	37 *	40	36 *
CBLOF	33	39 *	35	45 *
MCD	18	51 *	26	47 *
HBOS	38	38	44	37 *
COPOD	42	31 *	51	29 *
Isolation Forest	36	35	44	35 *
Variazione in tre ore	11	55 *	9	67 *

La fine. Nei cluster brevi G_n finisce dopo cinque baseline su otto e prima di CBLOF, MCD e della variazione in tre ore. Questo dipende dalla soglia: con il 97-esimo percentile G_n finisce dopo quattro baseline, con il 99-esimo prima della maggior parte (Appendice A.2). Nei cluster lunghi G_n finisce prima di sette baseline su otto, tutte tranne COPOD; a tutte le soglie finisce prima di PCA, CBLOF, MCD, della distanza dal normale e della variazione in tre ore.

Nei cluster lunghi G_n sta davanti lungo il moto. Nei cluster lunghi le segnalazioni del cluster sovrapposto di G_n stanno in mediana 16.3 km davanti al cluster concordato lungo il suo moto, e sono davanti nel 62% dei cluster. Fra le baseline solo MCD e la variazione in tre ore stanno davanti, di 8.8 e 8.7 km; le altre sei stanno dietro, fra 4.4 km (COPOD) e 13.0 km (CBLOF). Cluster per cluster, G_n sta più avanti di ciascuna baseline nel 57–65% dei cluster, sempre con $p < 0.01$. Lo spostamento lungo il moto cresce con la velocità del cluster (Figura 6.17b). È di 5.4 km nei cluster quasi fermi, sotto mezza cella ogni tre ore; di 24.1 km in quelli che si spostano di 0.5–1 celle ogni tre ore e di 33.6 km in quelli che si spostano di 1–2, cioè la distanza che il cluster percorre in un'ora o due. Nei 48 cluster più veloci è di 21.9 km, e lì

MCD sta più avanti, con 26.7 km. La posizione in avanti non viene solo dai valori lontani dal normale: le segnalazioni di G_n lontane dal normale e quelle moderate stanno davanti della stessa misura, 17.1 e 17.4 km. Si ritrova con il 97-esimo percentile (17.5 km) e, più piccolo, con il 99-esimo (9.7 km), dove G_n resta più avanti di ogni baseline nel 55–68% dei cluster.

Nei cluster brevi sta un po' dietro. Nei cluster brevi lo spostamento lungo il moto di G_n è in mediana di -4.4 km, cioè un po' dietro al cluster concordato, e cresce in valore assoluto con la velocità, fino a -14.3 km nei cluster più veloci, circa un quarto di cella (Figura 6.17a). PCA e MCD stanno sul cluster (0.0 e +0.9 km), la variazione in tre ore più dietro di G_n (-12.5 km, fino a -33.6 nei più veloci). Cluster per cluster G_n sta più indietro delle altre sette baseline nel 51–55% dei cluster e più avanti della variazione in tre ore nel 58%.

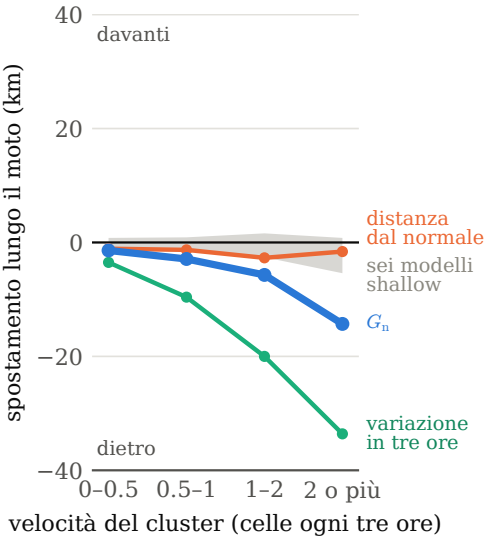


Figura 6.17a: Spostamento lungo il moto delle segnalazioni di ogni metodo rispetto ai cluster concordati brevi, secondo la velocità del cluster: mediana sui cluster, positiva davanti al cluster; la fascia grigia va dal più basso al più alto dei sei modelli shallow. G_n sta un po' dietro, di più nei cluster veloci.

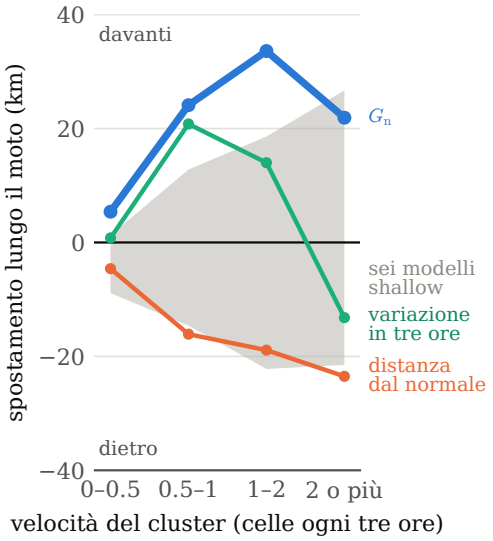


Figura 6.17b: Spostamento lungo il moto delle segnalazioni di ogni metodo rispetto ai cluster concordati lunghi, secondo la velocità del cluster: mediana sui cluster, positiva davanti al cluster; la fascia grigia va dal più basso al più alto dei sei modelli shallow. G_n sta davanti, più delle baseline tranne che nei 48 cluster più veloci.

Lettura. I cluster brevi e quelli lunghi danno due quadri diversi. Nei brevi G_{n} allarga il cluster concordato e ne manca una parte, segue il cubo concordato da un po' dietro e non comincia prima. Nei lunghi, che contengono quasi tutti i valori concordati, G_{n} non comincia prima né finisce dopo, ma mentre il cluster è in moto segnala di più dalla parte verso cui va: rispetto al cubo concordato, formato soprattutto da metodi che leggono una cella in un istante, G_{n} segnala di più le celle che il sistema sta per raggiungere. Lo spostamento lungo il moto è piccolo, una frazione di cella; e la direzione del moto è quella media fra il primo e l'ultimo istante, grossolana per sistemi che in cinque giorni cambiano direzione.

6.8.4 Che cosa c'è attorno ai cluster

Questa sottosezione guarda le segnalazioni non concordate di ogni metodo nell'intorno dei cluster concordati: quanto i valori sono lontani dal normale nell'istante del valore, come cambiano nelle ore dopo e quanto sono cambiati nelle tre ore prima (Tabella 6.11). Il termine di confronto sono i valori degli stessi intorni, nelle stesse posizioni, che nessun metodo segnala.

Tabella 6.11: Le segnalazioni non concordate di ogni metodo davanti e dietro i cluster concordati, sugli anni di test, e il termine di confronto. Oltre 2: percentuale di valori con almeno una variabile d'ingresso oltre due deviazioni standard. Scarto standardizzato dietro: il più grande in valore assoluto, in media, dietro i cluster brevi, nell'istante del valore e 24 ore dopo. Variazione in 3 h: la variazione più grande di uno scarto standardizzato nelle tre ore prima del valore, in media, nei cluster brevi, per i valori lontani dal normale e per quelli moderati.

	Oltre 2 [%]		Scarto stand. dietro		Variazione in 3 h	
Metodo	Brevi	Lunghi	0 h	24 h	Lontani	Moderati
G_{n}	74.1	77.5	2.44	1.90	2.80	2.77
Distanza dal normale	95.1	94.9	2.79	2.48	1.43	1.41
PCA	96.2	96.1	3.27	2.21	1.92	2.45
CBLOF	89.6	89.7	2.74	2.21	1.62	1.67
MCD	90.9	90.5	2.93	2.04	2.23	2.27
HBOS	94.1	95.0	2.66	2.03	1.58	1.68
COPOD	92.0	93.4	2.60	1.94	1.66	1.73
Isolation Forest	96.2	95.9	2.74	2.01	1.68	1.92
Variazione in tre ore	65.3	69.9	2.31	1.89	2.85	2.69
Termine di confronto	32.8	35.5	1.83	1.81	1.37	1.22

Le segnalazioni non concordate dei metodi che leggono una cella sono lontane dal normale. Per i sette metodi che leggono una cella in un istante, fra il 90% e il 96% delle segnalazioni non concordate davanti e dietro i cluster ha almeno una variabile oltre due deviazioni standard, contro il 33–36% del termine di confronto: sono valori lontani dal normale, che restano fuori dal cubo concordato solo perché meno di cinque metodi li segnalano. Per G_{n} la percentuale è il 74% nei cluster brevi e il 78% nei lunghi, per la variazione in tre ore il 65% e il 70%: una parte delle loro segnalazioni non concordate non è lontana dal normale.

Le segnalazioni non concordate di G_{n} sono cambiate in fretta. Nelle tre ore prima del valore la variazione più grande di uno scarto standardizzato è in media 2.7–2.8 per le segnalazioni non concordate di G_{n}, lontane dal normale o moderate, quanto per la variazione in tre ore e circa il doppio del termine di confronto, 1.2–1.4. Per MCD è 2.1–2.3, per la distanza dal normale 1.4, come per il termine di confronto. Anche dove nessuna variabile è lontana dal normale, dunque, ciò che G_{n} segnala fuori dal cubo concordato è un cambiamento rapido; vale anche per le sue segnalazioni esclusive moderate, che la variazione in tre ore non segnala, con 1.7–1.8. In parte è atteso: G_{n} è l'errore della ricostruzione di un istante dagli istanti precedenti, e un salto nelle ultime tre ore è difficile da ricostruire.

Dietro e dopo i cluster brevi, le segnalazioni di G_{n} rientrano in poche ore. Dietro i cluster brevi il più grande scarto standardizzato delle segnalazioni non concordate di G_{n} scende da 2.44 nell'istante del valore a 2.06 sei ore dopo e a 1.94 dopo dodici ore, vicino al termine di confronto, 1.81–1.83; dopo la fine del cluster scende da 2.20 a 1.85 in sei ore, contro 1.67–1.73 del termine di confronto. La variazione in tre ore fa lo stesso. Le segnalazioni degli altri metodi restano più a lungo sopra il termine di confronto: dopo 24 ore sono fra 1.94 e 2.21 dietro il cluster e fra 1.99 e 2.81 dopo la sua fine; quelle della distanza dal normale restano le più lontane, con 2.48 e 2.67. I metodi che leggono una cella in un istante segnalano quindi soprattutto stati che durano, G_{n} e la variazione in tre ore cambiamenti che rientrano in poche ore.

Davanti ai cluster lunghi lo scarto standardizzato resta alto. Davanti ai cluster lunghi il più grande scarto standardizzato delle segnalazioni non concordate di G_{n} resta alto per un giorno, da 2.54 a 2.41 dopo 24 ore, mentre quello del termine di confronto sale da 1.85 a 2.30: il cluster arriva in quelle celle. Dietro scende da 2.51 a 2.21.

6.8.5 Probabilità di superamento

La maggior parte delle segnalazioni ha una probabilità alta. Il 68.7% delle segnalazioni di G_{n} ha una probabilità di superamento di almeno 0.9: in queste segnalazioni quasi ogni estrazione supera la soglia. La percentuale scende in modo regolare con il livello: 93.1% con almeno 0.6, 86.1% con 0.7, 78.4% con 0.8 e 61.4% con 0.95.

Tabella 6.12: Le segnalazioni di G_{n} con probabilità di superamento almeno pari al livello, confrontate cluster per cluster con il loro controllo, lo stesso numero di segnalazioni di G_{n} estratte a caso, sui cluster concordati brevi e lunghi degli anni di test. Per ogni livello: la percentuale di segnalazioni tenute e, in percentuale dei cluster, quelli in cui le segnalazioni del livello cominciano prima / dopo il controllo (Inizio), finiscono dopo / prima (Fine) e stanno più avanti / più indietro lungo il moto (Moto). Le restanti percentuali sono i cluster in cui non differiscono. L'asterisco indica un test dei segni con $p < 0.01$.

		Cluster brevi			Cluster lunghi		
Livello	Tenute [%]	Inizio [%]	Fine [%]	Moto [%]	Inizio [%]	Fine [%]	Moto [%]
0.6	93.1	5/23 *	5/25 *	51/48 *	4/27 *	5/29 *	48/52
0.7	86.1	5/26 *	5/29 *	52/48 *	5/30 *	5/35 *	49/51
0.8	78.4	5/29 *	4/34 *	53/47 *	4/33 *	4/42 *	50/50
0.9	68.7	5/32 *	5/39 *	54/46 *	4/38 *	4/49 *	52/48
0.95	61.4	6/32 *	5/42 *	54/46 *	6/39 *	4/54 *	54/46 *

Le segnalazioni incerte stanno all'inizio, alla fine e dietro. A ogni livello, nei cluster brevi e nei lunghi, le segnalazioni con probabilità alta cominciano più tardi e finiscono prima del loro controllo (Tabella 6.12). Nei cluster brevi stanno anche meno dietro lungo il moto: con probabilità di almeno 0.9 lo spostamento lungo il moto mediano è di -0.8 km, contro -3.9 km del controllo. Il cluster sovrapposto di G_{n} comincia prima del cluster concordato in 9670 dei 25512 cluster brevi in cui esiste. In questi cluster il 34.4% delle segnalazioni prima dell'inizio ha probabilità di almeno 0.9, contro il 52.0% di tutte le segnalazioni di G_{n} nell'intorno; la probabilità mediana è 0.69 contro 0.90. Nei cluster lunghi le due percentuali sono 36.2% e 53.7%. Le segnalazioni incerte stanno quindi all'inizio, alla fine e dalla parte da cui il cluster si allontana; quelle con probabilità alta occupano il corpo del cluster.

La posizione in avanti non dipende dalla probabilità. Nei cluster lunghi le segnalazioni con probabilità alta non stanno più avanti del loro controllo, salvo di poco al livello più alto, 0.95, dove stanno più avanti nel 54% dei cluster e più indietro nel 46%: la posizione in avanti di G_{n} nei sistemi che si spostano non viene dalle segnalazioni incerte.

6.9 La dispersione del dropout

Quanto le segnalazioni di G_{n} reggono alle maschere di dropout è descritto nella Sezione 6.8.5, con la probabilità di superamento; questa sezione guarda in generale quanto le estrazioni differiscono fra loro. La dispersione delle 20 estrazioni (Sezione 4.6) non è una probabilità di anomalia: senza etichette non si può stabilire se una segnalazione con estrazioni concordi sia più giusta di una con estrazioni discordi. Si può però vedere dove le estrazioni si separano. Poiché la dispersione cresce con G, con una correlazione di Spearman di 0.86, conviene leggerla in proporzione, con il rapporto della Sezione 5.3.1. La sezione riguarda gli anni di test.

Pochi valori non segnalati arrivano alla soglia. Dei valori che G_{n} non segnala, solo l'1.8% supererebbe la soglia aggiungendo a G_{n} una volta la dispersione s della Sezione 5.5.

In proporzione, la dispersione cala solo sui valori di G più alti. In valore assoluto la dispersione cresce con G, ma in proporzione resta quasi costante (Figura 6.18a): in ogni fascia di G, la dispersione media divisa per G medio è fra l'11.1% e l'11.8% fino al 99-esimo percentile di G, e scende solo oltre, al 9.7% fra il 99-esimo e il 99.9-esimo percentile e al 9.1% nello 0.1% più alto. Le maschere di dropout incidono quindi su G in proporzione quasi uguale, tranne sui valori più alti, su cui incidono un po' meno.

Attraverso i cluster il rapporto è minimo poco dentro il bordo. La dispersione assoluta ha quasi lo stesso profilo di G_{n}: il percentile mediano è 94 appena dentro il bordo del cluster e 49 dopo sei celle, contro 96 e 50 di G_{n}. Il rapporto mediano è invece quasi costante (Figura 6.18b): circa il 10% in tutte le celle fuori dal cluster, con un minimo del 9.6% due celle dentro il nucleo e una risalita all'11.2% nelle pochissime celle più interne. Le differenze ci sono ma sono piccole; il motivo della risalita nelle celle più interne non è verificato. La mediana sta un po' sotto le medie della Figura 6.18a e delle mappe più avanti, che sono intorno all'11%.

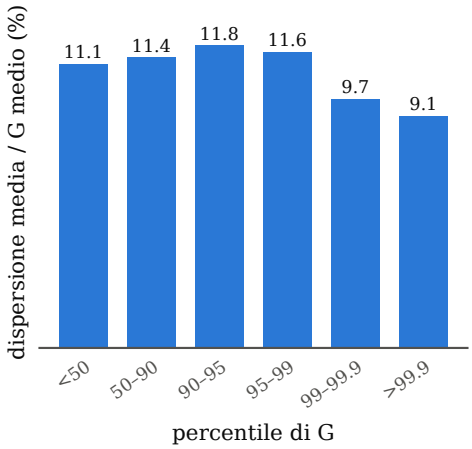


Figura 6.18a: Dispersione media divisa per G medio, per fascia di percentile di G, sugli anni di test. In proporzione a G la dispersione è quasi costante, e cala solo sui valori di G più alti.

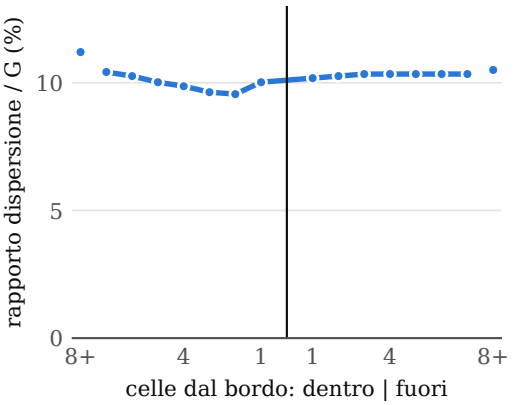


Figura 6.18b: Mediana del rapporto fra dispersione e G secondo la distanza in celle dal bordo del cluster di G_{n}, sugli anni di test. Il rapporto è quasi costante, con un minimo poco dentro il bordo.

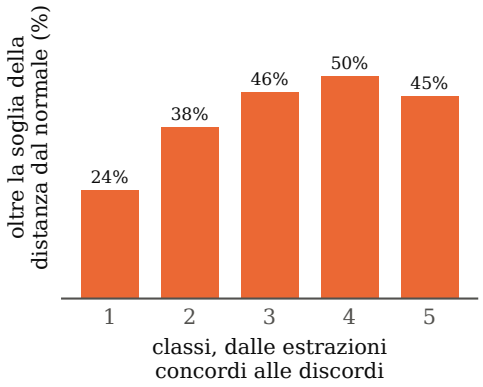


Figura 6.18c: Valori segnalati da G_{n} divisi a parità di G in cinque classi, dalle estrazioni più concordi (1) alle più discordi (5), e percentuale di ciascuna classe oltre la soglia della distanza dal normale. Anni di test. Fino alla classe 4, più dispersione va con dati più lontani dal normale.

A parità di G, più dispersione va con dati più lontani dal normale, ma non nella classe più discorde. Per confrontare valori con lo stesso G, i valori segnalati sono divisi nelle classi del rapporto (Sezione 5.3.1): la classe 1, con le estrazioni più concordi, ha un rapporto mediano del 5%, la classe 5, con le più discordi, del 19% (Figura 6.18c). Dalla classe 1 alla 4 la percentuale di valori oltre la soglia della distanza dal normale sale dal 24% al 50%; nella classe 5 scende al 45%. Il risultato è quasi uguale a parità di G_{n}. Fino alla classe 4, dunque, le estrazioni si separano di più dove i dati sono più lontani dal normale, coerentemente con l'idea che il modello sia meno stabile sui dati più diversi da quelli dell'addestramento; la classe più discorde non segue l'andamento, e il motivo non è verificato.

Per tipo di cluster il quadro è simile. Con gli stessi tipi della Sezione 6.7, il rapporto è quasi ovunque più basso poco dentro il nucleo e sale verso l'esterno, con l'eccezione dell'umidità del suolo, in cui scende verso l'esterno. A parità di G, in ogni tipo la classe 1 ha la percentuale più bassa di valori oltre la soglia della distanza dal normale e la più alta è la classe 3 o 4; per la velocità verticale, per esempio, la percentuale va dal 20% della classe 1 al 45% della 4 e scende al 40% nella 5. La classe 5 raggiunge la 4 solo nella precipitazione e nell'umidità del suolo.

La dispersione cella per cella. La Figura 6.19 mostra la dispersione di G in ogni cella. In media sugli anni di test è più alta a sud, dove è più alto anche G: circa il 23% in più fra 20° e 30°N che fra 50° e 60°N. Il rapporto medio invece varia poco, fra l'11.0% e l'11.4% da una fascia all'altra. Lungo il margine del dominio si vede una cornice, con una dispersione in media 1.8 volte quella delle celle interne, probabilmente un effetto del modello simile a quello della Sezione 6.2. Negli istanti dei tre esempi della Sezione 6.7.1 la dispersione nel nucleo è in mediana da 3.4 a 5 volte quella fuori dal nucleo, la più alta nella copertura nuvolosa; in proporzione a G, invece, il rapporto mediano nel nucleo resta vicino a quello di fuori, fra l'8% e il 13% contro il 10–11% fuori dal nucleo.

Sintesi. In proporzione a G la dispersione è quasi costante, attraverso i cluster e in quasi tutti i tipi di cluster. A parità di G le estrazioni concordano di meno dove i dati sono più lontani dal normale, fino alla classe 4. Questo descrive il comportamento del modello e non rende una segnalazione più o meno affidabile.

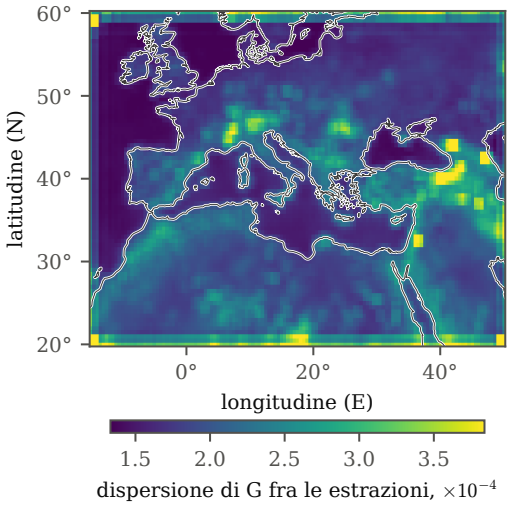


Figura 6.19a: Dispersione di G fra le 20 estrazioni in ogni cella, in media sugli anni di test. È più alta a sud e lungo il margine del dominio. Linee di costa da Natural Earth.

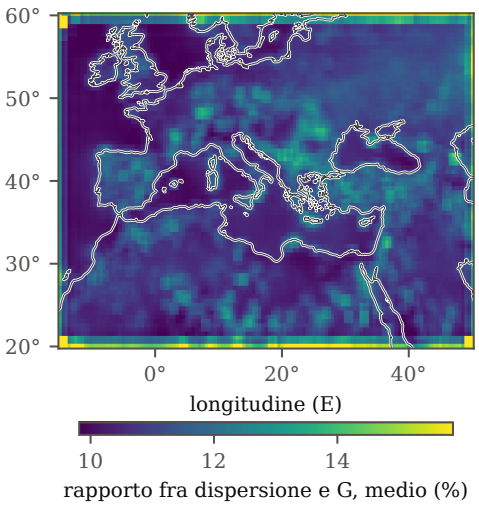


Figura 6.19b: Rapporto medio fra dispersione e G in ogni cella, sugli anni di test. Varia poco nel dominio. Linee di costa da Natural Earth.

6.10 Variabili che nessuno score legge

Le sezioni precedenti descrivono le segnalazioni con le variabili d'ingresso, cioè con ciò che i metodi leggono. Questa sezione le guarda, in via preliminare, con le otto grandezze di ERA5 che nessuno score legge (Sezione 5.5): per ogni grandezza si conta la percentuale di valori in cui è insolita, cioè nel suo 5% più estremo per quella cella, quel mese e quell'ora. Per caso la percentuale sarebbe il 5%. Le grandezze non sono state scelte per un tipo di anomalia, e un valore insolito non è di per sé un'anomalia meteorologica: la sezione descrive che cosa accompagna le segnalazioni, non le convalida.

Ogni metodo ha un tratto suo. Attorno ai cluster lunghi (Tabella 6.13) le segnalazioni non concordate di G_n hanno CAPE, indice K e vapore acqueo nella colonna insoliti nel 10.2%, nel 14.5% e nel 15.0% dei valori, contro il 4.2%, il 4.2% e il 4.8% del termine di confronto: per tutte e tre G_n ha la percentuale più alta dei nove metodi. Anche la precipitazione convettiva è insolita più spesso, nel 11.2% contro il 3.1%; qui la percentuale più alta è quella di MCD, 14.0%. MCD e la variazione in tre ore hanno un tratto simile a quello di G_n. Le code fredde e secche vanno invece nel senso opposto: la temperatura di rugiada bassa e la temperatura minima bassa sono insolite nel 3.1% e nel 3.5% delle segnalazioni di G_n, meno che nel termine di confronto. PCA,

Tabella 6.13: Percentuale di valori in cui ciascuna grandezza che nessuno score legge è insolita, per le segnalazioni non concordate di ogni metodo davanti e dietro i cluster concordati lunghi, sugli anni di test, e per il termine di confronto. Per caso la percentuale sarebbe il 5%. Rugiada e temperature sono a due metri, la raffica a dieci metri; alta e bassa indicano la coda del 5% più estremo.

Metodo	CAPE [%]	Raffica [%]	Prec. conv. [%]	Rug. alta [%]	Rug. bassa [%]	Indice K [%]	Min. bassa [%]	Mass. alta [%]	Vapore colonna [%]
G_n	10.2	7.2	11.2	10.1	3.1	14.5	3.5	9.4	15.0
Distanza dal normale	6.5	4.8	4.3	10.0	10.5	6.6	11.5	15.4	6.9
PCA	6.6	17.8	6.5	7.6	11.1	7.8	10.0	11.0	8.7
CBLOF	7.1	6.7	6.7	10.4	6.3	7.8	9.2	9.6	8.5
MCD	8.8	7.0	14.0	8.7	4.1	13.8	5.4	7.1	14.5
HBOS	6.8	20.8	5.8	9.0	9.5	8.1	9.7	13.7	9.6
COPOD	7.7	24.9	8.8	9.1	7.0	9.1	10.0	9.2	11.2
Isolation Forest	6.8	23.2	7.0	9.1	8.3	9.2	8.1	12.5	11.3
Variazione in tre ore	9.0	6.6	9.6	8.4	3.5	11.4	3.8	7.9	11.9
Termine di confronto	4.2	3.9	3.1	5.1	5.4	4.2	5.2	5.1	4.8

HBOS, COPOD e Isolation Forest segnalano soprattutto raffiche insolite, fra il 17.8% e il 24.9%, contro il 7.2% di G_n; la distanza dal normale segnala soprattutto temperature estreme, con la massima alta nel 15.4% e la minima bassa nell'11.5%.

Le segnalazioni esclusive di G_n hanno lo stesso tratto. Davanti e dietro i cluster lunghi, le segnalazioni che solo G_n fa hanno CAPE insolito nel 8.1–8.8%, indice K nell'11.7–13.0% e vapore nella colonna nel 12.3–14.1% dei valori, sopra il termine di confronto in tutti i 20 anni; temperatura di rugiada bassa e temperatura minima bassa sono sotto il termine di confronto in tutti i 20 anni.

Dentro i cluster G_n manca la parte fredda e secca. Dentro i cluster concordati lunghi, i valori concordati che G_n segnala hanno CAPE, precipitazione convettiva, indice K e vapore nella colonna insoliti circa due volte più spesso di quelli che manca: il CAPE nel 14.1–15.3% contro il 7.7–8.2%, l'indice K nel 20.6–22.9% contro l'8.0–9.9%. I valori che manca hanno invece più spesso la temperatura minima bassa, nel 12.2–16.9% contro il 6.0–9.3%, la temperatura di rugiada bassa, nel 10.8–12.0% contro il 4.2–4.9%, e la raffica

insolita, nel 27.6–32.7% contro il 23.2–24.8%. Insieme alla Sezione 6.8.2, dove gli stessi valori risultano cambiati poco nelle tre ore prima, questo indica che dentro i cluster G_{n} segnala la parte umida e instabile che cambia in fretta e manca la parte fredda, secca e ventosa che cambia lentamente.

Nei cluster brevi i segni sono gli stessi, ma deboli. Attorno ai cluster brevi CAPE, precipitazione convettiva, indice K e vapore nella colonna sono insoliti nel 6.1–7.0% delle segnalazioni non concordate di G_{n}, contro il 4.7–5.2% del termine di confronto. Anche qui COPOD segnala soprattutto raffiche, nel 18.3% dei valori.

Sintesi. Insieme alle Sezioni 6.8.2 e 6.8.4, questi risultati indicano che G_{n} è complementare ai metodi più semplici. Questi riconoscono soprattutto gli stati lontani dal normale che durano; G_{n} riconosce i cambiamenti rapidi, in particolare la parte umida e instabile dei sistemi che si spostano, che nei cluster lunghi segnala anche un po' più avanti lungo il moto (Sezione 6.8.3), e manca le condizioni fredde e secche che persistono. La verifica con le grandezze che nessuno score legge resta preliminare.

Capitolo 7

Conclusioni e sviluppi futuri

7.1 Il problema affrontato

7.2 Sintesi dei risultati

7.3 Sviluppi futuri

Il primo sviluppo è ripetere la configurazione scelta con più semi, per avere un riferimento con cui leggere le differenze fra configurazioni.

Il secondo riguarda il protocollo: aggiornare periodicamente soglie e normalizzazione climatologica su una finestra di anni recenti, invece di tenerle fisse a quelle degli anni di validazione, ridurrebbe l'effetto della deriva del clima sulla percentuale di valori segnalati.

Il terzo riguarda la valutazione. Un catalogo esterno di anomalie su tutto il dominio, o anomalie artificiali inserite in posizioni note, darebbe una misura del richiamo, che in questa tesi manca.

Il quarto riguarda l'incertezza dello score. La Sezione 6.9 descrive come la dispersione varia con G; resta da verificare, con un riferimento esterno, se può essere usata come misura di incertezza. I metodi basati su equazioni differenziali stocastiche (Sezione 2.4) potrebbero inoltre essere applicati al rilevatore: richiedono di aggiungere a STGAN una rete di diffusione, una modifica che questa tesi ha evitato per restare vicina all'architettura dell'articolo.

Ritorno alla previsione fotovoltaica. Il lavoro è partito dalla previsione della produzione fotovoltaica sui dati PVGIS, ed è passato ai campi ERA5 perché quei dati non permettevano di riconoscere anomalie meteorologiche di tipo generale. Il rilevatore può ora essere riportato a quel problema in più modi. Il primo passo è allineare i due insiemi di dati: le località PVGIS, su un reticolo

di 5 km, ricadono in poche decine di celle ERA5 di 0.5°, e lo score, calcolato ogni tre ore, va riportato alle ore del previsore. Con questo allineamento le segnalazioni del rilevatore possono servire a valutare il previsore separatamente sui valori non segnalati e su quelli segnalati, misurando se l'errore del previsore cresce quando il rilevatore segnala. Possono servire poi all'addestramento, per escludere dall'addestramento gli istanti segnalati, secondo il protocollo di SDE U-Net, oppure per dare loro un peso diverso. Lo score può infine entrare nel previsore come ingresso aggiuntivo, oppure regolare l'incertezza delle sue previsioni, aumentandola quando lo score è alto. In ciascun caso la verifica più diretta sarebbe sulle misure di impianti reali, dove disponibili.

Appendice A

Sensibilità alla soglia

Nel Capitolo 6 un valore è segnalato quando lo score supera il 95-esimo percentile dei propri valori sugli anni di validazione. È una scelta convenzionale, non ottimizzata. Questa appendice verifica quanto i risultati dipendono dalla soglia: la Sezione A.1 ripete le analisi principali con il 99-esimo percentile, la Sezione A.2 ricostruisce le segnalazioni concordate con il 97-esimo e il 99-esimo, e la Sezione A.3 varia la soglia di ogni metodo con il cubo concordato fisso.

A.1 Le analisi principali con il 99-esimo percentile

Questa sezione ripete le analisi principali delle Sezioni 6.3–6.7 con il 99-esimo percentile, cioè segnalando l'1% dei valori degli anni di validazione, per verificare quanto le conclusioni dipendano dalla soglia (Tabella A.1). Le correlazioni fra G e D della Sezione 6.2 usano tutti i valori e non dipendono dalla soglia, e non sono ripetute; non è ripetuta nemmeno l'analisi del dropout.

La normalizzazione climatologica nella coda. Con la soglia più alta la normalizzazione climatologica riduce ancora molto le differenze fra luoghi e stagioni, ma non le annulla: resta un eccesso di segnalazioni a sud, dove la percentuale media è circa il doppio di quella a nord: 1.4% fra 20° e 30°N contro 0.7% fra 50° e 60°N, con l'1% atteso. La normalizzazione climatologica allinea media e deviazione standard di G in ogni cella, non la frequenza dei suoi valori più estremi; con il 5% questa differenza si vede appena, con l'1% sì.

Tabella A.1: Le analisi principali con la soglia al 95-esimo e al 99-esimo percentile degli score sugli anni di validazione: percentuali per luogo e zone sugli anni di validazione, confronti e cluster sugli anni di test. La differenza relativa è quella della Sezione 5.3.1.

Analisi	Misura	95-esimo	99-esimo
Percentuale per fascia di latitudine e mese (Sez. 6.3)	G senza normalizzazione climatologica, intervallo fra fasce e mesi	1.6–11.1%	0.2–3.6%
	G_{n}, intervallo	3.7–6.3%	0.5–2.1%
	differenza relativa, G $\rightarrow$ G_{n}	0.39 $\rightarrow$ 0.11	0.70 $\rightarrow$ 0.28
Zone dei cluster (Sez. 6.4)	cluster di G_{n}	184877	70954
	D_{reale} nel nucleo, percentile mediano	5	1
	D_{reale} nel contorno, percentile mediano	12	4
	D nel nucleo, percentile mediano	27	2
Confronti (Sez. 6.6)	segnalazioni di G_{n} condivise con la variazione in tre ore	53.9%	46.4%
	condivise con MCD	52.1%	45.8%
	condivise con HBOS	39.2%	24.3%
	segnalazioni esclusive di G_{n}	18.1%	27.4%
	valori segnalati da almeno 5 metodi su 9	4.22%	0.72%
Cluster (Sez. 6.7)	valori nei cluster con almeno 20 valori	93%	85%
	durata dei cluster più grandi dei tre tipi principali	23–40 giorni	8–24 giorni

Il comportamento del discriminatore. Con la soglia più alta i cluster sono meno della metà, e il comportamento del discriminatore è lo stesso e più marcato. Nel nucleo D_{reale} scende dal percentile 5 all'1 e D dal 27 al 2. Anche nel contorno D_{reale} scende, da 12 a 4: con la soglia più alta i cluster sono più estremi, e anche le celle vicine sono fra i valori più alti di G_{n}.

Cluster e catene. Con la soglia più alta le catene si accorciano ma restano: i cluster più grandi dei tre tipi con più valori durano fra 8 e 24 giorni, contro 23–40 giorni con il 5%, e i cluster con almeno 20 valori contengono ancora l'85% dei valori segnalati, contro il 93% con il 5%. I tre tipi con più valori nei cluster di almeno 20 valori restano velocità verticale, precipitazione e copertura nuvolosa, ma la precipitazione passa al primo posto.

Confronti con le baseline. Con la soglia più alta il quadro resta lo stesso, con un accordo più basso. La variazione in tre ore e MCD restano i metodi più vicini a G_{n}, con il 46% delle sue segnalazioni condivise; il metodo più lontano resta HBOS. I valori segnalati da almeno cinque metodi su nove sono lo 0.72%: il calo è in gran parte automatico, perché ogni metodo segnala circa cinque volte meno. L'accordo resta molto sopra quello atteso per caso: con l'1% due metodi indipendenti condividerebbero circa l'1% delle segnalazioni, mentre G_{n} ne condivide il 46% con la variazione in tre ore.

Sintesi. Le conclusioni sul discriminatore non dipendono dalla soglia, e con una soglia più alta diventano più nette. Anche il quadro del confronto con le baseline non cambia, con un accordo più basso e una percentuale più alta di segnalazioni esclusive di G_{n}. Le catene si accorciano, ma restano. L'effetto della normalizzazione climatologica dipende invece dalla soglia: la normalizzazione climatologica riduce le differenze fra luoghi e stagioni di circa tre quarti con il 5% e di circa tre quinti con l'1%.

A.2 Le segnalazioni concordate con il 97-esimo e il 99-esimo percentile

Le segnalazioni concordate della Sezione 6.8 sono ricostruite, con le stesse regole, con la soglia di ogni metodo al 97-esimo e al 99-esimo percentile degli score sugli anni di validazione, cioè segnalando il 3% e l'1% dei valori; sono ripetuti anche l'inizio, la fine e lo spostamento lungo il moto della Sezione 6.8.3 (Tabella A.2). La sovrapposizione, la probabilità di superamento e ciò che c'è attorno ai cluster non sono ripetuti.

Tabella A.2: Le segnalazioni concordate con la soglia di ogni metodo al 95-esimo, 97-esimo e 99-esimo percentile degli score sugli anni di validazione, sugli anni di test. Lo spostamento lungo il moto è positivo quando le segnalazioni stanno davanti al cluster concordato. "Più avanti della baseline" riporta l'intervallo fra le otto baseline.

Misura	95-esimo	97-esimo	99-esimo
Cubo e cluster concordati			
Valori concordati [%]	6.20	3.54	1.05
Valori concordati senza la chiusura [%]	4.22	2.41	0.72
Voto decisivo di G_{n} [% del cubo]	8.4	9.2	11.5
Voto decisivo di PCA [% del cubo]	15.3	17.3	21.5
Cluster brevi	27233	25392	16549
Cluster lunghi	2142	1850	785
Valori concordati nei cluster lunghi [%]	85.4	74.5	50.6
Durata del cluster più lungo [giorni]	97.8	97.4	40.5
G_{n} *nei cluster brevi*			
Spostamento lungo il moto, mediana [km]	−4.4	−3.9	−2.8
Cluster con G_{n} davanti [%]	46	46	47
Inizio: G_{n} prima / dopo MCD [%]	18 / 51	16 / 50	14 / 48
G_{n} *nei cluster lunghi*			
Spostamento lungo il moto, mediana [km]	16.3	17.5	9.7
Cluster con G_{n} davanti [%]	62	64	61
Cluster con G_{n} più avanti della baseline [%]	57–65	56–67	55–68
Spostamento lungo il moto di MCD, mediana [km]	8.8	9.0	1.5
Inizio: G_{n} prima / dopo MCD [%]	16 / 54	14 / 56	8 / 59

Il cubo segue la soglia. Con soglie più alte il cubo concordato si riduce insieme alle segnalazioni di ogni metodo, dal 6.20% dei valori al 3.54% e all'1.05%. Il voto decisivo di G_{n} cresce, dall'8.4% all'11.5% del cubo, ma resta molto più basso di quello di PCA, che passa dal 15.3% al 21.5%: a ogni soglia il riferimento dipende poco dal voto di G_{n}.

La durata dei cluster lunghi dipende dalla soglia. I cluster lunghi contengono l'85.4% dei valori concordati con il 95-esimo percentile, il 74.5% con il 97-esimo e il 50.6% con il 99-esimo; il cluster più lungo passa da 97.8 a 40.5 giorni. Con soglie più alte le catene si accorciano: la durata dei cluster lunghi dipende in parte dalla soglia, non solo dai sistemi che li formano.

L'inizio. A ogni soglia G_{n} non anticipa l'inizio dei cluster concordati. MCD comincia prima di G_{n} in circa metà dei cluster brevi e in più della metà dei lunghi; G_{n} comincia prima di MCD in meno di un cluster su cinque.

Lo spostamento lungo il moto. Nei cluster lunghi G_{n} sta davanti a ogni soglia, di 16.3, 17.5 e 9.7 km in mediana, e sta più avanti di ciascuna baseline nel 55–68% dei cluster. Con il 99-esimo percentile lo spostamento lungo il moto è più piccolo, anche per MCD, e i sistemi veloci sono pochi: solo 7 cluster si spostano di almeno due celle ogni tre ore. Nei cluster brevi G_{n} resta a ogni soglia leggermente dietro, di 2.8–4.4 km.

La fine. La fine è il risultato che dipende di più dalla soglia. Nei cluster brevi, con il 95-esimo percentile G_{n} finisce dopo cinque baseline su otto; con il 97-esimo dopo quattro, HBOS, COPOD, Isolation Forest e la distanza dal normale, prima di tre e senza differenza significativa con PCA; con il 99-esimo prima di PCA, CBLOF, MCD e della variazione in tre ore, dopo COPOD e senza differenza significativa con HBOS e con la distanza dal normale. Nei cluster lunghi G_{n} finisce prima di sette baseline su otto con il 95-esimo percentile, di sei con il 97-esimo e di cinque con il 99-esimo; a ogni soglia finisce prima di PCA, CBLOF, MCD, della distanza dal normale e della variazione in tre ore.

Sintesi. Tre risultati della Sezione 6.8 non dipendono dalla soglia: G_{n} non anticipa l'inizio dei cluster concordati, nei cluster lunghi sta davanti lungo il moto più di ogni baseline, nei brevi sta leggermente dietro. Dipendono invece dalla soglia la durata dei cluster lunghi e la fine nei cluster brevi: che G_{n} finisca dopo la maggior parte delle baseline vale con il 95-esimo percentile, non con il 99-esimo.

A.3 Curve precision–recall rispetto al cubo concordato

Da scrivere dopo la corsa: con il cubo concordato fisso (95-esimo percentile), per ogni metodo si varia la propria soglia e si calcolano precision e recall rispetto al cubo, anche contro il cubo senza il voto del metodo.

Bibliografia

[1] Stephan Rasp et al. «WeatherBench: A Benchmark Data Set for Data-Driven Weather Forecasting». In: *Journal of Advances in Modeling Earth Systems* 12.11 (2020), e2020MS002203. DOI: 10.1029/2020MS002203.

[2] J. Antonanzas et al. «Review of photovoltaic power forecasting». In: *Solar Energy* 136 (2016), pp. 78–111. DOI: 10.1016/j.solener.2016.06.069.

[3] Hans Hersbach et al. «The ERA5 global reanalysis». In: *Quarterly Journal of the Royal Meteorological Society* 146.730 (2020), pp. 1999–2049. DOI: 10.1002/qj.3803.

[4] Qihang Zhou et al. «Label-Free Multivariate Time Series Anomaly Detection». In: *IEEE Transactions on Knowledge and Data Engineering* 36.7 (2024), pp. 3166–3179. DOI: 10.1109/TKDE.2024.3349613. arXiv: 2312.11549.

[5] Leyan Deng et al. «Graph Convolutional Adversarial Networks for Spatiotemporal Anomaly Detection». In: *IEEE Transactions on Neural Networks and Learning Systems* 33.6 (2022), pp. 2416–2428. DOI: 10.1109/TNNLS.2021.3136171.

[6] Xingjian Shi et al. «Convolutional LSTM Network: A Machine Learning Approach for Precipitation Nowcasting». In: *Advances in Neural Information Processing Systems*. Vol. 28. Curran Associates, Inc., 2015. arXiv: 1506.04214.

[7] Nicolas Ballas et al. «Delving Deeper into Convolutional Networks for Learning Video Representations». In: *International Conference on Learning Representations (ICLR)*. 2016. arXiv: 1511.06432.

[8] Yarin Gal e Zoubin Ghahramani. «Dropout as a Bayesian Approximation: Representing Model Uncertainty in Deep Learning». In: *Proceedings of the 33rd International Conference on Machine Learning*. Vol. 48. Proceedings of Machine Learning Research. PMLR, 2016, pp. 1050–1059. arXiv: 1506.02142.

[9] Manish Gupta et al. «Outlier Detection for Temporal Data: A Survey». In: *IEEE Transactions on Knowledge and Data Engineering* 26.9 (2014), pp. 2250–2267. DOI: 10.1109/TKDE.2013.184.

[10] Zahra Zamanzadeh Darban et al. «Deep Learning for Time Series Anomaly Detection: A Survey». In: *ACM Computing Surveys* 57.1 (2024), pp. 1–42. DOI: 10.1145/3691338.

[11] Xingjian Wu et al. «CATCH: Channel-Aware Multivariate Time Series Anomaly Detection via Frequency Patching». In: *International Conference on Learning Representations (ICLR)*. 2025. arXiv: 2410.12261.

[12] Sarah Alnegheimish et al. «M^{2}AD: Multi-Sensor Multi-System Anomaly Detection through Global Scoring and Calibrated Thresholding». In: *Proceedings of the 28th International Conference on Artificial Intelligence and Statistics*. Vol. 258. Proceedings of Machine Learning Research. PMLR, 2025, pp. 4384–4392.

[13] Pankaj Malhotra et al. *LSTM-based Encoder-Decoder for Multi-sensor Anomaly Detection*. Presentato all'ICML 2016 Anomaly Detection Workshop. 2016. arXiv: 1607.00148.

[14] Kyle Hundman et al. «Detecting Spacecraft Anomalies Using LSTMs and Nonparametric Dynamic Thresholding». In: *Proceedings of the 24th ACM SIGKDD International Conference on Knowledge Discovery & Data Mining*. ACM, 2018, pp. 387–395. DOI: 10.1145/3219819.3219845.

[15] Jiehui Xu et al. «Anomaly Transformer: Time Series Anomaly Detection with Association Discrepancy». In: *International Conference on Learning Representations (ICLR)*. 2022. arXiv: 2110.02642.

[16] Ailin Deng e Bryan Hooi. «Graph Neural Network-Based Anomaly Detection in Multivariate Time Series». In: *Proceedings of the AAAI Conference on Artificial Intelligence*. Vol. 35. 5. 2021, pp. 4027–4035. DOI: 10.1609/aaai.v35i5.16523.

[17] Ian J. Goodfellow et al. «Generative Adversarial Nets». In: *Advances in Neural Information Processing Systems*. Vol. 27. Curran Associates, Inc., 2014. arXiv: 1406.2661.

[18] Thomas Schlegl et al. «Unsupervised Anomaly Detection with Generative Adversarial Networks to Guide Marker Discovery». In: *Information Processing in Medical Imaging (IPMI 2017)*. Vol. 10265. Lecture Notes in Computer Science. Springer, 2017, pp. 146–157. DOI: 10.1007/978-3-319-59050-9_12.

[19] Dan Li et al. «MAD-GAN: Multivariate Anomaly Detection for Time Series Data with Generative Adversarial Networks». In: *Artificial Neural Networks and Machine Learning – ICANN 2019: Text and Time Series*. Vol. 11730. Lecture Notes in Computer Science. Springer, 2019, pp. 703–716. DOI: 10.1007/978-3-030-30490-4_56.

[20] Renjie Wu e Eamonn J. Keogh. «Current Time Series Anomaly Detection Benchmarks are Flawed and are Creating the Illusion of Progress». In: *IEEE Transactions on Knowledge and Data Engineering* 35.3 (2023), pp. 2421–2429. DOI: 10.1109/TKDE.2021.3112126. arXiv: 2009.13807.

[21] Qinghua Liu e John Paparrizos. «The Elephant in the Room: Towards A Reliable Time-Series Anomaly Detection Benchmark». In: *Advances in Neural Information Processing Systems 37 (NeurIPS 2024), Datasets and Benchmarks Track*. Vol. 37. 2024, pp. 108231–108261. DOI: 10.52202/079017-3437.

[22] Peter Bauer, Alan Thorpe e Gilbert Brunet. «The quiet revolution of numerical weather prediction». In: *Nature* 525.7567 (2015), pp. 47–55. DOI: 10.1038/nature14956.

[23] Remi Lam et al. «Learning skillful medium-range global weather forecasting». In: *Science* 382.6677 (2023), pp. 1416–1421. DOI: 10.1126/science.adi2336.

[24] Yunjie Liu et al. *Application of Deep Convolutional Neural Networks for Detecting Extreme Weather in Climate Datasets*. 2016. arXiv: 1605.01156.

[25] Evan Racah et al. «ExtremeWeather: A large-scale climate dataset for semi-supervised detection, localization, and understanding of extreme weather events». In: *Advances in Neural Information Processing Systems*. Vol. 30. Curran Associates, Inc., 2017.

[26] Prabhat et al. «ClimateNet: an expert-labeled open dataset and deep learning architecture for enabling high-precision analyses of extreme weather». In: *Geoscientific Model Development* 14 (2021), pp. 107–124. DOI: 10.5194/gmd-14-107-2021.

[27] Pablo G. Zaninelli et al. «AI-Based Anomaly Detection for Extreme Event Attribution: An Analysis of European Heatwaves». In: *Earth Systems and Environment* 10 (2026), pp. 9949–9969. DOI: 10.1007/s41748-026-01122-6.

[28] Aytaç Paçal et al. «A multivariate analysis of atmospheric drivers for Western European heatwaves». In: *Earth System Dynamics* 17 (2026), pp. 955–986. DOI: 10.5194/esd-17-955-2026.

[29] Bing Yu, Haoteng Yin e Zhanxing Zhu. «Spatio-Temporal Graph Convolutional Networks: A Deep Learning Framework for Traffic Forecasting». In: *Proceedings of the Twenty-Seventh International Joint Conference on Artificial Intelligence (IJCAI-18)*. 2018, pp. 3634–3640. DOI: 10.24963/ijcai.2018/505.

[30] Kyunghyun Cho et al. «Learning Phrase Representations using RNN Encoder–Decoder for Statistical Machine Translation». In: *Proceedings of the 2014 Conference on Empirical Methods in Natural Language Processing (EMNLP)*. Association for Computational Linguistics, 2014, pp. 1724–1734. DOI: 10.3115/v1/D14-1179. arXiv: 1406.1078.

[31] Moloud Abdar et al. «A review of uncertainty quantification in deep learning: Techniques, applications and challenges». In: *Information Fusion* 76 (2021), pp. 243–297. DOI: 10.1016/j.inffus.2021.05.008.

[32] Balaji Lakshminarayanan, Alexander Pritzel e Charles Blundell. «Simple and Scalable Predictive Uncertainty Estimation using Deep Ensembles». In: *Advances in Neural Information Processing Systems*. Vol. 30. Curran Associates, Inc., 2017. arXiv: 1612.01474.

[33] Lingkai Kong, Jimeng Sun e Chao Zhang. «SDE-Net: Equipping Deep Neural Networks with Uncertainty Estimates». In: *Proceedings of the 37th International Conference on Machine Learning*. Vol. 119. Proceedings of Machine Learning Research. PMLR, 2020, pp. 5405–5415. arXiv: 2008.10546.

[34] Simone Monaco et al. «Uncertainty-aware methods for enhancing rainfall prediction with deep-learning based post-processing segmentation». In: *Computers & Geosciences* 205 (2025), p. 105992. DOI: 10.1016/j.cageo.2025.105992.

[35] Russ Rew e Glenn Davis. «NetCDF: An Interface for Scientific Data Access». In: *IEEE Computer Graphics and Applications* 10.4 (1990), pp. 76–82. DOI: 10.1109/38.56302.

[36] Charles R. Harris et al. «Array Programming with NumPy». In: *Nature* 585.7825 (2020), pp. 357–362. DOI: 10.1038/s41586-020-2649-2.

[37] Thomas Huld, Richard Müller e Attilio Gambardella. «A new solar radiation database for estimating PV performance in Europe and Africa». In: *Solar Energy* 86.6 (2012), pp. 1803–1815. DOI: 10.1016/j.solener.2012.03.006.

[38] Sepp Hochreiter e Jürgen Schmidhuber. «Long Short-Term Memory». In: *Neural Computation* 9.8 (1997), pp. 1735–1780. DOI: 10.1162/neco.1997.9.8.1735.

[39] Diederik P. Kingma e Jimmy Ba. «Adam: A Method for Stochastic Optimization». In: *International Conference on Learning Representations (ICLR)*. 2015. arXiv: 1412.6980.

[40] Arthur Gretton et al. «A Kernel Two-Sample Test». In: *Journal of Machine Learning Research* 13.25 (2012), pp. 723–773.

[41] Takuya Akiba et al. «Optuna: A Next-Generation Hyperparameter Optimization Framework». In: *The 25th ACM SIGKDD International Conference on Knowledge Discovery & Data Mining*. 2019, pp. 2623–2631. DOI: 10.1145/3292500.3330701.

[42] Adam Paszke et al. «PyTorch: An Imperative Style, High-Performance Deep Learning Library». In: *Advances in Neural Information Processing Systems*. Vol. 32. Curran Associates, Inc., 2019.

[43] Stephan Hoyer e Joe Hamman. «xarray: N-D labeled Arrays and Datasets in Python». In: *Journal of Open Research Software* 5.1 (2017), p. 10. DOI: 10.5334/jors.148.

[44] Wes McKinney. «Data Structures for Statistical Computing in Python». In: *Proceedings of the 9th Python in Science Conference*. 2010, pp. 56–61. DOI: 10.25080/Majora-92bf1922-00a.

[45] Pauli Virtanen et al. «SciPy 1.0: Fundamental Algorithms for Scientific Computing in Python». In: *Nature Methods* 17.3 (2020), pp. 261–272. DOI: 10.1038/s41592-019-0686-2.

[46] J. M. Lora, C. A. Shields e J. J. Rutz. «Consensus and Disagreement in Atmospheric River Detection: ARTMIP Global Catalogues». In: *Geophysical Research Letters* 47.20 (2020), e2020GL089302. DOI: 10.1029/2020GL089302.

[47] Christine A. Shields et al. «Atmospheric River Tracking Method Intercomparison Project (ARTMIP): project goals and experimental design». In: *Geoscientific Model Development* 11.6 (2018), pp. 2455–2474. DOI: 10.5194/gmd-11-2455-2018.

[48] Urs Neu et al. «IMILAST: A Community Effort to Intercompare Extratropical Cyclone Detection and Tracking Algorithms». In: *Bulletin of the American Meteorological Society* 94.4 (2013), pp. 529–547. DOI: 10.1175/BAMS-D-11-00154.1.

[49] Shebuti Rayana e Leman Akoglu. «Less is More: Building Selective Anomaly Ensembles». In: *ACM Transactions on Knowledge Discovery from Data* 10.4 (2016), pp. 1–33. DOI: 10.1145/2890508.

[50] Paul A. Ullrich et al. «TempestExtremes v2.1: a community framework for feature detection, tracking, and analysis in large datasets». In: *Geoscientific Model Development* 14.8 (2021), pp. 5023–5048. DOI: 10.5194/gmd-14-5023-2021.

[51] L. Mandonnet et al. «Accounting for exposure in 3D spatiotemporally contiguous heatwaves in Europe 1975–2024». In: *Climatic Change* 179.7 (2026), p. 144. DOI: 10.1007/s10584-026-04234-0.

[52] Ming Luo et al. «Anthropogenic forcing has increased the risk of longer-traveling and slower-moving large contiguous heatwaves». In: *Science Advances* 10.13 (2024), eadl1598. DOI: 10.1126/sciadv.adl1598.

[53] Ryan Lagerquist, Amy McGovern e David John Gagne II. «Deep Learning for Spatially Explicit Prediction of Synoptic-Scale Fronts». In: *Weather and Forecasting* 34.4 (2019), pp. 1137–1160. DOI: 10.1175/WAF-D-18-0183.1.

[54] Stella Bourdin et al. «Intercomparison of four algorithms for detecting tropical cyclones using ERA5». In: *Geoscientific Model Development* 15.17 (2022), pp. 6759–6786. DOI: 10.5194/gmd-15-6759-2022.

[55] Alexis Huet, Jose Manuel Navarro e Dario Rossi. «Local Evaluation of Time Series Anomaly Detection Algorithms». In: *Proceedings of the 28th ACM SIGKDD Conference on Knowledge Discovery and Data Mining*. KDD '22. ACM, 2022, pp. 635–645. DOI: 10.1145/3534678.3539339.

[56] Adam J. Clark et al. «Application of Object-Based Time-Domain Diagnostics for Tracking Precipitation Systems in Convection-Allowing Models». In: *Weather and Forecasting* 29.3 (2014), pp. 517–542. DOI: 10.1175/WAF-D-13-00098.1.

[57] Christopher Davis, Barbara Brown e Randy Bullock. «Object-Based Verification of Precipitation Forecasts. Part II: Application to Convective Rain Systems». In: *Monthly Weather Review* 134.7 (2006), pp. 1785–1795. DOI: 10.1175/MWR3146.1.

[58] Nicholas M. Leonardo e Brian A. Colle. «An Investigation of Large Along-Track Errors in Extratropical Transitioning North Atlantic Tropical Cyclones in the ECMWF Ensemble». In: *Monthly Weather Review* 148.1 (2020), pp. 457–476. DOI: 10.1175/MWR-D-19-0044.1.

[59] Tilmann Gneiting et al. «Calibrated Probabilistic Forecasting Using Ensemble Model Output Statistics and Minimum CRPS Estimation». In: *Monthly Weather Review* 133.5 (2005), pp. 1098–1118. DOI: 10.1175/MWR2904.1.

[60] Christian Leibig et al. «Leveraging uncertainty information from deep neural networks for disease detection». In: *Scientific Reports* 7 (2017), p. 17816. DOI: 10.1038/s41598-017-17876-z.

[61] Alex Kendall e Yarin Gal. «What Uncertainties Do We Need in Bayesian Deep Learning for Computer Vision?» In: *Advances in Neural Information Processing Systems*. Vol. 30. Curran Associates, Inc., 2017.

[62] Yaniv Ovadia et al. «Can You Trust Your Model's Uncertainty? Evaluating Predictive Uncertainty Under Dataset Shift». In: *Advances in Neural Information Processing Systems*. Vol. 32. Curran Associates, Inc., 2019.